APM 41033
-
Statistiques

Ce sujet est composé de 4 exercices indépendants.

1. L'exercice 1 correspond à des questions liées au cours.
2. Les exercices 2 et 3 suivants correspondent à des problèmes
3. L'exercice 4 est un QCM / questions à réponses courtes, portant sur les DM et EN

La durée de cet examen est de 3h. A titre très indicatif, il est recommandé de ne pas passer plus de $\sim$20 min sur l'exercice 1 (cours) et 15-20 min sur l'exercice 4 (DM / EN).

Si vous trouvez une erreur dans le sujet, merci de l'indiquer sur le sujet et de poursuivre votre composition.

Toutes les réponses doivent être justifiées, sauf dans l'exercice 4, dans lequel des réponses courtes et simples sont attendues.

Rappels / notations :

— Tout vecteur $u \in \mathbb{R}^p$ est identifié au vecteur colonne de ses coordonnées dans la base canonique.

— Pour toute matrice M, on note M^T sa transposée et, quand M est inversible, M^{-1} son inverse. La matrice identité est notée $\mathbf{I}$.

— Pour tout couple de vecteurs u, v de $\mathbb{R}^p$, on note $\langle u, v\rangle := u^T v$ leur produit scalaire canonique.

— L'ensemble des matrices symétriques définies positives est noté $\mathscr{S}_+$.

— Pour tout $a > 0$ et $b > 0$, on appelle $\Gamma(a,b)$ la loi sur $\mathbb{R}_+$ de densité par rapport à la mesure de Lebesgue

$$\gamma_{a,b}(x) := \frac{b^a}{\Gamma(a)} x^{a-1} \exp(-bx) \ .$$

Son espérance vaut a/b, sa variance a/b^2. Si $X_1, \ldots, X_n$ sont indépendants et de même loi $\Gamma(a,b)$, alors $\sum_{i=1}^n X_i$ suit la loi $\Gamma(na,b)$.

— Pour tout entier $p \geqslant 1$, la loi $\chi^2(p)$ à p degrés de liberté est la loi $\Gamma(p/2, 1/2)$.

— De la même façon, la loi Beta de paramètre (a,b) a pour densité sur $]0,1[$:

$$x \mapsto q_{a,b}(x) = \frac{x^{a-1}(1-x)^{b-1}}{B(a,b)},$$

dont l'espérance est donnée par $\frac{a}{a+b}$. Par ailleurs, on rappelle le lien entre loi Binomiale et loi Beta : pour tout entiers n, p, k, on a

$$\mathbb{P}\left(Bin(n,p) \geq k\right) = \mathbb{P}\left(\text{Beta}(k, n-k+1) \leq p\right).$$

— On rappelle que la transformée de Laplace d'une variable aléatoire Gaussienne standard $\xi \sim \mathrm{N}(0,1)$ est donnée par :

$$t \mapsto \mathbb{E}[e^{t\xi}] = e^{\frac{t^2}{2}}.$$

— Enfin, on rappelle que si ξ suit une loi $\mathrm{N}(0,1)$, alors $\mathrm{Var}(\xi^2) = 2$.

— Pour un n-échantillon i.i.d. $X_1, \ldots, X_n$, de densité f continue strictement positive sur $\mathbb{R}$, et fonction de répartition F, on rappelle le théorème central limite satisfait par l'estimateur empirique du quantile $\hat{q}_\alpha$ pour $\alpha \in (0,1)$:

$$\sqrt{n}(\hat{q}_\alpha - q_\alpha) \xrightarrow{d} \mathscr{N}(0, \frac{\alpha(1-\alpha)}{f^2(q_\alpha)}),$$

où $q_\alpha = F^{-1}(\alpha)$ et $\hat{q}_\alpha = X_{\lfloor n\alpha \rfloor}$ est la statistique d'ordre $\lfloor n\alpha \rfloor$ de l'échantillon $X_1, \ldots, X_n$, c'est à dire la $\lfloor n\alpha \rfloor$ valeur dans l'ordre croissant.

— on note $\xrightarrow{d}$ la convergence en distribution d'une suite de variables aléatoires.

— **Théorème central limite multivarié.** Soient $(X_i, Y_i)_{i \geqslant 1}$ une suite de variables aléatoires indépendantes et identiquement distribuées (i.i.d.), admettant une espérance $\mathbb{E}\begin{pmatrix} X_1 \\ Y_1 \end{pmatrix} = \begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}$ finie et une matrice de covariance $\mathrm{Var}\begin{pmatrix} X_1 \\ Y_1 \end{pmatrix} = \Sigma$ finie. On définit les moyennes empiriques $\overline{X}_n = \frac{1}{n}\sum_{i=1}^n X_i$, et $\overline{Y}_n = \frac{1}{n}\sum_{i=1}^n Y_i$. Alors, le **théorème central limite multivarié** donne que :

$$\sqrt{n}\begin{pmatrix} \overline{X}_n - \mu_X \\ \overline{Y}_n - \mu_Y \end{pmatrix} \xrightarrow{d} \mathscr{N}\left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \Sigma\right), \quad \text{quand } n \to \infty.$$

1 Exercice 1 : Questions de cours

On observe un n-échantillon $(X_1,\dots,X_n)$ du modèle statistique $\{\mathbb{R}_+,\mathscr{B}(\mathbb{R}_+),(p_\theta\cdot \mathrm{dLeb},\theta>0)\}$, où Leb est la mesure de Lebesgue sur $\mathbb{R}_+$ et

$$\forall x \geqslant 0, \qquad p_\theta(x) := \theta \exp(-\theta x) \ .$$

On admet que ce modèle est régulier.

1. Donner la borne de Cramer-Rao sur le risque quadratique d'un estimateur régulier sans biais de θ calculé à partir de $X_1,\dots,X_n$.
2. Soient θ_0,θ_1 deux réels strictement positifs tels que $\theta_1>\theta_0$. Déterminer le test de Neyman-Pearson de niveau $\alpha\in]0,1[$ de $H_0:\theta=\theta_0$ contre $H_1:\theta=\theta_1$. On explicitera en particulier la valeur du seuil en fonction d'un quantile d'une loi Gamma bien choisie.
3. (a) Donner la définition de la p-valeur ainsi que son expression dans le cadre ci dessus.
   (b) Expliquer en des termes simples l'intérêt et l'interprétation de la p-valeur. Par exemple, qu'indiquerait une p-valeur de 3% ?
   (c) Peut elle s'interpréter comme "la probabilité d'être sous Θ_0", "la probabilité d'être sous Θ_1", autre chose ?

2 Exercice 2 : Statistique pour la loi log-normale

On dit qu'une variable aléatoire X suit une loi log-normale de paramètres $\mu\in\mathbb{R}$ et $\sigma^2>0$, si $\ln X$ est distribuée comme une loi normale $\mathrm{N}(\mu,\sigma^2)$ de moyenne μ et de variance σ^2. On écrit alors $X\sim LN(\mu,\sigma^2)$. On a alors, de manière équivalente, $X=e^{\mu+\sigma\xi}$, où $\xi\sim\mathrm{N}(0,1)$ suit la loi Gaussienne standard. On admet que le modèle est régulier.

On observe un n-échantillon $(X_1,\dots,X_n)$ du modèle

$$(\mathbb{R},\mathscr{B}(\mathbb{R}),\{LN(\mu,\sigma^2),\theta:=(\mu,\sigma^2)\in\Theta:=\mathbb{R}\times\mathbb{R}_+^*\}) \ .$$

1. Soit $\mu\in\mathbb{R}$, $\sigma^2>0$ et $X\sim LN(\mu,\sigma^2)$. Déterminer le support S de X et montrer que sa densité par rapport à la mesure de Lebesgue sur $\mathbb{R}$ est donnée par :

$$x\mapsto p_{\mu,\sigma}(x)=\frac{e^{-(\ln x-\mu)^2/2\sigma^2}}{x\sqrt{2\pi\sigma^2}}\mathbf{1}_S(x).$$

2. Déterminer l'estimateur du maximum de vraisemblance $(\widehat{\mu}_{ML},\widehat{\sigma^2}_{ML})$ de (μ,σ^2).
3. Déterminer le biais et la variance de $\widehat{\mu}_{ML}$.
4. Déterminer le biais et la variance de $\widehat{\sigma^2}_{ML}$.
5. Soit $\alpha\in(0,1)$. Déterminer un intervalle de confiance non-asymptotique bilatéral pour σ^2 de niveau $1-\alpha$.
6. Démontrer que l'estimateur $(\widehat{\mu}_{ML},\widehat{\sigma^2}_{ML})$ est consistant.
7. Montrer que le vecteur d'estimateurs $(\widehat{\mu}_{ML},\widehat{\sigma^2}_{ML})$ est asymptotiquement normal et préciser la valeur de la moyenne et de la matrice de covariance limite, en fonction de μ et σ^2.

8. On note pour n impair $\tilde{X}_n$ la médiane de l'échantillon $(X_1,\dots,X_n)$. Donner un estimateur naturel de μ noté $\widehat{\mu}_{Med}$ dans ce contexte. Démontrer le théorème central limite

$$\sqrt{n}\,(\widehat{\mu}_{Med}-\mu) \xrightarrow{d} \mathcal{N}(0,C\sigma^2),$$

où C est une constante que l'on explicitera.

9. On définit

$$\widehat{m}_1 := \frac{1}{n}\sum_{i=1}^{n} X_i \qquad \text{et} \qquad \widehat{m}_2 := \frac{1}{n}\sum_{i=1}^{n} X_i^2.$$

   (a) Construire l'estimateur par la méthode des moments de (μ,σ^2), noté $(\widehat{\mu}_{Mom},\widehat{\sigma^2}_{Mom})$, associé aux statistiques $T_1(X)=X$ et $T_2(X)=X^2$.

   (b) Montrer que $(\widehat{m}_1,\widehat{m}_2)$ est un estimateur asymptotiquement normal de $(\mathbb{E}_\theta[X],\mathbb{E}_\theta[X^2])$. Calculer l'expression de la matrice de covariance limite en fonction de $\sigma^2, m_{1,\theta} := \mathbb{E}_\theta[X]$ et $m_{2,\theta} := \mathbb{E}_\theta[X^2]$.

   (c) Montrer que $\widehat{\mu}_{Mom}$ est un estimateur asymptotiquement normal de μ.

   On donnera une formule exacte et un développement limité de la variance limite quand $\sigma^2 \to 0$.

10. Discuter de l'intérêt de $\widehat{\mu}_{ML},\widehat{\mu}_{Med},\ \widehat{\mu}_{Mom}$. Asymptotiquement (par rapport à n), comment se classent les trois estimateurs, en particulier selon que $\sigma \to 0$ ou $\sigma \to \infty$?

3 Exercice 3 : apprentissage statistique

On considère un problème de classification binaire. On observe un échantillon i.i.d. $\mathscr{D}_n := \{(X_1,Y_1),\dots,(X_n,Y_n)\}$, où $X_i \in \mathscr{X} \subset \mathbb{R}^d$ et $Y_i \in \{-1,1\}$. La loi jointe de (X,Y) est notée $\mathbb{P}$ tandis que $\mathbb{E}$ est l'espérance associée. La fonction de régression η est donnée par :

$$\forall x \in \mathscr{X} \qquad \eta(x) := \mathbb{P}(Y=1|X=x).$$

On suppose :

(H_1) Le support de X, noté $\mathscr{X}$, est compact.

(H_2) La distribution de X possède une densité p_X par rapport à la mesure de Lebesgue qui est minorée et majorée sur son support :

$$\exists (c_-,c_+), \qquad \forall x \in \mathscr{X} : \qquad 0 < c_- \le p_X(x) \le c_+$$

et on note pour $x \in \mathscr{X}$ et $B(x,t)$ la boule de centre x et de rayon t la fonction F_x définie par $F_x(t) := \int_{B(x,t)} p_X(u)du = \mathbb{P}(X \in B(x,t))$.

(H_3) La fonction de régression η est L-Lipschitzienne.

On observe que la probabilité d'obtenir deux observations égales $X_i = X_j$ pour $i \neq j$ dans l'échantillon D_n est nulle. Pour tout classifieur $g : x \mapsto g(x) \in \{-1,1\}$, on définit le risque de classification en

$$R(g) = \mathbb{P}(g(X) \neq Y).$$

1. Démontrer que le classifieur bayésien est

$$g^*(x) := 2\mathbf{1}_{\{\eta(x)\ge 1/2\}} - 1.$$

On notera $R^* := R(g^*)$ le risque de ce classifieur bayésien.

2. Montrer que pour tout classifieur g,

$$R(g) - R^* = \mathbb{E}\left[|2\eta(X) - 1| \mathbf{1}_{\{g(X) \neq g^*(X)\}}\right].$$

3. On introduit un estimateur $\hat{\eta}$ de la fonction de régression et le classifieur obtenu par plug-in :

$$\hat{g}(x) := 2\mathbf{1}_{\{\hat{\eta}(x) \geq 1/2\}} - 1.$$

Démontrer que

$$R(\hat{g}) - R^* \leq 2\mathbb{E}[|\eta(X) - \hat{\eta}(X)|].$$

Dans les questions 4 à 7, le point $x \in \mathscr{X}$ est fixé. En notant $\mathbb{P}_n$ la loi sur l'ensemble d'apprentissage D_n, et $\mathbb{E}_n$ l'espérance associée, pour un classifieur $\hat{g}_n$ calculé à partir de D_n, on définit le risque de classification de $\hat{g}_n$ par $R(\hat{g}_n)$ et le risque de classification *moyen* de $\hat{g}_n$ par $\mathbb{E}_n[R(\hat{g}_n)]$.

4. On note $N_k(x)$ l'ensemble des indices des k plus proches voisins de x dans l'ensemble d'apprentissage $\{X_1, \ldots, X_n\}$ (pour la distance euclidienne). On définit alors

$$\hat{g}_{n,k}(x) = \begin{cases} 1 & \text{si le nombre de voisins dans } N_k(x) \text{ contient au moins la moitié de labels } Y = 1 \\ \text{-1} & \text{sinon.} \end{cases}$$

Démontrer que $\hat{g}_{n,k}$ est la méthode plug-in obtenue lorsque l'estimateur de la fonction de régression est définie par :

$$\hat{\eta}_{n,k}(x) := \frac{1}{k} \sum_{i \in N_k(x)} \mathbf{1}_{Y_i = 1} \quad .$$

5. Proposer une illustration graphique de cette méthode, avec $k = 3, n = 10$, et $d = 2$, ainsi que la valeur de la prédiction en quelques points de votre choix.

6. On définit $\mathfrak{R}_k(x)$ le rayon de la boule contenant les k plus proches voisins. démontrer que :

$$\forall x \in \mathscr{X} \quad \forall t > 0 : \qquad \mathbb{P}_n(\mathfrak{R}_k(x) \leq t) = \sum_{j=k}^{n} \binom{n}{j} F_x(t)^j (1 - F_x(t))^{n-j}.$$

En utilisant les rappels, identifier la loi de $U_k(x) := F_x(\mathfrak{R}_k(x))$.

7. En déduire via l'hypothèse (H_2) que :

$$\frac{1}{c_+ v_d} \frac{k}{n+1} \leq \mathbb{E}_n[\mathfrak{R}_k(x)^d] \leq \frac{1}{c_- v_d} \frac{k}{n+1},$$

où $v_d := \int_{B(0,1)} \mathrm{d}x$ est la mesure de Lebesgue de la boule unité Euclidienne de $\mathbb{R}^d$.

8. En utilisant une décomposition biais/variance, démontrer qu'il existe une constante C_d telle que :

$$\mathbb{E}_n\left[(\hat{\eta}_{n,k}(x) - \eta(x))^2\right] \leq C_d \left(\left(\frac{k}{n}\right)^{2/d} + \frac{1}{k} \right).$$

On donnera une expression de la constante C_d.

9. En déduire une borne sur risque moyen du classifieur des k plus proches voisins, c'est à dire une majoration de $\mathbb{E}_n[R(\hat{g}_{n,k})] - R^*$. Déterminer la valeur minimale de cette borne en k. Comment se comporte cette borne en grande dimension ?

4 Exercice 4 : QCM & questions aux réponses courtes sur ENs / DMs

1. Exceptionnellement, dans cet exercice, on ne demande pas de raisonnement détaillé, uniquement d'indiquer la bonne réponse. ou une explication claire et concise d'un phénomène. Les réponses libres doivent être en 1 ou 2 phrases maximum par question. (1 phrase $\rightarrow$ environ 20 mots au plus)
2. **NE PAS RENDRE LE SUJET. Indiquer vos réponses sur votre copie, par exemple *"Q0 - (a)"***
3. **Pour le QCM, une unique réponse par question est valide.** Toute réponse erronée au QCM rapportera -0.5.

Sur l'Exploration Numérique 1. On considère $t_1, \dots, t_n$ des réels tels que $\exists i \neq j, t_i \neq t_j$, ainsi que le modèle statistique

$$\left(\mathbb{R}^n, \mathscr{B}(\mathbb{R}^n), \left\{ p_\theta \cdot d\mathrm{Leb}^{\otimes n} := \bigotimes_{i=1}^{n} \mathscr{N}(\beta_1 + \beta_2 t_i, \sigma^2) : \theta := (\beta_1, \beta_2, \sigma^2) \in \mathbb{R}^2 \times \mathbb{R}_+^* \right\} \right).$$

Question 1. L'expression correcte de l'EMV $\hat{\beta}_2$ de β_2 est :

(a) $\hat{\beta}_2 = \dfrac{\sum_i X_i}{\sum_i t_i}$

(b) $\hat{\beta}_2 = \dfrac{\sum_i (t_i - \bar{t})(X_i - \bar{X})}{\sum_{i=1}^n (t_i - \bar{t})^2}$

(c) $\hat{\beta}_2 = \dfrac{\sum_i (t_i - \bar{X})(X_i - \bar{t})}{\sum_i t_i^2}$

(d) $\hat{\beta}_2 = \dfrac{\bar{X}}{\bar{t}}$

Question 2. Le nombre de degrés de liberté de l'estimateur $\hat{\sigma}^2$ (défini par la somme des carrés des résidus renormalisée) est :

(a) n (b) $n-1$ (c) $n-2$ (d) $n+1$

Question 3. Que doit-on attendre des résidus standardisés si le modèle linéaire simple est bien adapté ? Décrivez brièvement ce qui, sur les graphiques de résidus, indiquerait un mauvais ajustement du modèle.

Sur l'Exploration Numérique 2. On considère des observations $(X_1, \dots, X_n, Y_1, \dots, Y_p)$ issues du modèle statistique

$$\left(\mathbb{R}^{n+p}, \mathscr{B}(\mathbb{R}^{n+p}), \left\{ p_\theta \cdot d\mathrm{Leb}^{\otimes (n+p)} := \mathscr{N}(\mu_0, \sigma_0^2)^{\otimes n} \otimes \mathscr{N}(\mu_1, \sigma_1^2)^{\otimes p} : \theta := (\mu_0, \mu_1, \sigma_0^2, \sigma_1^2) \in \mathbb{R}^2 \times (\mathbb{R}_+^*)^2 \right\} \right),$$

Question 4. Le test de l'égalité des variances $\sigma_0^2 = \sigma_1^2$, qui utilise le rapport de vraisemblance généralisé, repose sur :

(a) Une loi du χ^2. (b) Un test de Student. (c) Une loi de Fisher. (d) Un test de Kolmogorov-Smirnov.

Question 5. Pour comparer les moyennes sous hypothèse de variances égales, la statistique du test est :

(a) $z = \dfrac{\bar{X}_n - \bar{Y}_p}{\sigma}$

(b) $t = \dfrac{\bar{X}_n - \bar{Y}_p}{\sqrt{s_X^2 + s_Y^2}}$ avec s_X^2, s_Y^2 les variances empiriques respectives de $(X_1, \dots, X_n)$ et $(Y_1, \dots, Y_p)$.

(c) $t = \dfrac{s_X^2 - s_Y^2}{\bar{X}_n - \bar{Y}_p}$

(d) $t = \dfrac{\bar{X}_n - \bar{Y}_p}{s_p \sqrt{\frac{1}{n} + \frac{1}{p}}}$ avec s_p^2 la variance empirique combinée.

Question 6. Expliquer pourquoi, lorsque l'on effectue plusieurs tests, une correction peut être nécessaire. Donner (en justifiant) un exemple de telle correction.

Sur l'exploration Numérique 3.

Question 7. Analyse en Composantes Principales (ACP)
On considère un ensemble de données $X \in \mathbb{R}^{n\times d}$, supposé centré colonne par colonne.

1. Expliquer brièvement (une phrase) l'objectif de l'Analyse en Composantes Principales (ACP).
2. Donner la clé de la formulation mathématique de ce procédé (une phrase).

Question 8. Comparaison entre LDA, QDA et Régression Logistique
Les modèles LDA, QDA et régression logistique peuvent tous être utilisés pour la classification binaire.

1. Indiquer les principales différences d'hypothèses entre ces trois méthodes.
2. Donner une situation (forme des données ou nature du bruit) où la QDA devrait mieux fonctionner que la LDA.

Sur le Devoir Maison 1. On se place dans le modèle de régression linéaire multiple

$$Y = Z\beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n),$$

où $Z \in \mathbb{R}^{n\times p}, \beta \in \mathbb{R}^p, \sigma^2 > 0$,

Question 9. Sous les hypothèses adéquates, l'estimateur des moindres carrés de β s'écrit :

(a) $\hat{\beta} = (Z^T Z)^{-1} Z^T Y$ (b) $\hat{\beta} = Z^T (ZZ^T)^{-1} Y$

(c) $\hat{\beta} = (ZZ^T)^{-1} Y$ (d) $\hat{\beta} = Z^{-1} Y$

Question 10. Dans le cas gaussien, sous P_θ, la loi de l'estimateur $\hat{\beta}$ est :

(a) $\hat{\beta} \sim \mathcal{N}(Z\beta, \sigma^2 I_n)$ (b) $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 (Z^T Z)^{-1})$

(c) $\hat{\beta} \sim \chi^2(n-p)$ (d) $\hat{\beta} \sim \mathcal{N}(\beta, \sigma^2 I_p)$

Question 11. Que peut on dire de $\hat{\beta}$ parmi les estimateurs sans biais ?

Question 12. Dans la partie pratique (O3, T12, Vx, Ne12), expliquer comment tester :

— si le vent Vx influence significativement O3,
— s'il existe un effet de la nébulosité,
— si O3 dépend conjointement de Vx et $T12$.

Décrire les hypothèses nulle/alternative et la nature de la statistique de test utilisée.