2 Solutions

2.1 Exercice 1

Dans cet exercice, on notera $Y_1, \cdots, Y_n$ les statistiques canoniques ; on utilisera les notations $\mathbf{Y} = (Y_1, \ldots, Y_n)^T$ et $\bar{Y} = n^{-1} \sum_{i=1}^n Y_i$.

La densité p_θ par rapport à la mesure $\mathrm{Leb}^{\otimes n}$ est donnée par

$$\begin{aligned} p_\theta(y_1, \cdots, y_n) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{1}{2\sigma^2}(y_i - \beta_1 - \beta_2 x_i)^2\right) \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^2\right). \end{aligned}$$

1. Nous avons
$$\mathbf{X^T X} = n \begin{bmatrix} 1 & n^{-1}\sum_{i=1}^n x_i \\ n^{-1}\sum_{i=1}^n x_i & n^{-1}\sum_{i=1}^n x_i^2 \end{bmatrix} .$$
Le déterminant de la matrice vaut $n^{-1}\sum_{i=1}^n x_i^2 - (n^{-1}\sum_{i=1}^n x_i)^2$. D'après l'inégalité de Cauchy-Schwarz,
$$\left(\frac{1}{n}\sum_{i=1}^n x_i\right)^2 \leq \frac{1}{n}\sum_{i=1}^n x_i^2 ,$$
autrement dit il est positive ou nul avec égalité si et seulement si $\underline{\mathbf{x}}$ et $\mathbf{1}$ sont colinéaires. Comme il existe deux indices i et j tels que $x_i \neq x_j$, l'inégalité de Cauchy-Schwarz est stricte. Ainsi, le déterminant est strictement positive et la matrice est inversible.

2. De l'expression de p_θ, on déduit que la vraisemblance est donnée par
$$\theta \mapsto L_n(\theta, Y_1, \ldots, Y_n) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 x_i)^2\right) ,$$
et définie sur $\mathbb{R}^2 \times \mathbb{R}_+^*$. Maximiser la vraisemblance étant équivalent à maximiser son logarithme,
$$\theta \mapsto C - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 x_i)^2 = C - \frac{n}{2}\ln\sigma^2 - \frac{1}{2\sigma^2}\left\|\mathbf{Y} - \mathbf{X}\beta\right\|^2 ,$$
on cherche tout d'abord la solution des équations de vraisemblance ; puis on discutera si la solution est un maximum ou pas. Les équations de vraisemblance s'écrivent
$$\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 x_i) = 0, \quad \sum_{i=1}^n x_i(Y_i - \beta_1 - \beta_2 x_i) = 0, \quad -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 x_i)^2 = 0 ;$$
les deux premières sont équivalentes à
$$\mathbf{X^T X}\beta = \mathbf{X^T Y}$$
dont on déduit que
$$\hat{\beta} = (\mathbf{X^T X})^{-1}\,\mathbf{X^T Y} ;$$

et la troisième est équivalente à

$$\widehat{\sigma^2} = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{\beta}_1 - \hat{\beta}_2 x_i)^2 = \frac{1}{n}\|\mathbf{Y} - \mathbf{X}\hat{\beta}\|^2 \ .$$

On vérifie que cette racine des équations de vraisemblance est un maximum de la fonction de log-vraisemblance, en prenant les limites en $\pm\infty$ pour β_i et en $0, +\infty$ pour σ^2.

`Remarques` Pour la suite de l'exercice, il est important de remarquer

— Les coefficients (β_1, β_2) ont été déterminés comme résolvant

$$\text{argmin}_{(\beta_1,\beta_2)\in\mathbb{R}^2}\|\mathbf{Y} - \beta_1\mathbf{1} - \beta_2\underline{\mathbf{x}}\|^2$$

montrant que $\hat{\beta}_1\mathbf{1} + \hat{\beta}_2\underline{\mathbf{x}}$ est le projeté orthogonal de $\mathbf{Y}$ sur l'espace vectoriel engendré par $(\mathbf{1}, \underline{\mathbf{x}})$, les colonnes de $\mathbf{X}$. D'après la première question, on sait que cet espace est de dimension 2.

— Par suite, on a

$$\mathbf{X}\hat{\beta} = \mathbf{X}(\mathbf{X^T X})^{-1}\ \mathbf{X^T Y} = P\mathbf{Y},$$

où P est le projecteur sur l'espace vectoriel engendré par $\mathbf{1}$ et $\underline{\mathbf{x}}$, les colonnes de $\mathbf{X}$. Avec cette notation P, on en déduit l'expression de $\hat{\sigma}^2$

$$\widehat{\sigma^2} = \frac{1}{n}\|(I - P)\mathbf{Y}\|^2;$$

qui montre que $\widehat{\sigma^2}$ est lié à la norme au carré de "la partie résiduelle de $\mathbf{Y}$, c'est-à-dire la partie de $\mathbf{Y}$ qui n'est pas expliquée par les colonnes de $\mathbf{X}$".

3. On a établi que

$$\begin{bmatrix}\hat{\beta}_1\\ \hat{\beta}_2\end{bmatrix} = (\mathbf{X^T X})^{-1}\ \mathbf{X^T Y} \qquad \text{est de la forme } A\mathbf{Y}.$$

Sous $p_\theta \cdot \text{dLeb}^{\otimes n}$, le vecteur $\mathbf{Y}$ est un vecteur gaussien, d'espérance $\mathbf{X}\beta$ et de matrice de covariance $\sigma^2 I_n$. Par suite, le vecteur $\begin{bmatrix}\hat{\beta}_1\\ \hat{\beta}_2\end{bmatrix}$ est encore un vecteur gaussien. Son espérance est

$$A\mathbf{X}\beta = \beta;$$

L'estimateur est sans biais. La matrice de covariance est donnée par

$$\sigma^2 AA^T = \sigma^2(\mathbf{X^T X})^{-1} \ .$$

4. Sous $p_\theta \cdot \text{dLeb}^{\otimes n}$, $\begin{bmatrix}\hat{\beta}_1\\ \hat{\beta}_2\end{bmatrix}$ est un vecteur gaussien. Les composantes sont indépendantes ssi la matrice de covariance est diagonale. Le calcul de l'inverse de cette matrice 2×2 montre que la covariance est diagonale ssi $n^{-1}\sum_{i=1}^{n} x_i = 0$.

5. Nous avons remarqué plus haut que $\widehat{\sigma^2} = n^{-1}\|(I-P)\mathbf{Y}\|^2$ où P est une matrice de projection sur un espace vectoriel de dimension 2. Donc $(I-P)$ est la projection sur l'espace orthogonal, de dimension $n-2$. Puisque sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$, $\mathbf{Y}$ est un vecteur gaussien, alors $(I-P)\mathbf{Y}$ est aussi un vecteur gaussien. Son espérance est

$$\mathbb{E}_\theta\left[(I-P)\mathbf{Y}\right] = (I-P)\mathbf{X}\beta = 0_{\mathbb{R}^n},$$

puisqu'on projette un élement de l'espace vectoriel engendré par les colonnes de $\mathbf{X}$, sur l'espace orthogonal ; et sa matrice de covariance est

$$\mathrm{Cov}_\theta\left((I-P)\mathbf{Y}\right) = \sigma^2(I-P)(I-P)^T = \sigma^2(I-P);$$

dans le calcul précédent on a utilisé que P est symétrique et que comme tout projecteur, $(I-P)^2 = I-P$. Puisque $(I-P)$ est un projecteur sur un espace de dimension $(n-2)$, il est de la forme $Q\Delta Q^T$ où Q est une matrice orthogonale et Δ est une matrice diagonale avec $n-2$ éléments diagonaux valant 1 et les 2 autres sont nuls. Puisqu'une transformation par matrice orthogonale ne change pas la norme, nous avons

$$\|Q^T(I-P)\mathbf{Y}\| = \|(I-P)\mathbf{Y}\|.$$

Nous savons par ailleurs que sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$,

$$Q^T(I-P)\mathbf{Y} \sim \mathcal{N}_n\left(0; \sigma^2\,\Delta\right).$$

Nous en déduisons que sous $p_\theta\,\mathrm{dLeb}^{\otimes n}$,

$$\frac{n}{\sigma^2}\widehat{\sigma^2} \sim \chi^2(n-2).$$

6. Nous avons vu que $\widehat{\sigma^2}$ est une fonction (déterministe) de $(I-P)\mathbf{Y}$.
Par ailleurs, puisque $\mathbf{X}\hat{\beta} = P\mathbf{Y}$, $(\hat{\beta}_1, \hat{\beta}_2)$ est une fonction déterministe de $P\mathbf{Y}$:

$$\mathbf{X^T}\mathbf{X}\hat{\beta} = \mathbf{X^T}P\mathbf{Y} \qquad \hat{\beta} = (\mathbf{X^T}\mathbf{X})^{-1}\mathbf{X^T}P\mathbf{Y}.$$

Or, sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$, $(I-P)\mathbf{Y}$ et $P\mathbf{Y}$ sont des vecteurs gaussiens (et le premier est centré) ; de plus, ils sont décorrélés puisque

$$\mathbb{E}_\theta\left[(I-P)\mathbf{Y}\mathbf{Y^T}P\right] = \sigma^2(I-P)P = 0_{\mathbb{R}^n}.$$

Donc ils sont indépendants. D'où l'indépendance de $\widehat{\sigma^2}$ et de $\hat{\beta}$.

7. Nous avons établi que sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$,

$$n\frac{\widehat{\sigma^2}}{\sigma^2} \sim \chi^2(n-2).$$

En notant $q^{n-2}_{\alpha/2}$ et $q^{n-2}_{1-\alpha/2}$ les quantiles d'ordre $\alpha/2$ et $1-\alpha/2$ d'une loi du χ^2 à $(n-2)$ degrés de liberté, nous avons

$$\mathbb{P}_\theta\left(q^{n-2}_{\alpha/2} \le n\frac{\widehat{\sigma^2}}{\sigma^2} \le q^{n-2}_{1-\alpha/2}\right) = 1-\alpha,$$

ou de façon équivalente

$$\mathbb{P}_\theta\left(n\frac{\widehat{\sigma^2}}{q^{n-2}_{1-\alpha/2}} \leq \sigma^2 \leq n\frac{\widehat{\sigma^2}}{q^{n-2}_{\alpha/2}}\right) = 1-\alpha.$$

Par suite l'intervalle **aléatoire**

$$\left[n\frac{\widehat{\sigma^2}}{q^{n-2}_{1-\alpha/2}}; n\frac{\widehat{\sigma^2}}{q^{n-2}_{\alpha/2}}\right]$$

est un intervalle de confiance de niveau $1-\alpha$ pour σ^2.

2.2 Exercice 2

Préliminaire. Calcul de la fonction de répartition. Soit $\theta \in]0,1[$. On considère $t \in \mathbb{R}$ et on note $F_\theta(t) = \mathbb{P}_\theta(X \leq t)$. Clairement,

$$\forall t \leq 0 \qquad F_\theta(t) = 0, \qquad \forall t \geq b, F_\theta(t) = 1.$$

Puis, en considérant les tirages possibles de la première loi uniforme $\mathcal{U}_{[0,a]}$ ou la seconde loi uniforme $\mathcal{U}_{[0,b]}$, on a :

$$\forall t \in [0,a] \qquad F_\theta(t) = \mathbb{P}_\theta(X \leq t) = \theta\frac{t}{a} + (1-\theta)\frac{t}{b}.$$

Enfin

$$\forall t \in [a,b] \qquad F_\theta(t) = \theta + (1-\theta)\frac{t}{b}.$$

1. En reprenant l'expression précédente, on remarque que

$$\forall t \in \mathbb{R} \qquad f_\theta(t) = \left[\frac{\theta}{a} + \frac{1-\theta}{b}\right]\mathbf{1}_{t\in[0,a]} + \left[\frac{1-\theta}{b}\right]\mathbf{1}_{t\in[a,b]}.$$

   Aussi, la vraisemblance s'écrit

$$\begin{aligned} L(\theta, X_1, \ldots, X_n) &= \prod_{i=1}^{n}\left(\left[\frac{\theta}{a} + \frac{1-\theta}{b}\right]\mathbf{1}_{X_i\in[0,a]} + \left[\frac{1-\theta}{b}\right]\mathbf{1}_{X_i\in[a,b]}\right) \\ &= \left[\frac{\theta}{a} + \frac{1-\theta}{b}\right]^{N_a}\left[\frac{1-\theta}{b}\right]^{n-N_a}. \end{aligned}$$

2. On calcule la log-vraisemblance (normalisée i.e. en divisant par le nombre total d'observations ; ce qui ne change rien à ses optima) et on obtient que

$$\ell(\theta, X_1, \ldots, n) = \frac{N_a}{n}\log\left[\frac{\theta}{a} + \frac{1-\theta}{b}\right] + \frac{(n-N_a)}{n}\log\left[\frac{1-\theta}{b}\right].$$

   Vu comme une fonction définie sur $\mathbb{R}$, la dérivée par rapport à θ est

$$\frac{N_a\, b - na - \theta n(b-a)}{(1-\theta)(a+\theta(b-a))}.$$

   Sur $]0,1[$, le dénominateur est strictement positif. Posons

$$\hat{\theta}_n = \frac{bN_a - na}{n(b-a)} = \frac{b(N_a/n) - a}{b-a}.$$

   qui est le point qui annule le numérateur. Notons que $\mathbb{P}_\theta(\hat{\theta}_n \leq 1) = 1$. Pour le numérateur :

   — soit $\hat{\theta}_n > 0$: c'est l'unique racine de la dérivée dans $]0,1[$, et la dérivée est positive pour $\theta \in \left]0, \hat{\theta}_n\right[$ et négative sinon. Donc le maximum est atteint en $\hat{\theta}_n$.

   — soit $\hat{\theta}_n \leq 0$, et dans ce cas, la dérivée est négative sur $]0,1[$. Donc le maximum est atteint en $\theta = 0$.

Par suite, on voit que le maximum sur $]0,1[$ de la log-vraisemblance est

$$\hat{\theta}_n^{(1)} = \hat{\theta}_n \vee 0.$$

Remarque sur le biais de l'estimateur. En observant que sous $\mathbb{P}_\theta$, N_a suit une loi binomiale de paramètres $(n, \theta + (1-\theta)a/b)$, on en déduit que

$$\mathbb{E}_\theta\left[\hat{\theta}_n\right] = \theta$$

et donc cet estimateur est sans biais. De plus, $\mathbb{P}_\theta(\hat{\theta}_n \leq 0) = \mathbb{P}_\theta(N_a/n \leq a/b)$ et cette probabilité tend vers zero puisque sous $\mathbb{P}_\theta$, la loi des grands nombres indique que

$$\mathbb{P}_\theta(\lim_n N_a/n = (1-\theta)a/b + \theta) = 1$$

donc la v.a. N_a/n converge presque-sûrement vers un point de l'intervalle $]a/b, 1[$.

3. On calcule l'espérance de X sous $f_\theta \cdot \mathrm{dLeb}$ et on trouve

$$\mathbb{E}_\theta[X] = \theta\frac{a}{2} + (1-\theta)\frac{b}{2}. \tag{3}$$

Aussi, l'estimateur des moments est obtenu en résolvant l'équation

$$\theta \text{ tel que } \theta\frac{a}{2} + (1-\theta)\frac{b}{2} = \frac{S_n}{n}, \tag{4}$$

où on a noté $S_n = \sum_{i=1}^n X_i$. Cette équation a-t-elle toujours une solution $\theta \in]0,1[$? Puisque $\mathbb{P}_\theta(X_i \in [0,b]) = 1$, on a $\mathbb{P}_\theta(S_n/n \in [0,b]) = 1$; la loi des grands nombres dit que $\mathbb{P}_\theta(\lim_n S_n/n \in]a/2, b/2[) = 1$ (voir (3)). Donc à n fixé, rien ne garantit que S_n/n soit dans $]a/2, b/2[$ et donc qu'il puisse s'écrire comme un barycentre des deux extremités de cet intervalle.
Posons

$$\tilde{\theta}_n = \frac{b - \frac{2S_n}{n}}{b-a} = 2\left(\frac{b/2 - \frac{S_n}{n}}{b-a}\right),$$

qui résout l'équation (4). On peut poser comme estimateur

$$\hat{\theta}_n^{(2)} = \begin{cases} 0 & \text{si } \tilde{\theta}_n \leq 0 \\ 1 & \text{si } \tilde{\theta}_n \geq 1 \\ \tilde{\theta}_n \text{ sinon} & \end{cases}$$

Remarque sur le biais de l'estimateur : On vérifie facilement que (exploiter (4) par exemple)

$$\mathbb{E}_\theta[\tilde{\theta}_n] = \theta,$$

c'est-à-dire l'estimateur $\tilde{\theta}_n$ est sans biais.

▶ **Analyse numérique.** On prend $a = 1$ et $b = 3$. • Sur la figure 3, on trace la densité et la fonction de répartition. Pour θ fixé, la densité est constante par morceaux et pour x fixé, c'est une fonction croissante de θ sur $[0,a]$ et décroissante sur $[a,b]$.
• On simule $n_{\max} = 200$ réalisations de la loi mélange de paramètre $\theta_{\text{true}} = 0.2$. Sur la

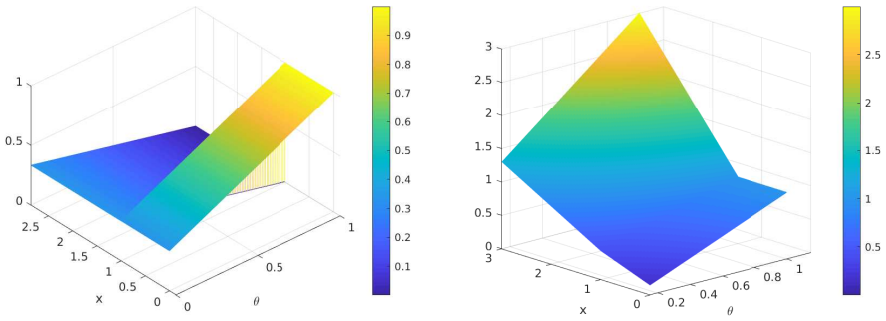


FIGURE 3 – Densité et fonction de répartition pour différentes valeurs de θ dans $]0,1[$

figure 4, on trace la vraisemblance calculée à partir des $n = 10$ premières observations, puis des $n = 200$ observations. Sur le premier jeu de données de taille $n = 10$, nous observons $N_a/n = 0.3000$ et sur le second de taille $n = 200$, nous observons $N_a/n = 0.5250$. Dans le premier cas (courbe en trait continue), on voit que le maximum est atteint sur le bord en $\theta = 0$; et dans le second cas (courbe en traits pointillés), le maximum est atteint dans $]0,1[$. Dans ce second cas, l'estimateur du maximum de vraisemblance est bien défini et on pourra observer qu'il diffère de θ_{true}.

- Toujours en utilisant ce jeu de données simulées : sur la figure 5, on trace l'application

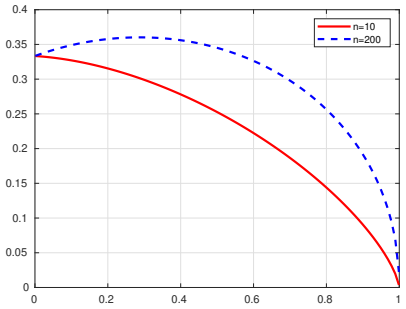


FIGURE 4 – Tracé de deux réalisations de la fonction de vraisemblance $\theta \mapsto L(\theta, X_1, \cdots, X_n)$: une pour $n = 10$ puis une pour $n = 200$.

$\theta \mapsto \theta a/2 + (1-\theta)b/2 - S_n/n$ dans le cas $n = 10$ puis $n = 200$. Noter que cette fonction dépendant des réalisations via S_n, elle est aléatoire. L'estimateur des moments (basé sur le moment d'ordre 1) existe si cette courbe admet un zero. Dans le cas $n = 10$, on voit que la racine est négative (le zero est atteint en $\theta < 0$) ; tandis que dans le cas $n = 200$, l'estimateur existe et est unique. Là encore, il diffère de θ_{true}.

- Sur la figure 6, nous traçons le biais de l'estimateur

$$\theta \mapsto \mathbb{E}_\theta\left[\hat{\theta}_n^{(1)}\right] - \theta.$$

Le calcul de l'espérance utilise le fait que sous $\mathbb{P}_\theta$, N_a suit une loi binomiale de paramètre

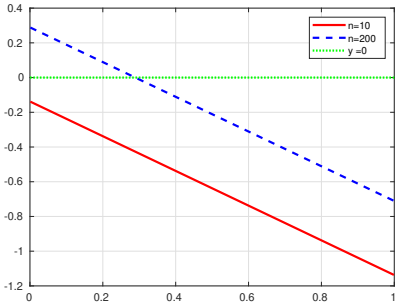


FIGURE 5 – Tracé de deux réalisations de la fonction (aléatoire) dont l'estimateur des moments est un zero : une dans le cas $n = 10$ et l'autre dans le cas $n = 200$.

$(n, \theta + (1-\theta)a/b)$; puis on exploite la formule

$$\mathbb{E}_\theta\left[\hat{\theta}_n^{(1)}\right] = \left(b\frac{\mathbb{E}_\theta[N_a \mathbb{1}_{N_a \geq na/b}]}{n} - a\mathbb{P}_\theta(N_1 \geq na/b)\right)(b-a)^{-1},$$

On affiche le biais dans le cas $n = 10$ et $n = 200$. On observe que ce biais est d'autant moins important que n est grand.

• Nous terminons ces analyses en répétant l'expérience $N = 5000$ fois : nous produisons N

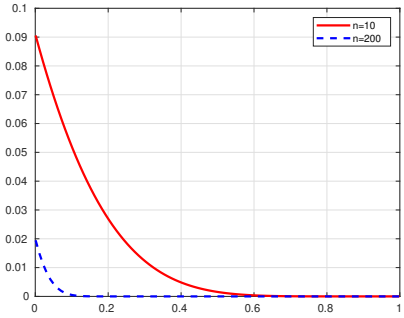


FIGURE 6 – Evolution du biais de l'estimateur $\hat{\theta}_n^{(1)}$ en fonction de θ. Dans le cas $n = 10$ et $n = 200$.

jeux de données de longueur $n = 200$, en utilisant le paramètre $\theta_{\text{true}} = 0.2$. Tout d'abord, pour chaque jeu de données, nous calculons $\hat{\theta}_n$, $\hat{\theta}_n^{(1)}$, $\tilde{\theta}_n$, $\hat{\theta}_n^{(2)}$ sur les $n = 10$ premières réalisations ; on affiche les boxplots de ces N réalisations indépendantes sur la figure 2 (gauche). On fait de même mais cette fois en utilisant les $n = 200$ réalisations pour chacun des jeux de données ; les boxplots sont sur la figure 2(droite). On fera attention aux échelles de l'ordonnée pour comparer le graphe de gauche et celui de droite. On notera que, logiquement, les estimateurs MV-2 et Mom-2 ne prennent que des valeurs dans $]0, 1[$. Enfin, la comparaison de MV-1/MV-2 d'une part, et de Mom-1/Mom-2 d'autre part, montre que (i) dans le cas $n = 10$, l'effet de seuillage dans $]0, 1[$ survient assez souvent ; (ii) dans le cas $n = 200$, il ne se réalise que sur Mom-1/Mom-2 parmi ces $N = 5000$ réalisations des estimateurs.

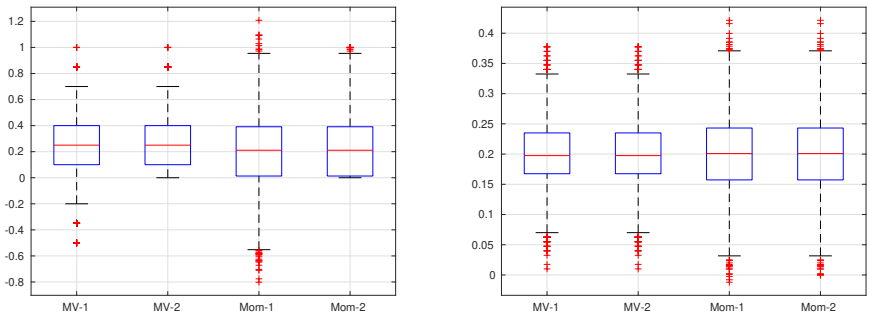


FIGURE 7 – Boxplot de la réalisation de $N = 5000$ estimateurs dans le cas $n = 10$ (gauche) et $n = 200$ (droite). Les boxplots MV-1 et MV-2 correspondent resp. à $\hat{\theta}_n$ et $\hat{\theta}_n^{(1)}$; ceux de Mom-1 et Mom-2 correspondent à $\tilde{\theta}_n$ et $\hat{\theta}_n^{(2)}$.

2.3 Exercice 3

1. (a) Posons $T(x) = -x$ et $h(x) = 1$; μ est la mesure de Lebesgue sur $\mathbb{R}_+$. On a alors pour tout $\eta > 0$,
$$\exp(A(\eta)) = \int_{\mathbb{R}_+} \exp(-\eta x)\mathrm{d}x = \frac{1}{\eta}.$$
On vérifie bien que $x \mapsto \eta \exp(-\eta x)\mathbb{1}_{\mathbb{R}_+}(x)$ est égale à $x \mapsto h(x)\exp(\eta T(x) - A(\eta))$. Noter que $\Xi =]0, +\infty[$.

(b) La densité de la loi est
$$x \mapsto \frac{1}{\sqrt{2\pi}} \exp(-0.5(x-\eta)^2) = \frac{1}{\sqrt{2\pi}} \exp(-0.5\left(x^2 + \eta^2 - 2x\eta\right)).$$
Posons $T(x) = x$ et $h(x) = \frac{1}{\sqrt{2\pi}} \exp(-0.5x^2)$; μ est la mesure de Lebesgue sur $\mathbb{R}$. On a alors pour tout $\eta \in \mathbb{R}$,
$$\exp(A(\eta)) = \frac{1}{\sqrt{2\pi}} \int \exp(-0.5(x^2 - 2\eta x))\mathrm{d}x = \exp(0.5\eta^2).$$
On vérifie bien que $x \mapsto \frac{1}{\sqrt{2\pi}} \exp(-0.5(x-\eta)^2)$ est égale à $x \mapsto h(x)\exp(\eta T(x) - A(\eta))$; noter que $\Xi = \mathbb{R}$.

(c) La densité s'écrit
$$x \mapsto \alpha x^{\alpha-1} \lambda^{-\alpha} \exp(-x^\alpha \lambda^{-\alpha}) \mathbb{1}_{x>0}$$
Le paramètre naturel serait donc plutôt $\lambda^{-\alpha} \in \mathbb{R}_+^\star$. Par suite, ce n'est pas un modèle exponentiel *canonique* ; il s'agit d'un modèle exponentiel général.

(d) La loi de Poisson est un modèle exponentiel par rapport à la mesure de comptage sur $\mathbb{N}$. On a pour tout $k \in \mathbb{N}$
$$\frac{\theta^k}{k!} \exp(-\theta) = \frac{1}{k!} \exp\left(k \ln\theta - \theta\right).$$
Posons
$$\phi(\theta) = \ln\theta \qquad T(x) = x \qquad h(x) = \frac{1}{x!} \qquad B(\theta) = \theta \qquad \Theta =]0, +\infty[\,.$$
On peut se ramener à un modèle exponentiel canonique par reparamétrisation : $\eta = \ln\theta$; auquel cas $A(\eta) = B(\exp(\eta)) = \exp(\eta)$.

(e) Pour tout $k \in \{0, \cdots, n\}$, on a
$$p_\theta(k) = \frac{n!}{k!(n-k)!}\theta^k(1-\theta)^{n-k} = \frac{n!}{k!(n-k)!} \exp\left\{k \ln\left(\frac{\theta}{1-\theta}\right) + n\ln(1-\theta)\right\}.$$
Posons
$$\phi(\theta) = \ln\left(\frac{\theta}{1-\theta}\right) \qquad B(\theta) = -n\ln(1-\theta) \qquad T(x) = x \qquad \Theta =]0,1[\,, \quad h(x) = \frac{n!}{x!(n-x)!}$$
On peut se ramener au modèle exponentiel canonique par reparamétrisation
$$\eta = \ln\left(\frac{\theta}{1-\theta}\right) \qquad \text{i.e. } \theta = \frac{\exp(\eta)}{1+\exp(\eta)}.$$

2. (a) On a
$$A'(\eta) = \int T(x) q_\eta(x) \mu(\mathrm{d}x) = \mathbb{E}_\eta \left[T(X) \right]$$
et
$$A''(\eta) = \mathrm{Var}_\eta(T(X)).$$

(b) Soient $\eta_1, \eta_2 \in \Xi$; et $\lambda \in]0,1[$. Montrons que $\lambda\eta_1 + (1-\lambda)\eta_2 \in \Xi$. On a en utilisant l'inégalité de Hölder
$$\begin{aligned} A(\lambda\eta_1 + (1-\lambda)\eta_2) &= \log \int h(x) \exp\left(\{\lambda\eta_1 + (1-\lambda)\eta_2\} T(x) \right) \mu(\mathrm{d}x) \\ &= \log \int \exp\left(\lambda\eta_1 T(x)\right) \ \exp((1-\lambda)\eta_2 T(x)) \ h(x) \ \mu(\mathrm{d}x) \\ &\leq \lambda \log \left(\int \exp\left(\eta_1 T(x)\right) \ h(x) \ \mu(\mathrm{d}x) \right) \\ &+ (1-\lambda) \log \left(\int h(x) \exp\left(\eta_2 T(x)\right) \ h(x) \ \mu(\mathrm{d}x) \right) \\ &\leq \lambda A(\eta_1) + (1-\lambda) A(\eta_2). \end{aligned} \tag{5}$$

On en déduit que
$$A(\lambda\eta_1 + (1-\lambda)\eta_2) \leq \lambda \left| A(\eta_1) \right| + (1-\lambda) \left| A(\eta_2) \right| ;$$
cela entraine $A(\eta) < +\infty$ puisque $\eta_1, \eta_2 \in \Xi$. Puisque Ξ est non vide, il existe $\eta_\star$ tel que $\exp(A(\eta_\star))) > 0$: cela entraine que
$$\mu\left(\{ x \in \mathsf{X} : h(x) > 0 \} \right) > 0.$$
Donc pour tout $\eta \in \mathbb{R}$, en notant que $\exp(\eta T(x)) > 0$, on a
$$\exp(A(\eta)) \geq \int_{h>0} \exp(\eta T(x)) \, h(x) \, \mu(\mathrm{d}x) > 0.$$
Il vient que $A(\eta) > -\infty$ pour tout $\eta \in \mathbb{R}$.
Ainsi $|A(\lambda\eta_1 + (1-\lambda)\eta_2)| < \infty$ ce qui montre que $\lambda\eta_1 + (1-\lambda)\eta_2 \in \Xi$.
Notons que la convexité de la fonction A a été établie par l'inégalité (5).

(c) Soit $\eta \in \Xi$; puisque Ξ est ouvert, il existe $\varepsilon > 0$ tel que $\eta + \varepsilon \in \Xi$ et $\eta - \varepsilon \in \Xi$. Notons que
$$\exp\left(\varepsilon |T(x)|\right) \leq \exp\left(\varepsilon T(x)\right) + \exp\left(-\varepsilon T(x)\right)$$
ce qui entraine
$$\int h(x) \ \exp(\varepsilon |T(x)|) \exp(\eta T(x)) \, \mu(\mathrm{d}x) < \infty. \tag{6}$$
Noter que (6) entraine aussi pour tout $k \geq 0$,
$$\int h(x) \ |T(x)|^k \ \exp(\eta T(x)) \, \mu(\mathrm{d}x) < \infty. \tag{7}$$

On écrit, pour tout s tel que $|s| < \varepsilon/2$,

$$\frac{G(\eta+s)-G(\eta)}{s} = \int h(x)\frac{\exp(sT(x))-1}{s}\,\exp(\eta T(x))\mu(\mathrm{d}x)$$

et on vérifie les hypothèses du théorème de convergence dominée. Quand $s \to 0$, $\{\exp(sT(x))-1\}/s \to T(x)$. De plus, par le théorème des accroissements finis,

$$\left|\frac{\exp(sT(x))-1}{s}\right| \leq |T(x)|\exp(\varepsilon\,|T(x)|/2)$$

et ce terme est majoré, pour tout x, par $C\,\exp(\varepsilon|T(x)|)$. On a donc, en utilisant (6), que pour tout $|s| \leq \varepsilon/2$,

$$\int h(x)\left|\frac{\exp(sT(x))-1}{s}\right|\exp(\eta T(x))\mu(\mathrm{d}x) \leq C\int |g(x)|\,\exp(\varepsilon|T(x)|)\,\exp(\eta T(x))\mu(\mathrm{d}x) < \infty.$$

On en conclut que

$$G'(\eta) = \lim_{s\to 0}\frac{G(\eta+s)-G(\eta)}{s} = \int h(x)T(x)\,\exp(\eta T(x))\mu(\mathrm{d}x).$$

On termine par récurrence : on répète le raisonnement avec $h(x) \leftarrow h(x)|T|^k(x)$ pour établir la propriété au rang $(k+1)$.

(d) Nous avons $G(\eta) = \exp(A(\eta))$: on en déduit que la fonction $\eta \mapsto \exp(A(\eta))$ est infiniment différentiable sur Ξ. En particulier,

$$G'(\eta) = A'(\eta)\;\exp(A(\eta)) = \int h(x)T(x)\exp(\eta T(x)\mu(\mathrm{d}x)$$

soit encore

$$A'(\eta) = \int T(x)\,q_\eta(x)\,\mu(\mathrm{d}x).$$

Sous modèle $q_\eta\,\mathrm{d}\mu$, les v.a. $(X_k)_k$ sont i.i.d. de loi $q_\eta\,\mathrm{d}\mu$ ce qui entraine que

$$A'(\eta) = \mathbb{E}_\eta\left[T(X_1)\right] \text{ en ayant posé } \mathbb{E}_\eta\left[T(X_1)\right] := \int T(x)\;q_\eta(x)\mathrm{d}\mu(x).$$

L'estimateur des moments associé à la fonction T est donc l'estimateur solution de

$$\eta: \qquad A'(\eta) = \frac{1}{n}\sum_{k=1}^n T(X_k).$$

(e) Sous modèle $q_\eta\,\mathrm{d}\mu$, les v.a. $(X_k)_k$ sont i.i.d. de loi $q_\eta\,\mathrm{d}\mu$, donc dans ce modèle, leur densité par rapport à la mesure de domination $\mu^{\otimes n}$, est donnée par

$$(x_1,\cdots,x_n) \mapsto \left(\prod_{k=1}^n h(x_k)\right)\;\exp\left(\eta\sum_{k=1}^n T(x_k) - nA(\eta)\right).$$

Par suite, sous le modèle $q_\eta\,\mathrm{d}\mu$, la log-vraisemblance est donnée par (C designant un terme indépendant de η)

$$\eta \mapsto \ell_n(\eta) := C - nA(\eta) + \eta\sum_{k=1}^n T(X_k).$$

Noter que $G^{(2)} = A^{(2)} \exp(A) + (A')^2 \exp(A)$ dont on déduit que

$$A^{(2)}(\eta) > 0 \text{ ssi } \int (T(x) - \mathbb{E}_\eta [T(X_1)])^2 \, q(\eta; x) \mathrm{d}\mu(x) > 0.$$

Par (7), la variance de $T(X)$ lorsque $X \sim q_\eta \, \mathrm{d}\mu$, existe pour tout $\eta \in \Xi$. Si elle est strictement positive, $\eta \mapsto A(\eta)$ est strictement convexe. Il s'ensuit que le MV est unique lorsqu'il existe et qu'il est donné par

$$\eta : \qquad A'(\eta) = \frac{1}{n} \sum_{k=1}^{n} T(X_k).$$

En conclusion, pour les modèles exponentiels canoniques, l'estimateur des moments basé sur la statistique T et celui par maximum de vraisemblance coïncident (voir l'exemple de la gaussienne dans la feuille PC1).

3. Difféomorphisme : ϕ est bijective de Θ dans Ξ, différentiable, et d'inverse différentiable. Sous le modèle $p_\theta \, \mathrm{d}\mu$, la densité des v.a i.i.d. $X_1, \cdots, X_n$ par rapport à la mesure $\mu^{\otimes n}$ est

$$(x_1, \cdots, x_n) \mapsto \left(\prod_{k=1}^{n} h(x_k) \right) \exp \left(\phi(\theta) \sum_{k=1}^{n} T(x_k) - nB(\theta) \right)$$

dont on déduit que la log-vraisemblance est donnée par

$$\theta \mapsto C + \phi(\theta) \sum_{k=1}^{n} T(X_k) - nB(\theta)$$

La solution des équations de vraisemblance est

$$\theta \in \Theta : \qquad \frac{B'(\theta)}{\phi'(\theta)} = n^{-1} \sum_{k=1}^{n} T(X_k),$$

ou encore

$$\eta \in \Xi : \qquad \frac{B' \circ \phi^{-1}(\eta)}{\phi' \circ \phi^{-1}(\eta)} = n^{-1} \sum_{k=1}^{n} T(X_k).$$

En remarquant que $\eta = \phi(\theta)$ entraine $B(\phi^{-1}(\eta)) = A(\eta)$, on a

$$\frac{B' \circ \phi^{-1}(\eta)}{\phi' \circ \phi^{-1}(\eta)} = A'(\eta).$$

Ainsi, l'estimateur solution des équations de vraisemblance est $\hat{\theta}_n = \phi^{-1}(\hat{\eta}_n)$ où $\hat{\eta}_n$ est solution de

$$\eta \in \Xi : \qquad A'(\eta) = n^{-1} \sum_{k=1}^{n} T(X_k).$$

Existence, unicité de $\hat{\theta}_n$ ssi existence et unicité de $\hat{\eta}_n$.

2.4 Exercice 4

1. Soit $x > 0$ et $X \sim \mathcal{E}(\lambda)$. Alors

$$\mathbb{P}(X > x) = \int_x^{+\infty} \lambda \exp(-\lambda t) dt = [-\exp(-\lambda t)]_x^{\infty} = \exp(-\lambda x).$$

Réciproquement, supposons que $\mathbb{P}(X > x) = \exp(-\lambda x)$. Alors $\mathbb{P}(X \leq x) = 1 - \exp(-\lambda x)$ et c'est la fonction de répartition d'une loi exponentielle de paramètre λ.

2. Posons $\theta = (\lambda_0, \lambda_1) \in \Theta =]0, +\infty[^2$. $F_\lambda(t)$ désigne la fonction de répartition d'une loi expo de param λ.
On a $Z = X_0 \wedge X_1$ puisque le système ne marche que si les deux machines fonctionnent. La probabilité que le système ne tombe pas en panne avant la date t est $\mathbb{P}_\theta(Z > t) = \mathbb{P}_\theta(X_0 \wedge X_1 > t)$. On a, en utilisant l'indépendance de X_0, X_1 sous $\mathbb{P}_\theta$,

$$\mathbb{P}_\theta(Z > t) = \mathbb{P}_\theta\left(X_0 > t, X_1 > t\right) = \mathbb{P}_\theta(X_0 > t)\mathbb{P}_\theta(X_1 > t) = \exp(-(\lambda_0 + \lambda_1)t).$$

On en déduit que sous $\mathbb{P}_\theta$, $Z \sim \mathcal{E}(\lambda_0 + \lambda_1)$.
La probabilité que la défaillance du système soit due à la machine 1 est $\mathbb{P}_\theta(Z = X_1)$. On a

$$\begin{aligned}
\mathbb{P}_\theta(Z = X_1) = \mathbb{P}_\theta(X_0 \geq X_1) &= \int_0^\infty \int_0^\infty \lambda_0\lambda_1 \exp(-\lambda_1 x_1) \exp(-\lambda_0 x_0) \mathbb{1}_{x_0 \geq x_1} \, \mathrm{d}x_1 \mathrm{d}x_0 \\
&= \lambda_1 \int_0^\infty \exp(-\lambda_1 x_1) \left(\int_{x_1}^\infty \lambda_0 \exp(-\lambda_0 x_0) \mathrm{d}x_0 \right) \mathrm{d}x_1 \\
&= \lambda_1 \int_0^\infty \exp(-\lambda_1 x_1 - \lambda_0 x_1) \mathrm{d}x_1 = \frac{\lambda_1}{\lambda_1 + \lambda_0} \, .
\end{aligned}$$

3. Soit $t \geq 0$.

$$\begin{aligned}
\mathbb{P}_\theta(Z > t, I = 1) = \mathbb{P}_\theta(Z > t, Z = X_1) &= \mathbb{P}_\theta(X_0 \geq X_1, X_1 > t) \\
&= \lambda_1 \int_t^\infty \exp(-\lambda_1 x_1) \left(\int_{x_1}^\infty \lambda_0 \exp(-\lambda_0 x_0) \mathrm{d}x_0 \right) \mathrm{d}x_1 \\
&= \lambda_1 \int_t^\infty \exp(-(\lambda_1 + \lambda_0) x_1) \mathrm{d}x_1 \\
&= \frac{\lambda_1}{\lambda_1 + \lambda_0} \exp(-(\lambda_1 + \lambda_0)t) = \mathbb{P}(Z = X_1) \ \mathbb{P}(Z > t)
\end{aligned}$$

De même,

$$\mathbb{P}_\theta(Z > t, I = 0) = \frac{\lambda_0}{\lambda_1 + \lambda_0} \exp(-(\lambda_1 + \lambda_0)t) = \mathbb{P}_\theta(Z = X_0) \ \mathbb{P}_\theta(Z > t).$$

Dont on déduit que (Z, I) sont indépendantes sous $\mathbb{P}_\theta$.

4. a) Premier modèle statistique
   - Espace mesurable : $]0, +\infty[^n$ muni de la tribu borélienne.
   - Famille de fonctions de répartition F_θ sur $]0, +\infty[$ indexées par $\theta = (\lambda_0, \lambda_1) \in \Theta =]0, +\infty[^2$ et définies par

$$F_\theta(x) = \left(1 - \exp(-(\lambda_0 + \lambda_1)x)\right) \mathbb{1}_{\mathbb{R}^+}(x)$$

Soit λ_0 et λ_1 des réels strictement positifs. Pour tout $\tau \in (0, \lambda_1)$, on a, pour tout $x > 0$

$$1 - \exp(-((\lambda_1 - \tau) + (\lambda_0 + \tau))x) = 1 - \exp(-(\lambda_1 + \lambda_0)x)$$

donc $F_{\lambda_0+\tau,\lambda_1-\tau} = F_{\lambda_0,\lambda_1}$, le modèle n'est pas identifiable.

b) Nouveau modèle statistique

• Espace mesurable : $(]0, +\infty[\times \{0, 1\})^n$ muni de la tribu engendrée par les ensembles $A \times \{0\}, A \times \{1\}$ où A est un borélien.

• Famille de fonctions de répartition F_θ sur $]0, +\infty[\times \{0, 1\}$ indexées par $\theta = (\lambda_0, \lambda_1) \in \Theta =]0, +\infty[^2$ et définies par

$$F_\theta(x, 1) = (1 - \exp(-(\lambda_0 + \lambda_1)x))\, \mathbb{1}_{\mathbb{R}^+}(x)\, \frac{\lambda_1}{\lambda_1 + \lambda_0}$$
$$F_\theta(x, 0) = (1 - \exp(-(\lambda_0 + \lambda_1)x))\, \mathbb{1}_{\mathbb{R}^+}(x)\, \frac{\lambda_0}{\lambda_0 + \lambda_1}$$

Supposons que $F_\theta = F_{\tilde{\theta}}$. Alors on a pour tout $x > 0$ et $\delta = 1$

$$(1 - \exp(-(\lambda_0 + \lambda_1)x))\, \frac{\lambda_1}{\lambda_0 + \lambda_1} = \left(1 - \exp(-(\tilde{\lambda}_0 + \tilde{\lambda}_1)x)\right) \frac{\tilde{\lambda}_1}{\tilde{\lambda}_0 + \tilde{\lambda}_1}$$

ce qui entraine

$$\lambda_0 + \lambda_1 = \tilde{\lambda}_0 + \tilde{\lambda}_1$$
$$\frac{\lambda_1}{\lambda_0 + \lambda_1} = \frac{\tilde{\lambda}_1}{\tilde{\lambda}_0 + \tilde{\lambda}_1}$$

On en déduit que $\lambda_i = \tilde{\lambda}_i$ et donc $\theta = \tilde{\theta}$. Le modèle est identifiable.

2.5 Exercice 5

1. Soit $\theta := (\phi, \sigma^2)$ et $\Theta := \mathbb{R} \times]0, +\infty[$.
Pour établir l'expression de la densité p_θ, notons que les v.a. $(X_k)_k$ ne sont pas i.i.d. mais ont la structure d'une chaîne de Markov. On propose deux méthodes.
• **Solution 1.** Notons $\mathcal{F}_n = \sigma(X_1, \cdots, X_n) = \sigma(\xi_1, \cdots, \xi_n)$. La loi conditionnelle de X_n sachant $(\xi_1, \cdots, \xi_{n-1})$ est une gaussienne centrée en ϕX_{n-1} et de variance σ^2. Donc

$$\begin{aligned}
\mathbb{E}_\theta\left[\prod_{k=1}^n f_k(X_k)\right] &= \mathbb{E}\left[\prod_{k=1}^{n-1} f_k(X_k)\mathbb{E}_\theta\left[f_n(X_n)|\mathcal{F}_{n-1}\right]\right] \\
&= \frac{1}{\sigma\sqrt{2\pi}}\mathbb{E}_\theta\left[\prod_{k=1}^{n-1} f_k(X_k)\int f_n(x_n)\exp\left(-0.5\left(\frac{x_n-\phi X_{n-1}}{\sigma}\right)^2\right)\mathrm{d}x_n\right] \\
&= \cdots \\
&= \frac{1}{(\sigma\sqrt{2\pi})^n}\int_{\mathbb{R}^n}\prod_{k=1}^n f_k(x_k)\exp\left(-0.5\left(\frac{x_k-\phi x_{k-1}}{\sigma}\right)^2\right)\mathrm{d}x_1\cdots\mathrm{d}x_n \\
&= \frac{1}{(\sigma\sqrt{2\pi})^n}\int_{\mathbb{R}^n}\prod_{k=1}^n f_k(x_k)\exp\left(-0.5\sigma^{-2}\sum_{k=1}^n\left(x_k-\phi x_{k-1}\right)^2\right)\mathrm{d}x_1\cdots\mathrm{d}x_n \\
&= \frac{1}{(\sigma\sqrt{2\pi})^n}\int_{\mathbb{R}^n}\prod_{k=1}^n f_k(x_k)\exp\left(-0.5\sigma^{-2}\sum_{k=1}^n\left(x_k^2+\phi^2x_{k-1}^2-2\phi x_kx_{k-1}\right)\right)\mathrm{d}x_1\cdots\mathrm{d}x_n
\end{aligned}$$

Ainsi la loi jointe possède une densité w.r.t. Lebesgue donnée par

$$\begin{aligned}
&\frac{1}{(\sigma\sqrt{2\pi})^n}\exp\left(-\frac{1}{2\sigma^2}\sum_{k=1}^n\left(x_k^2+\phi^2x_{k-1}^2-2\phi x_kx_{k-1}\right)\right) \\
&\qquad\qquad = \frac{1}{(\sigma\sqrt{2\pi})^n}\exp\left(-\frac{1}{2\sigma^2}\underline{x}^T\Gamma^{-1}\underline{x}\right) \quad (8)
\end{aligned}$$

avec $\underline{x} := (x_1, \cdots, x_n)$ et

$$\Gamma^{-1} := \begin{bmatrix}
1+\phi^2 & -\phi & 0 & \cdots & \cdots \\
-\phi & 1+\phi^2 & -\phi & 0 & \cdots \\
0 & -\phi & 1+\phi^2 & -\phi & \cdots \\
\cdots & \cdots & \cdots & \cdots & \cdots \\
\cdots & \cdots & -\phi & 1+\phi^2 & -\phi \\
\cdots & \cdots & 0 & -\phi & 1
\end{bmatrix}$$

Fonctions produit pour la méthode de la variable muette. Lorsque l'on applique la méthode dite "de la fonction muette" pour déterminer la loi d'un vecteur aléatoire, il est plus usuel de prendre une fonction $h : \mathbb{R}^n \to \mathbb{R}$ qui n'est pas nécessairement de forme produit de fonctions à variables séparées (comme on l'a fait ici). Néanmoins, ces deux approches sont équivalentes. En effet, si la relation est vraie pour toute fonction $h : \mathbb{R}^n \to \mathbb{R}$ mesurable bornée, alors elle est vraie en particulier pour une fonction mesurable bornée de type produit $h(x_1, \cdots, x_n) = \prod_{k=1}^n h_k(x_k)$. Réciproquement, si on a la propriété pour toute fonction h de la forme $h(x_1, \cdots, x_n) = \prod_{k=1}^n h_k(x_k)$ où les h_k

sont mesurables bornées, alors on l'a pour toutes les indicatrices de pavés $\prod_{k=1}^n \mathbb{1}_{]-\infty,a_k]}$; on en déduit que la propriété reste vraie pour toutes les indicatrices de boréliens de $\mathbb{R}^n$; puis pour toute fonction mesurable (bornée).

• **Solution 2.** Sous $\mathbb{P}_\theta$, X_k a même loi que $\phi X_{k-1} + \sigma\xi_k$ où les $\{\xi\}_i$ sont i.i.d. $\mathcal{N}(0,1)$. En procédant par récurrence, on a pour tout $k \geq 1$ (attention, égalité en loi)

$$X_k = \sum_{j=1}^{k} \phi^{k-j} \xi_j$$

Donc la loi de $(X_1, \cdots, X_n)$ est obtenue par transformation affine du vecteur gaussien $\underline{\xi} = (\xi_1, \cdots, \xi_n)$

$$\begin{bmatrix} 1 & 0 & \cdots & 0 & 0 \\ \phi & 1 & \cdots & 0 & 0 \\ \phi^2 & \phi & 1 & 0 & \cdots \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ \phi^{n-1} & \phi^{n-2} & \cdots & \phi & 1 \end{bmatrix} \begin{bmatrix} \xi_1 \\ \xi_2 \\ \cdots \\ \xi_{n-1} \\ \xi_n \end{bmatrix} = \mathbf{A} \begin{bmatrix} \xi_1 \\ \xi_2 \\ \cdots \\ \xi_{n-1} \\ \xi_n \end{bmatrix}.$$

Puisque $\underline{\xi} \sim \mathcal{N}_n(0, \sigma^2 I)$, il vient que $Z \sim \mathcal{N}_n\left(0, \sigma^2 \mathbf{A}\,\mathbf{A}^T\right)$. D'où pour tout borélien A,

$$\mathbb{P}_\theta(A) = \int_A \frac{1}{(\sqrt{2\pi}\sigma)^n} \frac{1}{\sqrt{\det(\mathbf{A}\,\mathbf{A}^T)}} \exp\left(-\frac{1}{2\sigma^2} \underline{x}^T \left(\mathbf{A}\,\mathbf{A}^T\right)^{-1} \underline{x}\right) \mathrm{d}\underline{x}.$$

• `On peut vérifier que` $\mathbf{A}\,\mathbf{A}^T \Gamma^{-1} = I$ en observant que

$$\mathbf{A}^T \Gamma^{-1} = \begin{bmatrix} 1 & 0 & 0 & & \\ -\phi & 1 & 0 & & \\ 0 & -\phi & 1 & 0 & \cdots \\ \cdots & & & & \\ & & 0 & -\phi & 1 \end{bmatrix}$$

2. En partant de la relation (8), la log-vraisemblance est donnée par

$$\theta \mapsto -\frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{k=1}^{n} (X_k - \phi X_{k-1})^2 ;$$

on voit que le maximum existe, est unique [1] et est donnné par la solution des équations de vraisemblance. On obtient

$$\hat{\phi}_n := \frac{\sum_{k=1}^n X_k X_{k-1}}{\sum_{k=1}^n X_k^2} \qquad \hat{\sigma}_n^2 := \frac{1}{n} \sum_{k=1}^{n} \left(X_k - \hat{\phi}_n X_{k-1}\right)^2.$$

1. se déduit de l'unicité de la solution de l'équation $\nabla \ell_n = 0$