3 Les exercices

Leb *et* $\mathrm{Leb}^{\otimes n}$ *désignent respectivement la mesure de Lebesgue sur* $\mathbb{R}$ *et celle sur* $\mathbb{R}^n$. $\mathcal{N}(\mu, \sigma^2)$ *désigne la loi Gaussienne de moyenne* μ *et de variance* σ^2. *Par convention, les vecteurs sont des vecteurs colonne ; et* a^T *désigne la transposée de* a.

3.1 Questions courtes : avez-vous assimilé le chapitre ?

Avant d'aborder les exercices, vérifiez votre compréhension du chapitre en répondant – de tête, sans revenir au texte – aux questions suivantes. En cas d'hésitation, la référence entre parenthèses renvoie au passage concerné.

1. Soit $(X_1, \dots, X_n)$ un n-échantillon du modèle exponentiel $\{\mathcal{E}(\theta)\,,\ \theta \in \mathbb{R}_+^*\}$. Parmi X_1, $\bar{X}_n$, θ et la constante 1, lesquels sont des estimateurs de θ ? Lesquels sont de *bons* estimateurs ? (Exemple 1.1)
2. Décrire en une phrase le principe de la méthode des moments. Un modèle admet-il un seul estimateur des moments ? (Méthode 1.1, Exemple 1.4)
3. Pour le modèle uniforme sur $[a, b]$ avec $a < b$ inconnus, combien de fonctions de moment faut-il, et pourquoi ? L'intervalle $[\hat{a}_n, \hat{b}_n]$ obtenu contient-il toujours toutes les observations ? (Exemple 1.5)
4. Parmi les qualificatifs « estimateur des moments », « Z-estimateur » et « M-estimateur », lesquels s'appliquent à la médiane empirique ? (Exemple 1.6, Exemple 1.15)
5. *Vrai ou faux :* la vraisemblance dépend du choix de la mesure dominante ; l'estimateur du maximum de vraisemblance aussi. (Définition 1.4)
6. *Vrai ou faux :* l'estimateur du maximum de vraisemblance existe toujours et est unique. (Exemple 1.12, Exemple 1.13)
7. Pour le modèle uniforme $\mathcal{U}([0, \theta])$, comment détermine-t-on l'estimateur du maximum de vraisemblance ? Pourquoi ne faut-il pas écrire l'équation de vraisemblance ? (Exemple 1.11, Méthode 1.2)
8. *Vrai ou faux :* toute racine des équations de vraisemblance est un estimateur du maximum de vraisemblance. (Définition 1.6)
9. Dans le modèle gaussien, l'estimateur du maximum de vraisemblance de σ^2 est la variance empirique non corrigée. Quel est celui de σ ? Quel résultat invoque-t-on ? (Proposition 1.2)
10. Pourquoi $\mathrm{KL}(\mathbb{P}_0, \mathbb{P}_1) \geq 0$? Vers quoi converge la log-vraisemblance normalisée $\ell_n(\vartheta)$ sous $\mathbb{P}_{\theta^\star}$, et pourquoi la limite atteint-elle son maximum en $\theta^\star$ seulement lorsque le modèle est identifiable ? (Théorème 1.1, Proposition 1.3)

3.2 Groupe 1 — Exercices traités en petite classe

Les trois exercices de ce groupe sont traités en petite classe ; ils mettent en œuvre les deux méthodes de construction du chapitre, sur le modèle de régression linéaire gaussienne, sur un modèle de mélange et sur les familles exponentielles (Section 1.5).

Objectif : Modèle linéaire gaussien

Cet exercice poursuit l'Exercice 4 (PC1), où le modèle de régression linéaire gaussienne a été construit et où un estimateur des coefficients a été proposé par moindres carrés : on établit ici que cet estimateur est celui du maximum de vraisemblance, on détermine sa loi et celle de l'estimateur de la variance. Les questions 5 et 6 reposent sur le théorème de Cochran, énoncé et démontré au chapitre 1 (Théorème 1.1) ; la question 7 utilise la notion d'intervalle de confiance, définie dans les outils de ce chapitre (Définition 2.2).

Exercice 1 (Modèle linéaire gaussien (⋆⋆)). Soient $x_1, \dots, x_n$ des réels. On considère le modèle statistique

$$\left(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \left\{ p_\theta \cdot \mathrm{dLeb}^{\otimes n} := \bigotimes_{i=1}^n \mathcal{N}(\beta_1 + \beta_2 x_i, \sigma^2) \ : \ \theta := (\beta_1, \beta_2, \sigma^2) \in \mathbb{R}^2 \times \mathbb{R}_+^* \right\}\right) .$$

On note $\mathbf{1}$ et $\underline{\mathbf{x}}$ les vecteurs de $\mathbb{R}^n$ définis par $\mathbf{1} := (1, \dots, 1)^T$ et $\underline{\mathbf{x}} := (x_1, \dots, x_n)^T$. Dans la suite, on suppose qu'il existe au moins deux indices $i \neq j$ tels que $x_i \neq x_j$. Nous utiliserons les notations matricielles suivantes

$$\mathbf{Y} := \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \in \mathbb{R}^n , \qquad \mathbf{X} := \begin{bmatrix} \mathbf{1} & \underline{\mathbf{x}} \end{bmatrix} \in \mathbb{R}^{n \times 2} , \qquad \beta := \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} \in \mathbb{R}^2 .$$

1. Montrer que la matrice $\mathbf{X^T X}$ est inversible.
   Remarque : Puisque $u^T \mathbf{X^T X} u \geq 0$ pour tout $u \in \mathbb{R}^2$, on en déduit que la matrice est définie positive.
2. Déterminer les estimateurs du maximum de vraisemblance $(\hat\beta_1, \hat\beta_2, \hat\sigma^2)$ de $(\beta_1, \beta_2, \sigma^2)$.
3. Déterminer la loi de $(\hat\beta_1, \hat\beta_2)$ sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$.
4. Montrer que, sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$, $\hat\beta_1$ et $\hat\beta_2$ sont indépendants si et seulement si $n^{-1} \sum_{i=1}^n x_i = 0$.
   Remarque : le modèle dépend de $x_1, \cdots, x_n$ via les quantités $\beta_1 + \beta_2 x_i$ pour tout $1 \leq i \leq n$ soit encore, les lignes de $\mathbf{X}\beta$. Sans "pré-traitement", il n'y a pas de raisons que $n^{-1} \sum_{i=1}^n x_i = 0$. Néanmoins, en écrivant

$$\begin{aligned} \beta_1 \mathbf{1} + \beta_2 \underline{\mathbf{x}} &= \left(\beta_1 + \beta_2 n^{-1} \sum_{i=1}^n x_i \right) \mathbf{1} + \beta_2 (\underline{\mathbf{x}} - n^{-1} \sum_{i=1}^n x_i \mathbf{1}) \\ &= \tilde\beta_1 \mathbf{1} + \beta_2 \tilde{\underline{\mathbf{x}}} = \begin{bmatrix} \mathbf{1} & \tilde{\underline{\mathbf{x}}} \end{bmatrix} \begin{bmatrix} \tilde\beta_1 \\ \beta_2 \end{bmatrix} \qquad \tilde{\underline{\mathbf{x}}} = \underline{\mathbf{x}} - n^{-1} \sum_{i=1}^n x_i \mathbf{1} = \underline{\mathbf{x}} - \frac{\mathbf{1}^T \underline{\mathbf{x}}}{\mathbf{1}^T \mathbf{1}} \mathbf{1} \end{aligned}$$

   on peut paramétrer le modèle de façon équivalente par $(\tilde\beta_1, \beta_2, \sigma^2)$, tout en introduisant une matrice d'expérience $\begin{bmatrix} \mathbf{1} & \tilde{\underline{\mathbf{x}}} \end{bmatrix}$ dont les colonnes sont **orthogonales** *(c'est le sens de $n^{-1} \sum_{i=1}^n \tilde x_i = 0$).*
5. Déterminer la loi de $\hat\sigma^2$ sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$.
6. Montrer que sous $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$, $\hat\sigma^2$ et $(\hat\beta_1, \hat\beta_2)$ sont indépendants.
7. Soit $\alpha \in]0, 1[$. Proposer un intervalle de confiance de niveau $(1-\alpha)$ pour σ^2. *(La notion d'intervalle de confiance est définie a minima dans les outils de ce chapitre, Définition 2.2 ; elle est développée au chapitre suivant.)*

Corrigé : page 39. ♢

Objectif : Modèles de mélanges uniformes, estimation

Cet exercice compare, sur un modèle de mélange de deux lois uniformes, un estimateur du maximum de vraisemblance et un estimateur des moments (Méthode 1.1 et Méthode 1.2) : les deux méthodes conduisent à des estimateurs différents, dont les analyses numériques de l'énoncé comparent le biais et la dispersion.

Exercice 2 (Estimation d'un coefficient de mélange (⋆)). Soit un n-échantillon $(X_1, \dots, X_n)$ du modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{f_\theta \cdot \mathrm{Leb}, \theta \in]0, 1[\})$ où

$$f_\theta(x) = \frac{\theta}{a} \ \mathbb{1}_{\{[0,a]\}}(x) + \frac{(1-\theta)}{b} \ \mathbb{1}_{\{[0,b]\}}(x).$$

On suppose que a et b sont connus et que $0 < a < b$. La fonction de répartition associée à la densité f_θ vaut

$$x \mapsto \begin{cases} 0 & x \leq 0 \\ \left(\frac{\theta}{a} + \frac{(1-\theta)}{b}\right) x & 0 \leq x \leq a \\ \theta + \frac{(1-\theta)}{b} x & a \leq x \leq b \\ 1 & x \geq b \end{cases}$$

1. Exprimer la fonction de vraisemblance à l'aide de $N_a := \sum_{i=1}^n \mathbb{1}_{X_i \in [0,a]}$ le nombre d'observations à valeur dans $[0, a]$.

2. En déduire l'estimateur du maximum de vraisemblance de θ, noté $\hat{\theta}_n^{(1)}$.
3. En utilisant la méthode des moments (d'ordre 1), proposer un estimateur $\hat{\theta}_n^{(2)}$ de θ.

▶ **Analyses numériques.** Pour les analyses numériques ci-dessous, on se donne des mesures $x_1, \ldots, x_n$ obtenues comme la réalisation de tirages indépendants sous la loi $f_{0.2}$ dans le cas $a = 1$ et $b = 3$.

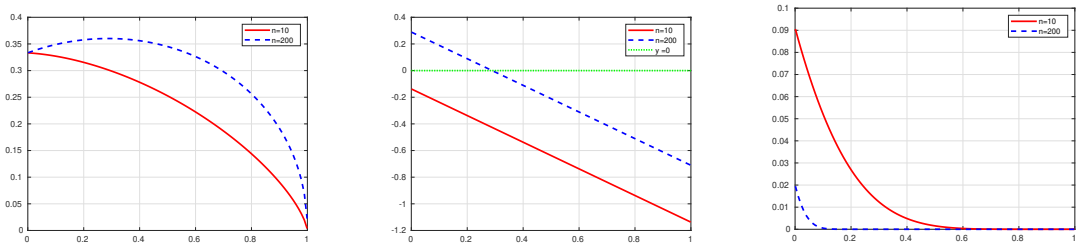


FIGURE 1 – [gauche] Tracé de deux réalisations de la fonction de vraisemblance $\theta \mapsto L(\theta, X_1, \cdots, X_n)$: une pour $n = 10$ puis une pour $n = 200$. [centre] Tracé de deux réalisations de la fonction (aléatoire) dont l'estimateur des moments est un zero : une dans le cas $n = 10$ et l'autre dans le cas $n = 200$. [droite] Evolution du biais de l'estimateur $\hat{\theta}_n^{(1)}$ en fonction de θ. Dans le cas $n = 10$ et $n = 200$.

Sur la figure 2, on visualise la loi de différents estimateurs : $\hat{\theta}_n^{(1)}$, $\hat{\theta}_n^{(2)}$ et

$$\hat{\theta}_n := \frac{b(N_a/n) - a}{b - a}, \qquad \tilde{\theta}_n := \frac{b - 2n^{-1}\sum_{i=1}^n X_i}{b - a}\,.$$

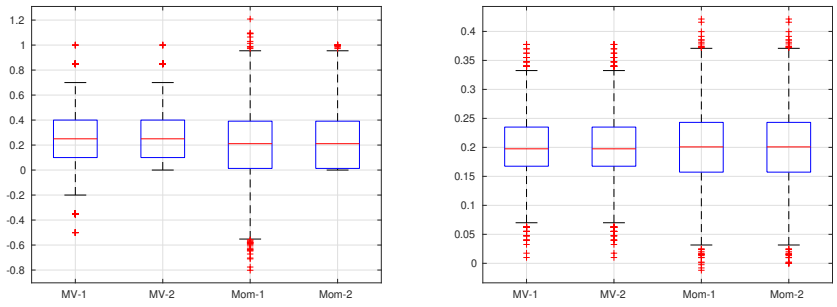


FIGURE 2 – Boxplot de la réalisation de $N = 5000$ estimateurs dans le cas $n = 10$ (gauche) et $n = 200$ (droite). Les boxplots MV-1 et MV-2 correspondent resp. à $\hat{\theta}_n$ et $\hat{\theta}_n^{(1)}$; ceux de Mom-1 et Mom-2 correspondent à $\tilde{\theta}_n$ et $\hat{\theta}_n^{(2)}$. On fera attention aux échelles en ordonnées pour comparer les schémas de gauche et de droite.

Illustration / animation : L'estimateur seuillé du mélange prend souvent la valeur 0 quand n est petit

L'animation accessible par le QR code ci-contre permet de comparer, pour les quatre estimateurs de cet exercice, les boîtes à moustaches obtenues sur des échantillons répétés à mesure que n augmente, et d'observer la fréquence à laquelle l'estimateur seuillé vaut exactement 0.

link

Corrigé : page 41. ♢

Objectif : modèle exponentiel général

Cet exercice définit les familles exponentielles, qui contiennent la plupart des modèles usuels, et établit pour elles la propriété observée sur les modèles de Bernoulli et de Poisson (Exemples 1.8 et 1.9) : l'estimateur du maximum de vraisemblance est un estimateur des moments. La dernière question fait jouer l'invariance par reparamétrisation (Proposition 1.2). Les questions 2(b) et 2(c) demandent des outils d'intégration (inégalité de Hölder, dérivation sous le signe intégral par convergence dominée).

Exercice 3 (Famille exponentielle de densités (⋆⋆⋆)). Beaucoup de lois (dont des usuelles) ont une structure particulière pour lesquelles elles sont dites dans *la famille exponentielle*. Soit $(\mathsf{X}, \mathcal{X})$ un espace mesurable (nous prendrons $\mathsf{X} = \mathbb{R}^k$ ou $\mathsf{X} = \mathbb{N}^k$) et μ une mesure σ-finie sur $(\mathsf{X}, \mathcal{X})$. Soit $T : \mathsf{X} \to \mathbb{R}$ et $h : \mathsf{X} \to \mathbb{R}^+$ deux fonctions mesurables.

On appelle `modèle exponentiel canonique associé au couple` (T, h), une famille de lois ayant une densité par rapport à μ de la forme

$$x \mapsto q_\eta(x) = h(x) \exp\left(\eta T(x) - A(\eta)\right) \ , \quad x \in \mathsf{X} \, , \tag{4}$$

où $A(\eta)$ est défini par :

$$A(\eta) := \log \int h(x) \exp\left(\eta T(x)\right) \mu(\mathrm{d}x) \, . \tag{5}$$

L'*espace des paramètres naturels* de la famille canonique associée à (T, h) est l'ensemble

$$\Xi := \{\eta \in \mathbb{R} \, : \, |A(\eta)| < \infty\} \ .$$

Plus généralement on appelle `famille exponentielle` toute famille de loi de densité

$$x \mapsto p_\theta(x) = h(x) \exp(\varphi(\theta) T(x) - B(\theta))$$

par rapport à une mesure μ σ-finie sur $\mathbb{R}$ ou $\mathbb{N}$. Les valeurs admissibles de θ sont les éléments de

$$\Theta := \{\theta \in \mathbb{R} : \int h(x) \ \exp(\varphi(\theta) T(x)) \, \mu(\mathrm{d}x) < \infty\}.$$

1. Les lois suivantes sont-elles dans la famille exponentielle, et si oui, sont-elles canoniques ?
   (a) La loi exponentielle de densité

   $$x \mapsto p_\eta(x) = \eta \exp(-\eta x) \mathbb{1}_{\mathbb{R}^+}(x)$$

   sur $\mathsf{X} = \mathbb{R}$? Si oui, précisez l'espace des paramètres naturels.
   (b) La loi gaussienne $\mathcal{N}(\eta, 1)$ sur $\mathbb{R}$. Si oui, précisez l'espace des paramètres naturels.
   (c) Soit $\alpha > 0$ fixé. La loi de Weibull sur $]0, \infty[$ de paramètre d'échelle $\lambda > 0$ et de densité

   $$x \mapsto q_\lambda(x) = \frac{\alpha}{\lambda} \left(\frac{x}{\lambda}\right)^{\alpha - 1} \ \exp(-(x/\lambda)^\alpha) \qquad x > 0.$$

   Si oui, précisez l'espace des paramètres naturels.
   (d) Montrer que la loi de Poisson définit un modèle exponentiel avec

   $$\varphi(\theta) = \log(\theta), \quad B(\theta) = \theta, \quad T(x) = x, \quad h(x) = 1/x!.$$

   Préciser le modèle exponentiel canonique associé.
   (e) Montrer que la loi binomiale définit un modèle exponentiel avec

   $$\varphi(\theta) = \log\left(\frac{\theta}{1-\theta}\right), \quad B(\theta) = -n \log(1-\theta), \quad T(x) = x, \quad h(x) = \binom{n}{x}.$$

   Préciser le modèle exponentiel canonique associé.
2. Nous allons tout d'abord établir certaines propriétés des modèles exponentiels canoniques.
   (a) Supposons que l'espace des paramètres est ouvert, que A est régulière et que l'on peut permuter dérivée et intégrale. Quelle relation a-t-on entre $A'(\eta)$, $A''(\eta)$ et l'espérance et la variance de $T(X)$ sous q_η ?

(b) Montrer que la fonction $\eta \mapsto A(\eta)$ est convexe et que l'espace des paramètres naturels est un sous-ensemble convexe de $\mathbb{R}$.

(c) On suppose dans la suite que Ξ est un intervalle ouvert. Pour $\eta \in \Xi$, on pose

$$G(\eta) := \int h(x) \exp\left(\eta T(x)\right) \mu(\mathrm{d}x) \ .$$

Montrer que G est infiniment différentiable sur Ξ et que, pour tout $k \in \mathbb{N}^*$ et $\eta \in \Xi$,

$$G^{(k)}(\eta) = \int h(x)\, T^k(x)\, \exp\left(\eta T(x)\right) \mu(\mathrm{d}x) \ .$$

(d) Soit $(X_1, \ldots, X_n)$ un n-échantillon du modèle exponentiel canonique associé à (T, h).

i. Déterminer l'estimateur des moments associé à la fonction T.

ii. Déterminer l'estimateur du maximum de vraisemblance. Que remarque-t-on ?

3. Considérons dorénavant le modèle exponentiel général. On supposera que Θ est un intervalle ouvert de $\mathbb{R}$. On suppose que la fonction φ définit un difféomorphisme de Θ sur Ξ l'espace des paramètres naturels associé. On dispose d'un n-échantillon $(X_1, \ldots, X_n)$ du modèle

$$(\mathsf{X}, \mathcal{X}, \{p_\theta \cdot \mu \ : \ \theta \in \Theta\}) \ .$$

Déterminer l'estimateur du paramètre θ, solution des équations de vraisemblance [on pensera à utiliser la paramétrisation canonique].

Corrigé : page 44. ♢

En conclusion de l'exercice précédent : (i) les modèles exponentiels s'écrivent sous forme de facteurs séparables en la variable x et le paramètre de la famille $\varphi(\theta)$ (ou η dans le modèle canonique). (ii) Il n'y a pas unicité de la représentation, y compris du paramètre canonique : on a en effet $\eta T(x) = (\lambda\eta)\ (T(x)/\lambda)$ pour tout $\lambda \in \mathbb{R}$ par exemple. (iii) On a ici présenté une version simplifiée de la définition de ces modèles, mais en toute généralité le paramètre du modèle peut être vectoriel, et le produit $\varphi(\theta)T(x)$ peut être un produit scalaire entre des fonctions φ, T à valeur dans $\mathbb{R}^q$ i.e. $\sum_{j=1}^q \varphi_j(\theta)T_j(x)$. Par exemple, la loi gaussienne $\mathcal{N}_d(\mu, \Sigma)$ pour une matrice de covariance Σ inversible, a une densité proportionnelle à

$$\begin{aligned}
\exp\left(-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right) &\propto \exp\left(-\frac{1}{2}(x^T\Sigma^{-1}x - 2\mu^T\Sigma^{-1}x)\right) \\
&= \exp\left(-\frac{1}{2}\mathrm{Tr}\left(\Sigma^{-1}xx^T\right) + \mu^T\Sigma^{-1}x\right) \\
&= \exp\left(-\frac{1}{2}\left\langle\Sigma^{-1}, xx^T\right\rangle + \left\langle\Sigma^{-1}\mu, x\right\rangle\right)
\end{aligned}$$

et est donc un exemple de `famille exponentielle canonique de dimension` $q > 1$. *(iv) Une grande partie des modèles utilisés en pratique sont des modèles exponentiels (modèle gaussien, log-normal, exponentiel, gamma, Bernoulli, Poisson, etc). Ils sont traités dans le chapitre « Famille exponentielle » du polycopié.*

3.3 Groupe 2 — Exercices bonus

Guide de lecture. Les deux exercices qui suivent ne sont pas traités en petite classe. L'exercice **Durée de vie** (⋆⋆) ne demande que les notions du chapitre 1 (modèle statistique, identifiabilité, Définition 2) et des calculs sur la loi exponentielle : il montre comment l'observation supplémentaire de la cause de chaque panne rend identifiable un modèle qui ne l'était pas, et son corrigé se termine par le calcul de l'estimateur du maximum de vraisemblance dans le modèle ainsi enrichi. Vous pouvez l'aborder avant même d'avoir lu le chapitre 2. L'exercice **Modèle auto-régressif** (⋆⋆) demande d'écrire la densité d'observations qui ne sont ni indépendantes ni de même loi, à partir

des lois conditionnelles successives, puis de maximiser la vraisemblance obtenue ; il suppose acquis le calcul de l'estimateur du maximum de vraisemblance du modèle gaussien (Exemple 1.10) et les propriétés des vecteurs gaussiens du chapitre 1 (Section 2). Il est préférable de le traiter après l'Exercice 1, dont il reprend la démarche de maximisation en deux temps.

Objectif : Modélisation de durées de vie exponentielles

Exercice 4 (Durée de vie (⋆⋆)). On considère un système ne fonctionnant que si deux machines sont toutes les deux en état de marche. On observe les durées de vie des deux machines, que l'on modélise comme des lois exponentielles de paramètres λ_0 et λ_1, $\lambda_i > 0$; et des lois indépendantes.

1. Montrer qu'une variable aléatoire X suit la loi exponentielle $\mathcal{E}(\lambda)$ si et seulement si
$$\forall x > 0 : \ \mathbb{P}(X > x) = \exp(-\lambda x).$$

Le modèle statistique associé à cette expérience est
$$\left(\mathbb{R}_+^2, \mathcal{B}(\mathbb{R}_+^2), \{\mathbb{P}_\theta = \mathcal{E}(\lambda_0) \otimes \mathcal{E}(\lambda_1), \theta = (\lambda_0, \lambda_1) \in (\mathbb{R}_+^\star)^2\}\right).$$

2. Calculer la probabilité pour que le système ne tombe pas en panne avant la date t. En déduire la loi de la durée de vie Z du système. Le système tombe en panne ; calculer la probabilité pour que la panne soit due à une défaillance de la machine 1.
3. Soit $I = 1$ si la panne du système est due à une défaillance de la machine 1, $I = 0$ sinon. Calculer $\mathbb{P}_\theta(Z > t; I = \delta)$ pour tout $t \geq 0$ et $\delta \in \{0, 1\}$. En déduire que Z et I sont indépendantes.
4. On dispose de n systèmes identiques et fonctionnant indépendamment les uns des autres dont on observe les durées de vie $Z_1, \ldots, Z_n$.
   (a) Écrire le modèle statistique correspondant. Les paramètres λ_0 et λ_1 sont-ils identifiables ?
   (b) Supposons maintenant que l'on observe à la fois les durées de vie des systèmes $Z_1, \ldots, Z_n$ et les causes de la défaillance correspondantes $I_1, \ldots, I_n$, $I_i \in \{0, 1\}$. Écrire le modèle statistique dans ce cas. Les paramètres λ_0 et λ_1 sont-ils identifiables ?

Corrigé : page 47. ♢

Objectif : Série temporelle

Exercice 5 (Modèle auto-régressif (⋆⋆)). Soit $\theta := (\phi, \sigma^2) \in \Theta := \mathbb{R} \times \mathbb{R}_+^\star$. On considère l'observation $Z = (X_1, \ldots, X_n)$, qui sous le modèle statistique $p_\theta \cdot \mathrm{dLeb}^{\otimes n}$, a la loi suivante : pour tout $1 \leq k \leq n$, la loi conditionnelle de X_k sachant $(X_1, \cdots, X_{k-1})$ est une loi $\mathcal{N}(\phi\, X_{k-1}, \sigma^2)$. Par convention, $X_0 = 0$.

1. Écrire le modèle statistique engendré par l'observation Z.
2. Déterminer l'estimateur du maximum de vraisemblance de $\theta = (\phi, \sigma^2)$.

Corrigé : page 49. ♢

3.4 Corrigés des exercices

Les corrigés ci-dessous reprennent, en les complétant, ceux distribués avec la feuille de petite classe. Les résultats du chapitre 1 (vecteurs gaussiens, théorème de Cochran, loi du χ^2, méthode de la fonction muette) sont appelés par un renvoi et ne sont pas redémontrés ; la variable de la vraisemblance est notée ϑ, conformément à la convention du chapitre.

Corrigé de l'exercice 1 – Modèle linéaire gaussien

On note $Y_1, \dots, Y_n$ les statistiques canoniques, $\mathbf{Y} = (Y_1, \dots, Y_n)^T$, $\bar{Y} := n^{-1} \sum_{i=1}^n Y_i$ et $\bar{x} := n^{-1} \sum_{i=1}^n x_i$. Le paramètre est $\theta = (\beta_1, \beta_2, \sigma^2)$; la variable de la vraisemblance est notée $\vartheta = (b_1, b_2, v) \in \Theta = \mathbb{R}^2 \times \mathbb{R}_+^*$, avec $b := (b_1, b_2)^T$. On suppose $n \geq 3$: cette hypothèse, implicite dans l'énoncé, est nécessaire pour que l'estimateur de la variance soit presque sûrement défini (questions 2 et 5).

Préliminaire. Sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$, les Y_i sont indépendantes, de lois $\mathcal{N}(\beta_1 + \beta_2 x_i, \sigma^2)$. La densité de leur loi jointe par rapport à $\mathrm{Leb}^{\otimes n}$ est le produit des densités (Section 1.7, équation (1)) : pour $y = (y_1, \dots, y_n)^T$,

$$p_\theta(y_1, \dots, y_n) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\Big(- \frac{(y_i - \beta_1 - \beta_2 x_i)^2}{2\sigma^2} \Big) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\Big(- \frac{1}{2\sigma^2} \, \|y - \mathbf{X}\beta\|^2 \Big) \, .$$

Un vecteur dont les coordonnées sont des variables gaussiennes indépendantes est un vecteur gaussien (Lemme 2.1 du chapitre 1) : sous $\mathbb{P}_\theta$, $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2 \mathrm{I}_n)$.

1. On a

$$\mathbf{X}^T\mathbf{X} = \begin{bmatrix} n & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & \sum_{i=1}^n x_i^2 \end{bmatrix} \, , \qquad \det(\mathbf{X}^T\mathbf{X}) = n \sum_{i=1}^n x_i^2 - \Big(\sum_{i=1}^n x_i \Big)^2 = n \sum_{i=1}^n (x_i - \bar{x})^2 \, ,$$

la dernière égalité venant de $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$. Ce déterminant est positif, et nul si et seulement si $x_i = \bar{x}$ pour tout i, ce qui est exclu puisque deux des x_i sont distincts : il est strictement positif et la matrice est inversible. Comme $u^T\mathbf{X}^T\mathbf{X}u = \|\mathbf{X}u\|^2 \geq 0$ pour tout $u \in \mathbb{R}^2$, la matrice $\mathbf{X}^T\mathbf{X}$ est symétrique positive ; étant inversible, elle est définie positive. Explicitement,

$$(\mathbf{X}^T\mathbf{X})^{-1} = \frac{1}{n \sum_{i=1}^n (x_i - \bar{x})^2} \begin{bmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{bmatrix} \, .$$

La condition « deux x_i distincts » signifie que les colonnes $\mathbf{1}$ et $\underline{\mathbf{x}}$ de $\mathbf{X}$ sont linéairement indépendantes : le sous-espace $F := \mathrm{Im}(\mathbf{X}) = \mathrm{Vect}(\mathbf{1}, \underline{\mathbf{x}})$ de $\mathbb{R}^n$ est de dimension 2.

2. La vraisemblance est $\mathrm{L}_n(\vartheta) = p_\vartheta(Y_1, \dots, Y_n) > 0$, et la log-vraisemblance normalisée s'écrit

$$\ell_n(\vartheta) = -\frac{1}{2} \log(2\pi v) - \frac{1}{2nv} \, \|\mathbf{Y} - \mathbf{X}b\|^2 \, , \qquad \vartheta = (b, v) \in \mathbb{R}^2 \times \mathbb{R}_+^* \, .$$

Elle est différentiable sur Θ, qui est ouvert : on est dans le cas régulier de la Méthode 1.2, et les équations de vraisemblance s'écrivent

$$\nabla_b \, \ell_n(\vartheta) = \frac{1}{nv} \, \mathbf{X}^T(\mathbf{Y} - \mathbf{X}b) = 0 \, , \qquad \frac{\partial \, \ell_n}{\partial v}(\vartheta) = -\frac{1}{2v} + \frac{1}{2nv^2} \, \|\mathbf{Y} - \mathbf{X}b\|^2 = 0 \, .$$

Plutôt que de résoudre ce système directement, on maximise en deux temps, comme pour le modèle gaussien (Exemple 1.10).

Maximisation en b à v fixé. Maximiser ℓ_n en b revient à minimiser $J(b) := \|\mathbf{Y} - \mathbf{X}b\|^2$ sur $\mathbb{R}^2$. Cette fonction est quadratique, de gradient $\nabla J(b) = -2\mathbf{X}^T(\mathbf{Y} - \mathbf{X}b)$ et de matrice

hessienne $2\mathbf{X}^T\mathbf{X}$, définie positive d'après la question 1 : elle est strictement convexe et admet un unique minimum, caractérisé par les *équations normales* $\mathbf{X}^T\mathbf{X}\,b = \mathbf{X}^T\mathbf{Y}$, soit

$$\hat\beta := \begin{bmatrix}\hat\beta_1\\ \hat\beta_2\end{bmatrix} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}\ .$$

Les équations normales s'écrivent $nb_1 + b_2\sum_i x_i = \sum_i Y_i$ et $b_1\sum_i x_i + b_2\sum_i x_i^2 = \sum_i x_iY_i$; la première donne $b_1 = \bar Y - b_2\bar x$ et, en reportant dans la seconde,

$$\hat\beta_2 = \frac{\sum_{i=1}^n (x_i-\bar x)(Y_i-\bar Y)}{\sum_{i=1}^n (x_i-\bar x)^2}\ , \qquad \hat\beta_1 = \bar Y - \hat\beta_2\,\bar x\ .$$

Posons $P := \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$. Cette matrice est symétrique, vérifie $P^2 = P$ et $P\mathbf{X} = \mathbf{X}$, et son image est F : c'est la matrice de la projection orthogonale sur F, et $\mathrm{I}_n - P$ celle de la projection orthogonale sur $F^\perp$, de dimension $n-2$. Ainsi $\mathbf{X}\hat\beta = P\mathbf{Y}$ est la projection orthogonale de $\mathbf{Y}$ sur F, $\mathbf{Y} - \mathbf{X}\hat\beta = (\mathrm{I}_n - P)\mathbf{Y}$ et $J(\hat\beta) = \|(\mathrm{I}_n - P)\mathbf{Y}\|^2$.

Maximisation en v. Posons $S := n^{-1}\|(\mathrm{I}_n - P)\mathbf{Y}\|^2$. La fonction $v \mapsto \ell_n(\hat\beta, v) = -\frac12\log(2\pi v) - S/(2v)$ a pour dérivée $(S-v)/(2v^2)$. Si $S > 0$, cette dérivée est strictement positive pour $v < S$ et strictement négative pour $v > S$: le maximum est atteint en $v = S$ seulement. Pour tout $(b, v) \in \Theta$, on a alors $\ell_n(b, v) \le \ell_n(\hat\beta, v) \le \ell_n(\hat\beta, S)$, avec égalité si et seulement si $(b, v) = (\hat\beta, S)$. L'estimateur du maximum de vraisemblance existe donc, est unique, et vaut

$$(\hat\beta_1, \hat\beta_2, \hat\sigma^2) \qquad \text{avec} \qquad \hat\sigma^2 := \frac1n\sum_{i=1}^n (Y_i - \hat\beta_1 - \hat\beta_2 x_i)^2 = \frac1n\,\|\mathbf{Y} - \mathbf{X}\hat\beta\|^2 = \frac1n\,\|(\mathrm{I}_n - P)\mathbf{Y}\|^2\ .$$

Si $S = 0$, la fonction $v \mapsto \ell_n(\hat\beta, v)$ tend vers $+\infty$ en 0 et la vraisemblance n'a pas de maximum. On verra à la question 5 que $S > 0$ $\mathbb{P}_\theta$-presque sûrement dès que $n \ge 3$; pour $n = 2$, en revanche, $F = \mathbb{R}^2$, $P = \mathrm{I}_2$ et $S = 0$ toujours : l'estimateur du maximum de vraisemblance n'est pas défini.

L'estimateur $(\hat\beta_1, \hat\beta_2)$ est l'estimateur des moindres carrés proposé dans l'Exercice 4 (PC1) : dans le modèle gaussien, moindres carrés et maximum de vraisemblance coïncident pour les coefficients de régression (cas général dans les compléments, Exemple 4.7). L'estimateur du maximum de vraisemblance de σ^2 divise la somme des carrés des résidus par n, et non par $n-2$.

3. On a $\hat\beta = A\mathbf{Y}$ avec $A := (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T \in \mathbb{R}^{2\times n}$. Sous $\mathbb{P}_\theta$, $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2\mathrm{I}_n)$, et l'image d'un vecteur gaussien par une application linéaire est un vecteur gaussien (Proposition 2.4 du chapitre 1) :

$$\hat\beta \sim \mathcal{N}\big(A\mathbf{X}\beta,\ \sigma^2 AA^T\big) = \mathcal{N}\big(\beta,\ \sigma^2(\mathbf{X}^T\mathbf{X})^{-1}\big)\ ,$$

puisque $A\mathbf{X} = \mathrm{I}_2$ et $AA^T = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1} = (\mathbf{X}^T\mathbf{X})^{-1}$. En particulier $\mathbb{E}_\theta[\hat\beta] = \beta$: l'estimateur est sans biais. Avec l'expression de $(\mathbf{X}^T\mathbf{X})^{-1}$ obtenue à la question 1,

$$\mathrm{Var}_\theta(\hat\beta_1) = \frac{\sigma^2\sum_{i=1}^n x_i^2}{n\sum_{i=1}^n (x_i-\bar x)^2}\ , \qquad \mathrm{Var}_\theta(\hat\beta_2) = \frac{\sigma^2}{\sum_{i=1}^n (x_i-\bar x)^2}\ ,$$
$$\mathrm{Cov}_\theta(\hat\beta_1, \hat\beta_2) = -\frac{\sigma^2\sum_{i=1}^n x_i}{n\sum_{i=1}^n (x_i-\bar x)^2} = -\frac{\sigma^2\,\bar x}{\sum_{i=1}^n (x_i-\bar x)^2}\ .$$

4. Sous $\mathbb{P}_\theta$, $(\hat\beta_1, \hat\beta_2)$ est un vecteur gaussien ; ses deux coordonnées sont indépendantes si et seulement si elles sont décorrélées (Proposition 2.6 du chapitre 1), c'est-à-dire si et

seulement si $\mathrm{Cov}_\theta(\hat\beta_1,\hat\beta_2)=0$. D'après la question 3, et puisque $\sigma^2>0$ et $\sum_i(x_i-\bar x)^2>0$, cette covariance est nulle si et seulement si $\bar x = n^{-1}\sum_{i=1}^n x_i = 0$. Avec la paramétrisation centrée de la remarque de l'énoncé, l'estimateur de $\hat\beta_1=\beta_1+\beta_2\bar x$ est $\hat\beta_1+\hat\beta_2\bar x=\bar Y$, et il est indépendant de $\hat\beta_2$.

5. Sous $\mathbb{P}_\theta$, $\mathbf{Y}\sim\mathcal{N}(\mathbf{X}\beta,\sigma^2\mathrm{I}_n)$, et $\mathbb{R}^n = F\oplus F^\perp$ est une somme orthogonale de sous-espaces de dimensions 2 et $n-2$. Le théorème de Cochran (Théorème 1.1 du chapitre 1) affirme que $\|P_{F^\perp}(\mathbf{Y}-\mathbf{X}\beta)\|^2/\sigma^2\sim\chi^2(n-2)$. Or $\mathbf{X}\beta\in F$, donc $P_{F^\perp}(\mathbf{X}\beta)=0$ et $P_{F^\perp}(\mathbf{Y}-\mathbf{X}\beta)=(\mathrm{I}_n-P)\mathbf{Y}$. Ainsi

$$\frac{n\hat\sigma^2}{\sigma^2}=\frac{\|(\mathrm{I}_n-P)\mathbf{Y}\|^2}{\sigma^2}\sim\chi^2(n-2)\;,$$

autrement dit $\hat\sigma^2$ a la loi de $\frac{\sigma^2}{n}U$ avec $U\sim\chi^2(n-2)=\mathrm{Gamma}\left(\frac{n-2}{2},\frac12\right)$, c'est-à-dire la loi $\mathrm{Gamma}\left(\frac{n-2}{2},\frac{n}{2\sigma^2}\right)$ (Section 2). Comme $\mathbb{E}[U]=n-2$, on obtient $\mathbb{E}_\theta[\hat\sigma^2]=\frac{n-2}{n}\sigma^2$: l'estimateur du maximum de vraisemblance de σ^2 est biaisé, et $\frac{n}{n-2}\hat\sigma^2=\frac{1}{n-2}\|\mathbf{Y}-\mathbf{X}\hat\beta\|^2$ est sans biais. Enfin, la loi $\chi^2(n-2)$ ayant une densité par rapport à la mesure de Lebesgue dès que $n\geq 3$, $\mathbb{P}_\theta(\hat\sigma^2=0)=0$, ce qui achève la question 2.

6. Le théorème de Cochran affirme aussi que les projections $P_F\mathbf{Y}=P\mathbf{Y}$ et $P_{F^\perp}\mathbf{Y}=(\mathrm{I}_n-P)\mathbf{Y}$ sont indépendantes sous $\mathbb{P}_\theta$. Or $\hat\sigma^2=n^{-1}\|(\mathrm{I}_n-P)\mathbf{Y}\|^2$ est une fonction mesurable de $(\mathrm{I}_n-P)\mathbf{Y}$, et $\hat\beta$ une fonction mesurable de $P\mathbf{Y}$, puisque $\mathbf{X}^TP=(P\mathbf{X})^T=\mathbf{X}^T$ donne

$$\hat\beta=(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{Y}=(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^TP\mathbf{Y}\;.$$

Des fonctions mesurables de variables aléatoires indépendantes sont indépendantes : $\hat\sigma^2$ et $(\hat\beta_1,\hat\beta_2)$ sont indépendants. On peut aussi appliquer directement le Corollaire 2.1 du chapitre 1 au vecteur centré $\mathbf{Y}-\mathbf{X}\beta\sim\mathcal{N}(0,\sigma^2\mathrm{I}_n)$ et aux projecteurs P et I_n-P, dont le produit est nul.

7. Sous $\mathbb{P}_\theta$, la variable aléatoire $n\hat\sigma^2/\sigma^2$ suit la loi $\chi^2(n-2)$ quelle que soit la valeur de θ : c'est la situation décrite après la Définition 2.2. Notons $q^{n-2}_{\alpha/2}$ et $q^{n-2}_{1-\alpha/2}$ les quantiles d'ordre $\alpha/2$ et $1-\alpha/2$ de la loi $\chi^2(n-2)$. Cette loi a une densité strictement positive sur $\mathbb{R}_+^*$, donc une fonction de répartition continue et strictement croissante sur $\mathbb{R}_+^*$: ces quantiles sont bien définis, $0<q^{n-2}_{\alpha/2}<q^{n-2}_{1-\alpha/2}$, et

$$\mathbb{P}_\theta\left(q^{n-2}_{\alpha/2}\leq\frac{n\hat\sigma^2}{\sigma^2}\leq q^{n-2}_{1-\alpha/2}\right)=\left(1-\frac{\alpha}{2}\right)-\frac{\alpha}{2}=1-\alpha\;.$$

Comme $\sigma^2>0$ et $\hat\sigma^2>0$ presque sûrement, l'encadrement se résout par rapport à σ^2 :

$$\mathbb{P}_\theta\left(\frac{n\hat\sigma^2}{q^{n-2}_{1-\alpha/2}}\leq\sigma^2\leq\frac{n\hat\sigma^2}{q^{n-2}_{\alpha/2}}\right)=1-\alpha\;.$$

L'intervalle *aléatoire* $\left[n\hat\sigma^2/q^{n-2}_{1-\alpha/2},\ n\hat\sigma^2/q^{n-2}_{\alpha/2}\right]$, dont les bornes sont des statistiques, est donc un intervalle de confiance de niveau $1-\alpha$ pour σ^2 au sens de la Définition 2.2, et son niveau est égal à $1-\alpha$. D'autres choix de quantiles, par exemple 0 et $q^{n-2}_{1-\alpha}$, donnent d'autres intervalles de même niveau ; leur comparaison est l'objet du chapitre suivant.

Corrigé de l'exercice 2 – Estimation d'un coefficient de mélange

Le paramètre est noté $\theta\in\,]0,1[$ et la variable de la vraisemblance ϑ. Le modèle est dominé par la mesure de Lebesgue Leb sur $\mathbb{R}$.

Préliminaire : la fonction de répartition. Pour $t \in \mathbb{R}$, $F_\theta(t) := \mathbb{P}_\theta(X_1 \leq t) = \int_{-\infty}^t f_\theta \,\mathrm{dLeb}$. Comme f_θ est nulle hors de $[0,b]$, on a $F_\theta(t) = 0$ pour $t \leq 0$ et $F_\theta(t) = 1$ pour $t \geq b$; pour $0 \leq t \leq a$, $F_\theta(t) = \int_0^t \left(\frac{\theta}{a} + \frac{1-\theta}{b}\right)\mathrm{d}x = \left(\frac{\theta}{a} + \frac{1-\theta}{b}\right)t$, et pour $a \leq t \leq b$, $F_\theta(t) = F_\theta(a) + \int_a^t \frac{1-\theta}{b}\,\mathrm{d}x = \theta + \frac{1-\theta}{b}\,t$. C'est la fonction donnée dans l'énoncé. On lit sur cette expression que $f_\theta \cdot \mathrm{Leb}$ est le mélange, de poids θ et $1-\theta$, des lois uniformes sur $[0,a]$ et sur $[0,b]$.

1. Pour tout $x \in \mathbb{R}$, en séparant les cas $x \in [0,a]$ et $x \in]a,b]$,

$$f_\vartheta(x) = \Big(\frac{\vartheta}{a} + \frac{1-\vartheta}{b}\Big)\mathbb{1}_{[0,a]}(x) + \frac{1-\vartheta}{b}\,\mathbb{1}_{]a,b]}(x)\ .$$

Sous $\mathbb{P}_\theta$, les observations sont dans $[0,b]$ presque sûrement ; N_a d'entre elles sont dans $[0,a]$ et les $n - N_a$ autres dans $]a,b]$. La vraisemblance vaut donc

$$\mathrm{L}_n(\vartheta) = \prod_{i=1}^n f_\vartheta(X_i) = \Big(\frac{\vartheta}{a} + \frac{1-\vartheta}{b}\Big)^{N_a}\Big(\frac{1-\vartheta}{b}\Big)^{n-N_a}\ , \qquad \vartheta \in]0,1[\ .$$

Elle ne dépend des observations que par la statistique N_a.

2. Sur $]0,1[$, $\mathrm{L}_n > 0$ et la log-vraisemblance normalisée s'écrit

$$\ell_n(\vartheta) = \frac{N_a}{n}\log\Big(\frac{\vartheta}{a} + \frac{1-\vartheta}{b}\Big) + \Big(1 - \frac{N_a}{n}\Big)\log\frac{1-\vartheta}{b}\ .$$

Comme $\frac{\vartheta}{a} + \frac{1-\vartheta}{b} = \frac{a+\vartheta(b-a)}{ab}$, la fonction ℓ_n est dérivable sur $]0,1[$, de dérivée

$$\ell_n'(\vartheta) = \frac{N_a}{n}\,\frac{b-a}{a+\vartheta(b-a)} - \frac{n-N_a}{n}\,\frac{1}{1-\vartheta} = \frac{bN_a - na - n\vartheta(b-a)}{n(1-\vartheta)\big(a+\vartheta(b-a)\big)}\ .$$

Le dénominateur est strictement positif sur $]0,1[$. Le numérateur est une fonction affine strictement décroissante de ϑ, qui s'annule en

$$\hat\theta_n := \frac{bN_a - na}{n(b-a)} = \frac{b\,(N_a/n) - a}{b-a}\ .$$

Comme $0 \leq N_a/n \leq 1$, on a toujours $\hat\theta_n \leq 1$, avec égalité si et seulement si $N_a = n$, et $\hat\theta_n > 0$ si et seulement si $N_a/n > a/b$. Trois cas se présentent.

- Si $0 < \hat\theta_n < 1$, c'est-à-dire si $a/b < N_a/n < 1$: $\ell_n' > 0$ sur $\Big]0,\hat\theta_n\Big[$ et $\ell_n' < 0$ sur $\Big]\hat\theta_n, 1\Big[$. La log-vraisemblance atteint son maximum en $\hat\theta_n$ seulement : l'estimateur du maximum de vraisemblance existe, est unique et vaut $\hat\theta_n$.
- Si $\hat\theta_n \leq 0$, c'est-à-dire si $N_a/n \leq a/b$: $\ell_n' < 0$ sur $]0,1[$, la log-vraisemblance est strictement décroissante, et sa borne supérieure sur l'intervalle ouvert $]0,1[$, qui est sa limite en 0, n'est pas atteinte. Il n'y a pas d'estimateur du maximum de vraisemblance dans $\Theta =]0,1[$.
- Si $\hat\theta_n = 1$, c'est-à-dire si $N_a = n$: $\ell_n' > 0$ sur $]0,1[$, la log-vraisemblance est strictement croissante et sa borne supérieure n'est pas atteinte. Là encore, il n'y a pas d'estimateur du maximum de vraisemblance.

Les densités f_0 et f_1 sont celles des lois uniformes sur $[0,b]$ et sur $[0,a]$: le modèle se prolonge sans difficulté à $[0,1]$, sur lequel L_n est continue, et l'étude de signe ci-dessus montre que, sur $[0,1]$, le maximum de la vraisemblance est atteint en un point unique, $\hat\theta_n \vee 0 = \max(\hat\theta_n, 0)$, qui vaut 1 lorsque $N_a = n$. C'est l'estimateur retenu par la feuille,

$$\hat\theta_n^{(1)} := \hat\theta_n \vee 0\ ,$$

estimateur du maximum de vraisemblance du modèle prolongé à $[0,1]$, qui coïncide avec celui du modèle initial sur l'événement $\{0 < \hat\theta_n < 1\}$. Cet événement est de probabilité tendant vers 1 : sous $\mathbb{P}_\theta$, $N_a = \sum_{i=1}^n \mathbb{1}_{\{X_i\in[0,a]\}}$ est une somme de n variables de Bernoulli indépendantes, de paramètre

$$p_\theta := \mathbb{P}_\theta(X_1 \in [0,a]) = F_\theta(a) = \theta + (1-\theta)\frac{a}{b} \in]a/b, 1[\ ,$$

donc $N_a \sim \mathrm{Bin}(n, p_\theta)$, et la loi faible des grands nombres (Théorème 2.1) donne $N_a/n \overset{\mathbb{P}_\theta-\mathrm{prob}}{\longrightarrow} p_\theta$. Comme $a/b < p_\theta < 1$, il vient $\mathbb{P}_\theta(N_a/n \le a/b) \to 0$ et $\mathbb{P}_\theta(N_a = n) = p_\theta^n \to 0$.
Remarque sur le biais. Comme $\mathbb{E}_\theta[N_a] = np_\theta$,

$$\mathbb{E}_\theta[\hat\theta_n] = \frac{b\,p_\theta - a}{b-a} = \frac{b\theta + (1-\theta)a - a}{b-a} = \theta\ :$$

l'estimateur non seuillé $\hat\theta_n$ est sans biais. En revanche, $\hat\theta_n^{(1)} \ge \hat\theta_n$, avec inégalité stricte sur l'événement $\{\hat\theta_n < 0\}$, qui est de probabilité strictement positive (il contient $\{N_a = 0\}$, de probabilité $(1-p_\theta)^n > 0$) : $\mathbb{E}_\theta[\hat\theta_n^{(1)}] > \theta$, et le biais de $\hat\theta_n^{(1)}$ vaut $\mathbb{E}_\theta[-\hat\theta_n\,\mathbb{1}_{\{\hat\theta_n<0\}}] > 0$. Il se calcule à partir de la loi binomiale de N_a,

$$\mathbb{E}_\theta\big[\hat\theta_n^{(1)}\big] = \frac{1}{b-a}\sum_{k>na/b}\Big(\frac{bk}{n} - a\Big)\binom{n}{k}p_\theta^k(1-p_\theta)^{n-k}\ ,$$

et c'est cette formule qui est tracée sur la figure 1 (droite).

3. Le moment exact associé à $T(x) = x$ vaut

$$e(\theta) := \mathbb{E}_\theta[X_1] = \int_{\mathbb{R}} x f_\theta(x)\,\mathrm{d}x = \theta\int_0^a \frac{x}{a}\,\mathrm{d}x + (1-\theta)\int_0^b \frac{x}{b}\,\mathrm{d}x = \theta\,\frac{a}{2} + (1-\theta)\,\frac{b}{2}\ ,$$

soit $e(\theta) = \frac{b}{2} - \theta\,\frac{b-a}{2}$. L'équation des moments $e(\vartheta) = \bar X_n$, où $\bar X_n := n^{-1}\sum_{i=1}^n X_i$, admet une unique solution réelle,

$$\tilde\theta_n := \frac{b - 2\bar X_n}{b-a}\ ,$$

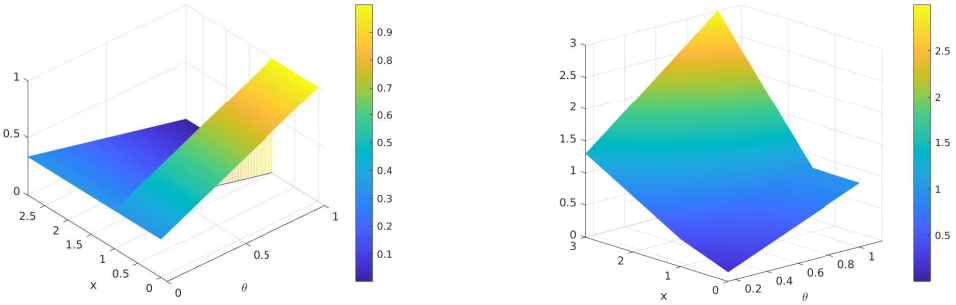
qui n'appartient pas nécessairement à $\Theta =]0,1[$: on a $\tilde\theta_n \in]0,1[$ si et seulement si $a/2 < \bar X_n < b/2$. Sous $\mathbb{P}_\theta$, les observations sont dans $[0,b]$, donc $\bar X_n \in [0,b]$, et rien n'impose $\bar X_n \in]a/2, b/2[$ à n fixé : par exemple, si toutes les observations sont inférieures à $a/2$, événement de probabilité $F_\theta(a/2)^n > 0$, alors $\tilde\theta_n \ge 1$. L'estimateur des moments au sens de la Définition 1.2 n'est donc défini que sur l'événement $\{a/2 < \bar X_n < b/2\}$, où il vaut $\tilde\theta_n$. Cet événement est de probabilité tendant vers 1, puisque $\bar X_n \overset{\mathbb{P}_\theta-\mathrm{prob}}{\longrightarrow} e(\theta) \in]a/2, b/2[$ (Proposition 1.1). Comme pour le maximum de vraisemblance, on retient l'estimateur seuillé

$$\hat\theta_n^{(2)} := \begin{cases} 0 & \text{si } \tilde\theta_n \le 0\ , \\ 1 & \text{si } \tilde\theta_n \ge 1\ , \\ \tilde\theta_n & \text{sinon.}\end{cases}$$

Remarque sur le biais. Comme $\mathbb{E}_\theta[\bar X_n] = e(\theta)$, on a $\mathbb{E}_\theta[\tilde\theta_n] = (b - 2e(\theta))/(b-a) = \theta$: l'estimateur non seuillé $\tilde\theta_n$ est sans biais, tandis que $\hat\theta_n^{(2)}$ ne l'est pas en général.

Analyses numériques. On prend $a = 1$ et $b = 3$.

— La figure ci-dessous représente la densité f_θ et la fonction de répartition F_θ pour plusieurs valeurs de θ. À θ fixé, la densité est constante par morceaux ; à x fixé, c'est une fonction croissante de θ sur $[0,a]$ et décroissante sur $]a,b]$.



Densité (à gauche) et fonction de répartition (à droite) de la loi de mélange, pour $a = 1$, $b = 3$ et différentes valeurs de θ dans $]0, 1[$.

— On simule $n_{\max} = 200$ réalisations de la loi de mélange de paramètre $\theta_{\text{true}} = 0{,}2$. La figure 1 (gauche) représente la vraisemblance calculée à partir des $n = 10$ premières observations, puis des $n = 200$ observations. Sur le jeu de taille $n = 10$, on observe $N_a/n = 0{,}30 \leq a/b$, donc $\hat{\theta}_n = (3 \times 0{,}30 - 1)/2 = -0{,}05 < 0$: la vraisemblance est décroissante sur $]0, 1[$ et son maximum sur $[0, 1]$ est atteint au bord, en $\theta = 0$. Sur le jeu de taille $n = 200$, on observe $N_a/n = 0{,}525$ et $\hat{\theta}_n = (3 \times 0{,}525 - 1)/2 = 0{,}2875$: le maximum est atteint à l'intérieur de $]0, 1[$, et l'estimateur diffère de θ_{true}.

— Sur le même jeu de données, la figure 1 (centre) représente la fonction $\vartheta \mapsto e(\vartheta) - \bar{X}_n = \vartheta\, a/2 + (1-\vartheta)\, b/2 - \bar{X}_n$ pour $n = 10$ puis $n = 200$; cette fonction dépend des observations par $\bar{X}_n$, elle est donc aléatoire. L'estimateur des moments existe si cette fonction s'annule dans $]0, 1[$. Pour $n = 10$, le zéro est négatif ; pour $n = 200$, l'estimateur existe et est unique, et il diffère lui aussi de θ_{true}.

— La figure 1 (droite) représente le biais $\theta \mapsto \mathbb{E}_\theta[\hat{\theta}_n^{(1)}] - \theta$, calculé par la formule binomiale de la question 2, pour $n = 10$ et $n = 200$. Il est positif, conformément à la remarque de la question 2, et d'autant plus faible que n est grand.

— On répète enfin l'expérience $N = 5000$ fois : on produit N jeux de données de taille $n = 200$ sous $\theta_{\text{true}} = 0{,}2$ et l'on calcule, pour chacun, $\hat{\theta}_n$, $\hat{\theta}_n^{(1)}$, $\tilde{\theta}_n$ et $\hat{\theta}_n^{(2)}$ sur les $n = 10$ premières observations, puis sur les $n = 200$ observations ; la figure 2 représente les boîtes à moustaches de ces N réalisations indépendantes. Les échelles des ordonnées diffèrent entre les deux graphiques. Les estimateurs seuillés MV-2 et Mom-2 prennent leurs valeurs dans $[0, 1]$. La comparaison de MV-1 et MV-2 d'une part, de Mom-1 et Mom-2 d'autre part, montre que le seuillage intervient fréquemment pour $n = 10$, et que, pour $n = 200$, il n'intervient plus, sur ces N réalisations, que pour l'estimateur des moments.

Corrigé de l'exercice 3 – Famille exponentielle de densités

Dans tout le corrigé, on note $G(\eta) := \int h(x) \exp(\eta T(x))\, \mu(\mathrm{d}x) \in [0, +\infty]$ pour $\eta \in \mathbb{R}$, de sorte que $A = \log G$, avec les conventions $\log 0 = -\infty$ et $\log(+\infty) = +\infty$.

1. (a) Prenons $\mathsf{X} = \mathbb{R}$, $\mu = \text{Leb}$, $h = \mathbb{1}_{\mathbb{R}^+}$ et $T(x) = -x$. Pour $\eta \in \mathbb{R}$, $G(\eta) = \int_0^{+\infty} \mathrm{e}^{-\eta x}\, \mathrm{d}x$ vaut $1/\eta$ si $\eta > 0$ et $+\infty$ sinon : l'espace des paramètres naturels est $\Xi =]0, +\infty[$, $A(\eta) = -\log \eta$, et $h(x) \exp(\eta T(x) - A(\eta)) = \eta \mathrm{e}^{-\eta x} \mathbb{1}_{\mathbb{R}^+}(x) = p_\eta(x)$. La famille des lois exponentielles est le modèle exponentiel canonique associé à (T, h).

(b) La densité de $\mathcal{N}(\eta,1)$ s'écrit

$$\frac{1}{\sqrt{2\pi}}\exp\Big(-\frac{(x-\eta)^2}{2}\Big)=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2}\exp\Big(\eta x-\frac{\eta^2}{2}\Big)\,.$$

Prenons $\mu=\mathrm{Leb}$, $h(x)=(2\pi)^{-1/2}\mathrm{e}^{-x^2/2}$ et $T(x)=x$. Pour tout $\eta\in\mathbb{R}$, en écrivant $x^2-2\eta x=(x-\eta)^2-\eta^2$, $G(\eta)=(2\pi)^{-1/2}\int_{\mathbb{R}}\exp(-(x^2-2\eta x)/2)\,\mathrm{d}x=\mathrm{e}^{\eta^2/2}$. Ainsi $\Xi=\mathbb{R}$, $A(\eta)=\eta^2/2$, et la famille $\{\mathcal{N}(\eta,1)\,,\ \eta\in\mathbb{R}\}$ est le modèle exponentiel canonique associé à (T,h).

(c) La densité de Weibull s'écrit, pour $x>0$,

$$q_\lambda(x)=\alpha x^{\alpha-1}\,\lambda^{-\alpha}\exp\big(-\lambda^{-\alpha}x^\alpha\big)=h(x)\exp\big(\varphi(\lambda)T(x)-B(\lambda)\big)$$

avec $h(x)=\alpha x^{\alpha-1}\mathbb{1}_{]0,+\infty[}(x)$, $T(x)=-x^\alpha$, $\varphi(\lambda)=\lambda^{-\alpha}$ et $B(\lambda)=\alpha\log\lambda$. C'est une famille exponentielle au sens général : le paramètre λ n'intervient que par $\varphi(\lambda)=\lambda^{-\alpha}$, et le modèle n'est pas canonique en λ, sauf si $\alpha=1$, où l'on retrouve les lois exponentielles. Le modèle canonique associé est obtenu par la reparamétrisation $\eta=\lambda^{-\alpha}$: le changement de variable $u=x^\alpha$ donne $G(\eta)=\int_0^{+\infty}\alpha x^{\alpha-1}\mathrm{e}^{-\eta x^\alpha}\,\mathrm{d}x=\int_0^{+\infty}\mathrm{e}^{-\eta u}\,\mathrm{d}u$, qui vaut $1/\eta$ si $\eta>0$ et $+\infty$ sinon : $\Xi=]0,+\infty[$ et $A(\eta)=-\log\eta$.

(d) La loi de Poisson de paramètre $\theta>0$ a pour densité, par rapport à la mesure de comptage μ sur $\mathbb{N}$,

$$p_\theta(k)=\mathrm{e}^{-\theta}\frac{\theta^k}{k!}=\frac{1}{k!}\exp\big(k\log\theta-\theta\big)\,,\qquad k\in\mathbb{N}\,,$$

ce qui est la forme $h(k)\exp(\varphi(\theta)T(k)-B(\theta))$ avec $h(k)=1/k!$, $T(k)=k$, $\varphi(\theta)=\log\theta$, $B(\theta)=\theta$ et $\Theta=]0,+\infty[$. Le modèle canonique associé s'obtient en posant $\eta=\log\theta\in\mathbb{R}$: pour tout $\eta\in\mathbb{R}$, $G(\eta)=\sum_{k\in\mathbb{N}}\mathrm{e}^{\eta k}/k!=\exp(\mathrm{e}^\eta)<\infty$, donc $\Xi=\mathbb{R}$, $A(\eta)=\mathrm{e}^\eta=B(\mathrm{e}^\eta)$, et $q_\eta(k)=\frac{1}{k!}\exp(\eta k-\mathrm{e}^\eta)$.

(e) Pour $k\in\{0,\dots,n\}$,

$$p_\theta(k)=\binom{n}{k}\theta^k(1-\theta)^{n-k}=\binom{n}{k}\exp\Big(k\log\frac{\theta}{1-\theta}+n\log(1-\theta)\Big)\,,$$

ce qui est la forme annoncée avec $h(k)=\binom{n}{k}$, $T(k)=k$, $\varphi(\theta)=\log(\theta/(1-\theta))$, $B(\theta)=-n\log(1-\theta)$, $\Theta=]0,1[$, et μ la mesure de comptage sur $\{0,\dots,n\}$. Le modèle canonique associé s'obtient en posant $\eta=\log(\theta/(1-\theta))\in\mathbb{R}$, c'est-à-dire $\theta=\mathrm{e}^\eta/(1+\mathrm{e}^\eta)$: pour tout $\eta\in\mathbb{R}$, $G(\eta)=\sum_{k=0}^n\binom{n}{k}\mathrm{e}^{\eta k}=(1+\mathrm{e}^\eta)^n<\infty$, donc $\Xi=\mathbb{R}$ et $A(\eta)=n\log(1+\mathrm{e}^\eta)=B\big(\mathrm{e}^\eta/(1+\mathrm{e}^\eta)\big)$.

2. (a) Si l'on peut dériver deux fois sous le signe intégral, $G'(\eta)=\int hT\mathrm{e}^{\eta T}\,\mathrm{d}\mu$ et $G''(\eta)=\int hT^2\mathrm{e}^{\eta T}\,\mathrm{d}\mu$, de sorte que, q_η étant égale à $h\mathrm{e}^{\eta T}/G(\eta)$,

$$A'(\eta)=\frac{G'(\eta)}{G(\eta)}=\int Tq_\eta\,\mathrm{d}\mu=\mathbb{E}_\eta[T(X)]\,,$$
$$A''(\eta)=\frac{G''(\eta)}{G(\eta)}-\Big(\frac{G'(\eta)}{G(\eta)}\Big)^2=\mathbb{E}_\eta[T(X)^2]-\mathbb{E}_\eta[T(X)]^2=\mathrm{Var}_\eta(T(X))\,.$$

La question (c) justifie ces dérivations sous l'intégrale lorsque Ξ est un intervalle ouvert.

(b) Si Ξ est vide, il n'y a rien à démontrer. Sinon, soit $\eta_0\in\Xi$: $0<G(\eta_0)<\infty$, ce qui impose $\mu(\{h>0\})>0$. Pour tout $\eta\in\mathbb{R}$, la fonction $h\mathrm{e}^{\eta T}$ est alors strictement positive sur l'ensemble $\{h>0\}$, de mesure strictement positive, donc $G(\eta)>0$ et $A(\eta)>-\infty$: ainsi $\Xi=\{\eta\in\mathbb{R}:\ A(\eta)<+\infty\}$. Soient $\eta_1,\eta_2\in\Xi$ et $\lambda\in]0,1[$.

L'inégalité de Hölder, pour les exposants conjugués $1/\lambda$ et $1/(1-\lambda)$, appliquée aux fonctions positives $(h\mathrm{e}^{\eta_1 T})^\lambda$ et $(h\mathrm{e}^{\eta_2 T})^{1-\lambda}$, donne

$$G(\lambda\eta_1+(1-\lambda)\eta_2) = \int \big(h\mathrm{e}^{\eta_1 T}\big)^\lambda \big(h\mathrm{e}^{\eta_2 T}\big)^{1-\lambda}\,\mathrm{d}\mu \\ \le \Big(\int h\mathrm{e}^{\eta_1 T}\,\mathrm{d}\mu\Big)^\lambda \Big(\int h\mathrm{e}^{\eta_2 T}\,\mathrm{d}\mu\Big)^{1-\lambda} = G(\eta_1)^\lambda\, G(\eta_2)^{1-\lambda} < \infty\,,$$

soit, en passant au logarithme, $A(\lambda\eta_1+(1-\lambda)\eta_2) \le \lambda A(\eta_1)+(1-\lambda)A(\eta_2) < +\infty$. Ainsi $\lambda\eta_1+(1-\lambda)\eta_2 \in \Xi$, ce qui montre que Ξ est convexe, et l'inégalité obtenue est la convexité de A sur Ξ.

(c) Soit $\eta \in \Xi$. Comme Ξ est ouvert, il existe $\varepsilon > 0$ tel que $\eta \pm \varepsilon \in \Xi$. De $\mathrm{e}^{\varepsilon|T|} \le \mathrm{e}^{\varepsilon T} + \mathrm{e}^{-\varepsilon T}$, on tire

$$\int h\,\mathrm{e}^{\varepsilon|T|}\mathrm{e}^{\eta T}\,\mathrm{d}\mu \le G(\eta+\varepsilon)+G(\eta-\varepsilon) < \infty\,. \tag{6}$$

Pour tout entier $m \ge 0$, la constante $C_m := \sup_{u\ge 0} u^m \mathrm{e}^{-\varepsilon u/2}$ est finie et $|T|^m \mathrm{e}^{\varepsilon|T|/2} \le C_m \mathrm{e}^{\varepsilon|T|}$; avec (6), il vient

$$\int h\,|T|^m \mathrm{e}^{\varepsilon|T|/2}\mathrm{e}^{\eta T}\,\mathrm{d}\mu < \infty\,, \qquad m \in \mathbb{N}\,. \tag{7}$$

En particulier, $h|T|^m\mathrm{e}^{\eta T}$ est μ-intégrable pour tout $m \in \mathbb{N}$ et tout $\eta \in \Xi$, et l'on peut poser $G_m(\eta) := \int hT^m\mathrm{e}^{\eta T}\,\mathrm{d}\mu$, avec $G_0 = G$. Montrons que G_m est dérivable sur Ξ, de dérivée G_{m+1}. Pour $\eta \in \Xi$, ε comme ci-dessus et $0 < |s| \le \varepsilon/2$,

$$\frac{G_m(\eta+s)-G_m(\eta)}{s} = \int h\,T^m\mathrm{e}^{\eta T}\,\frac{\mathrm{e}^{sT}-1}{s}\,\mathrm{d}\mu\,.$$

Quand $s \to 0$, l'intégrande converge en tout point vers $hT^{m+1}\mathrm{e}^{\eta T}$. L'inégalité des accroissements finis appliquée à $u \mapsto \mathrm{e}^u$ entre 0 et $sT(x)$ donne $|\mathrm{e}^{sT(x)}-1| \le |s|\,|T(x)|\,\mathrm{e}^{|s|\,|T(x)|}$, donc

$$\Big|h\,T^m\mathrm{e}^{\eta T}\,\frac{\mathrm{e}^{sT}-1}{s}\Big| \le h\,|T|^{m+1}\mathrm{e}^{\varepsilon|T|/2}\mathrm{e}^{\eta T}\,,$$

fonction μ-intégrable d'après (7) et indépendante de s. Le théorème de convergence dominée, appliqué le long de toute suite $s_j \to 0$, donne $G_m'(\eta) = G_{m+1}(\eta)$. Par récurrence sur k, G est infiniment dérivable sur Ξ et $G^{(k)} = G_k$, ce qui est la formule demandée. Comme $G > 0$ sur Ξ, la fonction $A = \log G$ est elle aussi infiniment dérivable sur Ξ, et les formules de la question (a) sont établies : $A' = G'/G$ et $A'' = G''/G - (G'/G)^2$.

(d) i. Le moment exact associé à T est $e(\eta) = \mathbb{E}_\eta[T(X_1)] = \int Tq_\eta\,\mathrm{d}\mu = G'(\eta)/G(\eta) = A'(\eta)$, bien défini d'après (7). L'estimateur des moments associé à T est donc la solution $\eta \in \Xi$, lorsqu'elle existe et est unique, de l'équation

$$A'(\eta) = \bar{T}_n\,, \qquad \bar{T}_n := \frac{1}{n}\sum_{k=1}^n T(X_k)\,.$$

ii. Sous $q_\eta \cdot \mu$, les variables $X_1,\dots,X_n$ sont i.i.d. de densité q_η ; la densité du n-échantillon par rapport à $\mu^{\otimes n}$ est

$$(x_1,\dots,x_n) \mapsto \Big(\prod_{k=1}^n h(x_k)\Big)\exp\Big(\eta\sum_{k=1}^n T(x_k) - nA(\eta)\Big)\,,$$

et la log-vraisemblance normalisée s'écrit, sur Ξ,

$$\ell_n(\eta) = \frac{1}{n}\sum_{k=1}^{n} \log h(X_k) + \eta\,\bar{T}_n - A(\eta)\ ,$$

où $\log h(X_k)$ est fini presque sûrement, puisque $\mathbb{P}_\eta(h(X_1) = 0) = \int_{\{h=0\}} q_\eta \,\mathrm{d}\mu = 0$. D'après la question (c), ℓ_n est infiniment dérivable sur Ξ, avec $\ell_n'(\eta) = \bar{T}_n - A'(\eta)$ et $\ell_n''(\eta) = -A''(\eta) = -\operatorname{Var}_\eta(T(X_1)) \leq 0$. Cette variance est nulle si et seulement si T est constante $q_\eta \cdot \mu$-presque sûrement, c'est-à-dire μ-presque partout sur $\{h > 0\}$, propriété qui ne dépend pas de η ; dans ce cas dégénéré, A est affine, q_η ne dépend pas de η, le modèle n'est pas identifiable et tout point de Ξ maximise la vraisemblance. Supposons donc $\operatorname{Var}_\eta(T(X_1)) > 0$ pour un, donc pour tout, $\eta \in \Xi$. Alors $\ell_n'' < 0$: la log-vraisemblance est strictement concave sur l'intervalle ouvert Ξ, et A' est continue et strictement croissante. D'après le Lemme 2.3, l'équation de vraisemblance $A'(\eta) = \bar{T}_n$ a au plus une solution, et cette solution, lorsqu'elle existe, est l'unique estimateur du maximum de vraisemblance ; elle existe si et seulement si $\bar{T}_n$ appartient à l'intervalle ouvert $A'(\Xi)$, et, dans le cas contraire, la log-vraisemblance n'a pas de maximum sur Ξ, un maximum intérieur étant nécessairement un point critique. On remarque que l'équation de vraisemblance est l'équation des moments de la question précédente : dans un modèle exponentiel canonique, l'estimateur du maximum de vraisemblance et l'estimateur des moments associé à la statistique T existent simultanément et coïncident. C'est ce que l'on a observé pour les modèles de Bernoulli (Exemple 1.8), de Poisson (Exemple 1.9) et gaussien (Exemple 1.10).

3. Dans le modèle exponentiel général, la normalisation $\int p_\theta \,\mathrm{d}\mu = 1$ impose $\mathrm{e}^{B(\theta)} = \int h \mathrm{e}^{\varphi(\theta)T}\,\mathrm{d}\mu = G(\varphi(\theta))$, c'est-à-dire $B = A \circ \varphi$ sur Θ. Puisque φ est un difféomorphisme de Θ sur Ξ, elle est dérivable, de dérivée ne s'annulant pas, et B est dérivable avec $B' = (A' \circ \varphi)\,\varphi'$. Sous $p_\theta \cdot \mu$, la densité du n-échantillon par rapport à $\mu^{\otimes n}$ est $\big(\prod_{k=1}^n h(x_k)\big) \exp\big(\varphi(\theta)\sum_{k=1}^n T(x_k) - nB(\theta)\big)$, et la log-vraisemblance normalisée vaut

$$\tilde{\ell_n}(\theta) = \frac{1}{n}\sum_{k=1}^{n} \log h(X_k) + \varphi(\theta)\,\bar{T}_n - B(\theta) = \ell_n(\varphi(\theta))\ ,$$

où ℓ_n est la log-vraisemblance du modèle canonique de la question 2(d). L'équation de vraisemblance $\tilde{\ell_n}'(\theta) = \varphi'(\theta)\bar{T}_n - B'(\theta) = 0$ s'écrit, en divisant par $\varphi'(\theta) \neq 0$,

$$\frac{B'(\theta)}{\varphi'(\theta)} = \bar{T}_n \qquad \text{soit} \qquad A'(\varphi(\theta)) = \bar{T}_n\ .$$

Sa solution est donc $\hat{\theta}_n = \varphi^{-1}(\hat{\eta}_n)$, où $\hat{\eta}_n$ est la solution dans Ξ de l'équation $A'(\eta) = \bar{T}_n$: l'existence et l'unicité de $\hat{\theta}_n$ équivalent à celles de $\hat{\eta}_n$. Comme $\tilde{\ell_n} = \ell_n \circ \varphi$ avec φ bijective, les points de maximum de $\tilde{\ell_n}$ sont les images réciproques par φ de ceux de ℓ_n : c'est l'invariance de l'estimateur du maximum de vraisemblance par reparamétrisation (Proposition 1.2). Pour la loi de Poisson, $A'(\eta) = \mathrm{e}^\eta$ et l'on retrouve $\hat{\theta}_n = \mathrm{e}^{\hat{\eta}_n} = \bar{X}_n$ (Exemple 1.9) ; pour la loi binomiale à m essais (le nombre noté n à la question 1(e)), $A'(\eta) = m\mathrm{e}^\eta/(1+\mathrm{e}^\eta)$ et $\hat{\theta}_n = \bar{X}_n/m$.

Corrigé de l'exercice 4 – Durée de vie

On note $\theta = (\lambda_0, \lambda_1) \in \Theta = (\mathbb{R}_+^*)^2$, et X_0, X_1 les durées de vie des deux machines, indépendantes sous $\mathbb{P}_\theta$, de lois $\mathcal{E}(\lambda_0)$ et $\mathcal{E}(\lambda_1)$.

1. Si $X \sim \mathcal{E}(\lambda)$, alors, pour tout $x > 0$, $\mathbb{P}(X > x) = \int_x^{+\infty} \lambda \mathrm{e}^{-\lambda t}\,\mathrm{d}t = \mathrm{e}^{-\lambda x}$. Réciproquement, supposons $\mathbb{P}(X > x) = \mathrm{e}^{-\lambda x}$ pour tout $x > 0$. La fonction de répartition F_X de X vérifie alors $F_X(x) = 1 - \mathrm{e}^{-\lambda x}$ pour $x > 0$; par continuité à droite, $F_X(0) = \lim_{x \downarrow 0} F_X(x) = 0$, et, F_X étant croissante et positive, $F_X(x) = 0$ pour tout $x \leq 0$. Ainsi F_X coïncide sur $\mathbb{R}$ avec la fonction de répartition de la loi $\mathcal{E}(\lambda)$; la fonction de répartition caractérisant la loi, $X \sim \mathcal{E}(\lambda)$.

2. Le système fonctionne tant que les deux machines fonctionnent : sa durée de vie est $Z = X_0 \wedge X_1 = \min(X_0, X_1)$. Pour $t > 0$, par indépendance et d'après la question 1,

$$\mathbb{P}_\theta(Z > t) = \mathbb{P}_\theta(X_0 > t,\ X_1 > t) = \mathbb{P}_\theta(X_0 > t)\,\mathbb{P}_\theta(X_1 > t) = \mathrm{e}^{-(\lambda_0+\lambda_1)t}\,,$$

et la question 1 donne $Z \sim \mathcal{E}(\lambda_0 + \lambda_1)$ sous $\mathbb{P}_\theta$. Le couple (X_0, X_1) a une densité par rapport à $\mathrm{Leb}^{\otimes 2}$ et la diagonale $\{x_0 = x_1\}$ est de mesure de Lebesgue nulle dans $\mathbb{R}^2$: $\mathbb{P}_\theta(X_0 = X_1) = 0$, et la panne est presque sûrement due à une seule machine. Elle est due à la machine 1 sur l'événement $\{X_1 < X_0\}$, de probabilité

$$\begin{aligned}\mathbb{P}_\theta(X_1 < X_0) &= \int_0^{+\infty} \lambda_1 \mathrm{e}^{-\lambda_1 x_1} \Big(\int_{x_1}^{+\infty} \lambda_0 \mathrm{e}^{-\lambda_0 x_0}\,\mathrm{d}x_0 \Big) \mathrm{d}x_1 \\ &= \int_0^{+\infty} \lambda_1 \mathrm{e}^{-(\lambda_0+\lambda_1)x_1}\,\mathrm{d}x_1 = \frac{\lambda_1}{\lambda_0+\lambda_1}\,,\end{aligned}$$

par le théorème de Fubini appliqué à la densité produit.

3. Posons $I = \mathbb{1}_{\{X_1 < X_0\}}$. Pour $t \geq 0$, le même calcul donne

$$\begin{aligned}\mathbb{P}_\theta(Z > t,\ I = 1) = \mathbb{P}_\theta(t < X_1 < X_0) &= \int_t^{+\infty} \lambda_1 \mathrm{e}^{-\lambda_1 x_1} \mathrm{e}^{-\lambda_0 x_1}\,\mathrm{d}x_1 \\ &= \frac{\lambda_1}{\lambda_0+\lambda_1}\,\mathrm{e}^{-(\lambda_0+\lambda_1)t} = \mathbb{P}_\theta(I = 1)\,\mathbb{P}_\theta(Z > t)\,,\end{aligned}$$

et, en échangeant les rôles des deux machines, $\mathbb{P}_\theta(Z > t,\ I = 0) = \mathbb{P}_\theta(t < X_0 < X_1) = \frac{\lambda_0}{\lambda_0+\lambda_1}\mathrm{e}^{-(\lambda_0+\lambda_1)t} = \mathbb{P}_\theta(I = 0)\,\mathbb{P}_\theta(Z > t)$. Par passage au complémentaire, $\mathbb{P}_\theta(Z \leq t,\ I = \delta) = \mathbb{P}_\theta(I = \delta) - \mathbb{P}_\theta(Z > t,\ I = \delta) = \mathbb{P}_\theta(I = \delta)\,\mathbb{P}_\theta(Z \leq t)$ pour tout $t \geq 0$ et tout $\delta \in \{0, 1\}$, et cette égalité est immédiate pour $t < 0$, les deux membres étant nuls. Les classes $\{\{Z \leq t\},\ t \in \mathbb{R}\}$ et $\{\{I = 0\}, \{I = 1\}\}$ sont stables par intersection finie et engendrent respectivement $\sigma(Z)$ et $\sigma(I)$; l'indépendance de deux classes stables par intersection s'étend aux tribus qu'elles engendrent (lemme de classe monotone) : Z et I sont indépendantes sous $\mathbb{P}_\theta$.

4. (a) Les durées de vie $Z_1, \ldots, Z_n$ des n systèmes sont indépendantes et de même loi $\mathcal{E}(\lambda_0 + \lambda_1)$ sous $\mathbb{P}_\theta$: l'observation est un n-échantillon du modèle $\big(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{E}(\lambda_0 + \lambda_1)\,,\ \theta \in \Theta\}\big)$, c'est-à-dire le modèle

$$\Big(\mathbb{R}_+^n,\ \mathcal{B}(\mathbb{R}_+^n),\ \big\{\mathcal{E}(\lambda_0 + \lambda_1)^{\otimes n}\,,\ \theta = (\lambda_0, \lambda_1) \in (\mathbb{R}_+^*)^2\big\}\Big)\,,$$

dominé par $\mathrm{Leb}^{\otimes n}$, de densité $(z_1, \ldots, z_n) \mapsto \prod_{i=1}^n (\lambda_0 + \lambda_1)\mathrm{e}^{-(\lambda_0+\lambda_1)z_i}\,\mathbb{1}_{\mathbb{R}_+}(z_i)$. La loi des observations ne dépend de θ que par la somme $\lambda_0 + \lambda_1$: pour $0 < \tau < \lambda_1$, les paramètres (λ_0, λ_1) et $(\lambda_0 + \tau, \lambda_1 - \tau)$ sont distincts et définissent la même loi. Le modèle n'est pas identifiable (Définition 2) ; seule la somme $\lambda_0 + \lambda_1$ l'est.

(b) On observe maintenant les couples $(Z_1, I_1), \dots, (Z_n, I_n)$, indépendants et de même loi que (Z, I). Déterminons cette loi. Pour $A \in \mathcal{B}(\mathbb{R}_+)$ et $\delta \in \{0, 1\}$, par indépendance de Z et I (question 3), et en notant λ_δ le paramètre de la machine δ,

$$\begin{aligned}\mathbb{P}_\theta(Z \in A,\ I = \delta) &= \mathbb{P}_\theta(Z \in A)\, \mathbb{P}_\theta(I = \delta) \\ &= \int_A (\lambda_0 + \lambda_1) \mathrm{e}^{-(\lambda_0+\lambda_1)z}\, \mathrm{d}z \times \frac{\lambda_\delta}{\lambda_0 + \lambda_1} = \int_A \lambda_\delta\, \mathrm{e}^{-(\lambda_0+\lambda_1)z}\, \mathrm{d}z\ .\end{aligned}$$

La loi de (Z, I) sur $\mathbb{R}_+ \times \{0, 1\}$ admet donc, par rapport à la mesure $\mu := \mathrm{Leb} \otimes \nu$, où ν est la mesure de comptage sur $\{0, 1\}$, la densité

$$q_\theta(z, \delta) = \lambda_\delta\, \mathrm{e}^{-(\lambda_0+\lambda_1)z} \mathbb{1}_{\mathbb{R}_+}(z)\ , \qquad (z, \delta) \in \mathbb{R}_+ \times \{0, 1\}\ .$$

L'observation est un n-échantillon du modèle

$$\big(\mathbb{R}_+ \times \{0, 1\},\ \mathcal{B}(\mathbb{R}_+) \otimes \mathcal{P}(\{0, 1\}),\ \{q_\theta \cdot \mu\,,\ \theta \in \Theta\}\big)\ ,$$

c'est-à-dire le modèle

$$\Big((\mathbb{R}_+ \times \{0, 1\})^n,\ \big(\mathcal{B}(\mathbb{R}_+) \otimes \mathcal{P}(\{0, 1\})\big)^{\otimes n},\ \big\{(q_\theta \cdot \mu)^{\otimes n}\,,\ \theta \in \Theta\big\}\Big)\ .$$

Ce modèle est identifiable : si $\theta = (\lambda_0, \lambda_1)$ et $\theta' = (\lambda'_0, \lambda'_1)$ définissent la même loi des observations, ils définissent la même loi de (Z_1, I_1), donc la même loi de I_1 et la même loi de Z_1, soit

$$\frac{\lambda_1}{\lambda_0 + \lambda_1} = \frac{\lambda'_1}{\lambda'_0 + \lambda'_1} \qquad \text{et} \qquad \mathcal{E}(\lambda_0 + \lambda_1) = \mathcal{E}(\lambda'_0 + \lambda'_1)\ ,$$

la seconde égalité entraînant $\lambda_0 + \lambda_1 = \lambda'_0 + \lambda'_1$, puisque la loi $\mathcal{E}(\lambda)$ a pour espérance $1/\lambda$. On en déduit $\lambda_1 = \lambda'_1$, puis $\lambda_0 = \lambda'_0$: $\theta = \theta'$. L'observation supplémentaire de la cause de chaque panne rend le modèle identifiable.

Complément : estimation dans le second modèle. Notons $N_\delta := \sum_{i=1}^n \mathbb{1}_{\{I_i = \delta\}}$ le nombre de pannes dues à la machine δ, avec $N_0 + N_1 = n$, et $\bar{Z}_n := n^{-1} \sum_{i=1}^n Z_i$, qui est strictement positive presque sûrement. Pour $\vartheta = (l_0, l_1) \in \Theta$, la vraisemblance et la log-vraisemblance normalisée du second modèle s'écrivent

$$\begin{aligned}\mathrm{L}_n(\vartheta) &= \prod_{i=1}^n l_{I_i}\, \mathrm{e}^{-(l_0+l_1)Z_i} = l_0^{N_0}\, l_1^{N_1}\, \mathrm{e}^{-(l_0+l_1)n\bar{Z}_n}\ , \\ \ell_n(\vartheta) &= \frac{N_0}{n} \log l_0 + \frac{N_1}{n} \log l_1 - (l_0 + l_1)\bar{Z}_n\ .\end{aligned}$$

La log-vraisemblance est la somme de deux fonctions d'une seule variable, $l_\delta \mapsto \frac{N_\delta}{n} \log l_\delta - l_\delta \bar{Z}_n$. Si $N_\delta > 0$, cette fonction est strictement concave sur $\mathbb{R}_+^*$, de dérivée $N_\delta/(nl_\delta) - \bar{Z}_n$, nulle en $l_\delta = N_\delta/(n\bar{Z}_n)$ seulement, qui est donc son unique point de maximum (Lemme 2.3). Si $N_\delta = 0$, elle se réduit à $l_\delta \mapsto -l_\delta \bar{Z}_n$, strictement décroissante, et n'a pas de maximum sur $\mathbb{R}_+^*$. Ainsi, sur l'événement $\{N_0 > 0,\ N_1 > 0\}$, dont la probabilité tend vers 1 puisque $\mathbb{P}_\theta(N_\delta = 0) = (1 - \mathbb{P}_\theta(I = \delta))^n \to 0$, l'estimateur du maximum de vraisemblance existe, est unique, et vaut

$$\hat{\lambda}_\delta = \frac{N_\delta}{\sum_{i=1}^n Z_i}\ , \qquad \delta \in \{0, 1\}\ :$$

le nombre de pannes imputables à la machine δ, rapporté à la durée totale de fonctionnement observée.

Corrigé de l'exercice 5 – Modèle auto-régressif

Les observations ne sont ni indépendantes ni de même loi : la vraisemblance n'est pas celle d'un n-échantillon, mais sa définition s'étend à tout modèle dominé, comme densité de l'observation vue comme fonction du paramètre (voir le modèle de régression, Section 4). Pour $v > 0$, on note $g_v(u) := (2\pi v)^{-1/2}\exp(-u^2/(2v))$ la densité de $\mathcal{N}(0, v)$. On suppose $n \geq 2$: avec une seule observation $X_1 \sim \mathcal{N}(0, \sigma^2)$, le paramètre ϕ n'intervient pas dans la loi de l'observation et ne peut être estimé.

1. Fixons $\theta = (\phi, \sigma^2) \in \Theta$. Montrons que, sous $\mathbb{P}_\theta$, la loi de $Z = (X_1, \dots, X_n)$ admet, par rapport à $\mathrm{Leb}^{\otimes n}$, la densité, avec la convention $x_0 := 0$,

$$p_\theta(x_1, \dots, x_n) := \prod_{k=1}^{n} g_{\sigma^2}(x_k - \phi x_{k-1}) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\Big(-\frac{1}{2\sigma^2}\sum_{k=1}^{n}(x_k - \phi x_{k-1})^2\Big) \,. \quad (8)$$

Méthode de la fonction muette (Section 2). Soient $f_1, \dots, f_n : \mathbb{R} \to \mathbb{R}$ mesurables bornées. La loi conditionnelle de X_n sachant $(X_1, \dots, X_{n-1})$ étant $\mathcal{N}(\phi X_{n-1}, \sigma^2)$, on a $\mathbb{E}_\theta[f_n(X_n) \,|\, X_1, \dots, X_{n-1}] = \int_{\mathbb{R}} f_n(x_n)\, g_{\sigma^2}(x_n - \phi X_{n-1})\,\mathrm{d}x_n$ presque sûrement, et cette quantité est une fonction mesurable bornée $\tilde{f}_{n-1}(X_{n-1})$ de X_{n-1}. Par la propriété de conditionnement successif,

$$\begin{aligned}\mathbb{E}_\theta\Big[\prod_{k=1}^{n} f_k(X_k)\Big] &= \mathbb{E}_\theta\Big[\prod_{k=1}^{n-1} f_k(X_k)\,\mathbb{E}_\theta\big[f_n(X_n) \,|\, X_1, \dots, X_{n-1}\big]\Big] \\ &= \mathbb{E}_\theta\Big[\prod_{k=1}^{n-2} f_k(X_k)\,\big(f_{n-1}\tilde{f}_{n-1}\big)(X_{n-1})\Big] \,,\end{aligned}$$

expression de la même forme avec $n-1$ facteurs. En répétant l'opération, et puisque $X_1 \sim \mathcal{N}(\phi X_0, \sigma^2) = \mathcal{N}(0, \sigma^2)$, on obtient

$$\begin{aligned}\mathbb{E}_\theta\Big[\prod_{k=1}^{n} f_k(X_k)\Big] &= \int_{\mathbb{R}^n} \prod_{k=1}^{n} f_k(x_k) \prod_{k=1}^{n} g_{\sigma^2}(x_k - \phi x_{k-1})\,\mathrm{d}x_1 \cdots \mathrm{d}x_n \\ &= \int_{\mathbb{R}^n} \prod_{k=1}^{n} f_k(x_k)\, p_\theta(x)\,\mathrm{d}x \,.\end{aligned}$$

Appliquée à $f_k = \mathbb{1}_{A_k}$, $A_k \in \mathcal{B}(\mathbb{R})$, cette égalité donne $\mathbb{P}_\theta(Z \in A_1 \times \cdots \times A_n) = \int_{A_1\times\cdots\times A_n} p_\theta \,\mathrm{dLeb}^{\otimes n}$; avec $A_k = \mathbb{R}$ pour tout k, elle montre que p_θ, positive, est d'intégrale 1. La loi de Z et la probabilité $p_\theta \cdot \mathrm{Leb}^{\otimes n}$ coïncident donc sur la classe des pavés mesurables, stable par intersection finie et engendrant $\mathcal{B}(\mathbb{R}^n)$: elles sont égales (lemme de classe monotone). Le modèle engendré par l'observation Z est

$$\Big(\mathbb{R}^n,\ \mathcal{B}(\mathbb{R}^n),\ \big\{p_\theta \cdot \mathrm{Leb}^{\otimes n}\,,\ \theta = (\phi, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\big\}\Big) \,.$$

Lecture matricielle. Notons $M := \mathrm{I}_n - \phi J$, où J est la matrice de décalage, $(Jx)_k = x_{k-1}$ avec $x_0 = 0$: M est triangulaire inférieure, avec des 1 sur la diagonale et $-\phi$ sur la sous-diagonale, et $(Mx)_k = x_k - \phi x_{k-1}$. Ainsi $\sum_{k=1}^{n}(x_k - \phi x_{k-1})^2 = \|Mx\|^2 = x^T M^T M x$, avec

$$M^T M = \begin{bmatrix} 1+\phi^2 & -\phi & 0 & \cdots & 0 \\ -\phi & 1+\phi^2 & -\phi & \ddots & \vdots \\ 0 & -\phi & \ddots & \ddots & 0 \\ \vdots & \ddots & \ddots & 1+\phi^2 & -\phi \\ 0 & \cdots & 0 & -\phi & 1 \end{bmatrix} .$$

Comme $\det M = 1$, la matrice $\Sigma := (M^T M)^{-1} = M^{-1}(M^{-1})^T$ est symétrique définie positive, de déterminant 1, et $p_\theta(x) = (2\pi\sigma^2)^{-n/2}\exp(-x^T(\sigma^2\Sigma)^{-1}x/2)$ est la densité de la loi $\mathcal{N}(0,\sigma^2\Sigma)$ (Proposition 2.7 du chapitre 1) : sous $\mathbb{P}_\theta$, Z est un vecteur gaussien centré, de matrice de covariance $\sigma^2\Sigma$. La matrice $A := M^{-1}$ se calcule explicitement : J est nilpotente ($J^n = 0$), donc $A = (\mathrm{I}_n - \phi J)^{-1} = \sum_{j=0}^{n-1}\phi^j J^j$, matrice triangulaire inférieure de coefficients $A_{kj} = \phi^{k-j}$ pour $k \geq j$.

Seconde lecture : représentation par un bruit gaussien. Soient $\xi_1, \ldots, \xi_n$ i.i.d. de loi $\mathcal{N}(0,1)$, et définissons par récurrence $X_0 = 0$ et $X_k = \phi X_{k-1} + \sigma\xi_k$ pour $k \geq 1$. Comme $(X_1, \ldots, X_{k-1})$ est une fonction de $(\xi_1, \ldots, \xi_{k-1})$, indépendante de ξ_k, la loi conditionnelle de X_k sachant $(X_1, \ldots, X_{k-1})$ est $\mathcal{N}(\phi X_{k-1}, \sigma^2)$: cette récurrence réalise le modèle. En itérant, $X_k = \sigma\sum_{j=1}^{k}\phi^{k-j}\xi_j$, soit $Z = \sigma A\,\xi$ avec $\xi = (\xi_1, \ldots, \xi_n)^T \sim \mathcal{N}(0, \mathrm{I}_n)$, et la Proposition 2.4 du chapitre 1 redonne $Z \sim \mathcal{N}(0, \sigma^2 AA^T) = \mathcal{N}(0, \sigma^2\Sigma)$.

2. Pour $\vartheta = (a, v) \in \Theta$, la log-vraisemblance normalisée s'écrit, d'après (8),

$$\ell_n(\vartheta) = -\frac{1}{2}\log(2\pi v) - \frac{1}{2nv}\,Q(a)\,,$$
$$Q(a) := \sum_{k=1}^{n}(X_k - aX_{k-1})^2 = \sum_{k=1}^{n}X_k^2 - 2a\sum_{k=1}^{n}X_kX_{k-1} + a^2\sum_{k=1}^{n}X_{k-1}^2\,.$$

On procède comme à l'exercice 1. Posons $D := \sum_{k=1}^{n}X_{k-1}^2 = \sum_{k=1}^{n-1}X_k^2$. Comme $X_1 \sim \mathcal{N}(0,\sigma^2)$ a une densité, $X_1 \neq 0$ presque sûrement, et $D > 0$ presque sûrement dès que $n \geq 2$. Sur cet événement, à v fixé, maximiser ℓ_n en a revient à minimiser le trinôme Q, de coefficient dominant $D > 0$, dont l'unique minimum est atteint en

$$\hat\phi_n := \frac{\sum_{k=1}^{n}X_kX_{k-1}}{\sum_{k=1}^{n}X_{k-1}^2} = \frac{\sum_{k=2}^{n}X_kX_{k-1}}{\sum_{k=1}^{n-1}X_k^2}\,.$$

Posons $S := Q(\hat\phi_n)/n$. On a $Q(\hat\phi_n) = 0$ si et seulement si $X_k = \hat\phi_n X_{k-1}$ pour tout k, ce qui impose $X_1 = \hat\phi_n X_0 = 0$: $S > 0$ presque sûrement. La fonction $v \mapsto \ell_n(\hat\phi_n, v) = -\frac{1}{2}\log(2\pi v) - S/(2v)$ a pour dérivée $(S - v)/(2v^2)$, strictement positive pour $v < S$ et strictement négative pour $v > S$: elle atteint son maximum en $v = S$ seulement. Pour tout $(a, v) \in \Theta$, $\ell_n(a, v) \leq \ell_n(\hat\phi_n, v) \leq \ell_n(\hat\phi_n, S)$, avec égalité si et seulement si $(a, v) = (\hat\phi_n, S)$. Presque sûrement, l'estimateur du maximum de vraisemblance existe donc, est unique, et vaut

$$\big(\hat\phi_n, \hat\sigma_n^2\big) \qquad \text{avec} \qquad \hat\sigma_n^2 := \frac{1}{n}\sum_{k=1}^{n}\big(X_k - \hat\phi_n X_{k-1}\big)^2\,.$$

L'estimateur $\hat\phi_n$ est le coefficient des moindres carrés de la régression, sans terme constant, de X_k sur X_{k-1} : c'est la formule de l'exercice 1, dans laquelle la variable explicative x_i est remplacée par l'observation précédente X_{k-1}, qui est ici aléatoire. Cette dépendance entre variable explicative et observations distingue les séries temporelles du modèle de régression : la loi de $\hat\phi_n$ ne s'obtient plus par le théorème de Cochran, et son étude sort du cadre de ce chapitre.

Note. Le corrigé distribué en 2025 donnait l'estimateur $\hat\phi_n$ avec le dénominateur $\sum_{k=1}^{n}X_k^2$; l'annulation de la dérivée de Q conduit à $\sum_{k=1}^{n}X_{k-1}^2$. La représentation par un bruit gaussien y était écrite avec des ξ_k de loi $\mathcal{N}(0,1)$ puis $\mathcal{N}(0,\sigma^2)$; on a pris ici $\xi_k \sim \mathcal{N}(0,1)$ et fait apparaître le facteur σ.