2 Solutions

2.1 Exercice 1

1. La vraisemblance est donnée par

$$\theta \mapsto \frac{1}{\theta^n} \prod_{i=1}^{n} \mathbb{1}_{[0,\theta]}(X_i) = \frac{1}{\theta^n} \mathbb{1}_{X_{n:n} \leq \theta}$$

où $X_{n:n}$ désigne le maximum des points $X_1, \cdots, X_n$. C'est une fonction qui est non nulle sur $[X_{n:n}, +\infty[$ et décroissante sur $[X_{n:n}, +\infty[$. Le maximum est donc atteint en $X_{n:n}$. Ainsi

$$\hat{\theta}_n^{\mathrm{MV}} := X_{n:n}.$$

2. On cherche T tel que $\mathbb{E}_\theta[T(X)] = g(\theta)$ pour tout $\theta \in \mathbb{R}_+^*$ soit encore

$$\theta^{-1} \int_0^\theta T(x)\mathrm{d}x = g(\theta), \qquad \forall \theta > 0.$$

Cela implique que T a une primitive, s'annulant en 0 par prolongement par continuité, qui est $\theta \mapsto \theta g(\theta)$. D'où l'on tire

$$T(x) = (xg(x))' = g(x) + xg'(x)\ , \tag{2}$$

et on vérifie aisément qu'avec cette définition de T, on a bien $\mathbb{E}_\theta[\widehat{\theta}_n^{(1)}] = g(\theta)$ pour tout $\theta \in \mathbb{R}_+^*$.

3. Pour tout $x \in [0, \theta]$, $\mathbb{P}_\theta(X_{n:n} \leq x) = \mathbb{P}\left(\cap_{i=1}^n \{X_i \leq x\}\right) = (x/\theta)^n$ où a utilisé que sous $\mathbb{P}_\theta$, les v.a. $(X_i)_i$ sont indépendantes et ont même loi uniforme. D'où l'on tire que sous $\mathbb{P}_\theta$, $X_{n:n}$ est une v.a. ayant une densité par rapport à la mesure de Lebesgue donnée par

$$x \mapsto \mathbb{1}_{[0,\theta]}(x) \frac{\partial}{\partial x} \left(\frac{x}{\theta}\right)^n = \mathbb{1}_{[0,\theta]}(x) \frac{nx^{n-1}}{\theta^n}\ .$$

On veut $\mathbb{E}_\theta[\widetilde{T}(X_{n:n})] = g(\theta)$ soit encore

$$n\theta^{-n} \int_0^\theta \widetilde{T}(x) x^{n-1} \mathrm{d}x = g(\theta), \qquad \forall \theta > 0,$$

ce qui revient à dire qu'une primitive de $x \mapsto \widetilde{T}(x)x^{n-1}$, s'annulant en 0 par prolongement par continuité, est donnée par $\theta \mapsto \theta^n g(\theta)/n$. D'où l'on tire

$$\widetilde{T}(x) = \frac{1}{x^{n-1}} \left(\frac{x^n g(x)}{n}\right)' = g(x) + \frac{x}{n} g'(x)\ . \tag{3}$$

Une nouvelle fois, avec cette definition de $\widetilde{T}$, on obtient bien que $\mathbb{E}_\theta[\widehat{\theta}_n^{(2)}] = g(\theta)$ pour tout $\theta \in \mathbb{R}_+^*$.

4. Le risque quadratique d'un estimateur $T(Z)$ est défini par $R(\theta, T) = \mathbb{E}_\theta[(T(Z) - \theta)^2]$. En injectant $g(x) = x$ dans (2), on a $T(x) = 2x$ ce qui conduit à la stratégie d'estimation

$$\widehat{\theta}_n^{(1)} = \frac{2}{n} \sum_{k=1}^{n} X_k;$$

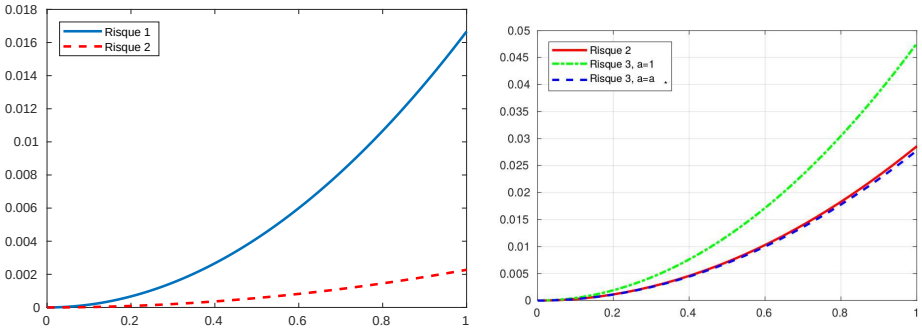


FIGURE 3 – Exercice 1 [gauche] Evolution de $\theta \mapsto \mathbb{E}_\theta\left[(\widehat{\theta}_n^{(i)} - \theta)^2\right]$ dans le cas $n = 20$. [droite] $\theta \mapsto \mathbb{E}_\theta\left[(\widehat{\theta}_n^{(i)} - \theta)^2\right]$ pour $i = 2, 3$ dans le cas $n = 5$; pour $\widehat{\theta}_n^{(3)}$, on a envisagé $a = 1$ et $a = a_\star$.

(on rappelle que sous $\mathbb{P}_\theta$, les X_i sont i.i.d. d'espérance $\theta/2$). Le risque quadratique de cet estimateur est

$$R(\theta, \widehat{\theta}_n^{(1)}) = n^{-1} \operatorname{Var}_\theta(T(X_1)) = n^{-1}\left(\theta^{-1}\int_0^\theta 4x^2 \mathrm{d}x - \theta^2\right) = \theta^2/(3n) \; .$$

De même, en injectant $g(x) = x$ dans (3), on obtient $\tilde{T}(x) = (1 + 1/n)x$ et donc la stratégie d'estimation

$$\widehat{\theta}_n^{(2)} = \frac{n+1}{n} X_{n:n}.$$

Son risque quadratique est

$$R(\theta, \widehat{\theta}_n^{(2)}) = \operatorname{Var}_\theta(\tilde{T}(X_{n:n})) = n\theta^{-n}\int_0^\theta x^2\left(1 + \frac{1}{n}\right)^2 x^{n-1}\mathrm{d}x - \theta^2$$
$$= \frac{(n+1)^2}{n(n+2)}\theta^2 - \theta^2 = \frac{\theta^2}{n(n+2)} \; .$$

Comme $n > 1$, il vient que

$$R(\theta, \widehat{\theta}_n^{(2)}) = \frac{\theta^2}{n(n+2)} < \frac{\theta^2}{3n} = R(\theta, \widehat{\theta}_n^{(1)}) \; ,$$

ce qui montre l'inadmissibilité de $\widehat{\theta}_n^{(1)}$. On montre l'évolution du risque de chacun des deux estimateurs en fonction de $\theta \in [0, 1]$ sur la figure 4.

5. On a

$$\mathbb{E}_\theta[X_{n:n}] = n\theta^{-n}\int_0^\theta x(x^{n-1})\mathrm{d}x = n\theta/(n+1)$$
$$\mathbb{E}_\theta[X_{n:n}^2] = n\theta^{-n}\int_0^\theta x^2(x^{n-1})\mathrm{d}x = n\theta^2/(n+2) \; .$$

D'où l'on tire

$$R(\theta, \widehat{\theta}_{n,a}^{(3)}) = a^2\mathbb{E}_\theta[X_{n:n}^2] - 2a\theta\mathbb{E}_\theta[X_{n:n}] + \theta^2 = \left(a^2\frac{n}{n+2} - 2a\frac{n}{n+1} + 1\right)\theta^2$$

Choisissons a de façon à minimiser ce risque ; on trouve $a_\star = (n+2)/(n+1)$. On obtient alors

$$R(\theta, \widehat{\theta}^{(3)}_{n,a_\star}) = \frac{\theta^2}{(n+1)^2},$$

et puisque $(n+1)^2 > n(n+2)$ pour tout $n \geq 1$, il vient que pour tout $n \geq 1$

$$R(\theta, \widehat{\theta}^{(3)}_{n,a_\star}) < R(\theta, \widehat{\theta}^{(2)}_n), \qquad \forall \theta > 0,$$

ce qui montre bien que $\widehat{\theta}^{(2)}_n$ est inadmissible (et par conséquent aussi $\widehat{\theta}^{(1)}_n$).

2.2 Exercice 2

1. On pose $\theta = (\beta_1, \beta_2)^T$, $\mathbf{Y} = (Y_1, \dots, Y_n)^T$, $\mathbf{1} = (1, \dots, 1)^T$, $\mathbf{x} = (x_1, \dots, x_n)^T$ et $\mathbf{X} = [\mathbf{1}\ \mathbf{x}]$. La log-vraisemblance s'écrit :

$$\ell_n(\theta; Y_1, \dots, Y_n) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\mathbf{Y} - \mathbf{X}\theta\|^2$$

D'où l'on tire

$$\nabla_\theta \ell_n(\theta; Y_1, \dots, Y_n) = \frac{1}{\sigma^2}\mathbf{X}^T(\mathbf{Y} - \mathbf{X}\theta)$$

Ce qui donne

$$\begin{aligned}\mathbb{I}(\beta_1, \beta_2) &= \mathbb{E}_\theta[\nabla_\theta \ell_n(\theta; Y_1, \dots, Y_n)\ \nabla_\theta \ell_n^T(\theta; Y_1, \dots, Y_n)] \\ &= \sigma^{-4}\mathbf{X}^T\mathbb{E}_\theta[(\mathbf{Y} - \mathbf{X}\theta)(\mathbf{Y} - \mathbf{X}\theta)^T]\mathbf{X} \\ &= \sigma^{-2}\mathbf{X}^T\mathbf{X} = n\sigma^{-2}\begin{bmatrix} 1 & n^{-1}\sum_{i=1}^n x_i \\ n^{-1}\sum_{i=1}^n x_i & n^{-1}\|\mathbf{x}\|^2 \end{bmatrix}\end{aligned}$$

L'autre façon de calculer la matrice d'information de Fisher serait d'utiliser la formule avec la Hessienne mais comme on va le faire dans la 3ème question, on utilise cette formule de l'information de Fisher ici.

2. On pose $g(\theta) = \beta_1$. Donc $\nabla_\theta g(\theta) = (1, 0)^T$. Le modèle étant régulier, tout estimateur sans biais régulier de $g : \theta \mapsto g(\theta) = \beta_1$ a une variance bornée inférieurement par la borne de Cramer-Rao, borne qui s'écrit alors

$$\nabla_\theta g(\theta)^T \mathbb{I}^{-1}(\beta_1, \beta_2)\nabla_\theta g(\theta) = \sigma^2 \frac{\|\mathbf{x}\|^2}{n\|\mathbf{x}\|^2 - (\sum_{i=1}^n x_i)^2} = \frac{\sigma^2}{n}\frac{\|\mathbf{x}\|^2}{\|\mathbf{x}\|^2 - n(n^{-1}\sum_{i=1}^n x_i)^2}.$$

Observons que cette borne est minorée par σ^2/n (voir question suivante).

3. On se place maintenant dans le cas où $\theta = \beta_1$, la valeur de β_2 étant supposée connue. Alors, la log-vraisemblance s'écrit :

$$\tilde{\ell}_n(\beta_1; Y_1, \dots, Y_n) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^n (Y_i - \beta_1 - \beta_2 x_i)^2\ .$$

On dérive ensuite deux fois par rapport à β_1. On en déduit

$$\tilde{\mathbb{I}}(\beta_1) = \mathbb{E}_\theta\left[-\frac{\partial^2 \tilde{\ell}_n(\beta_1; Y_1, \dots, Y_n)}{\partial \beta_1^2}\right] = \frac{n}{\sigma^2}$$

On en tire que la borne inférieure d'un estimateur sans biais régulier de β_1 est $\tilde{\mathbb{I}}(\beta_1)^{-1} = \sigma^2/n$. On constate que la borne trouvée ici est inférieure à celle trouvée à la question 2. En effet, dans cette question la classe des estimateurs sans biais de β_1 est plus grande (car on peut utiliser la valeur de β_2, supposée connue, pour construire notre estimateur sans biais de β_1). Il est donc normal d'être capable d'avoir une meilleure précision sur β_1 que si on se restreint à des estimateurs n'utilisant pas la valeur de β_2.

4. Pour cette dernière question, on pose cette fois $g(\theta) = \beta_1\beta_2$ de sorte que $\nabla_\theta g(\theta) = (\beta_2, \beta_1)^T$. En inversant la matrice d'information de Fisher en question 1, il vient

$$\mathbb{I}^{-1}(\beta_1, \beta_2) = \frac{\sigma^2}{n\|\mathbf{x}\|^2 - (\sum_{i=1}^n x_i)^2} \begin{pmatrix} \|\mathbf{x}\|^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix}$$

ce qui donne une borne inférieure pour la variance de tout estimateur sans biais de g qui est :

$$\nabla_\theta g(\theta)^T \mathbb{I}^{-1}(\beta_1, \beta_2) \nabla_\theta g(\theta) = \frac{\sigma^2}{n\|\mathbf{x}\|^2 - (\sum_{i=1}^n x_i)^2} \left(\beta_2^2 \|\mathbf{x}\|^2 - 2\beta_1\beta_2 \sum_{i=1}^n x_i + n\beta_1^2 \right)$$

2.3 Exercice 3

1. Par Cauchy-Schwarz,

$$\begin{aligned}\{\mathrm{Cov}_\theta(T(Z),\Psi(Z))\}^2 &= \mathbb{E}_\theta^2\left[(T(Z)-\mathbb{E}_\theta[T(Z)])(\Psi(Z)-\mathbb{E}_\theta[\Psi(Z)])\right]\\ &\le \mathbb{E}_\theta[(T(Z)-\mathbb{E}_\theta[T(Z)])^2]\mathbb{E}_\theta[(\Psi(Z)-\mathbb{E}_\theta[\Psi(Z)])^2] = \mathrm{Var}_\theta(T(Z))\,\mathrm{Var}_\theta(\Psi(Z))\ .\end{aligned}$$

   On conclut en observant que $0 < \mathrm{Var}_\theta(\Psi(Z)) < \infty$ par hypothèses.

2. Pour tout $\alpha \in \Theta$, posons $A_\alpha := \{z \in \mathsf{Z}\,; p_\alpha(z) > 0\}$. D'après l'énoncé, on a $A_{\theta-\delta} \subset A_\theta$.

$$\begin{aligned}\mathbb{E}_\theta[\Psi(Z)] &= \int\left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)}-1\right)\mathbb{1}_{A_\theta}(z)p_\theta(z)\mu(\mathrm{d}z) = \int[p_{\theta-\delta}(z)-p_\theta(z)]\mathbb{1}_{A_\theta}(z)\mu(\mathrm{d}z)\\ &= \int p_{\theta-\delta}(z)\mathbb{1}_{A_{\theta-\delta}}(z)\mu(\mathrm{d}z) - \int p_\theta(z)\mathbb{1}_{A_\theta}(z)\mu(\mathrm{d}z) = 1-1 = 0\ .\end{aligned}$$

   Dans l'avant-dernière égalité, on a utilisé le fait que par définition de A_θ,

$$p_{\theta-\delta}\mathbb{1}_{A_\theta} = p_{\theta-\delta}\mathbb{1}_{A_{\theta-\delta}}.$$

   Par suite,

$$\begin{aligned}\mathrm{Cov}_\theta(T(Z),\Psi(Z)) &= \mathbb{E}_\theta[T(Z)\Psi(Z)] = \int T(z)\left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)}-1\right)\mathbb{1}_{A_\theta}(z)p_\theta(z)\mu(\mathrm{d}z)\\ &= \int T(z)[p_{\theta-\delta}(z)\mathbb{1}_{A_{\theta-\delta}}(z) - p_\theta(z)\mathbb{1}_{A_\theta}(z)]\mu(\mathrm{d}z) = g(\theta-\delta)-g(\theta)\ .\end{aligned}$$

3. En combinant les deux dernières questions, il vient

$$\mathrm{Var}_\theta(T(Z)) \ge \frac{(g(\theta-\delta)-g(\theta))^2}{\int_{A_\theta}\left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)}-1\right)^2 p_\theta(z)\mu(\mathrm{d}z)} = \frac{(g(\theta)-g(\theta-\delta))^2}{\int_{A_\theta}\left(1-\frac{p_{\theta-\delta}(z)}{p_\theta(z)}\right)^2 p_\theta(z)\mu(\mathrm{d}z)}$$

4. On a

$$\mathrm{Var}_\theta(T(Z)) \ge \frac{\left(\frac{g(\theta)-g(\theta-\delta)}{\delta}\right)^2}{\int_{A_\theta}\left(\frac{p_\theta(z)-p_{\theta-\delta}(z)}{\delta}\right)^2\frac{1}{p_\theta(z)}\mu(\mathrm{d}z)}.$$

   Pour pouvoir retrouver la borne de Cramer-Rao, il faudrait pouvoir passer à la limite dans le membre de droite en faisant tendre δ vers 0, (ce qui necessite déjà que $\theta-\delta \in \Theta$ pour tout δ suffisamment petit). Il faut ensuite que g soit dérivable en θ ; et enfin que l'on puisse permuter limite et intégrale dans le dénominateur du membre de droite. Si toutes ces conditions sont remplies, on obtient alors :

$$\mathrm{Var}_\theta(T(Z)) \ge (g'(\theta))^2/\mathbb{I}(\theta) \quad \text{avec } \mathbb{I}(\theta) = \mathbb{E}_\theta\left[\left(\frac{\partial \log p_\theta(Z)}{\partial\theta}\right)^2\right]$$

   qui est bien la borne de Cramer-Rao (en dimension 1).

5. Posons $z = (x_1, \cdots, x_n)$. Nous nous plaçons maintenant dans le cas particulier $g(\theta) = \theta$,

$$p_\theta(z) = \theta^{-n} \prod_{i=1}^{n} \mathbb{1}_{[0,\theta]}(x_i);$$

et μ est la mesure de Lebesgue sur $\mathbb{R}^n$. On vérifie que si $\delta \in]0, \theta[$, alors $p_\theta(z) = 0$ implique $p_{\theta-\delta}(z) = 0$. Ceci permet d'appliquer la borne obtenue en question 3 :

$$\mathrm{Var}_\theta(T(Z)) \geq \frac{\delta^2}{\int_{A_\theta} \left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)} - 1\right)^2 p_\theta(z)\ \mathrm{d}z}; \qquad A_\theta = [0,\theta]^n.$$

Travaillons le dénominateur :

$$\begin{aligned}
\int_{A_\theta} \left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)} - 1\right)^2 p_\theta(z)\mathrm{d}z &= \int_{A_\theta} \left(\frac{p_{\theta-\delta}(z)}{p_\theta(z)}\right)^2 p_\theta(z)\mu(\mathrm{d}z) + 1 - 2\int_{A_\theta} \frac{p_{\theta-\delta}(z)}{p_\theta(z)} p_\theta(z)\mathrm{d}z \\
&= \frac{1}{\theta^n} \int_{[0,\theta]^n} \left(\theta^n\ p_{\theta-\delta}(z)\right)^2\ \mathrm{d}z - 1 \\
&= \frac{1}{\theta^n} \int_{[0,\theta-\delta]^n} \left(\frac{\theta^n}{(\theta-\delta)^n}\right)^2\ \mathrm{d}z - 1 \\
&= \frac{\theta^n}{(\theta-\delta)^n} - 1.
\end{aligned}$$

6. On pose maintenant $\delta = c\theta/n$ avec $0 < c < n$. Alors le dénominateur vaut

$$\left(1 - \frac{c}{n}\right)^{-n} - 1;$$

et donc $\mathrm{Var}_\theta(T(Z)) \geq \tau_n(c)\theta^2/n^2$ avec

$$\tau_n(c) = \frac{c^2}{(1-c/n)^{-n} - 1} \to_{n\to\infty} \frac{c^2}{\exp(c) - 1} = c\ \left(\frac{\exp(c) - 1}{c}\right)^{-1}.$$

La figure 6 montre l'évolution de $c \mapsto \tau_n(c)$ pour différentes valeurs de n, ainsi que l'évolution de $c \mapsto \lim_n \tau_n(c)$. On vient de montrer que dans le classe des estimateurs sans biais de θ (dans un modèle statistique non régulier, pour l'estimation du support de lois uniformes), le risque quadratique moyen est minoré par

$$\frac{\theta^2}{n^2}\tau_n(c), \forall 0 < c < n.$$

On en déduit que l'EQM est minoré par

$$\frac{\theta^2}{n^2} \sup_{c\in]0,n[} \tau_n(c).$$

Asymptotiquement, une borne inférieure sur l'EQM des estimateurs sans biais se comporte comme θ^2/n^2. On notera la vitesse en $O(1/n^2)$.

On a établi dans l'exercice 1 que l'estimateur sans biais $\widehat{\theta}_n^{(2)} = (n+1)X_{n:n}/n$ avait un risque quadratique moyen valant

$$\frac{\theta^2}{n^2}\frac{n}{n+2}$$

et qu'il était inadmissible. Asymptotiquement, son EQM est équivalent à θ^2/n^2.

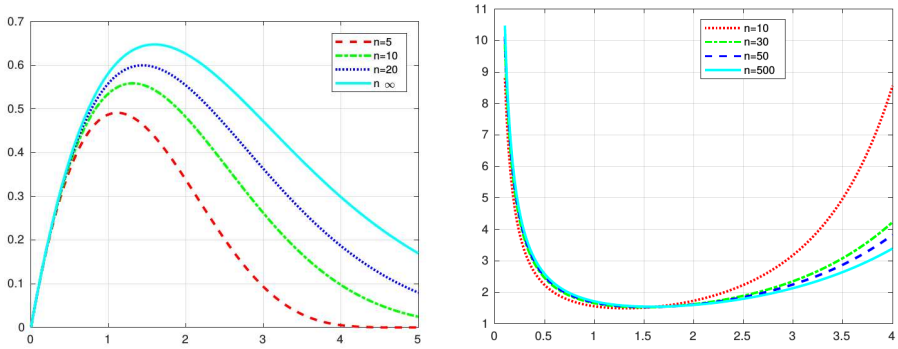


FIGURE 4 – Exercice 3 (gauche) Tracé de $c \mapsto \tau_n(c)$ pour différentes valeurs de n, et tracé de $c \mapsto \lim_n \tau_n(c)$. (droite) Tracé de $c \mapsto n/((n+2)\tau_n(c))$, ratio de l'EQM de $\widehat{\theta}_n^{(2)}$ et du minorant de l'EQM des estimateurs sans biais.

2.4 Exercice 4

Dans la suite, on omet la dépendance en n de $\underline{a}$.
Observons [1] que sous p_θLeb, X_k a même loi que $\theta + \sigma Y_k$ où $Y_k \sim q$. On en déduit que

$$\mathbb{E}_\theta [X_k] = \theta, \qquad \mathrm{Var}_\theta(X_k) = \sigma^2.$$

Calculons l'espérance et la variance de l'estimateur :

$$\mathbb{E}_\theta \left[\hat{\theta}_n(\underline{a})\right] = \theta \left(\sum_{k=1}^n a_k\right), \qquad \mathrm{Var}_\theta(\hat{\theta}_n(\underline{a})) = \sigma^2 \left(\sum_{k=1}^n a_k^2\right).$$

1. Par suite, le risque quadratique est donné par

$$R(\hat{\theta}_n(\underline{a}), \theta) = \theta^2 \left(\sum_{k=1}^n a_k - 1\right)^2 + \sigma^2 \left(\sum_{k=1}^n a_k^2\right).$$

Comme il est sans biais, on veut minimiser

$$\underline{a} \mapsto \sigma^2 \left(\sum_{k=1}^n a_k^2\right) \qquad \text{sous la contrainte} \quad \sum_{k=1}^n a_k = 1.$$

Solution 1. Par Cauchy-Schwarz, et en utilisant la contrainte, on a

$$\frac{1}{n}\sum_{k=1}^n a_k^2 \geq \left|\frac{1}{n}\sum_{k=1}^n a_k\right|^2 = \frac{1}{n^2}.$$

Le minorant est indépendant de $\underline{a}$ et la borne inférieure est atteinte avec $a_k = 1/n$ pour tout k. Ainsi, l'estimateur sans biais de risque quadratique minimal est

$$\hat{\theta}_n(1/n, \cdots, 1/n) = \frac{1}{n}\sum_{k=1}^n X_k.$$

Solution 2. On résoud le problème de minimisation sous contraintes par la méthode des multiplicateurs de Lagrange. [2]
Soit $\lambda \in \mathbb{R}$: on veut minimiser sur $\mathbb{R}^n$

$$\underline{a} \mapsto \sum_{k=1}^n a_k^2 + \lambda \left(\sum_{k=1}^n a_k - 1\right) = \text{objectif} + \lambda \times \quad \text{contrainte}.$$

1. voir PC1

2. La technique consiste à remplacer le problème d'optimisation sous contraintes, par un problème d'optimisation d'une autre fonction objectif qui inclut la contrainte : pour $\lambda_1, \cdots, \lambda_\ell$, on définit une nouvelle fonction objectif à optimiser :

$$(\text{objectif initial}) + \sum_{i=1}^\ell \lambda_i \quad \text{contrainte}_i.$$

On utilise les outils classiques de résolution de l'optimisation sans contraintes (zeros du gradient, ...) ; la solution si elle existe va être une fonction des multiplicateurs $\lambda_1, \cdots, \lambda_\ell$. Pour trouver quelles valeurs il faut prendre pour ces multiplicateurs, il faut se souvenir que la solution doit satisfaire ℓ contraintes. On obtient un système à ℓ équations et ℓ inconnues. La résolution donne les valeurs des multiplicateurs $\lambda_1, \cdots, \lambda_\ell$; dont on va déduire la solution du problème initial.

Le gradient est nul ssi

$$\forall i \in \{1, \cdots, n\} : \qquad 2a_i + \lambda = 0.$$

Cela donne $a_i = -\lambda/2$ pour tout i. On utilise la contrainte pour déterminer λ : la contrainte $\sum_{k=1}^n a_k = 1$ entraine $-n\lambda/2 = 1$ soit $\lambda = -2/n$. Donc la solution est le vecteur constant $\underline{a} = (1/n, \cdots, 1/n)$.

2. On veut minimiser

$$\underline{a} \mapsto \theta^2 \left(\sum_{k=1}^n a_k - 1 \right)^2 + \sigma^2 \left(\sum_{k=1}^n a_k^2 \right).$$

Pour tout i, la dérivée par rapport à a_i est

$$2\theta^2 \left(\sum_{k=1}^n a_k - 1 \right) + 2\sigma^2 a_i \tag{4}$$

La racine du gradient est un minimum. En effet, la dérivée seconde $\partial_{a_i\, a_j}$ est

$$2\theta^2 + 2\sigma^2 \mathbb{1}_{i=j}.$$

On en déduit que la matrice hessienne est $H = 2\sigma^2 I + 2\theta^2 \mathbb{1}\mathbb{1}^T$, ses valeurs propres sont strictement positives puisque

$$\lambda^T H \lambda = 2\sigma^2 \|\lambda\|^2 + 2\theta^2 \left(\sum_{k=1}^n \lambda_k \right)^2 \geq 2\sigma^2 \|\lambda\|^2.$$

Donc la fonction possède un unique minimum donné par la racine du gradient.
Cherchons la racine du gradient. En sommant en i la relation (4), la racine est solution de

$$n\theta^2 \sum_{k=1}^n a_k - n\theta^2 + \sigma^2 \sum_{k=1}^n a_k = 0$$

ce qui donne

$$\sum_{k=1}^n a_k = \frac{n\theta^2}{\sigma^2 + n\theta^2}.$$

En utilisant à nouveau (4), on obtient

$$a_i = \frac{\theta^2}{\sigma^2} \left(1 - \frac{n\theta^2}{\sigma^2 + n\theta^2} \right) = \frac{\theta^2}{\sigma^2 + n\theta^2}.$$

Le minimum du risque est atteint en

$$\underline{a} = \left(\frac{\theta^2}{\sigma^2 + n\theta^2}, \cdots, \frac{\theta^2}{\sigma^2 + n\theta^2} \right) = \frac{\theta^2}{\theta^2 + \sigma^2/n} \left(\frac{1}{n}, \cdots, \frac{1}{n} \right); \tag{5}$$

de sorte que le risque est minoré par

$$R(\hat{\theta}_n(\underline{a}), \theta) \geq \frac{\sigma^2 \theta^2}{\sigma^2 + n\theta^2}.$$

▶ Notons que

$$\frac{\sigma^2\theta^2}{\sigma^2+n\theta^2} = \frac{\sigma^2}{n}\left(\frac{\theta^2}{\theta^2+\sigma^2/n}\right) < \frac{\sigma^2}{n}$$

montrant que le risque quadratique optimal (puisqu'atteignable avec les poids donnés par (5)) dans la classe des estimateurs linéaires, est plus faible que le risque quadratique optimal dans la classe (plus restreinte) des estimateurs linéaires sans biais. En toute logique !

2.5 Exercice 5

Noter qu'avec cette convention sur la paramétrisation de la loi exponentielle, on a

$$\mathbb{E}_\theta[U] = \theta, \qquad \mathrm{Var}_\theta(U) = \theta^2, \qquad \text{où } U \sim f_\theta(\cdot)\cdot \mathrm{Leb}. \tag{6}$$

1. Soit $\tau = (\tau_1, \cdots, \tau_n)$ une permutation de $\{1, \cdots, n\}$. Puisque sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$, $(X_1, \cdots, X_n)$ sont i.i.d., elles ont même loi que $(X_{\tau_1}, \cdots, X_{\tau_n})$ et cette loi est donnée par

$$(y_1, \cdots, y_n) \mapsto \left(\prod_{k=1}^n f_\theta(y_k)\right) \mathrm{d}y_1 \cdots \mathrm{d}y_n.$$

Puisque les v.a. $(X_k)_k$ ont des lois à densité par rapport à la mesure de Lebesgue, on a $\mathbb{P}_\theta(X_i = X_j) = 0$ pour tout $i \neq j$. Par suite, il existe une unique permutation aléatoire σ de $\{1, \cdots, n\}$ telle que

$$X_{k:n} = X_{\sigma_k}, \qquad X_{\sigma_1} < X_{\sigma_2} < \cdots < X_{\sigma_n} \text{ p.s.}$$

Notons $\mathcal{S}_n$ l'ensemble des permutations de $\{1, \cdots, n\}$, de cardinal $n!$.
On a pour toute fonction h mesurable bornée

$$\begin{aligned}
\mathbb{E}_\theta[h(X_{1:n}, \cdots, X_{n:n})] &= \mathbb{E}_\theta[h(X_{\sigma_1}, \cdots, X_{\sigma_n})] \\
&= \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta[h(X_{\tau_1}, \cdots, X_{\tau_n})\ \mathbb{1}_{\sigma=\tau}] \\
&= \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta\left[h(X_{\tau_1}, \cdots, X_{\tau_n})\ \mathbb{1}_{X_{\tau_1} < X_{\tau_2} < \cdots < X_{\tau_n}}\right]
\end{aligned}$$

On conclut en observant que l'espérance dans le terme de droite est indépendante de τ et vaut

$$\mathbb{E}_\theta\left[h(X_{\tau_1}, \cdots, X_{\tau_n})\ \mathbb{1}_{X_{\tau_1} < X_{\tau_2} < \cdots < X_{\tau_n}}\right] = \int_{y_1 < \cdots < y_n} h(y_1, \cdots, y_n) \left(\prod_{k=1}^n f_\theta(y_k)\right) \mathrm{d}y_1 \cdots \mathrm{d}y_n,$$

puis en utilisant le fait que $\sum_{\tau \in \mathcal{S}_n} 1 = n!$.

2. Soit h mesurable positive.

$$\begin{aligned}
\mathbb{E}_\theta[h(Z_1, \cdots, Z_n)] &= \mathbb{E}_\theta[h(nX_{1:n}, (n-1)(X_{2:n} - X_{1:n}), \cdots, (X_{n:n} - X_{n-1:n}))] \\
&= \frac{n!}{\theta^n} \int_{0 \le y_1 < \cdots < y_n} \exp\left(-\theta^{-1} \sum_{k=1}^n y_k\right)\ h\Big(ny_1, (n-1)(y_2 - y_1), \cdots, (y_n - y_{n-1})\Big) \mathrm{d}y_1 \cdots \mathrm{d}y_n \\
&= \frac{1}{\theta^n} \int_{z_1 > 0, z_2 > 0, \cdots, z_n > 0} \exp\left(-\theta^{-1} \sum_{k=1}^n \sum_{j=1}^k (n-j+1)^{-1} z_j\right)\ h(z_1, \cdots, z_n)\ \mathrm{d}z_1 \cdots \mathrm{d}z_n,
\end{aligned}$$

en faisant le changement de variable $z_i = (n-i+1)(y_i - y_{i-1})$, ce qui est équivalent à $y_i = \sum_{j=1}^i z_j (n-j+1)^{-1}$. On a

$$\sum_{k=1}^n \sum_{j=1}^k (n-j+1)^{-1} z_j = \sum_{k=1}^n \sum_{j=1}^n \mathbb{1}_{j \le k} \frac{z_j}{n-j+1} = \sum_{j=1}^n \frac{z_j}{n-j+1}(n-j+1) = \sum_{j=1}^n z_j,$$

dont on déduit que

$$\mathbb{E}_\theta\left[h\left(Z_1,\cdots,Z_n\right)\right]=\frac{1}{\theta^n}\int_{z_1>0,\cdots,z_n>0}\exp\left(-\theta^{-1}\sum_{j=1}^n z_j\right)\ h(z_1,\cdots,z_n)\mathrm{d}z_1\cdots\mathrm{d}z_n$$

La relation étant vraie pour tout h, on identifie la loi de $(Z_1,\cdots,Z_n)$ comme ayant la densité

$$(z_1,\cdots,z_n)\mapsto \mathbb{1}_{z_1>0,\cdots,z_n>0}\frac{1}{\theta^n}\ \exp\left(-\theta^{-1}\sum_{j=1}^n z_j\right).$$

Il vient que les v.a. $(Z_k)_k$ sont i.i.d. de loi exponentielle de paramètre θ.

3. On a

$$\begin{aligned}\sum_{j=1}^n m_{jn}\,Z_j&=\sum_{j=1}^n\frac{Z_j}{n-j+1}\sum_{i=j}^n a_{in}=\sum_{j=1}^n\sum_{i=1}^n 1_{j\le i}\frac{Z_j}{n-j+1}a_{in}\\&=\sum_{i=1}^n a_{in}\sum_{j=1}^i\frac{Z_j}{n-j+1}=\sum_{i=1}^n a_{in}X_{i:n}.\end{aligned}$$

4. En utilisant (6) et le résultat de la question 2, le risque quadratique de l'estimateur est donné par

$$\left(\sum_{j=1}^n m_{jn}-1\right)^2\theta^2+\theta^2\sum_{j=1}^n m_{jn}^2$$

5. Si on cherche sans biais, on veut minimiser en $\underline{m}$ l'application

$$\underline{m}\mapsto\theta^2\sum_{j=1}^n m_{jn}^2\qquad\text{sous la contrainte}\quad\sum_{j=1}^n m_{jn}=1.$$

En procédant comme dans l'exercice 4, on obtient successivement (noter la bijection entre $\underline{m}$ et $\underline{a}$)

$$\underline{m}=(1/n,\cdots,1/n),\qquad\underline{a}=(1/n,\cdots,1/n).$$

6. Sans imposer que l'estimateur soit sans biais, on obtient - en procédant encore comme dans l'exercice 4 -

$$\underline{m}=(1/(n+1),\cdots,1/(n+1)),\qquad\underline{a}=(1/(n+1)\cdots,1/(n+1)).$$