4 Les compléments

Les contenus de cette partie ne sont pas exigibles ; ils donnent le cadre général dans lequel s'inscrivent les notions du chapitre, les deux approches de l'optimalité qui n'ont pas été retenues, et deux résultats qui prolongent la borne de Cramér-Rao.

Théorie de la décision : le cadre général

Le risque a été défini pour un estimateur. La même définition vaut pour n'importe quelle procédure qui, à une observation, associe une décision : le choix d'un estimateur n'est qu'un cas particulier, et le test d'hypothèses en est un autre.

Définition 4.1: Risque d'une règle de décision

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\ ,\ \theta \in \Theta\})$ un modèle statistique paramétrique et $\ell : \Theta \times \mathsf{A} \to \mathbb{R}_+$ une *fonction de perte*, où A est un ensemble d'*actions* muni d'une tribu $\mathcal{A}$ telle que $\ell(\theta, \cdot) : (\mathsf{A}, \mathcal{A}) \to \mathbb{R}$ soit mesurable pour tout $\theta \in \Theta$. Une *règle de décision* δ est une fonction mesurable $\delta : (\mathsf{Z}, \mathcal{Z}) \to (\mathsf{A}, \mathcal{A})$, qui associe une action $\delta(Z)$ à une observation Z ; son *risque* est l'espérance

$$R_\ell(\theta, \delta) := \mathbb{E}_\theta\big[\ell(\theta, \delta(Z))\big]\ . \tag{15}$$

L'estimation ponctuelle en est le cas particulier vu dans les fondamentaux : si $g : \Theta \to \mathsf{Y}$ est la fonction à estimer, où $(\mathsf{Y}, \mathcal{Y})$ est un espace mesurable, on prend pour espace d'actions $\mathsf{A} = \mathsf{Y}$, et un estimateur $T : (\mathsf{Z}, \mathcal{Z}) \to (\mathsf{Y}, \mathcal{Y})$ de g est une règle de décision au sens de la définition ci-dessus. À une fonction de distance mesurable $W : \mathsf{Y} \times \mathsf{Y} \to \mathbb{R}_+$, on associe la fonction de perte $(\theta, a) \mapsto W(g(\theta), a)$, qui représente la perte réalisée lorsqu'on estime $g(\theta)$ par l'action a. Toutes les notions définies pour les règles de décision, à commencer par l'admissibilité, s'appliquent donc aux estimateurs.

Le test d'hypothèses se formule de la même façon. Écrivons $\Theta = \Theta_0 \cup \Theta_1$, où Θ_0 et Θ_1, disjoints, décrivent respectivement l'hypothèse nulle H_0 et l'hypothèse alternative H_1. Mettre en œuvre un test, c'est prendre une décision à valeurs dans $\mathsf{A} := \{0, 1\}$, l'action 0 étant d'accepter H_0 et l'action 1 de la rejeter. Une fonction de perte adaptée est

$$\ell(\theta, 0) = \begin{cases} \ell_0 & \text{si } \theta \in \Theta_1\ , \\ 0 & \text{sinon,} \end{cases} \qquad \ell(\theta, 1) = \begin{cases} \ell_1 & \text{si } \theta \in \Theta_0\ , \\ 0 & \text{sinon,} \end{cases}$$

pour deux réels ℓ_0, ℓ_1 strictement positifs : accepter H_0 alors qu'elle est fausse coûte ℓ_0, la rejeter alors qu'elle est vraie coûte ℓ_1, et une décision correcte ne coûte rien. Le risque d'un test ϕ pour cette perte vaut

$$R_\ell(\theta, \phi) = \begin{cases} \ell_0\, \mathbb{P}_\theta(\phi(Z) = 0) & \text{si } \theta \in \Theta_1\ , \\ \ell_1\, \mathbb{P}_\theta(\phi(Z) = 1) & \text{si } \theta \in \Theta_0\ . \end{cases}$$

Le choix $\ell_0 = \ell_1 = 1$ donne la perte dite 0-1, pour laquelle le risque s'exprime à l'aide de la fonction puissance $\beta_\phi(\theta) = \mathbb{P}_\theta(\phi(Z) = 1)$: il vaut $\beta_\phi(\theta)$ si $\theta \in \Theta_0$ et $1 - \beta_\phi(\theta)$ si $\theta \in \Theta_1$. Ces notions seront reprises et développées dans le chapitre consacré aux tests.

Approches minimax et bayésienne

La faiblesse des estimateurs constants est qu'ils ne se comportent bien que pour une seule valeur du paramètre, inconnue par hypothèse. Une façon de l'exclure consiste à agréger la fonction de risque en un seul nombre, ce qui rétablit un ordre total sur les règles de décision. Deux agrégations sont classiques ; elles ne sont pas développées dans ce cours, et l'on se contente ici de les définir.

L'*approche minimax* retient le risque dans le pire des cas,

$$\overline{R}_\ell(\delta) := \sup_{\theta \in \Theta} R_\ell(\theta, \delta)\ ,$$

et appelle *risque minimax* l'infimum $\overline{R}_\ell := \inf_\delta \overline{R}_\ell(\delta)$ sur toutes les règles de décision. Une règle δ^* est dite *minimax* si $\overline{R}_\ell(\delta^*) = \overline{R}_\ell$. Ces procédures sont sûres, au sens où elles se prémunissent uniformément contre toutes les valeurs du paramètre ; en contrepartie, la recherche de garanties uniformes conduit parfois à des procédures trop conservatrices.

L'*approche bayésienne* se donne une mesure de probabilité Π sur Θ, muni d'une tribu convenable, appelée *loi a priori*, et considère l'intégrale du risque plutôt que son supremum :

$$R_\ell(\Pi, \delta) := \int_\Theta R_\ell(\theta, \delta)\, \Pi(\mathrm{d}\theta) \,.$$

Le *risque de Bayes* selon Π est $\underline{R}_\ell(\Pi) := \inf_\delta R_\ell(\Pi, \delta)$, et une règle qui atteint cet infimum est dite *bayésienne selon* Π. Le risque intégré réapparaîtra dans la partie du cours consacrée à l'apprentissage statistique.

Quelles fonctions sont estimables sans biais dans le modèle binomial

L'Exemple 1.5 a montré qu'il n'existe pas d'estimateur sans biais de $1/\theta$ dans le modèle binomial. La relation (1) permet de décrire complètement les fonctions qui en admettent un.

Proposition 4.1: Fonctions estimables sans biais dans le modèle binomial

Dans le modèle $\big(\{0,\dots,n\}, \mathcal{P}(\{0,\dots,n\}), \{\mathrm{Bin}(n,\theta)\,,\ \theta \in \Theta\}\big)$ avec $\Theta = [0,1[$, une fonction $g : \Theta \to \mathbb{R}$ admet un estimateur sans biais si et seulement si g est un polynôme en θ de degré au plus n ; cet estimateur est alors unique.

Démonstration

D'après (1), pour toute fonction $T : \{0,\dots,n\} \to \mathbb{R}$, l'application $\Phi(T) : \theta \mapsto \mathbb{E}_\theta[T(Z)]$ est un polynôme de degré au plus n. L'application Φ est linéaire, de l'espace des fonctions $\{0,\dots,n\} \to \mathbb{R}$ vers celui des polynômes de degré au plus n ; ces deux espaces vectoriels étant de dimension finie $n+1$, il suffit de montrer que Φ est injective pour conclure qu'elle est bijective. Soit $T \in \ker \Phi$: pour tout $\theta \in [0,1[$,

$$(1-\theta)^n \sum_{k=0}^{n} \binom{n}{k} T(k) \Big(\frac{\theta}{1-\theta}\Big)^k = 0 \,.$$

En posant $t = \theta/(1-\theta)$ et en notant que $(1-\theta)^n \neq 0$, il vient $F(t) := \sum_{k=0}^n \binom{n}{k} T(k) t^k = 0$ pour tout $t \geq 0$. Un polynôme nul sur un intervalle est le polynôme nul, donc tous ses coefficients sont nuls et $T = 0$. Ainsi Φ est bijective : toute fonction g polynomiale de degré au plus n admet un et un seul estimateur sans biais, et aucune autre fonction n'en admet. □

Estimation équivariante du paramètre de translation

La restriction à une classe d'estimateurs invariants, évoquée à la Section 1.6, prend une forme particulièrement simple dans le modèle de translation.

Soit p une densité de probabilité par rapport à la mesure de Lebesgue sur $\mathbb{R}^d$. Pour $\theta \in \Theta := \mathbb{R}^d$ et $x \in \mathbb{R}^d$, posons $p_\theta(x) := p(x-\theta)$, et soit $(X_1,\dots,X_n)$ un n-échantillon du modèle $\big(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d), \{\mathbb{P}_\theta = p_\theta \cdot \mathrm{Leb}\,,\ \theta \in \Theta\}\big)$. On cherche un estimateur optimal de θ pour la perte $(u,v) \mapsto w(u-v)$, où $w : \mathbb{R}^d \to \mathbb{R}_+$ est mesurable.

Pour tout $c \in \mathbb{R}^d$, tout $\theta \in \Theta$ et toute fonction mesurable positive h,

$$\mathbb{E}_\theta[h(X_j + c)] = \int_{\mathbb{R}^d} h(x+c) p_\theta(x)\,\mathrm{d}x = \int_{\mathbb{R}^d} h(y) p_\theta(y-c)\,\mathrm{d}y = \int_{\mathbb{R}^d} h(y) p_{\theta+c}(y)\,\mathrm{d}y = \mathbb{E}_{\theta+c}[h(X_j)] \,,$$

où l'on a utilisé $p_\theta(u) = p(u-\theta) = p_{\theta+c}(u+c)$. Il est donc naturel de se restreindre aux estimateurs *équivariants*, c'est-à-dire vérifiant

$$T(x_1+c,\dots,x_n+c) = T(x_1,\dots,x_n) + c \,, \qquad c \in \mathbb{R}^d \,, \quad x_1,\dots,x_n \in \mathbb{R}^d \,, \tag{16}$$

ce qui équivaut à $T(x_1,\dots,x_n) = x_1 + T(0, x_2 - x_1, \dots, x_n - x_1)$ pour tous $x_1,\dots,x_n$. Si T est équivariant, son risque ne dépend pas du paramètre : en effet,

$$\begin{aligned} R_w(\theta, T) &= \mathbb{E}_\theta\big[w(T(X_1,\dots,X_n) - \theta)\big] = \mathbb{E}_\theta\big[w(T(X_1-\theta,\dots,X_n-\theta))\big] \\ &= \mathbb{E}_0\big[w(T(X_1,\dots,X_n))\big] = R_w(0,T)\ , \end{aligned}$$

la deuxième égalité par (16) appliquée avec $c = -\theta$, la troisième parce que le modèle est un modèle de translation. Il suffit donc de trouver un estimateur équivariant T_0 réalisant $\inf_T R_w(0,T)$ sur la classe des estimateurs équivariants pour disposer d'un estimateur optimal dans cette classe : la comparaison de fonctions s'est réduite à la comparaison de nombres.

Existence d'un estimateur efficace

Un estimateur efficace existe-t-il toujours ? La réponse est non, et le cas d'égalité dans l'inégalité de Cauchy-Schwarz caractérise exactement les modèles où il en existe un.

Plaçons-nous dans un modèle régulier avec $\Theta \subseteq \mathbb{R}$ ouvert, et cherchons un estimateur efficace T de $g(\theta) = \theta$. La preuve du Théorème 1.1 montre que T est efficace si et seulement s'il y a égalité dans l'inégalité de Cauchy-Schwarz appliquée aux variables $z \mapsto T(z) - \theta$ et $z \mapsto \nabla_\theta \ell(\theta, z)$, c'est-à-dire si et seulement si ces deux fonctions sont colinéaires μ-presque partout. Ceci devant valoir pour toute valeur de θ, on en déduit qu'il existe une fonction c telle que

$$\nabla_\theta \ell(\theta, z) = c(\theta)\,\{T(z) - \theta\}\ , \qquad \theta \in \Theta\ , \quad z \in \mathsf{Z}\ ,$$

condition nécessaire et suffisante d'efficacité. En intégrant cette équation par rapport à θ, on obtient le résultat suivant.

Théorème 4.1: Existence d'un estimateur efficace

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle paramétrique régulier avec $\Theta \subseteq \mathbb{R}$ ouvert. Il existe un estimateur efficace T^* de θ si et seulement si

$$p_\theta(z) = h(z) \exp\big(A(\theta)T^*(z) + B(\theta)\big)\ ,$$

où $\theta \mapsto A(\theta)$ et $\theta \mapsto B(\theta)$ sont différentiables.

Un modèle de cette forme est une *famille exponentielle*, au sens de l'Exercice 3 (PC2). La condition $\mathbb{E}_\theta[\nabla_\theta \ell(\theta, Z)] = 0$ impose alors $B'(\theta) = -\theta A'(\theta)$, de sorte que l'équation de vraisemblance s'écrit

$$0 = \nabla_\theta \ell(\theta, Z) = A'(\theta)\{T^*(Z) - \theta\}\ ,$$

ce qui montre que $T^*(Z)$ est solution des équations de vraisemblance : dans une famille exponentielle, l'estimateur efficace, lorsqu'il existe, est l'estimateur du maximum de vraisemblance.

Estimateur à rétrécissement

Le biais peut-il réduire l'erreur quadratique ? L'Exemple 1.8 l'a montré sur un cas particulier ; la famille suivante le montre en général.

Soient Z une observation d'un modèle $\big(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\}\big)$, $g : \Theta \to \mathbb{R}$, et $T(Z)$ un estimateur sans biais de $g(\theta)$, de carré intégrable. Pour $\gamma > 0$, considérons $T_\gamma(Z) := \gamma\, T(Z)$. Son biais et sa variance valent

$$b(\theta, T_\gamma) = \gamma\, \mathbb{E}_\theta[T(Z)] - g(\theta) = (\gamma - 1) g(\theta)\ , \qquad \mathrm{Var}_\theta(T_\gamma(Z)) = \gamma^2\ \mathrm{Var}_\theta(T(Z))\ ,$$

de sorte que, en posant $v(\theta) := \mathrm{Var}_\theta(T(Z))$, la décomposition biais-variance donne

$$R(\theta, T_\gamma) = (\gamma - 1)^2 \{g(\theta)\}^2 + \gamma^2 v(\theta)\ . \tag{17}$$

Si $\gamma > 1$, alors $R(\theta, T_\gamma) > v(\theta) = R(\theta, T)$ pour tout θ : l'estimateur T_γ est inadmissible, battu par T lui-même. Seules les valeurs $\gamma \in [0, 1]$ sont intéressantes ; on parle alors d'*estimateur à rétrécissement*.

Deux cas se présentent. Si $\{g(\theta)\}^2 \leq v(\theta)$ pour tout $\theta \in \Theta$, alors T_γ est préférable à T pour tout $\gamma \in [0, 1]$: un estimateur biaisé est donc préférable à un estimateur sans biais. Si au contraire $\{g(\theta)\}^2 > v(\theta)$, l'inégalité $R(\theta, T_\gamma) \leq R(\theta, T) = v(\theta)$ se réécrit, à partir de (17),

$$(1-\gamma)^2\{g(\theta)\}^2 \leq (1-\gamma^2)v(\theta) \, ,$$

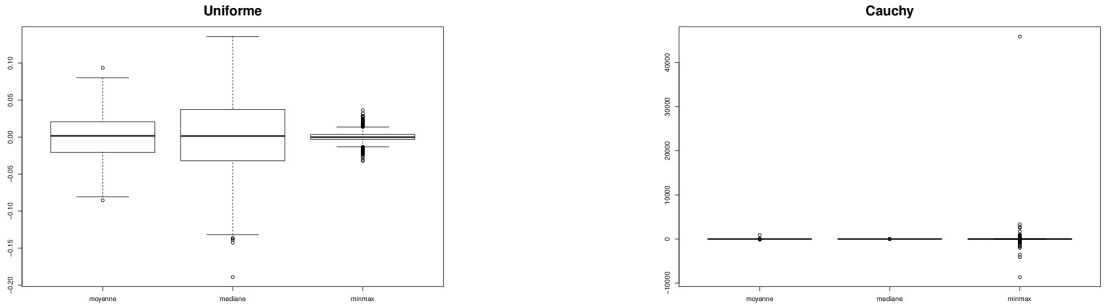
soit, pour $\gamma < 1$, après division par $1 - \gamma > 0$, $(1-\gamma)\{g(\theta)\}^2 \leq (1+\gamma)v(\theta)$, c'est-à-dire

$$\gamma \geq \gamma_{\min}(\theta) := \frac{\{g(\theta)\}^2 - v(\theta)}{\{g(\theta)\}^2 + v(\theta)} \, .$$

Le rétrécissement n'améliore alors le risque que s'il n'est pas trop prononcé, et le seuil dépend du paramètre, donc n'est pas calculable en pratique.

Le paramètre de translation : quatre lois de bruit

L'Exemple 1.1 a comparé les trois estimateurs du paramètre de translation pour deux lois de bruit. Voici les deux autres cas simulés, qui complètent le tableau.



À gauche, un bruit uniforme de densité $p(x) = \mathbb{1}_{[-1/2,1/2]}(x)$ *; à droite, un bruit de Cauchy de densité* $p(x) = 1/(\pi(1+x^2))$. *Mêmes conventions que pour l'Exemple 1.1 :* $m = 1000$ *répétitions,* $n = 100$ *observations, paramètre* $\theta = 0$.

Pour le bruit uniforme, dont la variance vaut $1/12$, la moyenne empirique a une variance $1/(12n)$ et la médiane empirique une variance asymptotique $1/(4np(0)^2) = 1/(4n)$: la moyenne l'emporte, mais c'est en réalité la demi-somme des extrêmes qui est de loin la meilleure, avec une variance d'ordre n^{-2} – le même phénomène que dans le modèle uniforme de l'Exemple 1.9, et pour la même raison, l'absence de régularité du modèle. Pour le bruit de Cauchy, ni la moyenne empirique ni la demi-somme des extrêmes n'ont d'espérance, encore moins de variance : la moyenne empirique de variables de Cauchy indépendantes suit la même loi de Cauchy quel que soit n, et n'apporte donc aucune précision supplémentaire (chapitre 2, Section 4). La médiane empirique, elle, reste un estimateur raisonnable. Les valeurs de variance annoncées pour la médiane sont, comme précédemment, des variances asymptotiques et non des variances exactes à n fini.