# Chapitre 3

# Bases de la théorie de la décision

Le chapitre précédent a construit des estimateurs sans dire lequel choisir. Or un même modèle en admet toujours plusieurs, et un estimateur, pour être utile, doit être « proche », en un certain sens, de la quantité qu'il estime. Ce chapitre définit les outils qui permettent de comparer deux estimateurs et d'établir des bornes quantitatives sur leur performance : le **biais**, la **fonction de perte**, le **risque**, l'**erreur quadratique moyenne** et sa décomposition en biais et variance, puis l'**admissibilité**. Comme le risque est une fonction du paramètre, la comparaison ne fournit qu'un ordre partiel ; il faut restreindre la classe des estimateurs pour espérer une notion d'optimalité, et l'on retient la classe des estimateurs sans biais.
Dans cette classe, la variance est minorée. C'est l'objet de la seconde moitié du chapitre : le **modèle régulier**, le **score**, l'**information de Fisher** et le **théorème de Cramér-Rao**, qui borne inférieurement la variance de tout estimateur sans biais régulier. Un estimateur qui atteint cette borne est dit **efficace** ; il est alors de variance minimale parmi les estimateurs sans biais.
La partie principale suit le déroulé du cours en amphi. Elle est suivie d'une partie *Outils mathématiques*, qui rassemble les prérequis mobilisés, comme l'inégalité de Cauchy-Schwarz, dérivation sous le signe intégral, matrice hessienne et matrices symétriques positives, décomposition biais-variance vectorielle, puis de la feuille d'exercices, et enfin d'une partie *Compléments*, hors programme d'examen, qui donne le cadre général de la théorie de la décision, les approches minimax et bayésienne, la caractérisation des estimateurs efficaces et l'estimateur à rétrécissement.

## Comment comparer deux estimateurs ?

Un estimateur ponctuel de $g(\theta)$ est une statistique quelconque (définition du chapitre 2) : la seule contrainte est d'être calculable à partir des observations. Le chapitre précédent a donné deux méthodes pour en construire, la méthode des moments et le maximum de vraisemblance, et l'on a vu qu'un même modèle peut en fournir plusieurs, sans que rien ne dise lequel retenir. Par exemple, on a vu deux estimateurs des moments dans le modèle exponentiel, et un estimateur des moments et un estimateur du maximum de vraisemblance qui ne coïncident pas dans le modèle uniforme.

Il existe donc de nombreux estimateurs ; lequel est le meilleur, et cette question a-t-elle seulement un sens ? Y répondre demande d'abord de mesurer l'erreur commise, ce qui se fait par une fonction de perte et le risque associé, puis de comparer ces mesures d'un estimateur à l'autre. On verra que cette comparaison n'est pas simple, et peut échouer en général, parce que le risque est une fonction du paramètre inconnu, et que l'ordre sur les fonctions n'est pas total, et que l'on doit se restreindre à une sous-classe d'estimateurs pour obtenir un résultat d'optimalité. C'est dans la

classe des estimateurs sans biais que le chapitre pourra aboutir, avec la borne de Cramér-Rao, un des plus beaux résultats de statistique mathématique élementaire.

# 1 Les fondamentaux

## 1.1 Un exemple pour commencer : le paramètre de translation

Avant toute définition, il est utile de voir sur un exemple ce que veut dire « comparer des estimateurs ». Le modèle de translation, déjà rencontré au chapitre 2, s'y prête bien : nos observations sont des réalisations d'une variable aléatoire de loi $\mathbb{Q}_\theta$, qui correspond à une valeur inconnue $\theta$ à laquelle s'ajoute un bruit de loi connue (de densité $p$), et l'on dispose de plusieurs façons naturelles de récupérer la valeur inconnue à partir des mesures.

**Exemple 1.1: Estimation d'un paramètre de translation**

Soit $p$ une densité de probabilité sur $\mathbb{R}$, symétrique au sens où $p(x) = p(-x)$ pour tout $x$. On considère le modèle

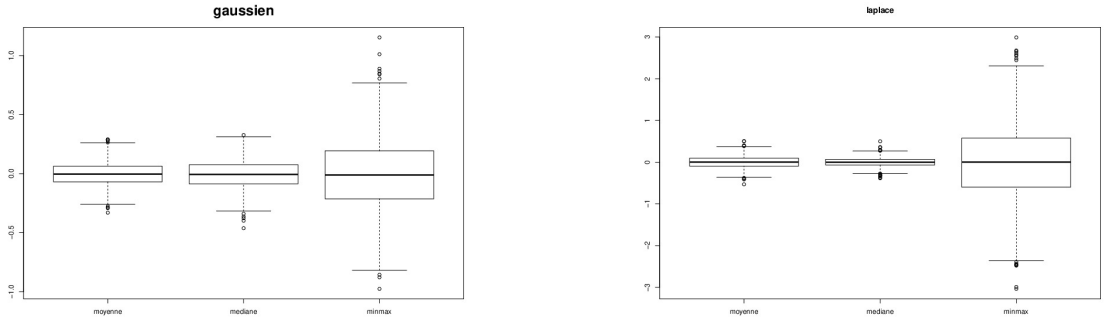
$$\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathbb{Q}_\theta = q_\theta \cdot \mathrm{Leb}\,,\ \theta \in \Theta := \mathbb{R}\}\big)\,, \qquad q_\theta(x) := p(x-\theta)\,,$$

et $(X_1, \dots, X_n)$ un $n$-échantillon de ce modèle. De façon équivalente, $X_i = \theta + \varepsilon_i$ où les bruits $\varepsilon_i$ sont indépendants de densité $p$ : on mesure une vraie valeur à laquelle s'ajoute un bruit de densité connue, et l'on cherche à estimer le paramètre de centrage $\theta$. Trois estimateurs se présentent :

1. la moyenne empirique $\hat\theta_n^{(1)} := n^{-1}\sum_{i=1}^n X_i$ ;
2. la médiane empirique $\hat\theta_n^{(2)} := \mathrm{med}(X_1, \dots, X_n)$ ;
3. la demi-somme des extrêmes $\hat\theta_n^{(3)} := \big(\min(X_1, \dots, X_n) + \max(X_1, \dots, X_n)\big)/2$.

Les deux premiers ont été identifiés au chapitre 2 comme des $Z$-estimateurs, associés respectivement à $\psi(\vartheta, x) = x - \vartheta$ et à $\psi(\vartheta, x) = \mathrm{signe}(x - \vartheta)$ (Exemple 1.6).

Aucun de ces trois estimateurs ne s'impose. Pour les départager, on peut simuler : on tire $m = 1000$ échantillons de taille $n = 100$ sous $\mathbb{Q}_0$, on calcule les trois estimateurs sur chaque échantillon, et l'on compare les distributions obtenues. Les deux figures ci-dessous donnent le résultat pour un bruit gaussien puis pour un bruit de Laplace.




*Distribution des trois estimateurs sur $m = 1000$ échantillons de taille $n = 100$, pour un bruit gaussien de densité $p(x) = (2\pi)^{-1/2}\mathrm{e}^{-x^2/2}$ (à gauche) et pour un bruit de Laplace de densité $p(x) = \mathrm{e}^{-|x|}/2$ (à droite). Les trois estimateurs se concentrent autour de la vraie valeur $\theta = 0$, mais leur dispersion n'est pas la même, et l'ordre entre eux change d'un bruit à l'autre.*

**Intuition.** *Les valeurs des* variances asymptotiques*, c'est-à-dire les limites de $n$ fois la variance de l'estimateur lorsque $n$ tend vers l'infini, peuvent permettre de comparer les estimateurs, mais dans un cadre asymptotique : elles ne décrivent le graphique qu'approximativement, et leur justification sera donnée au cours 6. Pour un bruit gaussien centré réduit, la moyenne empirique a une variance de l'ordre de $1/n$ et la médiane empirique de l'ordre de $\pi/(2n)$ : la moyenne est la meilleure des deux. Pour un bruit de*

*Laplace de densité* $\mathrm{e}^{-|x|}/2$*, dont la variance vaut* 2*, la moyenne empirique a une variance de l'ordre de* $2/n$ *tandis que la médiane empirique a une variance asymptotique* $1/(4np(0)^2) = 1/n$ *: c'est cette fois la médiane qui l'emporte. Le meilleur estimateur dépend donc du modèle, et il n'y a aucune raison qu'un même estimateur soit préférable dans tous les cas.*

---

**Illustration / animation :** Comparer les trois estimateurs du paramètre de translation, pour un bruit choisi parmi les quatre lois de l'exemple

Vous pouvez y tirer des échantillons sous chacune des quatre lois de bruit et observer, sur des répétitions, comment la moyenne empirique, la médiane empirique et la demi-somme des extrêmes se dispersent différemment autour de la vraie valeur selon le bruit choisi.



link

---

Ces simulations ne constituent pas une comparaison : elles décrivent le comportement des estimateurs pour une seule valeur du paramètre et pour une seule taille d'échantillon. Il faut une mesure de la qualité d'un estimateur, définie pour toute valeur du paramètre. Les deux notions qui suivent, le biais puis le risque, fournissent de premiers exemples.

## 1.2 Biais d'un estimateur

La première mesure compare l'estimateur à sa cible en moyenne : si l'on répétait l'expérience un grand nombre de fois, l'estimateur tomberait-il en moyenne sur la bonne valeur ?

**Définition 1.1: Biais d'un estimateur**

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique paramétrique, $g : \Theta \to \mathbb{R}^p$ une fonction mesurable et $T$ un estimateur de $g : \theta \mapsto g(\theta)$ tel que $\mathbb{E}_\theta[\|T(Z)\|] < \infty$ pour tout $\theta \in \Theta$. Le *biais* de $T$ est la fonction

$$b : \theta \longmapsto b(\theta, T) := \mathbb{E}_\theta[T(Z)] - g(\theta)\ .$$

L'estimateur $T$ est dit *sans biais* si $b(\theta, T) = 0$ pour tout $\theta \in \Theta$, c'est-à-dire si $\mathbb{E}_\theta[T(Z)] = g(\theta)$ pour tout $\theta \in \Theta$.

Le biais d'un estimateur est une fonction du paramètre, et non un nombre : un estimateur peut être sans biais en un point et biaisé ailleurs, et la définition de « sans biais » exige l'égalité pour *toutes* les valeurs du paramètre.

**Exemple 1.2: Modèle de Bernoulli : la fréquence empirique est sans biais**

Soit $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle $\big(\{0,1\}, \mathcal{P}(\{0,1\}), \{\mathcal{B}\mathrm{er}(\theta)\,,\ \theta \in \Theta := [0,1]\}\big)$. Comme $\mathbb{E}_\theta[X_i] = \theta$ pour tout $i$, on a $\mathbb{E}_\theta[\bar{X}_n] = \theta$ : la fréquence empirique $\bar{X}_n = n^{-1}\sum_{i=1}^n X_i$ est un estimateur sans biais de $\theta$. Plus généralement, dès que $\mathbb{E}_\theta[|X_1|] < \infty$ pour tout $\theta$, la moyenne empirique est un estimateur sans biais de l'espérance $g(\theta) := \mathbb{E}_\theta[X_1]$.

**Exemple 1.3: Modèle uniforme : le maximum est biaisé**

Soit $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle $\big(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{U}([0,\theta])\,,\ \theta \in \Theta := \mathbb{R}_+^*\}\big)$, dont l'estimateur du maximum de vraisemblance est $X_{n:n} = \max(X_1, \ldots, X_n)$ (chapitre 2, Exemple 1.11). Cet estimateur est biaisé, et son biais vaut $-\theta/(n+1)$ : il sous-estime systématiquement le paramètre, ce qui n'a rien d'étonnant puisque $X_{n:n} \le \theta$ presque sûrement. Le calcul est repris en détail à l'Exemple 1.9 et fait l'objet de l'Exercice 1 (PC3).

L'exemple suivant montre qu'un estimateur naturel peut être biaisé sans que cela se voie : la variance empirique doit être normalisée correctement pour être sans biais.

**Exemple 1.4: Variance empirique : quelle normalisation ?**

Reprenons un $n$-échantillon d'un modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathbb{P}_\theta\,,\ \theta \in \Theta\}\big)$ tel que $\mathbb{E}_\theta[X_1^2] < \infty$ pour tout $\theta$, et cherchons à estimer la variance $g(\theta) := \mathrm{Var}_\theta(X_1)$. L'estimateur naturel, qui est aussi l'estimateur du maximum de vraisemblance dans le modèle gaussien (chapitre 2, Exemple 1.10), est

$$\hat{\sigma}_n^2 := \frac{1}{n}\sum_{i=1}^n (X_i - \bar{X}_n)^2\ .$$

Pour tout $a \in \mathbb{R}$, un développement direct donne

$$\begin{aligned}\frac{1}{n}\sum_{i=1}^n (X_i - \bar{X}_n)^2 &= \frac{1}{n}\sum_{i=1}^n (X_i - a)^2 - 2(\bar{X}_n - a)\frac{1}{n}\sum_{i=1}^n (X_i - a) + (\bar{X}_n - a)^2 \\ &= \frac{1}{n}\sum_{i=1}^n (X_i - a)^2 - (\bar{X}_n - a)^2\ .\end{aligned}$$

En appliquant cette identité avec $a = \mathbb{E}_\theta[X_1]$ puis en prenant l'espérance sous $\mathbb{P}_\theta$, il vient

$$\mathbb{E}_\theta[\hat{\sigma}_n^2] = \frac{1}{n}\sum_{i=1}^n \mathrm{Var}_\theta(X_i) - \mathrm{Var}_\theta(\bar{X}_n) = \mathrm{Var}_\theta(X_1) - \frac{\mathrm{Var}_\theta(X_1)}{n} = \frac{n-1}{n}\,\mathrm{Var}_\theta(X_1)\ ,$$

de sorte que le biais de $\hat{\sigma}_n^2$ vaut $-\mathrm{Var}_\theta(X_1)/n$. L'estimateur

$$S_n^2 := \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X}_n)^2$$

est, lui, sans biais : c'est la raison de la normalisation par $n-1$.

Être sans biais est une contrainte, et non une propriété gratuite : il existe des fonctions du paramètre qu'aucun estimateur n'estime sans biais.

**Exemple 1.5: Une fonction sans estimateur sans biais**

Considérons le modèle binomial $\big(\{0,\dots,n\}, \mathcal{P}(\{0,\dots,n\}), \{\mathrm{Bin}(n,\theta)\,,\ \theta \in \Theta := ]0,1]\}\big)$, où $n$ est connu, et cherchons à estimer $g(\theta) = 1/\theta$. Pour tout estimateur $T$, l'observation $Z$ suivant la loi $\mathrm{Bin}(n,\theta)$,

$$\mathbb{E}_\theta[T(Z)] = \sum_{k=0}^n \binom{n}{k} T(k)\,\theta^k (1-\theta)^{n-k}\ . \tag{1}$$

Vue comme fonction de $\theta$ sur $]0,1]$, cette quantité est un polynôme, donc bornée. Or $g(\theta) = 1/\theta$ tend vers $+\infty$ quand $\theta$ tend vers 0 : aucune fonction mesurable $T$ ne peut vérifier $\mathbb{E}_\theta[T(Z)] = g(\theta)$ pour tout $\theta$. Il n'existe donc pas d'estimateur sans biais de $1/\theta$ dans ce modèle. La relation (1) dit en fait davantage : une fonction $g$ admet un estimateur sans biais si et seulement si c'est un polynôme en $\theta$ de degré au plus $n$, et cet estimateur est alors unique. Ce point est démontré dans les compléments (Section 4).

**Remarque.** Le biais mesure une erreur systématique : il dit de combien l'estimateur se trompe en moyenne, mais ne dit rien de sa dispersion. Un estimateur sans biais peut être très mauvais : l'observation $X_1$ seule est un estimateur sans biais de l'espérance, aussi bon en moyenne que $\bar{X}_n$ et bien plus dispersé. Par ailleurs, on le verra, un estimateur biaisé peut être préférable à un

estimateur sans biais. Le biais n'est donc qu'une des deux composantes de l'erreur ; la seconde est la variance, et c'est leur combinaison que mesure le risque quadratique.

## 1.3 Perte et risque d'un estimateur

Pour comparer deux estimateurs, on se donne d'abord une façon de chiffrer l'erreur commise lorsqu'on répond $a$ alors que la bonne réponse est $g(\theta)$ : c'est la *fonction de perte*. Le *risque* est la valeur moyenne de cette perte sous la loi des observations.

**Définition 1.2: Risque d'un estimateur**

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique paramétrique avec $\Theta \subseteq \mathbb{R}^d$, et $T : (\mathsf{Z}, \mathcal{Z}) \to (\mathbb{R}^p, \mathcal{B}(\mathbb{R}^p))$ un estimateur de $g : \theta \mapsto g(\theta)$. Soit $\ell : \Theta \times \mathbb{R}^p \to \mathbb{R}_+$ une *fonction de perte*, mesurable en sa seconde variable. Le *risque* de l'estimateur $T$ pour la perte $\ell$ est

$$R_\ell(\theta, T) := \mathbb{E}_\theta\big[\ell(\theta, T(Z))\big]\ , \qquad \theta \in \Theta\ .$$

Les pertes usuelles se construisent à partir d'une distance $W : \mathbb{R}^p \times \mathbb{R}^p \to \mathbb{R}_+$ en posant $\ell(\theta, a) := W(g(\theta), a)$ : la perte représente alors l'écart entre la valeur à estimer et l'action choisie. Deux choix reviennent constamment.

**Exemple 1.6: Pertes quadratique et absolue**

Pour l'estimation d'une fonction $g : \Theta \to \mathbb{R}^p$,

- la *perte quadratique* est $\ell_2(\theta, a) := \|a - g(\theta)\|_2^2 = \sum_{i=1}^p \big(a^{(i)} - g(\theta)^{(i)}\big)^2$, associée au carré de la norme euclidienne ;
- la *perte absolue* est $\ell_1(\theta, a) := \|a - g(\theta)\|_1 = \sum_{i=1}^p \big|a^{(i)} - g(\theta)^{(i)}\big|$, associée à la norme 1.

Cette définition est un cas particulier d'une définition plus générale, celle du risque d'une *règle de décision*, dans laquelle l'estimateur est remplacé par une application à valeurs dans un espace d'actions quelconque. Ce cadre, qui contient aussi les tests d'hypothèses, est donné dans les compléments (Section 4) ; tout ce qui suit s'y transpose sans changement.

**Remarque.** Le choix de la perte n'est pas neutre : il encode ce que l'on considère comme une erreur grave. La perte quadratique pénalise beaucoup les grands écarts, ce qui la rend sensible aux valeurs extrêmes ; la perte absolue les pénalise proportionnellement. Le fait qu'une même paire d'estimateurs puisse être classée dans un sens pour l'une et dans l'autre sens pour l'autre n'est pas une pathologie : la question « quel est le meilleur estimateur ? » n'a de sens qu'une fois la perte fixée. Dans tout ce chapitre, sauf mention contraire, c'est la perte quadratique qui est retenue.

## 1.4 Erreur quadratique moyenne et décomposition biais-variance

Le risque associé à la perte quadratique est appelé *risque quadratique* ou *erreur quadratique moyenne*. Comme il est employé dans toute la suite, on le note simplement $R$, sans indice.

**Définition 1.3: Risque quadratique, erreur quadratique moyenne**

Soit $T$ un estimateur de $g : \Theta \to \mathbb{R}$ tel que $\mathbb{E}_\theta[T(Z)^2] < \infty$ pour tout $\theta \in \Theta$. Le risque associé à la perte quadratique,

$$R(\theta, T) := R_{\ell_2}(\theta, T) = \mathbb{E}_\theta\big[(T(Z) - g(\theta))^2\big]\ ,$$

est appelé *risque quadratique*, ou *erreur quadratique moyenne*, de l'estimateur $T$.

Comme le biais, l'erreur quadratique moyenne d'un estimateur est une fonction du paramètre. Elle se décompose en deux termes, dont l'un est le carré du biais.

**Proposition 1.1: Décomposition biais-variance**

Sous les hypothèses de la Définition 1.3, pour tout $\theta \in \Theta$,

$$R(\theta, T) = \mathrm{Var}_\theta(T(Z)) + \big(b(\theta, T)\big)^2 ,$$

où $b(\theta, T) = \mathbb{E}_\theta[T(Z)] - g(\theta)$ est le biais de $T$.

**Démonstration**

En insérant $\mathbb{E}_\theta[T(Z)]$ et en développant,

$$\begin{aligned} R(\theta, T) &= \mathbb{E}_\theta\Big[\big(T(Z) - \mathbb{E}_\theta[T(Z)] + \mathbb{E}_\theta[T(Z)] - g(\theta)\big)^2\Big] \\ &= \mathbb{E}_\theta\Big[\big(T(Z) - \mathbb{E}_\theta[T(Z)]\big)^2\Big] + \big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)^2 \\ &\quad + 2\big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)\,\mathbb{E}_\theta\big[T(Z) - \mathbb{E}_\theta[T(Z)]\big] \\ &= \mathrm{Var}_\theta(T(Z)) + \big(b(\theta, T)\big)^2 , \end{aligned}$$

le double produit étant nul puisque $\mathbb{E}_\theta[T(Z) - \mathbb{E}_\theta[T(Z)]] = 0$ et que $\mathbb{E}_\theta[T(Z)] - g(\theta)$ est un nombre. □

La version vectorielle de cette décomposition, portant sur la matrice $\mathbb{E}_\theta[(T(Z) - g(\theta))(T(Z) - g(\theta))^\top]$, dont l'énoncé ci-dessus se déduit en prenant la trace, est donnée dans les outils (Proposition 2.3).

**Intuition.** *La décomposition sépare deux sources d'erreur de nature différente. La variance mesure l'instabilité de l'estimateur d'un échantillon à l'autre ; le biais mesure son décalage systématique. Un estimateur sans biais a un risque quadratique égal à sa variance, ce qui explique pourquoi, dans la classe des estimateurs sans biais, minimiser le risque revient à minimiser la variance. En revanche, rien n'oblige à annuler le biais : accepter un peu de biais pour réduire beaucoup la variance peut faire baisser le risque total, comme le montrent l'Exemple 1.8 et l'estimateur à rétrécissement des compléments (Section 4).*

Dans l'exemple interactif qui suit, on effectue une telle décomposition sur l'*estimateur à rétrécissement*, qui consiste à multiplier un estimateur sans biais par un facteur $\gamma \in [0, 1]$ pour le tirer vers zéro. On va voir qu'une telle opération, quoique source de biais, peut réduire le risque quadratique pour certaines valeurs de $\theta$.

**Illustration / animation :** Le risque de $T_\gamma$ se décompose en biais au carré et en variance, qui varient en sens opposés avec $\gamma$

On illustre ici, sur la famille $T_\gamma = \gamma T$, la décomposition biais-variance et le risque $R(\gamma, \theta)$, en déplaçant $\gamma$, $\theta$ et la taille de l'échantillon, et en superposant à la distribution empirique de $T_\gamma$ sur des tirages répétés la valeur vraie et la valeur estimée.

link

**Exemple 1.7: Modèle de Poisson : erreur quadratique moyenne de la moyenne empirique**

Soit $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle $\big(\mathbb{N}, \mathcal{P}(\mathbb{N}), \{\mathcal{P}\mathrm{oi}(\lambda)\,,\ \lambda \in \mathbb{R}_+^*\}\big)$, dont l'estimateur du maximum de vraisemblance de $\lambda$ est $\hat{\lambda}_n = \bar{X}_n$ (chapitre 2, Exemple 1.9). Comme

$\mathbb{E}_\lambda[X_1] = \lambda$, cet estimateur est sans biais, et la décomposition biais-variance donne

$$R(\lambda, \hat{\lambda}_n) = \mathrm{Var}_\lambda(\bar{X}_n) = \frac{\mathrm{Var}_\lambda(X_1)}{n} = \frac{\lambda}{n} \, .$$

Le risque décroît en $n^{-1}$ et croît avec $\lambda$ : le paramètre est d'autant plus difficile à estimer qu'il est grand.

L'exemple suivant compare les deux estimateurs de la variance de l'Exemple 1.4 et montre que l'estimateur biaisé a le plus petit risque quadratique.

**Exemple 1.8: Estimation de la variance dans le modèle gaussien**

Soit $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle

$$\left(\mathbb{R}, \mathcal{B}(\mathbb{R}), \left\{\mathcal{N}(\mu, \sigma^2) \, , \; \theta = (\mu, \sigma^2) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*\right\}\right) \, ,$$

et comparons, pour $n \geq 2$, les risques quadratiques des deux estimateurs $S_n^2$ et $\hat{\sigma}_n^2$ de $g(\theta) = \sigma^2$. Le théorème de Gosset (chapitre 1, Théorème 1.3) donne la loi de $(n-1)S_n^2/\sigma^2$, à savoir $\chi^2(n-1)$, dont la variance vaut $2(n-1)$ ; il s'ensuit

$$\mathrm{Var}_\theta(S_n^2) = \frac{2\sigma^4}{n-1} \, , \qquad \text{et donc} \qquad R(\theta, S_n^2) = \frac{2\sigma^4}{n-1} \, ,$$

puisque $S_n^2$ est sans biais. Comme $\hat{\sigma}_n^2 = \frac{n-1}{n} S_n^2$, on a

$$\mathbb{E}_\theta[\hat{\sigma}_n^2] = \frac{n-1}{n}\sigma^2 \, , \qquad \mathrm{Var}_\theta(\hat{\sigma}_n^2) = \frac{(n-1)^2}{n^2} \cdot \frac{2\sigma^4}{n-1} = \frac{2(n-1)\sigma^4}{n^2} \, ,$$

d'où, par la décomposition biais-variance,

$$R(\theta, \hat{\sigma}_n^2) = \left(\frac{n-1}{n}\sigma^2 - \sigma^2\right)^2 + \frac{2(n-1)\sigma^4}{n^2} = \frac{\sigma^4}{n^2} + \frac{2(n-1)\sigma^4}{n^2} = \frac{(2n-1)\sigma^4}{n^2} \, .$$

La différence des deux risques vaut

$$R(\theta, S_n^2) - R(\theta, \hat{\sigma}_n^2) = \frac{2\sigma^4}{n-1} - \frac{(2n-1)\sigma^4}{n^2} = \frac{(3n-1)\sigma^4}{(n-1)n^2} > 0 \, ,$$

et ceci pour toute valeur de $\theta$. L'estimateur $\hat{\sigma}_n^2$ est biaisé, mais son risque quadratique est strictement plus petit que celui de $S_n^2$ : le carré du biais est plus que compensé par la réduction de variance. Pour le risque quadratique, l'estimateur sans biais $S_n^2$ n'est donc pas le meilleur.

Le dernier exemple de cette série reprend le modèle uniforme, où le maximum de vraisemblance est biaisé, et calcule les risques de toute une famille d'estimateurs.

**Exemple 1.9: Estimation du support d'une loi uniforme**

Soit $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle $\left(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \left\{\mathcal{U}([0,\theta]) \, , \; \theta \in \Theta := \mathbb{R}_+^*\right\}\right)$, et considérons la statistique d'ordre $X_{n:n} = \max(X_1, \ldots, X_n)$.
*Loi de $X_{n:n}$.* Pour tout $\theta \in \Theta$ et tout $x \in [0, \theta]$, par indépendance,

$$\mathbb{P}_\theta(X_{n:n} \leq x) = \mathbb{P}_\theta(X_1 \leq x, \ldots, X_n \leq x) = (x/\theta)^n \, ,$$

de sorte que $X_{n:n}$ admet la densité $x \mapsto n\, x^{n-1}/\theta^n$ sur $[0, \theta]$.

*Biais.* Il vient

$$\mathbb{E}_\theta[X_{n:n}] = \int_0^\theta x\,\frac{n\,x^{n-1}}{\theta^n}\,\mathrm{d}x = \frac{n}{n+1}\theta\ ,$$

donc $b(\theta, X_{n:n}) = -\theta/(n+1)$, et

$$T_n^{(1)} := \frac{n+1}{n} X_{n:n}$$

est un estimateur sans biais de $\theta$.
*Risque de la famille* $a\,X_{n:n}$. Comme $\mathbb{E}_\theta[X_{n:n}^2] = \int_0^\theta x^2\, nx^{n-1}\theta^{-n}\,\mathrm{d}x = n\theta^2/(n+2)$, on a pour tout $a \in \mathbb{R}$

$$\mathbb{E}_\theta\big[(aX_{n:n}-\theta)^2\big] = a^2\,\frac{n\theta^2}{n+2} - 2a\theta\cdot\frac{n\theta}{n+1} + \theta^2 = \theta^2\Big\{\frac{na^2}{n+2} - \frac{2an}{n+1} + 1\Big\}\ .$$

L'accolade est un trinôme en $a$ de coefficient dominant strictement positif, dont le minimum est atteint en $a_n := (n+2)/(n+1)$, et ceci quelle que soit la valeur de $\theta$. Pour ce choix, le risque vaut

$$R\big(\theta,\, a_n X_{n:n}\big) = \frac{\theta^2}{(n+1)^2}\ ,$$

tandis que $T_n^{(1)}$, qui correspond à $a = (n+1)/n$, a un risque strictement plus grand pour tout $\theta$. L'estimateur sans biais $T_n^{(1)}$ n'est donc pas le meilleur estimateur de la famille.
*Vitesse.* Le risque de ces estimateurs décroît en $n^{-2}$, et non en $n^{-1}$ comme dans les exemples précédents. On reviendra sur ce point à l'Exemple 1.16.

Ces calculs, ainsi que la comparaison complète des estimateurs de la famille, font l'objet de l'Exercice 1 (PC3).

## 1.5 Comparer des risques : admissibilité

On dispose maintenant, pour chaque estimateur, d'une fonction du paramètre qui mesure sa qualité. Comparer deux estimateurs, c'est comparer deux fonctions ; or deux fonctions ne se comparent pas toujours, et c'est là toute la difficulté.

Le risque définit un ordre partiel sur l'espace des estimateurs : on dit que $T$ est *préférable* à $T'$, ou *uniformément meilleur* que $T'$ pour la perte $\ell$, si

$$R_\ell(\theta, T) \le R_\ell(\theta, T') \qquad \text{pour tout } \theta \in \Theta\ .$$

On dit que $T$ est *uniformément optimal* pour la perte $\ell$ s'il est uniformément meilleur que tout autre estimateur. Deux estimateurs dont les fonctions de risque se croisent ne sont, eux, pas comparables. La définition suivante retient la propriété la plus faible que l'on puisse exiger.

**Définition 1.4: Admissibilité**

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\ ,\ \theta \in \Theta\})$ un modèle statistique et $\ell$ une fonction de perte. Un estimateur $T$ de $g : \Theta \to \mathbb{R}^p$ est dit *inadmissible* (pour la perte $\ell$) s'il existe un estimateur $T^*$ tel que

$$\begin{aligned} &R_\ell(\theta, T^*) \le R_\ell(\theta, T) && \text{pour tout } \theta \in \Theta\ ,\\ &R_\ell(\theta, T^*) < R_\ell(\theta, T) && \text{pour au moins un } \theta \in \Theta\ . \end{aligned}$$

Un estimateur qui n'est pas inadmissible est dit *admissible* : c'est un élément maximal pour l'ordre partiel induit par la fonction de risque.

**Intuition.** *La différence entre les deux notions se comprend sur une analogie. Dire que je suis* admissible *parmi les élèves de la promotion, c'est dire qu'il n'existe pas d'élève qui ait une meilleure note que moi*

*dans* toutes *les matières ; dire que je suis* uniformément optimal*, c'est dire que je suis le meilleur dans toutes les matières. La première propriété est facile à obtenir et n'apprend presque rien – il suffit d'être le meilleur dans une matière ; la seconde est très forte, et l'on va voir qu'elle est en général hors d'atteinte.*

L'admissibilité est un prérequis un peu minimal : dire qu'un estimateur est inadmissible signifie qu'il en existe un autre dont le risque est partout inférieur, et qui est strictement meilleur quelque part – il n'y a alors aucune raison de garder le premier. C'est ainsi que l'Exemple 1.8 montre que $S_n^2$ est inadmissible dans le modèle gaussien, et l'Exemple 1.9 que $T_n^{(1)}$ est inadmissible dans le modèle uniforme. En revanche, il existe en général beaucoup d'estimateurs incomparables, et des estimateurs admissibles parfaitement indésirables.

**Exemple 1.10: Un estimateur admissible mais indésirable**

Considérons un $n$-échantillon du modèle de Bernoulli,

$$\big(\{0,1\}^n, \mathcal{P}(\{0,1\}^n), \big\{\mathcal{B}\mathrm{er}(\theta)^{\otimes n}\,,\ \theta \in \Theta := [0,1]\big\}\big)\ ,$$

le risque quadratique, et l'estimation de $\theta$. Fixons $\vartheta \in\ ]0,1[$ et considérons l'*estimateur constant* $\hat\theta_\vartheta : Z \mapsto \vartheta$. Son risque vaut

$$R(\theta, \hat\theta_\vartheta) = (\theta - \vartheta)^2\ , \qquad \theta \in \Theta\ ,$$

et il s'annule en $\theta = \vartheta$. Cet estimateur est admissible. En effet, supposons qu'il soit inadmissible : il existerait alors un estimateur $T$ tel que $R(\theta, T) \le R(\theta, \hat\theta_\vartheta)$ pour tout $\theta$, donc en particulier $R(\vartheta, T) = 0$. Compte tenu de la perte quadratique, cela signifie $T(Z) = \vartheta$ $\mathbb{P}_\vartheta$-presque sûrement, donc $T(z) = \vartheta$ pour tout $z \in \{0,1\}^n$, puisque $\mathbb{P}_\vartheta$ charge tous les points de $\{0,1\}^n$ dès que $\vartheta \in\ ]0,1[$ ; ainsi $T = \hat\theta_\vartheta$, et l'inégalité stricte demandée par la définition ne peut être réalisée en aucun point. L'estimateur constant est donc admissible, alors qu'il n'estime correctement qu'une seule valeur du paramètre et ignore complètement les observations.
Ce contre-exemple montre du même coup qu'il n'existe pas d'estimateur uniformément optimal pour le risque quadratique. Si $T^\star$ était uniformément optimal, on aurait, pour tout $\vartheta \in\ ]0,1[$, $R(\vartheta, T^\star) \le R(\vartheta, \hat\theta_\vartheta) = 0$, donc $T^\star$ serait constant égal à $\vartheta$ pour toute valeur de $\vartheta$, ce qui est impossible. Le résultat s'étend à d'autres pertes, à d'autres modèles statistiques dominés et à d'autres fonctions du paramètre.

**Illustration / animation :** Le risque quadratique compare les estimateurs point par point, et deux courbes peuvent se croiser

L'animation accessible par le QR code ci-contre permet de choisir un modèle et plusieurs estimateurs à la fois, afin de tracer leur risque en fonction de $\theta$ et de voir directement lequel domine l'autre, ou si aucun ordre ne s'impose entre eux.

link

## 1.6 Restreindre la classe des estimateurs

Puisqu'aucun estimateur n'est uniformément optimal parmi tous les estimateurs, deux voies s'ouvrent. La première consiste à changer de critère, en agrégeant la fonction de risque en un seul nombre : c'est ce que font l'approche minimax, qui retient le risque dans le pire des cas, et l'approche bayésienne, qui en fait une moyenne pondérée par une loi a priori. Ces deux approches sont définies dans les compléments (Section 4) et ne sont pas développées ici. La seconde voie, celle que suit ce chapitre, consiste à restreindre la classe des estimateurs : on cherche un estimateur optimal, non plus parmi tous, mais parmi ceux d'une classe assez petite pour que l'optimum existe, et assez grande pour qu'il soit intéressant.

Trois restrictions reviennent souvent.

1. *Absence de biais* : on cherche l'estimateur de risque quadratique minimal dans la classe des estimateurs sans biais. C'est la restriction retenue dans la suite de ce chapitre ; elle exclut en particulier l'estimateur constant.
2. *Invariance sous l'action d'un groupe de transformations* : on cherche le meilleur estimateur dans une classe possédant une propriété d'invariance. Dans un modèle de translation, par exemple, on se limite aux estimateurs vérifiant $T(x_1 + c, \dots, x_n + c) = c + T(x_1, \dots, x_n)$ pour tout $c$ ; le risque d'un tel estimateur ne dépend alors pas du paramètre, ce qui rend la comparaison immédiate (Section 4).
3. *Linéarité* : on cherche le meilleur estimateur dans la classe des estimateurs obtenus par transformation affine des observations, $T(X_1, \dots, X_n) = \sum_{i=1}^n a_i X_i + b$.

L'exemple suivant combine les deux dernières idées et donne le premier résultat d'optimalité du chapitre.

**Exemple 1.11: Meilleur estimateur linéaire sans biais de l'espérance**

Soit $(X_1, \dots, X_n)$ un $n$-échantillon d'un modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathbb{P}_\theta\,,\ \theta \in \Theta\}\big)$ tel que $\mathbb{E}_\theta[X_1^2] < \infty$ pour tout $\theta$, et cherchons à estimer $g(\theta) := \mathbb{E}_\theta[X_1]$ en nous limitant aux estimateurs de la forme

$$\hat{\mu}_\alpha := \sum_{i=1}^n \alpha_i X_i\ , \qquad \alpha = (\alpha_1, \dots, \alpha_n) \in \mathbb{R}^n \ \text{ tel que } \ \sum_{i=1}^n \alpha_i = 1\ .$$

Notons $\sigma^2(\theta) := \mathrm{Var}_\theta(X_1)$. La contrainte $\sum_i \alpha_i = 1$ assure que $\hat{\mu}_\alpha$ est sans biais, donc, par la décomposition biais-variance et par indépendance des observations,

$$R(\theta, \hat{\mu}_\alpha) = \mathrm{Var}_\theta(\hat{\mu}_\alpha) = \sigma^2(\theta) \sum_{i=1}^n \alpha_i^2\ .$$

Le risque est minimisé, *pour toute valeur de $\theta$ simultanément*, par les poids de somme 1 qui minimisent $\sum_i \alpha_i^2$. Par l'inégalité de Cauchy-Schwarz (Proposition 2.1), ou par stricte convexité de la fonction carré,

$$\frac{1}{n} \sum_{i=1}^n \alpha_i^2 \geq \Big(\frac{1}{n} \sum_{i=1}^n \alpha_i\Big)^2\ ,$$

avec égalité si et seulement si $\alpha_1 = \dots = \alpha_n$ ; la somme valant 1, le minimum est atteint en $\alpha_1^\star = \dots = \alpha_n^\star = 1/n$. La moyenne empirique est donc le meilleur estimateur linéaire sans biais de l'espérance, au sens du risque quadratique. Si de plus $\sigma^2(\theta) > 0$ pour au moins un $\theta$, tout $\hat{\mu}_\alpha$ avec $\alpha \neq (1/n, \dots, 1/n)$ est inadmissible.

L'Exercice 4 (PC3) reprend cette question dans un modèle de translation, en levant la contrainte d'absence de biais.

Dans la classe des estimateurs sans biais, la décomposition biais-variance réduit le risque quadratique à la variance, ce qui conduit à la définition suivante.

**Définition 1.5: Estimateur sans biais de variance minimale**

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique, $g : \Theta \to \mathbb{R}$ une fonction et $T, T'$ des estimateurs sans biais de $g(\theta)$, de carré intégrable.

— On dit que $T$ est *uniformément meilleur* que $T'$ si $\mathrm{Var}_\theta(T(Z)) \leq \mathrm{Var}_\theta(T'(Z))$ pour tout $\theta \in \Theta$.

— On dit que $T$ est un *estimateur sans biais de variance minimale*, en abrégé E.S.B.V.M., s'il est uniformément meilleur que tout estimateur sans biais de $g(\theta)$.

Un estimateur E.S.B.V.M. est donc optimal au sein de la classe des estimateurs sans biais de $g(\theta)$. Reste à savoir comment en exhiber un. La stratégie de la fin du chapitre est indirecte : on établit une borne inférieure valable pour la variance de *tout* estimateur sans biais, et tout estimateur sans biais qui atteint cette borne est automatiquement E.S.B.V.M..

**Résumé.** Le fil de cette première moitié de chapitre peut se résumer ainsi. On veut parler d'optimalité d'un estimateur ; on définit pour cela une perte, puis le risque associé, par exemple le risque quadratique. On obtient un risque pour chaque valeur du paramètre, donc une fonction, et comparer des fonctions n'est pas immédiat. On définit alors l'admissibilité, qui n'est qu'un prérequis minimal, et l'on constate que des estimateurs triviaux sont admissibles et qu'aucun estimateur n'est uniformément optimal. Il faut donc restreindre la classe des estimateurs : c'est la classe des estimateurs sans biais que l'on retient.

## 1.7 Une borne inférieure pour la variance : le calcul

Avant d'écrire les hypothèses, faisons le calcul qui conduit à la borne : c'est lui qui dicte les hypothèses à poser, et non l'inverse. On travaille sur un modèle $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ où $\Theta$ est un ouvert de $\mathbb{R}$, et l'on se donne un estimateur $T$ sans biais de $\theta$. L'absence de biais s'écrit, pour tout $\theta \in \Theta$,

$$\theta = \mathbb{E}_\theta[T(Z)] = \int_{\mathsf{Z}} T(z)\, p_\theta(z)\, \mu(\mathrm{d}z)\ .$$

Dérivons les deux membres par rapport à $\theta$, en admettant provisoirement que la dérivation puisse se faire sous le signe intégral :

$$\begin{aligned} 1 &= \int_{\mathsf{Z}} T(z)\, \frac{\partial}{\partial\theta} p_\theta(z)\, \mu(\mathrm{d}z) = \int_{\mathsf{Z}} \big(T(z) - \theta\big)\, \frac{\partial}{\partial\theta} p_\theta(z)\, \mu(\mathrm{d}z) \\ &= \int_{\mathsf{Z}} \big(T(z) - \theta\big)\, \frac{\partial}{\partial\theta} \big(\log p_\theta(z)\big)\, p_\theta(z)\, \mu(\mathrm{d}z) = \mathbb{E}_\theta\Big[\big(T(Z) - \theta\big)\, \frac{\partial}{\partial\theta} \log p_\theta(Z)\Big]\ , \end{aligned}$$

où la deuxième égalité utilise $\int_{\mathsf{Z}} \partial_\theta p_\theta(z)\, \mu(\mathrm{d}z) = \partial_\theta \int_{\mathsf{Z}} p_\theta(z)\, \mu(\mathrm{d}z) = \partial_\theta 1 = 0$, encore une dérivation sous le signe intégral. En élevant au carré et en appliquant l'inégalité de Cauchy-Schwarz,

$$1 \le \mathbb{E}_\theta\big[(T(Z) - \theta)^2\big] \cdot \mathbb{E}_\theta\Big[\Big(\frac{\partial}{\partial\theta} \log p_\theta(Z)\Big)^2\Big] = \mathrm{Var}_\theta(T(Z)) \cdot \mathrm{Var}_\theta\Big(\frac{\partial}{\partial\theta} \log p_\theta(Z)\Big)\ ,$$

la première égalité parce que $T$ est sans biais, la seconde parce que la dérivée de la log-vraisemblance est d'espérance nulle sous $\mathbb{P}_\theta$, comme on vient de le voir. La variance de l'estimateur est donc minorée, en tout point, par l'inverse d'une quantité qui ne dépend que du modèle et du paramètre.

Le même calcul, mené pour un estimateur $T$ sans biais de $g(\theta)$ au lieu de $\theta$, donne

$$g'(\theta) = \mathbb{E}_\theta\Big[\big(T(Z) - g(\theta)\big)\, \frac{\partial}{\partial\theta} \log p_\theta(Z)\Big]\ ,$$

puis

$$\mathrm{Var}_\theta(T(Z)) \ge \frac{\{g'(\theta)\}^2}{\mathrm{Var}_\theta\big(\partial_\theta \log p_\theta(Z)\big)}\ .$$

**Intuition.** *Ce calcul est remarquable par ce qu'il produit : une* borne inférieure *valable pour tous les estimateurs sans biais à la fois, alors que la statistique fournit d'ordinaire des bornes supérieures sur l'erreur d'un estimateur particulier. Il dit qu'aucun estimateur sans biais, aussi ingénieux soit-il, ne descendra en dessous d'un certain niveau de variance, fixé par le modèle seul. Encore faut-il donner un sens à chacune des étapes : les deux dérivations sous le signe intégral ne sont licites que sous des hypothèses de domination, et l'inégalité de Cauchy-Schwarz demande des moments d'ordre 2. La suite du chapitre pose ces hypothèses (qui sont la régularité du modèle et celle de l'estimateur), et nomme les deux quantités qui apparaissent (le score et l'information de Fisher) et énonce le résultat sous sa forme générale.*

**Remarque.** Disposer d'une borne inférieure pour la variance de tout estimateur sans biais est un très beau résultat. La statistique, est fondamentalement, l'étude de l'information contenue dans les données : être capable de "quantifier" cette information, en obtenant des résultats d'optimalité d'un estimateur, est un résultat très puissant.

## 1.8 Modèles réguliers

Le calcul précédent demande que la densité dépende du paramètre de façon suffisamment régulière pour qu'on puisse la dériver, et que cette dérivation puisse s'échanger avec l'intégrale. C'est ce qu'exprime la définition suivante, où les conditions techniques sont écrites sous forme de dominations locales.

Rappelons d'abord deux notations, employées dans cette définition et dans toute la suite. Si $F : \Theta \times \mathsf{Z} \to \mathbb{R}$ est telle que $\theta \mapsto F(\theta, z)$ soit deux fois dérivable, on note $\mathrm{H}_F(\theta, z)$ sa matrice hessienne, de terme général $\partial^2 F / \partial\theta^{(i)} \partial\theta^{(j)}(\theta, z)$. Si $A \in \mathrm{Mat}_d(\mathbb{R})$, on note $\|A\|$ sa norme de Frobenius, définie par $\|A\|^2 := \mathrm{Tr}\left(A^\top A\right)$. Ces deux objets sont repris dans les outils (Section 2).

**Définition 1.6: Modèle régulier**

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle paramétrique, où $\Theta$ est un ouvert de $\mathbb{R}^d$. Ce modèle est dit *régulier* s'il satisfait les propriétés suivantes.

(i) Le modèle est dominé par une mesure $\sigma$-finie $\mu$ sur $(\mathsf{Z}, \mathcal{Z})$, de densité $p_\theta$ pour tout $\theta \in \Theta$, c'est-à-dire $\mathbb{P}_\theta = p_\theta \cdot \mu$. On pose alors, pour tout $\theta \in \Theta$ et tout $z \in \mathsf{Z}$,

$$\ell(\theta, z) := \log p_\theta(z)\ . \tag{2}$$

(ii) Pour $\mu$-presque tout $z \in \mathsf{Z}$, la fonction $\theta \mapsto p_\theta(z)$ est deux fois continûment différentiable sur $\Theta$.

(iii) Pour tout $\theta_0 \in \Theta$, il existe un voisinage $\mathcal{V}_0$ de $\theta_0$ dans $\Theta$ et deux fonctions mesurables positives $h_0, h_1 : (\mathsf{Z}, \mathcal{Z}) \to \mathbb{R}_+$ telles que

$$\int_{\mathsf{Z}} \{1 + h_1(z)\}\, h_0(z)\, \mu(\mathrm{d}z) < \infty \tag{3}$$

et, pour tout $\theta \in \mathcal{V}_0$ et $\mu$-presque tout $z \in \mathsf{Z}$,

$$\|\nabla_\theta \ell(\theta, z)\|^2 \le h_1(z)\ , \qquad \|\mathrm{H}_\ell(\theta, z)\| \le h_1(z)\ , \qquad p_\theta(z) \le h_0(z)\ . \tag{4}$$

(iv) Pour tout $\theta \in \Theta$, la matrice $\mathbb{E}_\theta[\mathrm{H}_\ell(\theta, Z)]$, bien définie par la condition (iii), est inversible.

**Remarque.** Les slides du cours donnent une version allégée de cette définition, où seules trois conditions sont demandées : la différentiabilité continue de $\theta \mapsto p_\theta(z)$, la validité de la dérivation sous le signe intégral $\nabla_\theta \int p_\theta(z)\mu(\mathrm{d}z) = \int \nabla_\theta p_\theta(z)\mu(\mathrm{d}z) = 0$, et la finitude de $\int \|\nabla_\theta \ell(\theta, z)\|^2 p_\theta(z)\mu(\mathrm{d}z)$. Ces trois conditions suffisent à démontrer le théorème de Cramér-Rao ; les conditions ci-dessus, plus fortes, sont celles qui permettent en outre d'écrire l'information de Fisher à l'aide de la hessienne (Proposition 1.2 (ii)), expression qui rend les calculs bien plus courts en pratique.

Toutes les conditions ci-dessus portent sur la dépendance de la densité *en le paramètre*, et non sur la régularité de $z \mapsto p_\theta(z)$ : c'est la variation de $\theta \mapsto p_\theta(z)$ qui est en jeu. La vérification est fastidieuse mais généralement sans surprise, et l'on admettra le plus souvent la régularité dans les exercices.

**Exemple 1.12: Quels modèles sont réguliers ?**

Les modèles suivants sont réguliers : le modèle exponentiel $\{\mathcal{E}(\theta)\,,\ \theta \in \mathbb{R}_+^*\}$, le modèle gaussien $\{\mathcal{N}(\mu, \sigma^2)\,,\ (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}$, le modèle de Bernoulli $\{\mathcal{B}\mathrm{er}(\theta)\,,\ \theta \in ]0,1[\}$, le modèle de Poisson $\{\mathcal{P}\mathrm{oi}(\theta)\,,\ \theta \in \mathbb{R}_+^*\}$ et le modèle géométrique $\{\mathcal{G}(\theta)\,,\ \theta \in ]0,1[\}$, où $\mathcal{G}(\theta)$ désigne la loi du rang du premier succès dans une suite de tirages de Bernoulli indépendants de paramètre $\theta$. Le modèle uniforme $\{\mathcal{U}([0,\theta])\,,\ \theta \in \mathbb{R}_+^*\}$, en revanche, n'est *pas* régulier. Sa densité par rapport à la mesure de Lebesgue est $p_\theta(x) = \theta^{-1}\mathbb{1}_{[0,\theta]}(x)$ ; pour $x > 0$ fixé, la fonction $\theta \mapsto p_\theta(x)$ est nulle sur $]0, x[$ et vaut $1/\theta$ sur $[x, +\infty[$, donc discontinue en $\theta = x$. La condition (ii) est en défaut, et déjà la simple différentiabilité.

Noter que l'espace des paramètres doit être *ouvert* pour qu'il soit question de dériver par rapport au paramètre : c'est pourquoi le modèle de Bernoulli est ici écrit sur $]0,1[$ et non sur $[0,1]$.

## 1.9 Score et information de Fisher

Un modèle régulier autorise à dériver la log-vraisemblance par rapport au paramètre. Cette dérivée porte un nom : elle indique dans quelle direction, et avec quelle intensité, la vraisemblance d'une observation change quand on déplace le paramètre.

**Définition 1.7: Log-vraisemblance et score**

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle régulier. Pour tout $\theta \in \Theta$ et tout $z \in \mathsf{Z}$, on appelle *log-vraisemblance* la fonction $\ell(\theta, z) := \log p_\theta(z)$ définie en (2), et *score* le gradient

$$S(\theta, z) := \nabla_\theta \ell(\theta, z) \in \mathbb{R}^d\,.$$

**Intuition.** *En dimension 1, le score évalué en une observation $z$ est la pente de la log-vraisemblance au point $\theta$ : il dit de combien la log-vraisemblance de cette observation augmente ou diminue si l'on déplace un peu le paramètre. En dimension $d$, c'est un gradient, qui pointe dans la direction où la log-vraisemblance croît le plus vite. La proposition qui suit établit qu'en moyenne sous $\mathbb{P}_\theta$, cette quantité est nulle : si, pour une observation, la log-vraisemblance croît quand le paramètre augmente, il existe d'autres observations pour lesquelles la même variation la fait décroître, et les deux effets se compensent exactement. Ce qui reste, une fois la moyenne annulée, c'est la* dispersion *du score : des valeurs souvent grandes en valeur absolue signifient qu'une petite variation du paramètre change beaucoup la vraisemblance des observations, donc que les observations sont discriminantes et le paramètre facile à cerner. C'est cette dispersion que mesure l'information de Fisher.*

**Définition 1.8: Information de Fisher**

L'*information de Fisher* du modèle régulier $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ est la fonction $\mathbb{I} : \Theta \to \mathrm{Mat}_d(\mathbb{R})$ définie par

$$\mathbb{I}(\theta) := \mathbb{E}_\theta\big[\nabla_\theta \ell(\theta, Z)\, \nabla_\theta \ell(\theta, Z)^\top\big] = \mathbb{E}_\theta\big[S(\theta, Z)\, S(\theta, Z)^\top\big]\,. \tag{5}$$

Cette matrice est bien définie et ne dépend pas du choix de la mesure dominante ; c'est l'objet du Lemme 2.1 des outils. Comme le score est d'espérance nulle sous $\mathbb{P}_\theta$, l'information de Fisher est la *matrice de covariance du score* sous $\mathbb{P}_\theta$ ; en dimension 1, c'est simplement sa variance,

$$\mathbb{I}(\theta) = \mathbb{E}_\theta\Big[\Big(\frac{\partial}{\partial\theta}\ell(\theta, Z)\Big)^2\Big] = \mathrm{Var}_\theta\big(S(\theta, Z)\big)\,.$$



**Point d'histoire : Ronald Aylmer Fisher (1890-1962)**

Fisher arrive en 1919 à Rothamsted, station d'agronomie au nord de Londres, avec plusieurs décennies de relevés d'essais de fertilisation à dépouiller. Il en tire la planification des expériences, l'analyse de la variance et le maximum de vraisemblance, nommé dans ses articles de 1922 et 1925, qui introduisent aussi la quantité d'information portant son nom : on la retrouvera au dénominateur de la borne démontrée plus loin.

Portrait : Wikimedia Commons, domaine public.

**Proposition 1.2: Propriétés du score et de l'information de Fisher**

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle statistique régulier. Les propriétés suivantes sont vérifiées.

(i) Pour tout $\theta \in \Theta$, le score est d'espérance nulle :

$$\mathbb{E}_\theta\big[\nabla_\theta \ell(\theta, Z)\big] = 0\,. \tag{6}$$

(ii) L'information de Fisher admet l'expression alternative

$$\mathbb{I}(\theta) = -\mathbb{E}_\theta\big[\,\mathrm{H}_\ell(\theta, Z)\big]\,. \tag{7}$$

(iii) Soient deux modèles réguliers $(\mathsf{Z}_1, \mathcal{Z}_1, \{\mathbb{P}_{1,\theta}\,,\ \theta \in \Theta\})$ et $(\mathsf{Z}_2, \mathcal{Z}_2, \{\mathbb{P}_{2,\theta}\,,\ \theta \in \Theta\})$ de même espace de paramètres, d'informations de Fisher $\mathbb{I}_1$ et $\mathbb{I}_2$. L'information de Fisher $\mathbb{I}_{12}$ du modèle produit

$$\big(\mathsf{Z}_1 \times \mathsf{Z}_2,\ \mathcal{Z}_1 \otimes \mathcal{Z}_2,\ \{\mathbb{P}_{1,\theta} \otimes \mathbb{P}_{2,\theta}\,,\ \theta \in \Theta\}\big)$$

vérifie $\mathbb{I}_{12}(\theta) = \mathbb{I}_1(\theta) + \mathbb{I}_2(\theta)$ pour tout $\theta \in \Theta$. En particulier, si $(X_1, \dots, X_n)$ est un $n$-échantillon du modèle régulier $\mathcal{M} = (\mathsf{X}, \mathcal{X}, \{q_\theta \cdot \mu\,,\ \theta \in \Theta\})$, alors, pour tout $\theta \in \Theta$ et tout $n \geq 1$,

$$\mathbb{I}_{\mathcal{M}^n}(\theta) = n\,\mathbb{I}_{\mathcal{M}}(\theta)\,.$$

**Remarque.** L'information de Fisher est une caractéristique du *modèle*, et non du seul paramètre : la notation complète serait $\mathbb{I}(\mathcal{M}, \theta)$, où $\mathcal{M}$ désigne le modèle. On écrit $\mathbb{I}(\theta)$ lorsque le modèle est clair d'après le contexte, $\mathbb{I}_1(\theta)$ ou $\mathbb{I}_{\mathcal{M}}(\theta)$ pour l'information associée à une seule observation, et $\mathbb{I}_{\mathcal{M}^n}(\theta)$ pour celle du $n$-échantillon. Le point (iii) énonce alors que l'information de Fisher est *additive* pour des observations indépendantes : l'information du $n$-échantillon vaut $n$ fois celle d'une observation.

**Remarque.** Pour tout $z \in \mathsf{Z}$ et tout $\theta \in \Theta$, la matrice $\nabla_\theta \ell(\theta, z)\,\nabla_\theta \ell(\theta, z)^\top$ est symétrique et semi-définie positive ; l'information de Fisher, qui en est l'espérance, l'est donc aussi. Par l'expression (7) et la condition (iv) de la Définition 1.6, elle est de plus inversible, donc définie positive. C'est ce qui donne un sens à $\mathbb{I}(\theta)^{-1}$ dans l'énoncé du théorème de Cramér-Rao.

**Démonstration**

Commençons par noter que, pour tout $\theta \in \Theta$ et $\mu$-presque tout $z \in \mathsf{Z}$,

$$\nabla_\theta \ell(\theta, z) = \frac{1}{p_\theta(z)} \nabla_\theta p_\theta(z)\,; \tag{8}$$

en différenciant une seconde fois,

$$\mathrm{H}_\ell(\theta,z)=\frac{1}{p_\theta(z)}\,\mathrm{H}_p(\theta,z)-\frac{1}{p_\theta(z)^2}\nabla_\theta p_\theta(z)\,\nabla_\theta p_\theta(z)^\top=\frac{1}{p_\theta(z)}\,\mathrm{H}_p(\theta,z)-\nabla_\theta\ell(\theta,z)\,\nabla_\theta\ell(\theta,z)^\top\,. \tag{9}$$

On peut alors écrire, pour tout $\theta\in\Theta$,

$$\mathbb{E}_\theta\big[\nabla_\theta\ell(\theta,Z)\big]=\int_{\mathsf{Z}}\nabla_\theta\ell(\theta,z)\,p_\theta(z)\,\mu(\mathrm{d}z)=\int_{\mathsf{Z}}\nabla_\theta p_\theta(z)\,\mu(\mathrm{d}z)\overset{(*)}{=}\nabla_\theta\int_{\mathsf{Z}}p_\theta(z)\,\mu(\mathrm{d}z)=\nabla_\theta 1=0\,,$$

ce qui établit (i), sous réserve que l'interversion $(*)$ soit justifiée. De même, en intégrant (9) contre $p_\theta\,\mu$,

$$\mathbb{E}_\theta\big[\,\mathrm{H}_\ell(\theta,Z)\big]=\int_{\mathsf{Z}}\mathrm{H}_p(\theta,z)\,\mu(\mathrm{d}z)-\int_{\mathsf{Z}}\nabla_\theta\ell(\theta,z)\,\nabla_\theta\ell(\theta,z)^\top p_\theta(z)\,\mu(\mathrm{d}z)\overset{(**)}{=}0-\mathbb{I}(\theta)\,,$$

ce qui établit (ii), sous réserve que l'interversion $(**)$, qui affirme $\int_{\mathsf{Z}}\mathrm{H}_p(\theta,z)\,\mu(\mathrm{d}z)=\mathrm{H}(\theta)\int_{\mathsf{Z}}p_\theta(z)\,\mu(\mathrm{d}z)=0$, soit valide.
Justifions les deux dérivations sous le signe intégral. Soient $\theta_0\in\Theta$, $\mathcal{V}_0$ un voisinage de $\theta_0$ et $h_0,h_1$ comme dans la condition (iii) de régularité. Pour tout $\theta\in\mathcal{V}_0$ et $\mu$-presque tout $z$, par (8),

$$\|\nabla_\theta p_\theta(z)\|=\|\nabla_\theta\ell(\theta,z)\|\;p_\theta(z)\le\big(1+\|\nabla_\theta\ell(\theta,z)\|^2\big)p_\theta(z)\le\{1+h_1(z)\}h_0(z)\,,$$

majorant intégrable par (3). La Proposition 2.2 de dérivation sous le signe intégral, appliquée coordonnée par coordonnée à $(\theta,z)\mapsto p_\theta(z)$, garantit alors que $(*)$ est correcte. De même, par (9) et par l'identité $\big\|aa^\top\big\|=\|a\|^2$ valable pour tout $a\in\mathbb{R}^d$,

$$\|\mathrm{H}_p(\theta,z)\|\le\Big(\,\|\mathrm{H}_\ell(\theta,z)\|+\|\nabla_\theta\ell(\theta,z)\|^2\,\Big)p_\theta(z)\le 2\,h_1(z)h_0(z)\,,$$

qui est $\mu$-intégrable ; comme $\mathrm{H}_p(\theta,z)$ est la matrice des dérivées partielles des coordonnées de $\nabla_\theta p_\theta(z)$, la même proposition appliquée à chacune d'elles montre que $(**)$ est valide.
Enfin, le troisième point découle du second et du fait que, pour le modèle produit, la log-vraisemblance se décompose en $\ell_{12}(\theta,(z_1,z_2))=\ell_1(\theta,z_1)+\ell_2(\theta,z_2)$, de sorte que $\mathrm{H}_{\ell_{12}}(\theta,(z_1,z_2))=\mathrm{H}_{\ell_1}(\theta,z_1)+\mathrm{H}_{\ell_2}(\theta,z_2)$ ; en prenant l'espérance sous $\mathbb{P}_{1,\theta}\otimes\mathbb{P}_{2,\theta}$ et en changeant de signe, il vient $\mathbb{I}_{12}=\mathbb{I}_1+\mathbb{I}_2$. Le cas du $n$-échantillon s'obtient par récurrence, les $n$ facteurs étant identiques. □

Les trois exemples qui suivent calculent le score et l'information de Fisher sur les modèles rencontrés au chapitre 2. Le schéma de calcul est toujours le même : écrire la densité, en prendre le logarithme, dériver, puis calculer soit la variance du score, soit l'espérance de la dérivée seconde changée de signe.

**Exemple 1.13: Information de Fisher du modèle exponentiel**

Considérons le modèle $\big\{\mathcal{E}(\theta)\,,\ \theta\in\Theta:=\mathbb{R}_+^*\big\}$ pour une observation.

1. Densité par rapport à la mesure de Lebesgue : $p_\theta(z)=\theta\mathrm{e}^{-\theta z}\mathbb{1}_{\mathbb{R}_+}(z)$.
2. Log-vraisemblance : $\ell(\theta,z)=\log\theta-\theta z$ pour $z>0$.
3. Score : $S(\theta,z)=\partial_\theta\ell(\theta,z)=1/\theta-z$. On vérifie que $\mathbb{E}_\theta[S(\theta,Z)]=1/\theta-\mathbb{E}_\theta[Z]=0$.
4. Information de Fisher : $\mathbb{I}(\theta)=\mathrm{Var}_\theta(S(\theta,Z))=\mathrm{Var}_\theta(1/\theta-Z)=\mathrm{Var}_\theta(Z)=1/\theta^2$.

**Exemple 1.14: Information de Fisher du modèle de Poisson**

Considérons le modèle $\{\mathcal{P}\mathrm{oi}(\theta)\,,\ \theta \in \Theta := \mathbb{R}_+^*\}$ pour une observation.

1. Densité par rapport à la mesure de comptage sur $\mathbb{N}$ : $p_\theta(z) = \mathrm{e}^{-\theta}\theta^z/z!$.
2. Log-vraisemblance : $\ell(\theta, z) = -\theta + z\log\theta - \log(z!)$.
3. Score : $S(\theta, z) = z/\theta - 1$, d'espérance $\mathbb{E}_\theta[Z]/\theta - 1 = 0$.
4. Information de Fisher : $\mathbb{I}(\theta) = \mathrm{Var}_\theta(Z/\theta - 1) = \mathrm{Var}_\theta(Z)/\theta^2 = \theta/\theta^2 = 1/\theta$.

Par additivité, l'information de Fisher du $n$-échantillon vaut $n/\theta$.

**Exemple 1.15: Information de Fisher du modèle de Bernoulli**

Considérons le modèle $\{\mathcal{B}\mathrm{er}(\theta)\,,\ \theta \in \Theta := ]0,1[\}$, dominé par la mesure de comptage sur $\{0,1\}$, de densité $p_\theta(x) = \theta^x(1-\theta)^{1-x}$. Alors

$$\ell(\theta, x) = x\log\theta + (1-x)\log(1-\theta)\,, \qquad \partial_\theta\ell(\theta, x) = \frac{x}{\theta} - \frac{1-x}{1-\theta}\,, \qquad \partial_\theta^2\ell(\theta, x) = -\frac{x}{\theta^2} - \frac{1-x}{(1-\theta)^2}\,,$$

d'où, en utilisant l'expression par la dérivée seconde,

$$\mathbb{I}_1(\theta) = -\mathbb{E}_\theta\left[\partial_\theta^2\ell(\theta, X_1)\right] = -\theta\,\partial_\theta^2\ell(\theta, 1) - (1-\theta)\,\partial_\theta^2\ell(\theta, 0) = \frac{1}{\theta} + \frac{1}{1-\theta} = \frac{1}{\theta(1-\theta)}\,.$$

L'information de Fisher d'un $n$-échantillon de Bernoulli vaut donc $\mathbb{I}(\theta) = n/(\theta(1-\theta))$. On note au passage que le calcul par la dérivée seconde est ici plus court que le calcul de la variance du score.

---

**Illustration / animation :** Le score est la pente de la log-vraisemblance en $\theta$, et sa dispersion sous $\mathbb{P}_\theta$ est l'information de Fisher

Vous pouvez y observer, sur quatre modèles au choix, la courbe de log-vraisemblance d'une observation tirée et sa tangente au point choisi, puis reconstituer par tirages répétés la distribution du score et comparer la courbure de la divergence de Kullback-Leibler à la parabole que dicte l'information de Fisher.

link

---

**Illustration / animation :** Le score et l'information de Fisher se retrouvent à partir de la seule log-densité, sur le modèle de votre choix

L'animation accessible par le QR code ci-contre reprend, pour un modèle choisi parmi Bernoulli, Poisson et exponentiel, le calcul de la log-densité, du score puis de l'information de Fisher par la dérivée seconde, et fait interpréter sa variation avant de dérouler la solution rédigée.

link

---

**Intuition.** *Pourquoi appelle-t-on cette quantité une* information *? Le raisonnement qui suit n'est pas une démonstration : il enchaîne des dérivations sous le signe intégral sans les justifier et suppose la divergence deux fois différentiable en son second argument, ce qui demanderait des hypothèses supplémentaires. Il éclaire cependant le nom. Supposons que la vraie valeur du paramètre soit $\theta^\star$, et écrivons* $\mathrm{KL}(\theta^\star, \theta) := \mathrm{KL}(\mathbb{P}_{\theta^\star}, \mathbb{P}_\theta)$. *La quantité* $\log\left(p_{\theta^\star}(Z)/p_\theta(Z)\right)$ *traduit le pouvoir discriminant du modèle pour trancher entre $\theta^\star$ et $\theta$ au vu de l'observation : elle est nulle si les deux lois coïncident, et vaut $+\infty$ si $\theta$ est exclu par l'observation. Sa valeur moyenne sous $\mathbb{P}_{\theta^\star}$ est la divergence de Kullback-Leibler* $\mathrm{KL}(\theta^\star, \theta)$, *introduite au chapitre 2 (Définition 1.7), qui est positive et ne s'annule qu'en $\theta = \theta^\star$ lorsque le modèle est identifiable.*

*La fonction $\theta \mapsto \mathrm{KL}(\theta^\star, \theta)$ atteint donc son minimum en $\theta^\star$, où son gradient est nul – c'est l'espérance nulle du score. Sa dérivée seconde en ce point vaut*

$$\nabla_\theta^2 \,\mathrm{KL}(\theta^\star, \theta)\big|_{\theta=\theta^\star} = -\mathbb{E}_{\theta^\star}\big[\,\mathrm{H}_\ell(\theta^\star, Z)\big] = \mathbb{I}(\theta^\star)\,.$$

*L'information de Fisher est ainsi la courbure de la divergence de Kullback-Leibler au voisinage de la vraie valeur : une grande information correspond à une divergence qui remonte vite dès qu'on s'écarte de $\theta^\star$, donc à des lois voisines faciles à distinguer, donc à un paramètre facile à estimer. La borne de Cramér-Rao, où l'information apparaît au dénominateur, confirme cette lecture.*

## 1.10 Estimateur régulier et théorème de Cramér-Rao

La régularité du modèle justifie la première des deux dérivations sous le signe intégral du calcul de la Section 1.7. La seconde, qui porte sur $\theta \mapsto \mathbb{E}_\theta[T(Z)]$, dépend de l'estimateur ; on la pose comme hypothèse.

**Définition 1.9: Estimateur régulier**

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle régulier, où $\Theta$ est un ouvert de $\mathbb{R}^d$. Un estimateur $T : (\mathsf{Z}, \mathcal{Z}) \to \mathbb{R}$ d'une fonction $g : \Theta \to \mathbb{R}$ est dit *régulier* si

(i) $T(Z)$ est de carré intégrable, c'est-à-dire $\mathbb{E}_\theta[\{T(Z)\}^2] < \infty$ pour tout $\theta \in \Theta$ ;

(ii) la fonction $\theta \mapsto \mathbb{E}_\theta[T(Z)]$ est différentiable sur $\Theta$ et, pour tout $\theta \in \Theta$,

$$\nabla_\theta\, \mathbb{E}_\theta[T(Z)] = \int_{\mathsf{Z}} T(z)\, \nabla_\theta p_\theta(z)\, \mu(\mathrm{d}z)\,. \tag{10}$$

**Remarque.** Par la Proposition 2.2 de dérivation sous le signe intégral, la seconde condition est assurée dès que la condition suivante est vérifiée : pour tout $\theta_0 \in \Theta$, il existe un voisinage $\mathcal{V}_0$ de $\theta_0$ dans $\Theta$ et une fonction mesurable positive $h$ telle que $\int_{\mathsf{Z}} |T(z)|\, h(z)\, \mu(\mathrm{d}z) < \infty$, et il existe $\mathsf{Z}_0 \in \mathcal{Z}$ avec $\mu(\mathsf{Z}_0^c) = 0$ tel que, pour tout $z \in \mathsf{Z}_0$, la fonction $\theta \mapsto p_\theta(z)$ soit différentiable sur $\Theta$ et vérifie $\|\nabla_\theta p_\theta(z)\| \le h(z)$ pour tout $\theta \in \mathcal{V}_0$. Comme pour la régularité du modèle, la vérification est fastidieuse et sans surprise ; on l'admettra dans les exercices.

**Théorème 1.1: Borne de Cramér-Rao**

Soient $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle régulier, où $\Theta$ est un ouvert de $\mathbb{R}^d$, $g : \Theta \to \mathbb{R}$ une fonction dérivable à valeurs réelles, et $T$ un estimateur *sans biais et régulier* de $g : \theta \mapsto g(\theta)$. Alors, pour tout $\theta \in \Theta$,

$$\mathrm{Var}_\theta(T(Z)) \ge \big(\nabla_\theta g(\theta)\big)^\top\, \mathbb{I}(\theta)^{-1}\, \nabla_\theta g(\theta)\,. \tag{11}$$

**Démonstration**

Comme $T$ est sans biais et régulier, il vient

$$\begin{aligned}\nabla_\theta g(\theta) = \nabla_\theta\, \mathbb{E}_\theta[T(Z)] &= \int_{\mathsf{Z}} T(z)\, \nabla_\theta p_\theta(z)\, \mu(\mathrm{d}z) \\ &= \int_{\mathsf{Z}} T(z)\, \nabla_\theta \ell(\theta, z)\, p_\theta(z)\, \mu(\mathrm{d}z) = \mathbb{E}_\theta\big[T(Z)\, \nabla_\theta \ell(\theta, Z)\big]\,,\end{aligned}$$

la troisième égalité par (8). Or le score est d'espérance nulle (Proposition 1.2 (i)), donc $\mathbb{E}_\theta[g(\theta) \nabla_\theta \ell(\theta, Z)] = 0$ et l'égalité précédente se réécrit

$$\nabla_\theta g(\theta) = \mathbb{E}_\theta\big[\{T(Z) - g(\theta)\}\, \nabla_\theta \ell(\theta, Z)\big]\,.$$

Soit $u \in \mathbb{R}^d$. En prenant le produit scalaire avec $u$ puis en appliquant l'inégalité de Cauchy-Schwarz (Proposition 2.1),

$$\begin{aligned}\left\{\nabla_\theta g(\theta)^\top u\right\}^2 &= \Big(\mathbb{E}_\theta\big[\{T(Z)-g(\theta)\}\,\nabla_\theta \ell(\theta,Z)^\top u\big]\Big)^2 \\ &\le \mathbb{E}_\theta\big[\{T(Z)-g(\theta)\}^2\big]\;\mathbb{E}_\theta\big[\{\nabla_\theta \ell(\theta,Z)^\top u\}^2\big]\;.\end{aligned}$$

Comme $T$ est sans biais, $\mathbb{E}_\theta[\{T(Z)-g(\theta)\}^2] = \mathrm{Var}_\theta(T(Z))$. Par ailleurs, pour tout $a \in \mathbb{R}^d$, $\{a^\top u\}^2 = u^\top a a^\top u = u^\top (aa^\top) u$ ; en appliquant cette identité à $a = \nabla_\theta g(\theta)$ et à $a = \nabla_\theta \ell(\theta, Z)$, l'inégalité précédente devient

$$u^\top \nabla_\theta g(\theta)\,\nabla_\theta g(\theta)^\top u \le \mathrm{Var}_\theta(T(Z)) \cdot u^\top \mathbb{I}(\theta) u\;, \qquad u \in \mathbb{R}^d\;.$$

En particulier, pour $u = \mathbb{I}(\theta)^{-1}\nabla_\theta g(\theta)$, licite puisque $\mathbb{I}(\theta)$ est inversible, on obtient

$$\big(\nabla_\theta g(\theta)^\top \mathbb{I}(\theta)^{-1} \nabla_\theta g(\theta)\big)^2 \le \mathrm{Var}_\theta(T(Z)) \cdot \big(\nabla_\theta g(\theta)^\top \mathbb{I}(\theta)^{-1} \nabla_\theta g(\theta)\big)\;.$$

Le facteur $\nabla_\theta g(\theta)^\top \mathbb{I}(\theta)^{-1} \nabla_\theta g(\theta)$ est positif, puisque $\mathbb{I}(\theta)^{-1}$ est définie positive. S'il est nul, l'inégalité (11) est triviale ; sinon, on simplifie par ce facteur strictement positif, ce qui donne (11). □



**Point d'histoire : Calyampudi Radhakrishna Rao (1920-2023)**

Rao a vingt-cinq ans et assure un cours de statistique à l'Indian Statistical Institute de Calcutta lorsqu'il publie, en 1945 au *Bulletin of the Calcutta Mathematical Society*, l'inégalité démontrée ci-dessus. Le même article contient le théorème de Rao-Blackwell, qui améliore un estimateur en le conditionnant par une statistique exhaustive. Harald Cramér publie indépendamment le même résultat l'année suivante : d'où le nom sous lequel la borne est connue.

Portrait : Prateek Karandikar, Wikimedia Commons, CC BY-SA 4.0.

Le théorème prend trois formes selon la quantité estimée et la dimension du paramètre. La première est le cas unidimensionnel, qui reprend le calcul de la Section 1.7.

**Corollaire 1.1: Cas unidimensionnel**

Si $\Theta$ est un ouvert de $\mathbb{R}$, sous les hypothèses du Théorème 1.1, on a pour tout $\theta \in \Theta$

$$\mathrm{Var}_\theta(T(Z)) \ge \frac{\{g'(\theta)\}^2}{\mathbb{I}(\theta)}\;, \qquad \text{où} \qquad \mathbb{I}(\theta) = \mathrm{Var}_\theta\left(\frac{\partial}{\partial\theta}\ell(\theta,Z)\right).$$

La deuxième forme concerne l'estimation du paramètre lui-même, lorsqu'il est vectoriel ; l'inégalité est alors une inégalité entre matrices symétriques, au sens rappelé dans les outils (Section 2).

**Corollaire 1.2: Estimation d'un paramètre vectoriel**

Soient $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle régulier, où $\Theta$ est un ouvert de $\mathbb{R}^d$, et $T(Z)$ un estimateur sans biais et régulier de $\theta$, au sens où chaque coordonnée $\lambda^\top T(Z)$, $\lambda \in \mathbb{R}^d$, est un estimateur sans biais et régulier de $\lambda^\top\theta$. Alors, pour tout $\theta \in \Theta$,

$$\mathrm{Var}_\theta(T(Z)) \ge \mathbb{I}(\theta)^{-1}\;,$$

c'est-à-dire que la matrice symétrique $\mathrm{Var}_\theta(T(Z)) - \mathbb{I}(\theta)^{-1}$ est positive.

**Démonstration**

Soit $\lambda \in \mathbb{R}^d$ et considérons la fonction $g : \theta \mapsto \lambda^\top \theta$, dérivable, de gradient $\nabla_\theta g(\theta) = \lambda$. Par hypothèse, $\lambda^\top T(Z)$ est un estimateur sans biais et régulier de $g(\theta)$. Le Théorème 1.1 donne alors, en notant que $\mathrm{Var}_\theta(\lambda^\top T(Z)) = \lambda^\top \mathrm{Var}_\theta(T(Z))\lambda$,

$$\lambda^\top \mathrm{Var}_\theta(T(Z))\lambda \geq \lambda^\top \mathbb{I}(\theta)^{-1}\lambda \, .$$

Cette inégalité valant pour tout $\lambda \in \mathbb{R}^d$, la matrice $\mathrm{Var}_\theta(T(Z)) - \mathbb{I}(\theta)^{-1}$ est positive. □

La troisième forme est celle sous laquelle la borne s'emploie en pratique, pour un $n$-échantillon ; elle combine le théorème et l'additivité de l'information de Fisher.

**Corollaire 1.3: Borne de Cramér-Rao pour un $n$-échantillon**

Soient $(X_1, \ldots, X_n)$ un $n$-échantillon du modèle régulier $(\mathsf{X}, \mathcal{X}, \{q_\theta \cdot \mu \, , \, \theta \in \Theta\})$ et $T_n(X_1, \ldots, X_n)$ un estimateur sans biais et régulier de $g : \Theta \to \mathbb{R}$. En notant

$$\mathbb{I}_1(\theta) := \mathbb{E}_\theta\left[\nabla_\theta \ell_1(\theta, X_1)\, \nabla_\theta \ell_1(\theta, X_1)^\top\right] , \qquad \ell_1(\theta, x) := \log q_\theta(x) \, ,$$

l'information de Fisher associée à une seule observation, on a pour tout $\theta \in \Theta$

$$\mathrm{Var}_\theta\left(T_n(X_1, \ldots, X_n)\right) \geq \frac{1}{n}\, \nabla_\theta g(\theta)^\top\, \mathbb{I}_1(\theta)^{-1}\, \nabla_\theta g(\theta) \, .$$

**Intuition.** *On dispose donc de trois bornes de Cramér-Rao, qui sont trois lectures du même énoncé : la borne scalaire pour une fonction réelle d'un paramètre réel, la borne matricielle pour l'estimation d'un paramètre vectoriel, et la borne en $1/n$ pour un $n$-échantillon. La dernière porte le message le plus directement utilisable : dans un modèle régulier, la variance d'un estimateur sans biais, donc aussi son risque quadratique, est au moins d'ordre $n^{-1}$. Aucun raffinement de la construction ne fera mieux que cette vitesse.*

**Exemple 1.16: Vitesse d'estimation et modèles non réguliers**

La variance de la moyenne empirique $\bar{X}_n$, estimateur sans biais de l'espérance, est d'ordre $n^{-1}$, tout comme celle de $S_n^2$, estimateur sans biais de la variance dans le modèle gaussien (Exemple 1.8). Ces vitesses sont compatibles avec la borne de Cramér-Rao, d'ordre $n^{-1}$, ce qui montre que la dépendance en $n$ de la borne ne peut pas être améliorée.
En revanche, dans le modèle uniforme de l'Exemple 1.9, l'estimateur sans biais $T_n^{(1)} = \frac{n+1}{n} X_{n:n}$ a pour variance $\theta^2/\{n(n+2)\}$, qui décroît en $n^{-2}$ : la borne de Cramér-Rao, si elle s'appliquait, serait violée. Il n'y a pourtant aucune contradiction, puisque le modèle uniforme n'est pas régulier (Exemple 1.12). L'Exercice 3 (PC3) construit une borne inférieure valable, elle, sans hypothèse de régularité, et retrouve la vitesse $n^{-2}$ pour ce modèle.

## 1.11 Efficacité

La borne de Cramér-Rao est une inégalité ; il reste à savoir si elle est atteinte, c'est-à-dire si la constante qu'elle donne est la bonne. Les exemples ci-dessous montrent que oui, dans plusieurs modèles usuels.

**Définition 1.10: Efficacité**

Soient $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu \, , \, \theta \in \Theta\})$ un modèle régulier et $g : \Theta \to \mathbb{R}$ une fonction dérivable. Un estimateur sans biais et régulier $T$ de $g(\theta)$ est dit *efficace* si sa variance atteint la borne de

Cramér-Rao, c'est-à-dire si

$$\mathrm{Var}_\theta(T(Z)) = \big(\nabla_\theta g(\theta)\big)^\top \mathbb{I}(\theta)^{-1} \nabla_\theta g(\theta) \qquad \text{pour tout } \theta \in \Theta\ .$$

Un estimateur efficace est un estimateur sans biais de variance minimale, au sens de la Définition 1.5 : sa variance minore, par le théorème, celle de tout autre estimateur sans biais régulier. La réciproque est fausse en général – un estimateur peut être de variance minimale sans atteindre la borne.

**Exemple 1.17: Fréquence empirique dans le modèle de Bernoulli**

Pour un $n$-échantillon du modèle de Bernoulli sur $\Theta = ]0,1[$, l'information de Fisher vaut $\mathbb{I}(\theta) = n/(\theta(1-\theta))$ (Exemple 1.15), de sorte que la borne de Cramér-Rao pour l'estimation sans biais de $\theta$ vaut $\theta(1-\theta)/n$. Elle est atteinte par la fréquence empirique, puisque

$$\mathrm{Var}_\theta(\bar{X}_n) = \frac{\mathrm{Var}_\theta(X_1)}{n} = \frac{\theta(1-\theta)}{n}\ .$$

La fréquence empirique est donc efficace, et par conséquent E.S.B.V.M..

**Exemple 1.18: Le maximum de vraisemblance du modèle de Poisson est efficace**

Considérons le modèle $\mathcal{M}^n = \big\{\mathcal{P}\mathrm{oi}(\theta)^{\otimes n}\ ,\ \theta \in \Theta := \mathbb{R}_+^*\big\}$.

1. L'information de Fisher pour une observation vaut $\mathbb{I}(\mathcal{M},\theta) = 1/\theta$ (Exemple 1.14).
2. Par additivité, $\mathbb{I}(\mathcal{M}^n,\theta) = n/\theta$.
3. L'estimateur du maximum de vraisemblance est $\hat{\theta}_n = \bar{X}_n$ (chapitre 2).
4. Il est sans biais, puisque $\mathbb{E}_\theta[\bar{X}_n] = \theta$.
5. Sa variance vaut $\mathrm{Var}_\theta(\hat{\theta}_n) = \theta/n = 1/\mathbb{I}(\mathcal{M}^n,\theta)$.

L'estimateur du maximum de vraisemblance est donc efficace dans ce modèle.

**Exemple 1.19: Moyenne empirique dans le modèle gaussien**

Soit $(X_1,\dots,X_n)$ un $n$-échantillon du modèle $\big(\mathbb{R},\mathcal{B}(\mathbb{R}),\big\{\mathcal{N}(\theta,\sigma_0^2)\ ,\ \theta\in\mathbb{R}\big\}\big)$, où $\sigma_0^2 > 0$ est connue. On a

$$\ell_1(\theta,x) = -\frac{(x-\theta)^2}{2\sigma_0^2} - \log\sqrt{2\pi\sigma_0^2}\ , \qquad \partial_\theta \ell_1(\theta,x) = \frac{x-\theta}{\sigma_0^2}\ , \qquad \partial_\theta^2 \ell_1(\theta,x) = -\frac{1}{\sigma_0^2}\ ,$$

donc $\mathbb{I}_1(\theta) = 1/\sigma_0^2$ et $\mathbb{I}(\theta) = n/\sigma_0^2$ pour l'échantillon. L'estimateur sans biais $\bar{X}_n$ a pour variance $\sigma_0^2/n = \mathbb{I}(\theta)^{-1}$ : il atteint la borne de Cramér-Rao et il est efficace.

L'existence d'un estimateur efficace n'est cependant pas garantie : elle caractérise une famille particulière de modèles, les familles exponentielles, comme le montrent les compléments (Section 4). Le cours reviendra sur cette question au chapitre consacré au comportement asymptotique des estimateurs, où l'on verra que l'estimateur du maximum de vraisemblance est *asymptotiquement* efficace sous des hypothèses générales, c'est-à-dire que sa variance approche la borne de Cramér-Rao lorsque la taille de l'échantillon grandit, même lorsqu'aucun estimateur ne l'atteint à $n$ fixé.

## 1.12 En pratique : programme des exercices

Les notions de ce chapitre sont mises en œuvre dans la feuille d'exercices (PC 3), intégrée au chapitre (Section 3). Exercices traités en petite classe :

| Exercice | Notions du cours | Rappels |
|---|---|---|
| Exo 1 – *Modèle uniforme* | biais, risque quadratique, admissibilité | Statistiques d'ordre, loi de $X_{n:n}$ |
| Exo 2 – *Régression linéaire gaussienne* | information de Fisher matricielle, efficacité | Vecteurs gaussiens, th. de Cochran |
| Exo 3 – *Cramér-Rao sans régularité* | borne de type covariance | Inégalité de Cauchy-Schwarz, passage à la limite |

L'Exercice 1 (PC3) reprend et prolonge l'Exemple 1.9 : on y montre qu'aucun estimateur sans biais de la forme $n^{-1}\sum_i T(X_i)$ n'existe, on construit un estimateur sans biais fonction de $X_{n:n}$, puis on compare les risques quadratiques de toute la famille $aX_{n:n}$ et l'on conclut à l'inadmissibilité de plusieurs d'entre eux. L'Exercice 2 (PC3) poursuit l'Exercice 1 (PC2) sur le modèle de régression linéaire gaussienne : c'est le seul endroit du cours où l'information de Fisher est une matrice $2\times 2$, et l'on y calcule la borne de Cramér-Rao pour l'estimation d'un coefficient, puis du produit des deux. L'Exercice 3 (PC3) établit, pour toute statistique $\Psi$ de carré intégrable, la borne $\mathrm{Var}_\theta(T) \geq \mathrm{Cov}_\theta(T,\Psi)^2/\mathrm{Var}_\theta(\Psi)$, dont la borne de Cramér-Rao est un cas limite, et qui s'applique à des modèles non réguliers comme le modèle uniforme.

Les exercices bonus portent sur les estimateurs linéaires dans un modèle de translation (Exercice 4 (PC3)), qui généralise l'Exemple 1.11 en levant la contrainte d'absence de biais, et sur les statistiques d'ordre d'un échantillon exponentiel (Exercice 5 (PC3)).

**Notions de probabilités clés utilisées cette semaine, à revoir** : espérance, variance et covariance, inégalité de Cauchy-Schwarz, dérivation sous le signe intégral, matrices symétriques positives, statistiques d'ordre, vecteurs gaussiens et loi du $\chi^2$ (voir la partie *Outils mathématiques* ci-dessous).