3 Les exercices

Par convention, les vecteurs sont des vecteurs colonne, et pour un vecteur a, $a^\top$ désigne sa transposée. Lorsqu'un modèle statistique n'est que dominé par une mesure σ-finie μ, les intégrales s'écrivent par rapport à $\mu(\mathrm{d}z)$; lorsque $\mu = \mathrm{Leb}$ ou $\mu = \mathrm{Leb}^{\otimes n}$, cela est précisé.

3.1 Questions courtes : avez-vous assimilé le chapitre ?

Avant d'aborder les exercices, vérifiez votre compréhension du chapitre en répondant – de tête, sans revenir au texte – aux questions suivantes. En cas d'hésitation, la référence entre parenthèses renvoie au passage concerné.

1. Rappeler la définition du biais d'un estimateur. Un estimateur sans biais peut-il avoir un risque quadratique plus grand qu'un estimateur biaisé de la même quantité ? (Définition 1.1, Proposition 1.1)
2. *Vrai ou faux :* le risque d'un estimateur, pour une perte donnée, est un nombre réel. (Définition 1.2, Définition 1.3)
3. Qu'est-ce qu'un estimateur admissible ? Un estimateur admissible est-il nécessairement un bon estimateur ? (Définition 1.4, Exemple 1.10)
4. Le modèle uniforme sur $[0, \theta]$ est-il régulier ? Citer un modèle qui l'est. (Définition 1.6, Exemple 1.12)
5. Définir le score d'un modèle régulier. Quelle est son espérance sous $\mathbb{P}_\theta$, et en quoi cette propriété sert-elle à démontrer la borne de Cramér-Rao ? (Définition 1.7, Proposition 1.2)
6. L'information de Fisher est-elle une caractéristique du seul paramètre, ou du modèle tout entier ? Comment se comporte-t-elle pour un n-échantillon ? (Définition 1.8, Proposition 1.2 (iii))
7. Énoncer la borne de Cramér-Rao pour l'estimation d'un paramètre scalaire. Quelles hypothèses portent sur le modèle, et lesquelles portent sur l'estimateur ? (Théorème 1.1, Définition 1.6, Définition 1.9)
8. Qu'est-ce qu'un estimateur efficace ? Un estimateur sans biais de variance minimale est-il nécessairement efficace ? (Définition 1.10)
9. *Vrai ou faux :* dans le modèle uniforme sur $[0, \theta]$, il existe un estimateur sans biais de θ dont la variance décroît en n^{-2}, ce qui contredit la borne de Cramér-Rao. (Exemple 1.16)

3.2 Groupe 1 — Exercices traités en petite classe

Les trois exercices de ce groupe mettent en œuvre les deux notions du chapitre : la comparaison de règles de décision par le risque et l'admissibilité, puis la borne de Cramér-Rao, régulière et étendue au cas non régulier (Section 1.12).

Objectif : modèle uniforme, biais, risque quadratique et admissibilité

Cet exercice reprend et prolonge l'Exemple 1.9 du chapitre : on y montre qu'aucun estimateur sans biais de la forme $n^{-1}\sum_i T(X_i)$ n'existe pour une fonction g générale, on construit un estimateur sans biais fonction de $X_{n:n}$, puis on compare les risques quadratiques de toute la famille $aX_{n:n}$ et l'on conclut à l'inadmissibilité de plusieurs d'entre eux.

Exercice 1 (Modèle uniforme (⋆⋆)). Soit $Z = (X_1, \dots, X_n)$ un n-échantillon du modèle statistique

$$\big(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{U}([0,\theta])\,,\ \theta \in \Theta := \mathbb{R}_+^*\}\big)\ .$$

1. Calculer l'estimateur du maximum de vraisemblance de θ.

Soit $g : \mathbb{R}_+^* \to \mathbb{R}$ une fonction différentiable vérifiant $\lim_{\theta\to 0^+} \theta\, g(\theta) = 0$.

2. Peut-on choisir $T : \mathbb{R}_+ \to \mathbb{R}$ de telle sorte que $\hat{\theta}_n^{(1)} := n^{-1} \sum_{i=1}^n T(X_i)$ soit un estimateur sans biais de $g : \theta \mapsto g(\theta)$?
3. On pose $X_{n:n} := \max(X_1, \dots, X_n)$. Montrer que l'on peut choisir $\widetilde{T} : \mathbb{R}_+ \to \mathbb{R}$ de telle sorte que $\hat{\theta}_n^{(2)} := \widetilde{T}(X_{n:n})$ soit un estimateur sans biais de $g : \theta \mapsto g(\theta)$.

Dans la suite de l'exercice, on pose $g(\theta) = \theta$.

4. Comparer le risque quadratique des deux estimateurs $\hat{\theta}_n^{(1)}$ et $\hat{\theta}_n^{(2)}$. Montrer que l'estimateur $\hat{\theta}_n^{(1)}$ est inadmissible pour $n > 1$. *Voir la figure 1.*
5. Pour $a > 0$, calculer le risque quadratique de l'estimateur $\hat{\theta}_{n,a}^{(3)} := aX_{n:n}$. Montrer que l'estimateur $\hat{\theta}_n^{(2)}$ est inadmissible. *Voir la figure 1.*

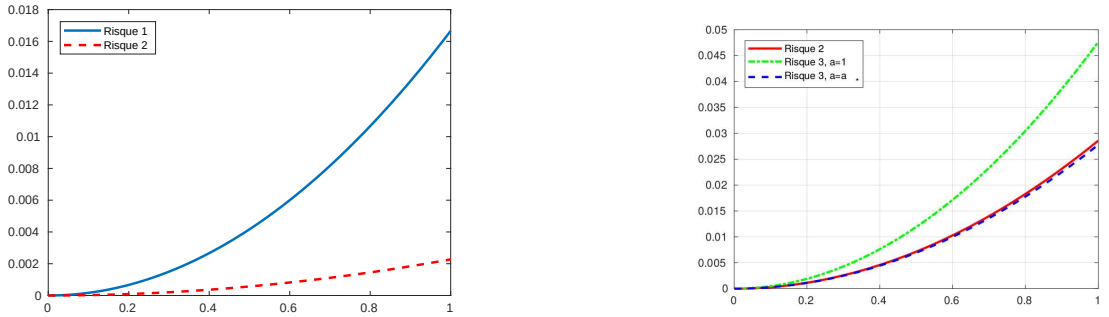


FIGURE 1 – [gauche] Évolution de $\theta \mapsto \mathbb{E}_\theta\left[(\hat{\theta}_n^{(i)} - \theta)^2\right]$ dans le cas $n = 20$. [droite] $\theta \mapsto \mathbb{E}_\theta\left[(\hat{\theta}_n^{(i)} - \theta)^2\right]$ pour $i = 2, 3$ dans le cas $n = 5$; pour $\hat{\theta}_{n,a}^{(3)}$, on a envisagé $a = 1$ et $a = a_\star$.

Corrigé : page 38. ♢

Objectif : information de Fisher matricielle et efficacité, modèle de régression

Cet exercice poursuit l'Exercice 1 (PC2), où le modèle de régression linéaire gaussienne a été construit et où la matrice $\mathbf{X}^\top \mathbf{X}$ a été inversée explicitement : c'est le seul endroit du cours où l'information de Fisher est une matrice 2×2, et l'on y calcule la borne de Cramér-Rao pour l'estimation d'un coefficient, puis du produit des deux, en réutilisant ce calcul plutôt qu'en le refaisant.

Exercice 2 (Régression linéaire gaussienne (⋆⋆)). Soient $x_1, \dots, x_n$ des réels tels que $x_i \neq x_j$ pour au moins deux indices $i \neq j$. On considère le modèle statistique

$$\left(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \left\{ \bigotimes_{i=1}^n \mathcal{N}(\beta_1 + \beta_2 x_i, \sigma^2)\,,\ (\beta_1, \beta_2) \in \mathbb{R}^2 \right\}\right),$$

où $\sigma^2 > 0$ est connu. On reprend les notations matricielles de l'Exercice 1 (PC2) : $\mathbf{Y} := (Y_1, \dots, Y_n)^\top$, $\mathbf{X} := [\mathbf{1}\ \ \underline{\mathbf{x}}]$ avec $\mathbf{1} := (1, \dots, 1)^\top$ et $\underline{\mathbf{x}} := (x_1, \dots, x_n)^\top$, et $\beta := (\beta_1, \beta_2)^\top$.

1. Déterminer la matrice d'information de Fisher $\mathbb{I}(\beta_1, \beta_2)$.
2. Déterminer une borne inférieure sur la variance d'un estimateur (régulier) sans biais de β_1.
3. On suppose que β_2 est connu. Donner une borne inférieure sur la variance d'un estimateur (régulier) sans biais de β_1.
4. Déterminer une borne inférieure sur la variance d'un estimateur (régulier) sans biais de $\beta_1 \beta_2$.

Corrigé : page 39. ♢

Objectif : extension de la borne de Cramér-Rao au cas non régulier

Cet exercice établit, pour toute statistique Ψ de carré intégrable, une borne inférieure sur la variance d'un estimateur sans biais qui ne demande aucune hypothèse de régularité au modèle, dont la borne de Cramér-Rao se déduit comme cas limite ; il l'applique ensuite au modèle uniforme, qui échappe à Cramér-Rao (Exemple 1.16) mais pas à cette borne plus générale.

Exercice 3 (Cramér-Rao sans régularité (⋆⋆⋆)). Soit $\Theta \subset \mathbb{R}$ et $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle statistique dominé. Soit T un estimateur sans biais de $g : \Theta \to \mathbb{R}$ tel que, pour tout $\theta \in \Theta$, $\mathbb{E}_\theta[T^2(Z)] < \infty$.

1. Montrer que pour toute fonction $\Psi : \mathsf{Z} \to \mathbb{R}$ mesurable telle que $0 < \mathrm{Var}_\theta(\Psi(Z)) < \infty$, on a

$$\mathrm{Var}_\theta(T(Z)) \geq \frac{\left\{\mathrm{Cov}_\theta(T(Z), \Psi(Z))\right\}^2}{\mathrm{Var}_\theta(\Psi(Z))}\ .$$

Dans la suite, on fixe θ, δ tels que $\theta \in \Theta$ et $\theta - \delta \in \Theta$. On suppose que

$$\{z \in \mathsf{Z} : p_\theta(z) = 0\} \subseteq \{z \in \mathsf{Z} : p_{\theta-\delta}(z) = 0\}\ .$$

2. On considère la fonction Ψ donnée par

$$\Psi(z) := \begin{cases} \dfrac{p_{\theta-\delta}(z)}{p_\theta(z)} - 1 & \text{si } p_\theta(z) > 0\ , \\ 0 & \text{sinon}\ . \end{cases}$$

   Montrer que $\mathbb{E}_\theta[\Psi(Z)] = 0$ et que $\mathrm{Cov}_\theta(T(Z), \Psi(Z)) = g(\theta - \delta) - g(\theta)$.

3. En déduire une borne sur les estimateurs sans biais de $g : \theta \mapsto g(\theta)$.

4. Proposer des conditions sous lesquelles la borne de Cramér-Rao (Théorème 1.1) se déduit de cette inégalité par passage à la limite $\delta \to 0$.

On suppose maintenant que $Z = (X_1, \ldots, X_n)$ est un n-échantillon du modèle

$$\left(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{U}([0,\theta])\,,\ \theta \in \Theta := \mathbb{R}_+^*\}\right)\ .$$

Observer que ce modèle n'est pas régulier (Exemple 1.12). On considère la fonction $g(\theta) = \theta$.

5. Montrer que pour tout $\delta \in]0, \theta[$, on a pour tout estimateur sans biais T de θ

$$\mathrm{Var}_\theta(T(Z)) \geq \frac{\delta^2}{\theta^n/(\theta-\delta)^n - 1}\ .$$

6. Soit $0 < c \leq n$. En posant $\delta = c\theta/n$, montrer que la borne inférieure peut s'écrire $\theta^2\,\tau_n(c)/n^2$ pour une quantité $\tau_n(c)$ telle que $\lim_{n\to\infty} \tau_n(c)$ existe. Conclure. *Voir la figure 2.*

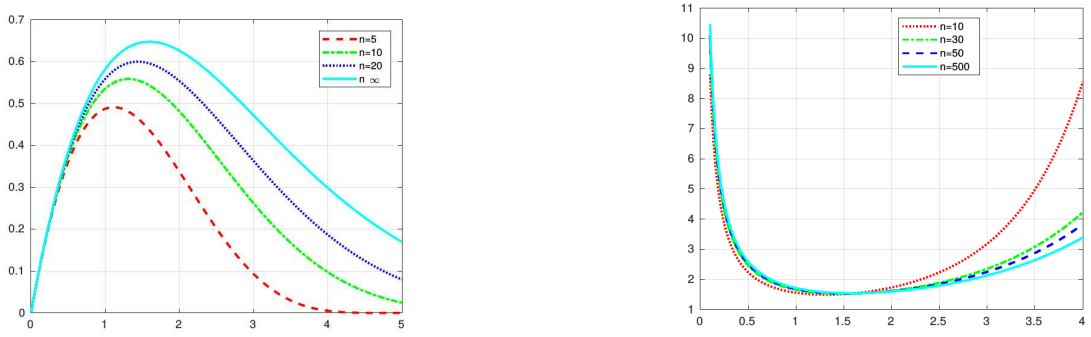


FIGURE 2 – [gauche] Tracé de $c \mapsto \tau_n(c)$ pour différentes valeurs de n, et de $c \mapsto \lim_n \tau_n(c)$. [droite] Tracé de $c \mapsto n/\{(n+2)\tau_n(c)\}$, ratio de l'erreur quadratique moyenne de $\hat{\theta}_n^{(2)}$ (Exercice 1) et du minorant de l'erreur quadratique moyenne des estimateurs sans biais.

Corrigé : page 40. ♢

3.3 Groupe 2 — Exercices bonus

Guide de lecture. Les deux exercices qui suivent ne sont pas traités en petite classe. L'exercice **Estimateurs linéaires** ($\star$) reprend le modèle de translation de l'Exemple 1.1 et généralise le meilleur estimateur linéaire sans biais de l'espérance (Exemple 1.11) en levant la contrainte d'absence de biais : c'est le prolongement naturel de cet exemple, et il ne demande rien de plus que les notions de biais, de risque quadratique et un calcul d'optimisation sous contrainte (multiplicateurs de Lagrange, ou directement l'inégalité de Cauchy-Schwarz). L'exercice **Statistiques d'ordre exponentielles** ($\star\star\star$) est plus technique : il calcule la loi jointe des statistiques d'ordre d'un échantillon exponentiel par un changement de variables explicite, puis en déduit, par la même méthode qu'à l'exercice précédent, l'estimateur linéaire optimal du paramètre. Vous pouvez l'aborder après l'exercice sur les estimateurs linéaires, dont il reprend la démarche dans un cadre plus général.

Objectif : estimateurs linéaires dans un modèle de translation

Exercice 4 (Estimateurs linéaires ($\star$)). Soit p une densité sur $\mathbb{R}$ par rapport à la mesure de Lebesgue vérifiant

$$\int x\, p(x)\, \mathrm{d}x = 0 \,, \qquad \int x^2\, p(x)\, \mathrm{d}x = 1 \,.$$

Soit $(X_1, \dots, X_n)$ un n-échantillon du modèle statistique

$$\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot \mathrm{Leb}\,,\ \theta \in \mathbb{R}\}\big) \,,$$

où p_θ est un modèle de translation

$$x \mapsto p_\theta(x) := \frac{1}{\sigma}\, p\Big(\frac{x-\theta}{\sigma}\Big) \,;$$

le facteur d'échelle $\sigma > 0$ est supposé connu. Pour tout $\underline{a}_n = (a_{1,n}, \dots, a_{n,n}) \in \mathbb{R}^n$, on considère la classe des *estimateurs linéaires*, c'est-à-dire des combinaisons linéaires des observations,

$$\hat{\theta}_n(\underline{a}_n) := \sum_{i=1}^n a_{i,n} X_i \,.$$

1. Déterminer l'estimateur de θ de risque quadratique minimal dans la classe des estimateurs $\{\hat{\theta}_n(\underline{a}_n), \underline{a}_n \in \mathbb{R}^n\}$ et sans biais.
2. Calculer une borne inférieure du risque quadratique dans la classe des estimateurs linéaires $\{\hat{\theta}_n(\underline{a}_n), \underline{a}_n \in \mathbb{R}^n\}$, sans contrainte d'absence de biais.

Corrigé : page 41. ♢

Objectif : statistiques d'ordre d'un échantillon exponentiel

Exercice 5 (Statistiques d'ordre exponentielles ($\star\star\star$)). Soit la densité exponentielle de paramètre $\theta > 0$:

$$x \mapsto p_\theta(x) := \theta^{-1} \mathrm{e}^{-x/\theta}\, \mathbb{1}_{\mathbb{R}_+}(x) \,, \qquad \theta \in \Theta := \mathbb{R}_+^* \,.$$

Soit $(X_1, \dots, X_n)$ un n-échantillon du modèle statistique $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot \mathrm{Leb}\,,\ \theta \in \Theta\}\big)$. On note $X_{1:n} \leq X_{2:n} \leq \cdots \leq X_{n:n}$ les statistiques d'ordre de l'échantillon, et

$$p_\theta(y_1, \dots, y_n) := \prod_{k=1}^n p_\theta(y_k) \,.$$

1. Montrer que sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$, la loi jointe des statistiques d'ordre $X_{1:n}, \dots, X_{n:n}$ admet une densité par rapport à $\mathrm{Leb}^{\otimes n}$, donnée par

$$(y_1, \dots, y_n) \mapsto f_{1:n}(\theta; y_1, \dots, y_n) := n!\, p_\theta(y_1, \dots, y_n)\, \mathbb{1}_{\{0 \leq y_1 < y_2 < \cdots < y_n\}} \,.$$

On considère la transformation

$$Z_1 := nX_{1:n} \ , \qquad Z_k := (n-k+1)(X_{k:n} - X_{(k-1):n}) \ , \quad k \geq 2 \ , \tag{14}$$

ou, de façon équivalente, $X_{k:n} = \sum_{j=1}^{k} Z_j/(n-j+1)$ pour tout $k \geq 1$. On remarquera que le jacobien de la transformation (14) vaut $n!$, et que pour tout $x_1, \ldots, x_n \in \mathbb{R}$, en posant $x_0 := 0$,

$$\sum_{i=1}^{n} x_i = \sum_{i=1}^{n} (n-i+1)(x_i - x_{i-1}) \ .$$

2. Montrer que sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$, les variables $(Z_1, \ldots, Z_n)$ sont i.i.d. de loi exponentielle de paramètre θ.

Pour tout $\underline{a}_n = (a_{1,n}, \ldots, a_{n,n}) \in \mathbb{R}^n$, on considère l'estimateur

$$\hat{\theta}_n(\underline{a}_n) := \sum_{i=1}^{n} a_{i,n} X_{i:n} \ .$$

3. Montrer que

$$\hat{\theta}_n(\underline{a}_n) = \sum_{j=1}^{n} Z_j \, m_{j,n} \ , \qquad \text{où} \quad m_{j,n} := \frac{1}{n-j+1} \sum_{i=j}^{n} a_{i,n} \ .$$

4. Calculer le biais et le risque quadratique de l'estimateur.
5. Déterminer les poids $\underline{a}_n$ de l'estimateur sans biais de risque quadratique minimal dans la classe des estimateurs $\{\hat{\theta}_n(\underline{a}_n), \underline{a}_n \in \mathbb{R}^n\}$. *Indication : on déterminera d'abord les poids $m_{j,n}$, puis les poids $a_{j,n}$.*
6. Déterminer les poids $\underline{a}_n$ pour lesquels le risque quadratique est minimal dans la classe des estimateurs $\{\hat{\theta}_n(\underline{a}_n), \underline{a}_n \in \mathbb{R}^n\}$, sans contrainte d'absence de biais.

Corrigé : page 42. ♢

3.4 Corrigés des exercices

Les corrigés ci-dessous reprennent, en les complétant et en corrigeant les points signalés en tête de fichier, ceux distribués avec la feuille de petite classe de 2023. Les résultats du chapitre (inégalité de Cauchy-Schwarz, dérivation sous le signe intégral, définition du modèle régulier) sont appelés par un renvoi et ne sont pas redémontrés.

Corrigé de l'exercice 1 – Modèle uniforme

1. La vraisemblance s'écrit $\mathrm{L}_n(\vartheta) = \vartheta^{-n} \prod_{i=1}^n \mathbb{1}_{[0,\vartheta]}(X_i) = \vartheta^{-n} \mathbb{1}_{X_{n:n} \le \vartheta}$, une fonction de ϑ nulle sur $[0, X_{n:n}[$, strictement décroissante sur $[X_{n:n}, +\infty[$ et continue à gauche en $X_{n:n}$: son maximum est atteint en $\vartheta = X_{n:n}$ seulement, et $\hat\theta_n^{\mathrm{MV}} := X_{n:n}$.
2. On cherche T tel que $\mathbb{E}_\theta[T(X_1)] = g(\theta)$ pour tout $\theta > 0$, c'est-à-dire $\theta^{-1} \int_0^\theta T(x)\,\mathrm{d}x = g(\theta)$. La fonction $\theta \mapsto \theta\, g(\theta)$ doit donc être une primitive de T s'annulant en 0 (ce qui est licite puisque $\lim_{\theta\to 0^+} \theta\, g(\theta) = 0$), d'où
$$T(x) = \big(x\, g(x)\big)' = g(x) + x\, g'(x)\ ,$$
et l'on vérifie que ce choix donne bien $\mathbb{E}_\theta[\hat\theta_n^{(1)}] = g(\theta)$ pour tout $\theta > 0$.
3. Pour $x \in [0,\theta]$, par indépendance et même loi, $\mathbb{P}_\theta(X_{n:n} \le x) = \mathbb{P}_\theta(X_1 \le x, \dots, X_n \le x) = (x/\theta)^n$: $X_{n:n}$ admet la densité $x \mapsto \mathbb{1}_{[0,\theta]}(x)\, n x^{n-1}/\theta^n$. On veut $\mathbb{E}_\theta[\widetilde T(X_{n:n})] = g(\theta)$, soit $n\theta^{-n} \int_0^\theta \widetilde T(x)\, x^{n-1}\,\mathrm{d}x = g(\theta)$; la fonction $\theta \mapsto \theta^n g(\theta)/n$ doit donc être une primitive de $x \mapsto \widetilde T(x)\, x^{n-1}$ s'annulant en 0, d'où
$$\widetilde T(x) = \frac{1}{x^{n-1}} \Big(\frac{x^n g(x)}{n} \Big)' = g(x) + \frac{x}{n}\, g'(x)\ ,$$
et l'on vérifie de même que $\mathbb{E}_\theta[\hat\theta_n^{(2)}] = g(\theta)$ pour tout $\theta > 0$.
4. Le risque quadratique d'un estimateur $T(Z)$ de θ est $R(\theta, T) := \mathbb{E}_\theta[(T(Z) - \theta)^2]$. En injectant $g(x) = x$ dans l'expression de T obtenue à la question 2, $T(x) = 2x$, d'où
$$\hat\theta_n^{(1)} = \frac{2}{n} \sum_{k=1}^n X_k\ .$$
Sous $\mathbb{P}_\theta$, les X_i sont i.i.d. d'espérance $\theta/2$ et $\mathbb{E}_\theta[X_1^2] = \theta^{-1} \int_0^\theta x^2\,\mathrm{d}x = \theta^2/3$, donc $\mathrm{Var}_\theta(X_1) = \theta^2/3 - \theta^2/4 = \theta^2/12$ et
$$R(\theta, \hat\theta_n^{(1)}) = n^{-1}\, \mathrm{Var}_\theta(2X_1) = \frac{4}{n} \cdot \frac{\theta^2}{12} = \frac{\theta^2}{3n}\ .$$
En injectant $g(x) = x$ dans l'expression de $\widetilde T$ obtenue à la question 3, $\widetilde T(x) = (1+1/n)x$, d'où
$$\hat\theta_n^{(2)} = \frac{n+1}{n}\, X_{n:n}\ ,$$
qui est le même estimateur que $T_n^{(1)}$ de l'Exemple 1.9 du chapitre. Son risque quadratique, déjà calculé à cet exemple, vaut
$$R(\theta, \hat\theta_n^{(2)}) = \frac{\theta^2}{n(n+2)}\ .$$
Comme $n(n+2) > 3n$ dès que $n > 1$,
$$R(\theta, \hat\theta_n^{(2)}) = \frac{\theta^2}{n(n+2)} < \frac{\theta^2}{3n} = R(\theta, \hat\theta_n^{(1)})\ , \qquad \text{pour tout } \theta > 0\ ,$$
ce qui montre l'inadmissibilité de $\hat\theta_n^{(1)}$ dès que $n > 1$ (Définition 1.4).

5. Comme à l'Exemple 1.9, $\mathbb{E}_\theta[X_{n:n}] = n\theta/(n+1)$ et $\mathbb{E}_\theta[X_{n:n}^2] = n\theta^2/(n+2)$, d'où pour tout $a \in \mathbb{R}$

$$R(\theta, \hat\theta^{(3)}_{n,a}) = a^2\,\mathbb{E}_\theta[X_{n:n}^2] - 2a\theta\,\mathbb{E}_\theta[X_{n:n}] + \theta^2 = \Big\{\frac{na^2}{n+2} - \frac{2an}{n+1} + 1\Big\}\,\theta^2 \,.$$

L'accolade est un trinôme en a, de coefficient dominant $n/(n+2) > 0$, minimal en $a_\star := (n+2)/(n+1)$, quelle que soit la valeur de θ. Pour ce choix,

$$R(\theta, \hat\theta^{(3)}_{n,a_\star}) = \frac{\theta^2}{(n+1)^2} \,,$$

et, comme $(n+1)^2 > n(n+2)$ pour tout $n \geq 1$,

$$R(\theta, \hat\theta^{(3)}_{n,a_\star}) < R(\theta, \hat\theta^{(2)}_n) \,, \qquad \text{pour tout } \theta > 0 \,,$$

ce qui montre que $\hat\theta^{(2)}_n$ est inadmissible (et, par transitivité de l'inégalité stricte, que $\hat\theta^{(1)}_n$ l'est aussi). L'évolution des risques est représentée sur la figure 1.

Corrigé de l'exercice 2 – Régression linéaire gaussienne

On reprend les notations du corrigé de l'Exercice 1 (PC2) : sous $\mathbb{P}_\beta$, $\mathbf{Y} \sim \mathcal{N}(\mathbf{X}\beta, \sigma^2 \mathrm{I}_n)$, et $\mathbf{X}^\top\mathbf{X} = n\begin{pmatrix} 1 & \bar x \\ \bar x & n^{-1}\sum_{i=1}^n x_i^2 \end{pmatrix}$ est inversible, de déterminant $n\sum_{i=1}^n (x_i - \bar x)^2 > 0$, avec

$$(\mathbf{X}^\top\mathbf{X})^{-1} = \frac{1}{n\sum_{i=1}^n (x_i-\bar x)^2} \begin{pmatrix} \sum_{i=1}^n x_i^2 & -\sum_{i=1}^n x_i \\ -\sum_{i=1}^n x_i & n \end{pmatrix} .$$

Ici σ^2 est connu ; le paramètre est $\beta = (\beta_1, \beta_2)$ et la variable de la log-vraisemblance $b = (b_1, b_2)$.

1. La log-vraisemblance s'écrit, pour $\mathbf{y} \in \mathbb{R}^n$,

$$\ell_n(b; \mathbf{y}) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\,\|\mathbf{y} - \mathbf{X}b\|^2 \,, \qquad \nabla_b \ell_n(b; \mathbf{y}) = \frac{1}{\sigma^2}\,\mathbf{X}^\top(\mathbf{y} - \mathbf{X}b) \,.$$

Comme $\mathbb{E}_\beta[(\mathbf{Y} - \mathbf{X}\beta)(\mathbf{Y} - \mathbf{X}\beta)^\top] = \sigma^2 \mathrm{I}_n$,

$$\mathbb{I}(\beta_1, \beta_2) = \mathbb{E}_\beta\big[\nabla_b \ell_n(\beta; \mathbf{Y})\,\nabla_b \ell_n(\beta; \mathbf{Y})^\top\big] = \frac{1}{\sigma^4}\,\mathbf{X}^\top\,\mathbb{E}_\beta\big[(\mathbf{Y}-\mathbf{X}\beta)(\mathbf{Y}-\mathbf{X}\beta)^\top\big]\,\mathbf{X} = \frac{1}{\sigma^2}\,\mathbf{X}^\top\mathbf{X} \,.$$

Cette matrice est inversible d'après le préliminaire, puisque deux x_i sont distincts par hypothèse.

2. Soit $g(\beta) = \beta_1$, de gradient $\nabla_\beta g(\beta) = (1, 0)^\top$. Le modèle étant régulier (les hypothèses de la Définition 1.6 se vérifient comme pour le modèle gaussien), tout estimateur sans biais et régulier de β_1 a une variance minorée, par le Théorème 1.1, par

$$\nabla_\beta g(\beta)^\top\,\mathbb{I}(\beta)^{-1}\,\nabla_\beta g(\beta) = \sigma^2\,\big[(\mathbf{X}^\top\mathbf{X})^{-1}\big]_{11} = \frac{\sigma^2}{n} \cdot \frac{\sum_{i=1}^n x_i^2}{\sum_{i=1}^n (x_i - \bar x)^2} \,.$$

3. Lorsque β_2 est connu, la log-vraisemblance ne dépend plus que de β_1 :

$$\tilde\ell_n(\beta_1; \mathbf{y}) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i)^2 \,, \qquad \frac{\partial^2 \tilde\ell_n}{\partial \beta_1^2}(\beta_1; \mathbf{y}) = -\frac{n}{\sigma^2} \,,$$

d'où $\tilde{\mathbb{I}}(\beta_1) = n/\sigma^2$ et une borne inférieure σ^2/n pour la variance d'un estimateur sans biais et régulier de β_1. Cette borne est inférieure ou égale à celle de la question 2, puisque $\sum_{i=1}^n x_i^2 \geq \sum_{i=1}^n (x_i - \bar{x})^2$ (l'écart est $n\bar{x}^2 \geq 0$), avec égalité si et seulement si $\bar{x} = 0$: c'est le cas, à l'Exercice 1 (PC2) question 4, où l'indépendance de $\hat{\beta}_1$ et $\hat{\beta}_2$ a été caractérisée par $\bar{x} = 0$. Connaître β_2 ne peut qu'aider à estimer β_1 ; la borne baisse d'autant moins que $\bar{x}$ est proche de 0, c'est-à-dire que les deux coefficients sont déjà peu corrélés.

4. Soit $g(\beta) = \beta_1\beta_2$, de gradient $\nabla_\beta g(\beta) = (\beta_2, \beta_1)^\top$. En utilisant l'inverse du préliminaire,

$$\nabla_\beta g(\beta)^\top \, \mathbb{I}(\beta)^{-1} \, \nabla_\beta g(\beta) = \frac{\sigma^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \Big(\beta_2^2 \sum_{i=1}^n x_i^2 - 2\beta_1\beta_2 \sum_{i=1}^n x_i + n\beta_1^2 \Big) \, ,$$

qui minore la variance de tout estimateur sans biais et régulier de $\beta_1\beta_2$.

Corrigé de l'exercice 3 – Cramér-Rao sans régularité

1. Par l'inégalité de Cauchy-Schwarz (Proposition 2.1), appliquée aux variables centrées $T(Z) - \mathbb{E}_\theta[T(Z)]$ et $\Psi(Z) - \mathbb{E}_\theta[\Psi(Z)]$,

$$\big\{ \operatorname{Cov}_\theta(T(Z), \Psi(Z)) \big\}^2 = \Big(\mathbb{E}_\theta \big[(T(Z) - \mathbb{E}_\theta[T(Z)])(\Psi(Z) - \mathbb{E}_\theta[\Psi(Z)]) \big] \Big)^2 \leq \operatorname{Var}_\theta(T(Z)) \, \operatorname{Var}_\theta(\Psi(Z)) \, ,$$

et l'on conclut en divisant par $\operatorname{Var}_\theta(\Psi(Z)) \in \,]0, \infty[$.

2. Pour $\alpha \in \Theta$, posons $A_\alpha := \{z \in \mathsf{Z} : p_\alpha(z) > 0\}$; l'hypothèse s'écrit $A_{\theta-\delta} \subseteq A_\theta$, et $p_{\theta-\delta} \mathbb{1}_{A_\theta} = p_{\theta-\delta} \mathbb{1}_{A_{\theta-\delta}}$. Alors

$$\begin{aligned} \mathbb{E}_\theta[\Psi(Z)] &= \int \Big(\frac{p_{\theta-\delta}(z)}{p_\theta(z)} - 1 \Big) \mathbb{1}_{A_\theta}(z) \, p_\theta(z) \, \mu(\mathrm{d}z) = \int \big[p_{\theta-\delta}(z) - p_\theta(z) \big] \mathbb{1}_{A_\theta}(z) \, \mu(\mathrm{d}z) \\ &= \int p_{\theta-\delta}(z) \mathbb{1}_{A_{\theta-\delta}}(z) \, \mu(\mathrm{d}z) - \int p_\theta(z) \mathbb{1}_{A_\theta}(z) \, \mu(\mathrm{d}z) = 1 - 1 = 0 \, , \end{aligned}$$

et, par le même argument,

$$\operatorname{Cov}_\theta(T(Z), \Psi(Z)) = \mathbb{E}_\theta[T(Z)\Psi(Z)] = \int T(z) \big[p_{\theta-\delta}(z) \mathbb{1}_{A_{\theta-\delta}}(z) - p_\theta(z) \mathbb{1}_{A_\theta}(z) \big] \, \mu(\mathrm{d}z) = g(\theta-\delta) - g(\theta) \, ,$$

en utilisant que T est sans biais sous $\mathbb{P}_{\theta-\delta}$ et sous $\mathbb{P}_\theta$.

3. En combinant les deux questions précédentes,

$$\operatorname{Var}_\theta(T(Z)) \geq \frac{\{g(\theta) - g(\theta-\delta)\}^2}{\int_{A_\theta} \big(1 - \frac{p_{\theta-\delta}(z)}{p_\theta(z)}\big)^2 \, p_\theta(z) \, \mu(\mathrm{d}z)} \, .$$

4. En divisant numérateur et dénominateur par δ^2,

$$\operatorname{Var}_\theta(T(Z)) \geq \frac{\big\{ \frac{g(\theta) - g(\theta-\delta)}{\delta} \big\}^2}{\int_{A_\theta} \big\{ \frac{p_\theta(z) - p_{\theta-\delta}(z)}{\delta} \big\}^2 \frac{1}{p_\theta(z)} \, \mu(\mathrm{d}z)} \, .$$

Pour retrouver la borne de Cramér-Rao par passage à la limite $\delta \to 0^+$, il suffit que : Θ soit ouvert, de sorte que $\theta - \delta \in \Theta$ pour δ assez petit ; g soit dérivable en θ, de sorte que le numérateur tende vers $g'(\theta)^2$; et que l'on puisse permuter limite et intégrale au dénominateur. Ces trois conditions sont exactement celles que rassemble la Définition 1.6 du modèle régulier : la différentiabilité de $\theta \mapsto p_\theta(z)$ donne la limite ponctuelle

$\{p_\theta(z) - p_{\theta-\delta}(z)\}/\delta \to \partial_\theta p_\theta(z)$, et les dominations qu'elle impose permettent d'appliquer le théorème de convergence dominée (Proposition 2.2 de dérivation sous le signe intégral) pour passer la limite sous l'intégrale. On retrouve alors

$$\mathrm{Var}_\theta(T(Z)) \geq \frac{\{g'(\theta)\}^2}{\mathbb{I}(\theta)}\,, \qquad \mathbb{I}(\theta) = \mathbb{E}_\theta\Big[\Big(\frac{\partial}{\partial\theta}\log p_\theta(Z)\Big)^2\Big]\,,$$

qui est la borne de Cramér-Rao unidimensionnelle (Corollaire 1.1).

5. Posons $z = (x_1, \ldots, x_n)$, $\mu = \mathrm{Leb}^{\otimes n}$ et $p_\theta(z) = \theta^{-n}\prod_{i=1}^n \mathbb{1}_{[0,\theta]}(x_i)$. Pour $\delta \in\,]0,\theta[$, $p_\theta(z) = 0$ entraîne $p_{\theta-\delta}(z) = 0$: l'hypothèse de la question 2 est vérifiée, et $A_\theta = [0,\theta]^n$. Le dénominateur de la borne de la question 3 vaut

$$\begin{aligned}\int_{A_\theta}\Big(\frac{p_{\theta-\delta}(z)}{p_\theta(z)} - 1\Big)^2 p_\theta(z)\,\mu(\mathrm{d}z) &= \int_{A_\theta}\Big(\frac{p_{\theta-\delta}(z)}{p_\theta(z)}\Big)^2 p_\theta(z)\,\mu(\mathrm{d}z) + 1 - 2\int_{A_\theta} p_{\theta-\delta}(z)\,\mu(\mathrm{d}z)\\ &= \frac{1}{\theta^n}\int_{[0,\theta]^n}\big(\theta^n p_{\theta-\delta}(z)\big)^2\,\mathrm{d}z - 1 = \frac{\theta^n}{(\theta-\delta)^n} - 1\,,\end{aligned}$$

puisque $\int_{A_\theta} p_{\theta-\delta}\,\mu(\mathrm{d}z) = 1$ (question 2) et $\theta^n p_{\theta-\delta}(z) = \big(\theta/(\theta-\delta)\big)^n$ sur $[0,\theta-\delta]^n$. D'où la borne annoncée.

6. En posant $\delta = c\theta/n$ avec $0 < c \leq n$, le dénominateur devient $(1-c/n)^{-n} - 1$, et $\mathrm{Var}_\theta(T(Z)) \geq \tau_n(c)\,\theta^2/n^2$ avec

$$\tau_n(c) := \frac{c^2}{(1-c/n)^{-n} - 1} \xrightarrow[n\to\infty]{} \frac{c^2}{\mathrm{e}^c - 1}\,.$$

La borne de la question 5 vaut ainsi, pour tout $0 < c \leq n$, $\theta^2\tau_n(c)/n^2$; en optimisant sur c, l'erreur quadratique moyenne de tout estimateur sans biais de θ dans ce modèle est minorée par $\theta^2 \sup_{c\in]0,n[}\tau_n(c)/n^2$, une quantité d'ordre θ^2/n^2 lorsque $n \to \infty$ (figure 2). On retrouve ainsi, par une borne qui ne suppose aucune régularité, la vitesse en n^{-2} annoncée à l'Exemple 1.16 : l'estimateur $\hat\theta_n^{(2)} = \frac{n+1}{n}X_{n:n}$ de l'Exercice 1, de risque quadratique $\theta^2/\{n(n+2)\}$, est de cet ordre.

Corrigé de l'exercice 4 – Estimateurs linéaires

Sous $\mathbb{P}_\theta$, chaque X_k a même loi que $\theta + \sigma Y_k$ avec $Y_k \sim p\cdot\mathrm{Leb}$ (Exemple 1.1), donc $\mathbb{E}_\theta[X_k] = \theta$ et $\mathrm{Var}_\theta(X_k) = \sigma^2$. Par indépendance des X_k,

$$\mathbb{E}_\theta\big[\hat\theta_n(\underline{a}_n)\big] = \theta\sum_{k=1}^n a_{k,n}\,, \qquad \mathrm{Var}_\theta\big(\hat\theta_n(\underline{a}_n)\big) = \sigma^2\sum_{k=1}^n a_{k,n}^2\,,$$

d'où le risque quadratique

$$R\big(\theta,\hat\theta_n(\underline{a}_n)\big) = \theta^2\Big(\sum_{k=1}^n a_{k,n} - 1\Big)^2 + \sigma^2\sum_{k=1}^n a_{k,n}^2\,.$$

1. Sans biais signifie $\sum_{k=1}^n a_{k,n} = 1$; il reste à minimiser $\sigma^2\sum_k a_{k,n}^2$ sous cette contrainte. Par l'inégalité de Cauchy-Schwarz appliquée à $\underline{a}_n$ et à $\mathbf{1} := (1,\ldots,1)$,

$$\frac{1}{n}\sum_{k=1}^n a_{k,n}^2 \geq \Big(\frac{1}{n}\sum_{k=1}^n a_{k,n}\Big)^2 = \frac{1}{n^2}\,,$$

avec égalité si et seulement si $a_{1,n} = \cdots = a_{n,n}$; la contrainte impose alors $a_{k,n} = 1/n$ pour tout k. L'estimateur sans biais de risque quadratique minimal dans cette classe est donc la moyenne empirique $\hat\theta_n(1/n, \dots, 1/n) = \bar X_n$: c'est le résultat de l'Exemple 1.11 du chapitre, ici retrouvé sous l'hypothèse plus faible $\mathbb{E}_\theta[X_1^2] < \infty$ remplacée par la structure de translation.

2. Sans la contrainte d'absence de biais, on minimise sur $\mathbb{R}^n$ la fonction

$$\underline{a}_n \mapsto \theta^2\Big(\sum_{k=1}^n a_{k,n} - 1\Big)^2 + \sigma^2 \sum_{k=1}^n a_{k,n}^2 \,,$$

dont la matrice hessienne, $2\sigma^2 \mathrm{I}_n + 2\theta^2 \mathbf{1}\mathbf{1}^\top$, vérifie $u^\top H u = 2\sigma^2\|u\|^2 + 2\theta^2(\sum_k u_k)^2 \geq 2\sigma^2\|u\|^2 > 0$ pour tout $u \neq 0$: la fonction est strictement convexe et son unique minimum est le point où le gradient s'annule, soit, pour tout i,

$$\theta^2\Big(\sum_{k=1}^n a_{k,n} - 1\Big) + \sigma^2 a_{i,n} = 0 \,.$$

En sommant sur i, $n\theta^2\big(\sum_k a_{k,n} - 1\big) + \sigma^2 \sum_k a_{k,n} = 0$, d'où $\sum_k a_{k,n} = n\theta^2/(\sigma^2 + n\theta^2)$, puis, en reportant,

$$a_{i,n} = \frac{\theta^2}{\sigma^2 + n\theta^2} \,, \qquad i = 1, \dots, n \,.$$

Le risque minimal dans la classe des estimateurs linéaires, atteint pour ce choix, vaut

$$R\big(\theta, \hat\theta_n(\underline{a}_n^\star)\big) = \frac{\sigma^2\theta^2}{\sigma^2 + n\theta^2} = \frac{\sigma^2}{n} \cdot \frac{\theta^2}{\theta^2 + \sigma^2/n} < \frac{\sigma^2}{n} \,,$$

strictement inférieur au risque optimal σ^2/n de la question 1 : en autorisant un biais, la classe des estimateurs comparés est plus grande, et le risque optimal ne peut que baisser.

Corrigé de l'exercice 5 – Statistiques d'ordre exponentielles

On note $\mathbb{E}_\theta[U] = \theta$ et $\mathrm{Var}_\theta(U) = \theta^2$ pour $U \sim p_\theta \cdot \mathrm{Leb}$.

1. Soit $\mathcal{S}_n$ l'ensemble des permutations de $\{1, \dots, n\}$, de cardinal $n!$. Sous $p_\theta \cdot \mathrm{Leb}^{\otimes n}$, $(X_1, \dots, X_n)$ sont i.i.d., donc pour toute permutation $\tau = (\tau_1, \dots, \tau_n)$, $(X_1, \dots, X_n)$ a même loi que $(X_{\tau_1}, \dots, X_{\tau_n})$. Comme les X_i ont une loi à densité, $\mathbb{P}_\theta(X_i = X_j) = 0$ pour $i \neq j$, donc il existe presque sûrement une unique permutation aléatoire σ telle que $X_{k:n} = X_{\sigma_k}$ pour tout k et $X_{\sigma_1} < \cdots < X_{\sigma_n}$. Pour toute fonction h mesurable bornée,

$$\begin{aligned}\mathbb{E}_\theta\big[h(X_{1:n}, \dots, X_{n:n})\big] &= \mathbb{E}_\theta\big[h(X_{\sigma_1}, \dots, X_{\sigma_n})\big] = \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta\big[h(X_{\tau_1}, \dots, X_{\tau_n})\, \mathbb{1}_{\sigma=\tau}\big] \\ &= \sum_{\tau \in \mathcal{S}_n} \mathbb{E}_\theta\big[h(X_{\tau_1}, \dots, X_{\tau_n})\, \mathbb{1}_{X_{\tau_1} < \cdots < X_{\tau_n}}\big] \,,\end{aligned}$$

et chaque terme de la somme vaut, par un changement de variables sur les indices (les X_i étant i.i.d.),

$$\int_{y_1 < \cdots < y_n} h(y_1, \dots, y_n)\Big(\prod_{k=1}^n p_\theta(y_k)\Big)\, \mathrm{d}y_1 \dots \mathrm{d}y_n \,,$$

indépendamment de τ ; en sommant les $n!$ termes égaux, on obtient la densité annoncée.

2. Soit h mesurable positive. En posant $z_i := (n-i+1)(y_i - y_{i-1})$ (c'est-à-dire $y_i = \sum_{j=1}^{i} z_j/(n-j+1)$), de jacobien $n!$ pour l'inverse de la transformation (14), et en utilisant $\sum_{k=1}^{n}\sum_{j=1}^{k} \mathbb{1}_{j\le k} z_j/(n-j+1) = \sum_{j=1}^{n} z_j$,

$$\begin{aligned}\mathbb{E}_\theta\big[h(Z_1,\dots,Z_n)\big] &= \frac{n!}{\theta^n}\int_{0\le y_1<\dots<y_n} \exp\Big(-\theta^{-1}\sum_{k=1}^{n} y_k\Big)\, h\big(ny_1,\dots,(y_n-y_{n-1})\big)\,\mathrm{d}y_1\dots\mathrm{d}y_n \\ &= \frac{1}{\theta^n}\int_{z_1,\dots,z_n>0} \exp\Big(-\theta^{-1}\sum_{j=1}^{n} z_j\Big)\, h(z_1,\dots,z_n)\,\mathrm{d}z_1\dots\mathrm{d}z_n\ ,\end{aligned}$$

ce qui identifie la loi de $(Z_1,\dots,Z_n)$ comme le produit de n lois exponentielles de paramètre θ.

3. On a

$$\sum_{j=1}^{n} m_{j,n} Z_j = \sum_{j=1}^{n} \frac{Z_j}{n-j+1}\sum_{i=j}^{n} a_{i,n} = \sum_{i=1}^{n} a_{i,n}\sum_{j=1}^{i}\frac{Z_j}{n-j+1} = \sum_{i=1}^{n} a_{i,n} X_{i:n} = \hat\theta_n(\underline{a}_n)\ ,$$

en intervertissant les sommes sur i et j (indice $j \le i$) et en reconnaissant $X_{i:n} = \sum_{j=1}^{i} Z_j/(n-j+1)$.

4. Par la question 2, $(Z_1,\dots,Z_n)$ sont i.i.d. de loi exponentielle de paramètre θ : $\mathbb{E}_\theta[Z_j] = \theta$ et $\mathrm{Var}_\theta(Z_j) = \theta^2$. Par la question 3, $\hat\theta_n(\underline{a}_n)$ est une combinaison linéaire des Z_j de poids $m_{j,n}$, donc

$$\mathbb{E}_\theta\big[\hat\theta_n(\underline{a}_n)\big] = \theta\sum_{j=1}^{n} m_{j,n}\ , \qquad \mathrm{Var}_\theta\big(\hat\theta_n(\underline{a}_n)\big) = \theta^2\sum_{j=1}^{n} m_{j,n}^2\ ,$$

d'où le risque quadratique

$$R\big(\theta,\hat\theta_n(\underline{a}_n)\big) = \theta^2\Big(\sum_{j=1}^{n} m_{j,n} - 1\Big)^2 + \theta^2\sum_{j=1}^{n} m_{j,n}^2\ .$$

5. Sans biais signifie $\sum_j m_{j,n} = 1$; on minimise alors $\sum_j m_{j,n}^2$ sous cette contrainte, exactement comme à la question 1 de l'Exercice 4, ce qui donne $m_{j,n} = 1/n$ pour tout j. La bijection entre $\underline{m}_n$ et $\underline{a}_n$ donnée par $m_{j,n} = (n-j+1)^{-1}\sum_{i=j}^{n} a_{i,n}$ (question 3) se résout en $a_{i,n} = m_{i,n} - m_{i+1,n}$ pour $i < n$ et $a_{n,n} = m_{n,n}$; avec $\underline{m}_n = (1/n,\dots,1/n)$, il vient $\underline{a}_n = (1/n,\dots,1/n)$: l'estimateur sans biais de risque quadratique minimal dans cette classe est de nouveau la moyenne empirique.

6. Sans la contrainte d'absence de biais, la minimisation en $\underline{m}_n$ de $\theta^2(\sum_j m_{j,n} - 1)^2 + \theta^2\sum_j m_{j,n}^2$ se fait comme à la question 2 de l'Exercice 4 (avec $\sigma^2 = \theta^2$) : le minimum est atteint en $m_{j,n} = \theta^2/(\theta^2 + n\theta^2) = 1/(n+1)$ pour tout j, d'où, par la même bijection, $a_{i,n} = 1/(n+1)$ pour tout i.