2 Les outils mathématiques

Vous retrouverez ci-dessous les éléments mathématiques ou probabilistes nécessaires pour comprendre cette partie du cours : l'inégalité de Cauchy-Schwarz, qui intervient deux fois dans la preuve de la borne de Cramér-Rao et une fois dans l'étude des estimateurs linéaires ; le théorème de dérivation sous le signe intégral, dont dépend toute la section consacrée à l'information de Fisher ; les notations matricielles employées par la définition d'un modèle régulier et par la forme vectorielle de la borne ; enfin la décomposition biais-variance dans sa version vectorielle. La fin de cette partie rappelle où trouver, aux chapitres 1 et 2, les résultats utilisés sans être redémontrés.

Inégalité de Cauchy-Schwarz

L'inégalité de Cauchy-Schwarz majore la covariance de deux variables aléatoires par le produit de leurs écarts-types ; c'est elle qui transforme une identité en inégalité dans la preuve de la borne de Cramér-Rao.

Proposition 2.1: Inégalité de Cauchy-Schwarz

Soient U et V deux variables aléatoires réelles de carré intégrable sur un même espace probabilisé. Alors UV est intégrable et

$$\big(\mathbb{E}[UV]\big)^2 \leq \mathbb{E}[U^2]\,\mathbb{E}[V^2]\,.$$

Il y a égalité si et seulement s'il existe $(\alpha,\beta) \neq (0,0)$ tel que $\alpha U + \beta V = 0$ presque sûrement.

Démonstration

L'intégrabilité de UV résulte de $|UV| \leq (U^2+V^2)/2$. Si $\mathbb{E}[V^2] = 0$, alors $V = 0$ presque sûrement, les deux membres sont nuls et le couple $(\alpha,\beta) = (0,1)$ convient. Supposons donc $\mathbb{E}[V^2] > 0$ et posons, pour $t \in \mathbb{R}$,

$$\varphi(t) := \mathbb{E}\big[(U+tV)^2\big] = \mathbb{E}[U^2] + 2t\,\mathbb{E}[UV] + t^2\,\mathbb{E}[V^2]\,.$$

C'est un trinôme du second degré en t, positif ou nul pour tout t, de coefficient dominant strictement positif : son discriminant $4(\mathbb{E}[UV])^2 - 4\mathbb{E}[U^2]\mathbb{E}[V^2]$ est donc négatif ou nul, ce qui est l'inégalité annoncée. Il y a égalité si et seulement si le discriminant est nul, c'est-à-dire s'il existe t_0 tel que $\varphi(t_0) = 0$, autrement dit tel que $U + t_0 V = 0$ presque sûrement. □

Appliquée à $U = T(Z) - g(\theta)$ et à $V = \nabla_\theta \ell(\theta, Z)^\top u$ sous $\mathbb{P}_\theta$, cette inégalité donne la forme employée dans la preuve du Théorème 1.1. Le cas d'égalité, qui demande la colinéarité presque sûre des deux variables, caractérise les estimateurs efficaces ; c'est le point de départ du résultat d'existence des compléments (Section 4).

Dérivation sous le signe intégral

La proposition suivante donne des conditions sous lesquelles la dérivée d'une intégrale dépendant d'un paramètre est l'intégrale de la dérivée. Elle est démontrée dans l'annexe du polycopié consacrée aux compléments de théorie de la mesure, comme conséquence du théorème de convergence dominée.

Proposition 2.2: Dérivation sous le signe intégral

Soient $(\mathsf{E}, \mathcal{E}, \mu)$ un espace mesuré, I un intervalle ouvert de $\mathbb{R}$ et $\{f(t,\cdot),\ t \in I\}$ une famille de fonctions μ-intégrables. On pose $\phi(t) := \int f(t,x)\,\mu(\mathrm{d}x)$ pour $t \in I$. On suppose qu'il existe $A \in \mathcal{E}$ et une fonction μ-intégrable h tels que

(i) $\mu(A^c) = 0$;

(ii) pour tout $x \in A$, la fonction $t \mapsto f(t,x)$ est dérivable sur I ;

(iii) pour tout $x \in A$ et tout $t \in I$, $\left|\frac{\partial f}{\partial t}(t,x)\right| \le h(x)$.

Alors ϕ est dérivable sur I et $\phi'(t) = \int \frac{\partial f}{\partial t}(t,x)\,\mu(\mathrm{d}x)$ pour tout $t \in I$.

Démonstration

Soit $t \in I$. Comme $\mu(A^c) = 0$, on a pour tout $h \neq 0$ assez petit pour que $t + h \in I$,

$$\frac{\phi(t+h) - \phi(t)}{h} = \int_A \frac{f(t+h,x) - f(t,x)}{h}\,\mu(\mathrm{d}x)\ .$$

Pour $x \in A$, le théorème des accroissements finis donne $|f(t+h,x) - f(t,x)|/|h| = |\partial_t f(s,x)|$ pour un s entre t et $t+h$, donc cette quantité est majorée par $h(x)$, indépendamment de h. Par ailleurs, la dérivabilité de $t \mapsto f(t,x)$ donne la convergence ponctuelle du taux d'accroissement vers $\partial_t f(t,x)$. Le théorème de convergence dominée s'applique et fournit la conclusion. □

Le chapitre en fait trois usages, tous sous la même forme : la domination locale de $\|\nabla_\theta p_\theta(z)\|$ par une fonction μ-intégrable justifie l'espérance nulle du score ; la domination de $\|\mathrm{H}_p(\theta,z)\|$ justifie l'expression de l'information de Fisher par la hessienne ; enfin, la domination de $|T(z)|\ \|\nabla_\theta p_\theta(z)\|$ donne la condition suffisante de régularité d'un estimateur. C'est le contenu même des conditions (iii) de la Définition 1.6, dont la formulation par dominations locales n'a pas d'autre but.

Matrice hessienne, norme de Frobenius, matrices symétriques positives

Par convention, les vecteurs sont des vecteurs colonne, et l'on note $u^\top$ le vecteur transposé de u.

Si $F : \Theta \times \mathsf{Z} \to \mathbb{R}$ est telle que, pour z fixé, la fonction $\theta \mapsto F(\theta,z)$ soit deux fois dérivable sur un ouvert $\Theta \subseteq \mathbb{R}^d$, on note $\nabla_\theta F(\theta,z)$ son gradient et

$$\mathrm{H}_F(\theta,z) := \Big[\frac{\partial^2 F}{\partial\theta^{(i)}\,\partial\theta^{(j)}}(\theta,z)\Big]_{1\le i,j\le d}$$

sa *matrice hessienne*, qui est symétrique lorsque les dérivées secondes sont continues.

Si $A = (a_{ij})_{1\le i,j\le d} \in \mathrm{Mat}_d(\mathbb{R})$, sa *norme de Frobenius* est

$$\|A\|^2 := \mathrm{Tr}\left(A^\top A\right) = \sum_{i=1}^d \sum_{j=1}^d a_{ij}^2\ .$$

Pour tout $a \in \mathbb{R}^d$, on a $\left\|aa^\top\right\| = \mathrm{Tr}\left(aa^\top aa^\top\right)^{1/2} = \mathrm{Tr}\left(a^\top a\, a^\top a\right)^{1/2} = \|a\|^2$: c'est l'identité utilisée dans la preuve de la Proposition 1.2 et dans celle du Lemme 2.1.

Enfin, une matrice symétrique $A \in \mathrm{Mat}_d(\mathbb{R})$ est dite *positive*, ce qu'on note $A \ge 0$, si $u^\top A u \ge 0$ pour tout $u \in \mathbb{R}^d$, et *définie positive* si l'inégalité est stricte pour $u \neq 0$. On écrit $A \ge B$ pour $A - B \ge 0$; c'est un ordre partiel sur les matrices symétriques, et c'est en ce sens qu'il faut lire l'inégalité $\mathrm{Var}_\theta(T(Z)) \ge \mathbb{I}(\theta)^{-1}$ du Corollaire 1.2. Une matrice symétrique définie positive est inversible et son inverse est définie positive.

Décomposition biais-variance vectorielle

La Proposition 1.1 a été énoncée pour un estimateur à valeurs réelles. Voici sa version vectorielle, dont le cas scalaire se déduit en prenant la trace.

Si $T(Z)$ est un estimateur de $g : \theta \mapsto g(\theta)$ à valeurs dans $\mathbb{R}^p$, la quantité

$$\mathbb{E}_\theta\left[(T(Z) - g(\theta))(T(Z) - g(\theta))^\top\right] \tag{12}$$

est une matrice de taille $p \times p$, dont le terme (i,j) vaut $\mathbb{E}_\theta[(T_i(Z) - g_i(\theta))(T_j(Z) - g_j(\theta))]$. Dans le cas $p = 1$, c'est le risque quadratique. Lorsque l'estimateur est sans biais, la matrice (12) est la matrice de covariance de $T(Z)$; dans le cas général, les deux sont liées par la décomposition suivante.

Proposition 2.3: Décomposition biais-variance vectorielle

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique, $g : \Theta \to \mathbb{R}^p$ une fonction mesurable et T un estimateur de g tel que $\mathbb{E}_\theta[\|T(Z)\|_2^2] < \infty$ pour tout $\theta \in \Theta$. Pour tout $\theta \in \Theta$,

$$\mathbb{E}_\theta\big[(T(Z)-g(\theta))(T(Z)-g(\theta))^\top\big] = \mathrm{Var}_\theta(T(Z)) + \big(\mathbb{E}_\theta[T(Z)]-g(\theta)\big)\big(\mathbb{E}_\theta[T(Z)]-g(\theta)\big)^\top\,, \quad (13)$$

où $\mathrm{Var}_\theta(T(Z)) \in \mathrm{Mat}_p(\mathbb{R})$ désigne la matrice de covariance de $T(Z)$ sous $\mathbb{P}_\theta$.

Démonstration

On écrit $T(Z) - g(\theta) = \big(T(Z) - \mathbb{E}_\theta[T(Z)]\big) + \big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)$, puis on développe le produit

$$\begin{aligned}(T(Z) - g(\theta))(T(Z) - g(\theta))^\top = {}& \big(T(Z) - \mathbb{E}_\theta[T(Z)]\big)\big(T(Z) - \mathbb{E}_\theta[T(Z)]\big)^\top \\ &+ \big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)\big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)^\top \\ &+ \big(T(Z) - \mathbb{E}_\theta[T(Z)]\big)\big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)^\top \\ &+ \big(\mathbb{E}_\theta[T(Z)] - g(\theta)\big)\big(T(Z) - \mathbb{E}_\theta[T(Z)]\big)^\top\,.\end{aligned}$$

En prenant l'espérance sous $\mathbb{P}_\theta$, le premier terme donne la matrice de covariance, le deuxième est déterministe et donne le terme de biais, et les deux derniers sont d'espérance nulle puisque $\mathbb{E}_\theta[T(Z) - \mathbb{E}_\theta[T(Z)]] = 0$. □

En prenant la trace de (13) et en notant que, pour tout $a \in \mathbb{R}^p$, $\mathrm{Tr}\left(aa^\top\right) = \|a\|^2$, il vient

$$\mathbb{E}_\theta\big[\,\|T(Z) - g(\theta)\|_2^2\,\big] = \mathbb{E}_\theta\big[\,\|T(Z) - \mathbb{E}_\theta[T(Z)]\|_2^2\,\big] + \|\mathbb{E}_\theta[T(Z)] - g(\theta)\|_2^2\,,$$

qui redonne, pour $p = 1$, la Proposition 1.1.

L'information de Fisher ne dépend pas de la mesure dominante

La définition de l'information de Fisher passe par une densité, donc par le choix d'une mesure dominante. Comme ce choix n'est pas unique (chapitre 1, Section 4), il faut vérifier que l'objet défini n'en dépend pas.

Lemme 2.1: L'information de Fisher est bien définie

Soit $(\mathsf{Z}, \mathcal{Z}, \{p_\theta \cdot \mu\,,\ \theta \in \Theta\})$ un modèle statistique régulier. La matrice

$$\mathbb{I}(\theta) := \mathbb{E}_\theta\big[\nabla_\theta \ell(\theta, Z)\, \nabla_\theta \ell(\theta, Z)^\top\big]$$

est bien définie, à coefficients finis, et ne dépend pas du choix de la mesure de domination.

Démonstration

Pour tout $a \in \mathbb{R}^d$, $\left\|aa^\top\right\| = \|a\|^2$ (Section 2). Ainsi, pour tout $\theta_0 \in \Theta$, en reprenant les fonctions h_0, h_1 de la condition (iii) de régularité,

$$\mathbb{E}_{\theta_0}\Big[\,\big\|\nabla_\theta \ell(\theta_0, Z)\, \nabla_\theta \ell(\theta_0, Z)^\top\big\|\,\Big] = \mathbb{E}_{\theta_0}\Big[\,\|\nabla_\theta \ell(\theta_0, Z)\|^2\,\Big] \le \int_{\mathsf{Z}} h_1(z) h_0(z)\, \mu(\mathrm{d}z) < \infty\,,$$

donc l'intégrale (5) est bien définie.
Pour l'indépendance vis-à-vis de la mesure dominante, soit ν une autre mesure de domination, avec $\mathbb{P}_\theta = q_\theta \cdot \nu$ pour tout θ, et posons $\lambda := \mu + \nu$. Par le théorème de Radon-Nikodym (chapitre 1, Théorème 2.1), il existe une fonction mesurable positive r, indépendante de θ, telle que $p_\theta(z) = r(z)\, q_\theta(z)$ pour λ-presque tout z. En passant au logarithme puis au gradient en θ, il vient $\nabla_\theta \log p_\theta(z) = \nabla_\theta \log q_\theta(z)$ pour λ-presque tout z, ce qui conclut en substituant dans (5). □

Résultats des chapitres 1 et 2 utilisés dans ce chapitre

Les résultats suivants sont utilisés sans être redémontrés ; ils sont énoncés et démontrés dans les chapitres précédents.

— *Estimateur ponctuel, statistique* (chapitre 2, définition de l'estimateur ponctuel, et chapitre 1, Section 1.5) : tout ce chapitre porte sur des estimateurs au sens de cette définition.

— *Densité d'un n-échantillon* (chapitre 1, Section 1.7) : la log-vraisemblance d'un échantillon est la somme des log-vraisemblances des observations, d'où l'additivité de l'information.

— *Modèle dominé, densités et théorème de Radon-Nikodym* (chapitre 1, Section 2 et Section 2) : la mesure dominante n'est pas unique, d'où la nécessité du Lemme 2.1.

— *Statistiques d'ordre* (chapitre 1, Section 1.5) : loi de $X_{n:n}$ dans le modèle uniforme, médiane empirique dans le modèle de translation.

— *Loi du χ^2, théorèmes de Cochran et de Gosset* (chapitre 1, Section 2 et Section 1.9) : loi de la variance empirique dans le modèle gaussien, utilisée à l'Exemple 1.8 et dans l'Exercice 2 (PC3).

— *Vraisemblance, log-vraisemblance et estimateur du maximum de vraisemblance* (chapitre 2, Section 1.3) : la log-vraisemblance dont le score est le gradient est celle du chapitre 2.

— *Divergence de Kullback-Leibler* (chapitre 2, Section 1.4) : positivité, annulation en $\theta = \theta^\star$, et lecture de l'information de Fisher comme sa courbure.