2 Solutions

2.1 Exercice 1

Posons $Z = (X_1, \cdots, X_n)$.

1. (a) Une loi exponentielle est une loi Gamma de paramètres $(1, 1/\theta)$. Or, si Y suit une loi Gamma de paramètres (a, b) alors pour tout $\lambda > 0$, λY suit une loi Gamma de paramètres $(a, b/\lambda)$.[5] Ainsi, sous $p_\theta \cdot \mathrm{dLeb}$, $2X_i\theta^{-1} \sim \Gamma(1, 1/2) = \chi^2(2) = \mathcal{E}(1/2)$. Comme sous $p_\theta \cdot \mathrm{dLeb}$, les X_i sont i.i.d., on en déduit que

$$2\theta^{-1} \sum_{i=1}^{n} X_i \sim \chi^2(2n)$$

sous $p_\theta \cdot \mathrm{dLeb}$.

Rque. On dit que $2\theta^{-1} \sum_{i=1}^n X_i$ est une *fonction pivotale* puisque sa loi est indépendante de θ sous $p_\theta \cdot \mathrm{dLeb}$, et ce pour tout $\theta \in \Theta$.

(b) Plusieurs idées pour proposer un estimateur :

i. Une loi exponentielle de paramètre τ est une loi Gamma de paramètres $(1, \tau)$. En utilisant le rappel, il vient que son espérance est $1/\tau$. Donc $\mathbb{E}_\theta[X_1] = \theta$; en utilisant la méthode des moments, on fait la proposition

$$\hat{\theta}_n = \frac{1}{n} \sum_{k=1}^{n} X_k.$$

ii. Par une approche maximum de vraisemblance : la vraisemblance est donnée par

$$\theta \mapsto \theta^{-n} \exp\left(-\theta^{-1} \sum_{i=1}^{n} X_i\right) \mathbb{1}_{X_1>0,\cdots,X_n>0}$$

et la log-vraisemblance normalisée est donnée par

$$\theta \mapsto -\log\theta - \frac{1}{\theta}\frac{1}{n}\sum_{i=1}^{n} X_i$$

si $(X_1, \cdots, X_n) \in (\mathbb{R}^+)^n$ et par $-\infty$ sinon. Lorsque $\theta \to 0$, cette fonction tend vers $-\infty$; et lorsque $\theta \to +\infty$ elle tend aussi vers $-\infty$. Son gradient possède une seule racine donnée par

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^{n} X_i$$

5. Soit h une fonction mesurable positive. Nous avons

$$\begin{aligned}\mathbb{E}[h(\lambda Y)] &= C_{a,b} \int_0^{+\infty} h(\lambda y) y^{a-1} \exp(-by)\mathrm{d}y \\ &= C_{a,b}\lambda^{-a} \int_0^{+\infty} h(\lambda y)(\lambda y)^{a-1} \exp(-b(\lambda y)/\lambda)\lambda \mathrm{d}y \\ &= \tilde{C} \int_0^{+\infty} h(z) z^{a-1} \exp(-bz/\lambda)\mathrm{d}z.\end{aligned}$$

qui est un maximum de la vraisemblance. Par suite, la moyenne empirique est l'estimateur du maximum de vraisemblance.

iii. La loi exponentielle est un élément de la famille de loi dite "exponentielle" ; le paramétrage proposé fait qu'il n'est pas dans la famille "canonique" mais dans la famille "généralisée" (voir PC2, exercice 3). Dans le paramétrage canonique ($\lambda \leftarrow 1/\theta$), l'estimateur du maximum de vraisemblance et celui des moments associé à la statistique $T(x) = x$ sont égaux (voir PC2 exercice 2) et nous avons donc

$$\hat{\lambda}_n^{MV} = \frac{1}{\frac{1}{n}\sum_{i=1}^n X_i}.$$

Puisque $\theta = \phi(\lambda)$ avec le difféomorphisme ϕ sur $\mathbb{R}^+$ donné par $\phi(t) = 1/t$, nous avons donc (voir PC2 exercice 3)

$$\hat{\theta}_n^{MV} = \phi\left(\hat{\lambda}_n^{MV}\right) = \frac{1}{n}\sum_{i=1}^n X_i.$$

(c) Construisons le test. *Intuition : on vient de voir la relation entre espérance et paramètre du modèle, et donc entre moyenne empirique et paramètre du modèle. On peut donc utiliser cette information pour proposer une façon de traduire une "distance" entre le paramètre du modèle et la valeur du paramètre testée par H_0. On sait que pour définir le seuil critique, il nous faudra être capable de trouver la loi de la statistique de test proposée. La question précédente, qui identifie une fonction pivotale, nous conduit à poser une statistique de test de la forme de cette fonction pivotale.*

(A) choix de la statistique de test. L'idée est donc de définir une zone de rejet à l'aide de la statistique de test

$$T(Z) = \frac{1}{n\theta_0}\sum_{k=1}^n X_k - 1$$

qui doit être proche de zero sous H_0, tandis qu'elle est "très supérieure à zero" sous H_1.

(B) Forme de la zone de rejet. Cela amène à poser une zone de rejet de la forme

$$\mathcal{R} = \{z \in (\mathbb{R}_+)^n, T(z) > c\}.$$

(C) Détermination du seuil critique c. Il faut calibrer le seuil critique c pour que l'erreur de première espèce soit au plus α. On cherche donc c tel que la quantité

$$\sup_{\theta\in\Theta_0} \mathbb{P}_\theta(Z \in \mathcal{R}) = \mathbb{P}_{\theta_0}(Z \in \mathcal{R}) = \mathbb{P}_{\theta_0}(T(Z) > c)$$

soit inférieure ou égale à α. En exploitant la fonction pivotale trouvée à la question précédente, on a

$$\begin{aligned}\mathbb{P}_{\theta_0}(T(Z) > c) &= \mathbb{P}_{\theta_0}\left(\frac{1}{n\theta_0}\sum_{k=1}^n X_k > c+1\right) = \mathbb{P}_{\theta_0}\left(\frac{2}{\theta_0}\sum_{k=1}^n X_k > 2n(c+1)\right)\\ &= \mathbb{P}(W > 2n(c+1)) = 1 - \mathbb{P}(W \le 2n(c+1))\end{aligned}$$

où W désigne une v.a. qui suit une loi $\chi^2(2n)$. Puisque la fonction de répartition de cette v.a. est une fonction continue, on cherche le seuil pour que cette quantité soit exactement égale à α ; on résoud donc

$$2n(c+1) = q_{1-\alpha}^{\chi^2(2n)}$$

où $q_{1-\alpha}^{\chi^2(2n)}$ désigne le quantile d'ordre $1-\alpha$ d'une loi du $\chi^2(2n)$.
(D) Conclusion Le test est défini par la zone de rejet

$$\mathcal{R} = \{z \in (\mathbb{R}_+)^n, \frac{2}{\theta_0}\sum_{k=1}^{n} z_k > q_{1-\alpha}^{\chi^2(2n)}\}$$

(d) La fonction puissance, définie sur $\Theta_0 \cup \Theta_1$ est donnée par

$$\forall \theta \geq \theta_0 \qquad \mathbb{P}_\theta[Z \in \mathcal{R}] = \mathbb{P}_\theta\left(\frac{2}{\theta_0}\sum_{k=1}^{n} X_k > q_{1-\alpha}^{\chi^2(2n)}\right)$$
$$= \mathbb{P}_\theta\left(\frac{2}{\theta}\sum_{k=1}^{n} X_k > \frac{\theta_0}{\theta} q_{1-\alpha}^{\chi^2(2n)}\right) = \mathbb{P}\left(W > \frac{\theta_0}{\theta} q_{1-\alpha}^{\chi^2(2n)}\right)$$

où $W \sim \chi^2(2n)$.
Comme H_0 est une hypothèse simple, l'erreur de première espèce est $\mathbb{P}_{\theta_0}(Z \in \mathcal{R}) = \alpha$; la taille et le niveau coincident.
Sur la figure 4, on trace la fonction puissance $\theta \mapsto \mathbb{P}_\theta(Z \in \mathcal{R})$ pour différentes valeurs de n. On observera que, compte-tenu de la façon dont le seuil critique a été calibré, toutes ces fonctions puissance valent 0.05 en $\theta = \theta_0 = 2$. On observe aussi que pour $\theta > \theta_0$ fixé, $n \mapsto \mathbb{P}_\theta(\mathcal{R})$ est une fonction croissante et qu'elle tend vers 1.

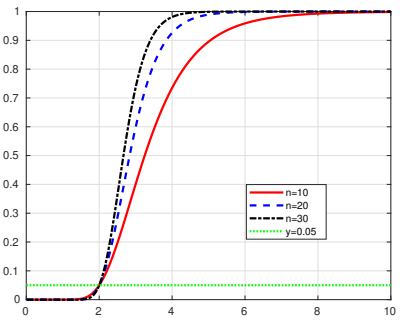


FIGURE 4 – Pour différentes valeurs de n, fonction puissance du test $\theta \mapsto \mathbb{P}_\theta(T(Z) > c_\alpha)$ lorsque $\alpha = 0.05$. On trace aussi en trait horizontal la droite d'équation $y = \alpha$.

(e) Soient $\alpha < \alpha'$. Alors $q_{1-\alpha} > q_{1-\alpha'}$ et $R_\alpha \subset R_{\alpha'}$. Dans ce contexte, la p-valeur est le plus petit niveau $\alpha(Z)$ à partir duquel le test sera rejeté compte-tenu de la valeur de la statistique $T(Z)$ associée à l'observation Z.

Si nous observons Z, et donc la statistique $T(Z) := \sum_{i=1}^n X_i/(2\theta_0)$, le test est rejeté si $T(Z) > q_{1-\alpha}^{\chi^2(2n)}$. Donc la p-valeur $\alpha(Z)$ est solution de

$$T(Z) = q_{1-\alpha(Z)}^{\chi^2(2n)}$$

soit encore

$$\alpha(Z) = \mathbb{P}(W > \frac{2s}{\theta_0})|_{s=\sum_{i=1}^n X_i},$$

où $W \sim \chi^2(2n)$.
Pour $\theta_0 = 2, n = 10$ et pour l'observation $(x_1, \cdots, x_n)$ donnée, on obtient que $2\sum_{i=1}^n x_i/\theta_0 = 28.1$ et la p-valeur vaut

$$\mathbb{P}\left(\chi^2(20) \geq 28.1\right) \simeq 10.7\%.$$

Aussi, on accepte H_0 au seuil 5%. On la rejetterait au seuil 11%. Sur la figure 5, on trace la densité de $T(Z)$ sous H_0 pour différentes valeurs de n. On a aussi indiqué par un trait vertical, la valeur $t_\star$ de $T(Z)$ calculée sur l'échantillon fourni dans l'énoncé. Ob observe que $n \mapsto \mathbb{P}_{\theta_0}(T(Z) > t_\star)$ est une fonction croissante.

2. (a) Pour l'hypothèse composite $H_0 = \{\theta \leq \theta_0\}$ contre $H_1 = \{\theta > \theta_0\}$, la région de rejet du test est définie par

$$R'_\alpha = \{z = (x_1, \cdots, x_n) \in (\mathbb{R}_+)^n : \frac{2}{\theta_0}\sum_{k=1}^n x_k > d\},$$

pour un seuil critique d à déterminer en fonction du niveau du test.

(b) La fonction puissance du test est définie par

$$\theta \mapsto \mathbb{P}_\theta\left(2\theta_0^{-1}\sum_{k=1}^n X_k > d\right) = \mathbb{P}\left(\chi^2(2n) > d\,\theta_0\theta^{-1}\right).$$

C'est une fonction croissante de θ et donc la taille du test est :

$$\sup_{\theta\in H_0}\mathbb{P}_\theta\left(2\theta_0^{-1}\sum_{k=1}^n X_k > d\right) = \mathbb{P}_{\theta_0}\left(2\theta_0^{-1}\sum_{k=1}^n X_k > d\right) = \mathbb{P}\left(\chi^2(2n) > d\right).$$

Pour un test de niveau α, $d = q_{1-\alpha}^{\chi^2(2n)}$. Puisque le test est identique à celui du premier jeu d'hypothèses (H_0, H_1), la p-valeur est également identique.

3. **Intervalles de confiance.**

(a) *IC bilatéral exact pour θ.* Sous $p_\theta \cdot \mathrm{dLeb}$, la v.a.

$$T(\theta, (X_i)_{i=1,\ldots,n}) := \frac{2}{\theta}\sum_{i=1}^n X_i$$

est une *fonction pivotale* de loi $\chi^2(2n)$ (sa loi ne dépend pas de θ). Pour $0 < \alpha < 1$,

$$\mathbb{P}_\theta\Big(q_{\alpha/2}^{\chi^2(2n)} \leq T(\theta, (X_i)_{i=1,\ldots,n}) \leq q_{1-\alpha/2}^{\chi^2(2n)}\Big) = 1 - \alpha.$$

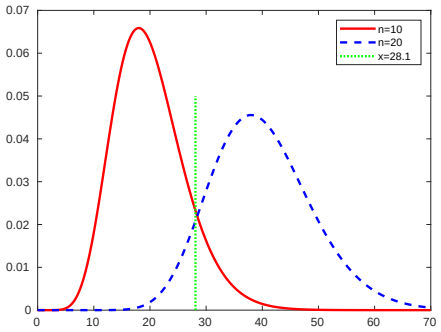


FIGURE 5 – Pour différentes valeurs de n, densité de la v.a. $T(Z) = 2\sum_{k=1}^{n} X_k/\theta_0$ sous p_{θ_0} dLeb.

En remplaçant $T(\theta, (X_i)_{i=1,\dots,n})$ et en inversant les inégalités relativement à θ, on a pour tout θ

$$\mathbb{P}_\theta\left(\frac{2\sum_{i=1}^{n} X_i}{q_{1-\alpha/2}^{\chi^2(2n)}} \leq \theta \leq \frac{2\sum_{i=1}^{n} X_i}{q_{\alpha/2}^{\chi^2(2n)}} \right) = 1-\alpha$$

d'où l'IC bilatéral exact de niveau $1-\alpha$.

(b) *Bornes unilatérales exactes pour θ.*

— pour la orne **supérieure seule** : on veut $\mathbb{P}_\theta(\theta \leq U) = 1-\alpha$. Or $\{\theta \leq U\} \Leftrightarrow \{T(\theta, (X_i)_{i=1,\dots,n}) \geq 2\sum X_i/U\}$. Comme $\mathbb{P}_\theta(T(\theta, (X_i)_{i=1,\dots,n}) \geq q_\alpha^{\chi^2(2n)}) = 1-\alpha$, on pose $2\sum X_i/U = q_\alpha^{\chi^2(2n)}$ et

Pour tout θ,

$$\mathbb{P}_\theta\left(\theta \in \left]-\infty; \frac{2\sum_{i=1}^{n} X_i}{q_\alpha^{\chi^2(2n)}}\right]\right) = 1-\alpha.$$

— pour la borne **inférieure seule** : on veut $\mathbb{P}_\theta(\theta \geq L) = 1-\alpha$. Or $\{\theta \geq L\} \Leftrightarrow \{T(\theta,(X_i)_{i=1,\dots,n}) \leq 2\sum X_i/L\}$. Comme $\mathbb{P}_\theta(T(\theta,(X_i)_{i=1,\dots,n}) \leq q_{1-\alpha}^{\chi^2(2n)}) = 1-\alpha$, on pose $2\sum X_i/L = q_{1-\alpha}^{\chi^2(2n)}$ et
Pour tout θ,

$$\mathbb{P}_\theta\left(\theta \in \left[\frac{2\sum_{i=1}^n X_i}{q_{1-\alpha}^{\chi^2(2n)}}; +\infty\right[\right) = 1-\alpha.$$

(c) *Application numérique* POur les valuers des quantiles, voir : `https://homepage.divms.uiowa.edu/~mbognar/applets/chisq.html` par exemple
($\alpha = 5\%$, $n = 10$, $\sum X_i = 28.1$, donc $2n = 20$ et $2\sum X_i = 56.2$). Avec

$$q_{0.025}^{\chi^2(20)} \approx 9.59, \quad q_{0.975}^{\chi^2(20)} \approx 34.17,$$

on obtient :

$$\mathrm{IC}_{95\%}(\theta) = \left[\ \tfrac{56.2}{34.17}\ ,\ \tfrac{56.2}{9.59}\right] \approx [1.64,\ 5.79],$$

2.2 Exercice 2

Observons tout d'abord que, sous $p_\mu \mathrm{dLeb}$, $\overline{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$ de sorte que

$$T(Z) \sim \left| \mathcal{N}\left(\frac{\sqrt{n}}{\sigma}(\mu - \mu_0); 1 \right) \right|.$$

Pour tout $c > 0$, on définit un test dont la zone de rejet est de la forme $\{T(Z) > c\}$.

1. La fonction puissance est donnée par

$$\mu \mapsto \beta_c(\mu) := \mathbb{P}_\mu(T(Z) > c) = \mathbb{P}\left(\left| \frac{\sqrt{n}}{\sigma}(\mu - \mu_0) + W \right| > c \right)$$

où $W \sim \mathcal{N}(0,1)$. En notant Φ la fonction de répartition d'une loi gaussienne $\mathcal{N}(0,1)$, il vient

$$\begin{aligned}
\beta_c(\mu) &= 1 - \mathbb{P}\left(\left| \frac{\sqrt{n}}{\sigma}(\mu - \mu_0) + W \right| \leq c \right) \\
&= 1 - \mathbb{P}\left(\frac{\sqrt{n}}{\sigma}(\mu_0 - \mu) - c \leq W \leq \frac{\sqrt{n}}{\sigma}(\mu_0 - \mu) + c \right) \\
&= 1 - \Phi\left(\frac{\sqrt{n}}{\sigma}(\mu_0 - \mu) + c \right) + \Phi\left(\frac{\sqrt{n}}{\sigma}(\mu_0 - \mu) - c \right).
\end{aligned}$$

Sur la figure 6, on trace cette fonction puissance dans le cas $\mu_0 = 0$, $\sigma = 1$ et pour une valeur du seuil critique c garantissant $\mathbb{P}_{\mu_0}(T(Z) > c) = 0.05$ (i.e. un test du niveau 5%). On envisage différentes valeurs de n.

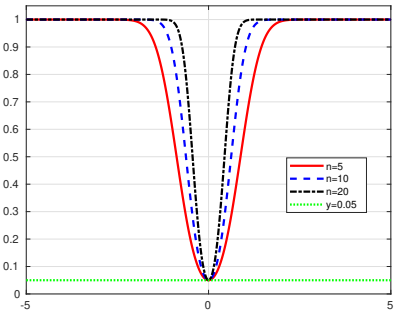


FIGURE 6 – Fonction puissance $\mu \mapsto \beta_c(\mu)$ pour différentes valeurs de n. On a pris $\mu_0 = 0$, $\sigma = 1$ et $c = \Phi^{-1}(0.975)$. On trace aussi la droite d'équation $y = 0.05$.

2. Le risque de première espèce $\overline{\alpha}_c$ est égal à

$$\overline{\alpha}_c = \mathbb{P}_{\mu_0}\left(T(Z) > c\right) = \beta_c(\mu_0) = 1 - \Phi(c) + \Phi(-c) = 2\left(1 - \Phi(c)\right)$$

en utilisant que $\Phi(-c) = 1 - \Phi(c)$.
Soit $\alpha \in (0,1)$. Le seuil critique c_α doit vérifier $\overline{\alpha}_{c_\alpha} = \alpha$, i.e. c_α est solution de

$$2\left(1 - \Phi(c)\right) = \alpha$$

donc

$$c_\alpha := \Phi^{-1}\left(1 - \frac{\alpha}{2}\right).$$

3. Soient $0 \leq \alpha < \alpha' \leq 1$; alors $c_\alpha > c_{\alpha'}$ donc $\{z : T(z) > c_\alpha\} \subset \{z : T(z) > c_{\alpha'}\}$. Puis

$$\mathbb{P}_{\mu_0}\left(T(Z) > c_\alpha\right) \leq \mathbb{P}_{\mu_0}\left(T(Z) > c_{\alpha'}\right).$$

La p-valeur est définie comme

$$\inf\{\alpha \in [0,1] \ : T(Z) > c_\alpha\}\ .$$

Puisque $\alpha \mapsto c_\alpha$ est décroissante et bijective de $]0,1[$ dans $\mathbb{R}_+$, la solution est donc $\alpha \in [0,1]$ tel que $T(Z) = c_\alpha$ soit

$$\hat{\alpha}(Z) := 2\left(1 - \Phi(T(Z))\right).$$

`Densité de` $T(Z)$ `sous` p_μ dLeb. On peut vérifier que si $X \sim \mathcal{N}(\nu, 1)$ alors la densité de $|X|$ est donnée par

$$x \mapsto \frac{1}{\sqrt{2\pi}}\left(\exp(-0.5(x-\nu)^2) + \exp(-0.5(x+\nu)^2)\right)\mathbb{1}_{\mathbb{R}_+}(x).$$

On donne en Figure 7 l'allure de la densité de $|\mathcal{N}(\nu, 1)|$ pour différentes valeurs de ν.

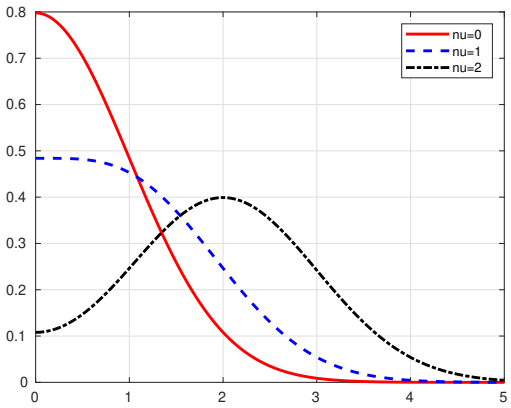


FIGURE 7 – Densité de $|X|$ (à une constante multiplicative près) lorsque $X \sim \mathcal{N}(\nu, 1)$.

4. Soit $\mathbf{1}$ le vecteur de $\mathbb{R}^n$ de coordonnées $(1, \ldots, 1)$, I_n la matrice identité de taille $n \times n$ et Π la projection orthogonale sur la droite engendrée par $\mathbf{1}$. On a

$$\overline{X}_n = \frac{1}{n}\mathbf{1}^T \Pi Z, \qquad S_n^2 = \frac{1}{n-1}\left\|(I_n - \Pi)Z\right\|^2 \ .$$

Observons que $\Pi(I_n - \Pi)^T = \Pi(I_n - \Pi) = 0$; de plus, sous p_θ dLeb, $Z \sim \mathrm{N}_n(\mu\mathbf{1}, \sigma^2 I_n)$ donc

$$\Pi Z \sim \mathrm{N}_n(\mu\mathbf{1}, \sigma^2\Pi), \qquad (I_n - \pi)Z \sim \mathrm{N}_n(0_{\mathbb{R}^n}, \sigma^2(I_n - \Pi));$$

cela entraine que le vecteur de $\mathbb{R}^{2n}$ obtenu en concaténant $(\pi Z, (I - \pi)Z)$, est un vecteur gaussien (et en particulier, chacun des deux blocs l'est). Ces deux vecteurs sont de plus indépendants : la matrice de covariance du vecteur $(\Pi Z, (I - \Pi)Z) \in \mathbb{R}^{2n}$ est diagonale par bloc puisque le bloc hors diagonal vaut

$$\mathbb{E}_\theta\left[\Pi(Z - \mu\mathbf{1})\,(Z - \mu\mathbf{1})^T(I_n - \Pi)\right] = \sigma^2\Pi(I_n - \Pi) = 0_{\mathbb{R}^{n\times n}}.$$

Par suite, $\overline{X_n}$ et S_n^2 sont indépendants sous p_θ dLeb.

5. Sous $p_\theta \, \mathrm{dLeb}$, $Z \sim \mathrm{N}_n(\mu \mathbf{1}, \sigma^2 I_n)$ donc $(I_n - \Pi)Z \sim \mathrm{N}_n(0_{\mathbb{R}^n}, \sigma^2(I_n - \Pi))$. $I_n - \Pi$ est une matrice de la forme $Q\Delta Q^T$ avec Q matrice orthogonale et Δ matrice diagonale dont les éléments diagonaux dont 0 (1 fois) et 1 ($n-1$ fois). Il vient

$$(n-1)\frac{S_n^2}{\sigma^2} = \left\| (I_n - \Pi)\frac{Z}{\sigma} \right\|^2 = \left\| Q^T(I_n - \Pi)\frac{Z}{\sigma} \right\|^2 = \|W\|^2 \ ,$$

où $W \sim \mathrm{N}_n(0, \Delta)$. On en déduit que, sous $p_\theta \, \mathrm{dLeb}$, la loi de $(n-1)S_n^2/\sigma^2$ est $\chi^2(n-1)$

6. Sous $p_\theta \, \mathrm{dLeb}$,

$$\sqrt{n}\frac{\overline{X}_n - \mu_0}{\sigma} \sim \mathrm{N}\left(\frac{\sqrt{n}}{\sigma}(\mu - \mu_0), 1\right) = \frac{\sqrt{n}}{\sigma}(\mu - \mu_0) + \mathrm{N}(0,1)$$

et

$$\frac{S_n}{\sigma} = \sqrt{\frac{(n-1)S_n^2}{\sigma^2(n-1)}} \sim \sqrt{\chi^2(n-1)}$$

et les deux v.a. sont indépendantes. On déduit du rappel B que

$$\frac{\sqrt{n}(\overline{X}_n - \mu_0)}{S_n}$$

suit une loi de Student décentrée à $n-1$ degrés de liberté, de paramètre de non-centralité $\gamma = \sqrt{n}(\mu - \mu_0)/\sigma$.

7. Notons t la fonction de répartition d'une loi de Student (centrée) à $n-1$ degrés de liberté. En répétant les arguments de la question 2, on obtient cette fois que la taille du test est égale à $\overline{\alpha}_c = 2\,(1 - t(c))$, en utilisant que $t(-c) = 1 - t(c)$.

8. Pour garantir un test de niveau α, il faut choisir c tel que $2(1 - t(c)) \leq \alpha$. Toute valeur de c supérieure à x_α défini par

$$c_\alpha := t^{-1}\,(1 - \alpha/2)$$

vérifie cette condition. Néanmoins, un critère basé sur la puissance du test nous amène à choisir la zone de rejet la plus grande possible (parmi toutes celles satisfaisant le contrôle de l'erreur de première espèce) et c'est la raison pour laquelle on prendra c_α comme seuil critique.

9. En répétant les arguments de la question 3, on trouve maintenant que la p-valeur du nouveau test est donnée par $\widehat{\alpha}(Z) = 2(1 - t(T(Z)))$.

2.3 Exercice 3

Sous $\mathbb{P}_\theta$, les v.a. $\{X_i\}_i$ sont i.i.d. de loi uniforme sur $[0,\theta]$.

1. On a, pour tout $x<0$, $\mathbb{P}_\theta(X_{n:n}/\theta \le x)=0$, pour tout $x>1$, $\mathbb{P}_\theta(X_{n:n}/\theta \le x)=1$ et, pour tout $x\in[0,1]$,

$$\mathbb{P}_\theta(X_{n:n}/\theta \le x) = \mathbb{P}_\theta\left(\cap_{i=1}^n \{X_i \le \theta x\}\right) = x^n \ .$$

La loi de $X_{n:n}/\theta$ sous $\mathbb{P}_\theta$ ne dépend donc pas de θ, donc $X_{n:n}/\theta$ est une fonction pivotale. Sur la figure 8, on trace la densité $x\mapsto nx^{n-1}$ sur $[0,1]$ pour différentes valeurs de $n>1$. On trace aussi la densité de $\theta/X_{n:n}$, qui sous $\mathbb{P}_\theta$ est $y\mapsto ny^{-(n+1)}$ sur $[1,+\infty[$; en effet, pour toute fonction g mesurable positive, nnous avons

$$\mathbb{E}_\theta\left[g\left(\frac{\theta}{X_{n:n}}\right)\right] = \int_{0,1} g(1/x)nx^{n-1}\mathrm{d}x = \int_1^{+\infty} g(y)\frac{n}{y^{n+1}}\mathrm{d}y.$$

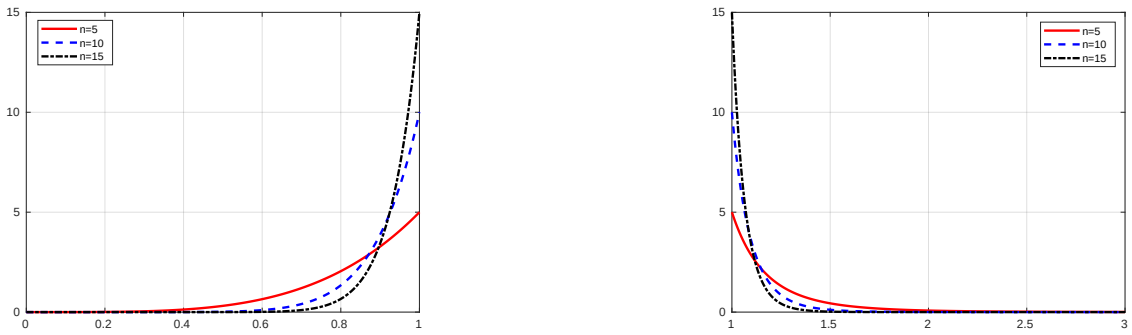


FIGURE 8 – Exercice 3. Pour différentes valeurs de $n\in\{5,10,15\}$, on trace [gauche] la densité $x\mapsto nx^{n-1}$ sur $[0,1]$ et [droite] la densité $y\mapsto ny^{-(n+1)}$ pour $y\ge 1$.

2. Soit

$$I := \left[X_{n:n}, \frac{X_{n:n}}{\alpha^{1/n}}\right], \tag{1}$$

on a

$$\mathbb{P}_\theta(\theta\in I) = \mathbb{P}_\theta(X_{n:n}/\theta \in [\alpha^{1/n},1]) = 1-[\alpha^{1/n}]^n = 1-\alpha \ .$$

Donc I est un intervalle de confiance pour θ au niveau $1-\alpha$. Vérifions que sa longueur est minimale parmi les intervalles $I_{a,b}$ de la forme $[X_{n:n}/a, X_{n:n}/b]$.

Step A. Pour être un intervalle de confiance de niveau $1-\alpha$, il faut que a et b satisfassent

$$\mathbb{P}_\theta(\theta\in I_{a,b}) = \mathbb{P}_\theta(X_{n:n}/\theta\in[b,a]) = (a\wedge 1)^n - (b\vee 0)^n \ge 1-\alpha \ .$$

On peut se restreindre à $a\le 1$ et $b\ge 0$. Donc on cherche $0\le b<a\le 1$ tels que $a^n \ge 1-\alpha+b^n$.

Step B. La longueur de l'intervalle est $\ell = 1/b - 1/a$; la condition précédente entraine

$$\ell \geq \frac{1}{a}\left(\frac{1}{(1-a^{-n}(1-\alpha))^{1/n}} - 1\right) \quad .$$

Cette fonction étant clairement décroissante en a sur $\mathbb{R}_+^*$, la borne inférieure sur ℓ est minimale (assurant donc la longueur la plus petite possible) lorsque $a = 1$.

Step C. Ainsi, les conditions que nous avons sur b, sont d'une part $\alpha^{1/n} \geq b \geq 0$ et d'autre part $\ell \geq \alpha^{-1/n} - 1$. Puisqu'on veut la longueur minimale, il faut prendre $\ell = \alpha^{-1/n} - 1$ et donc $1/b = \alpha^{-1/n}$. On retrouve bien l'intervalle de confiance proposé en (1).

2.4 Exercice 4

Rappels. On rappelle que l'espérance d'une loi de Poisson de paramètre $\lambda > 0$ est λ.

1. Si $X \sim \mathcal{P}(\theta_1)$ et $Y \sim \mathcal{P}(\theta_2)$ et si X et Y sont indépendantes, alors $X+Y \sim \mathcal{P}(\theta_1+\theta_2)$.
Compléments. Cela peut se démontrer à l'aide de la fonction génératrice des moments $G_U(s) = \mathbb{E}[s^U]$ pour tout $s \in \mathbb{R}$ pour lequel cette espérance existe. En utilisant l'expression de la loi de Poisson, on a $G_X(s) = \exp(-\theta_1(1-s))$. De même $G_Y(x) = \exp(-\theta_2(1-s))$. Si X et Y sont indépendantes, alors $G_{X+Y} = G_X G_Y$ donc $G_{X+Y}(s) = \exp(-(\theta_1+\theta_2)(1-s))$; cette expression est celle d'une fct génératrice de Poisson de paramètre $\theta_1+\theta_2$. On conclut en rappelant que la fonction génératrice d'une v.a. caractérise sa loi
Puisque sous $p_\theta \cdot \mathrm{d}\mu$, les v.a. $(X_i)_i$ sont i.i.d. de même loi de Poisson de paramètre θ, il vient que $\sum_{i=1}^n X_i \sim \mathcal{P}(n\theta)$.
2. Posons $Z = (X_1, \cdots, X_n)$.
(A) Avoir l'idée d'une statistique. On utilise la statistique

$$T(Z) = \sum_{i=1}^{n} X_i.$$

(B) Etablir la loi de cette statistique sous $p_\theta \cdot \mathrm{d}\mu$, pour θ satisfaisant H_0. Lorsque $\theta = 1$ i.e. sous H_0, la loi de $T(Z)$ est une loi de Poisson de paramètre n, et son espérance est n.
(C) Proposer une forme de zone de rejet. Lorsque $\theta = 2$ i.e. sous H_1, la loi de $T(Z)$ est une loi de Poisson de paramètre $2n$ et son espérance est $2n$. Aussi, $T(Z)$ aura tendance à prendre des valeurs plus grandes sous H_1 que sous H_0. Cela incite à poser une région de rejet de la forme

$$R_\alpha := \{z \in \mathbb{N}^n \, : \, T(z) > c_\alpha\}$$

(D) Déterminer le seuil critique On calibre alors c_α pour que l'erreur de première espèce soit au plus la tolérance donnée, à savoir α : on cherche c_α tel que

$$\mathbb{P}_1\left(T(Z) > c_\alpha\right) \leq \alpha,$$

ou encore

$$\mathbb{P}_1\left(T(Z) \leq c_\alpha\right) > 1-\alpha.$$

Ainsi,

$$c_\alpha = \inf\{t \in \mathbb{R} \, : \, F_{\mathcal{P}(10)}(t) > 1-\alpha\}.$$

Pour l'application numérique, on constate que $1-\alpha = 0.95$ et que

$$F_{\mathcal{P}(10)}(14) \simeq 0.917, \qquad F_{\mathcal{P}(10)}(15) \simeq 0.951.$$

On en déduit donc que $c_{5\%} = 15$. La zone de rejet du test est donc

$$R_{0.05} := \left\{z \in \mathbb{N}^{10} \, : \, T(z) > 15\right\}.$$

(E) Taille du test La taille de ce test est donnée par

$$\mathbb{P}_1(T(Z) > 15) = \mathbb{P}(\mathcal{P}(10) > 15) \simeq 4.9\% < 0.05.$$

On a donc ici un exemple de test pur dont le niveau et la taille diffèrent.

3. Comme l'hypothèse H_0 est simple, l'erreur de première espèce est donnée par

$$\sup_{\theta\in\Theta_0} \mathbb{P}_\theta(T(Z) > 15) = \mathbb{P}_1(T(Z) > 15) = 0.049.$$

On trace la fonction puissance de ce test sur la figure 9.

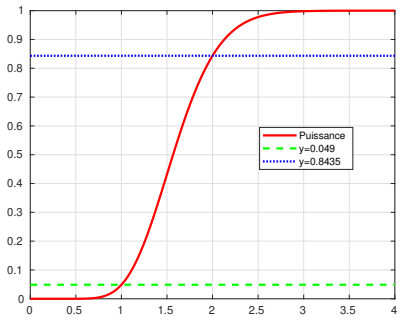


FIGURE 9 – Fonction puissance $\theta \mapsto \mathbb{P}_\theta(T(Z) > c_\alpha)$ du test.

4. Soient $0 < \alpha < \alpha' < 1$. La zone de rejet étant de la forme $\{T(Z) > c_\alpha\}$, il est aisé de voir que $c_{\alpha'} < c_\alpha$ et donc $R_\alpha \subseteq R_{\alpha'}$. La p-valeur est donc définie comme

$$\inf\{\alpha, Z \in R_\alpha\} = \inf_\alpha\{T(Z) > c_\alpha\}.$$

La monotonie de la zone de rejet en fonction de α montre que l'on cherche la zone de rejet la plus petite possible au sens de l'inclusion ; ici, $T(Z)$ ne prend que des valeurs entières, donc on a $c_{\alpha(Z)} = T(Z) - 1$. Par suite,

$$\alpha(Z) = \mathbb{P}(\mathcal{P}_{10} > T(Z) - 1) = 1 - \mathbb{P}(\mathcal{P}_{10} \leq T(Z) - 1)$$

Pour le premier jeu de données, la statistique $T(Z)$ vaut 18, donc $\alpha(Z) = 0.0143$; et pour le second, la statistique vaut $T(Z) = 13$ donc $\alpha(Z) = 0.2084$.

`Rque.` Pour le premier échantillon, on évalue la statistique $T(Z)$ et on obtient la valeur $t_1 = 18$. Cette valeur est dans la zone de rejet $R_{0.05} = \{z, T(z) > 15\}$ donc on rejette H_0 au niveau 5%.
Pour le second échantillon, on évalue la statistique $T(Z)$ et on obtient la valeur $t_2 = 13$. Cette fois, on accepte H_0 au niveau 5%. Deux situations : soit H_0 est vraie et on prend la bonne décision ; soit H_1 est vraie et en acceptant H_0, on se trompe avec une probabilité $\beta = 15.7\%$.

2.5 Exercice 5

1. La vraisemblance est donnée par (à une constante multiplicative près)

$$\theta \mapsto \frac{1}{\sigma^{n+p}} \exp\left(-0.5\sigma^{-2} \sum_{i=1}^{n} \{X_i - \mu_0\}^2 - 0.5\sigma^{-2} \sum_{j=1}^{p} \{Y_j - \mu_1\}^2 \right) .$$

On en déduit la log-vraisemblance

$$\theta \mapsto -\frac{(n+p)}{2} \ln \sigma^2 - 0.5\sigma^{-2} \sum_{i=1}^{n} \{X_i - \mu_0\}^2 - 0.5\sigma^{-2} \sum_{j=1}^{p} \{Y_j - \mu_1\}^2 .$$

Soit $Z := (X_1, \cdots, X_n, Y_1, \cdots, Y_p)$, la log-vraisemblance est maximisée en

$$\hat{\mu}_{0,n}(Z) := \frac{1}{n} \sum_{i=1}^{n} X_i,$$
$$\hat{\mu}_{1,p}(Z) := \frac{1}{p} \sum_{j=1}^{p} Y_j,$$
$$\hat{\sigma}^2_{n,p}(Z) := \frac{1}{n+p} \left(\sum_{i=1}^{n} (X_i - \hat{\mu}_{0,n})^2 + \sum_{j=1}^{p} (Y_j - \hat{\mu}_{1,p})^2 \right) .$$

Dans la suite, il nous arrivera d'omettre la dépendance en Z dans l'argument des $\hat{\mu}_{i,n}$ et de $\sigma^2_{n,p}$ pour simplifier l'écriture.

2. Dans cette question on omet la dépendance en Z des estimateurs. Il est naturel de penser à exploiter la statistique $\hat{\mu}_{0,n} - \hat{\mu}_{1,p}$ puisque sous $p_\theta \, \mathrm{dLeb}^{n+p}$,

$$\hat{\mu}_{0,n} - \hat{\mu}_{1,p} \sim \mathcal{N}\left(\mu_0 - \mu_1, \sigma^2 \left(\frac{1}{n} + \frac{1}{p} \right) \right) ,$$

ou de façon équivalente

$$\sqrt{\frac{np}{n+p}} \left\{ \frac{(\hat{\mu}_{0,n} - \hat{\mu}_{1,p}) - (\mu_0 - \mu_1)}{\sigma} \right\} \sim \mathcal{N}(0,1) .$$

σ^2 est inconnue ; on peut le remplacer par un estimateur

$$S^2_{n,p} := \frac{1}{n+p-2} \left(\sum_{i=1}^{n} (X_i - \hat{\mu}_{0,n})^2 + \sum_{j=1}^{p} (Y_j - \hat{\mu}_{1,p})^2 \right) = \frac{n+p}{n+p-2} \hat{\sigma}^2_{n,p}.$$

En procédant comme dans l'exercice 2, on montre que sous $p_\theta \, \mathrm{dLeb}^{n+p}$,

$S^2_{n,p}$ est indépendant de $\hat{\mu}_{0,n} - \hat{\mu}_{1,p}$.
$(n+p-2)S^2_{n,p}/\sigma^2 \sim \chi^2(n+p-2)$.

Par suite, en utilisant le Rappel C., sous $p_\theta \, \mathrm{dLeb}^{n+p}$,

$$\sqrt{\frac{np}{n+p}} \left\{ \frac{(\hat{\mu}_{0,n} - \hat{\mu}_{1,p}) - (\mu_0 - \mu_1)}{S_{n,p}} \right\} \sim t_{n+p-2} ,$$

où t_{n+p-2} désigne une loi de Student (centrée) de paramètre $n+p-2$. Notons t^u_{n+p-2} le quantile d'ordre u d'une loi de Student (centrée) à $n+p-2$ degrés de liberté. Alors un intervalle de confiance de niveau $1-\alpha$ est donné par

$$\left\{(\mu_0-\mu_1) : t^{\alpha/2}_{n+p-2} \leq \sqrt{\frac{np}{n+p}}\left\{\frac{(\hat{\mu}_{0,n}-\hat{\mu}_{1,p})-(\mu_0-\mu_1)}{S_{n,p}}\right\} \leq t^{1-\alpha/2}_{n+p-2}\right\};$$

soit encore

$$\mathcal{I}(Z) := \left[\hat{\mu}_{0,n}(Z)-\hat{\mu}_{1,p}(Z) \pm t^{1-\alpha/2}_{n+p-2}\sqrt{\frac{n+p}{np}}\, S_{n,p}(Z)\right]$$

en notant que $t^{\alpha/2}_{n+p-2} = -t^{1-\alpha/2}_{n+p-2}$.

Fonction pivotale Posons

$$G(Z,\theta) := \sqrt{\frac{np}{n+p}}\left\{\frac{(\hat{\mu}_{0,n}(Z)-\hat{\mu}_{1,p}(Z))-(\mu_0-\mu_1)}{S_{n,p}(Z)}\right\}$$

Alors pour tout θ,

$$\mathbb{P}_\theta(G(Z,\theta)\in A) = \mathbb{P}(W_{n+p-2}\in A) \qquad \text{où } W_{n+p-2}\sim t_{n+p-2}.$$

G est donc une fonction pivotale. On construit un intervalle de confiance de couverture $1-\alpha$:

$$\mathcal{I}_\alpha(Z) = \{\theta : G(\theta, Z)\in \mathcal{A}_\alpha\}$$

où on a choisi $\mathcal{A}_\alpha$ tel que $\mathbb{P}(W_{n+p-2}\in\mathcal{A}_\alpha) = 1-\alpha$. On choisit $\mathcal{A}_\alpha$ comme l'intervalle délimité par les quantiles d'ordre $\alpha/2$ et $1-\alpha/2$ d'une loi t_{n+p-2} ; car c'est le plus court des intervalles de probabilité $1-\alpha$ sous une loi t_{n+p-2}.

3. Posons le test défini par la zone de rejet

$$\mathcal{R}_\alpha := \left\{z\in\mathbb{R}^{n+p} : \sqrt{\frac{np}{n+p}}\frac{|\hat{\mu}_{0,n}(z)-\hat{\mu}_{1,p}(z)|}{S_{n,p}(z)} \geq t^{1-\alpha/2}_{n+p-2}\right\}.$$

Alors pour $\theta=(\mu_0,\mu_0,\sigma^2)\in\Theta_0$, on a

$$\mathbb{P}_\theta\left(Z\in\mathcal{R}_\alpha\right) = \alpha\,.$$

La taille du test de zone de rejet $\mathcal{R}_\alpha$ est α.

`Fonction pivotale` $\rightarrow$ `IC` $\rightarrow$ `test.` Le test défini ci-dessus est le même que celui de zone de rejet

$$\{z\in\mathbb{R}^{n+p} : G(z;\mu_0,\mu_0,\sigma^2)\notin\mathcal{A}_\alpha\} = \{z\in\mathbb{R}^{n+p} : |G(z;\mu_0,\mu_0,\sigma^2)|\geq t^{1-\alpha/2}_{n+p-2}\}.$$

4. Posons le test défini par la zone de rejet

$$\mathcal{R}_\alpha := \left\{z\in\mathbb{R}^{n+p} : \sqrt{\frac{np}{n+p}}\frac{(\hat{\mu}_{0,n}(z)-\hat{\mu}_{1,p}(z))}{S_{n,p}(z)} \geq t^{1-\alpha}_{n+p-2}\right\}.$$

Vérifions le niveau de ce test : pour tout θ tel que $\mu_0 - \mu_1 \leq 0$,

$$\begin{aligned}\mathbb{P}_\theta\left(Z \in \mathcal{R}_\alpha\right) &= \mathbb{P}_\theta\left(\sqrt{\frac{np}{n+p}}\frac{(\hat{\mu}_{0,n}(Z) - \hat{\mu}_{1,p}(Z))}{S_{n,p}(Z)} \geq t_{n+p-2}^{1-\alpha}\right) \\ &= \mathbb{P}_\theta\left(W_{n+p-2} + \sqrt{\frac{np}{n+p}}\frac{(\mu_0 - \mu_1)}{S_{n,p}(Z)} \geq t_{n+p-2}^{1-\alpha}\right),\end{aligned}$$

où $W_{n+p-2} \sim t_{n+p-2}$. Puisque $\mu_0 - \mu_1 \leq 0$, il vient

$$\begin{aligned}\mathbb{P}_\theta\left(Z \in \mathcal{R}_\alpha\right) &\leq \mathbb{P}_\theta\left(W_{n+p-2} + 0 \geq t_{n+p-2}^{1-\alpha}\right) \\ &= \mathbb{P}_{(\mu_0,\mu_0,\sigma^2)}\left(W_{n+p-2} + \sqrt{\frac{np}{n+p}}\frac{(\mu_0 - \mu_1)}{S_{n,p}(Z)} \geq t_{n+p-2}^{1-\alpha}\right) \\ &= \mathbb{P}\left(W_{n+p-2} \geq t_{n+p-2}^{1-\alpha}\right) = \alpha\,.\end{aligned}$$

Ainsi, on a montré que

$$\sup_{\theta:\mu_0-\mu_1\leq 0} \mathbb{P}_\theta(Z \in \mathcal{R}_\alpha) = \alpha$$

ce qui termine la démonstration du niveau (et de la taille) du test.

5. D'après la question 3, on cherche $\alpha(Z)$ tel que

$$\sqrt{\frac{np}{n+p}}\frac{|\hat{\mu}_{0,n}(Z) - \hat{\mu}_{1,p}(Z)|}{S_{n,p}(Z)} = t_{n+p-2}^{1-\alpha(Z)/2}$$

D'après les données du tableau, nous avons $n = p = 120$, $\hat{\mu}_{0,n}(z) = 75$, $\hat{\mu}_{1,n}(z) = 74.99$, et

$$S_{n,p}(z) = \sqrt{\frac{n}{n+p-2}8.72^2 + \frac{p}{n+p-2}6.54^2}.$$

Donc il faut résoudre

$$t_{238}^{1-\alpha(Z)/2} = 0.01.$$

On trouve $\alpha(Z) = 1 - 0.5040 = 0.4960$. Tout test de niveau raisonnable va donc accepter l'hypothèse nulle (consistance des deux correcteurs).

6. On a sous $p_\theta \,\mathrm{dLeb}^{n+p}$,

$$\begin{aligned}R_{n,1}(Z) &:= \sigma_0^{-2}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2 \sim \chi^2(n-1)\,, \\ R_{p,2}(Z) &:= \sigma_1^{-2}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2 \sim \chi^2(p-1)\,,\end{aligned}$$

et les deux v.a. $R_{n,1}(Z)$ et $R_{p,2}(Z)$ sont indépendantes car sont respectivement fonction des X_i, et des Y_j. On en déduit, en utilisant le Rappel D., que sous $p_\theta \,\mathrm{dLeb}^{n+p}$, la v.a.

$$G(Z;\theta) := \frac{\sigma_1^2}{\sigma_0^2}\frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2}$$

suit une loi de Fisher de paramètres $(n-1, p-1)$; c'est une loi indépendantes de θ. G est donc une fonction pivotale.

`Loi de Fisher.` On trace sur la figure 10 la densité d'une loi de Fisher pour deux jeux de paramètres.

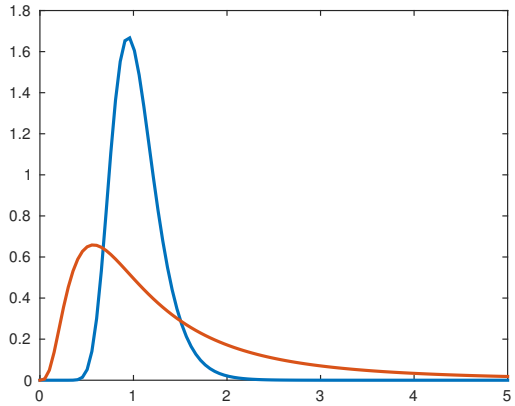


FIGURE 10 – Densité d'une loi de Fisher de paramètres $(10, 5)$ en rouge ; et $(100, 50)$ en bleu.

7. On propose le test de zone de rejet

$$\left\{ Z : \frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2} > f_{n-1,p-1}^{1-\alpha} \right\}$$

où $f_{n-1,p-1}^{1-\alpha}$ désigne le $(1-\alpha)$-quantile de la loi de Fisher de paramètres $(n-1, p-1)$. Etablissons le niveau de ce test. Notons $W_{n-1,p-1}$ une v.a. de loi de Fisher de paramètres $(n-1, p-1)$. Pour tout θ tel que $\sigma_0^2 \leq \sigma_1^2$, on a

$$\begin{aligned}
\mathbb{P}_\theta\left(\frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2} > f_{n-1,p-1}^{1-\alpha} \right) &= \mathbb{P}\left(\frac{\sigma_0^2}{\sigma_1^2} W_{n-1,p-1} > f_{n-1,p-1}^{1-\alpha} \right) \\
&= \mathbb{P}\left(W_{n-1,p-1} > \frac{\sigma_1^2}{\sigma_0^2}\, f_{n-1,p-1}^{1-\alpha} \right) \\
&\leq \mathbb{P}\left(W_{n-1,p-1} > \ f_{n-1,p-1}^{1-\alpha} \right).
\end{aligned}$$

D'une part

$$\mathbb{P}\left(W_{n-1,p-1} > \ f_{n-1,p-1}^{1-\alpha} \right) = \alpha$$

et d'autre part

$$\mathbb{P}\left(W_{n-1,p-1} > \ f_{n-1,p-1}^{1-\alpha} \right) = \mathbb{P}_{(\mu_0,\mu_1,\sigma_0^2,\sigma_0^2)}\left(\frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2} > f_{n-1,p-1}^{\alpha} \right)$$

ce qui montre que

$$\sup_{\theta:\sigma_0^2\leq\sigma_1^2} \mathbb{P}_\theta\left(\frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2} > f_{n-1,p-1}^{1-\alpha} \right) = \alpha.$$

8. Soit $T(Z) = \frac{(n-1)^{-1}\sum_{i=1}^{n}(X_i - \hat{\mu}_{0,n}(Z))^2}{(p-1)^{-1}\sum_{j=1}^{p}(Y_j - \hat{\mu}_{1,p}(Z))^2}$, la p-valeur du test est la plus petite valeur de α pour laquelle

$$T(Z) > f_{n-1,p-1}^{1-\alpha}\,.$$

En notant $F_{n-1,p-1}$ la fonction de répartition de la loi de Fisher de paramètres $n-1$ et $p-1$, on a $f^{1-\alpha}_{n-1,p-1} = F^{-1}_{n-1,p-1}(1-\alpha)$, c'est donc une fonction décroissante et bijective de $(0,1)$ dans $\mathbb{R}^*_+$ donc

$$\widehat{\alpha}(Z) = 1 - F_{n-1,p-1}(T(Z)) \ .$$

2.6 Exercice 6

Le modèle statistique est

$$(\{0,1\}^n, \mathcal{P}(\{0,1\}^n), \{\mathbb{P}_p = \otimes_{i=1}^n \mathcal{B}(p); p \in]0,1[\}) .$$

1. La proportion annoncée par le Ministère est $p_0 = 1/310\,000 \approx 3.23e-06$.
2. On prend un test dont la zone de rejet est de la forme $\{S_n > c\}$. Le risque de première espèce est
$$\sup_{p \le p_0} \mathbb{P}_p(S_n > c) = \mathbb{P}_{p_0}(S_n > c).$$
Démonstration de cette monotonie. Soit $p \le p_0$. Sous $\mathbb{P}_p$, S_n a même loi que $\sum_{k=1}^n \mathbb{1}_{U_k \le p}$ où $U_1, \cdots, U_n$ sont des v.a. i.i.d. uniformes sur $[0,1]$. Puisque
$$\sum_{i=1}^n \mathbb{1}_{U_i \le p} \le \sum_{i=1}^n \mathbb{1}_{U_i \le p_0},$$
il vient
$$\left\{ \sum_{i=1}^n \mathbb{1}_{U_i \le p} > c \right\} \subseteq \left\{ \sum_{i=1}^n \mathbb{1}_{U_i \le p_0} > c \right\}$$
dont on déduit que pour tout $p \le p_0$, $\mathbb{P}_p(S_n > c) \le \mathbb{P}_{p_0}(S_n > c)$.
On veut un test de niveau α, donc on prend c tel que $\mathbb{P}_{p_0}(S_n > c) \le \alpha$, en remarquant que sous $\mathbb{P}_{p_0}$, $S_n \sim \mathrm{Bin}(n, p_0)$. Posons
$$\begin{aligned} c_\alpha &:= \inf\{0 \le c \le n : \mathbb{P}_{p_0}(S_n > c) \le \alpha\} = \inf\{0 \le c \le n : \mathbb{P}_{p_0}(S_n \le c) \ge 1-\alpha\} \\ &= F_{p_0}^{-1}(1-\alpha) \end{aligned}$$
où F_b^{-1} désigne l'inverse généralisée de la fonction de répartition de la loi binomiale de paramètres $n = 300\,533$ et $p = p_0$.
Fonction de répartition de $\mathrm{Bin}(n, p_0)$**.** La figure 11(gauche) représente la fonction de répartition de la loi Binomiale de paramètres $n = 300\,533$ et p_0, sur $[-1.5; 5.5]$. On illustre aussi la détermination de $\inf\{0 \le c \le n : \mathbb{P}_{p_0}(S_n \le c) \ge 1-\alpha\}$ lorsque $\alpha = 0.05$ (en rouge) et $\alpha = 0.01$ (en vert). Voir aussi la figure de droite pour le tracé de la fonction de survie $x \mapsto \mathbb{P}_{p_0}(S_n > x)$.
3. Au niveau $\alpha = 0.05$, on trouve $c_\alpha = 3$; on relève $S_n = 4$ donc on rejette H_0. Pour $\alpha = 0.01$, on trouve $c_\alpha = 4$, donc on accepte H_0.
4. Si $\alpha < \alpha'$, alors $c_\alpha > c_{\alpha'}$ donc $\{S_n > c_\alpha\} \subset \{S_n > c_{\alpha'}\}$. On cherche donc
$$\inf\{\alpha \in [0,1] : S_n = 4 \in \mathcal{R}_\alpha\} = \inf\{\alpha \in [0,1] : 4 \in]c_\alpha, n]\} = \inf\{\alpha : c_\alpha = 3\}.$$
Donc on cherche α tel que
$$3 = F_b^{-1}(1-\alpha) \qquad \text{i.e.} \qquad \alpha = 1 - \mathbb{P}_{p_0}(S_n \le 3).$$
La p-valeur est 0.0172 (exactement 0.017172).
5. On attend $\theta_0 = 300\,533 \times p_0 = 300\,533/310\,000 \approx 0.9695$.

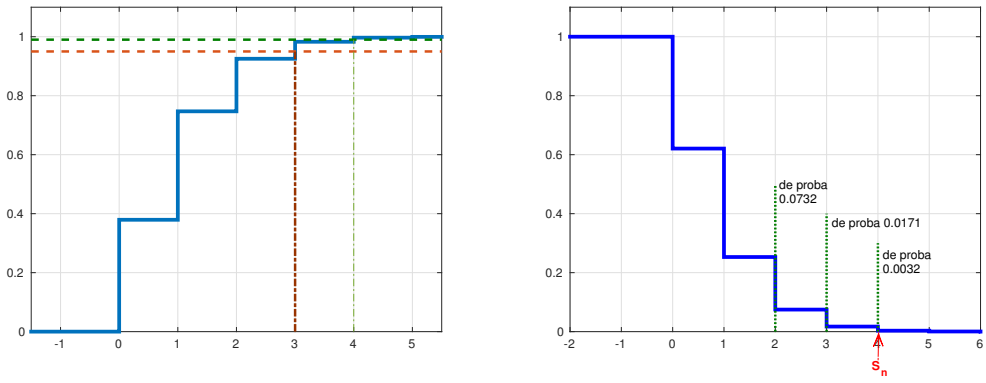


FIGURE 11 – (gauche) Fonction de répartition d'une loi binomiale avec $n = 300\,533$ et $p = p_0$. (droite) On trace $x \mapsto \mathbb{P}_{p_0}(S_n > x)$

2.6.1 Une façon de comprendre la formulation de la question 6 donnée en PC

On garde les mêmes hypothèses H_0 et H_1 que dans la première partie. La seule modification vient que l'on remplace la loi binômiale par une loi de Poisson pour calculer les cdf.

6. Les hypothèses nulle et alternative restent

$$H_0 : \quad \theta \leq \theta_0 \qquad H_1 : \theta > \theta_0.$$

On considère la famille de tests de zone de rejet de la forme $\{S_n > c\}$; et l'on choisit c tel que $\sup_{\theta \leq \theta_0} \mathbb{P}_\theta(S_n > c) \leq \alpha$. Puisque $\theta \mapsto \mathbb{P}_\theta(S_n > c)$ est croissante (voir la Figure 12), on choisit c tel que

$$\mathbb{P}_{\theta_0}(S_n > c) \leq \alpha.$$

Pour des considérations de puissance de test, on prendra le plus petit c qui vérifie cette condition. Posons

$$c_\alpha := \min\{c \geq 0 : \ \mathbb{P}_{\theta_0}(S_n > c) \leq \alpha\} = \min\{c \geq 0 : \ \mathbb{P}_{\theta_0}(S_n \leq c) \geq 1-\alpha\} = F^{-1}_{\theta_0}(1-\alpha),$$

où $F^{-1}_{\theta_0}$ désigne l'inverse généralisée de la fonction de répartition d'une loi de Poisson de paramètre θ_0. Le test associé est donc

$$\mathcal{R}_\alpha := \{n \in \mathbb{N} : n > c_\alpha\}.$$

7. On peut vérifier la monotonie des zones de rejet : si $\alpha < \alpha'$ alors $c_\alpha \geq c_{\alpha'}$ et donc $\mathcal{R}_\alpha \subset \mathcal{R}_{\alpha'}$. On cherche

$$\inf\{\alpha \in [0,1] : 4 > c_\alpha\} = \inf\{\alpha : c_\alpha = 3\} = 1 - F_{\theta_0}(3).$$

Il vient (probabilité calculée directement par $1 - \sum_{k=0}^{3} \theta_0^k/k! \exp(-\theta_0)$) :

$$\hat{\alpha}(S_n) = \mathbb{P}_{\theta_0}(S_n > 3) = 0.017173.$$

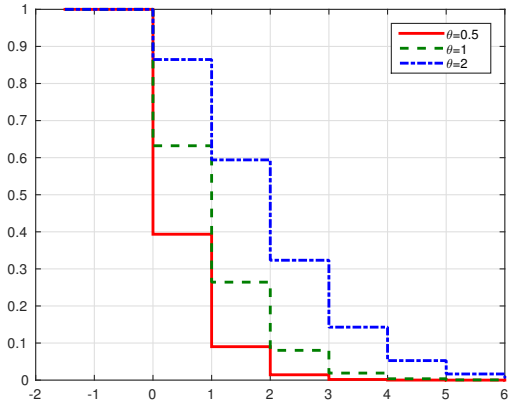


FIGURE 12 – Fonction de survie $x \mapsto \mathbb{P}_\theta(S_n > x)$ pour différentes valeurs de θ

2.6.2 Autre approche pour la question 6 : changer de point de vue

On change de point de vue. On se place du point de vue des patients.

jusqu'ici, via le risque de première espèce on a garanti que la procédure de test ne faisait pas l'erreur suivante dans plus de α% des cas : "affirmer que la probabilité que le vaccin a de graves effets secondaires est plus élevée que p_0, alors qu'en réalité elle ne l'est pas".

en fait, du point de vue du patient, il vaut mieux se protéger de l'erreur suivante "affirmer que la probabilité que le vaccin a de graves effets secondaires est inférieure à p_0, alors qu'en réalité, elle l'est". Pour le patient, le fait est que la probabilité réelle est plus élevée, et il attend que les données démontrent le contraire.

6. Les hypothèses nulle et alternative deviennent

$$H_0 : \quad \theta \geq \theta_0 \qquad H_1 : \theta < \theta_0.$$

On considère la famille de test de zone de rejet de la forme $\{S_n \leq c\}$; et l'on choisit c tel que $\sup_{\theta \geq \theta_0} \mathbb{P}_\theta(S_n \leq c) \leq \alpha$. Puisque $\theta \mapsto \mathbb{P}_\theta(S_n \leq c)$ est décroissante (voir la Figure 12), on choisit c tel que

$$\mathbb{P}_{\theta_0}(S_n \leq c) \leq \alpha.$$

Pour des considérations de puissance, on prendra le plus grand c qui vérifie cette condition. Posons

$$c_\alpha := \max\{c \in \mathbb{N} : \quad \mathbb{P}_{\theta_0}(S_n \leq c) \leq \alpha\} = F^{-1}_{\theta_0}(\alpha),$$

où $F^{-1}_{\theta_0}$ désigne l'inverse généralisée de la fonction de répartition d'une loi de Poisson de paramètre θ_0. Le test associé est donc

$$\mathcal{R}_\alpha := \{n \in \mathbb{N} : n \leq c_\alpha\}.$$

pour se donner une idée des valeurs du seuil critique en fonction de α (qu'on choisit plutôt de l'ordre de qq %) quelques valeurs

$$\mathbb{P}_{\theta_0}(S_n < 0) = 0 \qquad \mathbb{P}_{\theta_0}(S_n \leq 0) = 0.3793 \qquad \mathbb{P}_{\theta_0}(S_n \leq 1) = 0.7470.$$

7. On peut vérifier la monotonie des zones de rejet : si $\alpha < \alpha'$ alors $c_\alpha \leq c_{\alpha'}$ et donc $\mathcal{R}_\alpha \subset \mathcal{R}_{\alpha'}$. On cherche

$$\inf\{\alpha \in [0,1] : 4 \leq c_\alpha\} = \inf\{\alpha : c_\alpha = 4\} = F_{\theta_0}(4).$$

Il vient

$$\hat{\alpha}(S_n) = 0.9968.$$

2.7 Exercice 7

`La v.a.` R `est bien définie.` Puisque F_X et F_Y sont continues, on a $\mathbb{P}(Z_i = Z_j) = 0$ pour $i \neq j$.

1. • Sous H_0, les v.a. $(Z_1, \cdots, Z_{n+m})$ sont i.i.d. de loi F_X ce qui entraine que $(Z_1, \cdots, Z_{n+m})$ a même loi que $(Z_{\tau(1)}, \cdots, Z_{\tau(n+m)})$ pour toute permutation déterministe $\tau \in \mathcal{S}_N$. En particulier, on a
$$\mathbb{E}_0\left[\mathbb{1}_{Z_1<\cdots<Z_{n+m}}\right] = \mathbb{E}_0\left[\mathbb{1}_{Z_{\tau(1)}<\cdots<Z_{\tau(n+m)}}\right] ;$$
on a noté $\mathbb{P}_0$ la probabilité sous laquelle les v.a. $\{Z_k\}_{1\leq k\leq n+m}$ sont i.i.d. de loi F_X. Par suite pour tout permutation $\tau \in S_N$,
$$\begin{aligned}\mathbb{P}_0\left(R = (1, \cdots, n+m)\right) &= \mathbb{E}_0\left[\mathbb{1}_{Z_1<\cdots<Z_{n+m}}\right] = \mathbb{E}_0\left[\mathbb{1}_{Z_{\tau(1)}<\cdots<Z_{\tau(n+m)}}\right] \\ &= \mathbb{P}_0\left(R_{\tau(1)} = 1, \cdots, R_{\tau(i)} = i, \cdots, R_{\tau(n+m)} = n+m\right) .\end{aligned}$$
Cette relation étant vraie pour tout τ, il vient que R suis la loi uniforme sur $\mathcal{S}_N$ donc
$$\mathbb{P}_0(R = (i_1, \cdots, i_{n+m})) = \frac{1}{(n+m)!} .$$
• Montrons que sous H_0, $W_{n,m}$ est libre. Sous H_0, $W_{n,m}$ est à valeur dans l'intervalle délimité par (au mieux) $\sum_{i=1}^{n} i$ et (au pire) $\sum_{i=m+1}^{n+m} i$. Pour toute valeur q dans cet intervalle, on a
$$\begin{aligned}\mathbb{P}_0\left(W_{n,m} = q\right) &= \sum_{(i_1,\cdots,i_n)\in\mathcal{I}_q} \mathbb{P}_0(R_1 = i_1, \cdots, R_n = i_n) \\ &= \sum_{(i_1,\cdots,i_n)\in\mathcal{I}_q} \frac{m!}{(n+m)!}\end{aligned}$$
où $\mathcal{I}_q$ désigne l'ensemble des listes à n éléments, d'entiers deux à deux distincts choisis dans l'alphabet $\{1, \cdots, n+m\}$, et dont la somme vaut q ; et $m!$ correspond au nombre de possibilités de compléter les m valeurs manquantes pour $(R_{n+1}, \cdots, R_{n+m})$. La preuve est terminée en observant que le cardinal de $\mathcal{I}_q$ ne dépend pas de la loi F_X.
• Enfin, déterminons la loi de R_i sous H_0. On connaît la loi du vecteur R, qui est la loi uniforme. L'événement $\{R_i = q\}$ correspond à choisir les valeurs de $n+m-1$ autres rangs dans une liste à $n+m-1$ éléments : il y a $(n+m-1)!$ possibilités. Donc
$$\mathbb{P}_0(R_i = q) = \frac{(n+m-1)!}{(n+m)!} = \frac{1}{n+m} .$$
Autrement sur : sous H_0, R_i suit une loi uniforme sur $\{1, \cdots, n+m\}$.
2. On vient de voir que sous H_0, R_i suit une loi uniforme sur $\{1, \cdots, n+m\}$, donc
$$\mathbb{E}_0[R_i] = \frac{(n+m)(n+m+1)}{2(n+m)} = \frac{(n+m+1)}{2} .$$
Ce résultat est indépendant de i ; par suite, $\mathbb{E}_0[W_{n,m}] = n\,\mathbb{E}_0[R_1] = n(n+m+1)/2$.

3. • Par un développement classique de la variance d'une somme, et en utilisant que sous H_0, les v.a. $(R_i)_i$ ont même loi, il vient

$$\mathrm{Var}_0(W_{n,m}) = n\mathrm{Var}_0(R_1) + \sum_{1\le i\neq j\le n} \mathrm{Cov}_0(R_i, R_j) \ .$$

Il reste à montrer que sous H_0, $\mathrm{Cov}_0(R_i, R_j) = \mathrm{Cov}_0(R_1, R_2)$, ce qui est une conséquence du fait que sous H_0, les v.a. $(Z_k)_k$ sont iid. Pour s'en convaincre, on peut utiliser la relation

$$R_i = 1 + \sum_{\ell=1}^{n+m} \mathbb{1}_{]0,+\infty[}(Z_i - Z_\ell) \ .$$

• La démonstration de la seconde expression est identique ; le terme vaut zero puisque la somme de tous les rangs est une constante égale à la somme de tous les entiers de 1 à $n+m$.

• On déduit de la seconde relation que

$$\mathrm{Cov}_0(R_1, R_2) = -\frac{1}{n+m-1}\mathrm{Var}_0(R_1)$$

et en l'introduisant dans la première, il vient

$$\mathrm{Var}_0(W_{n,m}) = n\mathrm{Var}_0(R_1)\left(1 - \frac{n-1}{n+m-1}\right) = \frac{nm}{n+m-1}\mathrm{Var}_0(R_1) \ .$$

Puisque R_1 suit une loi uniforme sur $\{1, \cdots, n+m\}$, sa variance est $(n+m+1)(n+m-1)/12$ (en utilisant le fait que $\sum_{i=1}^q i^2 = q(q+1)(2q+1)/6$) ce qui donne le résultat.

4. Puisque sous H_0, la loi de $W_{n,m}$ ne dépend pas de F_X, on peut trouver $\mathcal{A}_\alpha$ telle que

$$\mathbb{P}_0\left(W_{n,m} \notin \mathcal{A}_\alpha\right) \le \alpha \ ,$$

et poser le test de zone de rejet

$$\{z_1, \cdots, z_{n+m} : \sum_{i=1}^n r_i \notin \mathcal{A}_\alpha\} \ .$$

Un exemple de tel ensemble $\mathcal{A}_\alpha$ peut être construit par Tchebychev : on sait que

$$\mathbb{P}_0\left(|W_{n,m} - n(n+m+1)/2| \ge \varepsilon\right) \le \frac{nm(n+m+1)}{12\,\varepsilon^2}$$

donc on choisit

$$\varepsilon_\alpha := \sqrt{\frac{nm(n+m+1)}{12\,\alpha}}$$

puis

$$\mathcal{A}_\alpha := \left[\frac{n(n+m+1)}{2} \pm \varepsilon_\alpha\right] \ .$$