Rappels.

A. Une loi Gamma de paramètres (α, β) positifs, est une loi sur $\mathbb{R}^+$ dont la densité est donnée par

$$x \mapsto \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} \exp(-\beta x) \; ; \qquad \Gamma(a) := \int_0^{+\infty} t^{a-1} \exp(-t) \, \mathrm{d}t.$$

Son espérance est α/β et sa variance est α/β^2. Si les v.a. X, Y sont indépendantes et de loi Gamma (a, b) et (a', b) respectivement, alors $X + Y$ suit une loi Gamma de paramètres $(a + a', b)$.

B. La loi du χ^2 à p degrés de liberté est une loi Gamma de paramètres $(p/2, 1/2)$. C'est la loi de $\sum_{i=1}^p X_i^2$ lorsque les v.a. $(X_i)_{i=1}^p$ sont i.i.d. de loi $\mathcal{N}(0, 1)$.

C. Soit W une variable gaussienne standard et V une variable du χ^2 centrée à p degrés de liberté, indépendante de W. Alors la variable

$$T = \frac{W + \gamma}{\sqrt{V/p}}$$

est distribuée suivant une loi de Student décentrée, à p degrés de liberté et de paramètre de non-centralité γ.

D. Si U et V sont deux v.a. indépendantes de loi resp. $\chi^2(n)$ et $\chi^2(p)$ alors

$$\frac{U/n}{V/p}$$

suit une loi de Fisher de paramètres (n, p).

1 Exercices

Par convention, les vecteurs sont des vecteurs colonne ; pour un vecteur a, a^T désigne sa transposée.

Exercice 1 ($\star\star$). Soit $(X_1, \ldots, X_n)$ un n-échantillon du modèle statistique $(\mathbb{R}^+, \mathcal{B}(\mathbb{R}^+), \{p_\theta \cdot \mathrm{dLeb}, \theta > 0\})$ où Leb désigne la mesure de Lebesgue sur $\mathbb{R}^+$ et p_θ est la densité d'une loi exponentielle de paramètre $1/\theta$:

$$p_\theta(x) := \theta^{-1} \exp(-x/\theta).$$

Soit $\alpha \in (0, 1)$ et $\theta_0 > 0$. On effectuera les applications numériques avec $\theta_0 = 2$, $\alpha = 5\%$ et l'échantillon de taille $n = 10$ donné par

$$\{2.9, 4.2, 5.9, 1.7, 6.8, 1.3, 1.5, 0.2, 0.4, 3.2\}; \qquad \text{sommes des éléments : } 28.1$$

1. On souhaite tester $H_0 : \; \theta = \theta_0, \quad \text{contre} \quad H_1 : \; \theta > \theta_0 \;$.

   (a) Montrer que, sous $p_\theta \cdot \mathrm{dLeb}$, $\frac{2}{\theta} \sum_{i=1}^n X_i$ suit une loi du χ^2 à $2n$ degrés de liberté. *On utilisera les rappels A et B ci-dessus. La figure 1 trace la densité de la loi du χ^2 pour différents degrés de liberté p.*

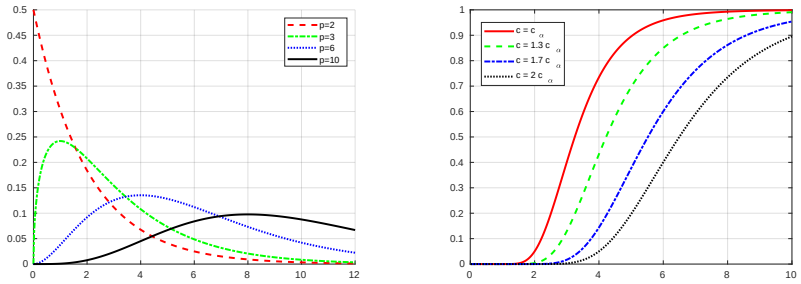


FIGURE 1 – [gauche] Exercice 1. Densité d'une loi du χ^2 pour différents degrés de liberté p. Lorsque $p \geq 2$, le mode de la densité est atteint en $x = p - 2$. [droite] Exercice 1. Fonction puissance de plusieurs tests répondant à la contrainte de niveau ; on remarquera que le test dont le seuil critique est c_α a une taille égale à α.

(b) Proposer un estimateur de θ.
On pourra comparer l'estimateur du maximum de vraisemblance et l'estimateur des moments associé à la statistique $T(x) = x$. Voir PC2 exercices 2 et 3.

(c) En déduire un test de niveau α.

(d) Donner l'expression de la fonction puissance et calculer l'erreur de première espèce.
La figure 1 donne l'allure de la fonction puissance pour différentes valeurs du seuil critique $c \geq c_\alpha$ où c_α est le seuil dont le test associé a une taille égale au niveau.

(e) Calculer la p-valeur.

2. On souhaite tester $H_0 : \theta \leq \theta_0$, contre $H_1 : \theta > \theta_0$.

(a) Donner la forme d'une région de rejet de niveau α.

(b) Étudier la fonction puissance du test.

(c) Calculer la p-valeur.

3. Intervalles de confiance pour θ

(a) En utilisant la fonction pivotale $T(\theta, (X_i)_{i=1,\dots,n}) := \frac{2}{\theta}\sum_{i=1}^n X_i$ sous $p_\theta \cdot \mathrm{dLeb}$, construire un intervalle de confiance bilatéral exact de niveau $1-\alpha$ pour θ.

(b) En déduire des bornes *unilatérales* exactes de niveau $1-\alpha$ pour θ (borne supérieure seule, puis borne inférieure seule)..

(c) *Application numérique* avec $\alpha = 5\%$, $n = 10$ et $\sum_{i=1}^n X_i = 28.1$: donner l'IC bilatéral pour θ. On donne

$$q_{0.025}^{\chi^2(20)} \approx 9.59, \quad q_{0.975}^{\chi^2(20)} \approx 34.17,$$

Exercice 2 (⋆⋆). Soit $\sigma^2 > 0$ un réel fixé (connu) et soit $Z = (X_1, \dots, X_n)$, un n-échantillon du modèle statistique

$$(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\mu \cdot \mathrm{dLeb} = \mathrm{N}(\mu, \sigma^2), \mu \in \mathbb{R}\}) .$$

Soit $\mu_0 \in \mathbb{R}$. On souhaite tester

$$H_0 : \ \mu = \mu_0, \quad \text{contre} \quad H_1 : \ \mu \neq \mu_0 \ .$$

Pour $c > 0$, on considère le test pur $\delta_c(X_1, \ldots, X_n) := \mathbb{1}_{T(X_1,\cdots,X_n)\geq c}$ dont la statistique de test $T(X_1, \cdots, X_n)$ est donnée par :

$$T(X_1, \ldots, X_n) := \sqrt{n}\frac{\left|\overline{X}_n - \mu_0\right|}{\sigma} \ , \qquad \text{où} \quad \overline{X}_n := \frac{1}{n}\sum_{i=1}^{n} X_i \ .$$

1. Déterminer la fonction puissance du test (pour un seuil c fixé) ; l'exprimer à l'aide de la fonction de répartition d'une loi gaussienne $\mathrm{N}(0, 1)$.
   La figure 2 trace cette fonction puissance dans le cas où $\mu_0 = 0$ et c est choisi pour que le test soit de niveau $\alpha = 5\%$; et ce, pour différentes valeurs de n.
2. Déterminer en fonction du seuil critique c, la taille du test (ou risque de première espèce). En déduire la valeur du seuil critique pour un test de niveau $\alpha \in]0, 1[$.
3. Calculer la p-valeur associée à l'observation Z.

On suppose dorénavant que la variance σ^2 est inconnue, i.e., que l'observation $Z = (X_1, \ldots, X_n)$ est un n-échantillon du modèle statistique

$$\left(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \, \mathrm{dLeb} = \mathrm{N}(\mu, \sigma^2), \theta := (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}\right) \ .$$

On pose

$$S_n^2 := \frac{1}{n-1}\sum_{k=1}^{n}(X_k - \overline{X}_n)^2.$$

4. Montrer que sous $p_\theta \cdot \mathrm{dLeb}$, les statistiques $\overline{X}_n$ et S_n^2 sont indépendantes.
   Indication : on pourra exprimer $\overline{X}_n$ et S_n^2 à l'aide de la projection Π sur le sous-espace vectoriel engendré par le vecteur constant $(1, \cdots, 1)$ de $\mathbb{R}^n$. Voir PC1 exercice 4 et PC2 exercice 1.
5. Montrer que sous $p_\theta \cdot \mathrm{dLeb}$, $(n-1)\, S_n^2/\sigma^2$ est distribuée suivant une loi du χ^2 à $(n-1)$ degrés de liberté.

Pour répondre au même problème de test d'hypothèse, on propose cette fois le test pur $\widetilde{\delta}_c(X_1, \cdots, X_n) := \mathbb{1}_{\{\widetilde{T}(Z)\geq c\}}$ dont la statistique de test est donnée par $\widetilde{T}(Z) := \sqrt{n}|\overline{X}_n - \mu_0|/S_n$.

6. Sous $p_\theta \cdot \mathrm{dLeb}$, déterminer la distribution de

$$\frac{\sqrt{n}(\overline{X}_n - \mu_0)}{S_n} \ .$$

   On pourra utiliser le rappel C.
7. Déterminer en fonction du seuil critique c la taille du test (ou risque de première espèce).
8. Déterminer le seuil critique de façon à obtenir un test de niveau $\alpha \in]0, 1[$.
9. Calculer la p-valeur de l'observation Z.

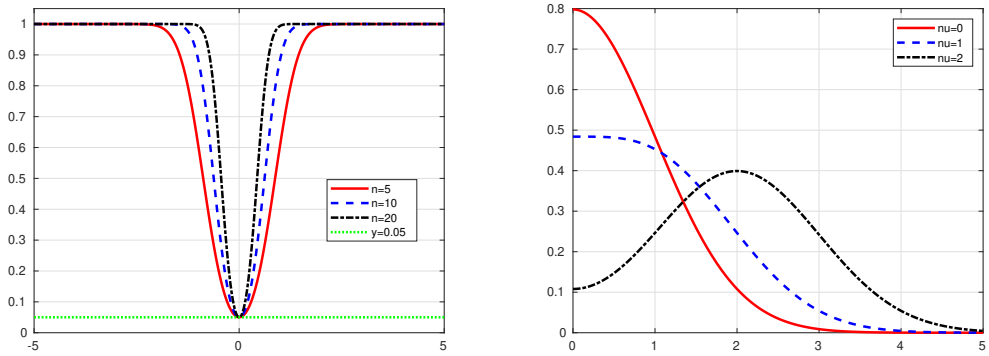


FIGURE 2 – Exercice 2. [gauche] Fonction puissance $\mu \mapsto \beta_c(\mu)$ pour différentes valeurs de $n \in \{5, 10, 20\}$. On a pris $\mu_0 = 0$, $\sigma = 1$ et $c = \Phi^{-1}(0.975)$. On trace aussi la droite d'équation $y = 0.05$. [droite] Densité de $|X|$ (à une constante multiplicative près) lorsque $X \sim \mathcal{N}(\nu, 1)$.

Exercice 3 (Intervalle de confiance pour la loi uniforme ($\star$)). Soit $(X_1, \dots, X_n)$, un n-échantillon d'un modèle de loi uniforme sur l'intervalle $[0, \theta]$ où $\theta \in \Theta := \mathbb{R}_+^*$. On pose $X_{n:n} := \max(X_1, \dots, X_n)$.

1. Montrer que $X_{n:n}/\theta$ est une fonction pivotale pour θ.
2. Déterminer l'intervalle de confiance de probabilité de couverture $(1 - \alpha)$ de longueur minimale.

Exercice 4 ($\star$). Soit $(X_1, \dots, X_n)$ un n-échantillon du modèle statistique $(\mathbb{N}, \mathcal{P}(\mathbb{N}), \{p_\theta \cdot \mathrm{d}\mu, \theta > 0\})$ où μ désigne la mesure de comptage sur $\mathbb{N}$ et p_θ est la densité d'une loi de Poisson de paramètre θ. On souhaite tester $H_0 : \ \theta = 1, \quad$ contre $\quad H_1 : \ \theta = 2$.

1. Rappeler la loi de $\sum_{i=1}^n X_i$ sous $p_\theta \cdot \mathrm{d}\mu$, $\theta > 0$.

Dans la suite, on prendra $n = 10$.

2. Proposer un test de niveau 5%. Quelle est la taille de ce test ?
3. Donner l'expression de la fonction puissance.
   La figure 3 trace la fonction puissance.
4. Pour chacun des échantillons suivants, calculer la p-valeur.

$$\{2, 3, 3, 1, 4, 0, 1, 4, 0, 0\} \qquad \text{et} \qquad \{4, 2, 1, 1, 0, 1, 0, 2, 0, 2\}.$$

Exercice 5 (Modèle gaussien à deux échantillons ($\star\star\star$)). On dispose d'une variable qualitative binaire qui permet de définir deux groupes.

— On mesure une variable quantitative qui permet de calculer dans chaque groupe les différents paramètres de la distribution : moyenne, estimateur de l'écart type...

— On désire savoir si les moyennes observées dans chacun des groupes peuvent être considérées comme des estimateurs de la même moyenne aux fluctuations du hasard près [1].

1. vous pourrez consulter `https://www.youtube.com/watch?v=oJjkjkY6mmA`

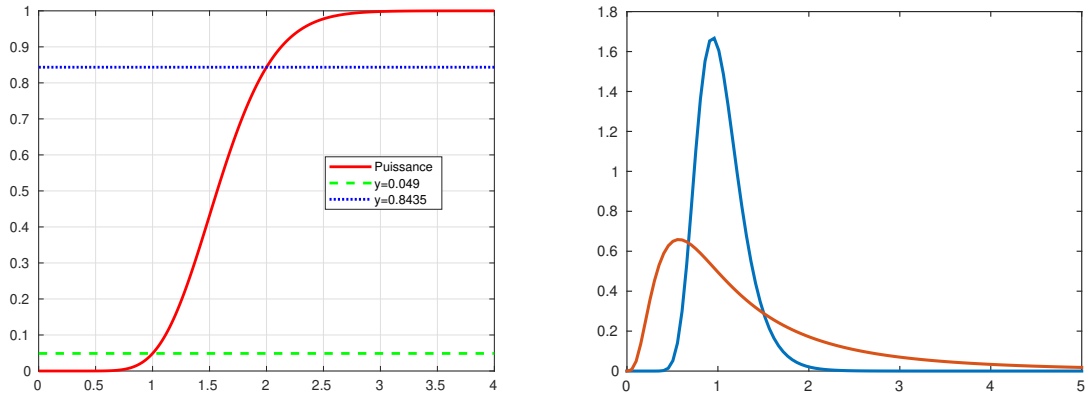


FIGURE 3 – [gauche] Exercice 2. Fonction puissance $\theta \mapsto \mathbb{P}_\theta(T(Z) > c_\alpha)$ du test. On trace aussi les droites d'équation $y = 0.049$ et $y = 0.8435 = 1 - 0.1565$. [droite] Exercice 4. Densité d'une loi de Fisher de paramètres $(10, 5)$ en rouge ; et $(100, 50)$ en bleu.

Nous formalisons ce test d'hypothèses ci-dessous. Nous effectuons n mesures dans le groupe 1 (resp. p mesures dans le groupe 2) ; ces mesures sont considérées comme l'observation de mécanismes aléatoires indépendants, et gaussiens ; les paramètres de la gaussienne dépendent uniquement des groupes. Nous introduisons donc le modèle statistique suivant

$$\left(\mathbb{R}^{n+p}, \mathcal{B}(\mathbb{R}^{n+p}), \{p_\theta \mathrm{dLeb}^{\otimes(n+p)} := \left(\mathrm{N}(\mu_0, \sigma^2)\right)^{\otimes n} \otimes \left(\mathrm{N}(\mu_1, \sigma^2)\right)^{\otimes p}, \theta := (\mu_0, \mu_1, \sigma^2) \in \mathbb{R}^2 \times \mathbb{R}_+^*\}\right).$$

Nous noterons $X_1, \ldots, X_n$ les n premières variables canoniques, et $Y_1, \cdots, Y_p$ les p dernières.

1. Déterminer l'estimateur du maximum de vraisemblance du paramètre θ.
2. Construire un intervalle de confiance de $\mu_0 - \mu_1$ de niveau de confiance $1 - \alpha$.
3. En déduire un test de niveau α de l'hypothèse

$$H_0 : \ \mu_0 = \mu_1, \quad \text{contre} \quad H_1 : \ \mu_0 \neq \mu_1 \ .$$

4. Construire un test de niveau α de l'hypothèse

$$H_0 : \ \mu_0 \leq \mu_1, \quad \text{contre} \quad H_1 : \ \mu_0 > \mu_1.$$

On utilise maintenant ce test pour comparer la consistance de deux correcteurs de l'examen d'entrée à l'Ecole Polytechnique. Nous avons visualisé les notes pour les deux correcteurs (sur 100) dans le tableau suivant

	Échantillon #1	Échantillon #2
Nombre d'observations	120	120
Moyenne	75	74.99
Ecart-type	8.72	6.54

5. Quelle est la p-valeur du test ? Qu'en concluez-vous ?

On suppose maintenant que les variances des gaussiennes des deux groupes sont différentes, et notées respectivement σ_0^2 et σ_1^2. Le modèle statistique est donc modifié en conséquence ; en particulier, $\theta := (\mu_0, \mu_1, \sigma_0^2, \sigma_1^2) \in \mathbb{R} \times \mathbb{R} \times \mathbb{R}_+^* \times \mathbb{R}_+^*$.

6. Construire une fonction pivotale du paramètre σ_1^2/σ_0^2.
7. En déduire un test de niveau α de l'hypothèse

$$H_0 : \ \sigma_0^2 \leq \sigma_1^2, \quad \text{contre} \quad H_1 : \ \sigma_0^2 > \sigma_1^2 \ .$$

8. Calculer la p-valeur de ce test.

Exercice 6 ($\star\star$). Des plaignants [2] ont poursuivi en justice le Ministère de la Santé suite à une campagne de vaccination menée sur des enfants et ayant entraîné des dommages fonctionnels irréversibles pour certains d'entre eux. Ce vaccin était connu pour entraîner ce type de dommages en de très rares circonstances. Des études antérieures menées dans d'autres pays ont montré que ce risque était en moyenne d'un cas sur 310 000 vaccinations. Les plaignants avaient été informés de ce risque et l'avaient accepté. Les doses de vaccin ayant provoqué les dommages objet de la plainte provenaient d'un lot ayant servi à vacciner un groupe de 300 533 enfants. Dans ce groupe, quatre cas de dommages ont été détectés.

1. On modélise l'événement "le vaccin provoque des dommages fonctionnels irréversibles sur l'enfant i" par une variable aléatoire de Bernoulli, X_i, de paramètre p. Calculer la valeur du paramètre correspondant aux résultats des études antérieures ; on la notera p_0 dans la suite.

On considère le test

$$H_0 : \ p \leq p_0, \quad \text{contre} \quad H_1 : \ p > p_0$$

L'hypothèse nulle correspond au risque que les clients avaient accepté.

2. On pose $S_n = \sum_{i=1}^n X_i$ avec $n = 300533$. Pour $\alpha \in [0, 1]$, déterminer un test de niveau α basé sur la statistique de test S_n.
3. On a $\mathbb{P}_{p_0}(S_n > 0) = 0.6207$, $\mathbb{P}_{p_0}(S_n > 1) = 0.2530$, $\mathbb{P}_{p_0}(S_n > 2) = 0.0748, \mathbb{P}_{p_0}(S_n > 3) = 0.0172$, $\mathbb{P}_{p_0}(S_n > 4) = 0.0032$. L'hypothèse est elle acceptée au niveau 0.05 ? au niveau 0.01 ?
4. Quelle est la p-valeur de l'observation ?

On peut modéliser la loi du nombre S_n de cas de dommages par une loi de Poisson de paramètre θ. [3]

5. Calculer la valeur θ_0 attendue si le vaccin est conforme aux études antérieures.
6. Les plaignants militent pour que le test prouve effectivement que le nombre moyen d'accidents reste inférieur à θ_0. Pour eux, le nombre moyen est supérieur à θ_0 sauf preuve du contraire. Proposer un test à partir de la variable S_n.
7. Donner la p-valeur de ce test. Accepte-t-on H_0 au seuil de 0.05 ?

2. M. Aitkin. Evidence and the Posterior Bayes Factor. *Math. Scientist*, vol. 17, pp. 15-25 (1992).
3. regarder `https://www.youtube.com/watch?v=Lygy1OxUG88`

Exercice 7 ($\star\star\star$). *On rappelle que pour une suite de réels $x_1, \cdots, x_q$, la notation $x_{\ell:q}$ désigne la suite ordonnée : on a $x_{1:q} \leq x_{2:q} \leq \cdots \leq x_{q:q}$.*

Une firme pharmaceutique a mis au point une nouvelle molécule pour faire chuter le taux de sucre dans le sang. Pour tester l'efficacité de cette molécule, elle la compare à un placebo. Elle réunit $n+m$ patients. A un premier groupe de m individus, elle administre un placebo (sans leur dire !). Au second groupe elle donne sa nouvelle molécule. Après un délai approprié, on mesure les taux de glycémie $\{X_i : \ i = 1, \ \ldots, \ n\}$ et $\{Y_j : \ j = 1, \ldots, m\}$ chez les deux groupes. [4]

On suppose que les variables aléatoires $(X_1, \ldots, X_n, Y_1, \ \ldots, \ Y_m)$ sont indépendantes ; que les v.a. $(X_i)_i$ ont même loi de fonction de répartition F_X ; et que les v.a. $(Y_i)_i$ ont même loi de fonction de répartition F_Y. On supposera que les fonctions F_X et F_Y sont continues.

On veut tester si les lois des X et des Y sont les mêmes ou si les Y_i sont stochastiquement plus petits que les X_i, c'est à dire $F_X < F_Y$. On va donc tester $H_0 : F_X = F_Y$ contre $H_1 : F_X < F_Y$.

On pose $Z_i = X_i$ pour $i = 1, \ldots, n$ et $Z_{n+i} = Y_i$ pour $i = 1, \ldots, m$. On note R_i le rang de Z_i dans la suite $(Z_1, \ \ldots, \ Z_{n+m})$, à savoir, $R_i = \ell$ si $Z_i = Z_{\ell:n+m}$. La statistique de Wilcoxon est définie par

$$W_{n,m} := \sum_{i=1}^{n} R_i \ .$$

L'idée est que sous H_1 la statistique $W_{n,m}$ sera plus grande que sous H_0.

1. Soit $N = n + m$. Montrez que la *statistique de rang* $R := (R_1, \ \ldots, \ R_N)$ suit sous H_0 la loi uniforme sur l'ensemble $\mathcal{S}_N$ de toutes les permutations de $\{1, \ldots, N\}$. En déduire que sous H_0 la statistique de Wilcoxon est *libre*, i.e., la loi de $W_{n,m}$ ne dépend pas de F_X. Quelle est la loi de R_i sous H_0 ?
2. Montrez que sous H_0 on a $\mathrm{E}(W_{n,m}) = n(n+m+1)/2$.
3. Montrez que sous H_0 on a

$$\mathrm{Var}(W_{n,m}) = n\,\mathrm{Var}(R_1) + n(n-1)\,\mathrm{Cov}(R_1, \ R_2)$$
$$0 = \mathrm{Var}\left(\sum_{i=1}^{n+m} R_i\right) = (n+m)\mathrm{Var}(R_1) + (n+m)(n+m-1)\mathrm{Cov}(R_1, \ R_2)\,.$$

   En déduire que, sous H_0, $\mathrm{Var}(W_{n,m}) = nm(n+m+1)/12$.
4. Proposer un test de niveau α.

4. voir `https://www.youtube.com/watch?v=QDUQscWyXqw`