Chapitre 4

Régions de confiance et tests

Les trois premiers chapitres construisent des estimateurs et mesurent leur qualité, mais ils ne rendent jamais qu'un nombre : une valeur estimée, sans indication de la marge à lui accorder. On peut aller au-delà des estimateurs ponctuels. Ce chapitre remplace la valeur unique par une **région de confiance**, ensemble aléatoire construit sur les observations dont on garantit qu'il contient la quantité inconnue avec une probabilité fixée, puis par une réponse à une question binaire portant sur le paramètre : c'est le **test d'hypothèses**.

La première moitié du chapitre définit la région de confiance et son niveau de couverture, met en garde contre l'interprétation qu'elle appelle naturellement, et donne l'outil qui sert à en construire : la **fonction pivotale**. On en déduit les intervalles du modèle gaussien (pour la moyenne à variance connue, pour la moyenne à variance inconnue, pour la variance) et, lorsque aucun pivot n'est disponible, un intervalle obtenu par une inégalité de déviation.

La seconde moitié pose le formalisme des tests : **hypothèse nulle** et **hypothèse alternative**, **test pur**, **région de rejet**, **fonction puissance**, **taille** et **niveau**. Les deux erreurs auxquelles un test expose ne se minimisent pas simultanément ; l'approche de **Neyman-Pearson** lève la difficulté en les traitant de façon dissymétrique, ce qui fait du choix de l'hypothèse nulle une décision de modélisation. On en tire une méthode de construction, puis la **p-valeur**, qui remplace la réponse binaire par le niveau limite au-delà duquel l'observation conduit à rejeter.

La suite de ce chapitre est organisée comme suit : les fondamentaux, puis les *outils mathématiques* mobilisés (fonction de répartition et quantile, loi de Student non centrale, loi de Fisher, inégalité de Hoeffding, couplage de variables de Bernoulli), puis la feuille d'exercices, enfin les *compléments*, hors programme d'examen, qui traitent la dualité entre régions de confiance et tests et la construction générale de tests par inégalités de déviation.

Que dire de plus qu'une valeur estimée ?

Le chapitre 2 a construit des estimateurs, le chapitre 3 a donné les moyens de les comparer. Reste que l'objet rendu à l'utilisateur est un nombre : une fréquence empirique vaut 0,53, une moyenne des mesures de bruit vaut 82 décibels. Ce nombre ne dit rien, à lui seul, de la précision avec laquelle il approche la quantité qu'il estime. Le risque quadratique donne une telle information, mais il dépend du paramètre inconnu, et il n'est pas calculable à partir des observations.

Deux réponses sont possibles, qui seront traitées dans ce chapitre, l'une après l'autre. La première consiste à rendre, non plus une valeur, mais un ensemble de valeurs (un intervalle, ou plus généralement une région) dont on peut garantir qu'il contient la quantité inconnue avec

une probabilité au moins égale à $1 - \alpha$, et cela pour toute valeur du paramètre. La seconde consiste à répondre à une question binaire posée sur le paramètre (l'espérance dépasse-t-elle le seuil réglementaire ? le nouveau traitement fait-il mieux que l'ancien ?), en contrôlant les taux d'erreur, sous nos hypothèses de modélisation. Les deux constructions reposent sur le même outils probabilistes, et la dualité entre régions de confiance et tests est traitée dans les compléments.

1 Régions de confiance

Plutôt qu'un estimateur $T(Z)$ de $g(\theta)$, on cherche une région $\mathcal{C}(Z)$, construite sur les observations, qui contienne $g(\theta)$ avec une probabilité garantie, et cela quelle que soit la valeur du paramètre, puisque celle-ci est inconnue.

Définition 1.1: Région de confiance

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique, $g : \Theta \to \mathbb{R}^p$ une fonction et $\alpha \in]0,1[$. Une fonction $\mathcal{C} : \mathsf{Z} \to \mathcal{B}(\mathbb{R}^p)$ est une *région de confiance au niveau de couverture* $1-\alpha$ pour $g(\theta)$ si

(i) pour tout $\theta \in \Theta$, $\{z \in \mathsf{Z}\,,\ g(\theta) \in \mathcal{C}(z)\} \in \mathcal{Z}$;

(ii) on a

$$\inf_{\theta\in\Theta} \mathbb{P}_\theta\big(\{g(\theta) \in \mathcal{C}(Z)\}\big) \geq 1-\alpha\,.$$

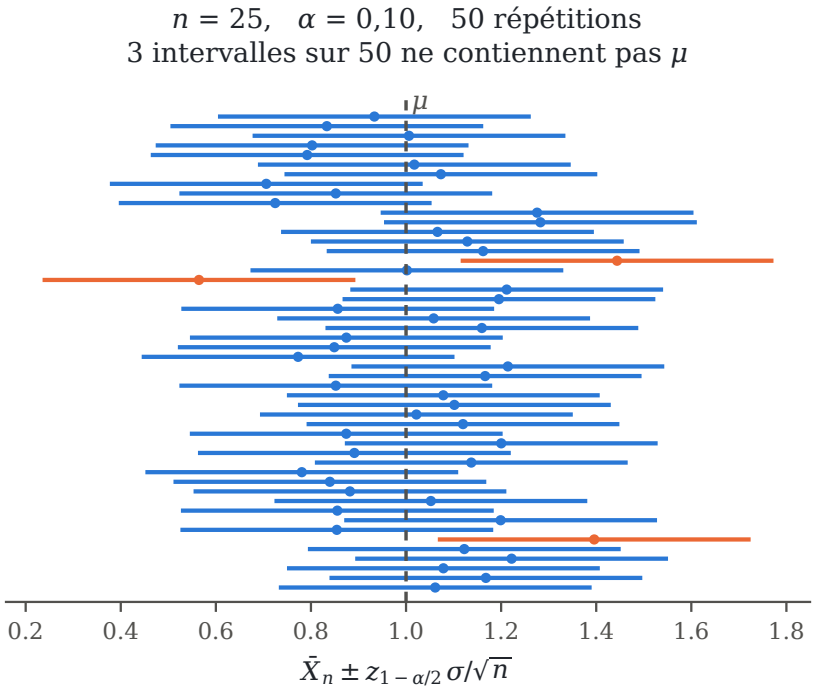
La condition (i) est une condition de mesurabilité : sans elle, la probabilité de la condition (ii) n'aurait pas de sens. La condition (ii) porte un « pour tout θ » écrit sous la forme d'un infimum : la garantie doit valoir en chaque point de l'espace des paramètres.

Qui est aléatoire ? Si $\mathcal{C}(Z)$ est une région de confiance de niveau $1-\alpha$ pour $g(\theta)$, l'interprétation qui vient spontanément est : « $g(\theta)$ a une probabilité $1-\alpha$ d'appartenir à $\mathcal{C}(Z)$ ». Cette interprétation est **erronée** : le paramètre θ est déterministe et fixé ; l'aléa porte sur l'observation Z, donc sur la région $\mathcal{C}(Z)$, qui est une statistique à valeurs ensemblistes. Ce qui est garanti est que, sous $\mathbb{P}_\theta$, «cette région aléatoire $C(Z)$ a une probabilité au moins égale à $1-\alpha$ de contenir $g(\theta)$», et cela quelle que soit la valeur $\theta \in \Theta$ du paramètre.

De même, une *réalisation numérique* ne se lit pas comme une probabilité. Si, sur un jeu de données, la région obtenue est l'intervalle $[0,2]$, il ne faut surtout pas conclure que $\mathbb{P}_\theta(g(\theta) \in [0,2]) \geq 1-\alpha$: cette dernière assertion n'a pas de sens, ses deux membres étant déterministes.

Intuition. *On saisit le sens de la garantie par une expérience de pensée. Répétons l'expérience N fois, indépendamment, pour une même valeur de θ, ce qui produit $Z^{(1)}, \ldots, Z^{(N)}$ et N régions $\mathcal{C}(Z^{(1)}), \ldots, \mathcal{C}(Z^{(N)})$. Alors la proportion de ces régions qui contiennent $g(\theta)$ est d'au moins $1-\alpha$ lorsque N est grand. L'énoncé exact est que cette proportion converge vers $\mathbb{P}_\theta(g(\theta) \in \mathcal{C}(Z)) \geq 1-\alpha$. C'est l'interprétation dite* fréquentiste *du niveau de couverture : elle porte sur la procédure, répétée, et non sur le résultat d'une expérience particulière.*

La figure suivante met cette expérience de pensée en images, sur le modèle gaussien à variance connue qui sera traité à la Section 1.4.



Cinquante répétitions indépendantes de l'expérience, pour $n = 25$ observations et $\alpha = 0{,}10$. Chaque trait horizontal est l'intervalle $\left[\bar{X}_n \pm z_{1-\alpha/2}\sigma/\sqrt{n}\right]$ obtenu sur une répétition, le point marquant la valeur de $\bar{X}_n$; la droite verticale en pointillé est la vraie valeur μ, identique d'une répétition à l'autre. Trois des cinquante intervalles, tracés en orange, ne contiennent pas μ. C'est ce que la garantie autorise : elle porte sur la proportion de répétitions réussies, et non sur une répétition donnée. Le nombre d'intervalles manquants fluctue d'une simulation à l'autre autour de $\alpha \times 50 = 5$.

Dans le cas $p = 1$, la région de confiance est le plus souvent un *intervalle de confiance*, qui prend l'une des trois formes suivantes.

(i) $\mathcal{C}(Z) = [m(Z), +\infty[$: $m(Z)$ est une *borne inférieure de confiance*.

(ii) $\mathcal{C}(Z) =]-\infty, M(Z)]$: $M(Z)$ est une *borne supérieure de confiance*.

(iii) $\mathcal{C}(Z) = [m(Z), M(Z)]$ est un *intervalle de confiance bilatéral*.

Les bornes m et M y sont des statistiques, c'est-à-dire des fonctions mesurables des observations.

1.1 Fonction pivotale

Pour construire une région de confiance, on cherche une fonction des observations *et* du paramètre dont la loi soit connue et ne dépende pas du paramètre. C'est le seul ingrédient dont on ait besoin : la garantie de couverture s'en déduit mécaniquement.

Définition 1.2: Fonction pivotale

Soit $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique paramétrique où $\Theta \in \mathcal{B}(\mathbb{R}^d)$. Une fonction

$$G : (\mathsf{Z} \times \Theta, \mathcal{Z} \otimes \mathcal{B}(\mathbb{R}^d)) \to (\mathbb{R}^p, \mathcal{B}(\mathbb{R}^p))\ , \qquad (z, \theta) \mapsto G(z, \theta)\ ,$$

est dite *pivotale*, ou est appelée un *pivot*, si

(i) pour tout $\theta \in \Theta$, la fonction $z \mapsto G(z, \theta)$ est mesurable ;

(ii) pour tous $\theta, \vartheta \in \Theta$, la loi image de $\mathbb{P}_\theta$ par $G(\cdot, \theta)$ coïncide avec la loi image de $\mathbb{P}_\vartheta$ par $G(\cdot, \vartheta)$, c'est-à-dire

$$\mathbb{P}_\theta\big(G(Z, \theta) \in A\big) = \mathbb{P}_\vartheta\big(G(Z, \vartheta) \in A\big) \qquad \text{pour tout } A \in \mathcal{B}(\mathbb{R}^p)\ .$$

On note $\mathbb{Q}$ la loi commune de $G(Z,\theta)$ sous $\mathbb{P}_\theta$; elle ne dépend pas de θ.

Remarque. La condition (ii) ne dit *pas* que la fonction G ne dépend pas de θ : si c'était le cas, G serait une statistique et la construction qui suit ne donnerait rien. Elle dit que le paramètre entre dans G de telle façon que son effet sur la loi des observations se compense exactement : la variable aléatoire $G(Z,\theta)$, calculée sous $\mathbb{P}_\theta$, a une loi qui est la même pour toutes les valeurs de θ. C'est une propriété conjointe de la fonction et du modèle, et non une propriété de la seule fonction.

Les deux exemples suivants se vérifient directement à partir de la fonction de répartition, sans aucun résultat préalable.

Exemple 1.1: Modèle exponentiel

Soit X une observation du modèle $\big(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{E}(\theta)\,,\ \theta\in\Theta := \mathbb{R}_+^*\}\big)$, où $\mathcal{E}(\theta)$ désigne la loi exponentielle d'intensité θ, de densité $x\mapsto \theta \mathrm{e}^{-\theta x}$ sur $\mathbb{R}_+$ par rapport à la mesure de Lebesgue. Posons

$$G(X,\theta) := \theta X\ .$$

Pour tout $t>0$ et tout $\theta\in\Theta$, on a $\mathbb{P}_\theta(X>t) = \int_t^{+\infty} \theta \mathrm{e}^{-\theta x}\,\mathrm{d}x = \mathrm{e}^{-\theta t}$, d'où

$$\mathbb{P}_\theta(\theta X > t) = \mathbb{P}_\theta\big(X > t/\theta\big) = \mathrm{e}^{-t} = \mathbb{P}\big(\mathcal{E}(1) > t\big)\ .$$

La loi de $G(X,\theta)$ sous $\mathbb{P}_\theta$ est donc $\mathcal{E}(1)$ pour tout θ : la fonction G est pivotale.

Exemple 1.2: Modèle uniforme

Soit X une observation du modèle $\big(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \{\mathcal{U}([0,\theta])\,,\ \theta\in\Theta := \mathbb{R}_+^*\}\big)$. Posons

$$G(X,\theta) := X/\theta\ .$$

Pour $t\in[0,\theta]$, on a $\mathbb{P}_\theta(X\le t) = t/\theta$, donc pour tout $u\in[0,1]$,

$$\mathbb{P}_\theta\big(X/\theta \le u\big) = \mathbb{P}_\theta(X\le u\theta) = u = \mathbb{P}\big(\mathcal{U}([0,1])\le u\big)\ .$$

La loi de $G(X,\theta)$ sous $\mathbb{P}_\theta$ est donc $\mathcal{U}([0,1])$ pour tout θ : la fonction G est pivotale.

1.2 Construire une région de confiance à partir d'un pivot

Un pivot fournit une région de confiance par une manipulation d'ensembles, ce que la proposition suivante formalise et que le bloc méthode juste après résume.

Proposition 1.1: Région de confiance associée à un pivot

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta\in\Theta\})$ un modèle statistique avec $\Theta\in\mathcal{B}(\mathbb{R}^d)$, $G : \mathsf{Z}\times\Theta\to\mathbb{R}^p$ une fonction pivotale, $\mathbb{Q}$ la loi de $G(Z,\theta)$ sous $\mathbb{P}_\theta$, et $\alpha\in\,]0,1[$. Soit $A_\alpha\in\mathcal{B}(\mathbb{R}^p)$ tel que $\mathbb{Q}(A_\alpha)\ge 1-\alpha$. Alors la région définie pour tout $z\in\mathsf{Z}$ par

$$\mathcal{C}(z) := \{\theta\in\Theta\,,\ G(z,\theta)\in A_\alpha\}$$

est une région de confiance au niveau de couverture $1-\alpha$ pour θ, c'est-à-dire pour la fonction $g=\mathrm{Id}$, avec $p=d$.

Démonstration

Pour $z \in \mathsf{Z}$ fixé, l'ensemble $\mathcal{C}(z)$ est la section en z de $G^{-1}(A_\alpha)$, qui appartient à $\mathcal{Z} \otimes \mathcal{B}(\Theta)$ par mesurabilité conjointe de G ; c'est donc un borélien de Θ, et $\mathcal{C}$ est bien à valeurs dans $\mathcal{B}(\mathbb{R}^d)$. Fixons maintenant $\theta \in \Theta$. Par définition de $\mathcal{C}$,

$$\{z \in \mathsf{Z}\,,\ \theta \in \mathcal{C}(z)\} = \{z \in \mathsf{Z}\,,\ G(z,\theta) \in A_\alpha\}\ ,$$

qui appartient à $\mathcal{Z}$ puisque $z \mapsto G(z,\theta)$ est mesurable et $A_\alpha \in \mathcal{B}(\mathbb{R}^p)$: la condition de mesurabilité de la Définition 1.1 est vérifiée. De plus,

$$\mathbb{P}_\theta\big(\theta \in \mathcal{C}(Z)\big) = \mathbb{P}_\theta\big(G(Z,\theta) \in A_\alpha\big) = \mathbb{Q}(A_\alpha) \geq 1-\alpha\ ,$$

le membre du milieu ne dépendant pas de θ puisque G est pivotale. En prenant l'infimum sur $\theta \in \Theta$, la seconde condition de la définition est vérifiée. □

Il est donc presque automatique de construire une région de confiance à partir d'un pivot : il suffit de choisir un ensemble de probabilité au moins $1-\alpha$ sous la loi du pivot, puis de résoudre l'appartenance à cet ensemble en θ.

Méthode 1.1: Construction d'une région de confiance par un pivot

Soit $1-\alpha \in]0,1[$ le niveau de couverture visé.

1. Exhiber une fonction pivotale $G : \mathsf{Z} \times \Theta \to \mathbb{R}^p$ pour le modèle $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$.
2. Identifier la loi $\mathbb{Q}$ de $G(Z,\theta)$ sous $\mathbb{P}_\theta$, qui ne dépend pas de θ.
3. Choisir $A_\alpha \in \mathcal{B}(\mathbb{R}^p)$ tel que $\mathbb{Q}(A_\alpha) \geq 1-\alpha$.
4. Résoudre en θ l'appartenance $G(Z,\theta) \in A_\alpha$: l'ensemble des solutions

$$\mathcal{C}(Z) = \{\theta \in \Theta\,,\ G(Z,\theta) \in A_\alpha\}$$

est une région de confiance de niveau de couverture $1-\alpha$.

En général, on redéroule cette méthode sur le modèle considéré plutôt que d'en appliquer la conclusion comme un résultat tout fait : c'est l'étape 4, la résolution en θ, qui change d'un modèle à l'autre, et c'est elle qui donne à l'intervalle sa forme.

Le choix de A_α. Il n'est pas unique, et la construction n'en dit rien : toute partie de probabilité au moins $1-\alpha$ sous $\mathbb{Q}$ convient. Plaçons-nous dans le cas $p=1$ et notons q_β le quantile d'ordre β de la loi $\mathbb{Q}$ (Section 3) ; ce quantile ne dépend pas de θ. Trois choix reviennent :

$$A_\alpha =]-\infty, q_{1-\alpha}]\ ,\qquad A_\alpha = [q_\alpha, +\infty[\ ,\qquad A_\alpha = \big]q_{\alpha/2}, q_{1-\alpha/2}\big]\ ,$$

les deux premiers donnant une borne de confiance unilatérale et le troisième un intervalle bilatéral. Plus généralement, pour tous $0 \leq p_1 < p_2 \leq 1$ tels que $p_2 - p_1 = 1-\alpha$, l'ensemble $A_\alpha =]q_{p_1}, q_{p_2}]$ convient. Le choix d'une paire est guidé soit par la question posée (on ne cherche parfois qu'une borne inférieure), soit par le souhait de minimiser la longueur de l'intervalle obtenu.

Intuition. *Le choix symétrique $p_1 = \alpha/2$, $p_2 = 1-\alpha/2$ n'est donc pas imposé par la théorie : c'est une convention, qui se trouve donner l'intervalle le plus court lorsque la densité de $\mathbb{Q}$ est paire et unimodale, comme pour la loi $\mathcal{N}(0,1)$ et la loi de Student. Dès que la loi du pivot est dissymétrique, l'intervalle le plus court n'est plus symétrique : c'est le cas de la loi uniforme, où l'intervalle de longueur minimale est entièrement décalé d'un côté (Exercice 3 (PC4)), et de la loi du χ^2, où l'optimum n'est atteint qu'approximativement par le choix symétrique.*

1.3 Mise en pratique : calcul d'intervalles de confiance multiples pour les lois gaussienne, exponentielle et de Student

L'exemple suivant applique la méthode au modèle uniforme et produit une borne inférieure de confiance : c'est le seul endroit du chapitre où l'une des trois formes unilatérales est effectivement construite.

Exemple 1.3: Modèle uniforme : borne inférieure de confiance

Reprenons l'Exemple 1.2 : X/θ est pivotale, de loi $\mathcal{U}([0,1])$ sous $\mathbb{P}_\theta$. Prenons $A_\alpha = [0, 1-\alpha]$, de probabilité $1-\alpha$ sous $\mathcal{U}([0,1])$. Pour tout $\theta \in \mathbb{R}_+^*$,

$$\mathbb{P}_\theta\big(X/\theta \leq 1-\alpha\big) = 1-\alpha \;,$$

et, puisque $\theta > 0$ et $1-\alpha > 0$, l'inégalité $X/\theta \leq 1-\alpha$ équivaut à $\theta \geq X/(1-\alpha)$. Il vient donc, pour tout $\theta \in \mathbb{R}_+^*$,

$$\mathbb{P}_\theta\Big(\theta \in \Big[\tfrac{X}{1-\alpha}, +\infty\Big[\Big) = 1-\alpha \;,$$

de sorte que $X/(1-\alpha)$ est une borne inférieure de confiance de niveau $1-\alpha$ pour θ.

1.4 Le cas gaussien

Le modèle gaussien est celui où les pivots se lisent le plus directement, et c'est aussi celui qui sert de référence à l'approche asymptotique du cours 6. On traite successivement la moyenne à variance connue, la moyenne à variance inconnue, la variance, puis le couple.

Exemple 1.4: Intervalle de confiance pour la moyenne, variance connue

Soit $(X_1, \ldots, X_n)$ un n-échantillon du modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(\mu, \sigma^2)\,,\ \mu \in \mathbb{R}\}\big)$, où la variance $\sigma^2 > 0$ est *connue*. La fonction

$$G(X_1, \ldots, X_n; \mu) := \sqrt{n}\,\frac{\bar{X}_n - \mu}{\sigma}\;, \qquad \bar{X}_n := n^{-1}\sum_{i=1}^n X_i\;,$$

est pivotale : sous $\mathbb{P}_\mu$, on a $\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$, donc $G(X_1, \ldots, X_n; \mu) \sim \mathcal{N}(0,1)$, et cela pour tout $\mu \in \mathbb{R}$.
Notons Φ la fonction de répartition de $\mathcal{N}(0,1)$ et, pour $\beta \in]0,1[$, z_β le quantile d'ordre β de $\mathcal{N}(0,1)$, caractérisé par $\Phi(z_\beta) = \beta$. Par symétrie de la loi $\mathcal{N}(0,1)$, $z_{\alpha/2} = -z_{1-\alpha/2}$, de sorte que

$$\mathbb{P}_\mu\big(G(X_1, \ldots, X_n; \mu) \in \big[-z_{1-\alpha/2}, z_{1-\alpha/2}\big]\,\big) = \Phi(z_{1-\alpha/2}) - \Phi(-z_{1-\alpha/2}) = 1-\alpha\;.$$

En résolvant l'appartenance en μ, il vient, pour tout $\mu \in \mathbb{R}$,

$$\mathbb{P}_\mu\Big(\mu \in \Big[\bar{X}_n \pm z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\Big]\Big) = 1-\alpha\;,$$

où $[a \pm b]$ désigne l'intervalle $[a-b, a+b]$. L'intervalle

$$\mathcal{I}_{n,\alpha} := \Big[\bar{X}_n \pm z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\Big]$$

est donc un intervalle de confiance bilatéral de niveau de couverture $1-\alpha$ pour μ. Sa longueur vaut $2\sigma z_{1-\alpha/2}/\sqrt{n}$: elle décroît en $n^{-1/2}$ à niveau fixé, et croît indéfiniment lorsque α tend vers 0 à n fixé.

Remarque. On rappelle les valeurs classiques : on a $z_{1-\alpha/2} \simeq 1{,}96$ pour $\alpha = 0{,}05$ et $z_{1-\alpha/2} \simeq 2{,}576$ pour $\alpha = 0{,}01$. C'est ce là que vient l'approximation « $\pm 2\sigma/\sqrt{n}$ » souvent utilisée pour un intervalle de confiance à 95%.

Intuition. *Les deux paramètres n et α jouent l'un contre l'autre, et c'est le compromis central de tout ce chapitre. Exiger une garantie plus forte, c'est diminuer α, donc augmenter le quantile, donc allonger l'intervalle : une région plus sûre est une région moins informative, et la région $\mathbb{R}$ tout entière est de niveau 1 sans rien apprendre. À l'inverse, augmenter n raccourcit l'intervalle à garantie constante. On retrouvera exactement ce compromis du côté des tests, entre la taille et la puissance.*

Lorsque la variance est inconnue, ce qui est la règle plutôt que l'exception, le pivot précédent n'en est plus un, puisque σ n'est pas calculable à partir des observations. On le remplace par la racine de la variance empirique

$$S_n^2 := \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X}_n)^2 \,,$$

estimateur sans biais de σ^2 (chapitre 3, Exemple 1.4). La loi du quotient obtenu est donnée par le théorème de Gosset, énoncé et démontré au chapitre 1 (théorème de Gosset) : si $(X_1, \dots, X_n)$ est un n-échantillon de $\mathcal{N}(\mu, \sigma^2)$ avec $n \geq 2$, alors $\bar{X}_n$ et S_n^2 sont indépendantes, $\bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$, $(n-1)S_n^2/\sigma^2 \sim \chi^2(n-1)$ et en conséquence, par définition de la loi de Student,

$$T_n := \sqrt{n}\,\frac{\bar{X}_n - \mu}{S_n} \sim \mathrm{t}(n-1) \,,$$

où $\mathrm{t}(k)$ est la loi de Student à k degrés de liberté (chapitre 1, Définition 12).

Exemple 1.5: Intervalle de confiance pour la moyenne, variance inconnue

Soit $(X_1, \dots, X_n)$, $n \geq 2$, un n-échantillon du modèle

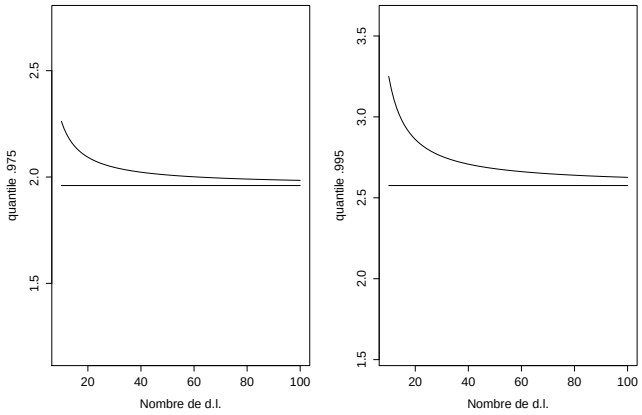
$$\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(\mu, \sigma^2)\,,\ \theta = (\mu, \sigma^2) \in \Theta := \mathbb{R} \times \mathbb{R}_+^*\}\big) \,.$$

Par le théorème de Gosset, la fonction $G(X_1, \dots, X_n; \mu) := \sqrt{n}(\bar{X}_n - \mu)/S_n$ est pivotale, de loi $\mathrm{t}(n-1)$ sous $\mathbb{P}_\theta$ pour tout $\theta \in \Theta$. Notons $\mathrm{t}_\beta^{(n-1)}$ le quantile d'ordre β de $\mathrm{t}(n-1)$. La densité de $\mathrm{t}(n-1)$ est paire et unimodale, de mode en 0, ce qui justifie de prendre un intervalle symétrique ; on a $\mathrm{t}_{\alpha/2}^{(n-1)} = -\,\mathrm{t}_{1-\alpha/2}^{(n-1)}$ et

$$\mathbb{P}_\theta\Big(-\,\mathrm{t}_{1-\alpha/2}^{(n-1)} \leq \sqrt{n}\,\frac{\bar{X}_n - \mu}{S_n} \leq \mathrm{t}_{1-\alpha/2}^{(n-1)}\Big) = 1 - \alpha \,.$$

En résolvant en μ, on obtient, pour tout $\theta = (\mu, \sigma^2) \in \Theta$,

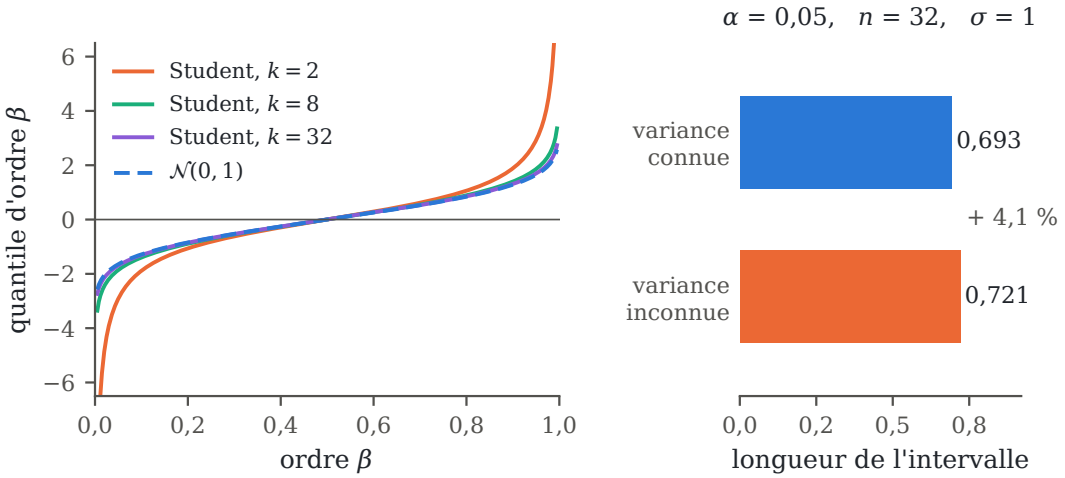
$$\mathbb{P}_\theta\left(\mu \in \left[\bar{X}_n \pm S_n \frac{\mathrm{t}_{1-\alpha/2}^{(n-1)}}{\sqrt{n}}\right]\right) = 1 - \alpha \,.$$



En traits pleins, les quantiles d'ordre 0,95, 0,975 *et* 0,99 *de la loi de Student à n degrés de liberté, en fonction de n. Les traits pointillés donnent les quantiles de même ordre de la loi $\mathcal{N}(0,1)$. Pour n grand, de l'ordre de la centaine, les deux familles de quantiles sont proches ; pour n petit, les quantiles de Student sont sensiblement plus grands, et l'intervalle de Student est donc plus long que celui qu'on obtiendrait en remplaçant naïvement σ par S_n dans l'Exemple 1.4.*

Intuition. *L'écart entre les deux familles de quantiles a une lecture simple : en remplaçant σ par son estimateur S_n, on introduit une source d'aléa supplémentaire, et il faut élargir l'intervalle pour conserver la même garantie. Le prix payé est d'autant plus élevé que n est petit, c'est-à-dire que S_n est mal déterminé. Le calcul complet de la loi de T_n est repris à l'Exercice 2 (PC4), qui redémontre le théorème de Gosset.*

Cet écart se chiffre. La figure ci-dessous compare les deux fonctions quantiles, puis les longueurs des deux intervalles pour une taille d'échantillon courante.



À gauche, les fonctions quantiles $\beta \mapsto \mathrm{t}_\beta^{(k)}$ de la loi de Student à $k = 2$, 8 et 32 degrés de liberté, et, en pointillé, la fonction quantile $\beta \mapsto z_\beta$ de $\mathcal{N}(0,1)$. Les quantiles de Student sont plus éloignés de 0, et d'autant plus que k est petit ; pour $k = 32$, les deux courbes sont déjà presque confondues. À droite, les longueurs des deux intervalles de confiance pour μ au niveau 0,95, *pour $n = 32$ observations et $\sigma = 1$: $2z_{0,975}\sigma/\sqrt{n} = 0{,}693$ à variance connue et $2\,\mathrm{t}_{0,975}^{(31)}\,S_n/\sqrt{n} = 0{,}721$ à variance inconnue, soit un allongement de* 4,1 %. *La seconde longueur est aléatoire, puisqu'elle dépend de S_n ; elle est représentée ici pour $S_n = \sigma$, ce qui est la seule façon de comparer les deux formules à la même échelle.*



Point d'histoire : William Sealy Gosset (1876-1937)

Chimiste chez Guinness, à Dublin, Gosset contrôle la qualité de l'orge et du malt sur des échantillons de quelques unités, trop petits pour l'approximation gaussienne à variance connue. Il détermine la loi de $\sqrt{n}(\bar{X}_n - \mu)/S_n$ et la publie en 1908 dans *Biometrika* sous le pseudonyme « Student » : la brasserie interdisait à ses employés de publier sous leur nom, de peur d'informer la concurrence. La démonstration était en partie heuristique ; l'argument géométrique est de Fisher, et redémontré à l'Exercice 2 (PC4).

Portrait : Wikimedia Commons, domaine public.

Le même théorème donne un pivot pour la variance, en ne conservant que le troisième point.

Exemple 1.6: Intervalle de confiance pour la variance, espérance inconnue

Soit $(X_1, \dots, X_n)$, $n \geq 2$, un n-échantillon du modèle $\{\mathcal{N}(\mu, \sigma^2)\,,\ (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}$. La fonction

$$G(X_1, \dots, X_n; \sigma^2) := \frac{(n-1)S_n^2}{\sigma^2}$$

est pivotale, de loi $\chi^2(n-1)$ sous $\mathbb{P}_{(\mu,\sigma^2)}$ pour tout couple (μ, σ^2). Notons $\chi^2_\beta(n-1)$ le quantile d'ordre β de la loi $\chi^2(n-1)$ et prenons $\alpha_1, \alpha_2 > 0$ tels que $\alpha_1 + \alpha_2 = \alpha$. Alors

$$\mathbb{P}_{\mu,\sigma^2}\Big(\chi^2_{\alpha_1}(n-1) \leq \frac{(n-1)S_n^2}{\sigma^2} \leq \chi^2_{1-\alpha_2}(n-1)\Big) = 1 - \alpha\,,$$

et, en résolvant en σ^2 (les trois membres étant strictement positifs, l'encadrement s'inverse),

$$\Big[\frac{(n-1)S_n^2}{\chi^2_{1-\alpha_2}(n-1)},\ \frac{(n-1)S_n^2}{\chi^2_{\alpha_1}(n-1)}\Big]$$

est un intervalle de confiance de niveau de couverture $1 - \alpha$ pour σ^2.
La paire (α_1, α_2) n'est pas uniquement déterminée par la contrainte $\alpha_1 + \alpha_2 = \alpha$. Si on note $L_n(S_n^2, \alpha_1, \alpha_2)$ la longueur de l'intervalle, qui est une statistique, on peut montrer qu'il existe une paire (α_1^*, α_2^*) de somme α qui minimise $\mathbb{E}_{\mu,\sigma^2}\left[L_n(S_n^2, \alpha_1, \alpha_2)\right]$ simultanément pour tout (μ, σ^2), et que $\alpha_1^* \simeq \alpha_2^* \simeq \alpha/2$ lorsque n est grand. C'est le choix $\alpha_1 = \alpha_2 = \alpha/2$ qui est retenu en pratique.

Enfin, l'exemple suivant illustre le cas où la région porte sur un couple, c'est-à-dire où $p > 1$ dans la Définition 1.1.

Exemple 1.7: Région de confiance pour le couple (μ, σ^2)

Soit $(X_1, \dots, X_n)$, $n \geq 2$, un n-échantillon du modèle $\{\mathcal{N}(\mu, \sigma^2)\,,\ (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}$. Posons

$$I_1(X_1, \dots, X_n) := \Big[\bar{X}_n \pm S_n \frac{\mathrm{t}^{(n-1)}_{1-\alpha/4}}{\sqrt{n}}\Big]\,, \qquad I_2(X_1, \dots, X_n) := \Big[\frac{(n-1)S_n^2}{\chi^2_{1-\alpha/4}(n-1)},\ \frac{(n-1)S_n^2}{\chi^2_{\alpha/4}(n-1)}\Big]\,,$$

qui sont, d'après les deux exemples précédents, des intervalles de confiance de niveau de couverture $1 - \alpha/2$ pour μ et pour σ^2 respectivement. Alors, par sous-additivité,

$$\mathbb{P}_{\mu,\sigma^2}\big((\mu, \sigma^2) \notin I_1 \times I_2\big) \leq \mathbb{P}_{\mu,\sigma^2}(\mu \notin I_1) + \mathbb{P}_{\mu,\sigma^2}(\sigma^2 \notin I_2) \leq \frac{\alpha}{2} + \frac{\alpha}{2} = \alpha\,,$$

de sorte que $I_1 \times I_2$ est une région de confiance de niveau de couverture au moins $1 - \alpha$ pour (μ, σ^2).
Le niveau exact de cette région produit ne se calcule pas simplement. L'événement $\{\mu \in I_1\}$ ne dépend de l'observation qu'à travers $T := \sqrt{n}(\bar{X}_n - \mu)/S_n$ et l'événement $\{\sigma^2 \in I_2\}$

qu'à travers $V := (n-1)S_n^2/\sigma^2$; mais T et V ne sont pas indépendantes, puisque $T = N/\sqrt{V/(n-1)}$ avec $N := \sqrt{n}(\bar{X}_n - \mu)/\sigma \sim \mathcal{N}(0,1)$ indépendante de V. Le niveau exact vaut donc $\mathbb{P}_{\mu,\sigma^2}(\{\mu \in I_1\} \cap \{\sigma^2 \in I_2\})$, en général strictement supérieur à $1-\alpha$ et différent du produit des deux niveaux.
Une région dont le niveau est exact. On l'obtient en appliquant la Proposition 1.1 directement en dimension $p = 2$. La fonction

$$G(Z;\mu,\sigma^2) := \left(\sqrt{n}\,\frac{\bar{X}_n - \mu}{\sigma},\ \frac{(n-1)S_n^2}{\sigma^2}\right)$$

est pivotale, de loi $\mathcal{N}(0,1) \otimes \chi^2(n-1)$: c'est exactement le contenu du théorème de Gosset, dont les points (i) à (iii) donnent les deux lois marginales et leur indépendance. En prenant

$$A_\alpha := \left[-z_{1-\alpha/4}, z_{1-\alpha/4}\right] \times \left[\chi^2_{\alpha/4}(n-1), \chi^2_{1-\alpha/4}(n-1)\right] ,$$

il vient $\mathbb{Q}(A_\alpha) = (1-\alpha/2)^2$ par indépendance des deux composantes, et la région

$$\mathcal{C}(Z) = \left\{(\mu,\sigma^2) \in \mathbb{R} \times \mathbb{R}_+^* \ :\ |\bar{X}_n - \mu| \le \frac{\sigma z_{1-\alpha/4}}{\sqrt{n}} \ \text{ et } \ \frac{(n-1)S_n^2}{\chi^2_{1-\alpha/4}(n-1)} \le \sigma^2 \le \frac{(n-1)S_n^2}{\chi^2_{\alpha/4}(n-1)}\right\}$$

est une région de confiance de niveau de couverture exactement $(1-\alpha/2)^2 = 1 - \alpha + \alpha^2/4$. Ce n'est plus un produit d'intervalles : la région est délimitée par deux droites horizontales dans le plan (μ,σ^2) et par les deux courbes $\mu = \bar{X}_n \pm \sigma z_{1-\alpha/4}/\sqrt{n}$.

Intuition. *La perte est du second ordre : la région exacte atteint $(1-\alpha/2)^2$ au lieu de $1-\alpha$, soit un excédent de $\alpha^2/4$, qui vaut 0,0625 % pour $\alpha = 5\,\%$. Le procédé par sous-additivité se généralise : pour couvrir simultanément p quantités, on construit p intervalles de niveau $1-\alpha/p$ et l'on prend leur produit, dont le niveau est au moins $1-\alpha$. C'est la correction dite de Bonferroni ; elle est d'autant plus conservatrice que p est grand, et c'est un sujet à part entière, celui des tests multiples.*

1.5 En l'absence de pivot : intervalle pour une proportion

Il est rare de disposer d'un pivot dont les quantiles soient explicites. Lorsque ce n'est pas le cas, une inégalité de déviation fournit une majoration de la probabilité de s'écarter de la cible, dont on tire un intervalle. Le modèle de Bernoulli en donne l'illustration la plus simple, et la comparaison de deux inégalités y est instructive.

Exemple 1.8: Intervalle de confiance pour une proportion

Soit $(X_1,\dots,X_n)$ un n-échantillon du modèle de Bernoulli

$$\left(\{0,1\}, \mathcal{P}(\{0,1\}), \{\mathcal{B}\mathrm{er}(\theta)\,,\ \theta \in \Theta := [0,1]\}\right) ,$$

et $\bar{X}_n = n^{-1}\sum_{i=1}^n X_i$ la fréquence empirique, estimateur sans biais de θ. On cherche un intervalle de confiance de niveau $1-\alpha$ pour θ. La loi de $\bar{X}_n$ dépend de θ autrement que par une translation ou un facteur d'échelle, et aucun pivot explicite ne se présente.
Par l'inégalité de Bienaymé-Tchebychev. On a $\mathrm{Var}_\theta(\bar{X}_n) = \theta(1-\theta)/n$, donc

$$\sup_{\theta\in\Theta} \mathrm{Var}_\theta(\bar{X}_n) = \frac{1}{4n} ,$$

le maximum de $\theta \mapsto \theta(1-\theta)$ sur $[0,1]$ étant atteint en $\theta = 1/2$. L'inégalité de Bienaymé-Tchebychev (chapitre 2, inégalité de Bienaymé-Tchebychev) donne alors, pour tout $\delta > 0$ et

tout $\theta \in \Theta$,

$$\mathbb{P}_\theta\big(|\bar{X}_n - \theta| \geq \delta\big) \leq \frac{\mathrm{Var}_\theta(\bar{X}_n)}{\delta^2} \leq \frac{1}{4n\delta^2} \,.$$

En prenant $\delta_{n,\alpha}$ solution de $1/(4n\delta^2) = \alpha$, c'est-à-dire $\delta_{n,\alpha} = 1/(2\sqrt{n\alpha})$, l'intervalle

$$\mathcal{I}_{n,\alpha} := \Big[\bar{X}_n \pm \frac{1}{2\sqrt{n\alpha}}\Big]$$

vérifie $\mathbb{P}_\theta(\theta \in \mathcal{I}_{n,\alpha}) \geq 1-\alpha$ pour tout $\theta \in \Theta$: c'est un intervalle de confiance de niveau de couverture $1-\alpha$. Sa longueur vaut $|\mathcal{I}_{n,\alpha}| = 1/\sqrt{n\alpha}$.
Par l'inégalité de Hoeffding. Les observations étant à valeurs dans $[0,1]$, l'inégalité de Hoeffding (Section 3) donne, pour tout $\delta > 0$,

$$\sup_{\theta\in\Theta} \mathbb{P}_\theta\big(|\bar{X}_n - \theta| > \delta\big) \leq 2\exp(-2n\delta^2) \,.$$

En prenant $\delta(\alpha, n)$ solution de $2\exp(-2n\delta^2) = \alpha$, c'est-à-dire $\delta(\alpha,n) = \sqrt{\log(2/\alpha)/(2n)}$, l'intervalle

$$\mathcal{I}^\star_{n,\alpha} := \Big[\bar{X}_n \pm \sqrt{\frac{1}{2n}\log\frac{2}{\alpha}}\Big]$$

est un intervalle de confiance de niveau de couverture $1-\alpha$.
Comparaison. Le rapport des longueurs vaut

$$\frac{|\mathcal{I}^\star_{n,\alpha}|}{|\mathcal{I}_{n,\alpha}|} = \sqrt{2\alpha\log(2/\alpha)} \,,$$

qui ne dépend pas de n et tend vers 0 lorsque α tend vers 0. Pour $\alpha = 5\,\%$, il vaut 0,61 ; pour $\alpha = 1\,\%$, il vaut 0,33, soit une précision trois fois meilleure. Les deux intervalles ont le même ordre de grandeur en n, à savoir $n^{-1/2}$, mais l'inégalité exponentielle est bien plus favorable dès que le niveau exigé est élevé.

Intuition. *La différence tient à la façon dont chaque inégalité dépend de α. Bienaymé-Tchebychev ne mobilise que la variance et paie le niveau en $\alpha^{-1/2}$; Hoeffding mobilise le caractère borné des observations et ne le paie qu'en $\sqrt{\log(1/\alpha)}$, c'est-à-dire beaucoup moins vite. En contrepartie, Hoeffding exige des observations bornées, ce qui exclut par exemple le modèle gaussien à variance inconnue. Ni l'un ni l'autre ne donne l'intervalle exact que fournirait la loi binomiale : ce sont des majorations, donc des intervalles plus longs qu'il n'est nécessaire.*

Ce qu'il faut retenir de cette première moitié du chapitre tient en cinq points. Une région de confiance est un ensemble aléatoire ; qui contient la quantité inconnue avec une probabilité au moins $1-\alpha$, et cela pour toute valeur du paramètre. La technique de construction la plus courante s'appuie sur une fonction pivotale. Le cas gaussien est particulièrement important, avec variance connue puis avec variance inconnue, où la loi de Student remplace la loi normale. Enfin, en l'absence de pivot, on peut recourir à une inégalité de concentration, ou à l'approche asymptotique du cours 6.

2 Tests d'hypothèses

2.1 Ce qu'un test cherche à établir

Un test a pour but de fournir une réponse à une question binaire portant sur le paramètre du modèle, par exemple « θ est-il inférieur ou supérieur à un θ_0 ? » Dans le cadre d'une modélisation statistique adaptée, cela peut permettre d'aborder des questions pratiques :

1. La modification de mon site augmente-t-elle le nombre de visites par jour ?
2. Ce nouveau médicament augmente-t-il les chances de survie ?
3. Mes données montrent-elles l'existence d'une particule nouvelle ?
4. Cette personne est-elle atteinte de la maladie à traiter urgemment ?

Le premier exemple peut par exemple se traduire ainsi :

(i) on modélise le nombre de visites par jour par une loi de Poisson de paramètre λ ;
(ii) le paramètre λ_0 observé avant la modification est supposé connu ;
(iii) on dispose d'un échantillon du modèle après modification,
(iv) on cherche à savoir si le paramètre a augmenté.

La question statistique est alors : « a-t-on $\lambda \leq \lambda_0$ ou $\lambda > \lambda_0$? ».

Remarque. Le passage de la question pratique à la question statistique est la partie du travail de modélisation, dont on a amplement parlé au cours 1, et c'est d'elle que dépend beaucoup la portée pratique de la réponse. Dans ce cours, on se place dans le cadre d'une modélisation statistique donnée, et on ne discutera pas en profondeur de la pertinence de telle ou telle modélisation. **Néanmoins, pour comprendre l'approche de Neyman-Pearson, il est indispensable de s'ancrer dans les cas d'usage, afin de percevoir l'asymétrie des erreurs.** Nous nous appuierons donc régulièrement, à cette fin, sur de petits exemples.

Remarque. La notion de *preuve statistique* n'a rien d'immédiat. Les tests sont, en pratique, l'outil le plus employé des sciences expérimentales (biologie, sciences sociales, économétrie, médecine), et ils sont aussi l'une des principales sources d'erreurs. En 2019, plus de huit cents scientifiques ont cosigné dans *Nature* un appel intitulé *Scientists rise up against statistical significance,* dont la conclusion demande l'abandon du concept même de signification statistique. Ils écrivent :

We [...] call for the entire concept of statistical significance to be abandoned.

Ce qui est en cause n'est pas la théorie exposée ici, qui est exacte, mais l'usage qui en est fait : un seuil conventionnel, 5 % le plus souvent, y est traité comme une frontière entre le vrai et le faux. Bien comprendre ce qu'un test dit et ce qu'il ne dit pas n'est pas difficile dès lors qu'on s'appuie sur les mathématiques ; c'est l'objet de la suite du chapitre, et les limites de l'outil sont reprises en détail à la Section 2.8, à la fin.

2.2 Formalisme : test pur, région de rejet

Le cadre formel des tests est le suivant. On se donne un modèle statistique $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ et une partition de l'espace des paramètres en deux parties Θ_0 et Θ_1, et le but du test est de déterminer si $\theta \in \Theta_0$ ou $\theta \in \Theta_1$. On dit qu'on fait le *test d'hypothèses*

$$H_0 :\ \theta \in \Theta_0, \quad \text{contre} \quad H_1 :\ \theta \in \Theta_1\ ,$$

H_0 étant *l'hypothèse nulle* et H_1 *l'hypothèse alternative*. Une première idée consiste à construire une statistique à valeurs dans $\{0, 1\}$, qui encode la décision ; on parle alors de test pur.

Définition 2.1: Test pur

Soient $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique et (Θ_0, Θ_1) une partition de Θ. Un *test pur* de $H_0 : \theta \in \Theta_0$ contre $H_1 : \theta \in \Theta_1$ est une fonction mesurable $\phi : \mathsf{Z} \to \{0, 1\}$. On convient que

— si $\phi(Z) = 1$, on *rejette* l'hypothèse nulle H_0 ;
— si $\phi(Z) = 0$, on *ne rejette pas* l'hypothèse nulle H_0.

L'ensemble $\mathcal{R} := \{z \in \mathsf{Z}\,,\ \phi(z) = 1\}$ est la *région de rejet* du test (on dit aussi *région critique*), et $\mathcal{A} := \mathsf{Z} \setminus \mathcal{R}$ est la *région d'acceptation*.

L'usage courant dit parfois « accepter H_0 » là où la définition dit « ne pas rejeter H_0 ». Les deux formulations décrivent la même décision, mais la seconde est plus prudente, et la raison en apparaîtra au Section 2.4 : la construction contrôlera en priorité la probabilité de rejeter à tort H_0, de sorte que le fait de "ne pas rejeter" n'établit rien. On pourra même dire, pour insister, que « on échoue à rejeter H_0 » (c'est même ma formulation recommandée !) : on ne peut pas conclure que H_0 est vrai, mais seulement que l'on n'a pas trouvé de preuve suffisante pour le rejeter. La notion d'échec ne veut pas dire ici que l'on souhaitait rejeter H_0, mais que l'on a échoué à trouver une preuve suffisante pour le faire.

Lorsque Θ_0 ou Θ_1 est réduit à un singleton, on parle d'*hypothèse simple* ; sinon, d'*hypothèse composite*. Lorsque les deux hypothèses considérées ne recouvrent pas Θ tout entier, ce qui arrive dès que l'on oppose deux valeurs particulières du paramètre, on peut se ramener à la définition en restreignant le modèle au sous-ensemble $\Theta_0 \cup \Theta_1$ de l'espace des paramètres. Dans le cas où $\Theta \subseteq \mathbb{R}$, les trois tests suivants sont couramment employés :

— $H_0 :\ \theta = \theta_0$, contre $H_1 :\ \theta = \theta_1$, hypothèse simple contre alternative simple ;

— $H_0 :\ \theta = \theta_0$, contre $H_1 :\ \theta \neq \theta_0$, hypothèse simple contre alternative composite ;

— $H_0 :\ \theta \leq \theta_0$, contre $H_1 :\ \theta > \theta_0$, hypothèse composite contre alternative composite.

Il est fréquent que la région de rejet se mette sous la forme

$$\mathcal{R} = \{z \in \mathsf{Z}\,,\ T(z) \geq c\}$$

pour une statistique $T : \mathsf{Z} \to \mathbb{R}$ et un réel c. La variable aléatoire $T(Z)$ est alors appelée la *statistique de test* et c la *valeur critique* du test ; on dit aussi qu'on fait le test de statistique T et de valeur critique c. Lorsque la loi de $T(Z)$ est continue, écrire $\{T(z) \geq c\}$ ou $\{T(z) > c\}$ ne change ni la région, à un ensemble de probabilité nulle près, ni la taille du test ; lorsque $T(Z)$ est à valeurs discrètes, en revanche, les deux conventions ne donnent pas le même seuil, et l'on adopte ici l'inégalité large dans tout le chapitre.

Exemple 2.1: Un test sur l'espérance d'un échantillon gaussien

On dispose de mesures à valeurs réelles, pour lesquelles on considère le modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(\theta, 1)\,,\ \theta \in \Theta := \mathbb{R}\}\big)$, et l'on souhaite répondre à la question : l'espérance est-elle inférieure ou égale à $\theta_0 = 2$? On veut en outre une procédure qui garantisse que l'erreur consistant à répondre « non » alors que l'espérance est bien inférieure ou égale à θ_0 ait une probabilité au plus α.
On teste donc $H_0 : \theta \in \Theta_0$ contre $H_1 : \theta \in \Theta_1$, avec $\Theta_0 :=]-\infty, 2]$ et $\Theta_1 :=]2, +\infty[$, qui forment bien une partition de $\mathbb{R}$. Une règle de décision naturelle se fonde sur la moyenne empirique des observations : on pose

$$\phi(Z) := \mathbb{1}_{\{\bar{X}_n \geq c_\alpha\}}\,,$$

de région de rejet $\mathcal{R} = \big\{(x_1, \ldots, x_n) \in \mathbb{R}^n\,,\ n^{-1}\sum_{i=1}^n x_i \geq c_\alpha\big\}$ et de région d'acceptation $\mathcal{A} = \big\{(x_1, \ldots, x_n) \in \mathbb{R}^n\,,\ n^{-1}\sum_{i=1}^n x_i < c_\alpha\big\}$. La valeur critique c_α est choisie pour garantir le niveau d'erreur fixé, c'est-à-dire $\mathbb{P}_\theta(\bar{X}_n \geq c_\alpha) \leq \alpha$ pour tout $\theta \in \Theta_0$. La clause « pour tout $\theta \in \Theta_0$ » est l'écho de « alors que l'espérance est bien inférieure ou égale à θ_0 », et l'événement dont on calcule la probabilité correspond à « on répond non ». On attend que c_α soit légèrement supérieur à θ_0 ; la valeur exacte sera calculée à l'Exemple 2.3.

Exemple 2.2: Sondage

Reprenons le modèle de sondage du chapitre 1 : $(X_1, \dots, X_n)$ est un n-échantillon de

$$\big(\{0,1\}, \mathcal{P}(\{0,1\}), \{\mathcal{B}\mathrm{er}(\theta)\,,\ \theta \in \Theta := [0,1]\}\big)\ ,$$

où θ est la probabilité de voter pour le candidat A. Pour $\theta_0 \in\ ]0,1[$ fixé, on considère la partition $\Theta_0 := \{\theta \in \Theta\,,\ \theta \leq \theta_0\}$ et $\Theta_1 := \{\theta \in \Theta\,,\ \theta > \theta_0\}$, et le test de $H_0 : \theta \leq \theta_0$ contre $H_1 : \theta > \theta_0$. Il est naturel de prendre pour statistique de test le nombre de suffrages favorables,

$$T(Z) = S_n := \sum_{i=1}^{n} X_i\ ,$$

et de rejeter H_0 lorsque S_n dépasse un seuil : le test est $\phi(Z) = \mathbb{1}_{\{S_n \geq c\}}$, de région de rejet $\mathcal{R} = \{(x_1, \dots, x_n) \in \{0,1\}^n\,,\ \sum_{i=1}^n x_i \geq c\}$. Le choix de c est détaillé à l'Exemple 2.5.

2.3 Fonction puissance, taille et niveau

Un test est une procédure ; pour la juger, on regarde, pour chaque valeur du paramètre, la probabilité qu'elle a de rejeter l'hypothèse nulle. Si $\theta \in \Theta_0$, on espère ne pas rejeter H_0 ; si $\theta \in \Theta_1$, on espère rejeter H_0. La fonction puissance rassemble ces deux exigences en un seul objet.

Définition 2.2: Fonction puissance

Soit $(\mathrm{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique paramétrique. La *fonction puissance* $\beta_\phi : \Theta \to [0,1]$ d'un test pur ϕ est définie par

$$\beta_\phi : \theta \longmapsto \mathbb{P}_\theta\big(\phi(Z) = 1\big) = \mathbb{P}_\theta\big(Z \in \mathcal{R}\big)\ .$$

Effectuer un test expose à **deux types d'erreur**.

— *Erreur de première espèce* : rejeter H_0 alors que cette hypothèse est satisfaite. Sa probabilité, sous $\mathbb{P}_\theta$ avec $\theta \in \Theta_0$, est le *risque de première espèce* $\beta_\phi(\theta)$.

— *Erreur de seconde espèce* : ne pas rejeter H_0 alors que cette hypothèse est fausse. Sa probabilité, sous $\mathbb{P}_\theta$ avec $\theta \in \Theta_1$, est le *risque de seconde espèce* $1 - \beta_\phi(\theta)$.

Définition 2.3: Taille et niveau d'un test

La *taille* du test ϕ est

$$\overline{\alpha}(\phi) := \sup_{\theta \in \Theta_0} \beta_\phi(\theta)\ .$$

Soit $\alpha \in\ ]0,1[$. Le test ϕ est dit *de niveau* α si $\overline{\alpha}(\phi) \leq \alpha$.

La taille est donc le risque de première espèce maximal : c'est la probabilité maximale de rejeter H_0 alors qu'elle est vraie. La taille est un nombre attaché au test ; le niveau est une contrainte qu'on lui impose. Un test de taille 3 % est de niveau 5 %, et il est aussi de niveau 3 %.

Étant donné un couple (Θ_0, Θ_1), il n'y a pas unicité du test, et l'on peut chercher à les comparer. Si ϕ_1 et ϕ_2 sont deux tests tels que

$$\begin{cases} \beta_{\phi_1}(\theta) \leq \beta_{\phi_2}(\theta) & \text{pour tout } \theta \in \Theta_0\ , \\ \beta_{\phi_1}(\theta) \geq \beta_{\phi_2}(\theta) & \text{pour tout } \theta \in \Theta_1\ , \end{cases}$$

alors ϕ_1 est préférable à ϕ_2 : il se trompe moins souvent des deux côtés. Cette relation définit un préordre sur l'ensemble des tests. Comme l'ordre partiel sur les risques du chapitre 3 (Section 1.5), il ne permet pas de comparer deux procédures quelconques : deux tests dont les fonctions puissance se croisent ne sont pas comparables.

Exemple 2.3: Test sur la moyenne d'une gaussienne de variance connue : calcul de la fonction puissan

Soit $Z = (X_1, \dots, X_n)$ un n-échantillon du modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(\theta, \sigma^2)\,,\ \theta \in \mathbb{R}\}\big)$, où $\sigma^2 \in \mathbb{R}_+^*$ est connue, et considérons le test

$$H_0 :\ \theta \leq 0, \quad \text{contre} \quad H_1 :\ \theta > 0\,.$$

On prend pour statistique de test

$$T(Z) := \sqrt{n}\,\frac{\bar{X}_n}{\sigma}\,,$$

et, pour $c \in \mathbb{R}$, on définit le test de valeur critique c par $\phi_c(Z) := \mathbb{1}_{\{T(Z)\geq c\}}$. Sa fonction puissance vaut, pour tout $\theta \in \mathbb{R}$,

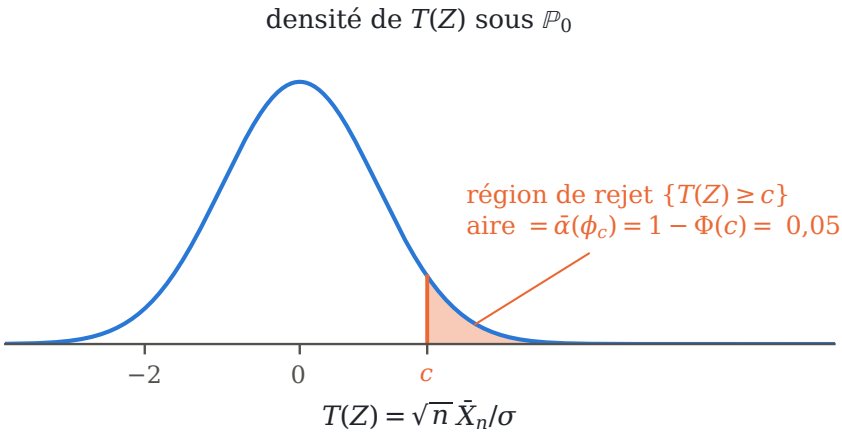
$$\begin{aligned}\beta_{\phi_c}(\theta) &= \mathbb{P}_\theta\big(\sqrt{n}\,\bar{X}_n/\sigma \geq c\big) = \mathbb{P}_\theta\Big(\frac{\sqrt{n}(\bar{X}_n - \theta)}{\sigma} \geq c - \frac{\sqrt{n}\,\theta}{\sigma}\Big)\\ &= 1 - \Phi\Big(c - \frac{\sqrt{n}\,\theta}{\sigma}\Big)\,,\end{aligned}$$

où Φ est la fonction de répartition de $\mathcal{N}(0,1)$, puisque $\sqrt{n}(\bar{X}_n - \theta)/\sigma \sim \mathcal{N}(0,1)$ sous $\mathbb{P}_\theta$. La fonction β_{ϕ_c} est strictement croissante, ce qui est la propriété qu'on attend : plus le paramètre est grand, plus il est probable qu'on rejette H_0. La taille du test vaut

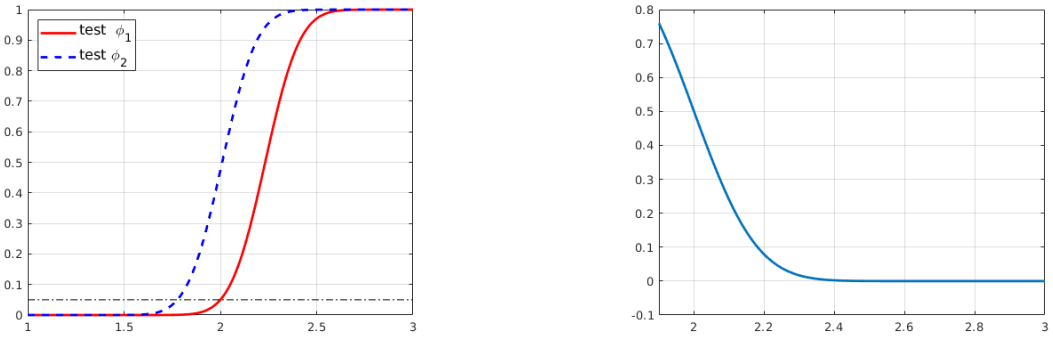
$$\overline{\alpha}(\phi_c) = \sup_{\theta\leq 0} \beta_{\phi_c}(\theta) = \sup_{\theta\leq 0}\Big\{1 - \Phi\Big(c - \frac{\sqrt{n}\,\theta}{\sigma}\Big)\Big\} = 1 - \Phi(c)\,,$$

le supremum étant atteint en $\theta = 0$. La taille décroît lorsque la valeur critique croît : on a donc intérêt à prendre c assez grand, et le choix $c = 0$ donnerait une taille de $1/2$. Pour obtenir un test de niveau α, et même de taille exactement α, on prend $c = z_{1-\alpha}$.

Sur cet exemple, la taille se lit comme une aire sous une courbe.



Densité de la statistique de test $T(Z) = \sqrt{n}\,\bar{X}_n/\sigma$ sous $\mathbb{P}_0$, qui est celle de $\mathcal{N}(0,1)$, pour la valeur critique $c = z_{0,95} \simeq 1{,}645$. Le test ϕ_c rejette H_0 lorsque la statistique tombe dans la zone ombrée, dont l'aire vaut $1 - \Phi(c) = 0{,}05$: c'est la taille du test, atteinte en $\theta = 0$. Déplacer c vers la droite diminue cette aire, donc la taille ; on verra à l'Exemple 2.4 que cela diminue en même temps la probabilité de rejeter lorsque $\theta > 0$.



Cas $\theta_0 = 2$, $n = 50$, pour le modèle $\mathcal{N}(\theta, 1)$ et la statistique $\bar{X}_n$. À gauche, les fonctions puissance des tests ϕ_1 et ϕ_2 de valeurs critiques $c_1 = 2{,}23$ et $c_2 = 0{,}9\,c_1$; le trait horizontal est la droite d'équation $y = 0{,}05$, et c_1 a été choisi pour que la taille de ϕ_1 vaille 5 %. À droite, la taille de ϕ_1 en fonction de sa valeur critique : elle vaut $1/2$ en $c = \theta_0$ et décroît vers 0.

Lorsque la valeur critique diminue, la région de rejet s'agrandit, et la probabilité de rejeter augmente sous toutes les valeurs du paramètre : la taille du test et sa puissance croissent ensemble. Le risque de première espèce et le risque de seconde espèce varient donc en sens contraire.

Exemple 2.4

Reprenons l'Exemple 2.1, avec $\Theta_0 =]-\infty, \theta_0]$ et $\Theta_1 =]\theta_0, +\infty[$, et donnons-nous deux réels $c_1 > c_2$. Posons $\phi_i(Z) := \mathbb{1}_{\{\bar{X}_n \geq c_i\}}$ pour $i \in \{1, 2\}$: la statistique de test est $T(Z) = \bar{X}_n$ et c_1, c_2 sont deux valeurs critiques. Les régions de rejet vérifient $\mathcal{R}_1 \subset \mathcal{R}_2$, donc

$$\beta_{\phi_1}(\theta) \leq \beta_{\phi_2}(\theta) \qquad \text{pour tout } \theta \in \Theta\,.$$

Plus précisément, sous $\mathbb{P}_\theta$, $\bar{X}_n \sim \mathcal{N}(\theta, 1/n)$, donc

$$\beta_{\phi_i}(\theta) = 1 - \Phi\big((c_i - \theta)\sqrt{n}\big)\,,$$

et la taille de ϕ_i vaut $\overline{\alpha}(\phi_i) = \sup_{\theta \leq \theta_0} \beta_{\phi_i}(\theta) = 1 - \Phi\big((c_i - \theta_0)\sqrt{n}\big)$.
L'inégalité $\beta_{\phi_1} \leq \beta_{\phi_2}$ se lit donc de deux façons opposées selon l'endroit où on la regarde. Sur Θ_0, elle dit que ϕ_1 a une taille strictement plus petite que ϕ_2 : ϕ_1 rejette moins souvent à tort. Sur Θ_1, la même inégalité dit que ϕ_1 a une puissance plus petite, donc un risque de seconde espèce plus grand : ϕ_1 manque plus souvent une alternative vraie. Les deux tests ne sont pas comparables au sens du préordre ci-dessus.
Pour $\theta_0 = 2$, $n = 50$ et un niveau $\alpha = 5\,\%$, la valeur critique c_1 est déterminée par $1 - \Phi\big((c_1 - \theta_0)\sqrt{n}\big) = 0{,}05$, c'est-à-dire $c_1 = \theta_0 + z_{0{,}95}/\sqrt{n} = 2 + 1{,}645/\sqrt{50} = 2{,}23$. En $\theta = \theta_0$, la fonction puissance vaut exactement la taille du test, soit 0,05.

Intuition. *On voudrait un test dont la fonction puissance soit nulle sur Θ_0 et égale à 1 sur Θ_1 : il ne se tromperait jamais. C'est impossible dès que Θ_0 et Θ_1 sont adjacents, comme ici en θ_0 : la fonction puissance est continue, et elle ne peut pas sauter de 0 à 1 au point de contact. La fonction puissance idéale est donc hors d'atteinte, et tout ce qu'on peut faire est de la rendre petite sur Θ_0 et grande sur Θ_1, deux objectifs qu'on ne peut pas satisfaire simultanément, puisque déplacer la valeur critique les fait varier dans le même sens.*

Exemple 2.5: Sondage : taille du test et seuil entier

Reprenons l'Exemple 2.2. La loi de $S_n = \sum_{i=1}^n X_i$ est explicite : sous $\mathbb{P}_\theta$, $S_n \sim \mathrm{Bin}(n, \theta)$,

c'est-à-dire

$$\mathbb{P}_\theta(S_n = k) = \binom{n}{k}\theta^k(1-\theta)^{n-k}\ , \qquad k \in \{0,\dots,n\}\ .$$

Croissance en θ. Montrons d'abord que, pour tout c fixé, la fonction $\theta \mapsto \mathbb{P}_\theta(S_n \geq c)$ est croissante, c'est-à-dire que

$$\mathbb{P}_\theta(S_n \geq c) \leq \mathbb{P}_\vartheta(S_n \geq c) \qquad \text{pour tous } 0 \leq \theta \leq \vartheta \leq 1\ .$$

Soient $U_1,\dots,U_n$ des variables aléatoires indépendantes de loi $\mathcal{U}([0,1])$. Pour $i \in \{1,\dots,n\}$, posons $A_i := \mathbb{1}_{\{U_i \leq \theta\}}$ et $B_i := \mathbb{1}_{\{U_i \leq \vartheta\}}$, de sorte que $A_i \leq B_i$ presque sûrement. Alors $\sum_{i=1}^n A_i \sim \mathrm{Bin}(n,\theta)$, $\sum_{i=1}^n B_i \sim \mathrm{Bin}(n,\vartheta)$ et $\sum_{i=1}^n A_i \leq \sum_{i=1}^n B_i$, d'où

$$\mathbb{P}_\theta(S_n \geq c) = \mathbb{P}\Big(\sum_{i=1}^n A_i \geq c\Big) \leq \mathbb{P}\Big(\sum_{i=1}^n B_i \geq c\Big) = \mathbb{P}_\vartheta(S_n \geq c)\ .$$

Ce procédé, qui réalise deux lois sur un même espace de façon à les comparer trajectoire par trajectoire, est un *couplage* (Section 3).

Taille. Il s'ensuit que, pour tout c,

$$\overline{\alpha}(\phi) = \sup_{\theta \leq \theta_0} \mathbb{P}_\theta(S_n \geq c) = \mathbb{P}_{\theta_0}(S_n \geq c)\ .$$

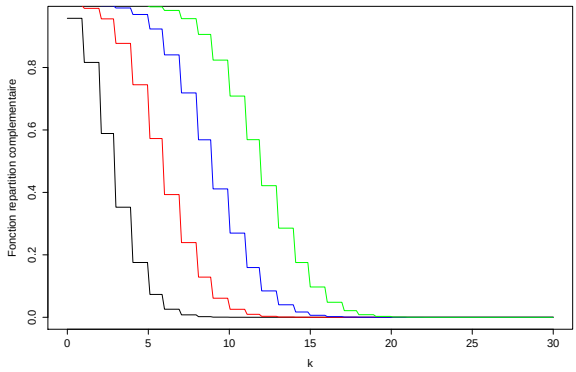
Choix du seuil. Comme S_n ne prend que des valeurs entières, il n'existe pas en général de valeur critique pour laquelle la taille égale exactement le niveau α. Pour obtenir un test de niveau α, on prend

$$c_\alpha := \min\left\{k \in \{0,\dots,n+1\}\,,\ \mathbb{P}_{\theta_0}(S_n \geq k) \leq \alpha\right\}\ ,$$

l'ensemble étant non vide puisque $\mathbb{P}_{\theta_0}(S_n \geq n+1) = 0$. Le test $\phi_\alpha(Z) = \mathbb{1}_{\{S_n \geq c_\alpha\}}$ est alors de niveau α, et sa taille est en général strictement inférieure à α. Enfin, la croissance établie plus haut donne, pour tout $\theta \in \Theta_1$,

$$\beta_{\phi_\alpha}(\theta) = \mathbb{P}_\theta(S_n \geq c_\alpha) \geq \mathbb{P}_{\theta_0}(S_n \geq c_\alpha) = \overline{\alpha}(\phi_\alpha)\ ,$$

c'est-à-dire que la puissance sur l'alternative est au moins égale à la taille.



Fonction de répartition complémentaire $c \mapsto \mathbb{P}_\theta(S_n \geq c)$ de la loi binomiale pour $n = 30$ et $\theta = 0{,}1$ (noir), 0,2 (rouge), 0,3 (bleu) et 0,4 (vert). Les courbes ne se croisent pas : c'est la croissance en θ établie par couplage, et l'escalier rend visible que la taille ne peut prendre qu'un nombre fini de valeurs.

2.4 L'approche de Neyman-Pearson

Chercher à minimiser la taille conduit à prendre la région de rejet la plus petite possible ; chercher à maximiser la puissance sur Θ_1 conduit à la prendre la plus grande possible. Les deux objectifs sont contradictoires, et la détermination de la région de rejet oblige à un compromis. La règle la plus communément admise pour le trancher est celle de *Neyman-Pearson* : elle se fonde sur une dissymétrie entre H_0 et H_1. On se donne un niveau $\alpha \in]0,1[$, typiquement petit (de l'ordre de 5 %, de 10^{-3} ou de 10^{-6} selon les applications), on ne retient que les tests de niveau α, et l'on cherche parmi eux à maximiser la fonction puissance sur Θ_1.

Intuition. *La dissymétrie n'est pas un artifice mathématique : elle correspond à des situations où les deux erreurs n'ont pas la même gravité. C'et le cas dans de nombreuses applications, et le choix de l'hypothèse nulle est crucial. Considérez par exemple les trois situations que les exemples ci-dessus décrivent :*

1. *dans un dépistage, qu'est-ce qui est le plus problématique : dire à un malade qu'il ne l'est pas, ou dire à un bien portant qu'il est malade ?*
2. *Dans un contrôle antidopage : laisser passer un sportif dopé, ou accuser un sportif qui ne l'est pas ?*
3. *Dans une expérience de physique : manquer la découverte d'une particule nouvelle, ou annoncer une découverte sans preuve suffisante ?*

Les réponses ne sont pas les mêmes dans les trois cas, et c'est ce qui détermine laquelle des deux hypothèses on met en H_0.

Dans l'approche de Neyman-Pearson, on garantit en priorité un risque de première espèce contrôlé : on s'assure de ne rejeter H_0 à tort qu'avec une probabilité petite, sous le modèle et sous H_0. La conséquence est que **la seule décision forte est de rejeter** H_0 : c'est elle, et elle seule, qui est assortie d'une garantie. Ne pas rejeter H_0 ne prouve rien. Cela peut signifier que H_0 est vraie, ou simplement que les données ne suffisent pas à la mettre en défaut. Le choix de H_0 est donc crucial, et il obéit à deux heuristiques.

— *Choisir en H_0 l'hypothèse qui est en notre défaveur.* Si l'on veut établir l'efficacité d'un nouveau médicament à partir d'essais cliniques, on met en H_0 que le médicament est inefficace : si cette hypothèse est rejetée, la conclusion est probante, ce qu'elle ne serait pas si la même hypothèse était simplement acceptée.

— *Choisir en H_0 l'hypothèse la plus dangereuse.* Si l'on teste la sécurité sismique d'un site avant l'implantation d'une centrale nucléaire, il est crucial de détecter un risque : on met donc en H_0 la présence d'un risque, quitte à écarter à tort un site sûr, ce qui est bien moins grave.

En vertu du second principe, deux groupes aux intérêts différents partiront souvent d'hypothèses nulles inversées : par exemple, dans un cas pratique, on peut imaginer qu'industriels et associations de consommateurs ne posent pas le même H_0.

L'exemple suivant montre ce que devient un test lorsqu'on échange les deux hypothèses.

Exemple 2.6: Échanger H_0 et H_1

Reprenons le modèle $\mathcal{N}(\theta,1)$ et un n-échantillon. Pour le test $H_0 : \theta \leq \theta_0$ contre $H_1 : \theta > \theta_0$, le calcul de l'Exemple 2.3, transposé au seuil θ_0, donne la région de rejet de niveau et de taille α

$$\mathcal{R} = \left\{ \sqrt{n}(\bar{X}_n - \theta_0) \geq z_{1-\alpha} \right\} .$$

Échangeons maintenant les hypothèses et testons $H_0' : \theta > \theta_0$ contre $H_1' : \theta \leq \theta_0$. On rejette cette fois pour des valeurs petites de $\bar{X}_n$: pour $c \in \mathbb{R}$, le test $\phi(Z) = \mathbb{1}_{\{\bar{X}_n \leq c\}}$ a pour fonction puissance

$$\theta \longmapsto \mathbb{P}_\theta(\bar{X}_n \leq c) = \Phi\big(\sqrt{n}(c-\theta)\big) ,$$

et sa taille vaut $\sup_{\theta>\theta_0} \Phi(\sqrt{n}(c-\theta)) = \Phi(\sqrt{n}(c-\theta_0))$. Ce supremum n'est pas atteint, puisque $\theta_0 \notin \Theta_0'$, mais il vaut bien la limite lorsque θ décroît vers θ_0. En choisissant c tel que cette taille égale α, c'est-à-dire $c = \theta_0 + z_\alpha/\sqrt{n} = \theta_0 - z_{1-\alpha}/\sqrt{n}$, on obtient la région de rejet

$$\mathcal{R}' = \left\{ \sqrt{n}(\bar{X}_n - \theta_0) \leq -z_{1-\alpha} \right\} .$$

Les deux régions de rejet ne sont pas complémentaires : entre les deux se trouve tout un domaine de valeurs de $\bar{X}_n$ où aucun des deux tests ne réussit à rejetter son hypothèse nulle.

Exemple 2.7: Trois régions, deux hypothèses simples

Précisons ce point sur un test entre deux hypothèses simples. Fixons $\theta_1 > 0$ et soit $(X_1, \dots, X_n)$ un n-échantillon du modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathcal{N}(\theta, 1)\,,\ \theta \in \Theta := \{0, \theta_1\}\}\big)$, dont l'espace des paramètres se réduit aux deux valeurs en présence. Pour tester $H_0 : \theta = 0$ contre $H_1 : \theta = \theta_1$, on prend $\bar{X}_n$ pour statistique et l'on cherche une région de rejet de la forme $\{\bar{X}_n \geq c\}$; le choix $c = z_{1-\alpha}/\sqrt{n}$ donne une taille égale à α, soit

$$\mathcal{R} := \left\{ \bar{X}_n \geq \frac{z_{1-\alpha}}{\sqrt{n}} \right\} .$$

Échangeons les hypothèses : pour tester $H_0' : \theta = \theta_1$ contre $H_1' : \theta = 0$, la même construction donne

$$\mathcal{R}' := \left\{ \bar{X}_n \leq \theta_1 - \frac{z_{1-\alpha}}{\sqrt{n}} \right\} ,$$

de taille α également. Supposons $0 < \theta_1 < 2z_{1-\alpha}/\sqrt{n}$, de sorte que $\theta_1 - z_{1-\alpha}/\sqrt{n} < z_{1-\alpha}/\sqrt{n}$. L'ensemble des valeurs prises par $\bar{X}_n$ se découpe alors en trois :

- $\big\{\bar{X}_n \leq \theta_1 - z_{1-\alpha}/\sqrt{n}\big\}$: le premier test ne rejette pas H_0, le second rejette H_0' ; les deux concluent $\theta = 0$.
- $\big\{\bar{X}_n \geq z_{1-\alpha}/\sqrt{n}\big\}$: le premier test rejette H_0, le second ne rejette pas H_0' ; les deux concluent $\theta = \theta_1$.
- $\big\{\theta_1 - z_{1-\alpha}/\sqrt{n} < \bar{X}_n < z_{1-\alpha}/\sqrt{n}\big\}$: aucun des deux tests ne rejette son hypothèse nulle. Une même observation conduit donc à conclure $\theta = 0$ si l'on a mis $\theta = 0$ en H_0, et $\theta = \theta_1$ si l'on y a mis $\theta = \theta_1$.

Dans cette troisième région, les données ne permettent pas de trancher entre les deux valeurs, et la règle de Neyman-Pearson consiste à retenir l'hypothèse nulle. La contradiction n'est qu'apparente : les deux procédures ne répondent pas à la même question, puisqu'elles ne protègent pas la même hypothèse.

2.5 Comment construire un test

La démarche que suivent tous les exemples précédents peut s'énoncer une fois pour toutes.

Méthode 2.1: Construction d'un test de niveau α

(0) Choisir le niveau $\alpha \in]0, 1[$: c'est le seul seuil que l'on fixe.

(1) Choisir une statistique de test $T(Z)$, en fonction de H_0 et du modèle.

(2) Choisir la forme de la région de rejet, en fonction de H_1 : typiquement $\{T(Z) \geq c_\alpha\}$ pour une alternative unilatérale, $\{|T(Z) - t_0| \geq c_\alpha\}$ pour une alternative bilatérale. Le test est alors $\phi_\alpha(Z) = \mathbb{1}_{\{T(Z) \in \mathcal{R}_\alpha\}}$.

(3) Choisir c_α de sorte que la taille soit au plus α, c'est-à-dire

$$\sup_{\theta \in \Theta_0} \mathbb{P}_\theta\big(T(Z) \geq c_\alpha\big) \leq \alpha .$$

Cette étape demande de connaître la loi de $T(Z)$ sous H_0.

(4) Éventuellement, calculer la fonction puissance β_{ϕ_α}.

(5) Éventuellement, calculer la p-valeur $\hat{\alpha}(Z)$ associée.

(6) Conclure numériquement.

L'étape (1) est la seule où le choix n'est pas dicté par la construction. Une réponse générale existe (prendre par défaut le test du rapport de vraisemblance) ; elle est l'objet du chapitre 5.

L'exemple qui suit déroule les six étapes sur une situation concrète, d'abord du point de vue de l'une des parties en présence, puis du point de vue de l'autre.

Exemple 2.8: Bruit d'aéroport : le point de vue des riverains

On considère un aéroport en conflit avec des riverains sur le niveau de bruit. La réglementation fixe le seuil légal à μ_0, par exemple 80 décibels. *Les riverains veulent établir que le niveau de bruit dépasse ce seuil.* On effectue n mesures, modélisées par un n-échantillon de $\mathcal{N}(\mu, \sigma^2)$, avec σ^2 connue.
(1) Choix des hypothèses. La seule décision forte étant de rejeter H_0, et les riverains cherchant à établir $\mu > \mu_0$, il faut mettre l'assertion contraire en hypothèse nulle :

$$H_0 : \ \mu \leq \mu_0, \quad \text{contre} \quad H_1 : \ \mu > \mu_0 \ .$$

(2) Statistique de test. On prend $T(Z) := \sqrt{n}(\bar{X}_n - \mu_0)/\sigma$, dont la loi sous $\mathbb{P}_{\mu_0}$ est $\mathcal{N}(0,1)$. Ni $\bar{X}_n$ seul, ni $\bar{X}_n - \mu_0$ ne conviendraient aussi bien : leur loi dépend encore de n et de σ, et il faudrait recalculer les quantiles à chaque jeu de données.
(3) Forme de la région de rejet. L'alternative étant $\mu > \mu_0$, on rejette pour des valeurs grandes de $T(Z)$: $\mathcal{R}_\alpha = \{T(Z) \geq c\}$.
(4) Valeur critique. La fonction puissance vaut $\beta(\mu) = 1 - \Phi\big(c - \sqrt{n}(\mu - \mu_0)/\sigma\big)$, donc la taille vaut $\sup_{\mu \leq \mu_0} \beta(\mu) = 1 - \Phi(c)$, et le choix $c = z_{1-\alpha}$ donne un test de taille exactement α.
(5) Application numérique. Pour $n = 100$, $\bar{X}_n = 82$ dB et $\sigma = 10$, on a $T(Z) = 10 \times (82 - 80)/10 = 2$. Au niveau $\alpha = 5\,\%$, $z_{0{,}95} = 1{,}645$, et $2 \geq 1{,}645$: on rejette H_0. De façon équivalente, on rejette dès que $\bar{X}_n \geq \mu_0 + \sigma z_{1-\alpha}/\sqrt{n} = 80 + 1{,}645 = 81{,}645$, ce qui est le cas. Au niveau $\alpha = 0{,}1\,\%$, $z_{0{,}999} = 3{,}090$, et $2 < 3{,}090$: on échoue à rejeter H_0.
(6) Conclusion. Au niveau 5 %, les riverains ont établi statistiquement que le niveau de bruit dépasse le seuil réglementaire. Au niveau 0,1 %, ils n'ont rien établi, ce qui ne signifie pas que le seuil est respecté.

Exemple 2.9: Bruit d'aéroport : le point de vue de l'aéroport

Même situation, mêmes données, mais *l'aéroport veut établir que le niveau de bruit ne dépasse pas le seuil.* L'hypothèse à mettre en H_0 est cette fois celle qui lui est défavorable :

$$H_0 : \ \mu \geq \mu_0, \quad \text{contre} \quad H_1 : \ \mu < \mu_0 \ .$$

La statistique reste $T(Z) = \sqrt{n}(\bar{X}_n - \mu_0)/\sigma$, mais l'alternative étant $\mu < \mu_0$, on rejette pour des valeurs petites : $\mathcal{R}'_\alpha = \{T(Z) \leq c'\}$. La taille vaut $\sup_{\mu \geq \mu_0} \Phi\big(c' - \sqrt{n}(\mu - \mu_0)/\sigma\big) = \Phi(c')$, atteinte en $\mu = \mu_0$, d'où $c' = z_\alpha = -z_{1-\alpha}$ et

$$\mathcal{R}'_\alpha = \big\{T(Z) \leq -z_{1-\alpha}\big\} \ .$$

Avec les mêmes données, $T(Z) = 2 > -1{,}645$: l'aéroport échoue à rejeter son hypothèse nulle, à tous les niveaux usuels. Il n'a donc rien établi.
Le même jeu de données conduit ainsi à des conclusions qui semblent contradictoires selon la partie qui pose la question, alors qu'elles ne le sont pas : chacune protège une hypothèse différente, et aucune des deux n'a « prouvé » que l'autre avait tort. Ici, seuls les riverains obtiennent une conclusion forte.

2.6 Construire un test à partir d'un pivot

La première moitié du chapitre a construit des régions de confiance à partir de pivots ; la même construction fournit des tests, et c'est le pont entre les deux notions. Soit G une fonction pivotale.

Pour tout $\alpha \in [0,1]$, on peut déterminer des réels t_α^- et t_α^+ tels que

$$\mathbb{P}_\theta\big(G(Z,\theta) \in \big[t_\alpha^-, t_\alpha^+\big]\,\big) \geq 1-\alpha \qquad \text{pour tout } \theta \in \Theta\,,$$

de sorte que $\hat{I}_\alpha := \{\theta \in \Theta\,,\ G(Z,\theta) \in [t_\alpha^-, t_\alpha^+]\}$ est une région de confiance de niveau $1-\alpha$ pour θ. Pour tester $H_0 : \theta = \theta_0$, il est naturel de rejeter lorsque $\theta_0 \notin \hat{I}_\alpha$, c'est-à-dire lorsque $G(Z,\theta_0) \notin [t_\alpha^-, t_\alpha^+]$. Attention toutefois : la région de confiance obtenue est en général implicite, et il n'est pas toujours facile d'en déduire un test explicite. Les trois exemples qui suivent sont des situations classiques où la résolution est possible.

Exemple 2.10: Test sur la moyenne, variance connue

Soit $(X_1,\dots,X_n)$ un n-échantillon du modèle $\big\{\mathcal{N}(\mu,\sigma^2)\,,\ \mu \in \mathbb{R}\big\}$, où σ^2 est connue, et soit $\mu_0 \in \mathbb{R}$. La fonction $G(Z;\mu) := \sqrt{n}(\bar{X}_n - \mu)/\sigma$ est pivotale, de loi $\mathcal{N}(0,1)$ (Exemple 1.4). Considérons le test bilatéral

$$H_0 :\ \mu = \mu_0, \quad \text{contre} \quad H_1 :\ \mu \neq \mu_0\,.$$

Sous H_0, $G(Z;\mu_0) \sim \mathcal{N}(0,1)$, donc pour tout $\alpha \in\,]0,1[$,

$$\mathbb{P}_{\mu_0}\Big(\big|G(Z;\mu_0)\big| < z_{1-\alpha/2}\Big) = 1-\alpha\,,$$

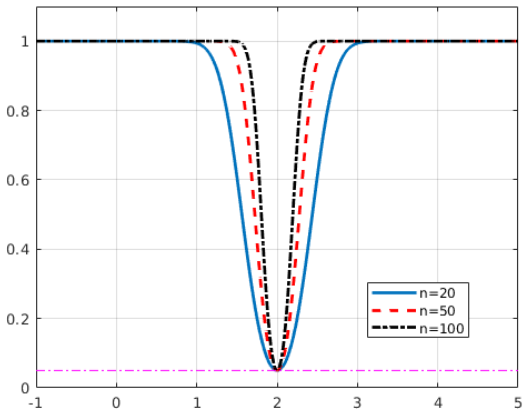
et le test $\phi_\alpha(Z) := \mathbb{1}_{\{|G(Z;\mu_0)| \geq z_{1-\alpha/2}\}}$ est de niveau et de taille α. Sa région d'acceptation est

$$\mathcal{A}_\alpha = \Big\{(x_1,\dots,x_n) \in \mathbb{R}^n\,,\ \mu_0 - z_{1-\alpha/2}\tfrac{\sigma}{\sqrt{n}} < n^{-1}\textstyle\sum_{i=1}^n x_i < \mu_0 + z_{1-\alpha/2}\tfrac{\sigma}{\sqrt{n}}\Big\}\,.$$

La fonction puissance se calcule explicitement, la loi de $(\bar{X}_n - \mu)/(\sigma/\sqrt{n})$ sous $\mathbb{P}_\mu$ restant $\mathcal{N}(0,1)$ pour tout μ :

$$\begin{aligned}
\beta(\mu) &= 1 - \mathbb{P}_\mu\Big(-z_{1-\alpha/2} < \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} < z_{1-\alpha/2}\Big)\\
&= 1 - \mathbb{P}_\mu\Big(\frac{\mu_0-\mu}{\sigma/\sqrt{n}} - z_{1-\alpha/2} < \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} < \frac{\mu_0-\mu}{\sigma/\sqrt{n}} + z_{1-\alpha/2}\Big)\\
&= 1 - \Phi\Big(\frac{\mu_0-\mu}{\sigma/\sqrt{n}} + z_{1-\alpha/2}\Big) + \Phi\Big(\frac{\mu_0-\mu}{\sigma/\sqrt{n}} - z_{1-\alpha/2}\Big)\,.
\end{aligned}$$

La fonction $\mu \mapsto \beta(\mu)$ atteint son minimum en $\mu = \mu_0$, où elle vaut α, et elle tend vers 1 lorsque n tend vers l'infini, aussi bien pour $\mu > \mu_0$ que pour $\mu < \mu_0$.



Fonction puissance du test bilatéral sur la moyenne, pour $n = 20$, $n = 50$ et $n = 100$, avec $\alpha = 0{,}05$, $\mu_0 = 2$ et $\sigma = 1$. Le trait horizontal est la droite d'équation $y = \alpha$; les trois courbes se rejoignent en $\mu = \mu_0$, où la puissance vaut la taille.

Exemple 2.11: Test sur la moyenne, variance inconnue

Soit $(X_1, \dots, X_n)$, $n \geq 2$, un n-échantillon du modèle $\{\mathcal{N}(\mu, \sigma^2)\,,\ (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}$ et soit $\mu_0 \in \mathbb{R}$. Par le théorème de Gosset, la fonction

$$G(Z; \mu) := \frac{\bar{X}_n - \mu}{S_n/\sqrt{n}}$$

est pivotale, de loi $\mathrm{t}(n-1)$. Sous l'hypothèse nulle du test $H_0 :\ \mu = \mu_0, \quad$ contre $\quad H_1 :\ \mu \neq \mu_0$, on a $G(Z; \mu_0) \sim \mathrm{t}(n-1)$, donc

$$\mathbb{P}_{\mu_0, \sigma^2}\Big(-\mathrm{t}_{1-\alpha/2}^{(n-1)} < G(Z; \mu_0) < \mathrm{t}_{1-\alpha/2}^{(n-1)} \Big) = 1 - \alpha$$

pour tout $\sigma^2 > 0$, et le test

$$\phi_\alpha(Z) := \mathbb{1}_{\{\left|G(Z;\mu_0)\right| \geq \mathrm{t}_{1-\alpha/2}^{(n-1)}\}}$$

est de taille α. C'est le *test de Student*.
Sa fonction puissance ne s'exprime plus à l'aide de la loi de Student : sous $\mathbb{P}_{(\mu,\sigma^2)}$ avec $\mu \neq \mu_0$, la quantité μ_0 n'est plus l'espérance de $\bar{X}_n$. En écrivant

$$\frac{\bar{X}_n - \mu_0}{S_n/\sqrt{n}} = \frac{\sqrt{n}(\bar{X}_n - \mu)/\sigma + \sqrt{n}(\mu - \mu_0)/\sigma}{S_n/\sigma}\ ,$$

on reconnaît, au numérateur, une variable $\mathcal{N}\big(\sqrt{n}(\mu - \mu_0)/\sigma, 1\big)$ et, au dénominateur, la racine de $S_n^2/\sigma^2 = \chi^2(n-1)/(n-1)$, indépendante du numérateur : la statistique de test suit une *loi de Student non centrale* à $n-1$ degrés de liberté et de paramètre de non-centralité $\sqrt{n}(\mu - \mu_0)/\sigma$ (Section 3).

Exemple 2.12: Test sur la variance

Soit $(X_1, \dots, X_n)$, $n \geq 2$, un n-échantillon du modèle $\{\mathcal{N}(\mu, \sigma^2)\,,\ (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\}$ et soit $\sigma_0^2 > 0$. On considère

$$H_0 :\ \sigma^2 = \sigma_0^2, \quad \text{contre} \quad H_1 :\ \sigma^2 \neq \sigma_0^2\ .$$

La fonction $G(Z; \sigma^2) := (n-1)S_n^2/\sigma^2$ est pivotale, de loi $\chi^2(n-1)$ (Exemple 1.6). Sous H_0, pour tout $\mu \in \mathbb{R}$,

$$\mathbb{P}_{\mu, \sigma_0^2}\Big(\chi^2_{\alpha/2}(n-1) < \frac{(n-1)S_n^2}{\sigma_0^2} < \chi^2_{1-\alpha/2}(n-1) \Big) = 1 - \alpha\ ,$$

de sorte que le test

$$\phi_\alpha(Z) := \mathbb{1}_{\{\frac{(n-1)S_n^2}{\sigma_0^2} \notin \left]\chi^2_{\alpha/2}(n-1), \chi^2_{1-\alpha/2}(n-1)\right[\}}$$

est de niveau et de taille α. La loi du χ^2 n'étant pas symétrique, les deux quantiles ne sont pas opposés, et la région de rejet n'est pas symétrique autour de σ_0^2.

Ces trois exemples ferment le triptyque du modèle gaussien : moyenne à variance connue, moyenne à variance inconnue, variance. Leur version à deux échantillons (comparaison de deux moyennes, comparaison de deux variances) fait l'objet de l'Exercice 5 (PC4).

2.7 La p-valeur

Se fixer un niveau α à l'avance a l'avantage de la simplicité, mais ne rend qu'une information binaire : rejet ou non-rejet. On peut demander davantage. Si je réduis le niveau, est-ce que je rejette plus ou moins souvent ?

→ **Le niveau α est ma tolérance à l'erreur de première espèce** ; en la diminuant, j'accepte de moins en moins de rejeter à tort, donc je rejette de moins en moins. Pour une famille de tests dont les régions de rejet décroissent avec α, il existe donc un niveau à partir duquel je cesse de rejeter, et ce niveau est une fonction des observations. C'est la p-valeur.

Définition 2.4: p-valeur

Soit $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique. Soit $\{\phi_\alpha\,,\ \alpha \in [0,1]\}$ une famille de tests purs vérifiant

(a) pour tout $\alpha \in [0,1]$, le test ϕ_α est de niveau α, c'est-à-dire $\overline{\alpha}(\phi_\alpha) = \sup_{\theta\in\Theta_0} \beta_{\phi_\alpha}(\theta) \leq \alpha$;

(b) pour tous $0 \leq \alpha \leq \alpha' < 1$, $\mathcal{R}_\alpha \subset \mathcal{R}_{\alpha'}$, où $\mathcal{R}_\alpha := \{z \in \mathsf{Z}\,,\ \phi_\alpha(z) = 1\}$.

La *p-valeur* de l'observation Z pour cette famille de tests est

$$\hat{\alpha}(Z) := \inf\{\alpha \in [0,1]\ ,\ Z \in \mathcal{R}_\alpha\}\ .$$

La condition (b) est ce qui donne son sens à l'infimum : augmenter le niveau, donc la tolérance, revient à agrandir la région de rejet. La p-valeur est alors la plus petite taille de test qui conduise à rejeter l'hypothèse nulle sur l'observation dont on dispose. Autrement dit, H_0 est rejetée pour tout niveau $\alpha > \hat{\alpha}(Z)$ et n'est pas rejetée pour tout $\alpha < \hat{\alpha}(Z)$. En particulier, plus la p-valeur est faible, plus les données sont défavorables à l'hypothèse nulle.

Proposition 2.1: Calcul pratique de la p-valeur

Soit $\{\phi_\alpha\,,\ \alpha \in [0,1]\}$ une famille de tests purs de niveau α, de la forme $\phi_\alpha(Z) = \mathbb{1}_{\{T(Z)\geq c_\alpha\}}$, où $\alpha \mapsto c_\alpha$ est décroissante sur $[0,1]$. Alors la famille vérifie la condition (b) de la Définition 2.4 et

$$\hat{\alpha}(Z) = \inf\{\alpha \in\,]0,1[\ ,\ T(Z) \geq c_\alpha\}\ .$$

Démonstration

Pour $\alpha \leq \alpha'$, la décroissance de $\alpha \mapsto c_\alpha$ donne $c_{\alpha'} \leq c_\alpha$, donc $\mathcal{R}_\alpha = \{z\,,\ T(z) \geq c_\alpha\} \subset \{z\,,\ T(z) \geq c_{\alpha'}\} = \mathcal{R}_{\alpha'}$: la condition (b) est vérifiée. L'expression de la p-valeur est alors la définition, réécrite avec $\mathcal{R}_\alpha = \{T(Z) \geq c_\alpha\}$. □

Exemple 2.13: p-valeur pour la moyenne d'une gaussienne

Soit $Z = (X_1, \ldots, X_n)$ un n-échantillon du modèle $\big(\mathbb{R}, \mathcal{B}(\mathbb{R}), \big\{\mathcal{N}(\theta, \sigma^2)\,,\ \theta \in \Theta := \mathbb{R}\big\}\big)$, avec σ^2 connue, et considérons $H_0 :\ \theta \leq 0,\quad$ contre $\quad H_1 :\ \theta > 0$. D'après l'Exemple 2.3, le test $\phi_\alpha(Z) = \mathbb{1}_{\{T(Z)\geq z_{1-\alpha}\}}$, avec $T(Z) = \sqrt{n}\,\bar{X}_n/\sigma$, est de niveau α ; sa région de rejet est

$$\mathcal{R}_\alpha = \big\{\sqrt{n}\,\bar{X}_n/\sigma \geq z_{1-\alpha}\big\}\ .$$

Comme $\alpha \mapsto z_{1-\alpha}$ est décroissante, la Proposition 2.1 s'applique. Or Φ est continue et strictement croissante, donc, pour $\alpha \in\,]0,1[$,

$$\sqrt{n}\,\bar{X}_n/\sigma \geq z_{1-\alpha} \text{ if and only if } \Phi\big(\sqrt{n}\,\bar{X}_n/\sigma\big) \geq 1-\alpha \text{ if and only if } \alpha \geq 1 - \Phi\big(\sqrt{n}\,\bar{X}_n/\sigma\big)\ ,$$

d'où

$$\hat{\alpha}(Z) = 1 - \Phi\big(\sqrt{n}\,\bar{X}_n/\sigma\big)\ .$$

La p-valeur ne dépend de l'observation qu'à travers $\bar{X}_n$. Pour $n = 100$ et $\sigma = 1$, on obtient $\hat{\alpha} = 0{,}999$ si $\bar{X}_n = -0{,}3$, $\hat{\alpha} = 0{,}159$ si $\bar{X}_n = 0{,}1$, et $\hat{\alpha} = 1{,}35 \cdot 10^{-3}$ si $\bar{X}_n = 0{,}3$.

Comment s'en servir. Supposons avoir calculé une p-valeur de 2 % sur un jeu de données. Alors, pour tout niveau $\alpha > 2\,\%$, on rejette H_0 ; pour tout niveau $\alpha < 2\,\%$, on échoue à rejeter H_0. La p-valeur résume donc, en un seul nombre, la réponse du test à tous les niveaux à la fois. C'est pour cela qu'on la publie plutôt que la seule décision.

L'énoncé suivant explique ce que l'on voit lorsqu'on répète l'expérience et que l'on trace l'histogramme des p-valeurs obtenues.

Proposition 2.2: Loi de la p-valeur sous l'hypothèse nulle

Soit $(\mathsf{Z}, \mathcal{Z}, \{\mathbb{P}_\theta\,,\ \theta \in \Theta\})$ un modèle statistique paramétrique et soit (Θ_0, Θ_1) une partition de Θ. Soit $\{\phi_\alpha\,,\ \alpha \in [0,1]\}$ une famille de tests purs vérifiant les conditions (a) et (b) de la Définition 2.4, et soit $\hat{\alpha}(Z)$ la p-valeur associée. Alors, pour tout $\theta \in \Theta_0$,

$$\mathbb{P}_\theta\big(\hat{\alpha}(Z) \le u\big) \le u \qquad \text{pour tout } u \in [0,1]\ , \tag{1}$$

c'est-à-dire que $\hat{\alpha}(Z)$ est stochastiquement dominée par la loi $\mathcal{U}([0,1])$. Si de plus

$$\mathbb{P}_\theta\big(Z \in \mathcal{R}_\alpha\big) = \alpha \qquad \text{pour tout } \alpha \in\,]0,1[\ , \tag{2}$$

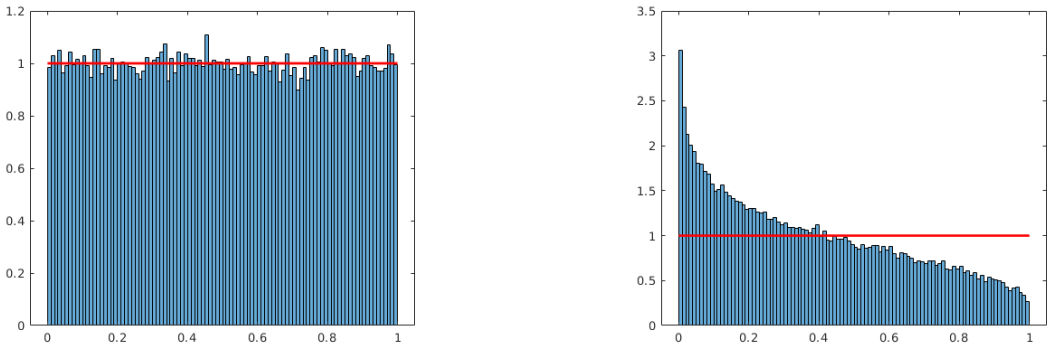
alors $\mathbb{P}_\theta(\hat{\alpha}(Z) \le u) = u$ pour tout $u \in\,]0,1[$: la statistique $\hat{\alpha}(Z)$ suit la loi uniforme sur $]0,1[$.

Démonstration

Soit $\theta \in \Theta_0$ et $u \in [0,1]$.
Domination. Soit $v \in\,]u,1[$. Si $\hat{\alpha}(Z) \le u < v$, alors, par définition de l'infimum, il existe $\alpha < v$ tel que $Z \in \mathcal{R}_\alpha$, et la condition (b) donne $\mathcal{R}_\alpha \subset \mathcal{R}_v$, donc $Z \in \mathcal{R}_v$. Ainsi $\{\hat{\alpha}(Z) \le u\} \subset \{Z \in \mathcal{R}_v\}$, et la condition (a) donne

$$\mathbb{P}_\theta\big(\hat{\alpha}(Z) \le u\big) \le \mathbb{P}_\theta\big(Z \in \mathcal{R}_v\big) \le \overline{\alpha}(\phi_v) \le v\ .$$

Cette inégalité valant pour tout $v > u$, on obtient (1) en faisant tendre v vers u par valeurs supérieures.
Cas d'égalité. Par définition de l'infimum, $\{Z \in \mathcal{R}_u\} \subset \{\hat{\alpha}(Z) \le u\}$, donc $\mathbb{P}_\theta(\hat{\alpha}(Z) \le u) \ge \mathbb{P}_\theta(Z \in \mathcal{R}_u)$. Si (2) est satisfaite, le membre de droite vaut u, d'où $\mathbb{P}_\theta(\hat{\alpha}(Z) \le u) \ge u$; combinée à (1), cette inégalité donne l'égalité annoncée. □



Histogramme de $N = 10^5$ p-valeurs associées à N observations indépendantes, pour le test de région de rejet $\{\bar{X}_n \ge \theta_0 + z_{1-\alpha}/\sqrt{n}\}$ avec $\theta_0 = 2$ et $n = 20$. Les observations sont des n-échantillons de $\mathcal{N}(\theta, 1)$; à gauche $\theta = 2$, à droite $\theta = 2{,}1$. Le trait horizontal d'équation $y = 1$ est la densité de la loi uniforme sur $[0,1]$.

Intuition. *La proposition explique ce que montrent ces deux histogrammes. À gauche, on est sous H_0 avec un niveau atteint, et la p-valeur est uniforme : elle ne porte alors aucune information, ce qui est cohérent,*

puisque l'hypothèse nulle est vraie. À droite, on est sous l'alternative, et l'histogramme se concentre près de zéro : les petites p-valeurs deviennent fréquentes. C'est ce contraste qui autorise à lire une petite p-valeur comme une indication défavorable à H_0, et rien de plus. La domination stochastique, plutôt que l'égalité, correspond aux cas où le niveau n'est pas atteint, par exemple lorsque la statistique de test est discrète, comme dans le modèle du sondage : l'histogramme n'y est plus plat.

2.8 Ce qu'un test dit et ce qu'il ne dit pas

Les six points suivants résument les erreurs d'interprétation les plus fréquentes, et se déduisent tous de ce qui précède.

1. La p-valeur n'est pas la probabilité que H_0 soit vraie. Elle est calculée *sous* H_0 : c'est une probabilité portant sur l'observation, le paramètre étant fixé. La probabilité que H_0 soit vraie n'a pas de sens dans le cadre de ce cours, où θ est déterministe.
2. Deux conclusions qui semblent contradictoires ne le sont pas nécessairement, comme le montrent l'Exemple 2.7 et les deux points de vue de l'aéroport : elles répondent à des questions différentes.
3. La seule décision significative est de rejeter H_0, puisque c'est la seule dont la probabilité d'erreur soit contrôlée.
4. La nomenclature qui rend ce point visible est donc « rejeter H_0 » et « échouer à rejeter H_0 », plutôt que « rejeter » et « accepter ».
5. Plus α est petit, plus la conclusion « on rejette » est assurée.
6. α est le niveau de tolérance au risque de première espèce : c'est une convention, choisie en fonction des conséquences d'une erreur, et non une constante universelle.

Le point suivant complète le troisième : une conclusion « statistiquement significative » ne dit rien de l'ampleur de l'effet observé.

Exemple 2.14: Signification statistique et taille d'effet

Reprenons le modèle gaussien de l'Exemple 2.8, avec $\mu_0 = 80$ dB, $\sigma = 10$ et le test $H_0 : \mu \leq \mu_0$, contre $H_1 : \mu > \mu_0$, et comparons deux jeux de données.

- $n = 4$ et $\bar{X}_n = 88$ dB. Alors $T(Z) = 2\times 8/10 = 1{,}6$, et la p-valeur vaut $1-\Phi(1{,}6) = 0{,}055$: on échoue à rejeter H_0 au niveau 5 %.
- $n = 10^4$ et $\bar{X}_n = 80{,}2$ dB. Alors $T(Z) = 100 \times 0{,}2/10 = 2$, et la p-valeur vaut $1-\Phi(2) = 0{,}023$: on rejette H_0 au niveau 5 %.

Le second jeu de données conduit à une conclusion « significative » pour un dépassement de 0,2 dB, inaudible ; le premier n'y parvient pas pour un dépassement de 8 dB, qui correspond à un bruit perçu bien plus fort. La p-valeur mêle en effet deux informations, l'ampleur de l'écart et la quantité de données : elle décroît quand l'un ou l'autre augmente. Une conclusion complète doit donc rapporter, outre la p-valeur, l'estimation de l'effet et un intervalle de confiance pour cet effet, qui sont, eux, à l'échelle de la quantité mesurée.

2.9 Une étude de cas : la fonte de la banquise arctique

L'exemple qui suit met en œuvre tout le chapitre sur des données réelles, celles de l'étendue de la banquise arctique mesurée chaque année depuis 1979. Le modèle est celui de la régression linéaire gaussienne, rencontré au chapitre 1 (Section 4) et étudié à l'Exercice 1 (PC2).

Exemple 2.15: Étendue de la banquise arctique

On observe $(Y_1, \dots, Y_n)$, où Y_i est l'étendue de la banquise l'année i, et l'on pose $t_i := \text{année}_i - 1979$. Le modèle est

$$Y_i = \beta_0 + \beta_1 t_i + \sigma\varepsilon_i \,, \qquad i \in \{1, \dots, n\} \,,$$

où $\theta = (\beta_0, \beta_1, \sigma^2) \in \mathbb{R}^2 \times \mathbb{R}_+^*$ et où les ε_i sont, sous $\mathbb{P}_\theta$, des variables gaussiennes centrées réduites indépendantes. Les estimateurs des moindres carrés sont

$$(\hat\beta_0, \hat\beta_1) := \operatorname*{arg\,min}_{(b_0,b_1)\in\mathbb{R}^2} \sum_{i=1}^n (Y_i - b_0 - b_1 t_i)^2 \,, \qquad \hat\sigma^2 := \frac{1}{n-2}\sum_{i=1}^n (Y_i - \hat\beta_0 - \hat\beta_1 t_i)^2 \,.$$

Notons $\bar t := n^{-1}\sum_{i=1}^n t_i$ et $s := n^{-1}\sum_{i=1}^n t_i^2 - \bar t^2$ la variance empirique des t_i, de sorte que $ns = \sum_{i=1}^n (t_i - \bar t)^2$. On montre (Exercice 1 (PC2)) que, sous $\mathbb{P}_\theta$,

$$\begin{pmatrix}\hat\beta_0 \\ \hat\beta_1\end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix}\beta_0 \\ \beta_1\end{pmatrix}, \frac{\sigma^2}{ns}\begin{pmatrix} n^{-1}\sum_i t_i^2 & -\bar t \\ -\bar t & 1\end{pmatrix}\right) \,,$$

que $(n-2)\hat\sigma^2/\sigma^2 \sim \chi^2(n-2)$, et que $\hat\sigma^2$ est indépendante de $(\hat\beta_0, \hat\beta_1)$. En particulier $\hat\beta_1 \sim \mathcal{N}(\beta_1, \sigma^2/(ns))$, et

$$G(Z;\beta_1) := \frac{\sqrt{ns}\,(\hat\beta_1 - \beta_1)}{\hat\sigma}$$

est une fonction pivotale de loi $\mathrm{t}(n-2)$, comme quotient d'une variable $\mathcal{N}(0,1)$ par la racine d'un $\chi^2(n-2)$ indépendant divisé par $n-2$.

Intervalle de confiance pour la pente. Il vient, pour tout θ,

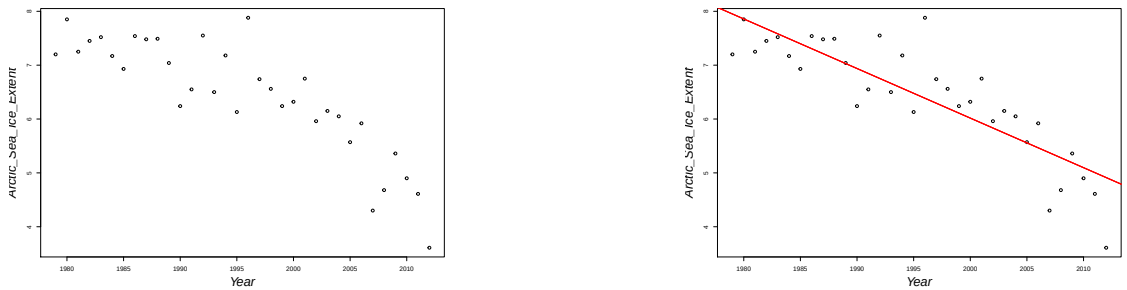
$$\mathbb{P}_\theta\Big(\beta_1 \in \Big[\hat\beta_1 \pm \frac{\hat\sigma\ \mathrm{t}_{1-\alpha/2}^{(n-2)}}{\sqrt{ns}}\Big]\Big) = 1 - \alpha \,.$$

Sur les données, au niveau de couverture 95 %, on obtient $[-0{,}11, -0{,}07]$ pour la pente β_1, en millions de kilomètres carrés par an, et $[7{,}55, 8{,}34]$ pour l'ordonnée à l'origine β_0.

Test de nullité de la pente. On teste $H_0 : \ \beta_1 = 0, \quad \text{contre} \quad H_1 : \ \beta_1 \neq 0$. Le test dual de l'intervalle précédent,

$$\phi_\alpha(Z) = \mathbb{1}_{\{0 \notin \left[\hat\beta_1 \pm \frac{\hat\sigma\ \mathrm{t}_{1-\alpha/2}^{(n-2)}}{\sqrt{ns}}\right]\}} = \mathbb{1}_{\{\left|G(Z;0)\right| \geq \mathrm{t}_{1-\alpha/2}^{(n-2)}\}} \,,$$

est de niveau α. Sur les données, la p-valeur associée vaut $1{,}76 \cdot 10^{-10}$.



Étendue de la banquise arctique par année (à gauche) et droite de régression ajustée par moindres carrés (à droite).

Intuition. *La p-valeur obtenue, de l'ordre de* 10^{-10}*, s'interprète ainsi et pas autrement :* si *la pente était nulle et* si *le modèle était exact, une pente estimée aussi éloignée de zéro que celle qu'on observe n'aurait qu'une chance sur dix milliards environ de se produire. Elle ne dit pas que la probabilité que la pente soit nulle vaut* 10^{-10}*. Elle ne dit rien non plus de la validité du modèle lui-même (indépendance des erreurs, homoscédasticité, linéarité), qui est ici l'hypothèse la plus discutable, les mesures successives d'une même grandeur physique n'étant pas indépendantes. En revanche, l'intervalle de confiance pour la pente,* $[-0{,}11, -0{,}07]$*, est directement lisible : il donne l'ordre de grandeur de la décroissance annuelle, ce que la p-valeur ne fait pas.*

2.10 En pratique : programme des exercices

Les notions de ce chapitre sont mises en œuvre dans la feuille d'exercices (PC 4), intégrée au chapitre (Section 4). Exercices traités en petite classe :

Exercice	Notions du cours	Rappels
Exo 1 – *Modèle exponentiel*	pivot, test unilatéral, fonction puissance, p-valeur, intervalle de confiance	Loi Gamma et loi du χ^2
Exo 2 – *Modèle gaussien*	test bilatéral, taille, p-valeur, test de Student	Th. de Cochran et th. de Gosset
Exo 3 – *Intervalle pour la loi uniforme*	pivot, intervalle de longueur minimale	Statistiques d'ordre, loi de $X_{n:n}$

L'Exercice 1 (PC4) est le seul de la feuille qui applique la méthode de construction par un pivot à un modèle non gaussien : on y établit que $2\theta^{-1}\sum_{i=1}^{n} X_i$ suit une loi $\chi^2(2n)$, on en tire un test de niveau α, sa fonction puissance, sa taille et sa p-valeur, puis un intervalle de confiance bilatéral et les deux bornes unilatérales. L'Exercice 2 (PC4), annoncé en amphi comme étant à savoir faire, reprend le test bilatéral sur la moyenne à variance connue, puis redémontre le théorème de Gosset avant de traiter le cas de la variance inconnue. L'Exercice 3 (PC4) construit l'intervalle de confiance de longueur minimale pour le modèle uniforme, $\left[X_{n:n}, X_{n:n}\alpha^{-1/n}\right]$: c'est le seul cas du cours où l'intervalle optimal n'est pas symétrique, et il prolonge le Section 1.2.

Les exercices suivants portent sur le modèle de Poisson, seul test d'une hypothèse simple contre une alternative simple de la feuille et seule préparation directe au chapitre 5 (Exercice 4 (PC4)) ; sur la comparaison de deux échantillons gaussiens, où la dualité entre intervalle et test est effectivement mise en œuvre et où intervient la loi de Fisher (Exercice 5 (PC4)) ; sur une campagne de vaccination, où le choix de H_0 change selon la partie qui pose la question (Exercice 6 (PC4)) ; et sur le test de rangs de Wilcoxon, seul test non paramétrique du cours et seul test construit par une inégalité de déviation (Exercice 7 (PC4)).

Une énigme à préparer. On considère une zone de terrain, représentée par une grille G de pixels. Chaque pixel a un coût d'achat $c_0 : G \to \mathbb{R}_+$ et rapporte un gain $r_1 : G \to \mathbb{R}_+$ si on l'achète. Étant donné un budget α, quels pixels acheter pour maximiser le bénéfice ? On modélisera ensuite le problème dans un cadre continu, où l'on achète un sous-ensemble de $\mathbb{R}^2$ plutôt qu'un ensemble fini de pixels. Quel rapport avec les tests ? Quel est le meilleur test de niveau α ? La réponse est l'objet du chapitre 5.

Notions de probabilités clés utilisées cette semaine, à revoir : fonction de répartition et quantile, loi gaussienne, loi du χ^2, loi de Student, loi de Fisher, théorèmes de Cochran et de Gosset, inégalités de Bienaymé-Tchebychev et de Hoeffding, statistiques d'ordre (voir la partie *Outils mathématiques* ci-dessous).