Exercice 1 ((*) Intervalles de confiance asymptotiques pour la loi exponentielle). Soit une suite de n-échantillons du modèle statistique

$$\left(\mathbb{R}_\star^+, \mathcal{B}(\mathbb{R}_\star^+), \{p_\theta \cdot \mathrm{Leb}, \theta \in \Theta := \mathbb{R}_\star^+\}\right)$$

où (modèle exponentiel)

$$p_\theta : x \mapsto \theta \exp(-\theta x) \mathbb{1}_{\mathbb{R}_+}(x).$$

On rappelle que

$$\mathbb{E}_\theta[X] = \frac{1}{\theta}, \qquad \mathbb{E}_\theta\left[X^2\right] = \frac{2}{\theta^2}, \qquad \mathrm{Var}_\theta(X^2) = \frac{20}{\theta^4}.$$

1. Construire les estimateurs de moments $\hat{\theta}_n^{(1)}$ et $\hat{\theta}_n^{(2)}$ associés aux fonctions $T_1(x) = x$ et $T_2(x) = x^2$.
2. Montrer que, pour $i = 1, 2$, les suites d'estimateurs $\{\hat{\theta}_n^{(i)}, n \in \mathbb{N}\}$ sont consistantes et asymptotiquement normales. Quel estimateur semble préférable d'un point de vue asymptotique ?
3. La loi exponentielle est un exemple de loi dans la famille dite *exponentielle* (voir PC2) i.e. sa densité est de la forme

$$x \mapsto h(x) \ \exp(T(x)\theta - A(\theta))$$

où ici $T(x) = -x$ et $A(\theta) = -\ln\theta$. Nous avons établi en PC2 que $\hat{\theta}_n^{(1)}$ était aussi l'estimateur MV. Calculer la (matrice d')information de Fisher de la loi d'une observation. Comment se compare-t-elle à la variance asymptotique de $\hat{\theta}_n^{(1)}$?
4. Proposer trois façons de construire des intervalles de confiance asymptotiques de niveau $1-\alpha$ à l'aide de l'estimateur identifié à la question précédente : on envisagera une méthode exploitant Slutsky, une méthode exploitant la méthode-δ (technique de *stabilisation de la variance*) et une méthode qui s'avère exploitable dans ce cas précis. *Voir la figure 1.*

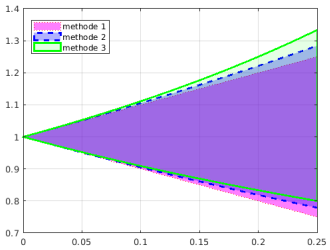


FIGURE 1 – Exercice 1. Les intervalles de confiance asymptotiques sont de la forme $[\hat{\theta}_n^{(1)} y_{\inf}, \hat{\theta}_n^{(1)} y_{\sup}]$. On trace les intervalles $[y_{\inf}, y_{\sup}]$ en fonction de $z_{1-\alpha/2}/\sqrt{n} \in [0, 0.25]$. On a noté $z_{1-\alpha/2}$ le quantile d'ordre $1-\alpha/2$ d'une loi $\mathcal{N}(0,1)$.

.

Exercice 2 ((*) Statistiques asymptotiques pour le modèle non régulier de Pareto translaté). La loi de Pareto est couramment utilisée pour modéliser des variables à queues lourdes. Cette loi a pour densité

$$x \mapsto p_\theta(x) = \eta\, \alpha^\eta\, x^{-(\eta+1)}\, \mathbb{1}_{[\alpha,+\infty[}(x)\ , \quad \theta := (\alpha, \eta) \in \mathbb{R}_*^+ \times \mathbb{R}_*^+\ ,$$

par rapport à la mesure de Lebesgue. On rappelle que

$$\mathbb{E}_\theta\,[X] = \frac{\eta}{\eta-1}\alpha\ , \qquad \mathrm{Var}_\theta(X) = \frac{\eta}{(\eta-1)^2(\eta-2)}\alpha^2\ ;$$

de plus, sous $\mathbb{P}_\theta$, $\ln(X_1/\alpha) \sim \mathcal{E}(\eta)$; l'espérance et la variance d'une v.a. $\mathcal{E}(\eta)$ sont $1/\eta$ et $1/\eta^2$.

Soit une suite de n-échantillons, d'un modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot \mathrm{Leb}, \theta \in \Theta := \mathbb{R}_*^+ \times \mathbb{R}_*^+\})$. Dans la première partie de l'exercice, on suppose α connu. On peut alors vérifier que le modèle est régulier.

1. Déterminer l'estimateur $\hat{\eta}_n$ du maximum de vraisemblance de η.
2. Montrer que la suite d'estimateurs $\{\hat{\eta}_n, n \in \mathbb{N}\}$ est consistante.
3. Montrer que la suite d'estimateurs $\{\hat{\eta}_n, n \in \mathbb{N}\}$ est asymptotiquement normale.
4. Construire un intervalle de confiance de probabilité de couverture asymptotique $1-\rho$ pour le paramètre η.

On suppose maintenant que α est aussi un paramètre inconnu.

5. Déterminer l'estimateur du maximum de vraisemblance de (α, η) ; on le notera $(\hat{\alpha}_n, \hat{\eta}_n)$.
6. Montrer que, pour tout $\theta = (\alpha, \eta)$, nous avons

$$\mathbb{P}_{n,\theta}(\hat{\alpha}_n > y) = \left(\frac{\alpha}{y}\right)^{n\eta}, \qquad \forall y \geq \alpha.$$

   Déterminer la moyenne et la variance de $\hat{\alpha}_n$ (on prendra n suffisamment grand) sous $\mathbb{P}_{n,\theta}$. En déduire l'erreur quadratique de cet estimateur et en donner un équivalent lorsque $n \to \infty$; commenter.
7. Montrer que $\{\hat{\alpha}_n, n \geq 1\}$ est une suite d'estimateurs consistante pour α. En déduire que $\{\hat{\eta}_n, n \geq 1\}$ est une suite d'estimateurs consistante pour η.
8. Déterminer la loi de $n\eta\, \ln(\hat{\alpha}_n/\alpha)$ sous $\mathbb{P}_{n,\theta}$. En déduire une **fonction pivotale asymptotique** pour α. Construire un intervalle de confiance de probabilité de couverture asymptotique $(1-\beta)$ du paramètre α.

Exercice 3 ((*) Non unicité d'une suite de tests consistante). Soit Θ un ouvert de $\mathbb{R}$ et $\theta_0 \in \Theta$. On souhaite tester

$$H_0 : \theta = \theta_0, \qquad H_1 : \theta > \theta_0$$

On dispose d'une suite de n-échantillons du modèle $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta, \theta \in \Theta\})$. Le modèle statistique est un modèle de translation : soit $q \cdot \mathrm{dLeb}$ une loi sur $\mathbb{R}$, on considère la famille de densités

$q_\theta : x \mapsto q(x-\theta)$. On suppose de plus la densité q symétrique par rapport à l'origine, continue et telle que $q(0) > 0$ [1] et de variance σ_q^2 inconnue. On définit les statistiques

$$M_n := 2\sqrt{n}\left(B_n - \frac{1}{2}\right), \qquad T_n := \sqrt{n}\frac{(\bar{X}_n - \theta_0)}{S_n},$$

où B_n, $\bar{X}_n$ et S_n^2 sont définis par

$$B_n := \frac{1}{n}\sum_{k=1}^{n} \mathbb{1}_{\{X_k \geq \theta_0\}}, \qquad \bar{X}_n := \frac{1}{n}\sum_{k=1}^{n} X_k, \qquad S_n^2 := \frac{1}{n}\sum_{k=1}^{n}(X_k - \bar{X}_n)^2.$$

On note $\mathbb{P}_{n,\theta} := \mathbb{Q}_\theta^{\otimes n}$.

1. Montrer que l'on peut choisir une suite $\{t_n,\ n \in \mathbb{N}\}$ de telle sorte que la suite de tests $\phi_{n,1} := \mathbb{1}_{\{M_n \geq t_n\}}$ soit de niveau asymptotique α et soit consistante, i.e. pour tout $\theta > \theta_0$, $\liminf_n \mathbb{P}_{n,\theta}(\phi_{n,1} = 1) = 1$. On pourra considérer les étapes suivantes
   — Proposer une valeur de t_n garantissant un test de niveau asymptotique α.
   — Pour $\theta > \theta_0$, exprimer l'espérance et la variance de la v.a. $\mathbb{1}_{\{X_k \geq \theta_0\}}$ sous $\mathbb{P}_{n,\theta}$, à l'aide de θ_0 et de la fonction de répartition F de la loi q. Observer le signe de $\mathbb{P}_{n,\theta}(X_k \geq \theta_0) - 1/2$.
   — Vérifier la consistance de la suite de tests.
2. Construire une suite de tests $\{\phi_{n,2}, n \in \mathbb{N}\}$ basée sur la statistique de test T_n de niveau asymptotique α et consistante.

Il n'y a donc pas unicité d'une suite de tests consistante pour un jeu d'hypothèses donnée. Nous verrons en PC7 une façon de comparer ces tests.

Exercice 4 ((*) Statistique asymptotique dans un modèle de Poisson). Soit une suite de n-échantillons du modèle statistique $(\mathbb{N}, \mathcal{P}(\mathbb{N}), \{p_\theta \cdot \mu, \theta \in \Theta := \mathbb{R}_\star^+\})$ où (modèle de Poisson)

$$p_\theta : k \mapsto \frac{\theta^k}{k!}\exp(-\theta),$$

et μ est la mesure de comptage sur $\mathbb{N}$. On pose $\overline{X}_n := n^{-1}\sum_{i=1}^n X_i$.

1. Montrer que la suite $\{\overline{X}_n,\ n \in \mathbb{N}\}$ est une suite d'estimateurs de θ asymptotiquement normale.
2. On cherche à estimer la probabilité $g(\theta) = \mathbb{P}_{n,\theta}(X_1 = 0) = \exp(-\theta)$. Montrer que $\{\exp(-\bar{X}_n), n \geq 0\}$ est une suite consistante et asymptotiquement normale d'estimateurs de g.
3. Construire un intervalle de confiance asymptotique pour g.

Exercice 5 ((*) LGN faible et limite de série). Soit $g : \mathbb{R} \to \mathbb{R}$ une fonction continue et bornée. Montrer que

$$\mathrm{e}^{-n\lambda}\sum_{k=0}^{\infty} g\left(\frac{k}{n}\right)\frac{(n\lambda)^k}{k!} \to_{n\to\infty} g(\lambda)\ .$$

1. ces conditions entrainent que la médiane est unique et vaut zero, et que la fonction de répartition F est strictement croissante dans un voisinage de 0.

Exercice 6 ((**) Estimateur de Hodges). Soit une suite de n-échantillons du modèle statistique $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot \mathrm{Leb}, \theta \in \Theta := \mathbb{R}\})$ où (modèle gaussien variance connue)

$$p_\theta : x \mapsto \frac{1}{\sqrt{2\pi}} \exp(-0.5(x-\theta)^2).$$

1. Montrer que l'estimateur du maximum de vraisemblance de θ est asymptotiquement normal.
2. Soit un réel $b \neq 1$ et une suite $\{a_n,\ n \in \mathbb{N}\}$ de nombres positifs tels que $\lim_{n\to\infty} a_n = 0$ et $\lim_{n\to\infty} \sqrt{n} a_n = \infty$. On considère la suite d'estimateurs :

$$\tilde{\theta}_n = \overline{X}_n \mathbb{1}_{\{|\overline{X}_n| \geq a_n\}} + b\overline{X}_n \mathbb{1}_{\{|\overline{X}_n| < a_n\}}$$

   où $\overline{X}_n := n^{-1} \sum_{i=1}^n X_i$. Montrer que cette suite d'estimateurs est asymptotiquement normale ; on distinguera le cas $\theta = 0$ et $\theta \neq 0$.
3. Commenter. *Voir la figure 2.*

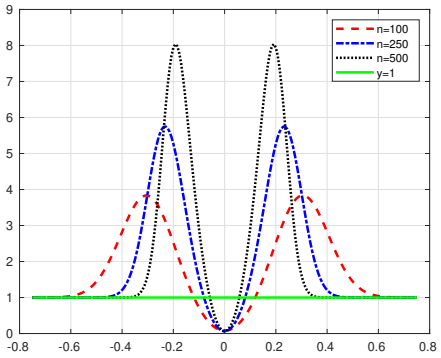


FIGURE 2 – Exercice 6. La figure 2 montre le comportement de l'erreur quadratique (multipliée par n) de cet estimateur : $\theta \mapsto n\mathbb{E}_{n,\theta}\left[\left(\tilde{\theta}_n - \theta\right)^2\right]$. On a pris $a_n = n^{-1/4}$ et $b = 0.25$. On observera la forte oscillation au voisinage de 0. Pour l'estimateur du maximum de vraisemblance, la même quantité $\theta \mapsto n\mathbb{E}_\theta\left[\left(\overline{X}_n - \theta\right)^2\right]$ est constante et vaut 1.

Exercice 7 ((***) Suite consistante d'estimateurs, racines des équations de vraisemblance). Soit un modèle statistique $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta := p_\theta \cdot \mu, \theta \in \Theta\})$ où μ est une mesure σ-finie sur $\mathcal{X}$, Θ est un intervalle ouvert de $\mathbb{R}$ et la densité p_θ vérifie

Ha pour tout $x \in \mathsf{X}$, $\theta \mapsto p_\theta(x)$ est continûment différentiable sur Θ ; et pour tout $x \in \mathsf{X}$ et $\theta \in \Theta$, $p_\theta(x) > 0$.

Hb pour tout $\theta, \theta_0 \in \Theta$, $\int |\log(p_{\theta_0}(x)/p_\theta(x))|\ p_{\theta_0}(x) \mathrm{d}\mu(x) < \infty$.

Hc le modèle est identifiable.

Soit une suite de n-échantillons de ce modèle statistique. Pour tout $n \in \mathbb{N}^*$, la log-vraisemblance de l'observation $Z = (X_1, \ldots, X_n)$ est donnée par :

$$\ell_n(\theta; X_1, \ldots, X_n) := \sum_{i=1}^{n} \log p_\theta(X_i) \ .$$

Les équations de vraisemblance associées sont données par

$$\sum_{i=1}^{n} \frac{\partial \log p_\theta(X_i)}{\partial \theta} = 0. \tag{1}$$

L'objectif de cet exercice est d'établir l'existence d'une suite consistante d'estimateurs $\{\tilde{\theta}_n, n \geq 1\}$ de θ, et telle que pour tout n assez grand, $\tilde{\theta}_n$ est une racine des equations de vraisemblance -(1).

Soient $\theta_0 \in \Theta$ et $\varepsilon > 0$ tels que $]\theta_0 - \varepsilon, \theta_0 + \varepsilon[\subset \Theta$.

1. On pose

   $$S_n = \{\mathbf{x} = (x_1, \ldots, x_n) \in \mathsf{X}^n \ : \ \ell_n(\theta_0, \mathbf{x}) > \ell_n(\theta_0 - \varepsilon, \mathbf{x}) \quad \text{et} \quad \ell_n(\theta_0, \mathbf{x}) > \ell_n(\theta_0 + \varepsilon, \mathbf{x})\} \ .$$

   Montrer que $\lim_{n\to\infty} \mathbb{P}_{n,\theta_0}((X_1, \ldots, X_n) \in S_n) = 1$.
2. Montrer que si $\mathbf{x} \in S_n$, il existe $\tilde{\theta}_n \in]\theta_0 - \varepsilon, \theta_0 + \varepsilon[$ tel que

   $$\frac{\partial \ell_n}{\partial \theta}(\tilde{\theta}_n, \mathbf{x}) = 0 \ .$$

3. Soit $\{\hat{\theta}_n, n \in \mathbb{N}\}$ une suite consistante d'estimateurs de θ. On définit la suite $\{\tilde{\theta}_n, n \geq 0\}$ par

   $$\tilde{\theta}_n := \begin{cases} \text{la (ou une des) racine(s) de } \theta \mapsto \partial_\theta \ell_n(\theta, X_1, \cdots, X_n), \text{ la plus proche de } \hat{\theta}_n & \text{si elle existe} \\ \hat{\theta}_n & \text{sinon} \end{cases}$$

   Montrer que $\{\tilde{\theta}_n, n \geq 1\}$ est une suite consistante d'estimateurs de θ.

Prenons $\Theta :=]0, 1[$. Soient f_0 et f_1 deux densités par rapport à la mesure de Lebesgue sur $\mathbb{R}$ telles que $\int |f_0(x) - f_1(x)| \mathrm{d}x > 0$. On considère

$$p_\theta(x) := (1 - \theta) f_0(x) + \theta f_1(x) \ .$$

4. Interpréter ce modèle.
5. Écrire les équations de vraisemblance.
6. Montrer l'existence d'une suite consistante d'estimateurs $\{\tilde{\theta}_n, n \in \mathbb{N}\}$ de θ telle que pour n assez grand, $\tilde{\theta}_n$ est une racine des eqs. de vraisemblance.
7. (Question subsidiaire !) un algorithme de recherche de racines ? *Voir la figure 3.*

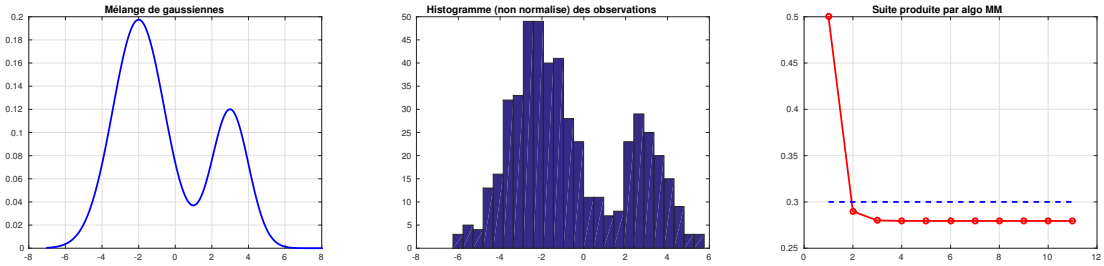


FIGURE 3 – Exercice 7. On prend $f_i \equiv \mathcal{N}(\mu_i, \sigma_i^2)$; $\theta_\star = 0.3$, $\mu_0 = -2$, $\mu_1 = 3$, $\sigma_0^2 = 2$, $\sigma_1^2 = 1$, $n = 500$. (gauche) densité mélange $x \mapsto p_{\theta_\star}(x)$; (centre) histogramme non normalisé de $n = 500$ observations ; (droite) En rouge, une trajectoire de l'algorithme Expectation Maximization, initialisée en $\theta_1 = 0.5$; en bleu, la valeur $\theta_\star$.