4 Les compléments

Les contenus de cette partie ne sont pas exigibles. Ils donnent la forme vectorielle du lemme de Slutsky et sa démonstration, les lois des grands nombres que le cours n'utilise pas, le contrôle de l'erreur d'approximation dans le théorème de la limite centrale, la comparaison des intervalles de Wald et de Wilson, et l'estimateur de Hodges.

4.1 Le lemme de Slutsky dans le cas vectoriel

Le lemme 1.1 a été énoncé pour des variables aléatoires réelles. Les démonstrations de la méthode-δ vectorielle (théorème 1.8) et de la normalité asymptotique d'une suite d'estimateurs à valeurs dans $\mathbb{R}^\ell$ en utilisent la forme suivante.

Théorème 4.1: Opérations sur les limites, cas vectoriel

Pour tout $n \in \mathbb{N}$, soit $(\mathsf{Z}_n, \mathcal{Z}_n, \mathbb{P}_n)$ un espace de probabilité et X_n, Y_n des vecteurs aléatoires définis sur $(\mathsf{Z}_n, \mathcal{Z}_n)$ et à valeurs respectivement dans $\mathbb{R}^d$ et $\mathbb{R}^p$. Soit X un vecteur aléatoire à valeurs dans $\mathbb{R}^d$, de loi μ.

(i) Si $d = p$, si $X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ et si $X_n - Y_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, alors $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$.

(ii) Soit $c \in \mathbb{R}^p$. Si $X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ et $Y_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} c$, alors $(X_n, Y_n) \overset{\mathbb{P}_n}{\Longrightarrow} \mu \otimes \delta_c$.

En particulier, si A_n est une suite de matrices aléatoires de taille $m \times d$ telle que $A_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} A$, où A est une matrice déterministe, alors $A_n X_n \overset{\mathbb{P}_n}{\Longrightarrow} AX$.

Démonstration

L'assertion *(i)* est l'étape 3 de la démonstration du lemme 1.1, dont l'argument ne fait intervenir que des normes et vaut donc en toute dimension. L'assertion *(ii)* s'obtient comme aux étapes 1 et 2 de cette même démonstration : on écrit

$$\begin{bmatrix} X_n \\ Y_n \end{bmatrix} = \begin{bmatrix} 0 \\ Y_n - c \end{bmatrix} + \begin{bmatrix} X_n \\ c \end{bmatrix} ,$$

le premier terme tend vers 0 en probabilité, et pour le second, la fonction caractéristique en $(t_1, t_2) \in \mathbb{R}^d \times \mathbb{R}^p$ vaut $\exp(\mathrm{i} t_2^\top c)\, \mathbb{E}_n[\exp(\mathrm{i} t_1^\top X_n)]$, qui converge vers la fonction caractéristique de $\mu \otimes \delta_c$; le théorème de Lévy 1.5 en dimension $d + p$ conclut, puis l'assertion *(i)* permet d'ajouter le premier terme. La dernière affirmation s'obtient en appliquant l'assertion *(ii)* au couple (X_n, A_n), puis le théorème de transformation continue 1.4 à la fonction $(x, M) \mapsto Mx$, qui est continue. □

La démonstration de la méthode-δ vectorielle est alors celle du cas scalaire : la différentiabilité de g au point θ (définition 2.4) donne

$$r_n \left(g(\mathbf{T}_n) - g(\theta)\right) - \mathrm{J}_g(\theta) \left\{r_n(\mathbf{T}_n - \theta)\right\} = r_n \left\|\mathbf{T}_n - \theta\right\| \tilde{R}(\mathbf{T}_n - \theta) ,$$

où $\tilde{R}$ est continue en 0 et nulle en 0. Comme $\mathbf{T}_n - \theta \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, on a $\tilde{R}(\mathbf{T}_n - \theta) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, et $r_n \left\|\mathbf{T}_n - \theta\right\| \overset{\mathbb{P}_n}{\Longrightarrow} \left\|\mathbf{T}\right\|$ par le théorème de transformation continue 1.4 ; le membre de droite tend donc vers zéro en probabilité, et l'assertion *(i)* donne la loi limite annoncée.

4.2 Les autres lois des grands nombres

Le chapitre n'utilise que la loi faible des grands nombres 1.2, qui suppose les variables de carré intégrable. Deux renforcements sont utiles à connaître.

Théorème 4.2: Loi faible des grands nombres, variables indépendantes de même loi intégrables

Soit $\{X_k,\ k \in \mathbb{N}\}$ une suite de variables aléatoires réelles définies sur $(\Omega, \mathcal{F}, \mathbb{P})$, indépendantes, de même loi et intégrables. Alors

$$\frac{1}{n}\sum_{k=1}^{n} X_k \overset{\mathbb{P}-\text{prob}}{\longrightarrow} \mathbb{E}[X_1]\ .$$

Théorème 4.3: Loi forte des grands nombres

Sous les mêmes hypothèses, la convergence a lieu presque sûrement :

$$\mathbb{P}\left(\lim_{n\to\infty} \frac{1}{n}\sum_{k=1}^{n} X_k = \mathbb{E}[X_1]\right) = 1\ .$$

Les deux énoncés sont admis ici ; ils figurent aux théorèmes IV-5.17 et IV-5.20 du polycopié d'origine. Le premier se démontre par troncature des variables, le second par le lemme de Borel-Cantelli. Lorsqu'une suite d'estimateurs converge presque sûrement vers $g(\theta)$ sous $\mathbb{P}_\theta$ pour tout θ, on dit qu'elle est *fortement consistante* ; cette propriété ne se formule que dans le cadre du produit infini (proposition 1.1), où une seule probabilité gouverne toutes les observations, et non dans celui de la définition 1.1, où l'espace change avec n.

4.3 La vitesse de convergence dans le théorème de la limite centrale

Le théorème de la limite centrale 1.6 donne une convergence, non une erreur d'approximation. Comme la fonction de répartition de la loi limite est continue, la convergence des fonctions de répartition est en fait uniforme en x : c'est le théorème de Polya. Le théorème suivant contrôle l'erreur.

Théorème 4.4: Berry-Esseen

Soit $\{X_k,\ k \in \mathbb{N}\}$ une suite de variables aléatoires réelles définies sur $(\Omega, \mathcal{F}, \mathbb{P})$, indépendantes, de même loi, telles que $\mathbb{E}\left[|X_1|^3\right] < \infty$. Notons $\mu := \mathbb{E}[X_1]$ et $\sigma^2 := \mathrm{Var}(X_1) > 0$. Il existe une constante universelle C, ne dépendant pas de la loi de X_1, telle que, pour tout $x \in \mathbb{R}$ et tout $n \in \mathbb{N}^*$,

$$\left|\mathbb{P}\left(\sqrt{n}\left(\frac{\bar{X}_n - \mu}{\sigma}\right) \le x\right) - \Phi(x)\right| \le \frac{C}{\sqrt{n}}\,\frac{\mathbb{E}\left[|X_1-\mu|^3\right]}{\sigma^3}\ ,$$

où Φ est la fonction de répartition de la loi $\mathcal{N}(0,1)$.

L'énoncé est admis. La valeur $C = 0.4784$ convient, et l'on sait que le résultat est faux pour $C < 0.4097$. L'erreur d'approximation décroît donc en $1/\sqrt{n}$, avec une constante qui dépend du troisième moment centré rapporté au cube de l'écart-type. Ce rapport est grand pour des lois très dissymétriques, ce qui éclaire les écarts observés ci-dessous sur une proportion voisine de 0.

4.4 L'intervalle de Wilson et l'intervalle de Wald

Les deux intervalles construits aux exemples 1.11 et 1.12 ont le même niveau asymptotique et ne coïncident pas. Les Figure 3 et 4 comparent, sur cinquante vecteurs d'observations indépendants, les intervalles obtenus pour $n = 100$ et pour deux valeurs de la proportion.

Pour $\theta = 0.25$, les deux intervalles sont pratiquement confondus, et la proportion d'intervalles qui contiennent θ est proche de 0.95 dans les deux cas. Pour $\theta = 0.025$, la situation est différente : la probabilité que les cent observations ne contiennent aucun succès vaut $(1-\theta)^{100} \approx 0.08$, et dans ce cas $\bar{X}_n = 0$, de sorte que l'intervalle de Wald est réduit au point $\{0\}$ et ne contient pas

θ. L'intervalle de Wilson, lui, reste d'étendue strictement positive, puisque le terme $z_{1-\alpha/2}^2/(4n^2)$ sous la racine ne s'annule pas.

La raison en est visible sur les formules : la validité des deux intervalles repose sur l'approximation gaussienne de la loi de $\sqrt{n}(\bar{X}_n - \theta)$, et $n\bar{X}_n$ suit une loi binomiale, dont l'approximation gaussienne est d'autant moins bonne que θ est proche de 0 ou de 1. Le théorème de Berry-Esseen 4.4 le quantifie : pour une loi $\mathcal{B}\mathrm{er}(\theta)$, le rapport $\mathbb{E}[|X_1 - \theta|^3]/\sigma^3$ vaut $\big(\theta(1-\theta)^3 + (1-\theta)\theta^3\big) \,/\, \big(\theta(1-\theta)\big)^{3/2}$, qui tend vers l'infini quand θ tend vers 0. L'intervalle de Wald ajoute à cette première approximation le remplacement de $\theta(1-\theta)$ par $\bar{X}_n(1-\bar{X}_n)$, ce qui aggrave l'écart ; l'intervalle de Wilson, qui résout l'inégalité du pivot sans estimer la variance, est en général préférable.

4.5 L'estimateur de Hodges

La comparaison de deux suites d'estimateurs par leurs variances asymptotiques (proposition 1.3) a une limite, que l'exercice 6 met en évidence sur le modèle gaussien de variance connue

$$(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{p_\theta \cdot \mathrm{Leb} \,:\, \theta \in \Theta := \mathbb{R}\}) \;, \qquad p_\theta : x \mapsto \frac{1}{\sqrt{2\pi}} \exp\left(-\tfrac{1}{2}(x-\theta)^2\right) \;.$$

L'estimateur du maximum de vraisemblance est $\bar{X}_n$, et $\sqrt{n}(\bar{X}_n - \theta)$ suit exactement la loi $\mathcal{N}(0,1)$ sous $\mathbb{P}_{n,\theta}$: la variance asymptotique vaut 1 pour toute valeur du paramètre, et elle atteint la borne de Cramér-Rao du chapitre 3.

Soient $b \neq 1$ et $\{a_n,\ n \in \mathbb{N}\}$ une suite de réels positifs telle que $a_n \to 0$ et $\sqrt{n}\, a_n \to \infty$. L'*estimateur de Hodges* est

$$\tilde{\theta}_n := \bar{X}_n \mathbb{1}_{\{|\bar{X}_n| \geq a_n\}} + b\, \bar{X}_n \mathbb{1}_{\{|\bar{X}_n| < a_n\}} \;,$$

c'est-à-dire la moyenne empirique, ramenée vers l'origine par le facteur b lorsqu'elle en est à distance inférieure à a_n. L'exercice 6 établit que cette suite d'estimateurs est asymptotiquement normale, de variance asymptotique

$$v(\theta) = \begin{cases} b^2 & \text{si } \theta = 0 \;, \\ 1 & \text{si } \theta \neq 0 \;. \end{cases}$$

Pour $|b| < 1$, la variance asymptotique de $\tilde{\theta}_n$ est donc partout au plus égale à celle de $\bar{X}_n$, et strictement plus petite au point $\theta = 0$. On parle de *super-efficacité* en ce point.

Intuition. *L'explication tient à l'écart entre les deux échelles a_n et $1/\sqrt{n}$. Lorsque $\theta = 0$, la moyenne empirique est à distance de l'ordre de $1/\sqrt{n}$ de l'origine, donc inférieure à a_n avec une probabilité qui tend vers 1 : l'estimateur vaut $b\,\bar{X}_n$ pour n grand, et sa variance asymptotique est b^2. Lorsque $\theta \neq 0$, la moyenne empirique est à distance de l'ordre de $|\theta|$ de l'origine, donc supérieure à a_n avec une probabilité qui tend vers 1 : l'estimateur vaut $\bar{X}_n$ pour n grand. Chaque valeur du paramètre finit donc par se trouver dans l'un des deux régimes, et la variance asymptotique ne voit jamais la transition entre les deux.*

Cette transition existe pourtant. Pour chaque n, les valeurs de θ de l'ordre de a_n sont celles pour lesquelles les deux régimes se disputent l'estimateur, et l'erreur quadratique moyenne y est bien plus grande que celle de $\bar{X}_n$. La Figure 5 montre, pour $a_n = n^{-1/4}$ et $b = 0.25$, le comportement de $\theta \mapsto n\,\mathbb{E}_{n,\theta}\left[(\tilde{\theta}_n - \theta)^2\right]$, à comparer à la valeur constante 1 obtenue pour $\bar{X}_n$: la quantité dépasse largement 1 au voisinage de l'origine, et le maximum sur θ croît avec n.

La variance asymptotique, prise point par point, ne rend donc pas compte du comportement de l'estimateur sur un voisinage du paramètre. Les critères qui le font reposent sur une forme d'uniformité en θ – borne inférieure locale asymptotique, risque maximal sur un voisinage de taille $1/\sqrt{n}$ – et sortent du cadre de ce chapitre.

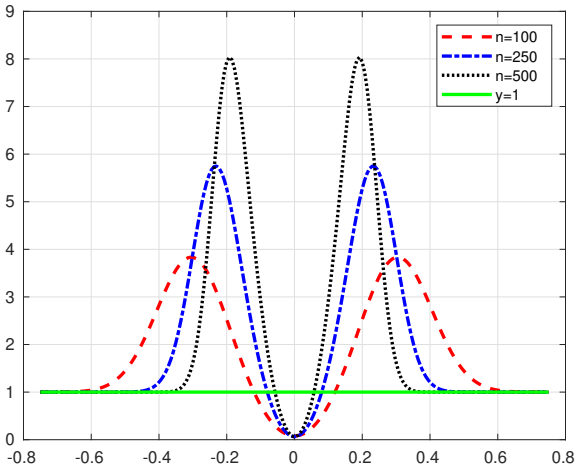


FIGURE 5 – Erreur quadratique moyenne de l'estimateur de Hodges, multipliée par n : $\theta \mapsto n\,\mathbb{E}_{n,\theta}\left[(\tilde{\theta}_n - \theta)^2\right]$, pour $a_n = n^{-1/4}$ et $b = 0.25$. Pour l'estimateur du maximum de vraisemblance, la même quantité est constante et vaut 1.