Chapitre 6

Statistiques asymptotiques

Les cinq premiers chapitres ont travaillé à n fixé : un modèle statistique, un estimateur ou un test construit sur n observations, et une mesure de qualité que l'on sait calculer exactement – un biais, une erreur quadratique moyenne, la taille et la fonction puissance d'un test, un niveau de confiance. Ces calculs exacts sont l'exception. Dès que l'estimateur n'est pas une moyenne empirique dans un modèle gaussien, la loi de la statistique considérée n'a pas d'expression explicite, et l'on ne sait plus ni comparer deux estimateurs par leur erreur quadratique, ni calculer le niveau d'une région de confiance, ni calibrer le seuil d'un test.

Les statistiques asymptotiques apportent une réponse en étudiant le comportement des statistiques lorsque le nombre n d'observations tend vers l'infini. Le cadre en est la *suite d'expériences statistiques*, qui permet de faire varier n tout en gardant un paramètre inconnu commun. Sur un estimateur, les deux propriétés recherchées sont la *consistance* – l'erreur d'estimation tend vers zéro en probabilité – et la *normalité asymptotique* – l'erreur, remise à l'échelle $\sqrt{n}$, converge en loi vers une gaussienne dont la variance mesure la précision. La loi faible des grands nombres et le théorème de la limite centrale fournissent ces deux propriétés pour une moyenne empirique ; le théorème de continuité, le lemme de Slutsky et la méthode-δ les transportent à toute fonction suffisamment régulière d'une moyenne empirique. On en déduit des régions de confiance et des tests dont le niveau n'est garanti qu'à la limite, et un critère de comparaison des estimateurs fondé sur leur variance asymptotique.

Les outils de probabilité mobilisés – les modes de convergence et leurs liens, les inégalités de Markov et de Bienaymé-Tchebychev, le procédé de Cramér-Wold, la différentiabilité d'une fonction vectorielle – sont rassemblés dans la partie *Outils mathématiques*, qui suit la partie principale, et la feuille d'exercices vient ensuite. La partie *Compléments*, hors programme d'examen, donne la forme vectorielle du lemme de Slutsky et sa démonstration, les lois des grands nombres que le cours n'utilise pas, la vitesse de convergence dans le théorème de la limite centrale, la comparaison des intervalles de Wald et de Wilson, et l'estimateur de Hodges, qui montre les limites du critère de variance asymptotique.

Pourquoi faire tendre n vers l'infini

Reprenons deux questions laissées sans réponse par les chapitres précédents. La première porte sur l'estimation : comment comparer deux estimateurs quand leurs erreurs quadratiques moyennes ne sont pas calculables, et comment construire une région de confiance quand la loi de l'estimateur

n'est pas explicite ? La seconde porte sur les tests : quel seuil de rejet choisir quand la loi de la statistique de test est inconnue ?

Dans les deux cas, le nombre d'observations est une quantité dont on dispose, et qui est souvent grande. L'idée est alors de remplacer la loi exacte de la statistique, inaccessible, par une loi limite, qui ne dépend plus du modèle que par quelques caractéristiques – une espérance, une variance – et qui est, dans la plupart des situations, gaussienne. En contrepartie, les garanties obtenues ne valent qu'à la limite : un test de niveau asymptotique α ne dit rien de sa taille pour la valeur de n dont on dispose réellement, et une région de confiance de niveau asymptotique $1-\alpha$ peut couvrir le paramètre avec une probabilité sensiblement différente. On verra sur l'exemple d'une proportion que cet écart n'est pas toujours négligeable.

Intuition. *La loi faible des grands nombres dit que la moyenne empirique de n variables indépendantes de même loi s'approche de leur espérance. Le théorème de la limite centrale précise cette distance : l'écart entre la moyenne empirique et l'espérance est de l'ordre de $\sigma/\sqrt{n}$, et, une fois divisé par cette quantité, il se comporte comme une gaussienne centrée réduite. C'est ce second énoncé qui produit les intervalles de confiance et les seuils de test de ce chapitre : toute l'information dont on a besoin sur la loi des observations s'y réduit à son espérance et à sa variance.*

1 Les fondamentaux

1.1 Une suite d'expériences statistiques

Faire tendre le nombre d'observations vers l'infini demande d'abord de dire ce que l'on fait varier. Les chapitres précédents se donnaient une expérience statistique et n observations ; ici, n change, donc l'espace des observations change aussi, et c'est une *suite* d'expériences statistiques que l'on se donne, indexée par le nombre d'observations, avec le même ensemble de paramètres Θ d'un bout à l'autre.

Définition 1.1: Suite d'expériences statistiques

Une *suite d'expériences statistiques* est une famille

$$\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta\}) \,:\, n \in \mathbb{N}\} \;, \qquad \text{où } \Theta \subseteq \mathbb{R}^d \;,$$

c'est-à-dire la donnée, pour chaque $n \in \mathbb{N}$, d'une expérience statistique $(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta\})$ dont l'espace des paramètres Θ ne dépend pas de n. On note Z_n l'observation de la n-ième expérience, $\mathbb{E}_{n,\theta}$ l'espérance et $\mathrm{Var}_{n,\theta}$ la variance sous $\mathbb{P}_{n,\theta}$.

Le paramètre inconnu est le même dans toutes les expériences de la suite : c'est ce qui donne un sens à la phrase « estimer θ d'autant mieux que n est grand ». Dans la quasi-totalité des situations de ce cours, la n-ième expérience est celle d'un n-échantillon.

Exemple 1.1: Suite de n-échantillons

Soit $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta \,:\, \theta \in \Theta\})$ une expérience statistique, avec $\Theta \subseteq \mathbb{R}^d$. La suite d'expériences statistiques *produit* associée est définie, pour tout $n \in \mathbb{N}$, par

$$\mathsf{Z}_n := \mathsf{X}^n \;, \qquad \mathcal{Z}_n := \mathcal{X}^{\otimes n} \;, \qquad \mathbb{P}_{n,\theta} := \mathbb{Q}_\theta^{\otimes n} \;, \quad \theta \in \Theta \;.$$

On définit sur chaque espace X^n les *statistiques canoniques*

$$X_i : \mathsf{X}^n \to \mathsf{X} \;, \qquad X_i : (x_1, \dots, x_n) \mapsto x_i \;, \qquad i \in \{1, \dots, n\} \;.$$

Pour (n, θ) fixés, sous $\mathbb{P}_{n,\theta}$, les statistiques $X_1, \dots, X_n$ sont indépendantes, et pour tout $i \in \{1, \dots, n\}$, le modèle statistique induit par X_i est $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta \,:\, \theta \in \Theta\})$.

Toutes les suites d'expériences statistiques ne sont pas de cette forme : les observations peuvent être dépendantes, ou de lois différentes. L'exercice 6 de la feuille de la semaine 1 et l'exercice 5 de la feuille de la semaine 2 en donnent deux exemples, et la définition 1.1 les couvre aussi bien.

> **Complément, hors programme : le produit infini d'expériences statistiques.** Dans le cas produit, il est commode de ne plus faire dépendre l'espace de l'indice n, de sorte qu'une seule probabilité $\mathbb{P}_\theta$ gouverne toutes les statistiques à la fois. C'est possible, au prix d'un argument de théorie de la mesure que l'on admet.

Proposition 1.1: Produit infini d'expériences statistiques

Soit $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta \,:\, \theta \in \Theta\})$ une expérience statistique. Posons

$$\mathsf{Z} := \mathsf{X}^{\mathbb{N}} \,, \qquad \mathcal{Z} := \mathcal{X}^{\otimes \mathbb{N}} \,,$$

l'ensemble des suites à valeurs dans X muni de la σ-algèbre produit, et, pour $k \in \mathbb{N}$, $X_k(z) := x_k$ où $z = \{x_n,\ n \in \mathbb{N}\}$. Il existe sur $(\mathsf{Z}, \mathcal{Z})$ une famille de probabilités $\{\mathbb{P}_\theta \,:\, \theta \in \Theta\}$ telle que, pour tout $\theta \in \Theta$, tout $n \in \mathbb{N}$ et tout $C_n \in \mathcal{X}^{\otimes n}$,

$$\mathbb{P}_\theta \left((X_1, \ldots, X_n) \in C_n \right) = \mathbb{Q}_\theta^{\otimes n}(C_n) \,.$$

De façon équivalente, pour tout $n \in \mathbb{N}$, le modèle statistique induit par la statistique $(X_1, \ldots, X_n)$ est $\left(\mathsf{X}^n, \mathcal{X}^{\otimes n}, \left\{\mathbb{Q}_\theta^{\otimes n} \,:\, \theta \in \Theta\right\}\right)$. On dit alors que $\{X_k,\ k \in \mathbb{N}^*\}$ est un *échantillon* du modèle $\{\mathbb{Q}_\theta \,:\, \theta \in \Theta\}$.

La construction repose sur le théorème d'extension de Carathéodory et n'est pas démontrée ici. On utilisera indifféremment les deux écritures : celle de la définition 1.1, avec une probabilité $\mathbb{P}_{n,\theta}$ par valeur de n, et celle de l'échantillon, avec une seule probabilité $\mathbb{P}_\theta$. Les énoncés ci-dessous sont écrits dans la première, qui ne suppose ni l'indépendance ni l'identité des lois.

1.2 Consistance et biais asymptotique

La première propriété que l'on demande à une suite d'estimateurs est que son erreur devienne petite quand n grandit. « Petite » s'entend ici en probabilité : la probabilité que l'erreur dépasse un seuil fixé tend vers zéro.

Définition 1.2: Suite d'estimateurs consistante

Soit une suite d'expériences statistiques paramétriques $\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta\}) \,:\, n \in \mathbb{N}\}$, où $\Theta \subseteq \mathbb{R}^d$, et soit $g : \Theta \to \mathbb{R}^\ell$ une fonction. Une suite d'estimateurs $\{T_n,\ n \in \mathbb{N}^*\}$ de $g(\theta)$,

$$T_n : (\mathsf{Z}_n, \mathcal{Z}_n) \to (\mathbb{R}^\ell, \mathcal{B}(\mathbb{R}^\ell)) \,,$$

est dite *consistante* pour g si

$$\forall \theta \in \Theta \,, \quad \forall \varepsilon > 0 \,, \qquad \lim_{n \to \infty} \mathbb{P}_{n,\theta} \left(\|T_n(Z_n) - g(\theta)\| \geq \varepsilon \right) = 0 \,.$$

On écrit alors $T_n(Z_n) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} g(\theta)$.

La norme est la norme euclidienne de $\mathbb{R}^\ell$. La convergence est demandée pour *chaque* valeur du paramètre, sans aucune uniformité en θ.

Définition 1.3: Suite d'estimateurs asymptotiquement sans biais

Dans le cadre de la définition 1.2, la suite d'estimateurs $\{T_n,\ n \in \mathbb{N}^*\}$ est dite *asymptotiquement sans biais* pour g si

$$\forall \theta \in \Theta \,, \qquad \lim_{n \to \infty} \mathbb{E}_{n,\theta} \left[T_n(Z_n) \right] = g(\theta) \,.$$

Intuition. *Les deux propriétés ne se déduisent pas l'une de l'autre. Être asymptotiquement sans biais ne porte que sur l'espérance de l'estimateur et laisse sa dispersion libre : une suite dont l'espérance converge vers $g(\theta)$ mais dont la variance ne diminue pas n'est pas consistante. Inversement, la consistance ne dit rien de l'espérance, qui peut même ne pas exister. Aucune des deux ne renseigne sur la* vitesse *: la*

définition 1.2 est satisfaite par une erreur d'ordre $1/\sqrt{n}$ comme par une erreur d'ordre $1/\ln n$. C'est ce que la normalité asymptotique (Section 1.8) viendra quantifier.

Les deux propriétés se lisent bien sur l'estimateur du support d'une loi uniforme, où tous les calculs sont explicites.

Exemple 1.2: Support d'une loi uniforme

Considérons la suite de modèles statistiques

$$\left\{\left(\mathbb{R}_+^n, \mathcal{B}(\mathbb{R}_+^n), \left\{\mathcal{U}^{\otimes n}([0,\theta]) \,:\, \theta \in \Theta := \mathbb{R}_+^*\right\}\right) \,:\, n \in \mathbb{N}_\star\right\} \ ,$$

et la suite des estimateurs du maximum de vraisemblance de θ,

$$\hat{\theta}_n := \max(X_1, \ldots, X_n) = X_{n:n} \ .$$

Alors $\{\hat{\theta}_n,\ n \in \mathbb{N}_\star\}$ est une suite consistante d'estimateurs de θ, et elle est asymptotiquement sans biais.

Démonstration

Soit $\theta > 0$. Par définition, $\mathbb{P}_{n,\theta}(\hat{\theta}_n \leq \theta) = 1$, de sorte que, pour tout $\varepsilon \in]0, \theta[$,

$$\begin{aligned}\mathbb{P}_{n,\theta}(|\hat{\theta}_n - \theta| > \varepsilon) &= \mathbb{P}_{n,\theta}(\hat{\theta}_n < \theta - \varepsilon) = \mathbb{P}_{n,\theta}(X_1 < \theta - \varepsilon, \ldots, X_n < \theta - \varepsilon) \\ &= \prod_{i=1}^{n} \mathbb{P}_{n,\theta}(X_i < \theta - \varepsilon) = (1 - \varepsilon/\theta)^n \ ,\end{aligned}$$

la troisième égalité résultant de l'indépendance des statistiques canoniques sous $\mathbb{P}_{n,\theta}$. Ainsi $\lim_{n\to\infty} \mathbb{P}_{n,\theta}(|\hat{\theta}_n - \theta| > \varepsilon) = 0$ pour tout $\varepsilon \in]0, \theta[$, donc pour tout $\varepsilon > 0$ puisque la probabilité est nulle dès que $\varepsilon \geq \theta$. La suite est donc consistante. Le calcul du biais, fait à l'exercice 1 de la feuille de la semaine 3, donne $\mathbb{E}_{n,\theta}[\hat{\theta}_n] = \frac{n}{n+1}\theta$ pour tout $\theta \in \Theta$, quantité qui converge vers θ : la suite est asymptotiquement sans biais. □

Illustration / animation : la consistance se voit sur la loi de l'estimateur. Pour le modèle uniforme sur $[0, \theta]$ et l'estimateur $\hat{\theta}_n = X_{n:n}$, l'histogramme de 2 000 réalisations se resserre contre θ quand n grandit, et la fréquence des réalisations hors de la bande $[\theta - \varepsilon, \theta + \varepsilon]$ tend vers zéro. On peut changer de modèle (exponentiel, Poisson), d'estimateur (maximum de vraisemblance ou moments) et faire croître n de 5 à 2 000.

link

Intuition. *L'histogramme de l'animation ci-dessus se resserre contre θ, ce qui est la consistance. Il indique aussi que la bonne échelle n'est pas celle de $1/\sqrt{n}$: le calcul ci-dessus donne $\mathbb{P}_{n,\theta}(\theta - \hat{\theta}_n > \varepsilon) = (1 - \varepsilon/\theta)^n$, qui est petit dès que ε est de l'ordre de $1/n$. On reviendra sur cet exemple après avoir défini la convergence en loi, pour établir que c'est $n(\theta - \hat{\theta}_n)$, et non $\sqrt{n}(\theta - \hat{\theta}_n)$, qui possède une loi limite (exemple 1.5).*

1.3 Le théorème de continuité

Une fois qu'une suite d'estimateurs est consistante, toute fonction continue de cette suite estime la même fonction continue de la quantité estimée. C'est le résultat le plus économique du chapitre, et celui dont on se sert le plus souvent.

Théorème 1.1: Théorème de continuité

Soit une suite d'expériences statistiques $\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta\}) \,:\, n \in \mathbb{N}\}$. Soit $\{T_n,\ n \in \mathbb{N}\}$ une suite consistante d'estimateurs de $g(\theta)$, où $g : \Theta \to \mathbb{R}^\ell$ et $T_n : (\mathsf{Z}_n, \mathcal{Z}_n) \to (\mathbb{R}^\ell, \mathcal{B}(\mathbb{R}^\ell))$, et soit $\varphi : \mathbb{R}^\ell \to \mathbb{R}^q$ une fonction continue en tout point de $g(\Theta)$. Alors $\{\varphi(T_n)_n,\ n \in \mathbb{N}\}$ est une suite consistante d'estimateurs de $\varphi \circ g$.

Démonstration

Soient $\theta \in \Theta$ et $\varepsilon > 0$. La fonction φ est continue au point $g(\theta)$: il existe donc $\delta > 0$ tel que, pour tout $u \in \mathbb{R}^\ell$ vérifiant $\|u - g(\theta)\| \leq \delta$, on ait $\|\varphi(u) - \varphi(g(\theta))\| < \varepsilon$. Par conséquent,

$$\{\|\varphi(T_n) - \varphi \circ g(\theta)\| \geq \varepsilon\} \subseteq \{\|T_n - g(\theta)\| > \delta\} \ ,$$

car sur l'événement complémentaire $\{\|T_n - g(\theta)\| \leq \delta\}$, l'inégalité $\|\varphi(T_n) - \varphi(g(\theta))\| < \varepsilon$ est vérifiée. Il vient

$$\mathbb{P}_{n,\theta}\left(\|\varphi(T_n) - \varphi \circ g(\theta)\| \geq \varepsilon\right) \leq \mathbb{P}_{n,\theta}\left(\|T_n - g(\theta)\| > \delta\right) \ ,$$

et le membre de droite tend vers zéro puisque la suite $\{T_n,\ n \in \mathbb{N}\}$ est consistante. □

Remarque. La version du théorème de continuité qui sert dans les preuves porte sur des suites de vecteurs aléatoires et non sur des estimateurs : si $\mathbf{X}_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \mathbf{X}$ et si φ est continue en tout point d'un ensemble C tel que $\mathbb{P}(\mathbf{X} \in C) = 1$, alors $\varphi(\mathbf{X}_n) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \varphi(\mathbf{X})$. Elle est énoncée dans les outils mathématiques (Section 2.1) et se démontre de la même façon.

Application : les estimateurs construits sur une moyenne empirique

Beaucoup d'estimateurs s'écrivent comme une fonction d'une moyenne empirique,

$$\varphi\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) \ ,$$

par construction pour les estimateurs des moments (chapitre 2), et après calcul pour nombre d'estimateurs du maximum de vraisemblance. Leur consistance résulte alors de deux ingrédients : le théorème de continuité 1.1, et la consistance de la moyenne empirique elle-même, qui est une loi faible des grands nombres.

Théorème 1.2: Loi faible des grands nombres pour des variables décorrélées

Soit $\{(\mathsf{Z}_n, \mathcal{Z}_n, \mathbb{P}_n) \,:\, n \in \mathbb{N}_\star\}$ une suite d'espaces probabilisés. Supposons que

- sous $\mathbb{P}_n$, les variables aléatoires réelles $X_1, \ldots, X_n$ sont décorrélées ;
- pour tout $k \in \{1, \ldots, n\}$, $\mathbb{E}_n[X_k^2] < \infty$;
- et

$$\lim_{n\to\infty} \frac{1}{n^2}\sum_{k=1}^{n} \mathrm{Var}_n(X_k) = 0 \ .$$

Alors

$$\lim_{n\to\infty} \mathbb{E}_n\left[\left(\frac{1}{n}\sum_{k=1}^{n}\{X_k - \mathbb{E}_n[X_k]\}\right)^2\right] = 0 \ , \qquad \frac{1}{n}\sum_{k=1}^{n}\{X_k - \mathbb{E}_n[X_k]\} \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0 \ .$$

Démonstration

Les variables $X_1, \ldots, X_n$ étant décorrélées sous $\mathbb{P}_n$ et de carré intégrable, le lemme de Bienaymé (Section 2.2) donne

$$\mathbb{E}_n\left[\left(\frac{1}{n}\sum_{k=1}^{n}\{X_k - \mathbb{E}_n[X_k]\}\right)^2\right] = \mathrm{Var}_n\left(\frac{1}{n}\sum_{k=1}^{n} X_k\right) = \frac{1}{n^2}\sum_{k=1}^{n}\mathrm{Var}_n(X_k)\ ,$$

qui tend vers zéro par hypothèse. La convergence en probabilité s'en déduit par l'inégalité de Bienaymé-Tchebychev (Section 2.2) : pour tout $\varepsilon > 0$,

$$\mathbb{P}_n\left(\left|\frac{1}{n}\sum_{k=1}^{n}\{X_k - \mathbb{E}_n[X_k]\}\right| \geq \varepsilon\right) \leq \frac{1}{\varepsilon^2}\,\mathbb{E}_n\left[\left(\frac{1}{n}\sum_{k=1}^{n}\{X_k - \mathbb{E}_n[X_k]\}\right)^2\right]\ .$$

□

Illustration / animation : la loi des grands nombres, trajectoire par trajectoire. On suit la moyenne empirique $\bar{X}_n$ d'une seule suite d'observations au fil de n, puis d'une seconde suite : chacune se stabilise autour de μ, ce qui est la convergence presque sûre. On tire ensuite cent valeurs de $\bar{X}_n$ à un instant n fixé, sans tracer les trajectoires : leur dispersion se resserre quand n augmente, ce qui est la convergence en probabilité. Deux questions demandent le nombre de réalisations tirées et le mode de convergence illustré.



link

Dans le cas d'une suite de n-échantillons d'une loi $\mathbb{Q}$ de carré intégrable, les hypothèses sont satisfaites : les variables sont indépendantes donc décorrélées, de même variance σ^2, et $n^{-2}\sum_{k=1}^{n}\sigma^2 = \sigma^2/n$ tend vers zéro. On obtient $\bar{X}_n \overset{\mathbb{P}_n-\mathrm{prob}}{\longrightarrow} \int x\,\mathbb{Q}(\mathrm{d}x)$, où $\bar{X}_n := n^{-1}\sum_{k=1}^{n} X_k$. L'hypothèse de carré intégrable n'est pas nécessaire : la loi faible des grands nombres vaut pour des variables indépendantes de même loi seulement intégrables, résultat plus délicat que l'on admet ici et qui est rappelé dans les compléments (Section 4.2).

Exemple 1.3: Paramètre d'une loi exponentielle

Soit une suite de n-échantillons du modèle $\left(\mathbb{R}_+, \mathcal{B}(\mathbb{R}_+), \left\{\mathcal{E}(\theta)\ :\ \theta \in \Theta := \mathbb{R}_+^*\right\}\right)$. L'estimateur du maximum de vraisemblance de θ est

$$T_n(Z_n) := \left(\frac{1}{n}\sum_{k=1}^{n} X_k\right)^{-1}\ , \qquad Z_n := (X_1, \ldots, X_n)\ .$$

La suite $\{T_n,\ n \in \mathbb{N}\}$ est une suite consistante d'estimateurs de θ.

Démonstration

Soit $\theta \in \Theta$. L'espérance d'une loi $\mathcal{E}(\theta)$ vaut $1/\theta$ et sa variance $1/\theta^2$: la loi faible des grands nombres 1.2 donne $\bar{X}_n \overset{\mathbb{P}_{n,\theta}-\mathrm{prob}}{\longrightarrow} \mathbb{E}_{n,\theta}[X_1] = 1/\theta$. La fonction $\varphi : u \mapsto 1/u$ est continue sur $\mathbb{R}_+^\star$, qui contient $\{1/\theta\ :\ \theta \in \Theta\}$; le théorème de continuité 1.1 donne alors $\varphi(\bar{X}_n) \overset{\mathbb{P}_{n,\theta}-\mathrm{prob}}{\longrightarrow} \varphi(1/\theta) = \theta$. □

Intuition. *Le schéma est toujours le même, et il vaut la peine d'être retenu sous cette forme : la loi des grands nombres traite la moyenne empirique, le théorème de continuité traite la fonction que l'on applique*

à cette moyenne. L'étape délicate est de vérifier que la fonction φ est continue au point où la moyenne empirique converge*, et non partout : ici $u \mapsto 1/u$ n'est pas continue en 0, mais 0 n'est pas une valeur possible de $1/\theta$ pour $\theta \in \mathbb{R}_+^*$, ce qui suffit.*

1.4 La convergence en loi

La consistance ne renseigne pas sur la vitesse. Pour l'obtenir, il faut un mode de convergence qui ne compare plus l'estimateur à une constante, mais la *loi* de l'erreur remise à l'échelle à une loi limite. Comme les variables en jeu sont définies sur des espaces qui changent avec n, cette convergence porte sur les lois et non sur les variables elles-mêmes.

Définition 1.4: Convergence en loi

Soit $\{(\mathsf{Y}_n, \mathcal{Y}_n, \mathbb{P}_n) : n \in \mathbb{N}^*\}$ une suite d'espaces de probabilité, $\{Y_n,\ n \in \mathbb{N}^*\}$ une suite de vecteurs aléatoires $Y_n : (\mathsf{Y}_n, \mathcal{Y}_n) \to (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$, et μ une mesure de probabilité sur $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$. La suite $\{Y_n,\ n \in \mathbb{N}^*\}$ *converge en loi* vers μ si, pour toute fonction continue bornée $f : \mathbb{R}^d \to \mathbb{R}$,

$$\lim_{n\to\infty} \mathbb{E}_n[f(Y_n)] = \int f(y)\,\mu(\mathrm{d}y)\ .$$

On note $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$.

Lorsque μ est la loi d'un vecteur aléatoire Y, on écrit aussi $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} Y$; seule la loi de Y intervient, et l'espace sur lequel Y est défini n'a pas d'importance.

Intuition. *Tester la convergence contre toutes les fonctions continues bornées est une définition commode pour les démonstrations, mais peu parlante. Les deux énoncés suivants la rendent utilisable : le théorème de Portmanteau, qui remplace les fonctions continues bornées par des probabilités d'événements – donc par des fonctions de répartition en dimension un –, et le théorème de Lévy, qui les remplace par les fonctions caractéristiques. On passera presque toujours par l'un de ces deux énoncés plutôt que par la définition.*

Deux caractérisations de la convergence en loi

Théorème 1.3: Portmanteau, version simple

Soit $\{(\mathsf{Y}_n, \mathcal{Y}_n, \mathbb{P}_n) : n \in \mathbb{N}^*\}$ une suite d'espaces de probabilité, $\{Y_n,\ n \in \mathbb{N}^*\}$ une suite de vecteurs aléatoires $Y_n : (\mathsf{Y}_n, \mathcal{Y}_n) \to (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ et μ une loi sur $\mathbb{R}^d$. Les assertions suivantes sont équivalentes.

(i) $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$.

(ii) Pour toute fonction $f : \mathbb{R}^d \to \mathbb{R}$ bornée et lipschitzienne, c'est-à-dire telle que $|f(x) - f(y)| \leq L_f \|x - y\|$ pour une constante L_f,

$$\lim_{n\to\infty} \mathbb{E}_n[f(Y_n)] = \int f(x)\,\mu(\mathrm{d}x)\ .$$

(iii) Pour tout pavé $A = \prod_{i=1}^d]a_i, b_i]$ dont la frontière ∂A vérifie $\mu(\partial A) = 0$,

$$\lim_{n\to\infty} \mathbb{P}_n(Y_n \in A) = \mu(A)\ .$$

Ce théorème est admis ; sa démonstration figure au théorème IV-5.26 du polycopié d'origine. L'assertion *(ii)* est celle que l'on utilise dans les preuves, l'assertion *(iii)* celle qui permet d'identifier une loi limite par calcul de probabilités. En dimension un, elle dit que $\mathbb{P}_n(Y_n \leq t) \to \mu(]-\infty, t])$ en tout point t où la fonction de répartition de μ est continue.

Exemple 1.4: Suite de lois uniformes de support $\{1/n, \dots, 1\}$

Sur l'espace $\mathsf{Y}_n := \{1/n, \dots, (n-1)/n, 1\}$ muni de $\mathcal{Y}_n := \mathcal{P}(\mathsf{Y}_n)$, on définit la loi $\mathbb{P}_n(\{k/n\}) := 1/n$ pour $k \in \{1, \dots, n\}$, et la variable aléatoire $Y_n : \mathsf{Y}_n \to [0,1]$ par $Y_n(x) = x$. Alors $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{U}([0,1])$.

Démonstration

Pour $t \in [0,1]$, on a $\mathbb{P}_n(Y_n \leq t) = \lfloor nt \rfloor / n$, et donc $\lim_{n\to\infty} \mathbb{P}_n(Y_n \leq t) = t$, puisque $nt - 1 < \lfloor nt \rfloor \leq nt$. Pour $t < 0$ la probabilité est nulle et pour $t > 1$ elle vaut 1. La fonction de répartition de la loi $\mathcal{U}([0,1])$ étant continue sur $\mathbb{R}$, le théorème de Portmanteau 1.3 permet de conclure. □

Appliquée à une fonction f continue sur $[0,1]$, donc continue bornée, la définition de la convergence en loi redonne la convergence des sommes de Riemann :

$$\mathbb{E}_n[f(Y_n)] = \frac{1}{n}\sum_{k=1}^{n} f(k/n) \xrightarrow[n\to\infty]{} \int_0^1 f(x)\,\mathrm{d}x \,.$$

Exemple 1.5: Support d'une loi uniforme : la loi limite de l'erreur

Reprenons la suite de modèles statistiques

$$\left\{\left((\mathbb{R}_+^*)^n, (\mathcal{B}(\mathbb{R}_+^*))^{\otimes n}, \left\{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta := \mathbb{R}_+^*\right\}\right) \,:\, n \in \mathbb{N}_\star\right\} \,, \qquad \mathbb{P}_{n,\theta} = \left(\theta^{-1}\mathbb{1}_{[0,\theta]} \cdot \mathrm{Leb}\right)^{\otimes n} \,,$$

et la suite des estimateurs du maximum de vraisemblance $\hat{\theta}_n = \max(X_1, \dots, X_n) = X_{n:n}$. Alors, pour tout $\theta \in \Theta$,

$$n\left(\theta - \hat{\theta}_n\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{E}(\theta^{-1}) \,.$$

Démonstration

Le calcul de l'exemple 1.2 donne, pour tout $\varepsilon \in]0, \theta[$,

$$\mathbb{P}_{n,\theta}\left(\theta - \hat{\theta}_n > \varepsilon\right) = (1 - \varepsilon/\theta)^n \,.$$

Soit $x > 0$. En prenant $\varepsilon = x/n$, licite dès que $n > x/\theta$, il vient

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta}\left(n(\theta - \hat{\theta}_n) > x\right) = \lim_{n\to\infty}\left(1 - \frac{x}{n\theta}\right)^n = \mathrm{e}^{-x/\theta} \,.$$

La fonction $x \mapsto 1 - \mathrm{e}^{-x/\theta}$, prolongée par 0 sur $\mathbb{R}_-$, est la fonction de répartition de la loi exponentielle d'intensité θ^{-1} ; elle est continue sur $\mathbb{R}$. Comme $\mathbb{P}_{n,\theta}(n(\theta - \hat{\theta}_n) \leq x) = 1 - \mathbb{P}_{n,\theta}(n(\theta - \hat{\theta}_n) > x)$ et que $\mathbb{P}_{n,\theta}(\theta - \hat{\theta}_n \geq 0) = 1$, la convergence de la fonction de répartition a lieu en tout point de $\mathbb{R}$, et le théorème de Portmanteau 1.3 donne la conclusion. □

Intuition. *La vitesse de convergence se lit dans le facteur qu'il faut mettre devant l'erreur pour obtenir une loi limite non dégénérée. Ici ce facteur est n, et non $\sqrt{n}$: l'erreur $\theta - \hat{\theta}_n$ est de l'ordre de $1/n$, soit bien plus petite que l'ordre $1/\sqrt{n}$ que donnera le théorème de la limite centrale pour une moyenne empirique. La loi limite n'est pas gaussienne non plus. Le modèle uniforme n'est pas régulier au sens du chapitre 3, et cet exemple montre que la normalité asymptotique n'est pas la règle générale, seulement le cas le plus fréquent.*

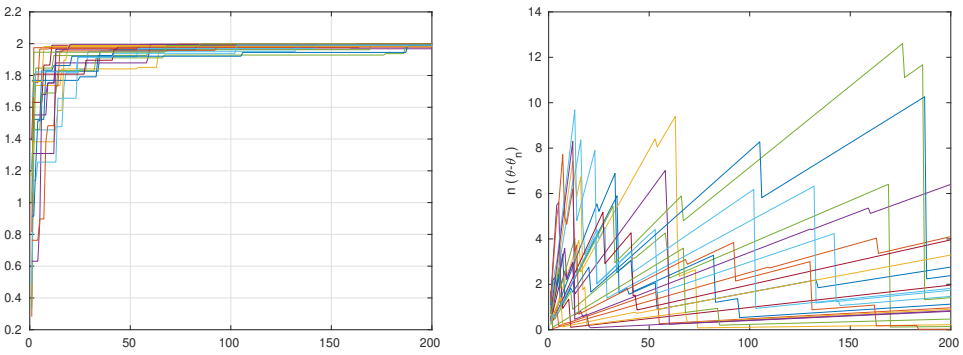


FIGURE 1 – À gauche, 50 réalisations de la suite $\left\{\hat{\theta}_n \ : \ n = 1, \ldots, 200\right\}$ calculée à partir d'observations $X_i \sim \mathcal{U}([0,2])$: on y voit la consistance, mais pas de loi limite. À droite, les 50 réalisations correspondantes de la suite $\left\{n(2-\hat{\theta}_n) \ : \ n = 1, \ldots, 200\right\}$: la dispersion ne se réduit plus, ce qui est le signe d'une loi limite non dégénérée.

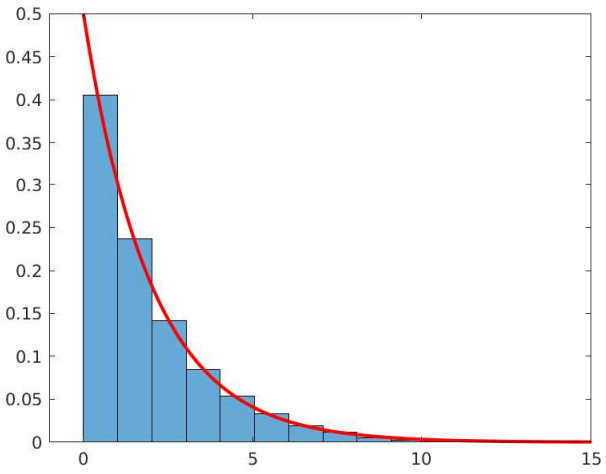


FIGURE 2 – Histogramme de $N = 5000$ réplications indépendantes de $n(\theta - \hat{\theta}_n)$, pour $n = 200$ et $\theta = 2$, les réalisations de $\hat{\theta}_n$ étant obtenues à partir de tirages uniformes sur $[0, \theta]$. En trait rouge, la densité $x \mapsto \theta^{-1} \exp(-x/\theta)$ de la loi $\mathcal{E}(\theta^{-1})$.

Effet d'une transformation continue

Théorème 1.4: Transformation continue

Soit $\{(\mathsf{Y}_n, \mathcal{Y}_n, \mathbb{P}_n) : n \in \mathbb{N}_\star\}$ une suite d'espaces de probabilité, $\{Y_n,\ n \in \mathbb{N}_\star\}$ une suite de vecteurs aléatoires $Y_n : (\mathsf{Y}_n, \mathcal{Y}_n) \to (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$, μ une loi sur $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ et $\varphi : \mathbb{R}^d \to \mathbb{R}^m$ une fonction continue en tout point d'un ensemble C tel que $\mu(C) = 1$. Si $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$, alors

$$\varphi(Y_n) \overset{\mathbb{P}_n}{\Longrightarrow} \mu_\varphi \ ,$$

où μ_φ est l'image de μ par φ, définie par $\mu_\varphi(A) := \mu(\varphi^{-1}(A))$ pour tout $A \in \mathcal{B}(\mathbb{R}^m)$.

Démonstration

Supposons d'abord φ continue sur $\mathbb{R}^d$ tout entier. Pour $f : \mathbb{R}^m \to \mathbb{R}$ continue bornée, $f \circ \varphi$ est continue bornée, et la convergence $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ donne

$$\mathbb{E}_n\left[f \circ \varphi(Y_n)\right] \xrightarrow[n\to\infty]{} \int f \circ \varphi(y)\, \mu(\mathrm{d}y) = \int f(u)\, \mu_\varphi(\mathrm{d}u) \ ,$$

la dernière égalité étant le théorème de transfert. C'est la convergence annoncée. Le cas général, où φ n'est continue qu'en tout point d'un ensemble de μ-mesure 1, demande de travailler avec les fermés et le théorème de Portmanteau ; il est admis ici et démontré au théorème IV-5.30 du polycopié d'origine. □

Fonction caractéristique et théorème de Lévy

La troisième caractérisation de la convergence en loi est celle qui servira à démontrer le théorème de la limite centrale. Les vecteurs sont ici des vecteurs colonnes, et $A^\top$ désigne la transposée de la matrice A.

Définition 1.5: Fonction caractéristique

Soit Y un vecteur aléatoire à valeurs dans $\mathbb{R}^d$ défini sur $(\mathsf{Y}, \mathcal{Y}, \mathbb{P})$. La *fonction caractéristique* de Y est la fonction

$$t \mapsto \mathbb{E}\left[\mathrm{e}^{\mathrm{i}t^\top Y}\right] \ , \qquad t \in \mathbb{R}^d \ .$$

Elle est définie pour tout t, puisque $|\mathrm{e}^{\mathrm{i}t^\top Y}| = 1$, et elle caractérise la loi de Y. Si $Y \sim \mathcal{N}_d(\mu, \Sigma)$, alors

$$\mathbb{E}\left[\mathrm{e}^{\mathrm{i}t^\top Y}\right] = \exp\left(\mathrm{i}t^\top \mu - \tfrac{1}{2} t^\top \Sigma t\right) \ , \tag{1}$$

et en particulier $t \mapsto \exp(-t^2/2)$ est la fonction caractéristique de la loi $\mathcal{N}(0, 1)$.

Théorème 1.5: Théorème de Lévy

Soit $\{(\mathsf{Y}_n, \mathcal{Y}_n, \mathbb{P}_n) : n \in \mathbb{N}_\star\}$ une suite d'espaces de probabilité, $\{Y_n,\ n \in \mathbb{N}_\star\}$ une suite de vecteurs aléatoires $Y_n : (\mathsf{Y}_n, \mathcal{Y}_n) \to (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ et μ une loi sur $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$. Alors $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ si et seulement si

$$\mathbb{E}_n\left[\exp\left(\mathrm{i}t^\top Y_n\right)\right] \xrightarrow[n\to\infty]{} \int \exp\left(\mathrm{i}t^\top y\right) \mu(\mathrm{d}y) \qquad \text{pour tout } t \in \mathbb{R}^d \ .$$

Le sens direct est immédiat, puisque $y \mapsto \cos(t^\top y)$ et $y \mapsto \sin(t^\top y)$ sont continues bornées. La réciproque est admise ; elle est démontrée au théorème IV-5.36 du polycopié d'origine.

1.5 Le théorème de la limite centrale

Le théorème de la limite centrale donne la loi limite d'une moyenne empirique remise à l'échelle $\sqrt{n}$. Il servira à deux choses : calculer des intervalles de confiance pour l'estimation d'un paramètre, et remplacer la loi non explicite d'une statistique de test par une loi limite.

Théorème 1.6: Théorème de la limite centrale, cas $\ell \geq 1$

Soit $\mathbb{Q}$ une loi sur $(\mathsf{X} := \mathbb{R}^\ell, \mathcal{X} := \mathcal{B}(\mathbb{R}^\ell))$ admettant un moment d'ordre 2, d'espérance μ et de matrice de covariance Σ, de taille $\ell \times \ell$. Soit une suite de n-échantillons de $\mathbb{Q}$,

$$\left\{ \left(\mathsf{X}^n, \mathcal{X}^{\otimes n}, \mathbb{P}_n := \mathbb{Q}^{\otimes n}\right) \,:\, n \in \mathbb{N}_\star \right\} .$$

Alors

$$\sqrt{n}\left(\frac{1}{n}\sum_{k=1}^n X_k - \mu\right) = \frac{1}{\sqrt{n}}\sum_{k=1}^n (X_k - \mu) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0,\Sigma) .$$

Illustration / animation : le théorème de la limite centrale sur les mêmes trajectoires. La trajectoire de $\bar{X}_n$ de l'animation précédente, transformée en $\sqrt{n}\,(\bar{X}_n - \mu)/\sigma$, ne se stabilise plus ; une seconde trajectoire oscille différemment. On tire alors quatre cents suites sans tracer leurs trajectoires et l'on regarde, à un instant n que l'on fait avancer, l'histogramme des valeurs transformées : il épouse la densité de $\mathcal{N}(0,1)$. Ce qui converge est la loi à n fixé, et non les trajectoires. Deux questions demandent le nombre de réalisations tirées et le mode de convergence illustré.



link

La démonstration est faite ci-dessous dans le cas $\ell = 1$ et $\sigma^2 := \mathrm{Var}_{\mathbb{Q}}(X_1) > 0$; le cas $\ell \geq 1$ s'en déduit par le procédé de Cramér-Wold (Section 2.4), et le cas $\sigma^2 = 0$ est immédiat puisque la variable $\sqrt{n}(\bar{X}_n - \mu)$ est alors nulle $\mathbb{P}_n$-presque sûrement. Le détail du cas général figure au théorème IV-5.39 du polycopié d'origine.

Démonstration

On traite le cas $\ell = 1$ avec $\sigma^2 > 0$.

Réduction à des variables centrées et réduites. Posons $Y_i := \sigma^{-1}(X_i - \mu)$ et $\bar{Y}_n := n^{-1}\sum_{i=1}^n Y_i$, de sorte que

$$\frac{\sqrt{n}}{\sigma}\left(\frac{1}{n}\sum_{i=1}^n X_i - \mu\right) = \sqrt{n}\left(\frac{1}{n}\sum_{i=1}^n \frac{X_i - \mu}{\sigma}\right) = \sqrt{n}\,\bar{Y}_n .$$

Sous $\mathbb{P}_n$, les variables $Y_1, \ldots, Y_n$ sont indépendantes, de même loi, de moyenne nulle et de variance unité. Il suffit d'établir que $\sqrt{n}\bar{Y}_n \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0,1)$, la conclusion s'obtenant en multipliant par la constante σ, par le théorème de transformation continue 1.4.

Ce qu'il faut démontrer. Pour $t \in \mathbb{R}$, notons $\phi_n(t) := \mathbb{E}_n[\exp(\mathrm{i}t\sqrt{n}\bar{Y}_n)]$ la fonction caractéristique de $\sqrt{n}\bar{Y}_n$. Au vu de (1) et du théorème de Lévy 1.5, il suffit de montrer que

$$\lim_{n\to\infty} \phi_n(t) = \exp(-t^2/2) \qquad \text{pour tout } t \in \mathbb{R} .$$

De la fonction caractéristique de $\sqrt{n}\bar{Y}_n$ à celle de Y_1. Sous $\mathbb{P}_n$, les variables $Y_1, \ldots, Y_n$

étant indépendantes et de même loi, on a, pour tout $t \in \mathbb{R}$,

$$\phi_n(t) = \mathbb{E}_n\left[\exp\left(\mathrm{i}\frac{t}{\sqrt{n}}\sum_{k=1}^{n} Y_k\right)\right] = \left(\psi\left(\frac{t}{\sqrt{n}}\right)\right)^n , \qquad \text{où } \psi(u) := \mathbb{E}_n\left[\exp(\mathrm{i}uY_1)\right] .$$

Comportement limite. La variable Y_1 est de carré intégrable : le lemme 2.3 montre que ψ est deux fois dérivable, de dérivée seconde continue, et que

$$\psi(u) = 1 + \mathrm{i}u\,\mathbb{E}_n[Y_1] - \frac{u^2}{2}\mathbb{E}_n[Y_1^2] + o(u^2) , \qquad u \to 0 .$$

Comme $\mathbb{E}_n[Y_1] = 0$ et $\mathbb{E}_n[Y_1^2] = 1$, il vient, en posant $u = t/\sqrt{n}$,

$$\psi\left(\frac{t}{\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o(n^{-1}) ,$$

et le lemme 2.4 donne alors

$$\lim_{n\to\infty} \phi_n(t) = \lim_{n\to\infty}\left(1 - \frac{t^2}{2n} + o(n^{-1})\right)^n = \exp(-t^2/2) .$$

□

Intuition. *Les deux moments de la loi des observations sont les seules caractéristiques qui subsistent dans la limite, et le calcul ci-dessus dit pourquoi : dans le développement de la fonction caractéristique, seuls les termes d'ordre 0, 1 et 2 survivent à l'élévation à la puissance n, parce que l'argument est divisé par $\sqrt{n}$. Tout le reste disparaît. C'est la raison pour laquelle le théorème de la limite centrale s'applique à des lois d'observations très diverses, et pourquoi la loi limite ne dépend plus du modèle que par μ et Σ.*

En dimension un, le théorème fournit directement un intervalle de confiance pour l'espérance lorsque l'écart-type est connu. Par le théorème de la limite centrale,

$$\frac{\sqrt{n}}{\sigma}\left(\frac{1}{n}\sum_{k=1}^{n} X_k - \mu\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0,1) ,$$

et, le pavé $]a, b]$ ayant une frontière de mesure nulle pour la loi $\mathcal{N}(0,1)$, le théorème de Portmanteau 1.3 donne, pour tout $a < b$,

$$\lim_{n\to\infty} \mathbb{P}_n\left(a\frac{\sigma}{\sqrt{n}} \le \frac{1}{n}\sum_{k=1}^{n} X_k - \mu \le b\frac{\sigma}{\sqrt{n}}\right) = \Phi(b) - \Phi(a) ,$$

où Φ est la fonction de répartition de la loi $\mathcal{N}(0,1)$.

Corollaire 1.1: Intervalle de confiance asymptotique pour l'espérance, écart-type connu

Dans le cadre du théorème 1.6 avec $\ell = 1$ et $\sigma^2 > 0$ connu, l'intervalle

$$\left[\frac{1}{n}\sum_{k=1}^{n} X_k - z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}} , \quad \frac{1}{n}\sum_{k=1}^{n} X_k + z_{1-\alpha/2}\frac{\sigma}{\sqrt{n}}\right]$$

est un intervalle de confiance de niveau asymptotique $1-\alpha$ pour μ, où z_u désigne le quantile d'ordre u de la loi $\mathcal{N}(0,1)$.

Lorsque σ est inconnu, on peut le remplacer par un estimateur consistant : c'est ce que le lemme de Slutsky permet de justifier.

1.6 Le lemme de Slutsky

Les théorèmes précédents transforment une convergence en loi par une fonction continue. Il reste à savoir ce que devient une somme, un produit ou un quotient lorsque l'un des deux facteurs converge en loi et l'autre vers une constante. C'est l'objet du lemme suivant, utilisé dans presque toutes les démonstrations de la fin du chapitre.

Lemme 1.1: Lemme de Slutsky

Soit $\{(\mathsf{Z}_n, \mathcal{Z}_n, \mathbb{P}_n) : n \in \mathbb{N}\}$ une suite d'espaces de probabilité, $\{X_n,\ n \in \mathbb{N}\}$ et $\{Y_n,\ n \in \mathbb{N}\}$ des variables aléatoires réelles définies sur $(\mathsf{Z}_n, \mathcal{Z}_n)$, et μ une probabilité sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Si $X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ et $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \delta_c$, où c est une constante, alors

(i) $X_n + Y_n \overset{\mathbb{P}_n}{\Longrightarrow} X + c$;

(ii) $Y_n X_n \overset{\mathbb{P}_n}{\Longrightarrow} cX$;

(iii) si $c \neq 0$ et si $\mathbb{P}_n(Y_n \neq 0) = 1$ pour tout n, $Y_n^{-1} X_n \overset{\mathbb{P}_n}{\Longrightarrow} c^{-1} X$;

où $X \sim \mu$.

Remarques.

1. La convergence en loi vers une masse de Dirac entraîne la convergence en probabilité, et l'hypothèse $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} \delta_c$ équivaut donc à $Y_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} c$. En effet, par le théorème de Portmanteau 1.3,
$$\mathbb{P}_n\left(|Y_n - c| > \varepsilon\right) = 1 - \mathbb{P}_n\left(c - \varepsilon < Y_n \leq c + \varepsilon\right) \xrightarrow[n\to\infty]{} 1 - \delta_c\left(]c-\varepsilon, c+\varepsilon]\right) = 0\,.$$
2. La démonstration établit au passage un énoncé que l'on utilisera seul : si $U_n \overset{\mathbb{P}_n}{\Longrightarrow} \nu$ et $V_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, alors $U_n + V_n \overset{\mathbb{P}_n}{\Longrightarrow} \nu$.
3. Dans l'expression d'un intervalle de confiance asymptotique, lorsque l'écart-type σ n'est pas connu, on peut le remplacer par un estimateur consistant : c'est l'assertion *(iii)*.

Démonstration

Étape 1. On écrit
$$\begin{bmatrix} X_n \\ Y_n \end{bmatrix} = \underbrace{\begin{bmatrix} 0 \\ Y_n - c \end{bmatrix}}_{U_n} + \underbrace{\begin{bmatrix} X_n \\ c \end{bmatrix}}_{V_n}\,.$$
Par hypothèse et par la première remarque ci-dessus, $Y_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} c$, donc $U_n \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$.

Étape 2. Montrons que $V_n \overset{\mathbb{P}_n}{\Longrightarrow} \nu := \mu \otimes \delta_c$, en passant par les fonctions caractéristiques. Pour $t_1, t_2 \in \mathbb{R}$,
$$\mathbb{E}_n\left[\exp\left(\mathrm{i}t_1 X_n\right)\exp\left(\mathrm{i}t_2 c\right)\right] = \exp(\mathrm{i}t_2 c)\,\mathbb{E}_n\left[\exp(\mathrm{i}t_1 X_n)\right] \xrightarrow[n\to\infty]{} \exp(\mathrm{i}t_2 c)\int \exp(\mathrm{i}t_1 x)\,\mu(\mathrm{d}x)\,,$$
la limite résultant de $X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu$ et du théorème de Lévy 1.5. Le membre de droite est la fonction caractéristique de $\mu \otimes \delta_c$ au point (t_1, t_2) ; le théorème de Lévy 1.5, appliqué cette fois en dimension 2, donne $V_n \overset{\mathbb{P}_n}{\Longrightarrow} \mu \otimes \delta_c$.

Étape 3. Montrons que $U_n + V_n \xRightarrow{\mathbb{P}_n} \nu$ dès que $U_n \xrightarrow{\mathbb{P}_n-\text{prob}} 0$ et $V_n \xRightarrow{\mathbb{P}_n} \nu$. Soit f lipschitzienne bornée, de constante de Lipschitz L_f. Pour tout $\delta > 0$,

$$\left|\mathbb{E}_n\left[f(U_n+V_n)\right] - \int f(w)\,\nu(\mathrm{d}w)\right| \le \left|\mathbb{E}_n\left[f(U_n+V_n)\right] - \mathbb{E}_n\left[f(V_n)\right]\right| + \left|\mathbb{E}_n\left[f(V_n)\right] - \int f(w)\,\nu(\mathrm{d}w)\right|$$
$$\le L_f\delta + 2\left\|f\right\|_\infty \mathbb{P}_n\left(\|U_n\| \ge \delta\right) + \left|\mathbb{E}_n\left[f(V_n)\right] - \int f(w)\,\nu(\mathrm{d}w)\right| ,$$

où la seconde inégalité s'obtient en séparant les événements $\{\|U_n\| < \delta\}$ et $\{\|U_n\| \ge \delta\}$. Les deux derniers termes tendent vers zéro quand $n \to \infty$, à δ fixé, et le premier est arbitrairement petit par le choix de δ. Donc $\mathbb{E}_n[f(U_n+V_n)] \to \int f\,\mathrm{d}\nu$ pour toute f lipschitzienne bornée, et le théorème de Portmanteau 1.3 permet de conclure.

Étape 4. On a donc $(X_n, Y_n) \xRightarrow{\mathbb{P}_n} \mu \otimes \delta_c$. Les trois assertions s'obtiennent en appliquant le théorème de transformation continue 1.4 aux fonctions $(x,y) \mapsto x+y$, $(x,y) \mapsto xy$ et $(x,y) \mapsto x/y$. Les deux premières sont continues sur $\mathbb{R}^2$. La troisième est continue sur $C := \mathbb{R} \times \mathbb{R}^*$, et $(\mu \otimes \delta_c)(C) = \delta_c(\mathbb{R}^*) = 1$ dès que $c \neq 0$. Les lois images de $\mu \otimes \delta_c$ par ces trois fonctions sont respectivement celles de $X + c$, cX et $c^{-1}X$ pour $X \sim \mu$. □

Remarque. Le lemme de Slutsky s'étend au cas vectoriel et matriciel ; l'énoncé et sa démonstration, qui reposent sur le procédé de Cramér-Wold, sont donnés dans les compléments (Section 4.1). C'est cette forme que l'on utilise sans la nommer lorsque T_n est à valeurs dans $\mathbb{R}^\ell$.

Application : un théorème de la limite centrale pour la variance empirique

La variance empirique n'est pas une moyenne empirique, mais elle en diffère par un terme négligeable, et le lemme de Slutsky permet de conclure. On note dans ce paragraphe

$$\widehat{\sigma}_n^2 := \frac{1}{n}\sum_{i=1}^n (X_i - \bar{X}_n)^2 , \qquad S_n^2 := \frac{1}{n-1}\sum_{i=1}^n (X_i - \bar{X}_n)^2 = \frac{n}{n-1}\widehat{\sigma}_n^2 ,$$

la seconde écriture étant la variance empirique corrigée des chapitres 1, 3 et 4.

Exemple 1.6: Théorème de la limite centrale pour la variance empirique

Soit une suite de n-échantillons d'une loi $\mathbb{Q}$ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$,

$$\left(\mathbb{R}^n, (\mathcal{B}(\mathbb{R}))^{\otimes n}, \mathbb{P}_n := \mathbb{Q}^{\otimes n}\right) ,$$

telle que $\int x^4\,\mathbb{Q}(\mathrm{d}x) < \infty$. Notons $\mu := \int x\,\mathbb{Q}(\mathrm{d}x)$ et $\sigma^2 := \mathrm{Var}_{\mathbb{Q}}(X_1)$. Alors

$$\sqrt{n}\left(\widehat{\sigma}_n^2 - \sigma^2\right) \xRightarrow{\mathbb{P}_n} \mathcal{N}(0,\gamma) , \qquad \text{avec } \gamma := \int (x-\mu)^4\,\mathbb{Q}(\mathrm{d}x) - \sigma^4 ,$$

et la même convergence vaut pour la variance empirique corrigée S_n^2.

Démonstration

a) Une autre expression de $\sqrt{n}(\widehat{\sigma}_n^2 - \sigma^2)$. En développant, $\widehat{\sigma}_n^2 = n^{-1}\sum_{i=1}^n (X_i - \mu)^2 - (\bar{X}_n - \mu)^2$, d'où

$$\sqrt{n}\left(\widehat{\sigma}_n^2 - \sigma^2\right) = \frac{1}{\sqrt{n}}\sum_{i=1}^n \left((X_i-\mu)^2 - \sigma^2\right) - \sqrt{n}\left(\bar{X}_n - \mu\right)^2 . \tag{2}$$

b) Le premier terme : un théorème de la limite centrale. Posons $Z_i := (X_i - \mu)^2 - \sigma^2$. Sous $\mathbb{P}_n$, les variables $Z_1, \dots, Z_n$ sont indépendantes et de même loi, $\mathbb{E}_n[Z_1] = 0$, et $\mathrm{Var}_n(Z_1) = \int (x-\mu)^4 \mathbb{Q}(\mathrm{d}x) - \sigma^4 = \gamma$ est finie puisque $\mathbb{Q}$ admet un moment d'ordre 4. Le théorème de la limite centrale 1.6 donne

$$\frac{1}{\sqrt{n}} \sum_{i=1}^{n} Z_i \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0, \gamma) \; .$$

c) Le second terme tend vers zéro en probabilité. Le théorème de la limite centrale donne aussi $\sqrt{n}(\bar{X}_n - \mu) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0, \sigma^2)$, puis, par le théorème de transformation continue 1.4 appliqué à $x \mapsto x^2$,

$$n \left(\bar{X}_n - \mu\right)^2 \overset{\mathbb{P}_n}{\Longrightarrow} \sigma^2 \chi^2(1) \; ,$$

où $\sigma^2\chi^2(1)$ désigne la loi de $\sigma^2 W$ pour $W \sim \chi^2(1)$. Le lemme de Slutsky 1.1, assertion *(ii)*, appliqué avec la suite déterministe $Y_n = n^{-1/2}$, qui converge vers 0, donne

$$\sqrt{n} \left(\bar{X}_n - \mu\right)^2 = \frac{1}{\sqrt{n}} \, n \left(\bar{X}_n - \mu\right)^2 \overset{\mathbb{P}_n}{\Longrightarrow} 0 \; , \quad \text{soit} \quad \sqrt{n} \left(\bar{X}_n - \mu\right)^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0 \; ,$$

la convergence en loi vers une constante entraînant la convergence en probabilité.

d) Conclusion. En reportant b) et c) dans (2) et en appliquant la deuxième remarque qui suit le lemme de Slutsky 1.1, il vient

$$\sqrt{n} \left(\widehat{\sigma}_n^2 - \sigma^2\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0, \gamma) \; .$$

Enfin, $\sqrt{n}(S_n^2 - \widehat{\sigma}_n^2) = \sqrt{n}\,\widehat{\sigma}_n^2/(n-1)$, et comme $\widehat{\sigma}_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \sigma^2$ par la loi faible des grands nombres et le théorème de continuité, le lemme de Slutsky donne $\sqrt{n}(S_n^2 - \widehat{\sigma}_n^2) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, d'où la même loi limite pour $\sqrt{n}(S_n^2 - \sigma^2)$. □

La conséquence suivante, qui servira pour le test de Student, ne demande pas de moment d'ordre 4.

Proposition 1.2: Consistance de la variance empirique

Soit une suite de n-échantillons d'une loi $\mathbb{Q}$ sur $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ de carré intégrable, de variance $\sigma^2 > 0$. Alors

$$\widehat{\sigma}_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \sigma^2 \; , \qquad S_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \sigma^2 \; , \qquad \text{et} \qquad \sigma^{-2} \, S_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 1 \; .$$

Démonstration

Sous $\mathbb{P}_n$, les variables $X_1, \dots, X_n$ sont indépendantes et de même loi $\mathbb{Q}$, de carré intégrable ; la loi faible des grands nombres 1.2 appliquée aux suites $\{X_i\}$ et $\{X_i^2\}$ donne

$$\left(\bar{X}_n, \frac{1}{n} \sum_{i=1}^{n} X_i^2 \right) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \left(\mu, \sigma^2 + \mu^2\right) \; ,$$

la convergence du couple résultant de celle de chaque composante (Section 2.1). Comme $\widehat{\sigma}_n^2 = n^{-1} \sum_{i=1}^n X_i^2 - \bar{X}_n^2$, le théorème de continuité en probabilité (Section 2.1) appliqué à la fonction continue $(u, w) \mapsto w - u^2$ donne $\widehat{\sigma}_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \sigma^2 + \mu^2 - \mu^2 = \sigma^2$. Comme $S_n^2 = \frac{n}{n-1}\widehat{\sigma}_n^2$ et que $n/(n-1) \to 1$, il vient $S_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} \sigma^2$, puis, en divisant par $\sigma^2 > 0$,

$$\sigma^{-2} \, S_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 1 \; . \tag{3}$$

□

1.7 La méthode-δ

Le théorème de continuité transporte une convergence en probabilité par une fonction continue. Si la suite $\{T_n,\ n \in \mathbb{N}\}$ vérifie de plus un théorème de la limite centrale, qu'en est-il de la suite $\{g(T_n)\ :\ n \in \mathbb{N}\}$ pour g régulière ? La réponse est que la loi limite est transportée par la dérivée de g au point considéré.

Théorème 1.7: Méthode-δ, cas scalaire

Soit

- $g : D_g \to \mathbb{R}$ une fonction définie sur un intervalle ouvert D_g de $\mathbb{R}$ et dérivable au point $\theta \in D_g$, de dérivée notée $\dot{g}(\theta)$;
- $\{T_n,\ n \in \mathbb{N}\}$ une suite de variables aléatoires, T_n définie sur $(\mathsf{X}_n, \mathcal{X}_n, \mathbb{P}_n)$, telle que $\mathbb{P}_n(T_n \in D_g) = 1$ pour tout $n \in \mathbb{N}$.

Supposons que

$$r_n(T_n - \theta) \overset{\mathbb{P}_n}{\Longrightarrow} G$$

pour une suite croissante $\{r_n,\ n \in \mathbb{N}\}$ de réels strictement positifs telle que $\lim_{n\to\infty} r_n = +\infty$. Alors

$$r_n\left(g(T_n) - g(\theta)\right) \overset{\mathbb{P}_n}{\Longrightarrow} \dot{g}(\theta)\, G\ , \qquad r_n\left(g(T_n) - g(\theta)\right) - r_n\dot{g}(\theta)(T_n - \theta) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0\ .$$

Démonstration

Convergence en probabilité de $T_n - \theta$. La suite $(r_n\{T_n - \theta\})_n$ converge en loi et $r_n^{-1} \to 0$; le lemme de Slutsky 1.1, assertion *(ii)*, donne

$$T_n - \theta = r_n^{-1}\left(r_n\{T_n - \theta\}\right) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0\ .$$

Développement de g. La fonction g est dérivable au point θ : en posant, pour $h \neq 0$ tel que $\theta + h \in D_g$,

$$\varepsilon(h) := \frac{g(\theta + h) - g(\theta)}{h} - \dot{g}(\theta)\ , \qquad \varepsilon(0) := 0\ ,$$

et en prolongeant ε par 0 hors de $\{h \in \mathbb{R}\ :\ \theta + h \in D_g\}$, on obtient une fonction continue au point 0, nulle en 0, telle que

$$g(\theta + h) = g(\theta) + \dot{g}(\theta)h + h\,\varepsilon(h) \qquad \text{pour tout } h \text{ tel que } \theta + h \in D_g\ .$$

Comme $\mathbb{P}_n(T_n \in D_g) = 1$, on peut écrire, $\mathbb{P}_n$-presque sûrement,

$$r_n\left(g(T_n) - g(\theta)\right) = \dot{g}(\theta)\, r_n(T_n - \theta) + r_n(T_n - \theta)\,\varepsilon(T_n - \theta)\ .$$

Passage à la limite. Le théorème de continuité en probabilité (Section 2.1), appliqué à ε continue au point 0 et à $T_n - \theta \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, donne $\varepsilon(T_n - \theta) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$. Le lemme de Slutsky 1.1 appliqué au produit donne alors

$$R_n := r_n(T_n - \theta)\,\varepsilon(T_n - \theta) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0\ ,$$

ce qui est la seconde assertion du théorème. Par ailleurs $\dot{g}(\theta)\{r_n(T_n - \theta)\} \overset{\mathbb{P}_n}{\Longrightarrow} \dot{g}(\theta)G$ par le théorème de transformation continue 1.4, et la deuxième remarque qui suit le lemme de Slutsky 1.1 permet d'ajouter R_n sans changer la loi limite. □

Intuition. *La méthode-δ est la traduction asymptotique d'une approximation au premier ordre : au voisinage de θ, la fonction g se confond avec sa tangente, et l'erreur $g(T_n)-g(\theta)$ se confond avec $\dot g(\theta)(T_n-\theta)$. L'énoncé rend cette approximation exacte en la plaçant dans la limite : le reste, une fois multiplié par r_n, tend vers zéro en probabilité. Ce que l'on gagne est que la loi limite de $g(T_n)$ se calcule sans aucun nouveau développement : la variance asymptotique est multipliée par $\dot g(\theta)^2$. Ce que l'on perd apparaît quand $\dot g(\theta)=0$: la loi limite est alors dégénérée, et la bonne échelle n'est plus r_n.*

Exemple 1.7: Estimateur du maximum de vraisemblance du paramètre d'une loi exponentielle

Une variable aléatoire de loi $\mathcal{E}(\theta)$ a pour densité $x \mapsto \theta \exp(-\theta x)$ sur $\mathbb{R}_+$, pour espérance $1/\theta$ et pour variance $1/\theta^2$. Soit une suite de n-échantillons d'une loi $\mathcal{E}(\theta)$, $\theta \in \mathbb{R}_+^*$, et l'estimateur du maximum de vraisemblance

$$\hat\theta_n := \left(\bar X_n\right)^{-1} , \qquad \bar X_n := \frac{1}{n}\sum_{k=1}^{n} X_k .$$

Alors la suite $\{\hat\theta_n,\ n \in \mathbb{N}\}$ est consistante et

$$\sqrt{n}\left(\hat\theta_n - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \theta^2\right) .$$

Démonstration

Posons $\varphi(u) := 1/u$ pour $u > 0$. La consistance a été établie à l'exemple 1.3. Pour la loi limite, le théorème de la limite centrale 1.6 donne

$$\sqrt{n}\left(\bar X_n - \theta^{-1}\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \mathrm{Var}_{n,\theta}(X_1)\right) = \mathcal{N}\left(0, \theta^{-2}\right) ,$$

et la fonction φ est dérivable au point $\theta^{-1} \in D_\varphi := \mathbb{R}_+^*$, avec $\dot\varphi(\theta^{-1}) = -\theta^2$. Comme $\mathbb{P}_{n,\theta}(\bar X_n \in \mathbb{R}_+^*) = 1$, la méthode-$\delta$ 1.7 donne

$$\sqrt{n}\left(\hat\theta_n - \theta\right) = \sqrt{n}\left(\varphi(\bar X_n) - \varphi(\theta^{-1})\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \dot\varphi(\theta^{-1})\,\mathcal{N}\left(0, \theta^{-2}\right) = \mathcal{N}\left(0, \theta^4 \cdot \theta^{-2}\right) = \mathcal{N}\left(0, \theta^2\right) .$$

□

Illustration / animation : le théorème de la limite centrale pour l'estimateur du maximum de vraisemblance se regarde dans l'animation de la semaine 3 « Pourquoi l'EMV trouve-t-il le bon paramètre ? », étape « M-estimation » : pour un modèle de Bernoulli ou de Poisson, on suit 400 estimateurs quand n grandit, on les rassemble en boîtes à moustaches pour $n = 64$, 512 et 4 096, puis on change d'échelle en $\sqrt{n}$; les boîtes cessent de se resserrer et l'histogramme des erreurs $\sqrt{n}(\hat\theta_n - \theta)$ prend la forme de la gaussienne limite.



link

Exemple 1.8: Lois limites de X_n^2 et de $1/X_n$

Soit $\{X_n,\ n \in \mathbb{N}\}$ une suite de variables aléatoires telle que

$$r_n(X_n - \mu) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0, \sigma^2) , \qquad \sigma^2 > 0 ,$$

où $\{r_n,\ n \in \mathbb{N}\}$ est croissante, à termes positifs, et tend vers l'infini. Que dire des lois limites de X_n^2 et de $1/X_n$?

Le cas de X_n^2. Posons $g(x) = x^2$, dérivable sur $\mathbb{R}$ avec $g'(x) = 2x$.
Si $\mu \neq 0$, alors $g'(\mu) = 2\mu \neq 0$, et la méthode-δ 1.7 donne

$$r_n \left(X_n^2 - \mu^2\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}\left(0, 4\mu^2\sigma^2\right) \ .$$

Si $\mu = 0$, alors $g'(\mu) = 0$ et la méthode-δ ne donne que

$$r_n X_n^2 \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0 \ .$$

La vitesse r_n est alors trop lente pour faire apparaître une loi limite non dégénérée. Avec la vitesse r_n^2, le théorème de transformation continue 1.4 appliqué à $x \mapsto x^2$ donne

$$\sigma^{-2} r_n^2 X_n^2 = \left(\sigma^{-1} r_n X_n\right)^2 \overset{\mathbb{P}_n}{\Longrightarrow} \chi^2(1) \ ,$$

puisque $\sigma^{-1} r_n X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0,1)$ et que le carré d'une variable $\mathcal{N}(0,1)$ suit la loi $\chi^2(1)$.

Le cas de $1/X_n$. Supposons ici que $\mathbb{P}_n(X_n = 0) = 0$ pour tout $n \in \mathbb{N}$, sans quoi $1/X_n$ n'est pas définie.
Si $\mu \neq 0$, la méthode-δ 1.7 appliquée à $g(x) = 1/x$, dérivable au point μ, donne

$$r_n \left(\frac{1}{X_n} - \frac{1}{\mu}\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}\left(0, \frac{\sigma^2}{\mu^4}\right) \ .$$

Si $\mu = 0$, le théorème de transformation continue 1.4 s'applique à $x \mapsto 1/x$, continue sur $C := \mathbb{R}^*$, qui est de mesure 1 pour la loi $\mathcal{N}(0,1)$; comme $\sigma^{-1} r_n X_n \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0,1)$, il vient

$$\frac{\sigma}{r_n X_n} \overset{\mathbb{P}_n}{\Longrightarrow} \frac{1}{X} \ , \qquad X \sim \mathcal{N}(0,1) \ .$$

Intuition. *Les deux cas $\mu = 0$ montrent ce que la méthode-δ ne dit pas. Quand la dérivée s'annule, l'approximation au premier ordre ne contient plus d'information, et la loi limite n'apparaît qu'à une autre échelle – ici r_n^2 au lieu de r_n – et avec une autre forme – une loi du χ^2, et non une gaussienne. On retrouvera la même situation à l'exercice 6, où un estimateur dont la dérivée de la transformation s'annule au point 0 a un comportement très irrégulier au voisinage de ce point.*

Le cas vectoriel

Dans le cas vectoriel, la dérivée est remplacée par la matrice jacobienne, et la dérivabilité par la différentiabilité ; ces deux notions sont rappelées dans les outils mathématiques (Section 2.5).

Théorème 1.8: Méthode-δ, cas vectoriel

Soit

- D_g un sous-ensemble ouvert de $\mathbb{R}^p$;
- $g : D_g \to \mathbb{R}^m$ une fonction différentiable au point $\theta \in D_g$, de matrice jacobienne $\mathrm{J}_g(\theta)$;
- $\{\mathbf{T}_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires, $\mathbf{T}_n$ définie sur $(\mathsf{X}_n, \mathcal{X}_n, \mathbb{P}_n)$, telle que $\mathbb{P}_n(\mathbf{T}_n \in D_g) = 1$ pour tout $n \in \mathbb{N}$.

Supposons que

$$r_n \left(\mathbf{T}_n - \theta\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathbf{T}$$

pour une suite croissante $\{r_n,\ n \in \mathbb{N}\}$ de réels strictement positifs telle que $\lim_{n\to\infty} r_n = +\infty$. Alors

$$r_n\left(g(\mathbf{T}_n) - g(\theta)\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathrm{J}_g(\theta)\,\mathbf{T}\ , \qquad r_n\left(g(\mathbf{T}_n) - g(\theta)\right) - r_n\,\mathrm{J}_g(\theta)\left(\mathbf{T}_n - \theta\right) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0\ .$$

La démonstration est celle du cas scalaire, en remplaçant le reste $h\varepsilon(h)$ par un reste $R(h)$ tel que $\|R(h)\| = o(\|h\|)$, et le lemme de Slutsky par sa forme vectorielle (Section 4.1). En particulier, si $r_n = \sqrt{n}$ et $\mathbf{T} \sim \mathcal{N}(0, \Sigma)$, alors

$$\sqrt{n}\left(g(\mathbf{T}_n) - g(\theta)\right) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}\left(0, \mathrm{J}_g(\theta)\,\Sigma\,\mathrm{J}_g(\theta)^\top\right)\ .$$

1.8 Normalité asymptotique

La consistance d'une suite d'estimateurs ne quantifie pas la vitesse à laquelle l'erreur décroît. En pratique, on veut savoir de combien on se trompe en remplaçant $g(\theta)$ par $T_n(Z_n)$, donc disposer de la loi de $T_n(Z_n) - g(\theta)$ sous $\mathbb{P}_{n,\theta}$. Cet objectif est hors d'atteinte en général ; en revanche, dans de nombreuses situations, la suite $\sqrt{n}\{T_n(Z_n) - g(\theta)\}$ converge en loi vers une gaussienne non dégénérée.

Définition 1.6: Normalité asymptotique

Soit $\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} : \theta \in \Theta\}) : n \in \mathbb{N}_\star\}$ une suite de modèles statistiques et $g : \Theta \to \mathbb{R}^\ell$ une fonction. La suite d'estimateurs $\{T_n,\ n \in \mathbb{N}\}$, $T_n : \mathsf{Z}_n \to \mathbb{R}^\ell$, de g est dite *asymptotiquement normale* si, pour tout $\theta \in \Theta$,

$$\sqrt{n}\left(T_n(Z_n) - g(\theta)\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \Sigma(\theta)\right)\ ,$$

où $\Sigma(\theta)$ est, pour tout $\theta \in \Theta$, une matrice symétrique positive de taille $\ell \times \ell$, appelée *matrice de covariance asymptotique* de la suite d'estimateurs, ou *variance asymptotique* dans le cas scalaire $\ell = 1$, où on la note alors $v(\theta)$.

Une suite d'estimateurs asymptotiquement normale est nécessairement consistante : puisque $1/\sqrt{n} \to 0$, le lemme de Slutsky 1.1 donne

$$T_n(Z_n) - g(\theta) = \frac{1}{\sqrt{n}}\sqrt{n}\left(T_n(Z_n) - g(\theta)\right) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} 0\ ,$$

pour tout $\theta \in \Theta$.

Exemple 1.9: Estimateur du maximum de vraisemblance dans un modèle exponentiel

L'exemple 1.7 a établi que, pour tout $\theta \in \mathbb{R}_+^*$,

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \theta^2\right)\ .$$

La suite des estimateurs du maximum de vraisemblance est donc asymptotiquement normale, de variance asymptotique $v(\theta) = \theta^2$.

Intuition. *La variance asymptotique est la grandeur que l'on cherchera à rendre petite. Elle joue, dans le monde asymptotique, le rôle que l'erreur quadratique moyenne joue à n fixé : l'écriture $\hat{\theta}_n \approx \theta + \sqrt{v(\theta)/n}\,\xi$ avec ξ approximativement $\mathcal{N}(0,1)$ est une approximation – elle n'est exacte qu'à la limite – mais c'est elle qui guide la lecture. On comparera deux estimateurs par leurs variances asymptotiques (Section 1.11), et on retrouvera dans $v(\theta)$, pour les estimateurs du maximum de vraisemblance des modèles réguliers, l'inverse de l'information de Fisher du chapitre 3.*

1.9 Fonctions asymptotiquement pivotales

Pour construire une région de confiance, on cherche une fonction des observations et du paramètre dont la loi ne dépende pas du paramètre. À n fixé, c'était la notion de fonction pivotale du chapitre 4. Ici, on demande seulement que la loi limite ne dépende pas du paramètre.

Définition 1.7: Fonction asymptotiquement pivotale

Soit $\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} : \theta \in \Theta\}) : n \in \mathbb{N}\}$ une suite de modèles statistiques. Une suite de fonctions mesurables $\{G_n,\ n \in \mathbb{N}\}$, $G_n : \mathsf{Z}_n \times \Theta \to \mathbb{R}^p$, est *asymptotiquement pivotale de loi L* s'il existe une probabilité L sur $(\mathbb{R}^p, \mathcal{B}(\mathbb{R}^p))$ telle que, pour tous $\theta, \vartheta \in \Theta$ et tout $A \in \mathcal{B}(\mathbb{R}^p)$,

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta}\left(G_n(Z_n, \theta) \in A\right) = \lim_{n\to\infty} \mathbb{P}_{n,\vartheta}\left(G_n(Z_n, \vartheta) \in A\right) = L(A)\ .$$

Exemple 1.10: Pivot asymptotique issu de la normalité asymptotique

Soit $\{T_n,\ n \in \mathbb{N}\}$, $T_n : \mathsf{Z}_n \to \mathbb{R}$, une suite d'estimateurs de g asymptotiquement normale :

$$\forall \theta \in \Theta\ , \qquad \sqrt{n}\left(T_n(Z_n) - g(\theta)\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, v(\theta)\right)\ , \qquad v(\theta) > 0\ .$$

Alors

$$G_n(Z_n; \theta) := \frac{\sqrt{n}}{\sqrt{v(\theta)}}\left(T_n(Z_n) - g(\theta)\right)$$

définit une suite de fonctions asymptotiquement pivotales, de loi $L = \mathcal{N}(0,1)$.

Démonstration

À θ fixé, la convergence $\sqrt{n}(T_n - g(\theta)) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0, v(\theta))$ et le théorème de transformation continue 1.4, appliqué à la multiplication par la constante $v(\theta)^{-1/2}$, donnent $G_n(Z_n; \theta) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1)$. La loi limite ne dépendant pas de θ, la définition est satisfaite pour tout borélien A dont la frontière est de mesure nulle sous $\mathcal{N}(0,1)$, donc pour tout borélien puisque la loi $\mathcal{N}(0,1)$ ne charge aucun point et que la convergence des fonctions de répartition en tout point entraîne celle des probabilités de tous les boréliens de la forme $]a, b]$, dont la classe engendre $\mathcal{B}(\mathbb{R})$. □

1.10 Régions et intervalles de confiance asymptotiques

Les pivots asymptotiques fournissent des régions de confiance dont le niveau n'est garanti qu'à la limite.

Définition 1.8: Région de confiance de niveau asymptotique $1-\alpha$

Soit $\{(\mathsf{Z}_n, \mathcal{Z}_n, \{\mathbb{P}_{n,\theta} : \theta \in \Theta\}) : n \in \mathbb{N}\}$ une suite de modèles statistiques, $g : \Theta \to \mathbb{R}^p$ une fonction et $\alpha \in]0,1[$. Une suite d'ensembles aléatoires $\{\mathcal{C}_n(Z_n) : n \in \mathbb{N}\} \subset \mathcal{B}(\mathbb{R}^p)$ définit une suite de *régions de confiance au niveau asymptotique* $1-\alpha$ pour la fonction g si

$$\inf_{\theta\in\Theta} \liminf_{n\to\infty}\ \mathbb{P}_{n,\theta}\left(g(\theta) \in \mathcal{C}_n(Z_n)\right) \geq 1 - \alpha\ .$$

L'ordre dans lequel on prend la limite et l'infimum est celui de l'énoncé : on passe d'abord à la limite en n, à θ fixé, puis on prend l'infimum sur Θ. Cette définition ne dit rien de la probabilité de couverture pour une valeur donnée de n, et c'est sa limite principale.

Méthode 1.1: Intervalle de confiance asymptotique, cas où $\theta \mapsto v(\theta)$ est continue

Soit une suite d'estimateurs de θ asymptotiquement normale,

$$\sqrt{n}\left(\hat{\theta}_n - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, v(\theta)\right) \ , \qquad v(\theta) > 0 \ ,$$

avec $\theta \mapsto v(\theta)$ continue sur Θ. Alors

- la fonction $G_n : (Z_n; \theta) \mapsto \sqrt{n}\,(\hat{\theta}_n - \theta)/\sqrt{v(\theta)}$ est asymptotiquement pivotale de loi $\mathcal{N}(0,1)$ (exemple 1.10) ;
- la normalité asymptotique entraîne la consistance, et v étant continue, le théorème de continuité 1.1 donne $v(\hat{\theta}_n) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} v(\theta) > 0$; le lemme de Slutsky 1.1 fournit alors une seconde fonction asymptotiquement pivotale,

$$\sqrt{n}\,\frac{\hat{\theta}_n - \theta}{\sqrt{v(\hat{\theta}_n)}} \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1) \ ;$$

- on en déduit l'intervalle de confiance de niveau asymptotique $1-\alpha$

$$\mathcal{C}_{n,\alpha}(\hat{\theta}_n) = \left[\hat{\theta}_n \pm z_{1-\alpha/2}\sqrt{\frac{v(\hat{\theta}_n)}{n}}\right] \ ,$$

où z_u est le quantile d'ordre u de la loi $\mathcal{N}(0,1)$.

L'intérêt de la seconde fonction pivotale est que ses bornes sont calculables : la première fait intervenir $v(\theta)$, donc le paramètre inconnu, et ne se résout en θ que lorsque l'inégalité $|G_n| \leq z_{1-\alpha/2}$ peut être inversée explicitement. L'exercice 1 construit, sur le modèle exponentiel, trois intervalles de confiance asymptotiques, dont un qui n'utilise pas la continuité de v.

Intuition. *Remplacer $v(\theta)$ par $v(\hat{\theta}_n)$ est l'opération que le lemme de Slutsky autorise, et elle ne change pas la loi limite. Elle change en revanche la probabilité de couverture à n fixé, puisqu'on a introduit une seconde source d'erreur. Les deux intervalles obtenus pour une proportion, ci-dessous, se distinguent exactement sur ce point, et les figures montrent que l'écart n'est pas négligeable lorsque la proportion est proche de* 0.

Trois intervalles de confiance pour une proportion

Soit une suite de n-échantillons du modèle de Bernoulli $\{\mathcal{B}\text{er}(\theta) : \theta \in \Theta :=]0,1[\}$ et $\bar{X}_n := n^{-1}\sum_{k=1}^n X_k$. Le théorème de la limite centrale 1.6 donne, pour tout $\theta \in \Theta$,

$$\sqrt{n}\left(\bar{X}_n - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \theta(1-\theta)\right) \ , \tag{4}$$

d'où la fonction asymptotiquement pivotale

$$G_n : (X_1, \ldots, X_n; \theta) \mapsto \sqrt{n}\frac{\bar{X}_n - \theta}{\sqrt{\theta(1-\theta)}} \ , \qquad G_n \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1) \ . \tag{5}$$

Trois façons de s'en servir conduisent à trois intervalles différents.

Exemple 1.11: Intervalle de Wilson

La région de confiance de niveau asymptotique $1-\alpha$ associée au pivot (5) admet les trois écritures équivalentes

$$\begin{aligned}&\left\{\theta\in\Theta\,:\,-z_{1-\alpha/2}\le\sqrt{n}\frac{\bar X_n-\theta}{\sqrt{\theta(1-\theta)}}\le z_{1-\alpha/2}\right\}\\&=\left\{\theta\in\Theta\,:\,n\left(\bar X_n-\theta\right)^2\le z_{1-\alpha/2}^2\,\theta(1-\theta)\right\}\\&=\left[\bar X_n+\frac{z_{1-\alpha/2}^2}{2n}\pm z_{1-\alpha/2}\sqrt{\frac{\bar X_n(1-\bar X_n)}{n}+\frac{z_{1-\alpha/2}^2}{4n^2}}\right]\left(1+\frac{z_{1-\alpha/2}^2}{n}\right)^{-1},\end{aligned}$$

la dernière intersectée avec Θ. C'est l'*intervalle de Wilson*.

Démonstration

La première écriture est celle de la région associée au pivot. La deuxième s'obtient en élevant au carré, l'inégalité $|u|\le z$ étant équivalente à $u^2\le z^2$ pour $z\ge 0$. En notant $z:=z_{1-\alpha/2}$, la condition s'écrit

$$(n+z^2)\theta^2-\left(2n\bar X_n+z^2\right)\theta+n\bar X_n^2\le 0\,,$$

trinôme en θ de coefficient dominant strictement positif, dont le discriminant vaut

$$\left(2n\bar X_n+z^2\right)^2-4(n+z^2)n\bar X_n^2=4nz^2\bar X_n(1-\bar X_n)+z^4\ge 0\,.$$

L'ensemble des θ qui vérifient l'inégalité est donc le segment compris entre les deux racines, c'est-à-dire

$$\frac{\bar X_n+\dfrac{z^2}{2n}\pm z\sqrt{\dfrac{\bar X_n(1-\bar X_n)}{n}+\dfrac{z^2}{4n^2}}}{1+\dfrac{z^2}{n}}\,,$$

après division du numérateur et du dénominateur par $2n$. □

Exemple 1.12: Intervalle de Wald

Le lemme de Slutsky 1.1 appliqué à (5) fournit une seconde fonction asymptotiquement pivotale,

$$\tilde G_n:(X_1,\dots,X_n;\theta)\mapsto\frac{\sqrt{n}\left(\bar X_n-\theta\right)}{\sqrt{\bar X_n(1-\bar X_n)}}\,,\qquad \tilde G_n\overset{\mathbb{P}_{n,\theta}}{\Longrightarrow}\mathcal{N}(0,1)\,,$$

et les régions de confiance de niveau asymptotique $1-\alpha$ qui en découlent sont les intervalles

$$\bar X_n\pm z_{1-\alpha/2}\frac{\sqrt{\bar X_n(1-\bar X_n)}}{\sqrt{n}}\,.$$

C'est l'*intervalle de Wald*.

Démonstration

La fonction $\theta\mapsto\sqrt{\theta(1-\theta)}$ est continue et strictement positive sur $]0,1[$, et $\bar X_n\overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow}\theta$ par la loi faible des grands nombres 1.2 : le théorème de continuité 1.1 donne

$$W_n:=\sqrt{\bar X_n(1-\bar X_n)}\overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow}\sqrt{\theta(1-\theta)}>0\,,$$

et en particulier $\mathbb{P}_{n,\theta}(W_n = 0) \to 0$. Comme W_n peut s'annuler, on convient que $\tilde{G}_n := 0$ lorsque $\bar{X}_n \in \{0, 1\}$, et l'on pose $Y_n := W_n$ sur $\{W_n > 0\}$ et $Y_n := 1$ ailleurs, de sorte que $\mathbb{P}_{n,\theta}(Y_n \neq 0) = 1$ et que $Y_n \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \sqrt{\theta(1-\theta)}$. Le lemme de Slutsky 1.1, assertion *(iii)*, donne alors

$$\frac{\sqrt{n}\left(\bar{X}_n - \theta\right)}{Y_n} \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1) \ ,$$

et $\tilde{G}_n$ coïncide avec cette variable hors d'un événement de probabilité tendant vers zéro : leur différence tend vers zéro en probabilité, et la deuxième remarque qui suit le lemme de Slutsky 1.1 donne la même loi limite pour $\tilde{G}_n$. Enfin l'inégalité $|\tilde{G}_n| \leq z_{1-\alpha/2}$ se résout immédiatement en θ. □

Exemple 1.13: Stabilisation de la variance

Soit g une fonction dérivable sur Θ telle que $g'(\theta) \neq 0$ pour tout θ. La méthode-δ 1.7 appliquée à (4) donne

$$\sqrt{n}\left(g(\bar{X}_n) - g(\theta)\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \left[g'(\theta)\right]^2 \theta(1-\theta)\right) \ .$$

Si l'on choisit g de sorte que $\left[g'(\theta)\right]^2 \theta(1-\theta) = k^2$ pour une constante $k > 0$ et tout $\theta \in \Theta$, la variance asymptotique ne dépend plus de θ, et

$$\left[g(\bar{X}_n) - z_{1-\alpha/2}\frac{k}{\sqrt{n}} \ , \quad g(\bar{X}_n) + z_{1-\alpha/2}\frac{k}{\sqrt{n}}\right]$$

est un intervalle de confiance de niveau asymptotique $1-\alpha$ pour $g(\theta)$. Avec $k = 1/2$, la condition s'écrit $g'(\theta) = \frac{1/2}{\sqrt{\theta(1-\theta)}}$, soit $g(\theta) = \arcsin(\sqrt{\theta})$, et l'on obtient, pour tout $\theta \in \Theta$,

$$\sqrt{n}\left(\arcsin\left(\sqrt{\bar{X}_n}\right) - \arcsin\left(\sqrt{\theta}\right)\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, 1/4\right) \ .$$

La fonction g étant croissante et de réciproque $u \mapsto \sin^2 u$ sur $[0, \pi/2]$, il vient l'intervalle de confiance de niveau asymptotique $1-\alpha$ pour θ

$$\left[\sin^2\left(\arcsin\left(\sqrt{\bar{X}_n}\right) - \frac{z_{1-\alpha/2}}{2\sqrt{n}}\right) \ , \quad \sin^2\left(\arcsin\left(\sqrt{\bar{X}_n}\right) + \frac{z_{1-\alpha/2}}{2\sqrt{n}}\right)\right] \ ,$$

les arguments du sinus étant au préalable ramenés à l'intervalle $[0, \pi/2]$.

Cette troisième construction évite d'estimer la variance asymptotique, mais elle demande de résoudre une équation différentielle, ce qui n'est possible qu'en dimension un. L'exercice 1 en donne un second exemple, sur le modèle exponentiel.

Les deux figures sont commentées dans les compléments (Section 4.4) : pour $\theta = 0.25$, les deux intervalles sont pratiquement confondus, alors que pour $\theta = 0.025$ l'intervalle de Wald est dégénéré dès que $\bar{X}_n = 0$, ce qui se produit avec une probabilité non négligeable.

1.11 Comparaison asymptotique de deux estimateurs

La variance asymptotique fournit un critère de comparaison là où l'erreur quadratique moyenne n'est pas calculable.

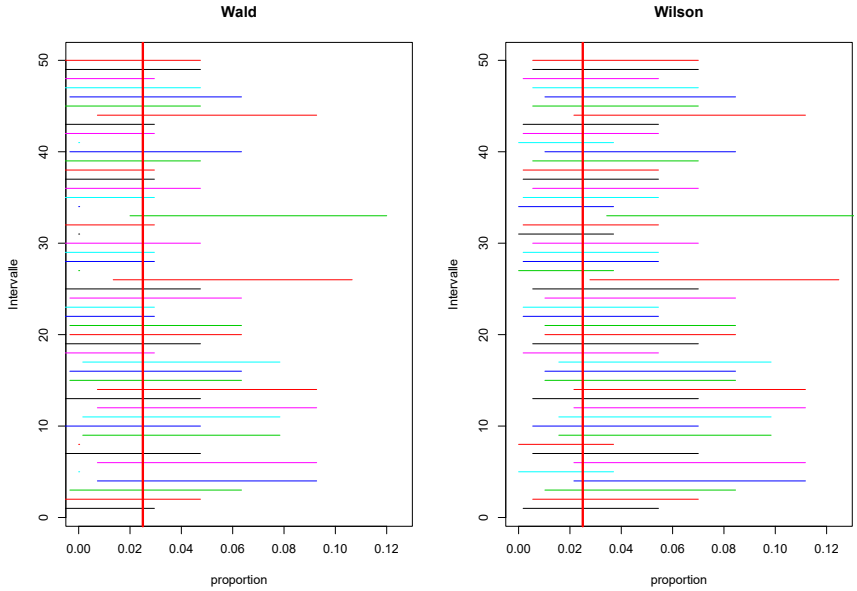


FIGURE 3 – Cinquante intervalles de confiance de Wald et de Wilson de niveau de couverture $1 - \alpha = 0.95$ pour une proportion $\theta = 0.025$ et $n = 100$.

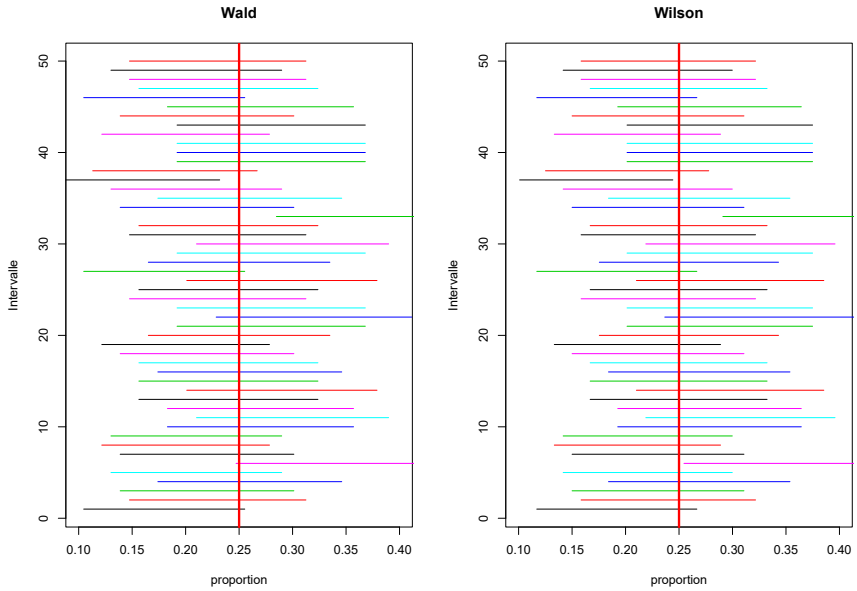


FIGURE 4 – Cinquante intervalles de confiance de Wald et de Wilson de niveau de couverture $1 - \alpha = 0.95$ pour une proportion $\theta = 0.25$ et $n = 100$.

Proposition 1.3: Comparaison par la variance asymptotique

Soient $\hat{\theta}_{n,1}$ et $\hat{\theta}_{n,2}$ deux suites d'estimateurs de θ, asymptotiquement normales de variances asymptotiques respectives v_1 et v_2, continues et strictement positives sur Θ, et telles que

$$v_1(\theta) < v_2(\theta) \ , \qquad \forall \theta \in \Theta \ .$$

Pour $i = 1, 2$, les intervalles

$$\mathcal{C}_{n,\alpha}(\hat{\theta}_{n,i}) := \left[\hat{\theta}_{n,i} \pm z_{1-\alpha/2} \sqrt{\frac{v_i(\hat{\theta}_{n,i})}{n}} \right]$$

sont des intervalles de confiance de niveau asymptotique $1-\alpha$ pour θ, et, pour tout $\theta \in \Theta$,

$$\frac{\left|\mathcal{C}_{n,\alpha}(\hat{\theta}_{n,1})\right|}{\left|\mathcal{C}_{n,\alpha}(\hat{\theta}_{n,2})\right|} \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \sqrt{\frac{v_1(\theta)}{v_2(\theta)}} < 1 \ .$$

On dit alors que la précision de $\hat{\theta}_{n,1}$ est *asymptotiquement meilleure* que celle de $\hat{\theta}_{n,2}$.

Démonstration

Le premier point est la méthode 1.1. Pour le second, la longueur de $\mathcal{C}_{n,\alpha}(\hat{\theta}_{n,i})$ vaut $2z_{1-\alpha/2}\sqrt{v_i(\hat{\theta}_{n,i})/n}$, de sorte que le rapport des longueurs est

$$\sqrt{\frac{v_1(\hat{\theta}_{n,1})}{v_2(\hat{\theta}_{n,2})}} \ .$$

Chaque suite d'estimateurs étant consistante et chaque v_i continue et strictement positive, le théorème de continuité 1.1 donne $v_i(\hat{\theta}_{n,i}) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} v_i(\theta) > 0$, puis le théorème de continuité appliqué au couple et à la fonction $(u_1, u_2) \mapsto \sqrt{u_1/u_2}$, continue au point $(v_1(\theta), v_2(\theta))$, donne la convergence annoncée. □

Intuition. *Le critère se lit sur les intervalles de confiance : à niveau asymptotique fixé, l'estimateur de plus petite variance asymptotique produit, pour n grand, un intervalle plus court dans un rapport $\sqrt{v_1(\theta)/v_2(\theta)}$. De façon équivalente, et en raisonnant sur l'approximation signalée plus haut, atteindre une précision donnée demande $v_1(\theta)/v_2(\theta)$ fois moins d'observations avec le premier estimateur qu'avec le second. Ce critère a ses limites : l'exercice 6 construit un estimateur dont la variance asymptotique est partout au moins aussi bonne que celle de l'estimateur du maximum de vraisemblance, et strictement meilleure en un point, mais dont le comportement à n fixé est mauvais (Section 4.5).*

1.12 Tests asymptotiques : taille, niveau et consistance

Rappelons du chapitre 4 que la fonction puissance d'un test de fonction critique $\phi \in \{0, 1\}$ est

$$\theta \mapsto \beta_\phi(\theta) := \mathbb{P}_\theta(\phi = 1) \ .$$

Lorsque la loi de la statistique de test n'est pas explicite, on ne sait pas calculer β_{ϕ_n} à n fixé, et les notions de taille et de niveau sont remplacées par leurs versions asymptotiques.

Définition 1.9: Taille asymptotique

Considérons le test $H_0 : \theta \in \Theta_0$, contre $H_1 : \theta \in \Theta_1$. La *taille asymptotique* d'une suite de tests $\{\phi_n,\ n \in \mathbb{N}\}$ est

$$\sup_{\theta\in\Theta_0} \limsup_{n\to\infty} \beta_{\phi_n}(\theta) \ .$$

Définition 1.10: Niveau asymptotique

La suite de tests $\{\phi_n,\ n \in \mathbb{N}^*\}$ est de *niveau asymptotique* α si

$$\forall \theta \in \Theta_0 \ , \qquad \limsup_{n\to\infty} \beta_{\phi_n}(\theta) \leq \alpha \ ,$$

c'est-à-dire si sa taille asymptotique est inférieure ou égale à α.

Définition 1.11: Suite de tests consistante

Considérons le test $H_0 : \theta \in \Theta_0$, contre $H_1 : \theta \in \Theta_1$. La suite $\{\phi_n,\ n \in \mathbb{N}\}$ est *consistante* si

$$\text{pour tout } \theta \in \Theta_1 \ , \qquad \liminf_{n\to\infty} \beta_{\phi_n}(\theta) = 1 \ .$$

Intuition. *Les deux notions se partagent les deux hypothèses, comme le niveau et la puissance du chapitre 4 : le niveau asymptotique borne, sur l'hypothèse nulle, la probabilité de rejeter à tort ; la consistance demande que, sur l'hypothèse alternative, la probabilité de rejeter tende vers* 1. *Une suite consistante de niveau asymptotique α finit donc par distinguer toute valeur du paramètre qui ne satisfait pas l'hypothèse nulle. Ce qu'elle ne dit pas est à quelle valeur de n cela se produit : deux suites de tests peuvent être toutes deux consistantes et de même niveau asymptotique, et se comporter très différemment pour la valeur de n dont on dispose. L'exercice 3 construit deux telles suites pour le même jeu d'hypothèses, et le chapitre suivant donnera un moyen de les comparer.*

Application : le test de Student

Le test de Student du chapitre 1 reposait sur l'hypothèse que les observations sont gaussiennes, et la loi exacte de la statistique de test était une loi de Student. Sans cette hypothèse, la loi exacte est inconnue, mais la loi limite est la même pour toutes les lois de carré intégrable.

Soit une suite de n-échantillons d'un modèle

$$\left(\mathbb{R}, \mathcal{B}(\mathbb{R}), \left\{\mathbb{Q}_\theta \ : \ \theta = (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*\right\}\right) \ ,$$

où l'on suppose que, pour tout θ, la loi $\mathbb{Q}_\theta$ est de carré intégrable, d'espérance $\mu := \int x\, \mathbb{Q}_\theta(\mathrm{d}x)$ et de variance $\sigma^2 := \int x^2\, \mathbb{Q}_\theta(\mathrm{d}x) - \mu^2 > 0$.

Exemple 1.14: Test de Student asymptotique

Soit $\mu_0 \in \mathbb{R}$. Pour tester les hypothèses

$$H_0 : \mu = \mu_0, \quad \text{contre} \quad H_1 : \mu \neq \mu_0 \ ,$$

on considère la statistique de test

$$T_n := \sqrt{n}\frac{\bar{X}_n - \mu_0}{S_n} \ , \qquad \bar{X}_n := \frac{1}{n}\sum_{i=1}^n X_i \ , \qquad S_n^2 := \frac{1}{n-1}\sum_{i=1}^n \left(X_i - \bar{X}_n\right)^2 \ ,$$

et la suite de tests de région de rejet

$$\mathcal{R}_{n,\alpha} := \left\{(x_1, \ldots, x_n) \in \mathbb{R}^n \ : \ |T_n| > z_{1-\alpha/2}\right\} \ .$$

Cette suite de tests est de taille asymptotique α et elle est consistante.

Démonstration

Loi limite de T_n sous l'hypothèse nulle. Soit $\theta = (\mu_0, \sigma^2)$ avec $\sigma^2 > 0$. Le théorème de la limite centrale 1.6 donne

$$\frac{\sqrt{n}}{\sigma}\left(\bar{X}_n - \mu_0\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1)\ ,$$

et la proposition 1.2 donne $\sigma^{-2}S_n^2 \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} 1$, donc $\sigma^{-1}S_n \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} 1$ par le théorème de continuité 1.1 appliqué à $u \mapsto \sqrt{u}$. Le lemme de Slutsky 1.1, assertion *(iii)*, appliqué au quotient, donne

$$T_n = \frac{\sqrt{n}(\bar{X}_n - \mu_0)/\sigma}{S_n/\sigma} \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1)\ .$$

Taille asymptotique. La loi $\mathcal{N}(0,1)$ ne charge pas les points $\pm z_{1-\alpha/2}$; le théorème de Portmanteau 1.3 donne donc, pour tout $\theta \in \Theta_0$,

$$\beta_{\phi_n}(\theta) = \mathbb{P}_{n,\theta}\left(|T_n| > z_{1-\alpha/2}\right) \xrightarrow[n\to\infty]{} \mathbb{P}\left(|U| > z_{1-\alpha/2}\right) = \alpha\ , \qquad U \sim \mathcal{N}(0,1)\ ,$$

la dernière égalité résultant de la définition du quantile et de la symétrie de la loi $\mathcal{N}(0,1)$. La taille asymptotique est donc égale à α, et la suite de tests est de niveau asymptotique α.

Consistance. Soit $\theta = (\mu, \sigma^2)$ avec $\mu \neq \mu_0$. On écrit

$$T_n = \frac{\sqrt{n}\left(\bar{X}_n - \mu\right)}{S_n} + \frac{\sqrt{n}\left(\mu - \mu_0\right)}{S_n}\ ,$$

de sorte que la région d'acceptation s'écrit

$$\left\{ -z_{1-\alpha/2} - \frac{\sqrt{n}(\mu-\mu_0)}{S_n} \leq \frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \leq z_{1-\alpha/2} - \frac{\sqrt{n}(\mu-\mu_0)}{S_n} \right\}\ .$$

Supposons $\mu - \mu_0 > 0$. Comme $S_n \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \sigma > 0$ et $\sqrt{n}(\mu-\mu_0) \to +\infty$, on a, pour tout $M > 0$,

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta}\left(\frac{\sqrt{n}(\mu-\mu_0)}{S_n} \geq M \right) = 1\ .$$

Par conséquent, pour tout $M > 0$,

$$\limsup_{n\to\infty} \mathbb{P}_{n,\theta}\left(|T_n| \leq z_{1-\alpha/2}\right) \leq \limsup_{n\to\infty} \mathbb{P}_{n,\theta}\left(\frac{\sqrt{n}(\bar{X}_n - \mu)}{S_n} \leq z_{1-\alpha/2} - M \right) = \mathbb{P}\left(U \leq z_{1-\alpha/2} - M\right)\ ,$$

où l'on a utilisé, comme au premier point, que $\sqrt{n}(\bar{X}_n - \mu)/S_n \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0,1)$, et où $U \sim \mathcal{N}(0,1)$. Cette majoration valant pour tout $M > 0$, on fait tendre M vers $+\infty$ et il vient

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta}\left(|T_n| \leq z_{1-\alpha/2}\right) = 0\ , \qquad \text{soit} \qquad \lim_{n\to\infty} \beta_{\phi_n}(\theta) = 1\ .$$

Le cas $\mu - \mu_0 < 0$ se traite de la même façon, en minorant $-\sqrt{n}(\mu-\mu_0)/S_n$. La suite de tests est donc consistante. □

Intuition. *La consistance ne s'obtient pas en remplaçant T_n par sa loi limite. Sous l'hypothèse alternative, la loi de T_n n'est pas fixe : elle se déplace vers l'infini, puisque T_n contient le terme $\sqrt{n}(\mu-\mu_0)/S_n$ qui diverge. C'est pourquoi la démonstration introduit un seuil auxiliaire M et passe à la limite deux fois, d'abord en n puis en M : les bornes de la région d'acceptation bougent avec n en même temps que la loi, et un raisonnement qui oublierait l'un des deux mouvements serait faux. L'exercice 3 demande le même type de soin.*

1.13 Le programme des exercices

La feuille de la semaine comporte sept exercices, et chacun met en œuvre un point du chapitre.

— L'exercice 1 construit, pour le modèle exponentiel, les estimateurs des moments associés à $T_1(x) = x$ et $T_2(x) = x^2$, établit leur consistance et leur normalité asymptotique, les compare par leurs variances asymptotiques (Section 1.11), et donne trois intervalles de confiance asymptotiques : l'un par le lemme de Slutsky, l'un par stabilisation de la variance (exemple 1.13), le dernier en résolvant directement l'inégalité du pivot, sans utiliser la continuité de v.

— L'exercice 2 traite le modèle de Pareto translaté, qui n'est pas régulier : l'estimateur du maximum de vraisemblance du paramètre de translation a une erreur d'ordre $1/n$ et une loi limite exponentielle, comme l'estimateur du support d'une loi uniforme (exemple 1.5).

— L'exercice 3 construit, pour un même jeu d'hypothèses, deux suites de tests consistantes et de même niveau asymptotique, l'une fondée sur une fréquence de signes, l'autre sur la statistique de Student (exemple 1.14).

— L'exercice 4 reprend, sur le modèle de Poisson, la chaîne complète : loi faible des grands nombres, théorème de la limite centrale, méthode-δ appliquée à $\theta \mapsto \mathrm{e}^{-\theta}$, puis intervalle de confiance asymptotique.

— L'exercice 5 est une application de la loi faible des grands nombres 1.2 au calcul de la limite d'une série.

— L'exercice 6 étudie l'estimateur de Hodges, dont la variance asymptotique est partout au moins aussi petite que celle de l'estimateur du maximum de vraisemblance, sans que son comportement à n fixé soit acceptable (Section 4.5).

— L'exercice 7 établit l'existence d'une suite consistante d'estimateurs définie comme racine des équations de vraisemblance, sur un modèle de mélange où la vraisemblance n'a pas de maximum explicite.