2 Les outils mathématiques

Vous retrouverez ci-dessous les éléments de probabilité que la partie précédente mobilise : les modes de convergence et les implications qui les relient, les deux inégalités qui donnent la loi faible des grands nombres, les deux lemmes d'analyse qui apparaissent dans la preuve du théorème de la limite centrale, le procédé qui ramène une convergence de vecteurs à une convergence de variables réelles, et la différentiabilité d'une fonction vectorielle. La liste des résultats admis dans ce chapitre clôt la partie.

2.1 Les modes de convergence et leurs liens

Définition 2.1: Convergence en probabilité

Soient $\{X_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires à valeurs dans $\mathbb{R}^d$ et X un vecteur aléatoire à valeurs dans $\mathbb{R}^d$, définis sur un même espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$. La suite $\{X_n,\ n \in \mathbb{N}\}$ *converge en probabilité* vers X, ce que l'on note $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$, si pour tout $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathbb{P}\left(\|X_n - X\| > \varepsilon\right) = 0 \ .$$

La définition 1.2 est cette définition, écrite pour une suite d'estimateurs dont la limite est la constante $g(\theta)$, sous la probabilité $\mathbb{P}_{n,\theta}$; la convergence en loi (définition 1.4) ne demande pas, elle, que les variables soient définies sur un même espace.

Proposition 2.1: Convergence d'un vecteur et de ses coordonnées

Soient $\{X_n,\ n \in \mathbb{N}\}$ et $\{Y_n,\ n \in \mathbb{N}\}$ deux suites de vecteurs aléatoires à valeurs dans $\mathbb{R}^d$ et $\mathbb{R}^p$, et X, Y deux vecteurs aléatoires à valeurs dans $\mathbb{R}^d$ et $\mathbb{R}^p$, définis sur le même espace de probabilité. Alors $(X_n, Y_n) \overset{\mathbb{P}-\text{prob}}{\longrightarrow} (X, Y)$ si et seulement si $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$ et $Y_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} Y$.

Démonstration

C'est une conséquence directe des inégalités

$$\|x_1 - x_2\| \leq \|(x_1, y_1) - (x_2, y_2)\| \leq \|x_1 - x_2\| + \|y_1 - y_2\| \ .$$

□

L'énoncé analogue est faux pour la convergence en loi : si $X_n \sim \mathcal{N}(0,1)$ et $Y_n := (-1)^n X_n$, chaque composante converge en loi vers $\mathcal{N}(0,1)$, mais le couple (X_n, Y_n) ne converge pas en loi, car $\mathbb{E}[f(X_n + Y_n)]$ vaut alternativement $\mathbb{E}[f(2X_n)]$ et $f(0)$. C'est pourquoi la démonstration du lemme de Slutsky établit la convergence en loi du *couple* (X_n, Y_n) et non celle de chaque composante.

Théorème 2.1: Théorème de continuité, convergence en probabilité

Soient $\{X_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires à valeurs dans $\mathbb{R}^d$ et X un vecteur aléatoire à valeurs dans $\mathbb{R}^d$, définis sur le même espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$. Soit $\varphi : \mathbb{R}^d \to \mathbb{R}^m$ une fonction continue en tout point d'un ensemble C tel que $\mathbb{P}(X \in C) = 1$. Si $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$, alors $\varphi(X_n) \overset{\mathbb{P}-\text{prob}}{\longrightarrow} \varphi(X)$. En particulier, si $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} c$ où c est une constante et si φ est continue au point c, alors $\varphi(X_n) \overset{\mathbb{P}-\text{prob}}{\longrightarrow} \varphi(c)$.

Démonstration

Soit $\varepsilon > 0$. Pour $\delta > 0$, soit B_δ l'ensemble des points x pour lesquels il existe y vérifiant $\|x - y\| \leq \delta$ et $\|\varphi(x) - \varphi(y)\| \geq \varepsilon$. Si $x \notin B_\delta$ et $\|\varphi(x_n) - \varphi(x)\| \geq \varepsilon$, alors $\|x_n - x\| > \delta$. On a donc

$$\mathbb{P}\left(\|\varphi(X_n) - \varphi(X)\| \geq \varepsilon\right) \leq \mathbb{P}\left(X \in B_\delta\right) + \mathbb{P}\left(\|X_n - X\| > \delta\right) \ .$$

Le second terme tend vers zéro puisque $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$. Par ailleurs $\mathbb{P}(X \in B_\delta \cap C^c) = 0$ et, la famille $(B_\delta)_{\delta>0}$ étant décroissante en δ et φ étant continue en tout point de C, $\lim_{\delta\to 0} \mathbb{P}(X \in B_\delta \cap C) = 0$. Le cas d'une limite constante s'obtient en prenant $X = c$ et $C = \{c\}$. □

Théorème 2.2: Convergence en probabilité et convergence en loi

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité, $\{X_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires et X un vecteur aléatoire définis sur $(\Omega, \mathcal{F}, \mathbb{P})$ et à valeurs dans $\mathbb{R}^d$. Alors

(i) $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$ entraîne $X_n \Longrightarrow X$;

(ii) si c est une constante, $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} c$ si et seulement si $X_n \Longrightarrow c$.

Démonstration

Pour *(i)*, soit f lipschitzienne bornée, de constante de Lipschitz L_f. Pour tout $\varepsilon > 0$,

$$|\mathbb{E}[f(X_n)] - \mathbb{E}[f(X)]| \leq \varepsilon L_f + 2\,\|f\|_\infty\, \mathbb{P}\left(\|X_n - X\| \geq \varepsilon\right) \ ,$$

en séparant selon que $\|X_n - X\|$ est inférieur ou supérieur à ε. Le second terme tend vers zéro et le premier est arbitrairement petit ; le théorème de Portmanteau 1.3 conclut. Pour *(ii)*, le sens direct découle de *(i)* ; la réciproque est la première remarque qui suit le lemme de Slutsky 1.1. □

La convergence presque sûre, $\mathbb{P}\left(\lim_n X_n = X\right) = 1$, entraîne la convergence en probabilité, donc la convergence en loi. Elle n'intervient pas dans ce chapitre, où les variables sont définies sur des espaces qui changent avec n ; elle apparaît dans la loi forte des grands nombres (Section 4.2).

Proposition 2.2: Convergence des moments et convergence en probabilité

Soient $\{X_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires et X un vecteur aléatoire à valeurs dans $\mathbb{R}^d$, définis sur $(\Omega, \mathcal{F}, \mathbb{P})$. S'il existe $p > 0$ tel que $\lim_{n\to\infty} \mathbb{E}\left[\|X_n - X\|^p\right] = 0$, alors $X_n \overset{\mathbb{P}-\text{prob}}{\longrightarrow} X$.

Démonstration

Par l'inégalité de Markov (Section 2.2), pour tout $\varepsilon > 0$,

$$\mathbb{P}\left(\|X_n - X\| > \varepsilon\right) \leq \frac{\mathbb{E}\left[\|X_n - X\|^p\right]}{\varepsilon^p} \xrightarrow[n\to\infty]{} 0 \ .$$

□

2.2 Inégalité de Bienaymé-Tchebychev et lemme de Bienaymé

Lemme 2.1: Inégalités de Markov et de Bienaymé-Tchebychev

Soit Y une variable aléatoire réelle positive définie sur $(\Omega, \mathcal{F}, \mathbb{P})$. Pour tout $a > 0$,

$$\mathbb{P}(Y \geq a) \leq \frac{\mathbb{E}[Y]}{a} .$$

En particulier, si W est une variable aléatoire réelle de carré intégrable, alors pour tout $\varepsilon > 0$,

$$\mathbb{P}\left(|W - \mathbb{E}[W]| \geq \varepsilon\right) \leq \frac{\mathrm{Var}(W)}{\varepsilon^2} .$$

Démonstration

La première inégalité résulte de $a\,\mathbb{1}_{\{Y \geq a\}} \leq Y$ et de la croissance de l'espérance. La seconde s'en déduit en l'appliquant à $Y := (W - \mathbb{E}[W])^2$ et $a := \varepsilon^2$. □

Définition 2.2: Variables décorrélées

Soient $X_1, \ldots, X_n$ des variables aléatoires réelles définies sur $(\Omega, \mathcal{F}, \mathbb{P})$ et de carré intégrable. Elles sont dites *décorrélées* si, pour tout $1 \leq k \neq \ell \leq n$,

$$\mathrm{Cov}(X_k, X_\ell) := \mathbb{E}\left[(X_k - \mathbb{E}[X_k])\,(X_\ell - \mathbb{E}[X_\ell])\right] = 0 .$$

Des variables indépendantes et de carré intégrable sont décorrélées ; la réciproque est fausse.

Lemme 2.2: Lemme de Bienaymé

Soient $X_1, \ldots, X_n$ des variables aléatoires réelles de carré intégrable et décorrélées, définies sur $(\Omega, \mathcal{F}, \mathbb{P})$. Alors

$$\mathrm{Var}\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} \mathrm{Var}(X_k) .$$

Démonstration

En développant le carré,

$$\mathrm{Var}\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} \mathbb{E}\left[(X_k - \mathbb{E}[X_k])^2\right] + \sum_{1 \leq k \neq \ell \leq n} \mathbb{E}\left[(X_k - \mathbb{E}[X_k])\,(X_\ell - \mathbb{E}[X_\ell])\right] ,$$

et la seconde somme est nulle par décorrélation. □

2.3 Deux lemmes pour la preuve du théorème de la limite centrale

Lemme 2.3: Développement d'une fonction caractéristique à l'ordre deux

Soit Y une variable aléatoire réelle de carré intégrable, de fonction caractéristique $\psi : u \mapsto \mathbb{E}[\mathrm{e}^{\mathrm{i}uY}]$. Alors ψ est deux fois dérivable sur $\mathbb{R}$, de dérivées

$$\psi'(u) = \mathrm{i}\,\mathbb{E}\left[Y \mathrm{e}^{\mathrm{i}uY}\right] , \qquad \psi''(u) = -\mathbb{E}\left[Y^2 \mathrm{e}^{\mathrm{i}uY}\right] ,$$

la seconde étant continue, et

$$\psi(u) = 1 + \mathrm{i}u\,\mathbb{E}[Y] - \frac{u^2}{2}\mathbb{E}\left[Y^2\right] + o(u^2)\,, \qquad u \to 0\,.$$

Démonstration

Pour $u, h \in \mathbb{R}$ avec $h \neq 0$,

$$\frac{\psi(u+h) - \psi(u)}{h} = \mathbb{E}\left[\mathrm{e}^{\mathrm{i}uY}\,\frac{\mathrm{e}^{\mathrm{i}hY} - 1}{h}\right]\,,$$

et $\left|\left(\mathrm{e}^{\mathrm{i}hY} - 1\right)/h\right| \leq |Y|$ puisque $|\mathrm{e}^{\mathrm{i}v} - 1| \leq |v|$ pour tout v réel. Comme Y est intégrable, le théorème de convergence dominée s'applique et donne $\psi'(u) = \mathrm{i}\mathbb{E}[Y\mathrm{e}^{\mathrm{i}uY}]$. Le même argument, appliqué à $u \mapsto \mathbb{E}[Y\mathrm{e}^{\mathrm{i}uY}]$ avec la domination $|Y| \cdot |Y| = Y^2$, intégrable par hypothèse, donne $\psi''(u) = -\mathbb{E}[Y^2\mathrm{e}^{\mathrm{i}uY}]$. La continuité de ψ'' résulte encore de la convergence dominée, avec la même domination. La formule de Taylor-Young appliquée en 0 à la fonction ψ, deux fois dérivable, donne

$$\psi(u) = \psi(0) + u\psi'(0) + \frac{u^2}{2}\psi''(0) + o(u^2)\,,$$

et $\psi(0) = 1$, $\psi'(0) = \mathrm{i}\mathbb{E}[Y]$, $\psi''(0) = -\mathbb{E}[Y^2]$. □

Lemme 2.4: Puissances n-ièmes

Soit $\{a_n,\ n \in \mathbb{N}\}$ une suite de nombres complexes telle que $na_n \to c \in \mathbb{C}$. Alors $(1+a_n)^n \to \mathrm{e}^c$.

Démonstration

Comme $na_n \to c$, on a $a_n \to 0$, donc $|a_n| \leq 1/2$ pour n assez grand ; sur le disque $\{z \in \mathbb{C} : |z| \leq 1/2\}$, le logarithme complexe principal est défini et vérifie $\mathrm{Log}(1+z) = z + r(z)$ avec $|r(z)| \leq |z|^2$. Pour n assez grand,

$$n\,\mathrm{Log}(1+a_n) = na_n + n\,r(a_n)\,, \qquad |n\,r(a_n)| \leq n|a_n|^2 = \frac{(n|a_n|)^2}{n} \xrightarrow[n\to\infty]{} 0\,,$$

puisque $n|a_n| \to |c|$. Donc $n\,\mathrm{Log}(1+a_n) \to c$, et en composant par l'exponentielle, qui est continue, $(1+a_n)^n = \exp\left(n\,\mathrm{Log}(1+a_n)\right) \to \mathrm{e}^c$. □

Dans la preuve du théorème de la limite centrale, ce lemme est appliqué à $a_n := \psi(t/\sqrt{n}) - 1 = -t^2/(2n) + o(n^{-1})$, pour lequel $na_n \to -t^2/2$.

2.4 Le procédé de Cramér-Wold

La convergence en loi d'une suite de vecteurs aléatoires se ramène à celle de toutes ses combinaisons linéaires, ce qui permet de démontrer un énoncé vectoriel en ne traitant que le cas réel.

Théorème 2.3: Procédé de Cramér-Wold

Soit $\{(\Upsilon_n, \mathcal{Y}_n, \mathbb{P}_n) : n \in \mathbb{N}\}$ une suite d'espaces de probabilité, $\{Y_n,\ n \in \mathbb{N}\}$ une suite de vecteurs aléatoires à valeurs dans $\mathbb{R}^d$ et Y un vecteur aléatoire à valeurs dans $\mathbb{R}^d$. Alors

$$Y_n \overset{\mathbb{P}_n}{\Longrightarrow} Y \qquad \text{si et seulement si} \qquad t^\top Y_n \overset{\mathbb{P}_n}{\Longrightarrow} t^\top Y \quad \text{pour tout } t \in \mathbb{R}^d\,.$$

Démonstration

La fonction caractéristique d'un vecteur aléatoire Y évaluée en $t \in \mathbb{R}^d$ est la fonction caractéristique de la variable réelle $t^\top Y$ évaluée au point 1. Si $Y_n \overset{\mathbb{P}_n}{\Longrightarrow} Y$, alors pour tous $t \in \mathbb{R}^d$ et $u \in \mathbb{R}$, $\mathbb{E}_n[\mathrm{e}^{\mathrm{i}ut^\top Y_n}] \to \mathbb{E}[\mathrm{e}^{\mathrm{i}ut^\top Y}]$, et le théorème de Lévy 1.5 appliqué en dimension un donne $t^\top Y_n \overset{\mathbb{P}_n}{\Longrightarrow} t^\top Y$. Réciproquement, si $t^\top Y_n \overset{\mathbb{P}_n}{\Longrightarrow} t^\top Y$ pour tout $t \in \mathbb{R}^d$, alors en prenant $u = 1$ il vient $\mathbb{E}_n[\mathrm{e}^{\mathrm{i}t^\top Y_n}] \to \mathbb{E}[\mathrm{e}^{\mathrm{i}t^\top Y}]$ pour tout t, et le théorème de Lévy 1.5, cette fois en dimension d, conclut. □

Intuition. *Appliqué au théorème de la limite centrale, le procédé fait exactement ce que l'on attend : il suffit de montrer que, pour tout t, la variable réelle $t^\top\sqrt{n}(\bar{X}_n - \mu)$ converge vers une loi $\mathcal{N}(0, t^\top\Sigma t)$, ce qui est le cas scalaire appliqué aux variables réelles $t^\top X_k$, dont la variance est $t^\top\Sigma t$. Le cas $t^\top\Sigma t = 0$ est le seul à traiter à part : la variable est alors nulle presque sûrement, et sa limite est la loi de Dirac en 0, qui est bien la loi $\mathcal{N}(0,0)$.*

2.5 Différentiabilité et matrice jacobienne

Soit g une fonction d'un ouvert de $\mathbb{R}^p$ à valeurs dans $\mathbb{R}^m$. Une telle fonction est définie par ses m fonctions composantes à valeurs réelles :

$$g : \begin{pmatrix} y_1 \\ \vdots \\ y_p \end{pmatrix} \longmapsto \begin{pmatrix} g_1(y_1, \ldots, y_p) \\ \vdots \\ g_m(y_1, \ldots, y_p) \end{pmatrix} .$$

Définition 2.3: Matrice jacobienne

Les dérivées partielles de ces fonctions en un point $\mathbf{y}$, si elles existent, se rangent dans une matrice à m lignes et p colonnes, appelée *matrice jacobienne* de g au point $\mathbf{y}$:

$$\mathrm{J}_g(\mathbf{y}) = \begin{pmatrix} \dfrac{\partial g_1}{\partial y_1} & \cdots & \dfrac{\partial g_1}{\partial y_p} \\ \vdots & \ddots & \vdots \\ \dfrac{\partial g_m}{\partial y_1} & \cdots & \dfrac{\partial g_m}{\partial y_p} \end{pmatrix} .$$

Définition 2.4: Fonction différentiable

La fonction $g : \mathbb{R}^p \to \mathbb{R}^m$ est *différentiable* au point $\mathbf{y}$ si

$$g(\mathbf{y} + \mathbf{h}) = g(\mathbf{y}) + \mathrm{J}_g(\mathbf{y})\,\mathbf{h} + \varepsilon(\mathbf{h}) \qquad \text{avec} \qquad \|\varepsilon(\mathbf{h})\| = o\left(\|\mathbf{h}\|\right) .$$

Si g admet des dérivées partielles continues par rapport à toutes les variables, alors g est différentiable ; la réciproque est fausse. En dimension $p = m = 1$, la différentiabilité au point θ est la dérivabilité, et la matrice jacobienne se réduit à $\dot{g}(\theta)$.

2.6 Les résultats admis

Quatre énoncés de ce chapitre sont utilisés sans être démontrés. Leurs démonstrations figurent dans le polycopié d'origine, dont la numérotation est rappelée ici.

— Le théorème de Portmanteau 1.3 (théorème IV-5.26).

— Le théorème de Lévy 1.5, dans le sens réciproque (théorème IV-5.36).

— Le théorème de transformation continue 1.4, dans le cas où φ n'est continue que sur un ensemble de mesure 1 (théorème IV-5.30) ; le cas d'une fonction continue partout est démontré.

— La construction du produit infini d'expériences statistiques (proposition 1.1), qui repose sur le théorème d'extension de Carathéodory.

À quoi s'ajoutent la loi faible des grands nombres pour des variables indépendantes de même loi seulement intégrables et la loi forte des grands nombres, rappelées dans les compléments (Section 4.2), et le théorème de Berry-Esseen (Section 4.3).