Exercice 1 ((*) puis (***)). *L'objectif de ce problème est de comparer la performance de deux statistiques de test pour un même test d'hypothèses. Si nous avons deux tests ϕ_n, $\phi_n^\star$ de fonctions puissance respectives β_n et $\beta_n^\star$, nous dirons que $\phi_n^\star$ est uniformément le plus puissant au niveau α si $\sup_{\theta\in\Theta_0}\beta_n^\star(\theta)\le\alpha$ et pour tout test ϕ_n de niveau α, $\beta_n^\star(\theta)\ge\beta_n(\theta)$ pour $\theta\in\Theta_1$. Ces conditions sont difficiles à vérifier en pratique ; on décide donc d'établir la comparaison sur les fonctions puissance asymptotiques.*

Soit Θ un ouvert de $\mathbb{R}$, et $\{\mathbb{Q}_\theta = q_\theta\cdot \mathrm{d}\nu, \theta\in\Theta\}$ une famille de lois sur $\mathsf{X}\in\mathcal{B}(\mathbb{R})$ muni de sa tribu borélienne $\mathcal{X}$. On suppose que ce modèle est régulier (voir Polycopié Définition I-4.16). Soit $\theta_0\in\Theta$. On souhaite tester

$$H_0:\theta=\theta_0,\qquad H_1:\theta>\theta_0$$

On dispose d'une suite de n-échantillons du modèle $(\mathsf{X},\mathcal{X},\{\mathbb{Q}_\theta,\theta\in\Theta\})$. On note

$$\mathbb{P}_{n,\theta}:=\mathbb{Q}_\theta^{\otimes n},\qquad \bar X_n:=\frac1n\sum_{k=1}^n X_k,\qquad S_n^2:=\frac1n\sum_{k=1}^n(X_k-\bar X_n)^2.$$

1. Dans cette question, le modèle statistique est un modèle de translation : soit $q\cdot\mathrm{dLeb}$ une loi sur $\mathbb{R}$, on considère la famille de densités $q_\theta: x\mapsto q(x-\theta)$. On suppose de plus la densité q symétrique par rapport à l'origine, continue et telle que $q(0)>0$ [1] et de variance σ_q^2 inconnue. On définit les statistiques

$$M_n:=\sqrt{n}\left(\frac1n\sum_{k=1}^n\mathbb{1}_{\{X_k\ge\theta_0\}}-\frac12\right),\qquad T_n:=\sqrt{n}\frac{(\bar X_n-\theta_0)}{S_n}.$$

   (a) Montrer que l'on peut choisir une suite $\{t_n,\ n\in\mathbb{N}\}$ de telle sorte que la suite de tests $\phi_{n,1}:=\mathbb{1}_{\{M_n\ge t_n\}}$ soit de niveau asymptotique α et soit consistante.

   (b) Construire une suite de tests $\{\phi_{n,2},n\in\mathbb{N}\}$ basée sur la statistique de test T_n de niveau asymptotique α et consistante.

L'exemple précédent montre que pour comparer des tests, la consistance du test ne suffit pas. Nous considérons ci-dessous l'approche de Pitman, qui consiste à comparer la puissance locale des tests : étudier la suite $\{\beta_n(\theta_n),n\in\mathbb{N}\}$ où

$$\theta_n>\theta_0,\qquad \theta_n=\theta_0+h_n/\sqrt{n}\quad\text{avec}\quad\lim_n h_n=h>0\,. \tag{1}$$

Soit $\{U_n,\ n\in\mathbb{N}\}$ une suite de statistiques. Nous supposons qu'il existe une fonction $\mu:\Theta\to\mathbb{R}$ et $\sigma>0$ tels que [2]

$$\sqrt{n}\ (U_n-\mu(\theta_n))\overset{\mathbb{P}_{n,\theta_n}}{\Longrightarrow}\mathrm{N}(0,\sigma^2);\qquad \sqrt{n}\ (U_n-\mu(\theta_0))\overset{\mathbb{P}_{n,\theta_0}}{\Longrightarrow}\mathrm{N}(0,\sigma^2). \tag{2}$$

Nous supposons que μ est dérivable en θ_0 de dérivée $\mu'(\theta_0)$ strictement positive. Pour tout $n>0$, nous considérons le test sur $(\mathsf{X}^n,\mathcal{X}^{\otimes n},\{\mathbb{P}_{n,\theta},\theta\in\Theta\})$ de zone de rejet

$$\mathcal{R}_n:=\{\sqrt{n}\ (U_n-\mu(\theta_0))>C_n z_{1-\alpha}\}$$

1. ces conditions entrainent que la médiane est unique et vaut zero, et que la fonction de répartition F est strictement croissante dans un voisinage de 0.

2. pour toute fonction continue et bornée f, on a

$$\lim_n\mathbb{E}_{n,\theta_n}\left[f\left(\sqrt{n}\,(U_n-\mu(\theta_n))\right)\right]=\int f(x)\frac{1}{\sigma\sqrt{2\pi}}\exp(-0.5\sigma^{-2}\,x^2)\mathrm{d}x.$$

où $z_{1-\alpha}$ est le quantile d'ordre $1-\alpha$ d'une loi $\mathrm{N}(0,1)$ et $\{C_n,\ n \in \mathbb{N}\}$ est une suite de statistiques telle que

$$\forall \varepsilon > 0, \qquad \lim_n \mathbb{P}_{n,\theta_0}\left(|C_n - \sigma| > \varepsilon\right) = 0. \tag{3}$$

2. Montrer que $\lim_n \mathbb{P}_{n,\theta_0}(\mathcal{R}_n) = \alpha$.
3. L'objectif de cette question est de montrer que pour toute suite déterministe $\{\theta_n, n \geq 0\}$ de Θ_1 telle que $\lim_n \sqrt{n}(\theta_n - \theta_0) = h$, on a

$$\lim_n \mathbb{P}_{n,\theta_n}\left(|C_n - \sigma| > \varepsilon\right) = 0.$$

   (a) Montrer que pour toute suite positive $\{\delta_n, n \geq 0\}$ telle que $\lim_n \delta_n = 0$,

$$\lim_n \frac{1}{n}\mathbb{E}_{n,\theta_0}\left[\sup_{0\leq t\leq \delta_n}\left|\sum_{k=1}^n \partial_\theta^2 \log q_{\theta_0+t}(X_k) - \sum_{k=1}^n \partial_\theta^2 \log q_{\theta_0}(X_k)\right|\right] = 0.$$

   (b) En utilisant la question précédente, montrer que

$$\prod_{k=1}^n \frac{q_{\theta_n}(X_k)}{q_{\theta_0}(X_k)} \overset{\mathbb{P}_{n,\theta_0}}{\Longrightarrow} \exp(h\,\mathrm{N}(0, I(\theta_0)) - \frac{h^2}{2} I(\theta_0))$$

   où $I(\theta_0)$ est l'information de Fisher associée à la loi $q_{\theta_0}\cdot \mathrm{d}\nu$. *On observera que l'espérance de la loi limite est* 1.
   (c) En déduire que pour tout $A_n \in \mathcal{X}^{\otimes n}$, $\lim_n \mathbb{P}_{n,\theta_0}(A_n) = 0$ entraine $\lim_n \mathbb{P}_{n,\theta_n}(A_n) = 0$. *On dit que la famille de loi* $\{\mathbb{P}_{n,\theta_n}, n \geq 1\}$ *est* **contiguë** *à la famille* $\{\mathbb{P}_{n,\theta_0}, n \geq 1\}$.
   (d) Conclure.
4. Montrer que

$$\lim_n \mathbb{P}_{n,\theta_n}\left(\mathcal{R}_n\right) = 1 - \Phi\left(z_{1-\alpha} - h\frac{\mu'(\theta_0)}{\sigma}\right)$$

   Ce résultat caractérise le comportement de la fonction puissance à droite de θ_0. *Un test sera d'autant meilleur que* $\mu'(\theta_0)/\sigma$ *est grand, la puissance asymptotique locale augmentant plus rapidement avec* h.
5. Nous terminons par un jeu de conditions suffisantes pour vérifier la condition (2) dans le cas où

$$U_n := \frac{1}{n}\sum_{k=1}^n g(X_k), \qquad \mu(\theta) := \int g(x) q_\theta(x)\ \mathrm{d}\nu(x)$$

   sous les conditions que
   (a) $\sigma_g^2(\theta) := \int (g(x) - \mu(\theta))^2\, q_\theta(x)\mathrm{d}\nu(x)$ existe dans un voisinage de θ_0 et est continue en θ_0 ;
   (b) il existe $\delta > 0$ tel que $D_g(\theta) := \int (g(x) - \mu(\theta))^{2+\delta}\, q_\theta(x)\mathrm{d}\nu(x)$ existe dans un voisinage de θ_0 et est continue en θ_0.

   En appliquant les conditions de Lindeberg-Feller (voir Polycopié, Théorème IV.5-41), montrer que la condition (2) est vérifiée avec $\sigma^2 = \sigma_g^2(\theta_0)$.
6. Appliquons ce résultat à l'exemple du test sur le paramètre de translation (voir question 1) ; en supposant que la loi $q\,\mathrm{d}\nu$ possède un moment d'ordre $2+\delta$ pour $\delta > 0$.

(a) Pour le test $\phi_{n,1}$, quelle est la pente $\mu'(\theta_0)/\sigma$?

(b) Pour le test $\phi_{n,2}$, quelle est la pente $\mu'(\theta_0)/\sigma$?

Dans le cas où $\theta_0 = 0$, le ratio des pentes (test $\phi_{n,1}$ divisé par test $\phi_{n,2}$) donne

Gaussienne $\sqrt{2/\pi} \approx 0.798$

(c) Que donne-t-il lorsque $q = \frac{1}{2}\mathrm{N}(-a, \tau^2) + \frac{1}{2}\mathrm{N}(a, \tau^2)$ pour $a, \tau > 0$. Quel test est préférable ? Voir figure 1.

(d) Que donne-t-il lorsque $q = \frac{1}{2}\mathrm{N}(0, 1) + \frac{1}{2}\mathrm{N}(0, \tau^2)$ pour $\tau > 0$. Quel test est préférable ? Voir figure 2.

Une autre conséquence du résultat de la question 4 est de donner un ordre de grandeur de la taille de l'échantillon nécessaire pour atteindre une puissance $\beta > \alpha$ donnée en un point $\theta \in \Theta_1$. On peut montrer[3] que si $N_i(\theta)$ est la taille de l'échantillon nécessaire pour que le test i ait une puissance d'au moins β contre $\theta \in \Theta_1$, alors

$$\lim_{\theta \downarrow \theta_0} \frac{N_1(\theta)}{N_2(\theta)} = \left(\frac{\sigma_1 \ \mu_2'(\theta_0)}{\sigma_2 \ \mu_1'(\theta_0)} \right)^2 .$$

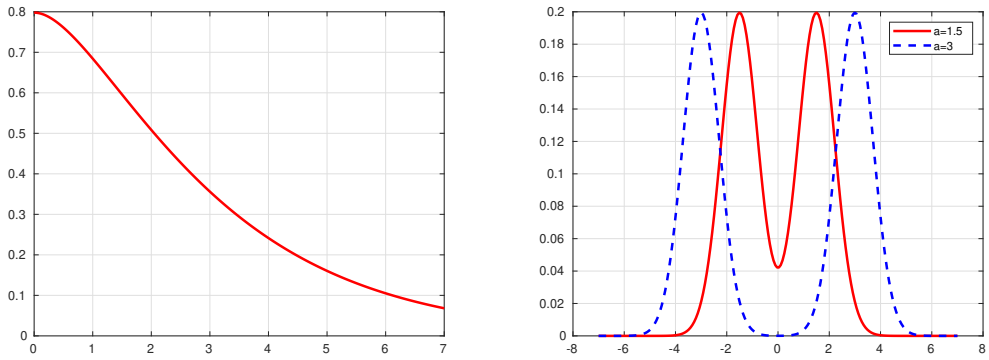


FIGURE 1 – Exercice 1. Cas du mélange de gaussienne avec $a > 0$, et $\tau = 1$. A gauche, l'évolution du ratio des pentes en fonction de $u := a^2/\tau^2$; à droite, deux exemples de densité pour des valeurs de a différentes ($a = 1.5$ et $a = 3$) et $\tau^2 = 1$.

Exercice 2 ((*)). Pour $(a, b) \in \mathbb{R}_+^* \times \mathbb{R}_+^*$, on appelle $\Gamma(a, b)$ la loi de densité par rapport à la mesure de Lebesgue donnée par

$$x \mapsto \frac{1}{\Gamma(a)} b^a x^{a-1} \mathrm{e}^{-bx} \mathbb{1}_{\mathbb{R}_+^*}(x) .$$

On rappelle que l'espérance d'une loi $\Gamma(a, b)$ est a/b et que sa variance est a/b^2. Enfin, si $X \sim \Gamma(a, b)$, $Y \sim \Gamma(a', b)$ et X, Y sont indépendantes, alors $X + Y \sim \Gamma(a + a', b)$.

Soit une suite de n-échantillons du modèle $\left(\mathbb{R}, \mathcal{B}(\mathbb{R}), \left\{\Gamma(2, \theta) \ : \ \theta \in \mathbb{R}_+^*\right\}\right)$.

1. Calculer l'estimateur du maximum de vraisemblance du paramètre θ.

3. voir par exemple Chapitre 13, E.L. Lehmann and J.P. Romano, *Testing Statistical Hypotheses*

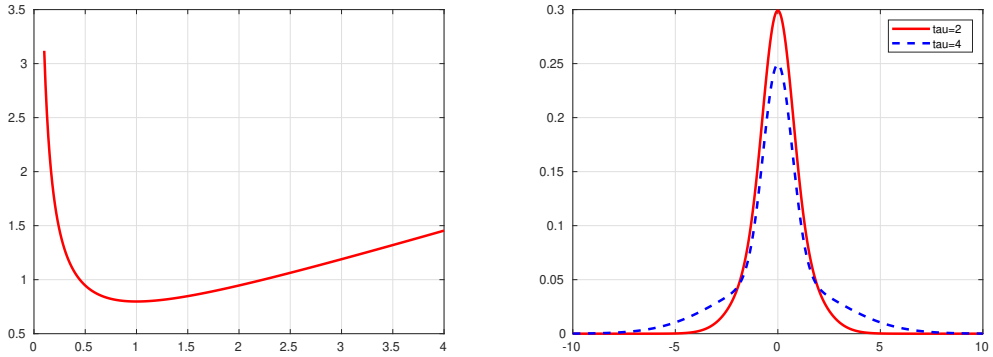


FIGURE 2 – Exercice 1. Cas du mélange de gaussiennes centrées et de variances différentes. A gauche, l'évolution du ratio des pentes en fonction de τ ; à droite deux exemples de densité pour des valeurs de τ différentes ($\tau^2 = 4$ et $\tau^2 = 16$).

2. Calculer le biais et le risque quadratique de l'estimateur du maximum de vraisemblance.
3. Montrer que l'estimateur du maximum de vraisemblance est consistant.
4. Prouver la normalité asymptotique de l'estimateur du maximum de vraisemblance.
5. Donner un intervalle de confiance asymptotique de niveau $(1-\alpha)$ pour le paramètre θ.

Exercice 3 ((*)). Une variable aléatoire X à valeurs dans $\mathbb{R}_+^*$ suit une loi log-normale de paramètre $(\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}_+^*$ si la variable $Y = \log(X)$ est normale de moyenne μ et variance σ^2. Cette distribution est très couramment utilisée pour modéliser le prix des actifs financiers (c'est la base du modèle très couramment utilisé de Black-Scholes-Merton ; voir PC1).

Soit une suite de n-échantillons de la famille de loi log-normale de paramètre $(\theta, \theta), \theta \in \Theta := \mathbb{R}_*^+$.

1. Déterminer l'estimateur du maximum de vraisemblance de θ.
2. Prouver la normalité asymptotique de l'estimateur du maximum de vraisemblance.
3. Construire un intervalle de confiance de probabilité de couverture asymptotique $1-\alpha$.

Exercice 4 ((*)). Soit une suite de n-échantillons du modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathrm{N}(\theta, 1) \,:\, \theta \in \Theta := \mathbb{R}_+\})$. *Attention, l'originalité de cet exercice est de contraindre le paramètre à être strictement positif.*

1. Déterminer l'estimateur du maximum de vraisemblance $\hat{\theta}_n^{\mathrm{MV}}$.
2. Montrer que pour tout $\theta > 0$,

$$\sqrt{n}(\hat{\theta}_n^{\mathrm{MV}} - \theta) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathrm{N}(0,1).$$

3. Déterminer la loi limite lorsque $\theta = 0$.

Exercice 5 ((***)). Soit f une densité par rapport à la mesure de Lebesgue sur $\mathbb{R}$ telle que $f(x) = f(-x)$ pour tout $x \in \mathbb{R}$. Pour $\theta \in \mathbb{R}$ et $x \in \mathbb{R}$, nous notons $q_\theta(x) := f(x-\theta)$. Soit

H1 $\gamma : \mathbb{R} \to \mathbb{R}$ une fonction impaire, croissante (au sens large) et telle que

$$\lim_{x\to-\infty} \gamma(x) < 0, \quad \lim_{x\to+\infty} \gamma(x) > 0, \tag{4}$$
$$\int_{\mathbb{R}} |\gamma(x-\theta)| f(x) \mathrm{Leb}(\mathrm{d}x) < +\infty \ , \quad \text{pour tout } \theta \in \mathbb{R} \ .$$

Considérons une suite de n-échantillons du modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{\mathbb{Q}_\theta = q_\theta \cdot \mathrm{Leb} \ : \ \theta \in \mathbb{R}\})$. Nous étudions les Z-estimateurs associés à

$$\psi(\theta, x) = \gamma(x-\theta) \ .$$

Soit une suite de fonctions aléatoires $\{\Psi_n, n \geq 1\}$ définies sur Θ, par :

$$\theta \mapsto \Psi_n(\theta) := \frac{1}{n}\sum_{k=1}^{n} \gamma(X_k - \theta) = -\frac{1}{n}\sum_{k=1}^{n} \gamma(\theta - X_k).$$

La figure 3 montre la fonction Ψ_n pour différentes valeurs de n, dans le cas où γ est égale à $\gamma_0 = \mathrm{signe}(x)$ (gauche), $\gamma_\infty(x) = x$ (centre) et $\gamma_1(x) = \mathrm{signe}(x)\,(|x| \wedge 1)$ (droite), et f est une densité gaussienne centrée réduite ; en trait épais, on trace aussi la fonction Ψ_{θ_0} (pour $\theta_0 = 2$) où

$$\theta \mapsto \Psi_{\theta_0}(\theta) := \mathbb{Q}_{\theta_0}\left(\gamma(\cdot - \theta)\right) = \int \gamma(x-\theta)\, q_{\theta_0}(x)\ \mathrm{Leb}(\mathrm{d}x)$$
$$= \int \gamma(x-\theta) f(x-\theta_0) \mathrm{Leb}(\mathrm{d}x) = \int \gamma(x+\theta_0-\theta) f(x) \mathrm{Leb}(\mathrm{d}x) \ .$$

Noter que la condition **H1** justifie l'existence de Ψ_θ pour tout θ.

1. Montrer que pour tout $n \geq 1$, tout $\theta_0 \in \mathbb{R}$,

$$\mathbb{P}_{n,\theta_0}\left(\exists \hat{\theta}_n \text{ tq } \ \Psi_n \geq 0 \text{ sur } \left]-\infty, \hat{\theta}_n\right[\text{ et } \Psi_n \leq 0 \text{ sur } \left]\hat{\theta}_n, +\infty\right[\right) = 1 \ .$$

   (a) Montrer que si γ est continue, il existe $\hat{\theta}_n$ tel que $\Psi_n(\hat{\theta}_n) = 0$.
   (b) Montrer que si γ est strictement croissante et continue, alors $\hat{\theta}_n$ est unique.
   (c) Etudier les cas où γ est une des fonctions suivantes :

$$\gamma_0(x) = \mathrm{signe}(x), \qquad \gamma_\infty(x) = x, \qquad \gamma_k(x) = \begin{cases} x & |x| \leq k \\ k\ \mathrm{signe}(x) & |x| > k \end{cases} \ . \tag{5}$$

Dans la suite, on fait l'hypothèse suivante.

H2 Il existe $\delta > 0$ telle que la fonction $\theta \mapsto \Psi_0(\theta) = \int \gamma(x-\theta) f(x) \mathrm{dLeb}(x)$ soit strictement monotone sur $[-\delta, \delta]$.

2. Montrer que pour tout $\theta_0 \in \mathbb{R}$, θ_0 est l'unique solution de l'équation $\Psi_{\theta_0}(\theta) = 0$.
3. Soit $\theta_0 \in \mathbb{R}$ et $\varepsilon \in \,]0, \delta[$. Montrer que sous $\mathbb{P}_{n,\theta_0}$,

$$\hat{\theta}_n < \theta_0 - \varepsilon \implies \Psi_n(\theta_0 - \varepsilon) \leqslant 0.$$

   En déduire que

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta_0}(\hat{\theta}_n < \theta_0 - \varepsilon) = 0 \ .$$

4. Montrer que $\{\hat{\theta}_n,\ n \in \mathbb{N}\}$ est une suite consistante d'estimateurs de θ.

On fait maintenant l'hypothèse supplémentaire suivante.

H3 γ est C^1 et

$$\int \gamma^2(x) f(x) \mathrm{Leb}(\mathrm{d}x) < \infty, \qquad \int \gamma'(x) f(x) \mathrm{Leb}(\mathrm{d}x) > 0, \tag{6}$$

$$\forall \delta > 0, \quad \int \sup_{|y-x| \le \delta} |\gamma'(y)| f(x) \mathrm{Leb}(\mathrm{d}x) < \infty\ . \tag{7}$$

5. Montrer que la suite d'estimateurs $\{\hat{\theta}_n,\ n \in \mathbb{N}\}$ est asymptotiquement normale et déterminer sa distribution asymptotique. Dans la suite, on notera $V[\gamma]$ la variance limite. *Pour la normalité asymptotique, on peut juste supposer que γ est "continue, C^1 par morceaux, et vérifie* (6)-(7)*".*

On compare l'efficacité relative des estimateurs $\{\hat{\theta}_n,\ n \in \mathbb{N}\}$ obtenus avec $\gamma = \gamma_\infty$ d'une part, et $\gamma = \gamma_k$ pour $k > 0$ d'autre part (voir Eq. 5).

6. On considère tout d'abord le cas où f est la densité de la loi $\mathrm{N}(0, \sigma^2)$. Comparer l'efficacité relative en fonction de k : sur la figure 4(gauche), on représente la variance asymptotique $V[\gamma_k]$ en fonction de k - on a pris $\sigma^2 = 1$.

7. Déterminer la variance asymptotique dans le cas où

$$f(x) = (1-\varepsilon)\phi(x) + \varepsilon \tau^{-1} \phi(\tau^{-1} x)\ ,$$

ϕ est la densité d'une Gaussienne centrée réduite (observer que dans ce cas, $\tau^{-1}\phi(\tau^{-1}x)$ est une Gaussience centrée de variance τ^2). Sur la figure 4(droite), on représente la variance asymptotique $V[\gamma_k]$ en fonction de k - on a pris $\varepsilon = 0.01$ et $\tau = 10$.
Ce type de modèles est utilisé en statistiques robustes pour modéliser la présence de données aberrantes : ε est la probabilité de contamination, qui est en général très petite et τ est l'écart-type des données "contaminées" que l'on prend très grande. Commenter l'intérêt de prendre la fonction γ_k, $(k < \infty)$ plutôt que γ_∞.

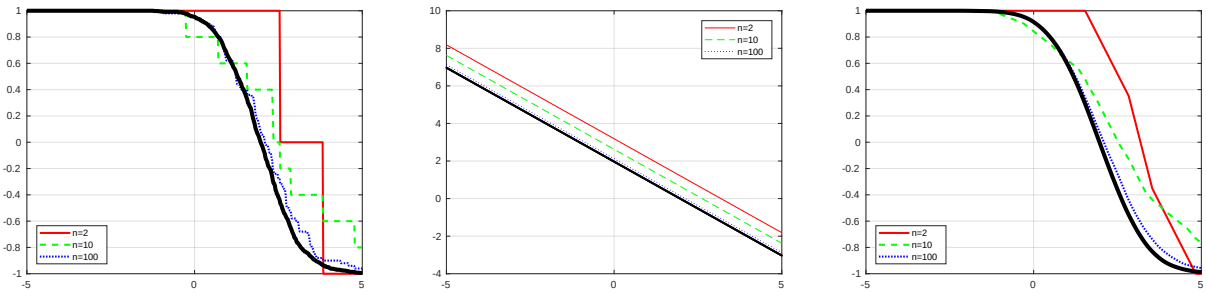


FIGURE 3 – Exercice 5. (gauche) cas γ_0, (centre) cas γ_∞, (droite) cas γ_k avec $k = 1$. Pour chacun des cas, on trace $\theta \mapsto \Psi_n(\theta)$ pour $n = 2, 10, 100$ et on trace $\theta \mapsto \Psi_{\theta_0}(\theta)$ en trait épais. On a pris $f \equiv \mathrm{N}(0,1)$ et $\theta_0 = 2$.

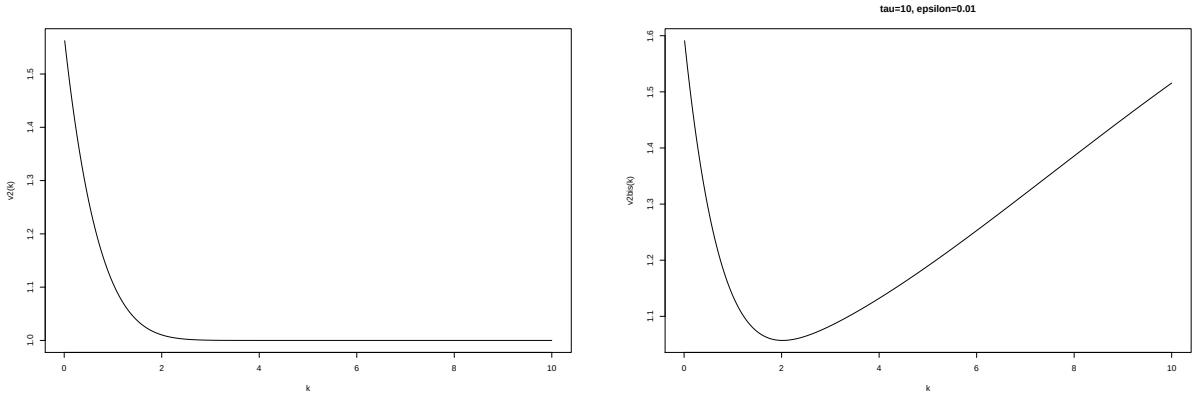


FIGURE 4 – Exercice 5. [gauche] : pas de contamination (cas $\sigma^2 = 1$). [droite] : $\varepsilon = 0.01$ et $\tau = 10$