4 Les compléments

Les contenus de cette partie ne sont pas exigibles. Ils donnent la définition générale des M- et Z-estimateurs, qui couvre les solutions approchées du problème d'optimisation, la consistance sans hypothèse de compacité, les énoncés de consistance de l'estimateur du maximum de vraisemblance, les lois limites dans le cas vectoriel, les régions de confiance que la normalité asymptotique de cet estimateur permet de construire, l'énoncé de l'efficacité asymptotique et la conjecture de Fisher, la méthode du score de Fisher, et les calculs détaillés du modèle de Cauchy.

4.1 Solutions approchées du problème d'optimisation

En pratique, le maximum de $\widehat{M}_n$ est atteint par une méthode numérique, qui ne fournit qu'une solution approchée dont on sait borner l'erreur. La définition suivante, celle du polycopié d'origine, couvre cette situation, et le théorème 1.1 vaut sous la même forme.

Théorème 4.1: Consistance des M-estimateurs, version approchée

Reprenons les notations du théorème 1.1 et remplaçons l'hypothèse (H-3) par la suivante : il existe une suite de variables aléatoires positives $\{\rho_n,\ n \in \mathbb{N}\}$ et une suite de variables aléatoires $\{\hat{\theta}_n, n \in \mathbb{N}\}$ à valeurs dans Θ telles que, pour tout $\theta^\star \in \Theta$,

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta^\star}\left(\rho_n \geq \varepsilon\right) = 0 \quad \text{pour tout } \varepsilon > 0\ , \qquad \liminf_{n\to\infty} \mathbb{P}_{n,\theta^\star}\left(\widehat{M}_n(\hat{\theta}_n) \geq \widehat{M}_n(\theta^\star) - \rho_n\right) = 1\ .$$

Sous les hypothèses (H-1), (H-2) et cette hypothèse, la suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est consistante.

Démonstration

La seule modification de la démonstration du théorème 1.1 porte sur la majoration du terme $(b) = \widehat{M}_n(\theta^\star) - \widehat{M}_n(\hat{\theta}_n)$, qui n'est plus négatif :

$$\widehat{M}_n(\theta^\star) - \widehat{M}_n(\hat{\theta}_n) \leq \rho_n + \left\{\widehat{M}_n(\theta^\star) - \widehat{M}_n(\hat{\theta}_n) - \rho_n\right\} \mathbb{1}_{\{\widehat{M}_n(\theta^\star)-\rho_n > \widehat{M}_n(\hat{\theta}_n)\}}\ .$$

Le premier terme tend vers zéro en probabilité par hypothèse, et le second est nul sur un événement de probabilité tendant vers 1. Le reste de la démonstration est inchangé. □

De même, la définition d'un Z-estimateur se relâche en remplaçant la condition $\widehat{\Psi}_n(\hat{\theta}_n) = 0$ par

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta^\star}\left(\left\|\widehat{\Psi}_n(\hat{\theta}_n)\right\| \geq \varepsilon\right) = 0 \qquad \text{pour tout } \varepsilon > 0\ ,$$

et le théorème 1.3 vaut sous cette forme.

4.2 Consistance sans hypothèse de compacité

L'hypothèse de compacité du corollaire 1.1 est souvent contraignante. On peut s'en passer lorsque la fonction objectif décroît vers $-\infty$ assez vite à l'infini, ce qui confine l'estimateur dans un compact avec une probabilité tendant vers 1.

Théorème 4.2: Consistance d'un M-estimateur, cas non compact

Soit une suite d'expériences statistiques produit d'espace des paramètres $\Theta = \mathbb{R}^d$. Supposons :

(i) pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto m(\theta, x)$ est continue sur $\mathbb{R}^d$;

(ii) pour tout compact $K \subseteq \mathbb{R}^d$ et tout $\theta^\star \in \mathbb{R}^d$, $\displaystyle\int \sup_{\theta \in K} |m(\theta, x)| \, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$;

(iii) pour tous $\theta \neq \theta^\star$ dans $\mathbb{R}^d$, $\mathsf{M}_{\theta^\star}(\theta) < \mathsf{M}_{\theta^\star}(\theta^\star)$;

(iv) pour tout $\theta^\star \in \mathbb{R}^d$, il existe $a > 0$ tel que $\displaystyle\int \sup_{\|\theta\| \geq a} |m(\theta, x)| \, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$;

(v) pour tout $x \in \mathsf{X}$, $\displaystyle\lim_{b \to \infty} \sup_{\|\theta\| > b} m(\theta, x) = -\infty$.

Alors toute suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ de M-estimateurs associés à m, au sens du théorème 4.1, est consistante.

Démonstration

Soit $\theta^\star \in \mathbb{R}^d$. La fonction $b \mapsto \sup_{\|\theta\| > b} m(\theta, x)$ est décroissante et tend vers $-\infty$ par (v) ; le théorème de convergence monotone, licite grâce à (iv), donne

$$\lim_{b \to \infty} \int \left\{ \sup_{\|\theta\| > b} m(\theta, x) \right\} \mathbb{Q}_{\theta^\star}(\mathrm{d}x) = -\infty \, .$$

Choisissons $b > \|\theta^\star\|$ tel que $\int \{\sup_{\|\theta\| > b} m(\theta, x)\} \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \mathsf{M}_{\theta^\star}(\theta^\star)$. La loi des grands nombres donne

$$\begin{aligned} \sup_{\|\theta\| > b} \widehat{M}_n(\theta) - \widehat{M}_n(\theta^\star) &\leq \frac{1}{n} \sum_{i=1}^{n} \left\{ \sup_{\|\theta\| > b} m(\theta, X_i) - m(\theta^\star, X_i) \right\} \\ &\overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \int \left\{ \sup_{\|\theta\| > b} m(\theta, x) \right\} \mathbb{Q}_{\theta^\star}(\mathrm{d}x) - \mathsf{M}_{\theta^\star}(\theta^\star) < 0 \, , \end{aligned}$$

d'où $\lim_n \mathbb{P}_{n,\theta^\star}\big(\sup_{\|\theta\| > b} \widehat{M}_n(\theta) - \widehat{M}_n(\theta^\star) + \rho_n \geq 0\big) = 0$. Posons $K := \overline{\mathrm{B}(0, b)}$, qui est compact. De

$$\left\{ \hat{\theta}_n \notin K \right\} \subseteq \left\{ \widehat{M}_n(\hat{\theta}_n) < \widehat{M}_n(\theta^\star) - \rho_n \right\} \cup \left\{ \sup_{\|\theta\| > b} \widehat{M}_n(\theta) \geq \widehat{M}_n(\theta^\star) - \rho_n \right\}$$

on tire $\limsup_n \mathbb{P}_{n,\theta^\star}(\hat{\theta}_n \notin K) = 0$. Il reste à appliquer le corollaire 1.1, dans sa version approchée, à l'estimateur $\hat{\theta}_n \mathbb{1}_K(\hat{\theta}_n)$, qui coïncide avec $\hat{\theta}_n$ avec une probabilité tendant vers 1. □

Exemple 4.1: La médiane empirique comme M-estimateur

Soit F une fonction de répartition sur $\mathbb{R}$ telle que $\int |x| F(\mathrm{d}x) < \infty$, $F(x) = 1 - F(-x)$ pour tout x, et $F(\eta) > 1/2$ pour tout $\eta > 0$. Pour $\theta \in \Theta = \mathbb{R}$, soit $\mathbb{Q}_\theta$ la loi de fonction de répartition $x \mapsto F(x - \theta)$, et considérons le M-estimateur associé à $m(\theta, x) = -|x - \theta|$, qui

est la médiane empirique. La continuité (i) est claire, et $|m(\theta,x)| \le |\theta| + |x|$ donne (ii) et (iv) ; l'inégalité $\sup_{\|\theta\|>b} m(\theta,x) \le |x| - b$ donne (v). Quant à (iii), un calcul élémentaire montre que, pour tous $\theta, \theta^\star$,

$$\mathsf{M}_{\theta^\star}(\theta^\star) - \mathsf{M}_{\theta^\star}(\theta) = 2\int_0^{|\theta-\theta^\star|} (|\theta-\theta^\star| - x)\, F(\mathrm{d}x) \;,$$

quantité strictement positive dès que $\theta \neq \theta^\star$, puisque $F(\eta) > 1/2$ pour tout $\eta > 0$. Le théorème 4.2 s'applique : la médiane empirique est consistante, sans hypothèse de moment d'ordre deux.

4.3 Consistance de l'estimateur du maximum de vraisemblance

Les deux énoncés suivants sont la traduction du corollaire 1.1 et du théorème 4.2 à $m(\theta,x) = \log p_\theta(x)$.

Théorème 4.3: Consistance du maximum de vraisemblance, cas compact

Soit une suite d'expériences statistiques produit du modèle dominé $\mathbb{Q}_\theta = p_\theta \cdot \mu$, où Θ est un compact de $\mathbb{R}^d$. Supposons :

(i) pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto \log p_\theta(x)$ est continue ;

(ii) pour tout $\theta^\star \in \Theta$, $\displaystyle\int \sup_{\theta\in\Theta} |\log p_\theta(x)|\, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$;

(iii) pour tous $\theta \neq \theta^\star$ dans Θ, $\mathbb{Q}_\theta \neq \mathbb{Q}_{\theta^\star}$.

Alors, pour tout $\theta^\star \in \Theta$, la fonction $\theta \mapsto \int \log p_\theta(x) \mathbb{Q}_{\theta^\star}(\mathrm{d}x)$ a un maximum unique au point $\theta = \theta^\star$, et toute suite $\{\hat\theta_n^{\mathrm{MV}}, n \in \mathbb{N}\}$ telle que $\lim_n \mathbb{P}_{n,\theta^\star}(\ell_n(\hat\theta_n^{\mathrm{MV}}) \ge \ell_n(\theta^\star)) = 1$, où $\ell_n(\theta) := n^{-1}\sum_{i=1}^n \log p_\theta(X_i)$, est consistante.

La version non compacte ajoute, comme au théorème 4.2, l'intégrabilité de $\sup_{\|\theta\|\ge a} \log p_\theta$ pour un $a > 0$ et la divergence $\lim_{b\to\infty} \sup_{\|\theta\|\ge b} \log p_\theta(x) = -\infty$ pour μ-presque tout x. Ce sont les théorèmes II-3.1 et II-3.2 du polycopié d'origine.

4.4 Lois limites dans le cas vectoriel

Les démonstrations de la partie principale (Section 1.5) s'étendent au cas $\Theta \subseteq \mathbb{R}^d$ sans difficulté de principe : le quotient devient un produit par l'inverse d'une matrice jacobienne, et la variance asymptotique une matrice de covariance.

Théorème 4.4: Loi limite des Z-estimateurs, cas vectoriel

Soit une suite d'expériences statistiques produit d'espace des paramètres $\Theta \subseteq \mathbb{R}^d$ et $\psi : \Theta \times \mathsf{X} \to \mathbb{R}^d$. Supposons que, pour tout $\theta^\star \in \Theta^o$:

(i) pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto \psi(\theta, x)$ est continûment différentiable sur un voisinage $\mathcal{V}(\theta^\star)$, et l'on pose

$$\mathrm{J}_\psi(\theta^\star) := \left[\int \frac{\partial \psi_r}{\partial \theta^{(s)}}(\theta^\star, x)\, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) \right]_{1 \leq r,s \leq d} ;$$

(ii) il existe une fonction mesurable g telle que, pour tout $x \in \mathsf{X}$, $\sup_{\theta \in \mathcal{V}(\theta^\star)} \sum_{i=1}^d \left\| \partial\psi/\partial\theta^{(i)}(\theta, x) \right\| \leq g(x)$ et $\int g \,\mathrm{d}\mathbb{Q}_{\theta^\star} < \infty$; de plus la matrice $\mathrm{J}_\psi(\theta^\star)$ est inversible ;

(iii) $\int \|\psi(\theta^\star, x)\|^2 \, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$ et $\int \psi(\theta^\star, x)\, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) = 0$.

Soit $\{\hat\theta_n, n \in \mathbb{N}\}$ une suite consistante d'estimateurs telle que $\sqrt{n}\, \widehat{\Psi}_n(\hat\theta_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$ pour tout $\theta^\star \in \Theta^o$. Alors, pour tout $\theta^\star \in \Theta^o$,

$$\sqrt{n}\left(\hat\theta_n - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \left[\mathrm{J}_\psi(\theta^\star)\right]^{-1} G_\psi(\theta^\star) \left[\mathrm{J}_\psi(\theta^\star)\right]^{-\top}\right) ,$$

où

$$G_\psi(\theta^\star) := \int \psi(\theta^\star, x)\, \psi(\theta^\star, x)^\top \mathbb{Q}_{\theta^\star}(\mathrm{d}x) .$$

Le cas des M-estimateurs s'en déduit en posant $\psi = \nabla m$: sous les hypothèses correspondantes de différentiabilité seconde et de domination, et si $\{\hat\theta_n, n \in \mathbb{N}\}$ est une suite consistante telle que $\sqrt{n}\, \nabla \widehat{M}_n(\hat\theta_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$, alors

$$\sqrt{n}\left(\hat\theta_n - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, U_m(\theta^\star)\, G_m(\theta^\star)\, U_m(\theta^\star)^\top\right) ,$$

avec

$$G_m(\theta^\star) := \int \nabla m(\theta^\star, x)\, \left(\nabla m(\theta^\star, x)\right)^\top \mathbb{Q}_{\theta^\star}(\mathrm{d}x) , \qquad U_m(\theta^\star) := \left(\int \mathrm{H}_m(\theta^\star, x)\, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) \right)^{-1} .$$

Ce sont les théorèmes II-2.18 et II-2.20 du polycopié d'origine.

Appliqué à $m = \ell$ dans un modèle régulier, le second donne la normalité asymptotique de l'estimateur du maximum de vraisemblance sous sa forme générale : la relation

$$\mathbb{I}(\theta) = \int \nabla\ell(\theta, x)\, \left(\nabla\ell(\theta, x)\right)^\top \mathbb{Q}_\theta(\mathrm{d}x) = -\int \mathrm{H}_\ell(\theta, x)\, \mathbb{Q}_\theta(\mathrm{d}x)$$

fait que $G_\ell(\theta) = \mathbb{I}(\theta)$ et $U_\ell(\theta) = -\mathbb{I}^{-1}(\theta)$, d'où

$$\sqrt{n}\left(\hat\theta_n^{\mathrm{MV}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \mathbb{I}^{-1}(\theta^\star)\right) .$$

4.5 Trois pivots asymptotiques et les régions de confiance associées

La normalité asymptotique de l'estimateur du maximum de vraisemblance fournit des régions de confiance asymptotiques pour θ, au sens de la définition 1.8. Plaçons-nous dans un modèle régulier de dimension d et notons $\chi^2_{1-\alpha}(d)$ le quantile d'ordre $1-\alpha$ de la loi $\chi^2(d)$.

L'information de Fisher au point courant. De $\sqrt{n}(\hat\theta_n^{\mathrm{MV}} - \theta) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0, \mathbb{I}^{-1}(\theta))$ on tire

$$n\left(\hat\theta_n^{\mathrm{MV}} - \theta\right)^\top \mathbb{I}(\theta)\left(\hat\theta_n^{\mathrm{MV}} - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \chi^2(d)\ ,$$

donc $\lim_n \mathbb{P}_{n,\theta}(\theta \in S_{n,\alpha}) = 1-\alpha$ pour

$$S_{n,\alpha} := \left\{\theta \in \Theta\ :\ n(\hat\theta_n^{\mathrm{MV}} - \theta)^\top \mathbb{I}(\theta)(\hat\theta_n^{\mathrm{MV}} - \theta) \le \chi^2_{1-\alpha}(d)\right\}\ .$$

Cette région est rarement employée : la dépendance de $\mathbb{I}$ en θ la rend difficile à décrire.

L'information de Fisher à l'estimateur. Si $\theta \mapsto \mathbb{I}(\theta)$ est continue, la consistance de $\{\hat\theta_n^{\mathrm{MV}}, n \in \mathbb{N}\}$ et le lemme de Slutsky donnent $\sqrt{n}\,\mathbb{I}^{1/2}(\hat\theta_n^{\mathrm{MV}})(\hat\theta_n^{\mathrm{MV}} - \theta) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0, \mathrm{I}_d)$, d'où la région

$$\tilde S_{n,\alpha} := \left\{\theta \in \Theta\ :\ n(\hat\theta_n^{\mathrm{MV}} - \theta)^\top \mathbb{I}(\hat\theta_n^{\mathrm{MV}})(\hat\theta_n^{\mathrm{MV}} - \theta) \le \chi^2_{1-\alpha}(d)\right\}\ ,$$

qui est un ellipsoïde centré en $\hat\theta_n^{\mathrm{MV}}$.

L'information de Fisher observée. Lorsque $\mathbb{I}$ n'a pas d'expression explicite, on la remplace par

$$\mathbb{I}_n(\theta) := -\frac{1}{n}\sum_{i=1}^n \mathrm{H}_\ell(\theta, X_i)\ ,$$

et l'on appelle *information de Fisher observée* la matrice $\mathbb{I}_n(\hat\theta_n^{\mathrm{MV}})$. Dans un modèle régulier, $\mathbb{I}_n(\hat\theta_n) \overset{\mathbb{P}_{n,\theta^\star}-\mathrm{prob}}{\longrightarrow} \mathbb{I}(\theta^\star)$ pour toute suite consistante d'estimateurs $\{\hat\theta_n, n \in \mathbb{N}\}$, de sorte que

$$\sqrt{n}\,\mathbb{I}_n^{1/2}(\hat\theta_n^{\mathrm{MV}})\left(\hat\theta_n^{\mathrm{MV}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}(0, \mathrm{I}_d)\ ,$$

et la région $\check S_{n,\alpha}$ obtenue en remplaçant $\mathbb{I}(\hat\theta_n^{\mathrm{MV}})$ par $\mathbb{I}_n(\hat\theta_n^{\mathrm{MV}})$ dans $\tilde S_{n,\alpha}$ est de niveau de couverture asymptotique $1-\alpha$. Elle ne dépend que de la log-vraisemblance et de sa hessienne au point $\hat\theta_n^{\mathrm{MV}}$.

Le rapport de vraisemblance. En développant la log-vraisemblance normalisée ℓ_n autour de son maximum $\hat\theta_n^{\mathrm{MV}}$, on obtient $\ell_n(\theta) = \ell_n(\hat\theta_n^{\mathrm{MV}}) - \frac{1}{2}(\hat\theta_n^{\mathrm{MV}} - \theta)^\top \mathbb{I}_n(\theta_n^*)(\hat\theta_n^{\mathrm{MV}} - \theta)$ pour un point θ_n^* du segment $\left[\theta, \hat\theta_n^{\mathrm{MV}}\right]$, et l'on en déduit

$$2n\ \ell_n(\hat\theta_n^{\mathrm{MV}}) - 2n\ \ell_n(\theta^\star) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \chi^2(d)\ ,$$

donc une troisième région, $\check S_{n,\alpha} := \left\{\theta \in \Theta\ :\ 2n\,\ell_n(\hat\theta_n^{\mathrm{MV}}) - 2n\,\ell_n(\theta) \le \chi^2_{1-\alpha}(d)\right\}$, définie par les seules valeurs de la vraisemblance.

Enfin, si $g : \mathbb{R}^d \to \mathbb{R}$ est différentiable en $\theta^\star$, la méthode-δ (théorème 1.8) donne un intervalle de confiance asymptotique pour $g(\theta^\star)$:

$$\left[g(\hat\theta_n^{\mathrm{MV}}) - \frac{z_{1-\alpha/2}\,\sigma_g(\hat\theta_n^{\mathrm{MV}})}{\sqrt{n}},\ g(\hat\theta_n^{\mathrm{MV}}) + \frac{z_{1-\alpha/2}\,\sigma_g(\hat\theta_n^{\mathrm{MV}})}{\sqrt{n}}\right]\ , \qquad \sigma_g^2(\theta) := (\nabla g(\theta))^\top\, \mathbb{I}^{-1}(\theta)\, \nabla g(\theta)\ ,$$

où $\mathbb{I}$ peut à nouveau être remplacée par l'information de Fisher observée.

4.6 Efficacité asymptotique et conjecture de Fisher

La comparaison des estimateurs par leur variance asymptotique, introduite au chapitre 6 (proposition 1.3), se formule dans les termes suivants. On se restreint à la classe des suites d'estimateurs asymptotiquement normales, c'est-à-dire telles qu'il existe $v(\theta) > 0$ avec $\sqrt{n}(\hat\theta_n - \theta) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}(0, v(\theta))$ pour tout $\theta \in \Theta$, et l'on suppose $\theta \mapsto v(\theta)$ continue.

Définition 4.1: Estimateur asymptotiquement efficace

Soient $\{\widehat{\theta}_{n,1}, n \in \mathbb{N}\}$ et $\{\widehat{\theta}_{n,2}, n \in \mathbb{N}\}$ deux suites d'estimateurs asymptotiquement normales, de variances asymptotiques continues v_1 et v_2. On dit que $\widehat{\theta}_{n,1}$ est *plus efficace* que $\widehat{\theta}_{n,2}$ si $v_1(\theta) \leq v_2(\theta)$ pour tout $\theta \in \Theta$ et s'il existe $\widetilde{\theta} \in \Theta$ tel que $v_1(\widetilde{\theta}) < v_2(\widetilde{\theta})$. Une suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est *asymptotiquement efficace* dans une classe d'estimateurs s'il n'existe dans cette classe aucune suite plus efficace qu'elle.

L'hypothèse de normalité asymptotique en *tout* point de Θ exclut les estimateurs constants $\hat{\theta}_n = \widetilde{\theta}$, dont le risque est nul en $\widetilde{\theta}$ et catastrophique ailleurs. Le théorème 1.7 se relit alors ainsi : dans un modèle régulier, l'estimateur du maximum de vraisemblance est asymptotiquement efficace dans la classe des Z-estimateurs réguliers.

En 1922, Fisher conjectura davantage : que, pour un modèle régulier, l'estimateur du maximum de vraisemblance a pour variance asymptotique $1/\mathbb{I}(\theta)$, et que *toute* suite d'estimateurs asymptotiquement normale a une variance asymptotique $v(\theta) \geq 1/\mathbb{I}(\theta)$. Le premier point est vrai, c'est le théorème 1.7 ; le second n'est vrai que dans la classe restreinte des Z-estimateurs réguliers. Il est faux en général : l'estimateur de Hodges, étudié au chapitre 6 (Section 4.5), est asymptotiquement normal, de variance asymptotique partout au plus égale à celle de la moyenne empirique dans le modèle $\mathcal{N}(\theta, 1)$, et strictement plus petite en $\theta = 0$. Son risque quadratique au voisinage de zéro est pourtant arbitrairement mauvais. La comparaison des estimateurs par leur variance asymptotique en un point n'est donc pas une notion d'optimalité satisfaisante ; une théorie complète demande de comparer les risques sur des voisinages, ce qui dépasse le cadre de ce cours.

4.7 La méthode du score de Fisher

Dans un modèle régulier, l'estimateur du maximum de vraisemblance est asymptotiquement efficace, mais il est parfois coûteux à calculer, alors qu'un autre M- ou Z-estimateur est explicite : c'est le cas du modèle de Cauchy, où la médiane empirique se lit sur les observations triées tandis que l'estimateur du maximum de vraisemblance demande une optimisation numérique. Un pas de Newton sur l'équation de vraisemblance, parti d'un estimateur quelconque asymptotiquement normal, suffit à récupérer la variance asymptotique optimale.

Lemme 4.1: Linéarisation de l'équation de vraisemblance

Supposons le modèle $\{p_\theta \cdot \mu : \theta \in \Theta\}$ régulier et soit $\{\hat{\theta}_n, n \in \mathbb{N}\}$ une suite d'estimateurs asymptotiquement normale. Alors, pour tout $\theta^\star \in \Theta$ et tout $\varepsilon > 0$,

$$\lim_{n\to\infty} \mathbb{P}_{n,\theta^\star}\left(\sqrt{n}\left\|\nabla \ell_n(\hat{\theta}_n) - \left\{\nabla \ell_n(\theta^\star) - \mathbb{I}(\theta^\star)(\hat{\theta}_n - \theta^\star)\right\}\right\| \geq \varepsilon\right) = 0\,,$$

où $\nabla \ell_n(\theta) := n^{-1}\sum_{i=1}^n \nabla \ell(\theta, X_i)$.

Démonstration

La formule de Taylor avec reste intégral appliquée à $\theta \mapsto \nabla\ell(\theta, X_i)$ entre $\theta^\star$ et $\hat{\theta}_n$ donne

$$\nabla \ell_n(\hat{\theta}_n) = \nabla \ell_n(\theta^\star) - \mathbb{I}_n(\theta^\star)\left(\hat{\theta}_n - \theta^\star\right) + \Delta_n\left(\hat{\theta}_n - \theta^\star\right)\,,$$

où

$$\Delta_n := -\int_0^1 \left\{\mathbb{I}_n\left(\theta^\star + w(\hat{\theta}_n - \theta^\star)\right) - \mathbb{I}_n(\theta^\star)\right\} \mathrm{d}w\,.$$

La convergence $\mathbb{I}_n(\hat{\theta}_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \mathbb{I}(\theta^\star)$ rappelée plus haut (Section 4.5) donne $\Delta_n \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$, et comme $\sqrt{n}(\hat{\theta}_n - \theta^\star)$ converge en loi, le lemme de Slutsky donne $\sqrt{n}\,\Delta_n(\hat{\theta}_n - \theta^\star) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$.

La loi des grands nombres donne de même $\mathbb{I}_n(\theta^\star) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \mathbb{I}(\theta^\star)$, donc $\sqrt{n}\{\mathbb{I}_n(\theta^\star)-\mathbb{I}(\theta^\star)\}(\hat{\theta}_n-\theta^\star) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$. □

Théorème 4.5: Méthode du score de Fisher

Supposons le modèle $\{p_\theta \cdot \mu : \theta \in \Theta\}$ régulier et soit $\{\hat{\theta}_n, n \in \mathbb{N}\}$ une suite d'estimateurs asymptotiquement normale. L'estimateur

$$\widetilde{\theta}_n := \hat{\theta}_n + \mathbb{I}_n(\hat{\theta}_n)^{-1} \nabla \ell_n(\hat{\theta}_n)$$

vérifie, pour tout $\theta^\star \in \Theta$,

$$\sqrt{n}\left(\widetilde{\theta}_n - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \mathbb{I}^{-1}(\theta^\star)\right) .$$

Le choix initial peut donc être n'importe quel M- ou Z-estimateur consistant et asymptotiquement normal, sans qu'on ait à se soucier de sa variance asymptotique : un pas de la méthode l'amène au niveau de l'estimateur du maximum de vraisemblance. C'est le théorème II-3.8 du polycopié d'origine.

4.8 Le modèle de Cauchy en détail

Reprenons l'exemple 1.9, de densité $q_\theta(x) = \pi^{-1}(1+(x-\theta)^2)^{-1}$.

L'information de Fisher. Le score vaut

$$\dot{\ell}(\theta, x) = \partial_\theta \left\{ -\log \pi - \log\left(1+(x-\theta)^2\right)\right\} = \frac{2(x-\theta)}{1+(x-\theta)^2} ,$$

d'où, par le changement de variable $u = x-\theta$ puis $u = \tan t$,

$$\mathbb{I}(\theta) = \int_{\mathbb{R}} \frac{4u^2}{(1+u^2)^2} \cdot \frac{1}{\pi(1+u^2)} \mathrm{d}u = \frac{4}{\pi} \int_{-\pi/2}^{\pi/2} \sin^2 t \, \cos^2 t \, \mathrm{d}t = \frac{1}{\pi} \int_{-\pi/2}^{\pi/2} \sin^2(2t) \, \mathrm{d}t = \frac{1}{2} .$$

L'information de Fisher ne dépend pas de θ, ce qui est attendu pour un modèle de translation, et la variance asymptotique de l'estimateur du maximum de vraisemblance vaut 2.

La loi limite de la médiane empirique. Soit F une fonction de répartition sur $\mathbb{R}$, $p \in]0,1[$ et $Q(p)$ le quantile d'ordre p. Si F est dérivable au point $Q(p)$ avec $F'(Q(p)) > 0$, la théorie des statistiques d'ordre donne, pour toute suite $\{k_n,\ n \in \mathbb{N}\}$ d'entiers telle que $\sqrt{n}(k_n/n - p) \to 0$,

$$\sqrt{n}\left(X_{k_n:n} - Q(p)\right) \Longrightarrow \mathcal{N}\left(0, \frac{p(1-p)}{[F'(Q(p))]^2}\right) .$$

Pour $p = 1/2$ et une loi symétrique autour de $\theta^\star$, $Q(1/2) = \theta^\star$ et $F' = q_{\theta^\star}$, d'où

$$\sqrt{n}\left(\widehat{\theta}_n^{\text{med}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \frac{1}{4\left(q_{\theta^\star}(\theta^\star)\right)^2}\right) .$$

Dans le modèle de Cauchy, $q_{\theta^\star}(\theta^\star) = 1/\pi$ et la variance asymptotique de la médiane vaut $\pi^2/4$.

L'efficacité relative. Le rapport des deux variances asymptotiques vaut

$$\frac{1/\mathbb{I}(\theta^\star)}{1/\left\{4(q_{\theta^\star}(\theta^\star))^2\right\}} = \frac{2}{\pi^2/4} = \frac{8}{\pi^2} \simeq 0{,}81\ .$$

Pour atteindre la précision asymptotique que l'estimateur du maximum de vraisemblance obtient avec n observations, la médiane en demande environ $n/0{,}81 \simeq 1{,}23\,n$. L'écart est visible sur la figure 4, où l'histogramme rouge est plus resserré que le bleu, mais il reste modeste : la médiane, qui se calcule sans optimisation, reste un estimateur raisonnable de ce modèle, et la méthode du score de Fisher (Section 4.7) permet d'en faire le point de départ d'un estimateur asymptotiquement efficace.

4.9 Au-delà des modèles réguliers

Trois situations, rencontrées dans les chapitres précédents et dans la feuille de ce chapitre, montrent de combien de façons la conclusion du théorème 1.7 peut tomber.

Le paramètre gouverne le support. Pour le modèle uniforme sur $[0,\theta]$, l'estimateur du maximum de vraisemblance est $\hat\theta_n = \max(X_1,\dots,X_n)$, et $n(\theta-\hat\theta_n) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{E}(\theta^{-1})$ (exemple 1.5) ; pour le modèle de Pareto, $n\eta(\hat\alpha_n-\alpha) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \alpha\,\mathcal{E}(1)$ (exemple 1.10). Dans les deux cas, $\theta \mapsto p_\theta(x)$ est discontinue au point x, la condition (R-2) n'est pas vérifiée, la vitesse est n et la loi limite exponentielle. L'erreur est donc d'un ordre de grandeur plus petit que dans le cas régulier.

La vraie valeur est sur la frontière. Le théorème 1.4 ne dit rien des points de la frontière de Θ. Pour le modèle $\mathcal{N}(\theta,1)$ avec $\Theta=\mathbb{R}_+$, étudié à l'exercice 4, l'estimateur du maximum de vraisemblance est $\hat\theta_n^{\mathrm{MV}} = \max(\bar X_n, 0)$: la normalité asymptotique vaut pour $\theta>0$, mais la loi limite en $\theta=0$ est celle de $\max(W,0)$ pour $W\sim\mathcal{N}(0,1)$, qui n'est pas gaussienne et charge le point 0 d'une masse $1/2$.

La fonction d'influence n'est pas régulière. La médiane empirique est le Z-estimateur associé à $\psi(\theta,x) = \mathrm{signe}(x-\theta)$, qui n'est différentiable en θ pour aucun x. L'estimateur reste consistant (exemple 4.1) et asymptotiquement normal (Section 4.8), mais ni la consistance ni la loi limite ne s'obtiennent par les théorèmes de ce chapitre : il faut passer par les statistiques d'ordre, ou par un argument de monotonie comme celui de l'exercice 5. L'absence de régularité de ψ n'est donc pas une absence de régularité du modèle, et elle se contourne.