Chapitre 7

Théorie asymptotique des M- et Z-estimateurs

Le chapitre précédent a donné les outils asymptotiques – loi des grands nombres, théorème de la limite centrale, lemme de Slutsky, méthode-δ – et les a appliqués à des estimateurs qui s'écrivent comme des fonctions régulières d'une moyenne empirique. Les deux grandes familles d'estimateurs construites au chapitre 2 n'ont pas cette forme : un M-estimateur est défini comme le point où une fonction aléatoire atteint son maximum, un Z-estimateur comme la solution d'une équation dont les coefficients sont aléatoires, et l'estimateur du maximum de vraisemblance appartient aux deux familles. Dans la plupart des modèles, ni l'un ni l'autre n'a d'expression explicite.
Ce chapitre établit la consistance et la normalité asymptotique de ces estimateurs à partir d'hypothèses portant sur la fonction objectif m ou sur la fonction d'influence ψ, et non sur l'estimateur lui-même. La consistance repose sur une convergence *uniforme* en θ de la fonction aléatoire vers sa limite, jointe au caractère isolé du maximum ou du zéro de cette limite. La loi limite s'obtient en développant l'équation d'estimation au premier ordre autour de la vraie valeur du paramètre : le théorème de la limite centrale gouverne le numérateur, la loi des grands nombres le dénominateur, et le lemme de Slutsky les assemble. La variance asymptotique qui en résulte, $\mathbb{E}_\theta[\psi^2]/(\mathbb{E}_\theta[\psi'])^2$, dépend du choix de ψ. Appliquée à la vraisemblance, cette variance vaut l'inverse de l'information de Fisher, et l'inégalité de Cauchy-Schwarz montre qu'aucun autre Z-estimateur régulier ne fait mieux : pour un modèle régulier, l'estimateur du maximum de vraisemblance est asymptotiquement efficace dans la classe des Z-estimateurs. Le modèle de Cauchy, où la médiane empirique et l'estimateur du maximum de vraisemblance sont tous deux asymptotiquement normaux, donne une lecture numérique de cet écart de variances, et le modèle de Pareto rappelle que la vitesse $\sqrt{n}$ et la loi limite gaussienne tombent dès que le modèle cesse d'être régulier.

Des estimateurs définis par un problème d'optimisation

Reprenons la situation du chapitre 2. Une fonction objectif m étant donnée, le M-estimateur associé maximise $\theta \mapsto n^{-1}\sum_{i=1}^n m(\theta, X_i)$, et une fonction d'influence ψ étant donnée, le Z-estimateur associé annule $\theta \mapsto n^{-1}\sum_{i=1}^n \psi(\theta, X_i)$. Les deux constructions ont la même logique : la fonction de θ que l'on manipule est aléatoire, parce qu'elle est construite sur les observations, et la loi des grands nombres dit qu'elle s'approche, en chaque point θ, d'une fonction déterministe dont on sait

par construction qu'elle est maximale, ou nulle, en la vraie valeur du paramètre. Reste à passer de la convergence des fonctions à celle de leurs points de maximum ou de leurs zéros.

Intuition. *Imaginons deux courbes tracées sur le même graphe : celle de la fonction limite, qui a un pic en $\theta^\star$, et celle de la fonction empirique, qui oscille autour de la première. Si l'oscillation est partout petite, le sommet de la seconde courbe ne peut pas être très loin du sommet de la première,* à condition *que le pic de la première soit franc : une fonction limite presque plate au voisinage de son maximum laisse le sommet empirique dériver loin. Les deux conditions du théorème de consistance disent précisément cela, l'une que l'écart entre les deux courbes est petit* uniformément *en θ, l'autre que le maximum de la courbe limite est isolé. L'image des deux courbes est une image : la démonstration n'y recourt pas.*

1 Les fondamentaux

1.1 Le cadre et les notations

Tout ce chapitre se place dans une suite d'expériences statistiques produit, au sens de la définition 1.1. On se donne une expérience statistique $(\mathsf{X}, \mathcal{X}, \{\mathbb{Q}_\theta \,:\, \theta \in \Theta\})$, où $\Theta \subseteq \mathbb{R}^d$ est l'espace des paramètres, et on considère, pour tout $n \in \mathbb{N}$, l'expérience

$$\left(\mathsf{X}^n, \mathcal{X}^{\otimes n}, \{\mathbb{P}_{n,\theta} \,:\, \theta \in \Theta\}\right) , \qquad \mathbb{P}_{n,\theta} := \mathbb{Q}_\theta^{\otimes n} ,$$

munie des statistiques canoniques $X_i : (x_1, \ldots, x_n) \mapsto x_i$, pour $1 \leq i \leq n$. Sous $\mathbb{P}_{n,\theta}$, les variables $X_1, \ldots, X_n$ sont indépendantes et de loi $\mathbb{Q}_\theta$. On note $\mathbb{E}_\theta$ l'espérance sous $\mathbb{Q}_\theta$ et $\mathbb{E}_{n,\theta}$ l'espérance sous $\mathbb{P}_{n,\theta}$; ces deux notations coïncident sur toute fonction d'une seule observation, et l'on écrit indifféremment $\mathbb{E}_\theta[f(X_1)]$ ou $\mathbb{Q}_\theta(f) := \int f(x)\mathbb{Q}_\theta(\mathrm{d}x)$.

La lettre $\theta^\star$ désigne, dans tout ce chapitre, la valeur du paramètre sous laquelle on calcule : c'est la valeur « vraie », celle que l'estimateur doit retrouver, et c'est elle qui indexe la loi $\mathbb{P}_{n,\theta^\star}$ des observations. La lettre θ reste la variable muette des fonctions que l'on maximise ou que l'on annule. Tout le calcul différentiel porte sur cette variable : on écrit $\nabla f(\theta, x)$ pour $\nabla_\theta f(\theta, x)$, et, dans le cas scalaire $d = 1$, $\psi'(\theta, x)$ et $\psi''(\theta, x)$ pour les dérivées première et seconde de $\theta \mapsto \psi(\theta, x)$.

1.2 Ce que le chapitre précédent a établi sur les tests

Le vocabulaire asymptotique des tests est celui du chapitre 6. Pour un test d'hypothèses $H_0 : \theta \in \Theta_0$ contre $H_1 : \theta \in \Theta_1$ et une suite de tests $\{\phi_n,\ n \in \mathbb{N}\}$ de fonctions puissance β_{ϕ_n}, la *taille asymptotique* est $\sup_{\theta\in\Theta_0} \limsup_n \beta_{\phi_n}(\theta)$, la suite est de *niveau asymptotique* α si $\limsup_n \beta_{\phi_n}(\theta) \leq \alpha$ pour tout $\theta \in \Theta_0$, et elle est *consistante* si $\liminf_n \beta_{\phi_n}(\theta) = 1$ pour tout $\theta \in \Theta_1$ (définitions 1.9, 1.10 et 1.11). Le test de Student asymptotique, dont la statistique est $T_n = \sqrt{n}(\bar{X}_n - \mu_0)/S_n^2$, fournit une suite de tests consistante de niveau asymptotique α pour l'hypothèse $\mu = \mu_0$ dès que le second moment existe : c'est l'exemple 1.14. La normalité asymptotique de la variance empirique non corrigée $\widehat{\sigma}_n^2 = n^{-1}\sum_{i=1}^n (X_i - \bar{X}_n)^2$, qui demande un moment d'ordre quatre et donne $\sqrt{n}(\widehat{\sigma}_n^2 - \sigma^2) \overset{\mathbb{P}_n}{\Longrightarrow} \mathcal{N}(0, \gamma)$ avec $\gamma = \mathbb{E}[(X_1 - \mu)^4] - \sigma^4$, est l'exemple 1.6, et la consistance de S_n^2 en découle (proposition 1.2).

1.3 M- et Z-estimateurs

Les deux définitions du chapitre 2 sont reprises ici sous la forme où elles seront utilisées, c'est-à-dire en faisant apparaître la fonction déterministe dont la fonction aléatoire est la version empirique.

Définition 1.1: M-estimateur

Soit $m : \Theta \times \mathsf{X} \to \mathbb{R}$ une fonction mesurable, dite *fonction objectif*, telle que pour tous $\theta, \theta^\star \in \Theta$ on ait $\mathbb{E}_{\theta^\star}\left[|m(\theta, X_1)|\right] < \infty$ et telle que, pour tout $\theta^\star \in \Theta$, la fonction

$$\theta \mapsto \mathsf{M}_{\theta^\star}(\theta) := \mathbb{E}_{\theta^\star}\left[m(\theta, X_1)\right]$$

admette un maximum au point $\theta = \theta^\star$. On appelle *M-estimateur associé à m* toute suite d'estimateurs $\{\hat{\theta}_n, n \in \mathbb{N}\}$ à valeurs dans Θ telle que

$$\widehat{M}_n(\hat{\theta}_n) = \max_{\theta\in\Theta} \widehat{M}_n(\theta) , \qquad \text{où} \quad \widehat{M}_n(\theta) := \frac{1}{n}\sum_{i=1}^n m(\theta, X_i) .$$

La fonction $\widehat{M}_n$ est une fonction aléatoire : elle dépend de l'observation $Z_n := (X_1, \ldots, X_n)$, et c'est la suite de ces fonctions aléatoires, et non une suite de nombres, dont il faudra contrôler le comportement asymptotique.

Définition 1.2: Z-estimateur

Soit $\psi : \Theta \times \mathsf{X} \to \mathbb{R}^d$ une fonction mesurable, dite *fonction d'influence*, telle que pour tous $\theta, \theta^\star \in \Theta$ on ait $\mathbb{E}_{\theta^\star}\left[\|\psi(\theta, X_1)\|\right] < \infty$ et telle que, pour tout $\theta^\star \in \Theta$, la fonction

$$\theta \mapsto \Psi_{\theta^\star}(\theta) := \mathbb{E}_{\theta^\star}\left[\psi(\theta, X_1)\right]$$

s'annule au point $\theta = \theta^\star$. On appelle *Z-estimateur associé à ψ* toute suite d'estimateurs $\{\hat{\theta}_n, n \in \mathbb{N}\}$ à valeurs dans Θ telle que

$$\widehat{\Psi}_n(\hat{\theta}_n) = 0\,, \qquad \text{où} \quad \widehat{\Psi}_n(\theta) := \frac{1}{n}\sum_{i=1}^n \psi(\theta, X_i)\,.$$

L'estimateur du maximum de vraisemblance est le M-estimateur de référence, et c'est à ce titre qu'il relèvera de toute la théorie de ce chapitre.

Exemple 1.1: L'estimateur du maximum de vraisemblance est un M-estimateur

Soit un modèle dominé $\mathbb{Q}_\theta = q_\theta \cdot \mu$ tel que $q_\theta(x) > 0$ pour tout $(\theta, x) \in \Theta \times \mathsf{X}$, et posons $m(\theta, x) := \log q_\theta(x)$. Pour tous $\theta^\star, \theta \in \Theta$, en supposant les deux intégrales finies,

$$\begin{aligned}
\mathsf{M}_{\theta^\star}(\theta) &= \mathbb{E}_{\theta^\star}\left[\log q_\theta(X_1)\right] = \mathbb{E}_{\theta^\star}\left[\log q_{\theta^\star}(X_1)\right] + \mathbb{E}_{\theta^\star}\left[\log \frac{q_\theta(X_1)}{q_{\theta^\star}(X_1)}\right] \\
&= \int (\log q_{\theta^\star}(x))\, q_{\theta^\star}(x)\mu(\mathrm{d}x) - \int \log\left(\frac{q_{\theta^\star}(x)}{q_\theta(x)}\right) q_{\theta^\star}(x)\mu(\mathrm{d}x) \\
&= \mathrm{Ent}(q_{\theta^\star}) - \mathrm{KL}(q_{\theta^\star}, q_\theta)\,,
\end{aligned}$$

où Ent désigne l'entropie et KL la divergence de Kullback-Leibler (définition 1.7). Le premier terme ne dépend pas de θ et le second est positif (théorème 1.1) : la fonction $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$ atteint donc son maximum en $\theta = \theta^\star$, et ce maximum est unique dès que le modèle est identifiable, puisque $\mathrm{KL}(q_{\theta^\star}, q_\theta) = 0$ équivaut alors à $\theta = \theta^\star$. Comme

$$\widehat{M}_n(\theta) = \frac{1}{n}\sum_{i=1}^n \log q_\theta(X_i)\,,$$

le M-estimateur associé à m est bien l'estimateur du maximum de vraisemblance, $\hat{\theta}_n^{\mathrm{MV}} \in \arg\max_{\theta\in\Theta} \widehat{M}_n(\theta)$.

Le modèle de translation fournit l'exemple le plus simple où la même suite d'estimateurs s'obtient des deux façons.

Exemple 1.2: Paramètre de translation : la moyenne empirique comme Z-estimateur

Soit q une densité sur $\mathbb{R}$ telle que $\int_{\mathbb{R}} x\, q(x)\mathrm{d}x = 0$ et $\int_{\mathbb{R}} x^2 q(x)\mathrm{d}x < \infty$. On considère le modèle dominé $\mathbb{Q}_\theta = q_\theta \cdot \mathrm{Leb}$ avec $\Theta := \mathbb{R}$ et $q_\theta(x) := q(x-\theta)$. On a $\mathbb{E}_\theta[X_1] = \int x\, q(x-\theta)\mathrm{d}x = \theta$. Posons $\psi(\theta, x) := x - \theta$: pour tous $\theta^\star, \theta \in \Theta$,

$$\Psi_{\theta^\star}(\theta) = \mathbb{E}_{\theta^\star}\left[X_1 - \theta\right] = \theta^\star - \theta\,,$$

qui ne s'annule qu'en $\theta = \theta^\star$. Comme $\widehat{\Psi}_n(\theta) = \bar{X}_n - \theta$, l'unique solution de $\widehat{\Psi}_n(\theta) = 0$ est $\hat{\theta}_n := \bar{X}_n$.

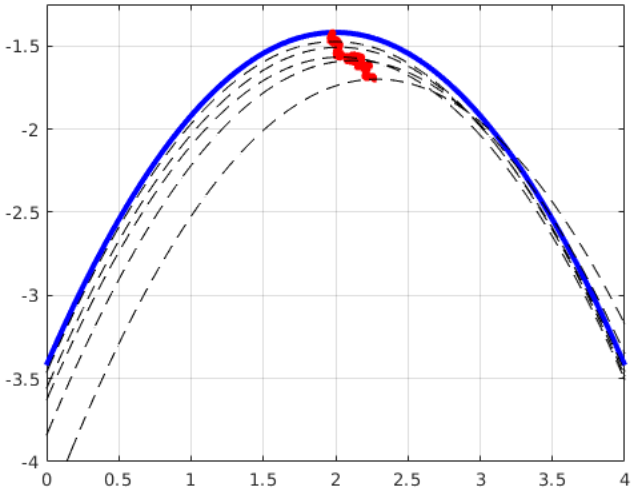


FIGURE 1 – Modèle de translation gaussien $\mathcal{N}(\theta, 1)$, pour $\theta^\star = 2$. En bleu, la fonction $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$; en noir, la fonction $\theta \mapsto \widehat{M}_n(\theta)$ pour trois valeurs de n ; en rouge, les points de coordonnées $(\hat{\theta}_n, \widehat{M}_n(\hat{\theta}_n))$ correspondants.

Exemple 1.3: Paramètre de translation : la moyenne empirique comme M-estimateur

Dans le cadre de l'exemple 1.2, posons $m(\theta, x) := -\frac{1}{2}(x-\theta)^2$. Pour tous $\theta^\star, \theta \in \Theta$,

$$\mathsf{M}_{\theta^\star}(\theta) = -\frac{1}{2}\mathbb{E}_{\theta^\star}\left[(X_1-\theta)^2\right] = -\frac{1}{2}\int (x+\theta^\star-\theta)^2 q(x)\mathrm{d}x = -\frac{1}{2}\int x^2 q(x)\mathrm{d}x - \frac{1}{2}(\theta^\star-\theta)^2 \,,$$

fonction qui atteint son maximum au seul point $\theta = \theta^\star$. La fonction $\theta \mapsto \widehat{M}_n(\theta) = -\frac{1}{2n}\sum_{k=1}^n (X_k-\theta)^2$ est strictement concave et son unique maximum est $\bar{X}_n$: la moyenne empirique est donc à la fois le Z-estimateur associé à $\psi(\theta, x) = x - \theta$ et le M-estimateur associé à $m(\theta, x) = -\frac{1}{2}(x-\theta)^2$.

Intuition. *La coïncidence de l'exemple 1.3 n'est pas un hasard : $\psi(\theta, x) = \partial_\theta m(\theta, x)$, et annuler la dérivée d'une fonction strictement concave revient à la maximiser. C'est le lien général entre les deux familles, énoncé plus bas, mais il ne vaut que sous une hypothèse de régularité.*

Le choix $m(\theta, x) = -(x-\theta)^2$ suppose que la loi des observations a un moment d'ordre deux. Lorsque ce n'est pas le cas, d'autres fonctions objectif ou d'influence restent utilisables, et c'est le point de départ de la statistique robuste.

Exemple 1.4: Paramètre de translation sans moment d'ordre deux

Reprenons le cadre de l'exemple 1.2, mais avec $\int x^2 q(x)\mathrm{d}x = +\infty$ et $q(x) = q(-x)$ pour tout $x \in \mathbb{R}$. Les fonctions suivantes restent admissibles : pour $\delta > 0$, la perte de Huber

$$m(\theta, x) = -\delta^2\left(\sqrt{1+\{(\theta-x)/\delta\}^2} - 1\right) \,,$$

qui définit un M-estimateur, et les fonctions d'influence

$$\psi(\theta, x) = \arctan(x-\theta) \,, \qquad \psi(\theta, x) = \mathrm{signe}(x-\theta) \,,$$

qui définissent des Z-estimateurs. La seconde donne la médiane empirique. Ces trois fonctions

sont bornées en x, ou de dérivée bornée, ce qui suffit à assurer l'intégrabilité quel que soit le comportement des queues de q. L'exercice 5 de la feuille de ce chapitre étudie en détail la famille de Z-estimateurs associés à $\psi(\theta, x) = \gamma(x - \theta)$ pour γ impaire croissante, dont ces exemples sont des cas particuliers.

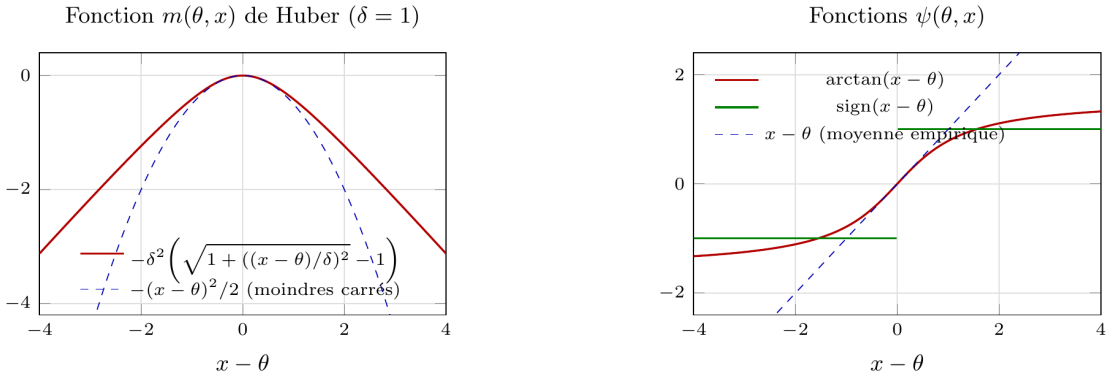


FIGURE 2 – À gauche, la fonction objectif de Huber $m(\theta, x) = -\delta^2(\sqrt{1 + \{(\theta - x)/\delta\}^2} - 1)$ pour $\delta = 1$, en trait plein, et la fonction des moindres carrés $-\frac{1}{2}(\theta - x)^2$, en pointillés ; à droite, les fonctions d'influence $\arctan(x-\theta)$ et $\text{signe}(x-\theta)$, en traits pleins, et $x-\theta$, en pointillés, qui donne la moyenne empirique.

Proposition 1.1: Un M-estimateur régulier est un Z-estimateur

Supposons que, pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto m(\theta, x)$ est différentiable sur Θ^o, et posons $\psi(\theta, x) := \nabla m(\theta, x)$. Si la fonction $\theta \mapsto \widehat{M}_n(\theta)$ atteint son maximum en un point $\hat{\theta}_n \in \Theta^o$, alors

$$\widehat{\Psi}_n(\hat{\theta}_n) = \frac{1}{n}\sum_{i=1}^{n} \nabla m(\hat{\theta}_n, X_i) = \nabla \widehat{M}_n(\hat{\theta}_n) = 0 \,,$$

c'est-à-dire que $\hat{\theta}_n$ est un Z-estimateur associé à ψ.

Démonstration

Le gradient d'une fonction différentiable s'annule en tout point intérieur où elle atteint un maximum, et la différentiation terme à terme d'une somme finie donne $\nabla \widehat{M}_n(\theta) = n^{-1}\sum_{i=1}^{n} \nabla m(\theta, X_i)$. □

La réciproque est fausse, et les deux classes ne sont pas comparables en général. Si m n'est pas régulière, un M-estimateur n'est pas nécessairement un Z-estimateur : c'est le cas de l'estimateur du maximum de vraisemblance du support d'une loi uniforme, dont la vraisemblance n'est pas dérivable (exemple 1.11). Et si l'équation d'estimation $\widehat{\Psi}_n(\theta) = 0$ admet plusieurs solutions, celles qui correspondent à des extrema locaux ou à des points selle ne maximisent pas $\widehat{M}_n$.

1.4 Consistance des M- et Z-estimateurs

Une suite d'estimateurs $\{T_n, n \in \mathbb{N}\}$ de $g : \Theta \to \mathbb{R}^d$ est consistante si $\mathbb{P}_{n,\theta}(\|T_n - g(\theta)\| > \varepsilon) \to 0$ pour tout $\theta \in \Theta$ et tout $\varepsilon > 0$ (définition 1.2). Les techniques du chapitre 6 – calcul explicite de la loi de T_n, loi des grands nombres combinée au théorème de continuité lorsque T_n est une fonction continue d'une moyenne empirique, inégalité de Bienaymé-Tchebychev appliquée à un moment de

l'erreur – ne s'appliquent à aucun des estimateurs de ce chapitre, qui ne sont pas des fonctions explicites des observations. La loi des grands nombres va servir tout de même, mais appliquée aux fonctions $\widehat{M}_n$ et $\widehat{\Psi}_n$, et non à l'estimateur.

La version de la loi des grands nombres qu'on emploiera ici ne demande que l'intégrabilité des variables, et non l'existence d'un moment d'ordre deux comme celle du chapitre 6. Elle est rappelée dans les outils (Section 2.1).

Consistance des M-estimateurs

Intuition. *Fixons $\theta^\star$ et θ. La loi des grands nombres donne $\widehat{M}_n(\theta) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \mathsf{M}_{\theta^\star}(\theta)$. Comme $\hat{\theta}_n$ maximise $\widehat{M}_n$ et $\theta^\star$ maximise $\mathsf{M}_{\theta^\star}$, il est tentant d'en conclure que $\hat{\theta}_n$ s'approche de $\theta^\star$. L'argument est incomplet : la convergence obtenue est une convergence* simple*, un θ à la fois, et rien n'empêche $\widehat{M}_n$ de prendre, loin de $\theta^\star$, des valeurs plus grandes que $\widehat{M}_n(\theta^\star)$ sur des événements dont la probabilité ne tend pas vers zéro. Le théorème ci-dessous remplace la convergence simple par une convergence uniforme en θ, et ajoute que le maximum de la fonction limite est isolé.*

L'énoncé est écrit pour une suite quelconque de fonctions aléatoires $\theta \mapsto \widehat{M}_n(\theta)$ et une suite quelconque de fonctions mesurables $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$: le cas d'une moyenne empirique et d'une espérance en est un cas particulier.

Théorème 1.1: Consistance des M-estimateurs généraux

Pour tout $n \in \mathbb{N}$, soit $\theta \mapsto \widehat{M}_n(\theta)$ une fonction aléatoire définie sur Θ, et pour tout $\theta^\star \in \Theta$, soit $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$ une fonction mesurable sur Θ. Supposons :

(H-1) pour tout $\theta^\star \in \Theta$,

$$\sup_{\theta\in\Theta} \left|\widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta)\right| \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0 \; ;$$

(H-2) pour tout $\theta^\star \in \Theta$ et tout $\varepsilon > 0$,

$$\sup_{\|\theta-\theta^\star\|\geq\varepsilon} \mathsf{M}_{\theta^\star}(\theta) < \mathsf{M}_{\theta^\star}(\theta^\star) \; ;$$

(H-3) la suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est à valeurs dans Θ et vérifie $\widehat{M}_n(\hat{\theta}_n) \geq \widehat{M}_n(\theta)$ pour tout $\theta \in \Theta$.

Alors la suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est consistante :

$$\text{pour tout } \theta^\star \in \Theta \text{ et tout } \varepsilon > 0 \, , \qquad \lim_{n\to\infty} \mathbb{P}_{n,\theta^\star}\left(\left\|\hat{\theta}_n - \theta^\star\right\| > \varepsilon\right) = 0 \, .$$

Démonstration

Soient $\theta^\star \in \Theta$ et $\varepsilon > 0$. Par (H-2), il existe $\eta > 0$ tel que $\mathsf{M}_{\theta^\star}(\theta) \leq \mathsf{M}_{\theta^\star}(\theta^\star) - \eta$ pour tout $\theta \in \Theta$ vérifiant $\|\theta - \theta^\star\| \geq \varepsilon$: il suffit de prendre $\eta := \mathsf{M}_{\theta^\star}(\theta^\star) - \sup_{\|\theta-\theta^\star\|\geq\varepsilon} \mathsf{M}_{\theta^\star}(\theta)$, qui est strictement positif. Comme $\hat{\theta}_n$ est à valeurs dans Θ, on en déduit l'inclusion d'événements

$$\left\{\left\|\hat{\theta}_n - \theta^\star\right\| \geq \varepsilon\right\} \subseteq \left\{\mathsf{M}_{\theta^\star}(\hat{\theta}_n) \leq \mathsf{M}_{\theta^\star}(\theta^\star) - \eta\right\} \, ,$$

et par conséquent

$$\mathbb{P}_{n,\theta^\star}\left(\left\|\hat{\theta}_n - \theta^\star\right\| \geq \varepsilon\right) \leq \mathbb{P}_{n,\theta^\star}\left(\mathsf{M}_{\theta^\star}(\theta^\star) - \mathsf{M}_{\theta^\star}(\hat{\theta}_n) \geq \eta\right) \, .$$

Il reste à majorer $\mathsf{M}_{\theta^\star}(\theta^\star) - \mathsf{M}_{\theta^\star}(\hat{\theta}_n)$. Cette quantité est positive, puisque $\mathsf{M}_{\theta^\star}$ atteint son

maximum en $\theta^\star$, et

$$\mathsf{M}_{\theta^\star}(\theta^\star) - \mathsf{M}_{\theta^\star}(\hat\theta_n) = \underbrace{\mathsf{M}_{\theta^\star}(\theta^\star) - \widehat{M}_n(\theta^\star)}_{(a)} + \underbrace{\widehat{M}_n(\theta^\star) - \widehat{M}_n(\hat\theta_n)}_{(b)} + \underbrace{\widehat{M}_n(\hat\theta_n) - \mathsf{M}_{\theta^\star}(\hat\theta_n)}_{(c)} .$$

Le terme (b) est négatif ou nul par (H-3), et les termes (a) et (c) sont majorés chacun par $\sup_{\theta\in\Theta} |\widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta)|$. Ainsi

$$0 \le \mathsf{M}_{\theta^\star}(\theta^\star) - \mathsf{M}_{\theta^\star}(\hat\theta_n) \le 2 \sup_{\theta\in\Theta} \left| \widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta) \right| ,$$

d'où

$$\mathbb{P}_{n,\theta^\star}\left(\left\| \hat\theta_n - \theta^\star \right\| \ge \varepsilon \right) \le \mathbb{P}_{n,\theta^\star}\left(\sup_{\theta\in\Theta} \left| \widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta) \right| \ge \eta/2 \right) \xrightarrow[n\to\infty]{} 0$$

par (H-1). □

Complément, hors programme. L'hypothèse (H-3) suppose que $\hat\theta_n$ maximise exactement $\widehat{M}_n$. En pratique, le problème d'optimisation est résolu numériquement et l'on ne dispose que d'une solution approchée, dont on sait contrôler l'erreur. Le polycopié d'origine énonce le théorème sous une hypothèse qui couvre ce cas ; elle est reprise dans les compléments (Section 4.1).

Les deux hypothèses (H-1) et (H-2) ne sont pas vérifiables directement ; les deux résultats qui suivent en donnent des conditions suffisantes dans le cas, de loin le plus fréquent, où $\widehat{M}_n$ est une moyenne empirique.

Une condition suffisante pour (H-1) : la loi uniforme des grands nombres. Lorsque $\widehat{M}_n(\theta) = n^{-1}\sum_{k=1}^n m(\theta, X_k)$ et $\mathsf{M}_{\theta^\star}(\theta) = \mathbb{E}_{\theta^\star}[m(\theta, X_1)]$, la convergence uniforme demandée par (H-1) est fournie par le théorème suivant, à condition que l'espace des paramètres soit compact.

Théorème 1.2: Loi des grands nombres uniforme

Soit K un sous-ensemble compact de $\mathbb{R}^d$, soit $\Theta \subseteq K$ et soit $\phi : K \times \mathsf{X} \to \mathbb{R}$. Supposons :

(i) pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto \phi(\theta, x)$ est continue sur K ;

(ii) pour tout $\theta^\star \in \Theta$,

$$\int \sup_{\theta\in K} |\phi(\theta, x)| \, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty .$$

Posons, pour $\theta \in K$, $\theta^\star \in \Theta$ et $n \ge 1$,

$$\widehat{W}_n(\theta) := \frac{1}{n}\sum_{i=1}^n \phi(\theta, X_i) , \qquad \mathsf{W}_{\theta^\star}(\theta) := \mathbb{E}_{\theta^\star}\left[\phi(\theta, X_1)\right] .$$

Alors, pour tout $\theta^\star \in \Theta$,

$$\sup_{\theta\in K} \left| \widehat{W}_n(\theta) - \mathsf{W}_{\theta^\star}(\theta) \right| \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0 .$$

Démonstration

Soient $\theta^\star \in \Theta$ et $\varepsilon > 0$. Reprenons le module de continuité

$$w_\delta(x) := \sup_{\{\theta,\vartheta\in K\,:\,\|\theta-\vartheta\|\le\delta\}} |\phi(\theta,x)-\phi(\vartheta,x)| \ , \qquad \delta>0 \ ,$$

introduit au lemme 2.1, qui montre sous les hypothèses (i) et (ii) que $\mathsf{W}_{\theta^\star}$ est continue sur K et que $\int w_\delta \mathrm{d}\mathbb{Q}_{\theta^\star} \to 0$ quand $\delta \to 0^+$. Fixons $\delta > 0$ tel que

$$\int w_\delta(x)\, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) \le \varepsilon/4 \ .$$

L'ensemble K est compact, donc du recouvrement $\bigcup_{\theta\in K} \mathrm{B}(\theta,\delta)$ on peut extraire un sous-recouvrement fini : il existe $L \in \mathbb{N}$ et $\theta^{(1)},\dots,\theta^{(L)} \in K$ tels que $K \subseteq \bigcup_{\ell=1}^{L} \mathrm{B}(\theta^{(\ell)},\delta)$. On a alors

$$\sup_{\theta\in K} \left|\widehat{W}_n(\theta) - \mathsf{W}_{\theta^\star}(\theta)\right| = \max_{1\le\ell\le L} \sup_{\theta\in \mathrm{B}(\theta^{(\ell)},\delta)\cap K} \left|\widehat{W}_n(\theta) - \mathsf{W}_{\theta^\star}(\theta)\right| \ .$$

Soit $\ell \in \{1,\dots,L\}$. Pour $\theta \in \mathrm{B}(\theta^{(\ell)},\delta)\cap K$, l'inégalité triangulaire donne

$$\begin{aligned}\left|\widehat{W}_n(\theta) - \mathsf{W}_{\theta^\star}(\theta)\right| \le{}& \left|\widehat{W}_n(\theta) - \widehat{W}_n(\theta^{(\ell)})\right| \\ &+ \left|\widehat{W}_n(\theta^{(\ell)}) - \mathsf{W}_{\theta^\star}(\theta^{(\ell)})\right| + \left|\mathsf{W}_{\theta^\star}(\theta^{(\ell)}) - \mathsf{W}_{\theta^\star}(\theta)\right| \ .\end{aligned}$$

Le troisième terme se majore sans aléa : pour $\left\|\theta-\theta^{(\ell)}\right\| \le \delta$,

$$\left|\mathsf{W}_{\theta^\star}(\theta^{(\ell)}) - \mathsf{W}_{\theta^\star}(\theta)\right| \le \mathbb{E}_{\theta^\star}\left[\left|\phi(\theta^{(\ell)},X_1) - \phi(\theta,X_1)\right|\right] \le \mathbb{E}_{\theta^\star}\left[w_\delta(X_1)\right] \le \varepsilon/4 \ .$$

Le premier terme se majore par une moyenne empirique du module de continuité :

$$\sup_{\theta\in \mathrm{B}(\theta^{(\ell)},\delta)\cap K} \left|\widehat{W}_n(\theta) - \widehat{W}_n(\theta^{(\ell)})\right| \le \frac{1}{n}\sum_{i=1}^n \sup_{\theta\in \mathrm{B}(\theta^{(\ell)},\delta)\cap K} \left|\phi(\theta,X_i) - \phi(\theta^{(\ell)},X_i)\right| \le \frac{1}{n}\sum_{i=1}^n w_\delta(X_i) \ ,$$

majoration qui ne dépend plus de ℓ. Les variables $w_\delta(X_i)$ sont indépendantes, de même loi et intégrables, puisque $w_\delta \le 2\sup_{\theta\in K}|\phi(\theta,\cdot)|$; la loi faible des grands nombres (théorème 2.1) donne donc

$$\frac{1}{n}\sum_{i=1}^n w_\delta(X_i) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \mathbb{E}_{\theta^\star}\left[w_\delta(X_1)\right] \le \varepsilon/4 \ ,$$

d'où $\lim_n \mathbb{P}_{n,\theta^\star}\left(n^{-1}\sum_{i=1}^n w_\delta(X_i) \ge \varepsilon/2\right) = 0$. Le second terme se traite par la même loi des grands nombres, appliquée pour chacun des L points $\theta^{(\ell)}$, qui sont en nombre fini :

$$\max_{1\le\ell\le L} \left|\widehat{W}_n(\theta^{(\ell)}) - \mathsf{W}_{\theta^\star}(\theta^{(\ell)})\right| \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0 \ .$$

En rassemblant les trois majorations,

$$\begin{aligned}\mathbb{P}_{n,\theta^\star}\left(\sup_{\theta\in K}\left|\widehat{W}_n(\theta) - \mathsf{W}_{\theta^\star}(\theta)\right| \ge \varepsilon\right) \le{}& \mathbb{P}_{n,\theta^\star}\left(\frac{1}{n}\sum_{i=1}^n w_\delta(X_i) \ge \frac{\varepsilon}{2}\right) \\ &+ \mathbb{P}_{n,\theta^\star}\left(\max_{1\le\ell\le L}\left|\widehat{W}_n(\theta^{(\ell)}) - \mathsf{W}_{\theta^\star}(\theta^{(\ell)})\right| \ge \frac{\varepsilon}{4}\right) \ ,\end{aligned}$$

et les deux termes du membre de droite tendent vers zéro. □

Intuition. *La compacité intervient deux fois, et de deux façons différentes. Elle permet de recouvrir Θ par un nombre* fini *de boules de rayon δ, donc de ramener un supremum sur un continuum à un maximum sur une liste finie de points, pour lequel la loi des grands nombres s'applique terme à terme. Elle assure par ailleurs, par le théorème de Heine, la continuité uniforme de $\theta \mapsto \phi(\theta, x)$, qui fait tendre le module de continuité vers zéro et contrôle ce qui se passe à l'intérieur de chaque boule. Sans compacité, le nombre de boules explose et la seconde majoration tombe.*

Une condition suffisante pour (H-2). La seconde hypothèse du théorème 1.1 demande que le maximum de $\mathsf{M}_{\theta^\star}$ soit isolé. Sur un compact, la stricte inégalité ponctuelle suffit.

Lemme 1.1: Maximum isolé sur un compact

Supposons que Θ est un compact de $\mathbb{R}^d$ et que, pour tout $\theta^\star \in \Theta$,

(i) la fonction $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$ est continue sur Θ ;

(ii) pour tout $\theta \in \Theta$ avec $\theta \neq \theta^\star$, on a $\mathsf{M}_{\theta^\star}(\theta) < \mathsf{M}_{\theta^\star}(\theta^\star)$.

Alors l'hypothèse (H-2) du théorème 1.1 est vérifiée.

Démonstration

Soient $\theta^\star \in \Theta$ et $\varepsilon > 0$. L'ensemble $\Theta \setminus \mathrm{B}(\theta^\star, \varepsilon)$ est fermé dans le compact Θ, donc compact. S'il est vide, le supremum à majorer vaut $-\infty$ et il n'y a rien à démontrer. Sinon, la fonction continue $\mathsf{M}_{\theta^\star}$ y atteint son maximum en un point $\theta_\varepsilon \neq \theta^\star$, et

$$\sup_{\|\theta - \theta^\star\| \geq \varepsilon} \mathsf{M}_{\theta^\star}(\theta) = \mathsf{M}_{\theta^\star}(\theta_\varepsilon) < \mathsf{M}_{\theta^\star}(\theta^\star) \, ,$$

par l'hypothèse (ii). □

Le théorème 1.1, le théorème 1.2 et le lemme 1.1 se combinent en un énoncé directement vérifiable.

Corollaire 1.1: Consistance d'un M-estimateur, cas compact

Supposons que Θ est un compact de $\mathbb{R}^d$ et que :

(i) pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto m(\theta, x)$ est continue sur Θ ;

(ii) pour tout $\theta^\star \in \Theta$, $\displaystyle\int \sup_{\theta \in \Theta} |m(\theta, x)| \, \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$;

(iii) pour tous $\theta, \theta^\star \in \Theta$ avec $\theta \neq \theta^\star$, on a $\mathsf{M}_{\theta^\star}(\theta) < \mathsf{M}_{\theta^\star}(\theta^\star)$.

Alors toute suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ de M-estimateurs associés à m au sens de la définition 1.1 est consistante.

Démonstration

Les hypothèses (i) et (ii) sont celles du théorème 1.2 avec $K = \Theta$ et $\phi = m$, qui donne (H-1). Le lemme 2.1 assure la continuité de $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta)$, et l'hypothèse (iii) permet alors d'appliquer le lemme 1.1, qui donne (H-2). L'hypothèse (H-3) est la définition même d'un M-estimateur. Le théorème 1.1 conclut. □

Exemple 1.5: Consistance de l'estimateur des moindres carrés dans un modèle de translation

Reprenons le modèle de translation de l'exemple 1.2, où q est une densité sur $\mathbb{R}$ telle que $\int x\, q(x)\mathrm{d}x = 0$ et $\sigma^2 := \int x^2 q(x)\mathrm{d}x < \infty$, et supposons que Θ est un segment borné de $\mathbb{R}$. Le M-estimateur considéré est celui associé à $m(\theta, x) := -(x-\theta)^2$, pour lequel

$$\mathsf{M}_{\theta^\star}(\theta) = -\int (x-\theta)^2 q(x-\theta^\star)\mathrm{d}x = -\sigma^2 - (\theta^\star - \theta)^2 \,,$$

et la fonction $\theta \mapsto \widehat{M}_n(\theta) = -n^{-1}\sum_{i=1}^n (X_i - \theta)^2$ admet l'unique maximum $\hat{\theta}_n = \bar{X}_n$. Plutôt que d'invoquer le théorème 1.2, on peut ici établir la convergence uniforme directement. En écrivant $X_i - \theta = (X_i - \theta^\star) + (\theta^\star - \theta)$,

$$\begin{aligned}\widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta) &= -\frac{1}{n}\sum_{i=1}^n \{(X_i - \theta^\star) + (\theta^\star - \theta)\}^2 + \sigma^2 + (\theta - \theta^\star)^2 \\ &= -\left\{\frac{1}{n}\sum_{i=1}^n (X_i - \theta^\star)^2 - \sigma^2\right\} + 2(\theta - \theta^\star)\left\{\frac{1}{n}\sum_{i=1}^n X_i - \theta^\star\right\} \,,\end{aligned}$$

d'où

$$\sup_{\theta\in\Theta}\left|\widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta)\right| \le \left|\frac{1}{n}\sum_{i=1}^n (X_i - \theta^\star)^2 - \sigma^2\right| + 2\,\mathrm{diam}(\Theta)\left|\frac{1}{n}\sum_{i=1}^n X_i - \theta^\star\right| \,,$$

où $\mathrm{diam}(\Theta)$ est le diamètre de Θ. Sous $\mathbb{P}_{n,\theta^\star}$, les variables $X_i - \theta^\star$ sont indépendantes, de densité q, d'espérance nulle et de variance σ^2 ; la loi faible des grands nombres donne la convergence en probabilité vers zéro de chacun des deux termes du membre de droite, donc du membre de gauche. L'hypothèse (H-2) résulte du lemme 1.1, et l'hypothèse (H-3) de la définition de $\hat{\theta}_n$: la suite $\{\bar{X}_n, n \in \mathbb{N}\}$ est consistante.

Le caractère borné de Θ est ici essentiel : c'est lui qui transforme le facteur $|\theta - \theta^\star|$ du second terme en une constante, et donc une convergence simple en une convergence uniforme. Employer le théorème général sur cet exemple est évidemment maladroit, puisque $\hat{\theta}_n = \bar{X}_n$ est explicite et que sa consistance se lit directement sur la loi des grands nombres. Le théorème 1.1 prend son sens dans les modèles où le M-estimateur n'a pas d'expression explicite, ce qui est le cas le plus fréquent.

Consistance des Z-estimateurs

La consistance des Z-estimateurs se déduit de celle des M-estimateurs par un changement de fonction objectif : annuler $\widehat{\Psi}_n$, c'est maximiser $-\left\|\widehat{\Psi}_n\right\|$.

Théorème 1.3: Consistance des Z-estimateurs

Pour tout $n \in \mathbb{N}$, soit $\theta \mapsto \widehat{\Psi}_n(\theta)$ une fonction aléatoire définie sur Θ et à valeurs dans $\mathbb{R}^d$, et pour tout $\theta^\star \in \Theta$, soit $\theta \mapsto \Psi_{\theta^\star}(\theta)$ une fonction mesurable. Supposons :

(Hz-1) pour tout $\theta^\star \in \Theta$,
$$\sup_{\theta\in\Theta} \left\| \widehat{\Psi}_n(\theta) - \Psi_{\theta^\star}(\theta) \right\| \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0 \; ;$$

(Hz-2) pour tout $\theta^\star \in \Theta$, $\Psi_{\theta^\star}(\theta^\star) = 0$ et, pour tout $\varepsilon > 0$,
$$\inf_{\|\theta-\theta^\star\|\geq\varepsilon} \|\Psi_{\theta^\star}(\theta)\| > 0 \; ;$$

(Hz-3) la suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est à valeurs dans Θ et vérifie $\widehat{\Psi}_n(\hat{\theta}_n) = 0$.

Alors la suite $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est consistante.

Démonstration

Posons $\widehat{M}_n(\theta) := -\left\|\widehat{\Psi}_n(\theta)\right\|$ et $\mathsf{M}_{\theta^\star}(\theta) := -\|\Psi_{\theta^\star}(\theta)\|$, et vérifions les trois hypothèses du théorème 1.1. La seconde inégalité triangulaire donne, pour tout $\theta \in \Theta$,
$$\left|\widehat{M}_n(\theta) - \mathsf{M}_{\theta^\star}(\theta)\right| = \left|\|\Psi_{\theta^\star}(\theta)\| - \left\|\widehat{\Psi}_n(\theta)\right\|\right| \leq \left\|\widehat{\Psi}_n(\theta) - \Psi_{\theta^\star}(\theta)\right\| \; ,$$
de sorte que (Hz-1) entraîne (H-1). Par (Hz-2), $\mathsf{M}_{\theta^\star}(\theta^\star) = 0$ et, pour tout $\varepsilon > 0$,
$$\sup_{\|\theta-\theta^\star\|\geq\varepsilon} \mathsf{M}_{\theta^\star}(\theta) = -\inf_{\|\theta-\theta^\star\|\geq\varepsilon} \|\Psi_{\theta^\star}(\theta)\| < 0 = \mathsf{M}_{\theta^\star}(\theta^\star) \; ,$$
ce qui est (H-2). Enfin $\widehat{M}_n(\hat{\theta}_n) = 0 \geq \widehat{M}_n(\theta)$ pour tout $\theta \in \Theta$ par (Hz-3), ce qui est (H-3). Le théorème 1.1 conclut. □

Le théorème 1.2, appliqué coordonnée par coordonnée à $\phi = \psi_j$ pour $1 \leq j \leq d$, donne l'hypothèse (Hz-1) lorsque Θ est compact, que $\theta \mapsto \psi(\theta, x)$ est continue et que
$$\int \sup_{\theta\in\Theta} \|\psi(\theta, x)\| \; \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty \; .$$

1.5 Loi limite des Z-estimateurs

La consistance dit que l'erreur $\hat{\theta}_n - \theta^\star$ tend vers zéro ; elle ne dit rien de sa taille. On cherche maintenant une normalisation $\alpha_n \to \infty$ telle que $\alpha_n(\hat{\theta}_n - \theta^\star)$ converge en loi vers une limite non dégénérée. Comme au chapitre 6, cette normalisation sera $\sqrt{n}$ et cette limite une gaussienne centrée, dont la variance mesurera la précision de l'estimateur. Tout ce paragraphe se place dans le cas scalaire $d = 1$, soit $\Theta \subseteq \mathbb{R}$, et l'on note $\psi'(\theta, x)$ la dérivée de $\theta \mapsto \psi(\theta, x)$; le cas vectoriel figure dans les compléments (Section 4.4).

L'identité clé et les trois convergences

Soit $\{\hat{\theta}_n, n \in \mathbb{N}\}$ une suite consistante de Z-estimateurs associés à ψ, de sorte que $\widehat{\Psi}_n(\hat{\theta}_n) = 0$. Supposons $\theta \mapsto \psi(\theta, x)$ continûment différentiable au voisinage de $\theta^\star$. La formule de Taylor avec reste intégral (Section 2.3) donne, pour θ dans ce voisinage,
$$\psi(\theta, x) = \psi(\theta^\star, x) + \psi'(\theta^\star, x)\,(\theta - \theta^\star) + r(\theta - \theta^\star, x)\,(\theta - \theta^\star) \; , \tag{1}$$

où

$$r(t,x) := \int_0^1 \{\psi'(\theta^\star + wt, x) - \psi'(\theta^\star, x)\}\,\mathrm{d}w\ . \tag{2}$$

En appliquant (1) en $\theta = \hat\theta_n$ et en $x = X_i$, puis en sommant sur i, il vient

$$0 = \widehat\Psi_n(\hat\theta_n) = \widehat\Psi_n(\theta^\star) + \left\{\widehat\Psi_n'(\theta^\star) + R_n\right\}(\hat\theta_n - \theta^\star)\ , \qquad R_n := \frac{1}{n}\sum_{i=1}^n r(\hat\theta_n - \theta^\star, X_i)\ ,$$

et, en multipliant par $\sqrt{n}$ et en divisant par le facteur entre accolades,

$$\sqrt{n}\left(\hat\theta_n - \theta^\star\right) = \frac{-\sqrt{n}\,\widehat\Psi_n(\theta^\star)}{\widehat\Psi_n'(\theta^\star) + R_n}\ . \tag{3}$$

Le membre de droite se lit comme un quotient de trois quantités dont on sait étudier le comportement séparément.

Intuition. *L'identité (3) dit que l'erreur d'estimation est le quotient de deux choses : au numérateur, l'écart entre l'équation d'estimation empirique et l'équation d'estimation théorique, évalué à la vraie valeur du paramètre ; au dénominateur, la pente de l'équation d'estimation en ce point. Plus la fonction $\theta \mapsto \Psi_{\theta^\star}(\theta)$ traverse zéro avec une pente raide, plus une perturbation donnée du membre de gauche de l'équation déplace peu sa solution. C'est ce que dit la variance asymptotique $\mathbb{E}_\theta^\star[\psi^2]/(\mathbb{E}_\theta^\star[\psi'])^2$: la pente au carré est au dénominateur. L'écriture (3) suppose que $\hat\theta_n$ appartient au voisinage où le développement de Taylor est valide et que le dénominateur ne s'annule pas ; la démonstration du théorème 1.4 ne fait pas cette division et procède autrement.*

Le numérateur. Comme $\mathbb{E}_{\theta^\star}[\psi(\theta^\star, X_1)] = 0$ par définition d'un Z-estimateur,

$$\sqrt{n}\,\widehat\Psi_n(\theta^\star) = \sqrt{n}\left(\frac{1}{n}\sum_{i=1}^n \psi(\theta^\star, X_i) - \mathbb{E}_{\theta^\star}\left[\psi(\theta^\star, X_1)\right]\right)\ ,$$

et si $\mathbb{E}_{\theta^\star}[\psi^2(\theta^\star, X_1)] < \infty$, le théorème de la limite centrale (théorème 1.6) donne

$$\sqrt{n}\,\widehat\Psi_n(\theta^\star) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \mathbb{E}_{\theta^\star}\left[\psi^2(\theta^\star, X_1)\right]\right)\ .$$

Le dénominateur. On a $\widehat\Psi_n'(\theta^\star) = n^{-1}\sum_{k=1}^n \psi'(\theta^\star, X_k)$. Si $\mathbb{E}_{\theta^\star}[|\psi'(\theta^\star, X_1)|] < \infty$, la loi faible des grands nombres (théorème 2.1) donne

$$\widehat\Psi_n'(\theta^\star) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} \mathbb{E}_{\theta^\star}\left[\psi'(\theta^\star, X_1)\right]\ ,$$

et l'on suppose cette limite non nulle.

Le reste. Il faut montrer que $R_n \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$. Pour $\delta > 0$,

$$\{|R_n| \geq \varepsilon\} \subseteq \left\{|R_n| \geq \varepsilon, |\hat\theta_n - \theta^\star| \leq \delta\right\} \cup \left\{|\hat\theta_n - \theta^\star| > \delta\right\}\ ,$$

et le second événement est de probabilité tendant vers zéro par consistance. Sur le premier,

$$|R_n| \leq \frac{1}{n}\sum_{i=1}^n \sup_{|\theta-\theta^\star|\leq\delta} |\psi'(\theta, X_i) - \psi'(\theta^\star, X_i)|\ .$$

Sous l'hypothèse de domination $\sup_{\theta\in\mathcal{V}(\theta^\star)} |\psi'(\theta, x)| \leq g(x)$ avec $\mathbb{E}_{\theta^\star}[g(X_1)] < \infty$, le théorème de convergence dominée donne

$$\lim_{\delta\to 0} \mathbb{E}_{\theta^\star}\left[\sup_{|\theta-\theta^\star|\leq\delta} |\psi'(\theta, X_1) - \psi'(\theta^\star, X_1)|\right] = 0\ ,$$

ce qui permet, en choisissant δ assez petit puis en appliquant l'inégalité de Markov, de rendre la probabilité du premier événement arbitrairement petite.

L'énoncé

Théorème 1.4: Normalité asymptotique des Z-estimateurs, cas scalaire

Soit $\Theta \subseteq \mathbb{R}$ et soit $\{\hat{\theta}_n, n \in \mathbb{N}\}$ une suite consistante de Z-estimateurs associés à $\psi : \Theta \times \mathsf{X} \to \mathbb{R}$. Supposons que, pour tout $\theta^\star \in \Theta^o$:

(i) $\mathbb{E}_{\theta^\star}\left[\psi(\theta^\star, X_1)\right] = 0$ et $\mathbb{E}_{\theta^\star}\left[\psi^2(\theta^\star, X_1)\right] < \infty$;

(ii) il existe un voisinage $\mathcal{V}(\theta^\star) \subseteq \Theta$ de $\theta^\star$ tel que, pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto \psi(\theta, x)$ soit continûment différentiable sur $\mathcal{V}(\theta^\star)$, et il existe une fonction mesurable g telle que

$$\sup_{\theta \in \mathcal{V}(\theta^\star)} |\psi'(\theta, x)| \leq g(x) \quad \text{pour tout } x \in \mathsf{X}\,, \qquad \mathbb{E}_{\theta^\star}\left[g(X_1)\right] < \infty\,;$$

(iii) $\mathbb{E}_{\theta^\star}\left[\psi'(\theta^\star, X_1)\right] \neq 0$.

Alors, pour tout $\theta^\star \in \Theta^o$,

$$\sqrt{n}\left(\hat{\theta}_n - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, v_\psi(\theta^\star)\right)\,, \qquad v_\psi(\theta) := \frac{\mathbb{E}_\theta\left[\psi^2(\theta, X_1)\right]}{\left(\mathbb{E}_\theta\left[\psi'(\theta, X_1)\right]\right)^2}\,.$$

Démonstration

Soit $\theta^\star \in \Theta^o$. Le reste intégral r défini en (2) vérifie, pour $\delta > 0$ tel que $[\theta^\star - \delta, \theta^\star + \delta] \subseteq \mathcal{V}(\theta^\star)$,

$$R_\delta(x) := \sup_{|t| \leq \delta} |r(t, x)| \leq 2g(x)\,, \qquad \lim_{\delta \to 0} R_\delta(x) = 0\,,$$

la seconde limite venant de la continuité de $\theta \mapsto \psi'(\theta, x)$ en $\theta^\star$. Le théorème de convergence dominée donne donc

$$\lim_{\delta \to 0} \mathbb{E}_{\theta^\star}\left[R_\delta(X_1)\right] = 0\,. \tag{4}$$

En appliquant (1) à chaque observation, on a, pour tout t tel que $\theta^\star + t \in \mathcal{V}(\theta^\star)$,

$$\widehat{\Psi}_n(\theta^\star + t) = \frac{1}{n}\sum_{i=1}^n \psi(\theta^\star, X_i) + t\,\mathbb{E}_{\theta^\star}\left[\psi'(\theta^\star, X_1)\right] + t\,R_n(t)\,, \tag{5}$$

où $R_n(t) := R_n^{(1)} + R_n^{(2)}(t)$ avec

$$R_n^{(1)} := \frac{1}{n}\sum_{i=1}^n \left\{\psi'(\theta^\star, X_i) - \mathbb{E}_{\theta^\star}\left[\psi'(\theta^\star, X_1)\right]\right\}\,, \qquad R_n^{(2)}(t) := \frac{1}{n}\sum_{i=1}^n r(t, X_i)\,.$$

Les variables $\psi'(\theta^\star, X_i)$ sont indépendantes, de même loi et intégrables par (ii) ; la loi faible des grands nombres (théorème 2.1) donne

$$R_n^{(1)} \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0\,. \tag{6}$$

Soit $\{\delta_n,\ n \in \mathbb{N}\}$ une suite positive de limite nulle. Comme $\sup_{|t| \leq \delta_n} |R_n^{(2)}(t)| \leq n^{-1}\sum_{i=1}^n R_{\delta_n}(X_i)$ et que $\mathbb{E}_{n,\theta^\star}\left[n^{-1}\sum_{i=1}^n R_{\delta_n}(X_i)\right] = \mathbb{E}_{\theta^\star}[R_{\delta_n}(X_1)]$, l'inégalité de Markov (lemme 2.1) et (4) donnent

$$\sup_{|t| \leq \delta_n} \left|R_n^{(2)}(t)\right| \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0\,. \tag{7}$$

Posons $\Delta_n := \hat\theta_n - \theta^\star$. La suite $\{\hat\theta_n, n \in \mathbb{N}\}$ étant consistante, il existe une suite $\{\delta_n,\ n \in \mathbb{N}\}$ de limite nulle telle que $\lim_n \mathbb{P}_{n,\theta^\star}(|\Delta_n| \geq \delta_n) = 0$; quitte à la diminuer, on la choisit telle que $[\theta^\star - \delta_n, \theta^\star + \delta_n] \subseteq \mathcal{V}(\theta^\star)$ pour tout n. Pour tout $\varepsilon > 0$,

$$\mathbb{P}_{n,\theta^\star}\left(\left|R_n^{(2)}(\Delta_n)\right| \geq \varepsilon\right) \leq \mathbb{P}_{n,\theta^\star}\left(\sup_{|t|\leq\delta_n}\left|R_n^{(2)}(t)\right| \geq \varepsilon\right) + \mathbb{P}_{n,\theta^\star}\left(|\Delta_n| \geq \delta_n\right)\ ,$$

donc $R_n^{(2)}(\Delta_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$ et, avec (6),

$$R_n(\Delta_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0\ . \tag{8}$$

Sur l'événement $\{|\Delta_n| \leq \delta_n\}$, dont la probabilité tend vers 1, l'identité (5) s'applique avec $t = \Delta_n$ et $\widehat\Psi_n(\hat\theta_n) = 0$, ce qui donne

$$0 = \frac{1}{\sqrt{n}}\sum_{i=1}^n \psi(\theta^\star, X_i) + \sqrt{n}\left(\hat\theta_n - \theta^\star\right)\left\{\mathbb{E}_{\theta^\star}\left[\psi'(\theta^\star, X_1)\right] + R_n(\Delta_n)\right\}\ . \tag{9}$$

Le théorème de la limite centrale (théorème 1.6) et l'hypothèse (i) donnent

$$\frac{1}{\sqrt{n}}\sum_{i=1}^n \psi(\theta^\star, X_i) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \mathbb{E}_{\theta^\star}\left[\psi^2(\theta^\star, X_1)\right]\right)\ .$$

Par (8) et l'hypothèse (iii), le facteur entre accolades dans (9) converge en probabilité vers $\mathbb{E}_{\theta^\star}[\psi'(\theta^\star, X_1)] \neq 0$. Le lemme de Slutsky (lemme 1.1) et le théorème de transformation continue (théorème 1.4) appliqué à $(u, c) \mapsto -u/c$ au voisinage de $c = \mathbb{E}_{\theta^\star}[\psi'(\theta^\star, X_1)]$ donnent alors la conclusion. □

Deux remarques sur les hypothèses. Le jeu d'hypothèses est *local* : il porte sur le comportement de ψ au voisinage de chaque $\theta^\star$ intérieur à Θ, ce qui exclut les valeurs du paramètre situées sur la frontière lorsque Θ n'est pas ouvert. L'exercice 4 de la feuille de ce chapitre montre sur le modèle $\mathcal{N}(\theta, 1)$ avec $\Theta = \mathbb{R}_+$ que la conclusion tombe en $\theta = 0$.
L'hypothèse (ii) de différentiabilité n'est pas vérifiée par $\psi(\theta, x) = \text{signe}(x - \theta)$, donc par la médiane empirique. La normalité asymptotique de la médiane s'établit par d'autres moyens, à partir de la loi des statistiques d'ordre ; elle est rappelée dans les compléments (Section 4.8).

Complément, hors programme. La démonstration n'utilise $\widehat\Psi_n(\hat\theta_n) = 0$ qu'à travers l'identité (9) : elle vaut telle quelle sous l'hypothèse plus faible $\sqrt{n}\,\widehat\Psi_n(\hat\theta_n) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$, qui autorise les solutions approchées de l'équation d'estimation. C'est sous cette forme que le théorème II-2.15 du polycopié d'origine est énoncé.

Intuition. *Le théorème dit aussi que $n^{-1/2}$ est le bon ordre de grandeur de l'erreur. Si l'on normalise par une autre suite $\alpha_n \to \infty$, alors $\alpha_n(\hat\theta_n - \theta^\star) = (\alpha_n/\sqrt{n}) \cdot \sqrt{n}(\hat\theta_n - \theta^\star)$ tend vers zéro en probabilité lorsque $\alpha_n/\sqrt{n} \to 0$, et devient arbitrairement grande, au sens où $\liminf_n \mathbb{P}_{n,\theta^\star}(|\alpha_n(\hat\theta_n - \theta^\star)| \geq M) > 0$ pour tout M, lorsque $\alpha_n/\sqrt{n} \to \infty$. Seule la normalisation en $\sqrt{n}$ donne une limite non dégénérée.*

1.6 Loi limite des M-estimateurs

La loi limite des M-estimateurs s'obtient de celle des Z-estimateurs par la relation $\psi = m'$, pourvu que l'on sache que cette fonction d'influence est bien centrée en $\theta^\star$.

Intuition. *Le point $\theta^\star$ maximise $\theta \mapsto \mathsf{M}_{\theta^\star}(\theta) = \mathbb{E}_{\theta^\star}[m(\theta, X_1)]$. Si l'on peut permuter dérivation et*

espérance, la dérivée de cette fonction s'annule en $\theta^\star$, c'est-à-dire

$$\mathbb{E}_{\theta^\star}\left[m'(\theta^\star, X_1)\right] = \partial_\theta \mathbb{E}_{\theta^\star}\left[m(\theta, X_1)\right]|_{\theta=\theta^\star} = 0\,,$$

et $\psi := m'$ vérifie bien la condition de centrage de la définition 1.2. La permutation n'est pas gratuite : elle demande une hypothèse de domination, du type de celle de la proposition 2.2, et $\theta^\star$ doit être intérieur à Θ.

Théorème 1.5: Normalité asymptotique des M-estimateurs, cas scalaire

Soit $\Theta \subseteq \mathbb{R}$ et soit $\{\hat\theta_n, n \in \mathbb{N}\}$ une suite consistante de M-estimateurs associés à $m : \Theta \times \mathsf{X} \to \mathbb{R}$, à valeurs dans Θ^o. Supposons que, pour tout $\theta^\star \in \Theta^o$:

(i) il existe un voisinage $\mathcal{V}(\theta^\star) \subseteq \Theta$ de $\theta^\star$ tel que, pour tout $x \in \mathsf{X}$, la fonction $\theta \mapsto m(\theta, x)$ soit deux fois continûment différentiable sur $\mathcal{V}(\theta^\star)$, et il existe une fonction mesurable g telle que

$$\sup_{\theta \in \mathcal{V}(\theta^\star)} |m''(\theta, x)| \le g(x) \quad \text{pour tout } x \in \mathsf{X}\,, \qquad \mathbb{E}_{\theta^\star}\left[g(X_1)\right] < \infty\,;$$

(ii) $\mathbb{E}_{\theta^\star}\left[m'(\theta^\star, X_1)\right] = 0$ et $0 < \mathbb{E}_{\theta^\star}\left[m'(\theta^\star, X_1)^2\right] < \infty$;

(iii) $\mathbb{E}_{\theta^\star}\left[m''(\theta^\star, X_1)\right] \neq 0$.

Alors, pour tout $\theta^\star \in \Theta^o$,

$$\sqrt{n}\left(\hat\theta_n - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \frac{\mathbb{E}_{\theta^\star}\left[m'(\theta^\star, X_1)^2\right]}{\left\{\mathbb{E}_{\theta^\star}\left[m''(\theta^\star, X_1)\right]\right\}^2}\right)\,.$$

Démonstration

Posons $\psi(\theta, x) := m'(\theta, x)$, de sorte que $\psi'(\theta, x) = m''(\theta, x)$. Comme $\hat\theta_n \in \Theta^o$ maximise $\widehat{M}_n$, la proposition 1.1 montre que $\widehat{\Psi}_n(\hat\theta_n) = 0$, c'est-à-dire que $\{\hat\theta_n, n \in \mathbb{N}\}$ est une suite consistante de Z-estimateurs associés à ψ. Les hypothèses (i), (ii) et (iii) sont les hypothèses (i), (ii) et (iii) du théorème 1.4 pour cette fonction ψ, dont la conclusion est celle annoncée. □

1.7 Application à l'estimateur du maximum de vraisemblance

L'estimateur du maximum de vraisemblance est le M-estimateur associé à la log-vraisemblance et, lorsque celle-ci est dérivable, le Z-estimateur associé au score. Les deux théorèmes qui précèdent s'y appliquent donc, et la variance asymptotique qu'ils produisent prend une forme remarquable.

Score et information de Fisher

Les deux objets sont ceux du chapitre 3, rappelés ici dans le cas scalaire.

Définition 1.3: Fonction score

Soit un modèle dominé $\mathbb{Q}_\theta = q_\theta \cdot \mu$ avec $\Theta \subseteq \mathbb{R}$. Pour $\theta \in \Theta$ et $x \in \mathsf{X}$, on pose $\ell(\theta, x) := \log q_\theta(x)$. Lorsqu'elle existe, la dérivée

$$\dot\ell(\theta, x) := \partial_\theta \log q_\theta(x)$$

s'appelle *fonction score*, ou *score de Fisher*. On note de même $\ddot\ell(\theta, x) := \partial_\theta^2 \log q_\theta(x)$.

Définition 1.4: Information de Fisher

Pour un modèle régulier (définition 1.6) et $\theta \in \Theta$, l'*information de Fisher* est la variance du score :

$$\mathbb{I}(\theta) := \mathbb{E}_\theta \left[\left\{ \dot{\ell}(\theta, X_1) \right\}^2 \right] = \int \left(\dot{\ell}(\theta, x) \right)^2 \mathbb{Q}_\theta(\mathrm{d}x) \; .$$

La proposition 1.2 donne les deux propriétés dont on se servira : dans un modèle régulier, le score est centré,

$$\mathbb{E}_\theta \left[\dot{\ell}(\theta, X_1) \right] = \int \dot{\ell}(\theta, x) \, \mathbb{Q}_\theta(\mathrm{d}x) = 0 \; ,$$

et l'information de Fisher s'exprime aussi à l'aide de la dérivée seconde,

$$\mathbb{I}(\theta) = \mathbb{E}_\theta \left[\left(\dot{\ell}(\theta, X_1) \right)^2 \right] = -\mathbb{E}_\theta \left[\ddot{\ell}(\theta, X_1) \right] \; . \tag{10}$$

Exemple 1.6: Information de Fisher du modèle gaussien

Pour $\mathbb{Q}_\theta = \mathcal{N}(\theta, \sigma^2)$ avec σ^2 connu,

$$\ell(\theta, x) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2}(x-\theta)^2 \; , \qquad \dot{\ell}(\theta, x) = \frac{x-\theta}{\sigma^2} \; , \qquad \ddot{\ell}(\theta, x) = -\frac{1}{\sigma^2} \; ,$$

d'où $\mathbb{I}(\theta) = \sigma^{-2}$.

Exemple 1.7: Information de Fisher du modèle de Poisson

Pour $\mathbb{Q}_\theta = \mathcal{P}\mathrm{oi}(\theta)$ avec $\theta \in \mathbb{R}_+^*$,

$$\ell(\theta, x) = x \log \theta - \theta - \log(x!) \; , \qquad \dot{\ell}(\theta, x) = \frac{x-\theta}{\theta} \; , \qquad \ddot{\ell}(\theta, x) = -\frac{x}{\theta^2} \; ,$$

et comme $\mathbb{E}_\theta[X_1] = \theta$ et $\mathrm{Var}_\theta(X_1) = \theta$, les deux expressions (10) donnent bien la même valeur $\mathbb{I}(\theta) = 1/\theta$.

Consistance de l'estimateur du maximum de vraisemblance

L'exemple 1.1 a établi que l'estimateur du maximum de vraisemblance est le M-estimateur associé à $m(\theta, x) = \ell(\theta, x)$, et que pour tout $\theta^\star \in \Theta$,

$$\mathsf{M}_{\theta^\star}(\theta) = \mathrm{Ent}(q_{\theta^\star}) - \mathrm{KL}(q_{\theta^\star}, q_\theta) \; ,$$

fonction maximale au seul point $\theta = \theta^\star$ lorsque le modèle est identifiable. Le corollaire 1.1 donne donc la consistance de $\{\hat{\theta}_n^{\mathrm{MV}}, n \in \mathbb{N}\}$ dès que Θ est compact, que $\theta \mapsto \log q_\theta(x)$ est continue pour tout x et que $\int \sup_{\theta \in \Theta} |\log q_\theta(x)| \mathbb{Q}_{\theta^\star}(\mathrm{d}x) < \infty$ pour tout $\theta^\star$. Les énoncés précis, dans le cas compact comme dans le cas non compact, figurent dans les compléments (Section 4.3).

Normalité asymptotique de l'estimateur du maximum de vraisemblance

L'estimateur du maximum de vraisemblance est aussi, lorsque la log-vraisemblance est dérivable et que le maximum est intérieur, le Z-estimateur associé à la fonction d'influence

$$\psi(\theta, x) = \dot{\ell}(\theta, x) \; .$$

Le théorème 1.4 donne alors, pour peu que ses hypothèses soient vérifiées,

$$\sqrt{n} \left(\hat{\theta}_n^{\mathrm{MV}} - \theta^\star \right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N} \left(0, \frac{\mathbb{E}_{\theta^\star} \left[\left(\dot{\ell}(\theta^\star, X_1) \right)^2 \right]}{\left\{ \mathbb{E}_{\theta^\star} \left[\ddot{\ell}(\theta^\star, X_1) \right] \right\}^2} \right) \; ,$$

et l'identité (10) fait disparaître l'une des deux espérances : le numérateur vaut $\mathbb{I}(\theta^\star)$ et le dénominateur $\mathbb{I}(\theta^\star)^2$.

Théorème 1.6: Normalité asymptotique du maximum de vraisemblance

Sous les hypothèses du théorème 1.4 appliquées à $\psi = \dot{\ell}$, on a, pour tout $\theta^\star \in \Theta^o$,

$$\sqrt{n}\left(\hat{\theta}_n^{\mathrm{MV}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \frac{1}{\mathbb{I}(\theta^\star)}\right) .$$

Exemple 1.8: Modèle de Poisson

Soit une suite de n-échantillons du modèle de Poisson de paramètre $\theta \in \Theta := \mathbb{R}_+^*$, de fonction de masse $x \mapsto \theta^x \mathrm{e}^{-\theta}/x!$ sur $\mathbb{N}$. Les dérivées de la log-vraisemblance ont été calculées à l'exemple 1.7. La log-vraisemblance normalisée s'écrit

$$\theta \mapsto \frac{1}{n}\sum_{i=1}^n \ell(\theta, X_i) = \bar{X}_n \log\theta - \theta - \frac{1}{n}\log\left(\prod_{i=1}^n X_i!\right) ;$$

c'est une fonction strictement concave de θ sur $\mathbb{R}_+^*$ dès que $\bar{X}_n > 0$, et son unique maximum est atteint en $\bar{X}_n$, de sorte que $\hat{\theta}_n^{\mathrm{MV}} = \bar{X}_n$.
La normalité asymptotique s'obtient ici directement par le théorème de la limite centrale, puisque $\mathrm{Var}_\theta(X_1) = \theta$:

$$\sqrt{n}\left(\hat{\theta}_n^{\mathrm{MV}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}(0, \theta^\star) .$$

Le théorème 1.6 donne le même résultat sans passer par l'expression explicite de l'estimateur, puisque $\mathbb{I}(\theta^\star) = 1/\theta^\star$: la variance asymptotique $\mathbb{I}^{-1}(\theta^\star)$ vaut bien $\theta^\star$.

Optimalité de l'estimateur du maximum de vraisemblance

La variance asymptotique $v_\psi(\theta)$ du théorème 1.4 dépend du choix de la fonction d'influence. Deux Z-estimateurs d'un même paramètre se comparent donc par leurs variances asymptotiques, selon la règle de la proposition 1.3 : celui dont la variance asymptotique est la plus petite a, pour n grand, les intervalles de confiance asymptotiques les plus courts. La question se pose alors de savoir s'il existe un plus petit élément.

Les conditions de régularité sous lesquelles la réponse est oui sont celles de la définition 1.6 du modèle régulier, qu'on réécrit ici dans le cas scalaire.

Cadre 1.1: Conditions de régularité, cas scalaire

Soit Θ un ouvert de $\mathbb{R}$ et $\mathbb{Q}_\theta = q_\theta \cdot \mu$ un modèle dominé. On suppose :

(R-1) pour tout $\theta \in \Theta$ et pour μ-presque tout $x \in \mathsf{X}$, $q_\theta(x) > 0$;

(R-2) pour μ-presque tout $x \in \mathsf{X}$, la fonction $\theta \mapsto q_\theta(x)$ est deux fois continûment différentiable sur Θ, et pour tout $\theta^\star \in \Theta$ il existe un voisinage $\mathcal{V}(\theta^\star)$ de $\theta^\star$ et deux fonctions mesurables positives g et h telles que, pour μ-presque tout $x \in \mathsf{X}$,

$$\sup_{\theta\in\mathcal{V}(\theta^\star)} \left\{ \left|\dot{\ell}(\theta, x)\right|^2 + \left|\ddot{\ell}(\theta, x)\right| \right\} \le h(x) , \qquad \sup_{\theta\in\mathcal{V}(\theta^\star)} q_\theta(x) \le g(x) ,$$

et $\int (1 + h(x))\, g(x)\, \mu(\mathrm{d}x) < \infty$;

(R-3) pour tout $\theta \in \Theta$, $0 < \mathbb{E}_\theta \left[\dot{\ell}^{\,2}(\theta, X_1) \right] < \infty$, c'est-à-dire que l'information de Fisher existe et est inversible.

Théorème 1.7: Optimalité asymptotique du maximum de vraisemblance

Soit une suite de n-échantillons d'un modèle régulier $\{q_\theta \cdot \mu \,:\, \theta \in \Theta\}$, où Θ est un ouvert de $\mathbb{R}$. Alors, pour tout $\theta \in \Theta$,

$$\sqrt{n}\left(\hat{\theta}_n^{\mathrm{MV}} - \theta\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{N}\left(0, \frac{1}{\mathbb{I}(\theta)}\right) .$$

De plus, si $\{\hat{\theta}_n, n \in \mathbb{N}\}$ est une suite consistante de Z-estimateurs associés à une fonction ψ vérifiant les hypothèses du théorème 1.4, de variance asymptotique v_ψ, alors

$$\text{pour tout } \theta \in \Theta\,, \qquad v_\psi(\theta) \geq \frac{1}{\mathbb{I}(\theta)} .$$

Autrement dit, pour un modèle statistique régulier, l'estimateur du maximum de vraisemblance est asymptotiquement optimal, ou *asymptotiquement efficace*, dans la classe des Z-estimateurs.

Le second point du théorème se démontre par l'inégalité de Cauchy-Schwarz.

Démonstration

Soit $\theta \in \Theta$. Par définition d'une fonction d'influence,

$$\int \psi(\tau, x)\, q_\tau(x)\, \mu(\mathrm{d}x) = 0 \qquad \text{pour tout } \tau \in \Theta\,,$$

de sorte que la dérivée en $\tau = \theta$ de cette fonction constante est nulle. En dérivant sous le signe intégral – permutation licite sous les conditions de régularité 1.1 et l'hypothèse de domination du théorème 1.4, par la proposition 2.2 – il vient

$$0 = \int \left[\psi'(\theta, x)\, q_\theta(x) + \psi(\theta, x)\, \partial_\theta q_\theta(x)\right] \mu(\mathrm{d}x) = \int \left[\psi'(\theta, x) + \psi(\theta, x)\, \dot{\ell}(\theta, x)\right] q_\theta(x)\, \mu(\mathrm{d}x) ,$$

où l'on a utilisé $\partial_\theta q_\theta = q_\theta \dot{\ell}(\theta, \cdot)$, valable par (R-1). Autrement dit,

$$\mathbb{E}_\theta \left[\psi'(\theta, X_1)\right] = -\mathbb{E}_\theta \left[\psi(\theta, X_1)\, \dot{\ell}(\theta, X_1)\right] . \tag{11}$$

L'inégalité de Cauchy-Schwarz (proposition 2.1) appliquée au membre de droite donne

$$\left(\mathbb{E}_\theta \left[\psi'(\theta, X_1)\right]\right)^2 \leq \mathbb{E}_\theta \left[\{\psi(\theta, X_1)\}^2\right]\ \mathbb{E}_\theta \left[\left\{\dot{\ell}(\theta, X_1)\right\}^2\right] ,$$

c'est-à-dire, en divisant par $\mathbb{E}_\theta[\psi^2(\theta, X_1)]$, qui est strictement positif puisque $\mathbb{E}_\theta[\psi'(\theta, X_1)] \neq 0$,

$$v_\psi(\theta)^{-1} = \frac{\left(\mathbb{E}_\theta \left[\psi'(\theta, X_1)\right]\right)^2}{\mathbb{E}_\theta \left[\{\psi(\theta, X_1)\}^2\right]} \leq \mathbb{E}_\theta \left[\left\{\dot{\ell}(\theta, X_1)\right\}^2\right] = \mathbb{I}(\theta) ,$$

ce qui est l'inégalité annoncée. □

Intuition. *L'identité (11) dit que la pente moyenne de l'équation d'estimation en θ n'est autre que la covariance, au signe près, entre la fonction d'influence et le score : les deux fonctions étant centrées sous $\mathbb{Q}_\theta$, $\mathbb{E}_\theta[\psi\dot{\ell}]$ est bien une covariance. Le cas d'égalité dans Cauchy-Schwarz est celui où $\psi(\theta,\cdot)$ est proportionnelle à $\dot{\ell}(\theta,\cdot)$, et la variance asymptotique est inchangée si l'on multiplie ψ par une constante non nulle : le score est donc, à cette indétermination près, la seule fonction d'influence optimale. C'est une lecture du cas d'égalité, et non une démonstration de l'unicité.*

Le premier point du théorème 1.7, qui affirme que la variance limite de l'estimateur du maximum de vraisemblance est l'inverse de l'information de Fisher, demande de rendre rigoureux sous les seules conditions de régularité le raisonnement qui précède ; le point délicat est le contrôle du terme de reste R_n dans la démonstration du théorème 1.4. C'est ce que fournit la condition de domination (R-2), et l'énoncé général, valable pour $\Theta \subseteq \mathbb{R}^d$, figure dans les compléments (Section 4.4).

Illustration : le paramètre de translation du modèle de Cauchy

Le modèle de Cauchy donne une lecture numérique de l'écart entre la variance asymptotique d'un Z-estimateur et la borne $1/\mathbb{I}(\theta)$.

Exemple 1.9: Médiane empirique et maximum de vraisemblance dans le modèle de Cauchy

Soit une suite de n-échantillons du modèle $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \{q_\theta \cdot \mathrm{Leb} \,:\, \theta \in \mathbb{R}\})$ de densité

$$q_\theta(x) := \frac{1}{\pi\,(1+(x-\theta)^2)}\,, \qquad x \in \mathbb{R}\,.$$

Ce modèle n'a de moment d'aucun ordre, de sorte que la moyenne empirique n'est pas un estimateur de θ. On compare la médiane empirique

$$\widehat{\theta}_n^{\mathrm{med}} := X_{(n+1)/2:n} \quad \text{si } n \text{ est impair}\,, \qquad \widehat{\theta}_n^{\mathrm{med}} \in \left[X_{n/2:n}, X_{n/2+1:n}\right] \quad \text{si } n \text{ est pair}\,,$$

et l'estimateur du maximum de vraisemblance

$$\hat{\theta}_n^{\mathrm{MV}} \in \operatorname*{arg\,min}_{\theta\in\mathbb{R}} \sum_{i=1}^{n} \log\left(1+(X_i-\theta)^2\right)\,,$$

qui n'a pas d'expression explicite. Sur les $N = 49$ observations de la figure 3, simulées avec $\theta^\star = 2$, on trouve $\widehat{\theta}_n^{\mathrm{med}} = 1{,}7717$ et $\hat{\theta}_n^{\mathrm{MV}} = 1{,}7813$.
Les deux estimateurs sont asymptotiquement normaux, pour tout $\theta^\star \in \mathbb{R}$:

$$\sqrt{n}\left(\widehat{\theta}_n^{\mathrm{med}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \frac{1}{4\left(q_{\theta^\star}(\theta^\star)\right)^2}\right)\,, \qquad \sqrt{n}\left(\hat{\theta}_n^{\mathrm{MV}} - \theta^\star\right) \overset{\mathbb{P}_{n,\theta^\star}}{\Longrightarrow} \mathcal{N}\left(0, \frac{1}{\mathbb{I}(\theta^\star)}\right)\,.$$

La première convergence s'obtient par la loi limite des statistiques d'ordre et non par le théorème 1.4, dont les hypothèses de différentiabilité ne sont pas vérifiées par $\psi(\theta,x) = \mathrm{signe}(x-\theta)$; elle est rappelée dans les compléments (Section 4.8). Pour la loi de Cauchy,

$$\dot{\ell}(\theta,x) = \frac{2(x-\theta)}{1+(x-\theta)^2}\,, \qquad q_{\theta^\star}(\theta^\star) = \frac{1}{\pi}\,, \qquad \mathbb{I}(\theta^\star) = \int \left(\dot{\ell}(\theta^\star,x)\right)^2 q_{\theta^\star}(x)\mathrm{d}x = \frac{1}{2}\,,$$

le calcul de l'information de Fisher étant détaillé dans les compléments (Section 4.8). Les deux variances asymptotiques valent donc $\pi^2/4 \simeq 2{,}47$ pour la médiane et 2 pour l'estimateur du maximum de vraisemblance, en accord avec l'inégalité du théorème 1.7.

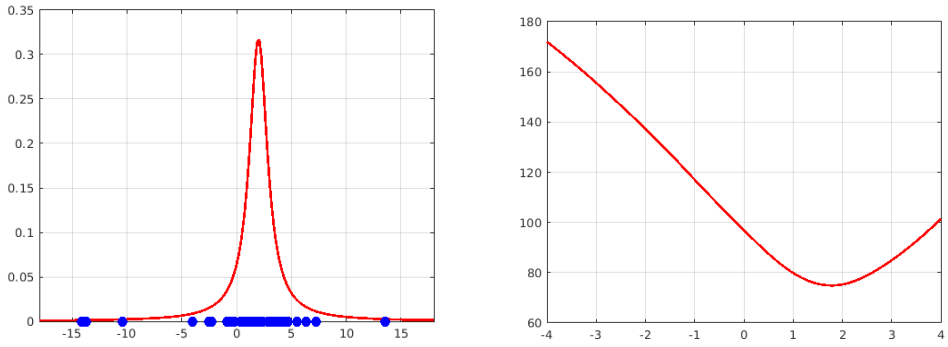


FIGURE 3 – À gauche, en bleu, les $N = 49$ observations tirées selon une loi de Cauchy de paramètre $\theta^\star = 2$, et en rouge la densité $q_{\theta^\star}$. À droite, l'opposé de la log-vraisemblance, dont le minimum définit $\hat{\theta}_n^{\mathrm{MV}}$.

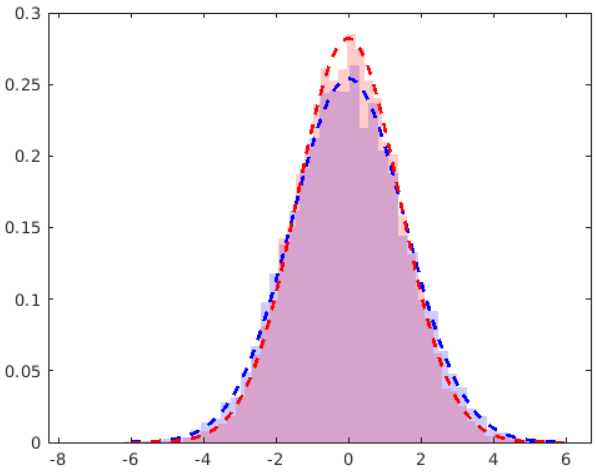


FIGURE 4 – Histogrammes de 10^4 réalisations indépendantes de $\sqrt{n}(\widehat{\theta}_n - \theta^\star)$ pour $\widehat{\theta}_n = \widehat{\theta}_n^{\mathrm{med}}$ (bleu) et $\widehat{\theta}_n = \hat{\theta}_n^{\mathrm{MV}}$ (rouge), avec $n = 499$. En pointillés, les densités des lois $\mathcal{N}(0, \pi^2/4)$ (bleu) et $\mathcal{N}(0, 2)$ (rouge).

Ce qui se passe hors des modèles réguliers

Les conditions de régularité 1.1 demandent en particulier que le support de $\mathbb{Q}_\theta$ ne dépende pas de θ : sans cela, $\theta \mapsto q_\theta(x)$ n'est pas continue. Dès que le paramètre gouverne le support, ni la vitesse $\sqrt{n}$ ni la loi limite gaussienne ne subsistent. L'estimation du support d'une loi uniforme en a donné un premier exemple au chapitre 6 (exemple 1.5) ; le modèle de Pareto, traité à l'exercice 2 de la feuille de la semaine 6, en donne un second.

Exemple 1.10: Modèle de Pareto

Soit une suite de n-échantillons du modèle de densité

$$q_\theta(x) = \eta\alpha^\eta \frac{1}{x^{1+\eta}} \mathbb{1}_{[\alpha,+\infty[}(x) \;, \qquad \theta = (\alpha,\eta) \in \mathbb{R}_+^\star \times \mathbb{R}_+^\star \;.$$

Pour $\eta > 0$ et $\alpha \leq \min(X_1,\dots,X_n)$, la log-vraisemblance vaut

$$\ell_n(\theta) = n\log\eta + n\eta\log\alpha - (1+\eta)\sum_{k=1}^n \log X_k \;,$$

et elle vaut $-\infty$ si $\alpha > \min(X_1,\dots,X_n)$. À η fixé, elle est croissante en α sur l'intervalle où elle est finie, de sorte que l'estimateur du maximum de vraisemblance est

$$\hat\alpha_n := \min(X_1,\dots,X_n) \;, \qquad \hat\eta_n := \left(\frac{1}{n}\sum_{k=1}^n \log\frac{X_k}{\hat\alpha_n}\right)^{-1} \;.$$

La loi de $\hat\alpha_n$ est explicite : pour $t \geq \alpha$,

$$\mathbb{P}_{n,\theta}\left(\hat\alpha_n \geq t\right) = \left(\mathbb{P}_{n,\theta}(X_1 \geq t)\right)^n = \left(\frac{\alpha}{t}\right)^{n\eta} \;,$$

c'est-à-dire que $\hat\alpha_n$ suit une loi de Pareto de paramètre d'échelle α et d'indice $n\eta$. Pour $n\eta > 2$, on en déduit le biais et la variance

$$\mathbb{E}_{n,\theta}\left[\hat\alpha_n - \alpha\right] = \frac{\alpha}{n\eta - 1} \;, \qquad \mathrm{Var}_{n,\theta}\left(\hat\alpha_n\right) = \frac{n\eta\,\alpha^2}{(n\eta-2)(n\eta-1)^2} \;,$$

donc une erreur quadratique moyenne en $O(n^{-2})$, et l'inégalité de Markov (lemme 2.1) appliquée à $(\hat\alpha_n - \alpha)^2$ donne la consistance : pour tout $\varepsilon > 0$,

$$\mathbb{P}_{n,\theta}\left(|\hat\alpha_n - \alpha| \geq \varepsilon\right) \leq \varepsilon^{-2}\,\mathbb{E}_{n,\theta}\left[(\hat\alpha_n - \alpha)^2\right] = O(n^{-2}) \;.$$

La loi limite se lit sur la fonction de répartition. En prenant $t = \alpha\exp\{x/(n\eta)\}$ avec $x \geq 0$ dans l'expression ci-dessus,

$$\mathbb{P}_{n,\theta}\left(n\eta\log\frac{\hat\alpha_n}{\alpha} \leq x\right) = 1 - \mathrm{e}^{-x} \;,$$

c'est-à-dire que $W_n := n\eta\log(\hat\alpha_n/\alpha)$ suit *exactement* la loi $\mathcal{E}(1)$, pour tout n. En posant $U_n := W_n/(n\eta)$, on a $\hat\alpha_n = \alpha\,\mathrm{e}^{U_n}$ et $n\eta\,U_n \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \mathcal{E}(1)$; la méthode-δ (théorème 1.7), appliquée au point 0 avec la vitesse $r_n = n\eta$ et la fonction $u \mapsto \alpha\mathrm{e}^u$, de dérivée α en 0, donne

$$n\eta\left(\hat\alpha_n - \alpha\right) \overset{\mathbb{P}_{n,\theta}}{\Longrightarrow} \alpha\,\mathcal{E}(1) \;.$$

La vitesse est n et non $\sqrt{n}$, ce qui est cohérent avec l'erreur quadratique en $O(n^{-2})$, et la loi limite est exponentielle et non gaussienne. La borne de Cramér-Rao et le théorème 1.7 ne s'appliquent ni l'un ni l'autre.

1.8 Le programme des exercices

La feuille de la semaine comporte cinq exercices.

— L'exercice 1 est un problème en deux temps. Sa première question construit, pour un modèle de translation, deux suites de tests consistantes et de même niveau asymptotique, l'une fondée sur une fréquence de signes, l'autre sur la statistique de Student (exemple 1.14) ; la consistance ne suffit donc pas à départager deux tests. La suite du problème, nettement plus difficile, compare les deux suites par leurs fonctions puissance le long d'une suite d'alternatives $\theta_n = \theta^\star + h/\sqrt{n}$, et introduit à cette occasion la distance de Hellinger, la différentiabilité en moyenne quadratique et la contiguïté.

— L'exercice 2 reprend sur le modèle Gamma$(2, \theta)$ la chaîne complète de ce chapitre : estimateur du maximum de vraisemblance, biais et risque quadratique à n fixé, consistance, normalité asymptotique et intervalle de confiance asymptotique.

— L'exercice 3 traite le modèle log-normal de paramètre (θ, θ), où les deux composantes du couple habituel sont liées, et demande la normalité asymptotique de l'estimateur du maximum de vraisemblance puis un intervalle de confiance asymptotique.

— L'exercice 4 contraint le paramètre du modèle $\mathcal{N}(\theta, 1)$ à rester positif. La normalité asymptotique vaut pour $\theta > 0$, conformément au théorème 1.4, qui ne dit rien des points de la frontière ; la loi limite en $\theta = 0$ n'est pas gaussienne.

— L'exercice 5 étudie la famille des Z-estimateurs de translation associés à $\psi(\theta, x) = \gamma(x - \theta)$ pour γ impaire et croissante, dont l'exemple 1.4 donne trois cas particuliers. Il en établit l'existence, la consistance et la normalité asymptotique, puis compare les variances asymptotiques $V[\gamma]$ d'une loi gaussienne à un mélange gaussien contaminé : c'est la justification quantitative de l'emploi des fonctions d'influence bornées en statistique robuste.