1 Solutions

1.1 Exercice 1

1. On écrit que le risque de classification d'une règle g est

$$\begin{aligned} R(g) &= \mathbb{E}[\ell(Y, g(X))] \\ &= \mathbb{E}\left[\mathbb{1}_{g(X)=1,Y=-1} + c\mathbb{1}_{g(X)=-1,Y=1}\right] \\ &= \mathbb{E}\left[\mathbb{1}_{g(X)=1}\mathbb{1}_{Y=-1}\right] + c\mathbb{E}\left[\mathbb{1}_{g(X)=-1}\mathbb{1}_{Y=1}\right] \\ &= \mathbb{E}\left[\mathbb{1}_{g(X)=1}\mathbb{E}\left[\mathbb{1}_{Y=-1}|X\right]\right] + c\mathbb{E}\left[\mathbb{1}_{g(X)=-1}\mathbb{E}\left[\mathbb{1}_{Y=1}|X\right]\right] \end{aligned}$$

Par définition de $\eta(X)$, nous avons

$$\eta(X) = \mathbb{P}(Y=1|X) = \mathbb{E}\left[\mathbb{1}_{Y=1}|X\right] = 1 - \mathbb{E}\left[\mathbb{1}_{Y=-1}|X\right]$$

De plus, puisque $g(X)$ ne prend que deux valeurs, nous avons

$$\mathbb{1}_{g(X)=1} = 1 - \mathbb{1}_{g(X)=-1}.$$

Il vient

$$\begin{aligned} R(g) &= \mathbb{E}\left[\left(1 - \mathbb{1}_{g(X)=-1}\right)\left(1-\eta(X)\right)\right] + c\mathbb{E}\left[\mathbb{1}_{g(X)=-1}\,\eta(X)\right] \\ &= 1 - \mathbb{E}\left[\eta(X)\right] + \mathbb{E}\left[\left((1+c)\eta(X) - 1\right)\mathbb{1}_{g(X)=-1}\right]\ . \end{aligned}$$

2. • `Solution 1.` Soit g une règle de classification binaire. L'excès de risque vaut :

$$\begin{aligned} R(g) - R(g_c^\star) &= (c+1)\ \mathbb{E}\left[\left(\mathbb{1}_{\{g(X)=-1\}} - \mathbb{1}_{\{g_c^\star(X)=-1\}}\right)\ \left(\eta(X) - \frac{1}{c+1}\right)\right] \\ &= (c+1)\ \mathbb{E}\left[\left(\mathbb{1}_{\{g(X)=-1\}} - \mathbb{1}_{\{\eta(X)-1/(c+1)<0\}}\right)\ \left(\eta(X) - \frac{1}{c+1}\right)\right]. \end{aligned}$$

Maintenant, on remarque que pour tout pour tout x , on a :

$$\left(\mathbb{1}_{\{g(x)=-1\}} - \mathbb{1}_{\{\eta(x)-1/(c+1)<0\}}\right)\ \left(\eta(x) - \frac{1}{c+1}\right) \geq 0.$$

Par suite, l'espérance est aussi positive ou nulle et donc $R(g) \geq R(g^\star)$.

• `Solution 2.` En partant de l'expression

$$R(g) = (c+1)\ \mathbb{E}\left[\left(\mathbb{1}_{\{g(X)=-1\}} - \mathbb{1}_{\{\eta(X)-1/(c+1)<0\}}\right)\ \left(\eta(X) - \frac{1}{c+1}\right)\right].$$

Si l'on veut choisir g de façon à minimiser le terme dont on calcule l'espérance, il faut prendre $g(X) = -1$ lorsque $\eta(X) - 1/(c+1) < 0$; et $g(X) = 1$ dans le cas contraire. On retrouve donc que $R(g) \geq R(g_c^\star)$.

► Dans le cas $c = 1$, la fonction de perte proposée coïncide avec la fonction de perte 0/1 usuelle ; et on retrouve que la règle de décision bayésienne est $\mathbb{1}_{\{\eta(X)\geq 1/2\}}$.

3. Supposons qu'il existe une autre règle, notée $f^\star$, telle que pour toute règle g on ait $R(g) \geq R(f^\star)$. Alors nécessairement, on a $R(g_c^\star) \geq R(f^\star)$. Par ailleurs, $g_c^\star$ est aussi une règle bayésienne, donc $R(f^\star) \geq R(g_c^\star)$. On en déduit que $R(f^\star) = R(g_c^\star)$.
Traduisons cette égalité des risques : en écrivant $\{g_c^\star(X) = -1\} = \{\eta(X) < 1/(c+1)\}$, nous avons

$$\mathbb{E}\left[\Xi(X)\right] = 0, \qquad \Xi(X) := \left(\mathbb{1}_{\{f^\star(X)=-1\}} - \mathbb{1}_{\{\eta(X)-1/(c+1)<0\}}\right)\left(\eta(X) - \frac{1}{c+1}\right).$$

La différence des indicatrices vaut soit 0, soit 1, soit -1. Le cas où elle vaut 1 correspond à $\{f^\star(X) = -1, \eta(X) \geq 1/(c+1)\}$; et dans ce cas, nous avons

$$\left(\mathbb{1}_{\{f^\star(X)=-1\}} - \mathbb{1}_{\{\eta(X)-1/(c+1)<0\}}\right)\left(\eta(X) - \frac{1}{c+1}\right) \geq 0\,.$$

Le cas où elle vaut -1 correspond à $\{f^\star(X) = 1, \eta(X) < 1/(c+1)\}$; et dans ce cas, nous avons

$$\left(\mathbb{1}_{\{f^\star(X)=-1\}} - \mathbb{1}_{\{\eta(X)-1/(c+1)<0\}}\right)\left(\eta(X) - \frac{1}{c+1}\right) \geq 0\,.$$

Donc $\Xi(X) \geq 0$ et si son espérance est nulle, c'est que $\Xi(X) = 0$ avec probabilité 1. Donc nécessairement, nous devons avoir $\eta(X) = 1/(c+1)$ sur l'ensemble $\mathbb{1}_{f^\star(X)=-1} - \mathbb{1}_{\eta(X)-1/(c+1)<0} \neq 0$.
Nous en déduisons que deux classifieurs bayésiens diffèrent uniquement sur l'ensemble $\{X : \eta(X) = 1/(c+1)\}$.

1.2 Exercice 2

1. Nous avons par définition du risque associé à la fonction de perte $0-1$,

$$\begin{aligned} R(g^\star) &= \mathbb{P}(g^\star(X) \neq Y) = \mathbb{P}(g(X)=1, Y=-1) + \mathbb{P}(g(X)=-1, Y=1) \\ &= \mathbb{E}\left[\mathbb{1}_{\{Y=-1\}}\mathbb{1}_{\{g(X)=1\}}\right] + \mathbb{E}\left[\mathbb{1}_{\{Y=1\}}\mathbb{1}_{\{g(X)=-1\}}\right] \\ &= \mathbb{E}\left[\mathbb{E}\left[\mathbb{1}_{\{Y=-1\}}|X\right]\mathbb{1}_{\{g(X)=1\}}\right] + \mathbb{E}\left[\mathbb{E}\left[\mathbb{1}_{\{Y=1\}}|X\right]\mathbb{1}_{\{g(X)=-1\}}\right] \\ &= \mathbb{E}\left[(1-\eta(X))\mathbb{1}_{\{g(X)=1\}} + \eta(X)\mathbb{1}_{\{g(X)=-1\}}\right]. \end{aligned}$$

   Or, $\{X : g(X)=1\} = \{X : \eta(X) \geq 1/2\}$; et nous avons aussi $\{X : \eta(X) \geq 1/2\} = \{X : \eta(X) \geq 1-\eta(X)\}$. Donc

$$\begin{aligned} \mathbb{E}\left[(1-\eta(X))\mathbb{1}_{\{g(X)=1\}}\right] &= \mathbb{E}\left[(1-\eta(X))\mathbb{1}_{\{\eta(X)\geq 1-\eta(X)\}}\right] \\ &= \mathbb{E}\left[((1-\eta(X))\wedge\eta(X))\,\mathbb{1}_{\{\eta(X)\geq 1-\eta(X)\}}\right]. \end{aligned}$$

   De même, on montre que

$$\mathbb{E}\left[\eta(X)\mathbb{1}_{\{g(X)=-1\}}\right] = \mathbb{E}\left[((1-\eta(X))\wedge\eta(X))\,\mathbb{1}_{\{\eta(X)\leq 1-\eta(X)\}}\right].$$

   On en déduit que

$$R(g^\star) = \mathbb{E}\left[(1-\eta(X))\wedge\eta(X)\right].$$

   La relation $a\wedge b + |a-b|/2 = (a+b)/2$ se démontre facilement en considérant l'intervalle $[a\wedge b, a\vee b]$. Elle exprime que ajouter la demi-longueur de l'intervalle à la borne inférieure est égal au milieu de l'intervalle.

2. La relation se démontre comme dans l'exercice 1 question 1, en prenant $c=1$. On obtient le résultat voulu.

3. On utilise le résultat de la question précédente. Nous avons

$$R(g_1) - R(g_2) = \mathbb{E}\left[(2\eta(X)-1)\left(\mathbb{1}_{\{g_1(X)=-1\}} - \mathbb{1}_{\{g_2(X)=-1\}}\right)\right].$$

   En prenant les valeurs absolues, on obtient

$$|R(g_1) - R(g_2)| \leq \mathbb{E}\left[|2\eta(X)-1||\mathbb{1}_{\{g_1(X)=-1\}} - \mathbb{1}_{\{g_2(X)=-1\}}|\right].$$

   La différence des indicatrices vaut 0, 1 ou -1 et elle est non nulle lorsque $g_1(X) \neq g_2(X)$; nous en déduisons donc que

$$|\mathbb{1}_{\{g_1(X)=-1\}} - \mathbb{1}_{\{g_2(X)=-1\}}| = \mathbb{1}_{\{g_1(X)\neq g_2(X)\}}.$$

   Ce qui conclut la démonstration.

4. On applique le résultat de la question précédente avec $g_1 \leftarrow \tilde{g}$ et $g_2 \leftarrow g^\star$. Il vient

$$|R(\tilde{g}) - R(g^\star)| \leq 2\mathbb{E}\left[|\eta(X)-1/2|\mathbb{1}_{\{\tilde{g}(X)\neq g^\star(X)\}}\right].$$

   Par définition de $g^\star$, nous avons $R(\tilde{g}) - R(g^\star) \geq 0$ pour tout classifieur $\tilde{g}$, ce qui entraine

$$R(\tilde{g}) - R(g^\star) \leq 2\mathbb{E}\left[|\eta(X)-1/2|\;\mathbb{1}_{\{\tilde{g}(X)\neq g^\star(X)\}}\right].$$

Considérons deux cas. Dans le premier cas, $\tilde{g}(X) = 1$ et $g^\star(X) = -1$. Puisque $\{X : \tilde{g}(X) = 1, g^\star(X) = -1\} = \{X : \tilde{\eta}(X) \geq 1/2, \eta(X) < 1/2\}$, nous avons sur cet ensemble :

$$|\eta(X) - 1/2| = \eta(X) - 1/2 \leq \eta(X) - \tilde{\eta}(X) = |\eta(X) - \tilde{\eta}(X)|.$$

Dans le second cas, $\tilde{g}(X) = -1$ et $g^\star(X) = 1$. De la même façon, nous montrons que sur cet ensemble

$$|\eta(X) - 1/2| = 1/2 - \eta(X) \leq \tilde{\eta}(X) - \eta(X) = |\eta(X) - \tilde{\eta}(X)|.$$

Par suite, nous avons établi que

$$|\eta(X) - 1/2| \; \mathbb{1}_{\{\tilde{g}(X) \neq g^\star(X)\}} \leq |\eta(X) - \tilde{\eta}(X)| \; \mathbb{1}_{\{\tilde{g}(X) \neq g^\star(X)\}}$$

ce qui termine la démonstration.

5. En utilisant la question 4, on a

$$\mathbb{E}_n \left[R(\tilde{g}_n) - R(g^\star)\right] \leq 2\, \mathbb{E}_n \left[\mathbb{E}\left[|\tilde{\eta}_n(X) - \eta(X)|\right]\right].$$

Dans la relation précédente, la première espérance $\mathbb{E}$ désigne l'espérance par rapport à X – l'aléa porté par $\mathcal{D}_n$ étant "gelé". Tandis que la seconde $\mathbb{E}_n$ consiste ensuite à prendre la valeur moyenne sur l'aléa porté par $\mathcal{D}_n$.

Puisque $|\tilde{\eta}_n(X) - \eta(X)| \leq 1$, nous pouvons appliquer le théorème de Fubini et nous obtenons

$$\mathbb{E}_n \left[R(\tilde{g}_n) - R(g^\star)\right] \leq 2\mathbb{E}\left[\; \mathbb{E}_n \left[|\tilde{\eta}_n(X) - \eta(X)|\right] \;\right].$$

Pour démontrer que le terme de droite tens vers zero, nous le voyons comme $2\,\mathbb{E}[\phi_n(X)]$ et ayant posé

$$\phi_n(X) := \; \mathbb{E}_n \left[|\tilde{\eta}_n(X) - \eta(X)|\right]$$

et nous allons appliquer le théorème de convergence dominée. Puisque $|\tilde{\eta}_n(X) - \eta(X)| \leq 1$, nous avons $|\phi_n(X)| \leq 1$. Il reste à montrer que pour $\mathbb{Q}$-presque tout x, nous avons $\lim_n \phi_n(x) = 0$. Soit x fixé ; nous écrivons pour tout $\varepsilon > 0$,

$$\phi_n(x) = \mathbb{E}_n \left[|\tilde{\eta}_n(x) - \eta(x)|\right] \leq \mathbb{P}_n \left(|\tilde{\eta}_n(x) - \eta(x)| \geq \varepsilon\right) + \varepsilon.$$

Cette relation étant vraie pour tout ε, et en utilisant la convergence en probabilité de $\tilde{\eta}_n(x)$ vers $\eta(x)$, on en déduit que $\lim_n \mathbb{E}_n \left[|\tilde{\eta}_n(x) - \eta(x)|\right] = 0$.

Ce qui termine la preuve.

C'est un résultat classique : si on sait estimer de façon consistante la fonction de régression $\eta(x)$ alors l'excès de risque du classifieur $\tilde{g}_n$ associé à cette estimation $\tilde{\eta}_n$ tend vers 0 dans L^1 (ou de façon équivalente en proba, puisque les v.a. sont bornées).

1.3 Exercice 3

1. La fonction de régression est donnée par

$$\begin{aligned}
&\eta_\theta(x) = \mathbb{Q}_\theta(Y=1|X=x) \\
&= \frac{\pi_1 \mathrm{e}^{-(x-\mu_1)^T\Sigma_1^{-1}(x-\mu_1)/2}}{\pi_1 \mathrm{e}^{-(x-\mu_1)^T\Sigma_1^{-1}(x-\mu_1)/2} + \pi_{-1}\left(\det\Sigma_1/\det\Sigma_{-1}\right)^{1/2}\mathrm{e}^{-(x-\mu_{-1})^T\Sigma_{-1}^{-1}(x-\mu_{-1})/2}} \\
&= \Bigg(1 + \frac{\pi_{-1}}{\pi_1}\left(\det\Sigma_1/\det\Sigma_{-1}\right)^{1/2} \\
&\quad \exp\left(-x^T(\Sigma_{-1}^{-1}-\Sigma_1^{-1})x/2 + \mu_1^T\Sigma_1^{-1}\mu_1/2 - \mu_{-1}^T\Sigma_{-1}^{-1}\mu_{-1}/2 + \mu_{-1}^T\Sigma_{-1}^{-1}x - \mu_1^T\Sigma_1^{-1}x\right)\Bigg)^{-1}.
\end{aligned}$$

   On en déduit que

$$\begin{aligned}
\phi_\theta(x) &= \frac{1}{2}x^T(\Sigma_{-1}^{-1}-\Sigma_1^{-1})x - \mu_{-1}^T\Sigma_{-1}^{-1}x \\
&\quad + \mu_1^T\Sigma_1^{-1}x - \frac{1}{2}\mu_1^T\Sigma_1^{-1}\mu_1 + \frac{1}{2}\mu_{-1}^T\Sigma_{-1}^{-1}\mu_{-1} + \ln\left(\frac{\pi_1}{\pi_{-1}}\left(\det\Sigma_{-1}/\det\Sigma_1\right)^{1/2}\right)
\end{aligned}$$

   La règle de classification est équivalente à $\phi_\theta(X) \geq 0 \iff Y = 1$. Ici, $x \mapsto \phi_\theta(x)$ est une forme quadratique. On parle de **Quadratic Discriminant Analysis (QDA)**. La géométrie de la séparation correspond à une forme quadrique en dimension d dont la signature dépend de la réduction simultanée de Σ_{-1} et Σ_1.

2. Lorsque $\Sigma_{-1} = \Sigma_1 = \Sigma$, il vient

$$\phi_\theta(x) = (\mu_1-\mu_{-1})^T\Sigma^{-1}x - \frac{1}{2}\mu_1^T\Sigma^{-1}\mu_1 + \frac{1}{2}\mu_{-1}^T\Sigma^{-1}\mu_{-1} + \ln\frac{\pi_1}{\pi_{-1}}$$

   qui est bien de la forme linéaire $w_\theta^T x + A_\theta$.

   De plus, la règle de décision Bayésienne est donnée par

$$g_\theta^\star(x) = 2\mathbb{1}_{\{\eta_\theta(x)\geq 1/2\}} - 1 = 2\mathbb{1}_{\{w_\theta^T x + A_\theta \geq 0\}} - 1.$$

   La frontière de décision est donc portée par un hyperplan orienté par le vecteur *normal* w_θ : les points situés d'un côté de cet hyperplan sont classés "classe -1" et ceux de l'autre côté sont classés "classe 1". On parle de **Linear Discriminant Analysis (LDA)**.
   Notons que si les deux classes sont équilibrées (i.e. $\pi_{-1} = \pi_1$) alors le milieu du segment $[\mu_{-1}, \mu_1]$ est sur l'hyperplan - remarquer en effet que $\phi_\theta((\mu_1+\mu_{-1})/2) = 0$.
   Si Σ est la matrice identité, alors le vecteur w normal à l'hyperplan de décision est tout simplement $\mu_1 - \mu_{-1}$.

3. On écrit la log-vraisemblance d'une observation

$$\begin{aligned}
\ell(X,Y;\theta) &= -\frac{d}{2}\ln(\pi/2) + \frac{Y+1}{2}\ln\left(\det(\Sigma_1)^{-1/2}(1-\pi_{-1})\mathrm{e}^{-(X-\mu_1)^T\Sigma_1^{-1}(X-\mu_1)/2}\right) \\
&\quad + \frac{(1-Y)}{2}\ln\left(\det(\Sigma_{-1})^{-1/2}\pi_{-1}\mathrm{e}^{-(X-\mu_{-1})^T\Sigma_{-1}^{-1}(X-\mu_{-1})/2}\right) \\
&= -\frac{d}{2}\ln(\pi/2) - \frac{\frac{Y+1}{2}\ln(\det(\Sigma_1)) + \frac{(1-Y)}{2}\ln(\det(\Sigma_{-1}))}{2} + \frac{Y+1}{2}\ln(1-\pi_1) + \frac{(1-Y)}{2}\ln\pi_{-1} \\
&\quad - \frac{Y+1}{2}\frac{(X-\mu_1)^T\Sigma_1^{-1}(X-\mu_1)}{2} - \frac{(1-Y)}{2}\frac{(X-\mu_{-1})^T\Sigma_{-1}^{-1}(X-\mu_{-1})}{2}.
\end{aligned}$$

On observe un echantillon d'apprentissage de n données *i.i.d.*, la log-vraisemblance de l'échantillon $\theta \mapsto \ell_n(X_1, Y_1, \ldots, X_n, Y_n; \theta)$ satisfait donc pour tout $\theta \in \Theta$, $\ell_n(X_1, Y_1, \ldots, X_n, Y_n; \theta) = \sum_{i=1}^n \ell(X_i, Y_i; \theta)$. En particulier la fonction de vraisemblance de l'échantillon est donnée par

$$\begin{aligned}
\ell_n(X_1, Y_1, \ldots, Y_1, Y_n; .) : \Theta \to & \mathbb{R} \\
\theta \mapsto & \ell_n(X_1, Y_1, \ldots, Y_1, Y_n; \theta) := -n\frac{d}{2}\ln(\pi/2) \\
& - \left(\sum_{k=1}^n \frac{Y_k+1}{2}\right)\frac{\log(\det(\Sigma_1))}{2} - \left(\sum_{k=1}^n \frac{(1-Y_k)}{2}\right)\frac{\log(\det(\Sigma_{-1}))}{2} \\
& + \left(\sum_{k=1}^n \frac{Y_k+1}{2}\right)\ln(1-\pi_{-1}) + \left(\sum_{k=1}^n \frac{(1-Y_k)}{2}\right)\ln\pi_{-1} \\
& - \sum_{k=1}^n \frac{Y_k+1}{2}\,\frac{(X_k-\mu_1)^T\Sigma_1^{-1}(X_k-\mu_1)}{2} \\
& - \sum_{k=1}^n \frac{(1-Y_k)}{2}\,\frac{(X_k-\mu_{-1})^T\Sigma_{-1}^{-1}(X_k-\mu_{-1})}{2}.
\end{aligned}$$

4. En dérivant par rapport à $\pi_{-1}, \mu_1, \mu_{-1}$ et en étudiant le comportement aux limites par rapport à ces trois paramètres, on obtient les estimateurs de maximum de vraisemblance :

$$\begin{aligned}
\hat{\pi}_{-1,n} &:= \frac{1}{n}\sum_{k=1}^n \frac{(1-Y_k)}{2} = \frac{1}{n}\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}, \\
\hat{\mu}_{-1,n} &:= \frac{\sum_{k=1}^n (1-Y_k)X_k}{\sum_{k=1}^n (1-Y_k)} = \frac{\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}X_k}{\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}} \\
\hat{\mu}_{1,n} &:= \frac{\sum_{k=1}^n (Y_k+1)X_k}{\sum_{k=1}^n (Y_k+1)} = \frac{\sum_{k=1}^n \mathbb{1}_{\{Y_k=1\}}X_k}{\sum_{k=1}^n \mathbb{1}_{\{Y_k=1\}}}.
\end{aligned}$$

• **Solution 1.** Le fait que l'on ait jusqu'ici défini les estimateurs tels que pour tout $\theta \in \Theta$

$$\ell_n(\theta) \leq \ell_n(\hat{\pi}_{-1,n}, \hat{\mu}_{-1,n}, \hat{\mu}_{1,n}, \Sigma_{-1}, \Sigma_1)$$

justifie le fait que l'on se contente de regarder la maximization de

$$\Sigma_{-1} \mapsto -N_{-1}\frac{\log(\det(\Sigma_{-1}))}{2} - \sum_{k\in\mathcal{K}_{-1}} \frac{(X_k-\hat{\mu}_{-1,n})^T\Sigma_{-1}^{-1}(X_k-\hat{\mu}_{-1,n})}{2},$$

où N_{-1} est le nombre de points dont le label vaut 0, points indexés par $\mathcal{K}_{-1}$. **Formellement**, cette maximisation est celle que l'on résoud quand on cherche l'estimateur MV d'une matrice de covariance d'un modèle $\mathrm{N}(\hat{\mu}_{-1,n}, \Sigma_{-1})$ à moyenne connue, à partir de N_{-1} réalisations indépendantes. Nous savons que pour les familles exponentielles de modèle statistique, l'estimateur MV correspond à l'estimateur des moments de $x \mapsto xx^T$ (voir PC2). Par suite, cette fonction est maximale en

$$\hat{\Sigma}_{-1,n} := \frac{1}{N_{-1}}\sum_{k\in\mathcal{K}_{-1}} (X_k-\hat{\mu}_{-1,n})(X_k-\hat{\mu}_{-1,n})^T = \frac{1}{\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}}\sum_{k=1}^n \frac{(1-Y_k)}{2}(X_k-\hat{\mu}_{-1,n})(X_k-\hat{\mu}_{-1,n})^T.$$

De même, on obtient

$$\hat{\Sigma}_{1,n} := \frac{1}{N_1}\sum_{k\in\mathcal{K}_1}(X_k-\hat{\mu}_{1,n})(X_k-\hat{\mu}_{1,n})^T = \frac{1}{\sum_{k=1}^n \mathbb{1}_{\{Y_k=1\}}}\sum_{k=1}^n \frac{Y_k+1}{2}(X_k-\hat{\mu}_{1,n})(X_k-\hat{\mu}_{1,n})^T.$$

• **Solution 2 (raisonnement dans le cas $\Sigma_{-1}=\Sigma_1=\Sigma$).** Pour calculer le maximum de vraisemblance en Σ, on utilise un peu de calcul différentiel. La différentielle de la fonction inverse est donnée par le calcul suivant :

$$(\Sigma+H)^{-1} = \Sigma^{-1} - \Sigma^{-1}H\Sigma^{-1} + o(\|H\|).$$

De même,

$$\log\det(\Sigma+H) = \log\det(\Sigma) + \mathrm{Tr}\left(\Sigma^{-1}H\right) + o(\|H\|).$$

Enfin, si $C_n(\pi_1)$ désigne une quantité ne dépendant que des données et de π_1, on écrit la vraisemblance astucieusement en :

$$\begin{aligned}
\ell_n(\Sigma) &= -\frac{n}{2}\log(\det(\Sigma)) - \frac{1}{2}\sum_{i=1}^n \mathbb{1}^T_{\{Y_i=1\}}(X_i-\mu_1)\Sigma^{-1}(X-\mu_1) \\
&\quad + (\mathbb{1}_{\{Y_i=-1\}})^T(X_i-\mu_{-1})\Sigma^{-1}(X-\mu_{-1}) + C_n(\pi_1) \\
&= -\frac{n}{2}\log(\det(\Sigma)) - \frac{1}{2}\sum_{i=1}^n \mathrm{Tr}\Big(\mathbb{1}^T_{\{Y_i=1\}}(X_i-\mu_1)\Sigma^{-1}(X_i-\mu_1) \\
&\quad + (\mathbb{1}_{\{Y_i=-1\}})^T(X_i-\mu_{-1})\Sigma^{-1}(X_i-\mu_{-1})\Big) + C_n(\pi_1) \\
&= -\frac{n}{2}\log(\det(\Sigma)) + \mathrm{Tr}\Big(\Sigma^{-1}\sum_{i=1}^n \mathbb{1}_{\{Y_i=1\}}(X_i-\mu_1)^T(X_i-\mu_1) \\
&\quad + (\mathbb{1}_{\{Y_i=-1\}})(X_i-\mu_{-1})^T(X_i-\mu_{-1})\Big) \\
&= -\frac{n}{2}\log(\det(\Sigma)) + \mathrm{Tr}\left(\Sigma^{-1}\hat{S}_n\right)
\end{aligned}$$

où on a introduit $\hat{S}_n$ par :

$$\hat{S}_n := \sum_{i=1}^n \mathbb{1}_{\{Y_i=1\}}(X_i-\hat{\mu}_{1,n})^T(X_i-\hat{\mu}_{1,n}) + (\mathbb{1}_{\{Y_i=-1\}})(X_i-\hat{\mu}_{-1,n})^T(X_i-\hat{\mu}_{-1,n}),$$

la condition d'annulation du gradient en Σ^{-1} permet alors d'écrire que le maximum de vraisemblance en Σ satisfait :

$$\forall H\in\mathcal{M}_d(\mathbb{R}) : -\frac{n}{2}\mathrm{Tr}\left(\Sigma^{-1}H\right) + \mathrm{Tr}\left(\Sigma^{-1}H\Sigma^{-1}\hat{S}_n\right) = 0.$$

Cette dernière équation se récrit en

$$\forall H\in\mathcal{M}_d(\mathbb{R}) : -Tr(n\Sigma^{-1}H - \Sigma^{-1}H\Sigma^{-1}\hat{S}_n) = 0.$$

C'est-à-dire

$$\forall H\in\mathcal{M}_d(\mathbb{R}) : Tr(\Sigma^{-1}H(nId + \Sigma^{-1}\hat{S}_n)) = 0.$$

On en déduit donc que

$$\hat{\Sigma}_n = \frac{\hat{S}_n}{n}.$$

5. Par un argument de loi faible des grands nombres et le lemme de Slutsky, on a

$$\begin{aligned}
\hat{\pi}_{-1,n} &\overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \mathbb{Q}_\theta(Y=-1)=\pi_{-1}\\
\hat{\mu}_{-1,n} &:= \frac{n^{-1}\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}X_k}{n^{-1}\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}} \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \mu_{-1}\\
\hat{\mu}_{1,n} &:= \frac{\sum_{k=1}^n \frac{Y_k+1}{2}X_k}{\sum_{k=1}^n \frac{Y_k+1}{2}} = \frac{\sum_{k=1}^n \mathbb{1}_{\{Y_k=1\}}X_k}{\sum_{k=1}^n \mathbb{1}_{\{Y_k=1\}}} \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \mu_1,\\
\hat{\Sigma}_{-1,n} &= \frac{n^{-1}\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}(X_kX_k^T)-\hat{\mu}_{-1,n}\hat{\mu}_{-1,n}^T}{n^{-1}\sum_{k=1}^n \mathbb{1}_{\{Y_k=-1\}}} \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \Sigma_{-1},\\
\hat{\Sigma}_{1,n} &\overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \Sigma_1,
\end{aligned}$$

6. Puisque pour $\mathbb{Q}_\theta$-presque tout x, $\theta \mapsto \phi_\theta(x)$ est une fonction continue sur Θ, il vient que pour $\mathbb{Q}_\theta$-presque tout x,

$$\phi_{\hat{\theta}_n}(x) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \phi_\theta(x), \qquad \eta_{\hat{\theta}_n}(x) \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \eta_\theta(x).$$

On conclut à l'aide de la question 5 de l'exercice 2.

7. Dans le cas du modèle plus simple, seule l'estimation de la matrice de covariance est changée (voir l'expression de ℓ_n ci-dessus dans le cas où $\Sigma_{-1}=\Sigma_1=\Sigma$). On obtient

$$\hat{\Sigma}_n := \frac{1}{n}\sum_{k=1}^n \left(\mathbb{1}_{\{Y_k=0\}}(X_k-\hat{\mu}_{-1,n})(X_k-\hat{\mu}_{-1,n})^T + \mathbb{1}_{\{Y_k=1\}}(X_k-\hat{\mu}_{1,n})(X_k-\hat{\mu}_{1,n})^T\right);$$

et on établit par la loi faible des grands nombres que

$$\hat{\Sigma}_n \overset{\mathbb{P}_{n,\theta}-\text{prob}}{\longrightarrow} \Sigma.$$

On conclut comme à la question précédente.

8. Dans un problème à plus de deux classes étiquetées par la variable Y, on obtient de la même façon en écrivant la vraisemblance des observations (on traite ici le cas d'une matrice de covariance commune)

$$\hat{\pi}_{j,n} := \frac{\sum_{i=1}^n \mathbb{1}_{\{Y_i=j\}}}{n}, \tag{2}$$

$$\hat{\mu}_{j,n} := \frac{\sum_{i=1}^n X_i\mathbb{1}_{\{Y_i=j\}}}{\sum_{i=1}^n \mathbb{1}_{\{Y_i=j\}}}, \tag{3}$$

$$\hat{\Sigma}_n := \frac{1}{n}\sum_{i=1}^n (X_i-\hat{\mu}_{Y_i,n})(X_i-\hat{\mu}_{Y_i,n})^T.. \tag{4}$$

`Commentaire des graphes:` les données sont simulées comme un mélange de gaussiennes.

— Dans le premier graphe, on a $\Sigma = \mathrm{I}$, donc la frontière de classification est la droite orthogonale au segment $[\hat{\mu}_{-1,n}\ ;\ \hat{\mu}_{1,n}]$. On a utilisé un graphe orthonormé pour mettre en avant ce point.

— Les $\star$ et les ellipsoïdes correspondent aux estimations des moyennes et des covariances par la méthode du maximum de vraisemblance.

— LDA et QDA ne sont pas équivalents dans le cas où la matrice de covariance (ayant servi à produire les données) est la même, car la matrice de covariance estimée est bien sûr différente (l'approche LDA en cherche une commune aux deux classes ; l'approche QDA en cherche une propre à chaque classe).

— Dans les cas où la matrice de covariance (ayant servi à produire les données) est différente, QDA se comporte *a priori* mieux puisqu'on utilise une règle de décision qui exploite une estimation de matrice de covariance spécifique pour chaque classe.

— Selon que $\hat{\Sigma}_1^{-1} - \hat{\Sigma}_{-1}^{-1}$ est définie positive (ou négative) ou non, la forme la frontière de décision n'est pas la même : c'est une ellipse si les deux valeurs propres de $\hat{\Sigma}_1^{-1} - \hat{\Sigma}_{-1}^{-1}$ sont de même signe (5ème ligne sur la Figure) et c'est une paire d'hyperboles sinon. En particulier, sur l'exemple de la 4ème ligne, on a le cas où $\Sigma_1 \simeq \begin{pmatrix} 1 & 0 \\ 0 & \varepsilon \end{pmatrix}$ et $\Sigma_{-1} \simeq \begin{pmatrix} \varepsilon & 0 \\ 0 & 1 \end{pmatrix}$. On peut discriminer deux gaussiennes de même moyenne mais dispersées dans deux directions quasi-orthogonales.

— Ligne 3-5, LDA, on remarque que l'estimation de la variance de la classe noire/bleue est mauvaise !

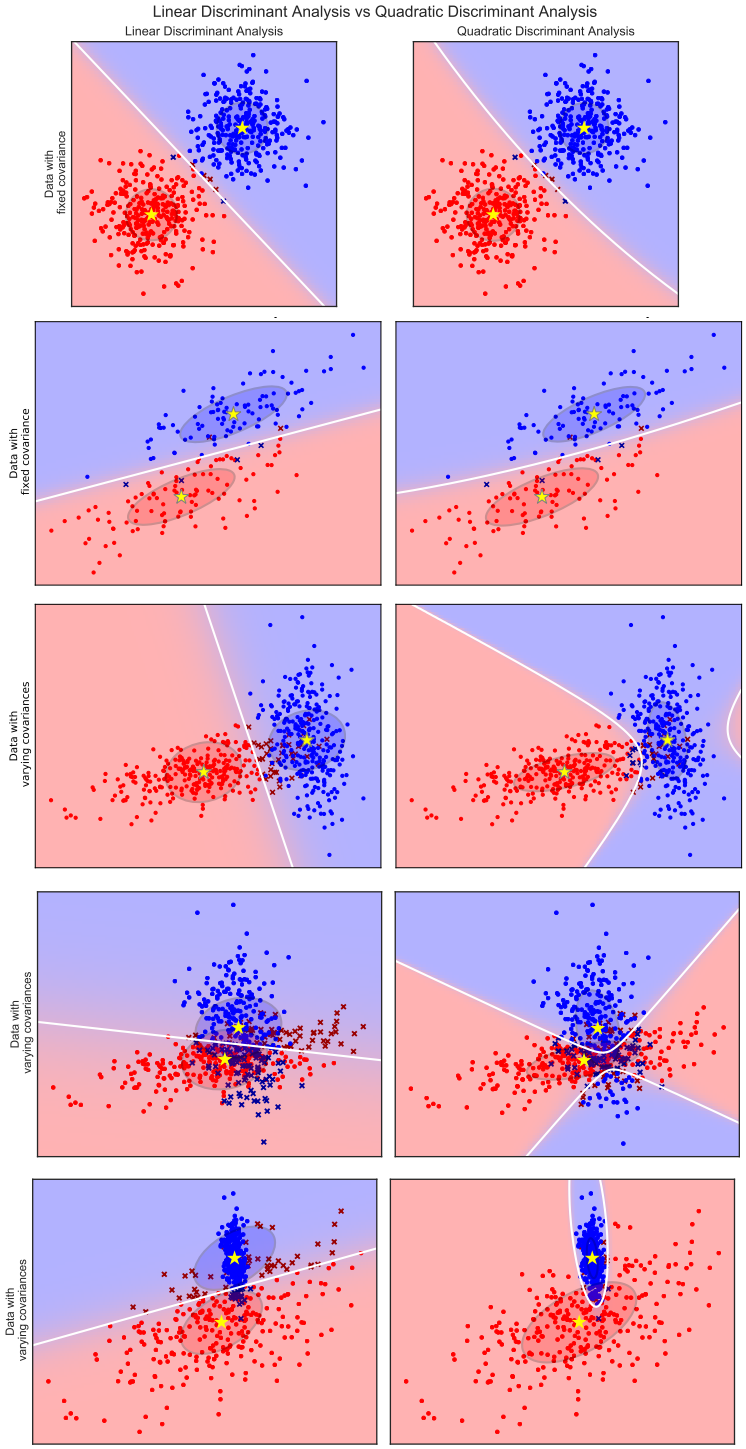


FIGURE 2 – Exercice 6. Classifieurs LDA et QDA and différents cas de figure. Colonne de gauche : LDA, colonne de droite : QDA. La ligne blanche correspond à la ligne de séparation. Les moyennes de chaque classe sont représentées par les $\star$. Les points d'une classe qui sont mal classifiés sont représentés par des $\times$. Deux premières lignes : même matrice de covariance, deux dernières lignes, matrice de covariance différentes.

1.4 Exercice 4

1. La variable aléatoire $\mathbb{E}[X \mid Y]$ est $\sigma(Y)$-mesurable donc il existe une fonction mesurable ψ telle que $\mathbb{E}[X \mid Y] = \psi(Y)$. De plus, pour toute fonction continue bornée f, on a (par égalité en loi de Y et Y'),

$$\mathbb{E}[f(\mathbb{E}[X \mid Y])] = \mathbb{E}[f(\psi(Y))] = \mathbb{E}\left[f\left(\psi\left(Y'\right)\right)\right]$$

Pour conclure il faut montrer l'égalité en loi entre $\psi(Y')$ et $\mathbb{E}[X' \mid Y']$.
Pour toute fonction $\sigma(Y)$-mesurable et bornée ϕ, la caractérsation de l'espérance conditionnelle implique

$$\mathbb{E}[X\phi(Y)] = \mathbb{E}[\mathbb{E}[X \mid Y]\phi(Y)] = \mathbb{E}[\psi(Y)\phi(Y)]$$

Enfin par égalité en loi de (X, Y) et (X', Y'), on a $\mathbb{E}[X\phi(Y)] = \mathbb{E}[X'\phi(Y')]$ et d'autre part $\mathbb{E}[\psi(Y)\phi(Y)] = \mathbb{E}[\psi(Y')\phi(Y')]$.
En conclusion, pour toute fonction $\sigma(Y)$-mesurable et bornée ϕ, on a

$$\mathbb{E}\left[X'\phi\left(Y'\right)\right] = \mathbb{E}\left[\psi\left(Y'\right)\phi\left(Y'\right)\right]$$

Par caractérisation de l'espérance conditionnelle on a donc $\mathbb{E}[X' \mid Y'] = \psi(Y')$, $\mathbb{P}-p.s.$.

2. Comme X est symétrique, X et $-X$ ont même loi. Donc $(X, |X|)$ et $(-X, |-X|) = (-X, |X|)$ ont même loi ; en effet, on utilise la fonction $f : t \mapsto (t, |t|)$ qui est continue. Donc $\mathbb{E}[X \mid |X|] = \mathbb{E}[-X \mid |X|]$ par la question 1. D'un autre côté, $\mathbb{E}[X \mid |X|] + \mathbb{E}[-X \mid |X|] = \mathbb{E}[0 \mid |X|] = 0$. On en déduit que $\mathbb{E}[X \mid |X|] = 0$.

3. Les couples $(X_i, X_1 + \cdots + X_n)$ sont de même loi pour $i \in \{1, \ldots, n\}$. En effet, en notant $\mathrm{d}\nu$ la loi de X_i, nous avons pour toute fonction mesurable bornée h

$$\mathbb{E}[h(X_i, X_1 + \cdots + X_n)] = \int h(x_i, x_1 + \cdots + x_n)\mathrm{d}\nu(x_1)\cdots\mathrm{d}\nu(x_n)$$

en en faisant le changement de variable $y_1 = x_i$ puis $y_2 = x_1$, $y_3 = x_2$, $\cdots$, $y_i = x_{i-1}$, $y_{i+1} = x_{i+1}$, $\cdots$, $y_n = x_n$, on obtient pour tout i

$$\mathbb{E}[h(X_i, X_1 + \cdots + X_n)] = \int h(y_1, y_2 + \cdots + y_{i-1} + y_1 + y_{i+1} + \cdots + y_n)\mathrm{d}\nu(y_1)\cdots\mathrm{d}\nu(y_n)$$

Le terme de droite est indépendant de i, ce qui donne le résultat.
Par suite, nous avons d'une part

$$\sum_{i=1}^{n} \mathbb{E}[X_i \mid X_1 + \cdots + X_n] = n\mathbb{E}[X_1 \mid X_1 + \cdots + X_n]$$

et d'autre part

$$\sum_{i=1}^{n} \mathbb{E}[X_i \mid X_1 + \cdots + X_n] = \mathbb{E}[X_1 + \cdots + X_n \mid X_1 + \cdots + X_n] = X_1 + \cdots + X_n.$$

Ainsi, pour tout $i \in \{1, \ldots, n\}$,

$$\mathbb{E}[X_i \mid X_1 + \cdots + X_n] = \frac{X_1 + \cdots + X_n}{n}.$$

1.5 Exercice 5

1. La loi de X est celle d'un mélange d'une loi uniforme sur $[0;2]$ et d'une loi uniforme sur $[1;4]$. En effet, on écrit pour $x \in \mathbb{R}$

$$\begin{aligned}\mathbb{P}(X \leq x) &= \mathbb{P}(X \leq x, Y = 1) + \mathbb{P}(X \leq x, Y = -1) \\ &= \mathbb{P}(X \leq x \,|Y = 1)\mathbb{P}(Y = 1) + \mathbb{P}(X \leq x \,|Y = -1)\mathbb{P}(Y = -1) \\ &= \frac{1}{2}\mathbb{P}(X \leq x \,|Y = -1) + \frac{1}{2}\mathbb{P}(X \leq x \,|Y = 1)\end{aligned}$$

On obtient donc

$$\mathbb{P}(X \leq x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \frac{x}{4} & \text{si} 0 < x \leq 1 \\ \frac{5}{12}x - \frac{1}{6} & \text{si} 1 < x \leq 2 \\ \frac{x}{6} + \frac{2}{6} & \text{si } 2 < x \leq 4 \\ 1 & si\ x > 4 \end{cases}$$

La densité de X par rapport à la mesure de Lebesgue λ_{Leb} est $p_X(x) = \frac{p_{-1}(x)+p_1(x)}{2}$, avec $p_{-1}(x) := \frac{1}{2}\mathbb{1}_{\{0\leq x\leq 2\}}$ et $p_1(x) := \frac{1}{3}\mathbb{1}_{\{1\leq x\leq 4\}}$.

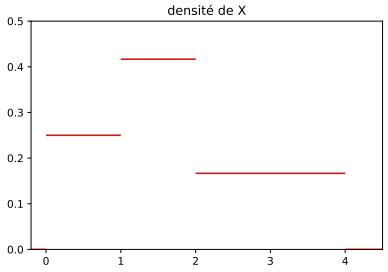


FIGURE 3 – Densité de X

2. On vient de montrer que $\mathbb{P}(X \in [0,4]) = 1$. La fonction η est donc définie sur $[0,4]$ uniquement.

   La densité de X par rapport à la mesure de Lebesgue $\lambda_{\text{Leb}}(\mathrm{d}x) = \mathrm{d}x$ est $p_X(x)$. Celle de Y par rapport à la mesure du comptage $c(\mathrm{d}x) = \delta_{\{0\}}(\mathrm{d}x) + \delta_{\{1\}}(\mathrm{d}x)$ est une Bernoulli de paramètre $1/2$. On rappelle que la densité jointe de (X,Y) par rapport à la mesure produit $\lambda_{\text{Leb}} \otimes c$ est donnée par

$$p_{Y,X}(y,x) = \frac{1}{2}p_1(x)\mathbb{1}_{\{1\}}(y) + \frac{1}{2}p_0(x)\mathbb{1}_{\{0\}}(y)$$

Dans ce cas, la fonction de régression *via* la formule de Bayes est donnée par :

$$\begin{aligned}\eta(x) = \mathbb{P}(Y = 1 \,|\, X = x) &= \frac{p_{Y,X}(1,x)}{p_X(x)} \\ &= \frac{\frac{1}{2}p_1(x)}{\frac{1}{2}p_1(x) + \frac{1}{2}p_{-1}(x)} \\ &= \frac{p_1(x)}{p_{-1}(x) + p_1(x)}\end{aligned}$$

p_1 est non nulle sur $[1,4]$ et p_{-1} est non nulle sur $[0,2]$. Par suite, $p_{-1}+p_1$ est non nulle sur $[0,4]$.
Il vient que $p_1/(p_{-1}+p_1)$ est définie sur $[0,4]$ et est non nulle sur $[1,4]$. On a

$$\forall x \in [0,1] \qquad \eta(x) = 0.$$

Si $1 < x \leq 2$, on a $p_{-1}(x) = \frac{1}{2}$ tandis que $p_1(x) = 1/3$. Ainsi :

$$\forall x \in [0,1] \qquad \eta(x) = \frac{\frac{1}{3}}{\frac{1}{2}+\frac{1}{3}} = \frac{2}{5}.$$

Enfin, si $2 < x \leq 4$, on a $p_1(x) = \frac{1}{3}$ tandis que $p_{-1}(x) = 0$. Par conséquent :

$$\forall x \in [0,1] \qquad \eta(x) = 1.$$

En résumé, pour $x \in [0,4]$, la fonction de régression est donc donnée par

$$\eta(x) = \begin{cases} 0 & \text{si } 0 \leq x \leq 1 \\ 2/5 & \text{si } 1 < x \leq 2 \\ 1 & \text{si } 2 < x \leq 4 \end{cases}$$

.

3. Le classifieur Bayésien est défini par

$$g^\star(x) = 2\mathbb{1}_{\{\eta(x) \geq 1/2\}} - 1.$$

En utilisant la question précédente, on obtient :

$$g^\star(x) = 2\mathbb{1}_{\{2 < x \leq 4\}} - 1.$$

On peut alors calculer le risque associé à ce classifieur (optimal) :

$$\begin{aligned}R(g^\star) &= \mathbb{P}(Y \neq g^\star(X)) \\ &= \mathbb{P}(Y = 1, g^\star(X) = -1) + \mathbb{P}(Y = -1, g^\star(X) = 1) \\ &= \mathbb{P}(Y = 1, X < 2) + \mathbb{P}(Y = -1, X > 2) \\ &= \mathbb{P}(Y = 1)\,\mathbb{P}(X < 2\,|Y = 1) + \mathbb{P}(Y = -1)\,\mathbb{P}(X > 2\,|Y = -1) \\ &= \frac{1}{2} \times \frac{1}{3} + 0 \\ &= \frac{1}{6}.\end{aligned}$$

où on a utilisé la formule de Bayes pour la quatrième égalité.

4. On considère la règle de classification $g(x) = 2\mathbb{1}_{\{x\geq 1\}} - 1$. On rappelle la formule du cours pour l'excès de risque

$$R(g)-R(g^\star) = \mathbb{E}\left[|2\eta(X)-1|\,\mathbb{1}_{\{g^\star(X)\neq g(X)\}}\right]. = \mathbb{E}\left[(2\eta(X)-1)\left(\mathbb{1}_{\{g^\star(X)=1\}} - \mathbb{1}_{\{g(X)=1\}}\right)\right].$$

On a donc

$$\begin{aligned} R(g) - R(g^\star) &= \mathbb{E}[(2\eta(X)-1)\left(\mathbb{1}_{\{X>2\}} - \mathbb{1}_{\{X\geq 1\}}\right)] \\ &= \mathbb{E}[(1-2\eta(X))\,\mathbb{1}_{\{1\leq X\leq 2\}}] \\ &= \mathbb{E}\left[\frac{1}{5}\mathbb{1}_{\{1\leq X\leq 2\}}\right] = \frac{\mathbb{P}\left(1\leq X\leq 2\right)}{5} \\ &= \frac{1}{5}\left(\mathbb{P}(X\leq 2) - \mathbb{P}(X<1)\right) \\ &= \frac{1}{12}. \end{aligned}$$

où la dernière égalité est déduite de la question 1.

1.6 Exercice 6

1. Soient $(x', y') \in \mathbb{R} \times \{-1, 1\}$. Par la formule des probabilités totales et comme $\mathbb{1}_{\{y'=-1\}} + \mathbb{1}_{\{y'=1\}} = 1$, on a

$$\begin{aligned} R(g_{(x',y')}) &= \mathbb{P}\left(Y \neq g_{(x',y')}(X)\right) \\ &= \mathbb{P}(Y=-1)\,\mathbb{P}\left(g_{(x',y')}(X) = 1 \,|Y=-1\right) + \mathbb{P}(Y=1)\,\mathbb{P}\left(g_{(x',y')}(X) = 0 \,|Y=1\right) \\ &= (1-p)\left(\mathbb{1}_{\{y'=-1\}}\mathbb{P}(X > x'|Y=-1) + \mathbb{1}_{\{y'=1\}}\mathbb{P}(X \leq x'|Y=-1)\right) \\ &+ p\left(\mathbb{1}_{\{y'=-1\}}\mathbb{P}(X \leq x'|Y=1) + \mathbb{1}_{\{y'=1\}}\mathbb{P}(X > x'|Y=1)\right). \end{aligned}$$

   En distinguant selon les deux valeurs possibles de y', nous obtenons

$$\begin{aligned} R(g_{(x',0)}) &= (1-p)(1-F_0(x')) + pF_1(x') \\ R(g_{(x',1)}) &= (1-p)F_0(x') + p(1-F_1(x')). \end{aligned}$$

   On obtient bien l'expression demandée.

2. On a en particulier

$$R \leq \lim_{x \to -\infty} \left(R(g_{(x',0)}) \wedge R(g_{(x',1)})\right) = (1-p) \wedge p.$$

   On a bien $R \leq 1/2$ en notant que

$$\begin{aligned} &(1-p) \wedge p = 1-p \iff p \geq 1/2 \iff 1-p \leq 1/2, \\ &(1-p) \wedge p = p \iff p \leq 1/2 \iff p \leq 1/2. \end{aligned}$$

3. Par définition du risque bayésien, on a toujours $R^\star \leq R(g_{(x',y')})$ pour tout x', y' ; et donc $R^\star \leq R$. Puisque $R \leq 1/2$, il vient que si $R^\star = 1/2$ alors $R = 1/2$.
   Réciproquement, supposons que $R = 1/2$. Alors $1/2 \leq p \wedge (1-p) \leq 1/2$ d'après la question 2 ; ce qui entraine $p = 1-p = 1/2$. On en déduit, en utilisant la question 1 que pour tout $x' \in \mathbb{R}$,

$$F_1(x') + (1 - F_0(x')) \geq 1 \qquad \text{et} \qquad (1 - F_1(x')) + F_0(x') \geq 1.$$

   En particulier $F_1(x') - F_0(x')) \geq 0$ d'après la première inégalité et $F_1(x') - F_0(x')) \leq 0$ d'après la seconde, donc $F_1 = F_0$ et donc X et Y sont indépendants. La règle optimale (classifieur Bayésien) $g^\star$ est telle que $R(g^\star) = 1/2$ ssi $\eta(X) := \mathbb{E}[Y \,|\, X] = 1/2$ $\mathbb{P}-p.s.$ (voir Exercice 2, question 1). Ici $\mathbb{E}[Y \,|\, X] = \mathbb{E}Y = p = 1/2$ donc $R^\star = 1/2$.

4. Notons $A_x := (1-p)(1-F_0(x)) + pF_1(x)$ et $B_x := p(1-F_1(x)) + (1-p)F_0(x)$. Alors $R = \min_x(A_x \wedge B_x)$. Par ailleurs, observons que

$$\frac{1}{2} - \sup_x |pF_1(x) - (1-p)F_0(x) - p + 1/2| = \inf_x \left(\frac{1}{2} - \frac{1}{2}|1 - 2B_x|\right);$$

   Il suffit donc de montrer que

$$\frac{1}{2} - \frac{1}{2}|1 - 2B_x| = A_x \wedge B_x$$

en exploitant le fait que $A_x + B_x = 1$. Par un calcul analogue à la fin de la correction de la question 1 exercice 2, nous avons

$$\begin{aligned}\frac{1}{2} - \frac{1}{2}\left|1 - 2B_x\right| &= \frac{1}{2} - \frac{1}{2}\left|A_x - B_x\right| \\ &= \frac{1}{2} - \frac{1}{2}\left(A_x - B_x\right)\mathbb{1}_{\{A_x > B_x\}} + \frac{1}{2}\left(A_x - B_x\right)\mathbb{1}_{\{A_x \leq B_x\}} \\ &= \frac{1}{2} - \frac{1}{2}\left(A_x - B_x\right) + \left(A_x - B_x\right)\mathbb{1}_{\{A_x \leq B_x\}} \\ &= B_x + \left(A_x - B_x\right)\mathbb{1}_{\{A_x \leq B_x\}} = A_x\mathbb{1}_{\{A_x \leq B_x\}} + B_x\mathbb{1}_{\{A_x > B_x\}} = A_x \wedge B_x.\end{aligned}$$

1.7 Exercice 7

1. Ecrivons

$$\begin{aligned}\mathbb{P}(g(X)\neq Y) &= \mathbb{P}(g(X)\neq Y, Y=g^*(X)) + \mathbb{P}(g(X)\neq Y, Y\neq g^*(X)) \\ &= \mathbb{P}(g(X)\neq g^*(X), Y=g^*(X)) + \mathbb{P}(g(X)= g^*(X), Y\neq g^*(X))\ .\end{aligned}$$

On en déduit

$$\mathbb{P}(g(X)\neq Y)-\mathbb{P}(g^*(X)\neq Y) = \mathbb{P}(g(X)\neq g^*(X), Y=g^*(X))-\mathbb{P}(g(X)\neq g^*(X), Y\neq g^*(X))\ .$$

En conditionnant par rapport à X, il vient

$$\begin{aligned}\mathbb{P}(g(X)\neq Y)-\mathbb{P}(g^*(X)\neq Y) &= \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\mathbb{P}(Y=g^*(X)|X)\right] - \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\mathbb{P}(Y\neq g^*(X)|X)\right) \\ &= \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\{\mathbb{1}_{\{g^\star(X)=1\}}\eta^\star(X) + \mathbb{1}_{\{g^\star(X)=-1\}}(1-\eta^\star(X))\}\right] \\ &- \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\{\mathbb{1}_{\{g^\star(X)=1\}}(1-\eta^\star(X)) + \mathbb{1}_{\{g^\star(X)=-1\}}\eta^\star(X)\}\right) \\ &= \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\mathbb{1}_{\{g^\star(X)=1\}}\left(2\eta^\star(X)-1\right)\right] \\ &+ \mathbb{E}\left[\mathbb{1}_{\{g(X)\neq g^*(X)\}}\mathbb{1}_{\{g^\star(X)=-1\}}\left(1-2\eta^\star(X)\right)\right]\ .\end{aligned}$$

Ce qui conclut la preuve.

2. On a

$$\begin{aligned}\mathbb{1}_{\{g(X)\neq g^*(X)\}} &= \mathbb{1}_{\{\eta(X)<1/2\leq\eta^*(X)\}} + \mathbb{1}_{\{\eta(X)\geq 1/2>\eta^*(X)\}} \\ &\leqslant \mathbb{1}_{\{|\eta^*(X)-1/2|\leq|\eta^*(X)-\eta(X)|\}}\ .\end{aligned}$$

Ce qui donne le résultat en utilisant la question précédente.