Dans les exercices ci-dessous, sauf mention explicite, on considère un couple de variables aléatoires (X, Y) d'attributs (la variable X) et de réponses (la variable Y) définies sur $(\Omega, \mathcal{F}, \mathbb{P})$; avec $X \in \mathbb{R}^d$ et $Y \in \{-1, 1\}$. On note

$$\eta : X \mapsto \mathbb{P}(Y = 1 \,|\, X)$$

la fonction de régression.

Exercice 1. Nous considérons le problème de la classification binaire. A la place de la perte 0/1 nous considérons la perte

$$\ell(y, g(x)) := \begin{cases} c & si\ g(x) = -1,\ y = 1 \\ 1 & si\ g(x) = 1,\ y = -1 \\ 0 & \text{sinon} \end{cases},$$

où $c > 0$.

1. Déterminer l'expression du risque de classification $R(g) := \mathbb{E}[\ell(Y, g(X))]$ d'une règle g en fonction de $\{g(X) = -1\}$, de la fonction de régression η et du coût c.
2. Montrer que $g_c^\star(X) := 2\mathbb{1}_{\{\eta(X) \geq \frac{1}{c+1}\}} - 1$ est une règle de décision bayésienne pour ce risque R.
   Dans le cas $c = 1$, la fonction de perte est la fonction de perte $0 - 1$ et la règle de décision bayésienne $g_1^\star$ coïncide avec celle vue en Amphi.
3. A-t-on unicité de la règle de décision bayésienne ?

Exercice 2. On considère un problème de classification binaire, pour la perte $0 - 1$. On rappelle que un classifieur bayésien est donné par

$$g^\star(X) = 2\mathbb{1}_{\eta(X) \geq 1/2} - 1\ .$$

1. Montrer que le risque bayésien $R(g^\star)$ vérifie

   $$R(g^\star) = \mathbb{E}[\min(\eta(X), 1 - \eta(X))]$$

   On rappelle que pour deux réels a, b : $\min(a, b) + |b - a|/2 = (a + b)/2$. En déduire que

   $$R(g^\star) = \frac{1}{2} - \frac{1}{2}\mathbb{E}[|2\eta(X) - 1|]\ .$$

   Cela entraine que $R(g^\star) \leq 1/2$ et que $R(g^\star) = 1/2$ ssi $\mathbb{P}(\eta(X) = 1/2) = 1$.
2. Montrer que pour tout classifieur g, nous avons

   $$R(g) = \mathbb{E}\left[\mathbb{1}_{\{g(X)=-1\}}(2\eta(X) - 1) + (1 - \eta(X))\right]\ . \tag{1}$$

3. Soient deux classifieurs g_1, g_2 ; déduire de la question précédente que

   $$|R(g_1) - R(g_2)| \leq \mathbb{E}\left[|2\eta(X) - 1|\mathbb{1}_{\{g_1(X) \neq g_2(X)\}}\right]\ .$$

   Puisque $\eta(X) \in [0, 1]$, $|2\eta(X) - 1| \leq 1$ et par suite, nous avons la majoration

   $$|R(g_1) - R(g_2)| \leq \mathbb{P}(g_1(X) \neq g_2(X))\ .$$

4. Etant donnée une fonction $\tilde{\eta} : X \mapsto \tilde{\eta}(X) \in [0,1]$, on définit le classifieur $\tilde{g}$ par

$$\tilde{g}(X) := 2\mathbb{1}_{\{\tilde{\eta}(x) \geq 1/2\}} - 1 \ .$$

Déduire de la question 3 que

$$R(\tilde{g}) - R(g^\star) \leq 2\,\mathbb{E}\left[|\eta(X) - \tilde{\eta}(X)|\mathbb{1}_{\{g^\star(X) \neq \tilde{g}(X)\}}\right] \ .$$

5. Appelons $\mathbb{Q}$ la loi de (X,Y). En pratique, cette loi est inconnue ; aussi la fonction de régression η est-elle inconnue, et le classifieur bayésien $g^\star$ ne peut-il pas être appliqué. Supposons que l'on dispose d'un ensemble d'apprentissage $\mathcal{D}_n := \{(X_1,Y_1), \cdots, (X_n,Y_n)\}$, modélisé comme un n-échantillon de la loi $\mathbb{Q}$. A l'aide de $\mathcal{D}_n$, on apprend une approximation $\tilde{\eta}_n : X \mapsto \tilde{\eta}_n(X) \in [0,1]$ de la fonction η et on considère le classifieur

$$\tilde{g}_n(X) := 2\mathbb{1}_{\tilde{\eta}_n(X) \geq 1/2} - 1 \ .$$

En utilisant la question 4, montrer que si pour $\mathbb{Q}$-presque tout x, $\tilde{\eta}_n(x) - \eta(x) \overset{\mathbb{P}_n-\text{prob}}{\longrightarrow} 0$, alors

$$\lim_n \mathbb{E}_n\left[R(\tilde{g}_n) - R(g^\star)\right] = 0.$$

L'exercice 3 donne un exemple d'apprentissage d'une approximation $\tilde{\eta}_n$ de la fonction de régression η, à partir de $\mathcal{D}_n$.

Exercice 3. On considère un problème de classification binaire lorsque les attributs sont vectoriels ($X \in \mathbb{R}^d$). On suppose que la loi du couple (X,Y) est donnée par

— Conditionnellement à $Y = i$, la loi des attributs X est une loi gaussienne de moyenne $\mu_i \in \mathbb{R}^d$ et de matrice de covariance Σ_i ; nous supposerons Σ_{-1}, Σ_1 inversibles.

— La variable réponse Y suit une loi de Bernoulli de paramètre π_1. On pose $\pi_{-1} := \mathbb{P}(Y = -1) = 1 - \pi_1$.

En pratique, les paramètres $\theta := (\pi_1, \mu_{-1}, \mu_1, \Sigma_{-1}, \Sigma_1)$ qui définissent ces lois sont inconnus : ils vont être appris à l'aide d'un ensemble d'apprentissage $\mathcal{D}_n$.

1. Montrer que la fonction de régression est donnée par

$$\eta_\theta(x) = \frac{1}{1 + \exp(-\phi_\theta(x))} = \text{sigm}(\phi_\theta(x)) \ ,$$

où sigm est la fonction sigmoïde $t \mapsto 1/(1+\exp(-t))$ et ϕ_θ est une fonction que l'on précisera.
Interpréter la règle de classification

$$g_\theta(X) := 2\mathbb{1}_{\{\eta_\theta(X) \geq 1/2\}} - 1.$$

2. Montrer que si l'on modélise la loi de (X,Y) en supposant que $\Sigma_{-1} = \Sigma_1 = \Sigma$, alors il existe $w_\theta \in \mathbb{R}^d$ et $A_\theta \in \mathbb{R}$ tels que $\phi_\theta(x) = w_\theta^T x + A_\theta$.
Interpréter la règle de classification dans ce cas.

Dans le cas où $\Sigma_1 = \Sigma_{-1}$, on parle de "Linear Discriminant Analysis" (LDA) ; tandis que dans le cas général $\Sigma_1 \neq \Sigma_{-1}$, on parle de "Quadratic Discriminant Analysis" (QDA).

On dispose d'un ensemble d'apprentissage $\{(X_i, Y_i)\}_{i=1}^n$ vu comme un n-échantillon du modèle

$$\Big(\mathbb{R}^d \times \{-1,1\}, \mathcal{B}(\mathbb{R}^d) \times \{-1,1\}, \{\mathbb{Q}_\theta, \theta \in \Theta :=]0,1[\times \mathbb{R}^d \times \mathbb{R}^d \times M_d^+ \times M_d^+\}\Big)$$

où M_d^+ est l'ensemble des matrices de covariance $d \times d$ inversibles.

3. Ecrire la log-vraisemblance des observations.
4. Calculer l'estimateur du maximum de vraisemblance $\hat{\theta}_n$ de θ.
5. Montrer qu'il est consistant.
6. Soit la règle de classification $\tilde{g}_n(X) := 2\mathbb{1}_{\{\eta_{\hat{\theta}_n}(X) \geq 1/2\}} - 1$. En utilisant la question 5 de l'exercice 2, montrer que pour tout $\theta \in \Theta$,

$$\lim_n \mathbb{E}_{n,\theta}\left[|R(\tilde{g}_n) - R(g_\theta^\star)|\right] = 0,$$

où $R(g_\theta^\star)$ est le risque bayésien i.e. le risque de la règle de classification

$$g^\star(X) := 2\mathbb{1}_{\{\eta_\theta(X) \geq 1/2\}} - 1.$$

7. Reprendre ces questions dans le cas du modèle plus simple où l'on suppose que les deux classes ont même covariance ($\Sigma_{-1} = \Sigma_1 = \Sigma$).
8. Dans cette configuration de covariance commune, comment étendre cette méthode à plus de deux classes ?

La figure 1 illustre cette situation. Nous avons $X \in \mathbb{R}^2$ et $Y \in \{-1,1\}$: on représente des ensembles d'apprentissage $\mathcal{D}_n$ en indiquant en noir tous les attributs X_i de la classe -1 (i.e. tels que $Y_i = -1$) ; et en rouge ceux de la classe 1.
Ces ensembles d'apprentissage ont été simulés : on a choisi une valeur de $\pi_1^\star$ et tiré des v.a. réponses $Y_i \sim 2\mathcal{B}(\pi_1^\star) - 1$; puis on a choisi une valeur $\mu_{-1}^\star, \mu_1^\star, \Sigma_{-1}^\star, \Sigma_1^\star$, et à chaque réponse Y_i valant 0 on a associé un attribut $X_i \sim \mathcal{N}(\mu_{-1}^\star, \Sigma_{-1}^\star)$ et à chaque réponse Y_i valant 1 on a associé un attribut $X_i \sim \mathcal{N}(\mu_1^\star, \Sigma_1^\star)$. Pour les ensembles $\mathcal{D}_n$ affichés lignes 1 et 2, nous avons pris $\Sigma_{-1}^\star = \Sigma_1^\star$ tandis que pour ceux affichés lignes 3 et 4, nous avons pris $\Sigma_{-1}^\star \neq \Sigma_1^\star$. Dans toutes les lignes, nous avons pris $\mu_{-1}^\star \neq \mu_1^\star$.
Pour chacun des quatre ensembles d'apprentissage (lignes 1 à 4), nous avons appris le paramètre $\widehat{\theta}_n$; puis l'avons utilisé pour construire un classifieur LDA (colonne de gauche) et un classifieur QDA (colonne de droite). Les frontières de classification (qui séparent l'ensemble des points $X \in \mathbb{R}^2$ qui seront tels que $g_{\hat{\theta}_n}(X) = -1$ de ceux tels que $g_{\hat{\theta}_n}(X) = 1$) sont représentées en gris.
Enfin, nous avons utilisé le classifieur $g_{\hat{\theta}_n}$ pour classer chaque point de l'ensemble d'apprentissage (en ignorant leur vrai label Y_i). Afin de visualiser la qualité de ce classifieur, nous avons distingué les attributs correctement classés de ceux mal classés : un attribut X_i tel que $g_{\hat{\theta}_n}(X_i) \neq Y_i$ est indiqué par une croix.

Exercice 4. Soient (X, Y) et (X', Y') deux couples de variables aléatoires définies sur $(\Omega, \mathcal{F}, \mathbb{P})$ et de même loi. On suppose que $\mathbb{E}[|X|] < \infty$.

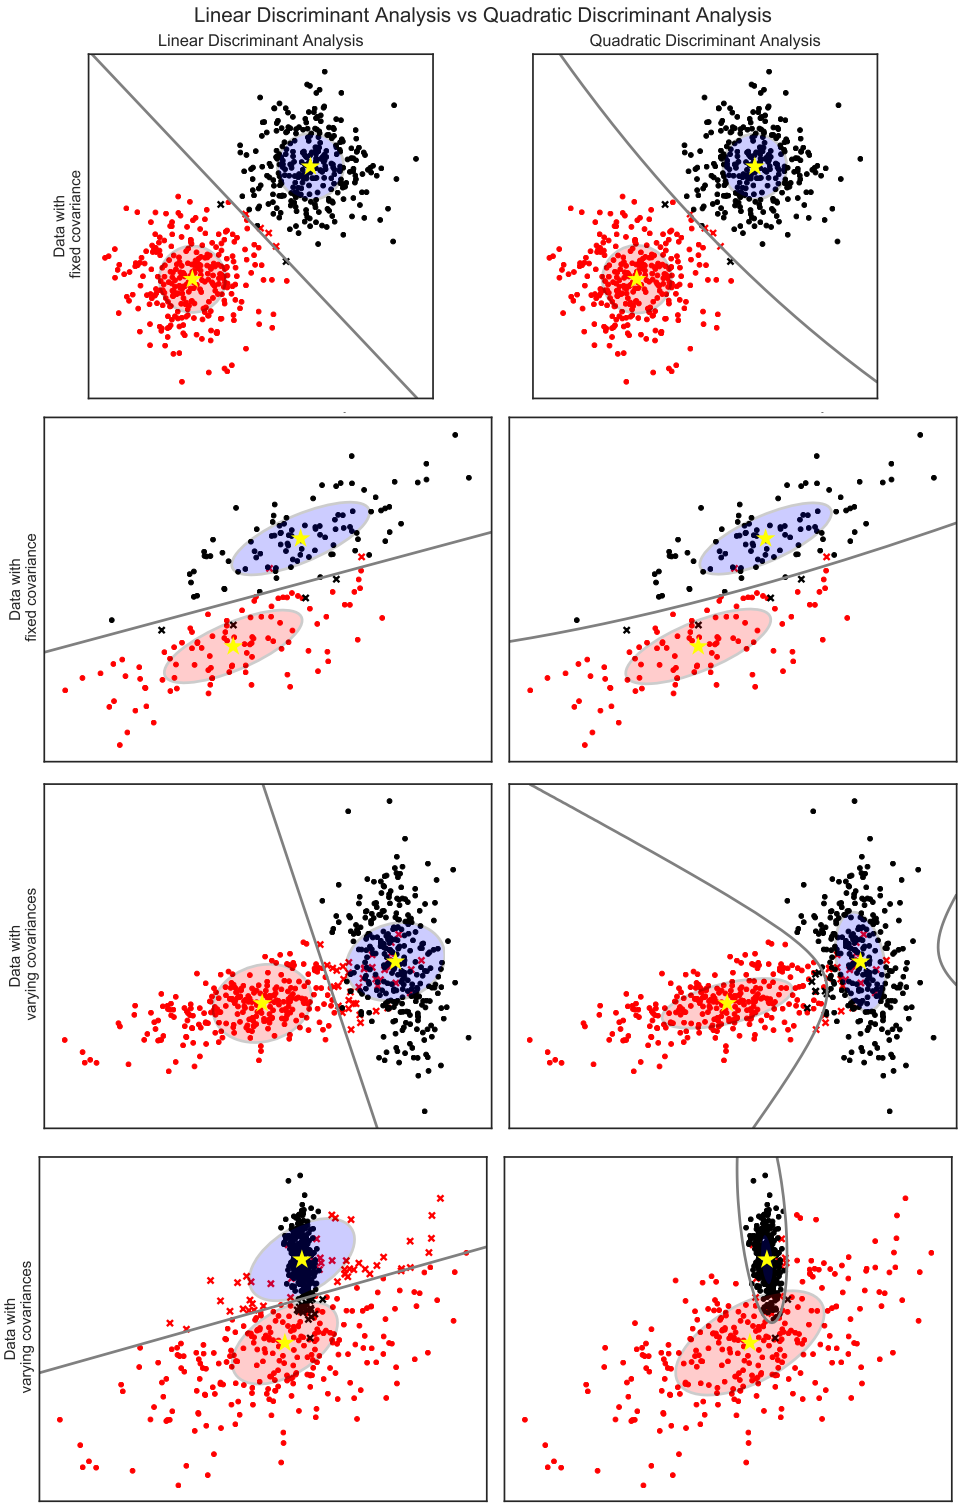


FIGURE 1 – Exercice 3. Classifieurs LDA (colonne de gauche) et QDA (colonne de droite), et quatre ensembles d'apprentissage (lignes 1 à 4). La ligne grise correspond à la ligne de séparation des classes par le classifieur $g_{\hat{\theta}_n}$. Les moyennes de chaque classe sont représentées par les $\star$. Les attributs qui sont mal classés sont représentés par des $\times$. Deux premières lignes : les données d'apprentissage sont issues de deux populations avec même matrice de covariance (et sur la première ligne, $\Sigma^{\star}_{-1} = \Sigma^{\star}_{1} = \mathrm{I}$) ; et dans les deux dernières lignes, ces matrices sont différentes. Adapted from https://scikit-learn.org/

1. Soit f une fonction mesurable telle que $\mathbb{E}[X \,|\, Y] = f(Y)$ $\mathbb{P}$ −p.s.. Montrer que $\mathbb{E}[X' \,|\, Y'] = f(Y')$ $\mathbb{P}$ − p.s.. En déduire que $\mathbb{E}[X \,|\, Y]$ et $\mathbb{E}[X' \,|\, Y']$ ont même loi.
2. Supposons que la loi de la variable X soit symétrique. Déterminer $\mathbb{E}[X \,|\, |X|]$.
3. Soient $(X_1, \ldots, X_n)$ des variables aléatoires réelles i.i.d. intégrables. Déterminer $\mathbb{E}[X_i \,|\, X_1 + \cdots + X_n]$.

Exercice 5. Considérons le problème de la classification binaire pour la perte 0/1. On se place dans le cas $d = 1$, et suppose que $\mathbb{P}(Y = -1) = \mathbb{P}(Y = 1) = 1/2$ et que

$$\mathbb{P}(X \leq x | Y = -1) = \begin{cases} 0 & \text{si } x \leq 0 \\ x/2 & \text{si } 0 < x \leq 2 \\ 1 & \text{si } x > 2 \end{cases}$$

et

$$\mathbb{P}(X \leq x | Y = 1) = \begin{cases} 0 & \text{si } x \leq 1 \\ (x-1)/3 & \text{si } 1 < x \leq 4 \\ 1 & \text{si } x > 4 \end{cases} .$$

1. Déterminer la distribution marginale des attributs.
2. Calculer la fonction de régression η.
3. Utiliser les informations ci-dessus pour calculer le risque du classifieur bayésien.
4. Quel est l'excès de risque de la règle de classification $g(x) = 2\mathbb{1}_{\{x \geq 1\}}$ -1 ?

Exercice 6. On suppose que les attributs sont à valeur réelle ($d = 1$) et on considère la classe $\mathcal{C}$ de règles de classification données par : pour $x' \in \mathbb{R}$ et $y' \in \{-1, 1\}$,

$$g_{(x',y')}(x) := \begin{cases} y' & \text{si } x \leq x' \\ -y' & \text{autrement} \end{cases} .$$

On note $p := \mathbb{P}(Y = 1)$ la probabilité de la classe 1 et $F_i(x)$ la fonction de répartition des attributs conditionnellement à leur appartenance à la classe i ; $i \in \{-1, 1\}$.

1. Montrer que le minimum du risque R dans la classe $\mathcal{C}$ est donné par :

$$R = \inf_{x'} \left(pF_1(x') + (1-p)(1 - F_0(x')) \right) \quad \wedge \quad \inf_{x'} \left(p(1 - F_1(x')) + (1-p)F_0(x') \right).$$

2. Montrer que $R \leq \min(p, (1-p))$. En déduire que $R \leq 1/2$.
3. On définit $R^\star$ comme étant le risque du classifieur Bayésien. Montrer que $R = 1/2$ si et seulement si $R^\star = 1/2$.
4. Montrer que

$$R = \frac{1}{2} - \frac{1}{2} \sup_x |1 - 2\left(p(1 - F_1(x)) + (1-p)F_0(x)\right)| .$$

Exercice 7. On considère un problème de classification binaire. On note $\eta(X)$ la fonction de regression et $g^*(X) := 2\mathbb{1}_{\{\eta^*(X)\geq 1/2\}} - 1$ le classifieur bayésien pour la perte 0/1. Soit $\eta : \mathbb{R}^d \to [0,1]$ une fonction et $g(x) := 2\mathbb{1}_{\{\eta(x)\geq 1/2\}} - 1$ la règle de décision associée.

1. Montrer que

$$R(g) - R(g^\star) = \mathbb{P}(g(X) \neq Y) - \mathbb{P}(g^*(X) \neq Y) = 2\mathbb{E}[\mathbb{1}_{\{g(X)\neq g^*(X)\}}|\eta^*(X) - 1/2|] \,.$$

2. En déduire que

$$R(g) - R(g^\star) = \mathbb{P}(g(X) \neq Y) - \mathbb{P}(g^*(X) \neq Y) \leq 2\mathbb{E}[|\eta^*(X) - \eta(X)|] \,.$$