4 Les compléments

Les contenus de cette partie ne sont pas exigibles. Ils donnent deux modèles où tout se calcule à la main, la propriété d'optimalité quadratique de la fonction de régression, la notion de risque empirique et le phénomène de sur-apprentissage qu'elle entraîne, la distinction entre probabilité d'erreur conditionnelle et risque moyen, la définition de la consistance d'une suite de classifieurs, le compromis entre risque d'approximation et risque d'estimation, la démonstration de la majoration employée à la proposition 1.5, et une présentation des perceptrons et des réseaux de neurones.

4.1 Un modèle jouet

Le modèle suivant est le plus simple sur lequel la fonction de régression, la règle bayésienne et son risque se calculent entièrement.

Exemple 4.1: Attribut uniforme et classe à deux niveaux

L'attribut X est scalaire, de loi uniforme sur $[-1,1]$; étant donné un attribut $x \in [0,1]$, l'individu est de la classe 1 dans 90 % des cas, et dans 10 % des cas lorsque $x \in [-1,0[$. Autrement dit,

$$q_{Y|X}(1 \mid x) = \begin{cases} 0{,}9 & \text{si } x \in [0,1] \ , \\ 0{,}1 & \text{si } x \in [-1,0[\ , \end{cases} \qquad \mathbb{P}(X \in A) = \frac{1}{2} \int_{A \cap [-1,1]} \mathrm{d}x \ .$$

Le couple (X,Y) admet alors, par rapport à $\mathrm{Leb} \otimes \mathrm{c}$, la densité

$$p_{X,Y}(x,1) = \frac{0{,}9}{2} \, \mathbb{1}_{[0,1]}(x) + \frac{0{,}1}{2} \, \mathbb{1}_{[-1,0[}(x) \ , \qquad p_{X,Y}(x,-1) = \frac{0{,}1}{2} \, \mathbb{1}_{[0,1]}(x) + \frac{0{,}9}{2} \, \mathbb{1}_{[-1,0[}(x) \ ,$$

de sorte que $p = \mathbb{P}(Y=1) = \frac{1}{2}\int_0^1 0{,}9 \, \mathrm{d}x + \frac{1}{2}\int_{-1}^0 0{,}1 \, \mathrm{d}x = 1/2$. La fonction de régression vaut $\eta(x) = 0{,}9$ sur $[0,1]$ et $\eta(x) = 0{,}1$ sur $[-1,0[$, et la règle bayésienne est la règle à seuil $g^\star(x) = 2\,\mathbb{1}_{[0,1]}(x) - 1$. Son risque se calcule directement :

$$\begin{aligned} \mathbb{P}(g^\star(X) \neq Y) &= \mathbb{P}(X \geq 0, Y = -1) + \mathbb{P}(X < 0, Y = 1) \\ &= \int_0^1 p_{X,Y}(x,-1) \, \mathrm{d}x + \int_{-1}^0 p_{X,Y}(x,1) \, \mathrm{d}x = \frac{0{,}1}{2} + \frac{0{,}1}{2} = 0{,}1 \ , \end{aligned}$$

ce que la formule (5) redonne : $\mathbb{E}[\min(\eta(X), 1-\eta(X))] = 0{,}1$.

4.2 La fonction de régression comme meilleure approximation quadratique

Le théorème 1.1 dit que l'espérance conditionnelle minimise l'erreur quadratique. Appliqué à la classification binaire, il prend la forme suivante, où l'on compare non plus des règles à valeurs dans $\{-1,1\}$ mais des fonctions à valeurs dans $[0,1]$.

Proposition 4.1: Optimalité quadratique de la fonction de régression

Soit η la fonction de régression du modèle de classification binaire avec $Y \in \{0,1\}$ et soit $g : \mathbb{R}^d \to [0,1]$ une fonction mesurable. Alors

$$\mathbb{E}\left[(\eta(\mathbf{X}) - Y)^2\right] \leq \mathbb{E}\left[(g(\mathbf{X}) - Y)^2\right] \ .$$

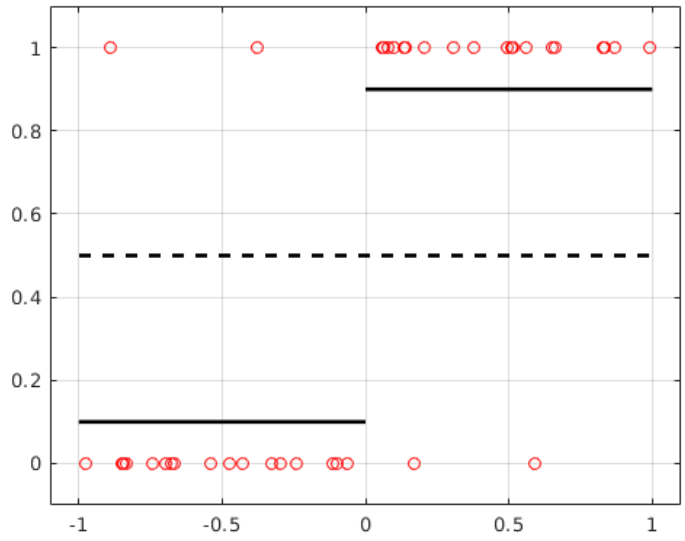


FIGURE 7 – Quarante réalisations indépendantes (x_k, y_k) du modèle de l'exemple 4.1. Le trait plein noir représente la fonction de régression η, le trait pointillé la droite d'équation $y = 1/2$. La figure code les deux classes par les ordonnées 0 et 1, là où le chapitre les note -1 et 1 : la règle bayésienne prédit la classe supérieure sur l'ensemble des x où $\eta(x)$ dépasse $1/2$, et quatre des quarante points sont mal classés.

Démonstration

En développant $(g(\mathbf{X}) - Y)^2 = (g(\mathbf{X}) - \eta(\mathbf{X}))^2 + 2(g(\mathbf{X}) - \eta(\mathbf{X}))(\eta(\mathbf{X}) - Y) + (\eta(\mathbf{X}) - Y)^2$ et en prenant l'espérance, le terme croisé vaut

$$\mathbb{E}\left[(g(\mathbf{X}) - \eta(\mathbf{X}))\,\mathbb{E}\left[\eta(\mathbf{X}) - Y \,|\, \mathbf{X}\right]\right] = \mathbb{E}\left[(g(\mathbf{X}) - \eta(\mathbf{X}))\,\left(\eta(\mathbf{X}) - \mathbb{E}\left[Y \,|\, \mathbf{X}\right]\right)\right] = 0\,,$$

par la propriété du produit (proposition 2.3) et par $\eta(\mathbf{X}) = \mathbb{E}\left[Y \,|\, \mathbf{X}\right]$, qui est la définition de η lorsque Y est à valeurs dans $\{0, 1\}$. Il reste $\mathbb{E}[(g(\mathbf{X}) - Y)^2] = \mathbb{E}[(g(\mathbf{X}) - \eta(\mathbf{X}))^2] + \mathbb{E}[(\eta(\mathbf{X}) - Y)^2] \geq \mathbb{E}[(\eta(\mathbf{X}) - Y)^2]$. □

Le lemme de décomposition selon la fonction de régression (lemme 2.2) appartient au même cercle d'idées : il figure dans la partie « Les outils mathématiques » parce que la démonstration du théorème 1.2 le mobilise.

4.3 Risque empirique et sur-apprentissage

À défaut de connaître la loi de $(\mathbf{X}, Y)$, on peut songer à remplacer le risque par sa version empirique, calculée sur l'ensemble d'apprentissage.

Définition 4.1: Risque empirique

Pour la perte 0–1, le *risque empirique* associé à l'ensemble d'apprentissage $\mathcal{D}_n = \{(\mathbf{X}_k, Y_k), 1 \leq k \leq n\}$ est

$$\widehat{\mathrm{R}}_n(g) := \frac{1}{n} \sum_{k=1}^{n} \mathbb{1}_{\{g(\mathbf{X}_k) \neq Y_k\}}\,.$$

La loi des grands nombres montre que, pour toute règle de classification g *fixée*, $\widehat{\mathrm{R}}_n(g)$ converge en probabilité vers $R(g)$. Mais minimiser $\widehat{\mathrm{R}}_n$ sur l'ensemble de toutes les règles ne donne rien : considérons la règle

$$g_{\mathrm{bad},n}(\mathbf{x}) = \begin{cases} Y_k & \text{si } \mathbf{x} = \mathbf{X}_k \text{ pour un } k \in \{1, \dots, n\} \ , \\ -1 & \text{sinon .} \end{cases}$$

Son risque empirique est nul, donc elle minimise $\widehat{\mathrm{R}}_n$; pourtant elle prédit la classe -1 pour tout attribut qui n'a pas été observé pendant l'apprentissage, ce qui n'a aucune raison d'être une bonne décision. On peut d'ailleurs modifier $g_{\mathrm{bad},n}$ en tout point hors de $\{\mathbf{X}_1, \dots, \mathbf{X}_n\}$ sans changer son risque empirique : il existe donc une infinité de règles de risque empirique nul, dont la plupart sont mauvaises.

Exemple 4.2: Sur-apprentissage

La Figure 8 montre un ensemble d'apprentissage en dimension $d = 2$ engendré par un mélange de deux lois gaussiennes de même matrice de covariance, et une frontière de décision qui se contorsionne pour étiqueter correctement tous les points de l'ensemble d'apprentissage. Si la loi des observations était connue, le classifieur bayésien serait, d'après la Section 1.3, un hyperplan. La frontière de la figure classe mieux les données d'apprentissage et moins bien les données nouvelles : c'est le *sur-apprentissage*.

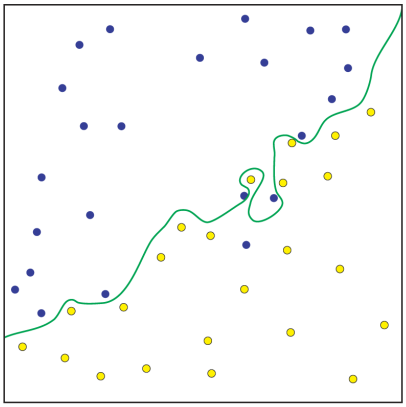


FIGURE 8 – Un exemple de sur-apprentissage. La frontière de décision du classifieur s'adapte de façon à étiqueter correctement toutes les données d'apprentissage, alors que le classifieur bayésien est ici un hyperplan.

4.4 Probabilité d'erreur conditionnelle et risque moyen

Lorsque la règle est construite sur l'ensemble d'apprentissage, elle est aléatoire, et son risque l'est aussi. Il faut alors distinguer deux quantités.

La règle s'écrit $\widehat{g}_n : \mathbf{x} \mapsto \widehat{g}_n(\mathbf{x}) := g(\mathbf{x}; \mathbf{X}_1, Y_1, \dots, \mathbf{X}_n, Y_n)$, que l'on note aussi $g(\mathbf{x}; \mathcal{D}_n)$. Sa performance est mesurée par la *probabilité d'erreur conditionnelle*, ou risque de classification conditionnel,

$$R(\widehat{g}_n) := \mathbb{P}\left(\widehat{g}_n(\mathbf{X}) \neq Y \,|\, \mathcal{D}_n\right) \ ,$$

où $(\mathbf{X}, Y)$ est un couple de même loi que les paires de $\mathcal{D}_n$ et **indépendant** de $\mathcal{D}_n$. C'est une *variable aléatoire*, fonction de $\mathcal{D}_n$: le conditionnement par $\mathcal{D}_n$ sépare l'aléa de l'échantillon d'apprentissage

de celui du couple de test. Cette quantité s'interprète comme l'erreur de généralisation : on a appris une règle sur $\mathcal{D}_n$, et l'on évalue en moyenne la perte $\mathbb{1}_{\{\widehat{g}_n(\mathbf{X})\neq Y\}}$ sur un exemple nouveau. Son calcul repose sur la proposition 2.5, appliquée avec $U = (\mathbf{X}, Y)$ et $V = \mathcal{D}_n$, qui sont indépendants.

L'espérance de cette variable, appelée *risque moyen*, est

$$\mathbb{E}\left[R(\widehat{g}_n)\right] = \mathbb{P}\left(\widehat{g}_n(\mathbf{X};\mathcal{D}_n) \neq Y\right) \ ,$$

la moyenne étant cette fois prise sur la loi des n paires qui constituent l'ensemble d'apprentissage. C'est cette quantité qui apparaît dans la proposition 1.5, sous le nom $\mathbb{E}_{n,\theta^\star}[R_{01}(\widehat{g}_n)]$.

4.5 Consistance d'une suite de classifieurs

Le risque bayésien est la meilleure performance accessible. À défaut de savoir calculer une règle bayésienne, on peut espérer construire une suite de règles dont le risque s'en approche quand la taille de l'ensemble d'apprentissage croît.

Définition 4.2: Consistance d'une suite de classifieurs

Soit $\{(\mathbf{X}_k, Y_k), k \in \mathbb{N}^*\}$ une suite de variables aléatoires i.i.d. de même loi que $(\mathbf{X}, Y)$, et soit $\{\widehat{g}_n, n \geq 1\}$ une suite de classifieurs construite à partir des ensembles d'apprentissage $\{\mathcal{D}_n, n \geq 1\}$, $\widehat{g}_n(\cdot) = g(\cdot\,;\mathcal{D}_n)$. La suite est dite *faiblement consistante* si

$$R(\widehat{g}_n) \overset{\mathbb{P}-\text{prob}}{\longrightarrow} R^\star \ . \tag{15}$$

Comme $R(\widehat{g}_n) \geq R^\star$ par définition du risque bayésien, cela revient à dire que pour tout $\varepsilon > 0$, $\lim_n \mathbb{P}(R(\widehat{g}_n) > R^\star + \varepsilon) = 0$. Pour la perte 0–1, le risque est majoré par 1, de sorte que $R^\star \leq R(\widehat{g}_n) \leq 1$ et que (15) équivaut à la convergence en espérance

$$\lim_{n\to\infty} \mathbb{E}\left[R(\widehat{g}_n)\right] = R^\star \ . \tag{16}$$

Démontrons cette équivalence. Si (16) a lieu, l'inégalité de Markov donne, pour tout $\delta > 0$,

$$\mathbb{P}\left(R(\widehat{g}_n) - R^\star \geq \delta\right) \leq \delta^{-1}\left\{\mathbb{E}[R(\widehat{g}_n)] - R^\star\right\} \xrightarrow[n\to\infty]{} 0 \ .$$

Réciproquement, si (15) a lieu, alors, puisque $R^\star \leq R(\widehat{g}_n) \leq 1$,

$$\mathbb{E}\left[R(\widehat{g}_n)\right] - R^\star \leq \mathbb{P}\left(R(\widehat{g}_n) - R^\star \geq \delta\right) + \delta$$

pour tout $\delta > 0$, en séparant selon que $R(\widehat{g}_n) - R^\star$ dépasse δ ou non ; le premier terme tend vers zéro et δ est arbitraire.

Une suite de classifieurs est jugée bonne lorsque son risque moyen converge vers le risque bayésien *quelle que soit* la loi du couple $(\mathbf{X}, Y)$; on parle alors de *consistance universelle*. C'est le sujet du chapitre 6 de *A Probabilistic Theory of Pattern Recognition* de L. Devroye, L. Györfi et G. Lugosi.

4.6 Compromis entre risque d'approximation et risque d'estimation

La Section 4.3 a montré que minimiser le risque empirique sur l'ensemble de toutes les règles ne mène à rien. On restreint donc la recherche à une famille $\mathcal{C}$ de classifieurs, et l'on prend

$$\widehat{g}_n \in \arg\min_{g\in\mathcal{C}} \frac{1}{n}\sum_{k=1}^{n} \mathbb{1}_{\{g(\mathbf{X}_k)\neq Y_k\}} \ .$$

L'écart entre le risque moyen de $\widehat{g}_n$ et le risque bayésien,

$$\mathbb{E}\left[R(\widehat{g}_n)\right] - R^\star \ ,$$

se décompose alors en deux termes :

$$\underbrace{\mathbb{E}\left[R(\widehat{g}_n)\right] - \inf_{g\in\mathcal{C}} R(g)}_{\text{risque d'estimation}} + \underbrace{\inf_{g\in\mathcal{C}} R(g) - R^\star}_{\text{risque d'approximation}} \quad .$$

Le risque d'estimation mesure à quel point $\widehat{g}_n$, construit sur les données, approche le meilleur classifieur de la classe $\mathcal{C}$; il dépend de la taille de $\mathcal{C}$ et de l'algorithme employé. Le risque d'approximation quantifie la perte due au choix de $\mathcal{C}$; il ne dépend pas des données d'apprentissage, mais seulement de $\mathcal{C}$ et de la loi de $(\mathbf{X}, Y)$.

Les deux cas extrêmes éclairent le compromis. Si $\mathcal{C}$ est petite – à la limite, un singleton –, le risque d'estimation est faible, voire nul, et le risque d'approximation est grand. Si $\mathcal{C}$ est l'ensemble de toutes les règles de classification, le risque d'approximation est nul et le risque d'estimation est grand.

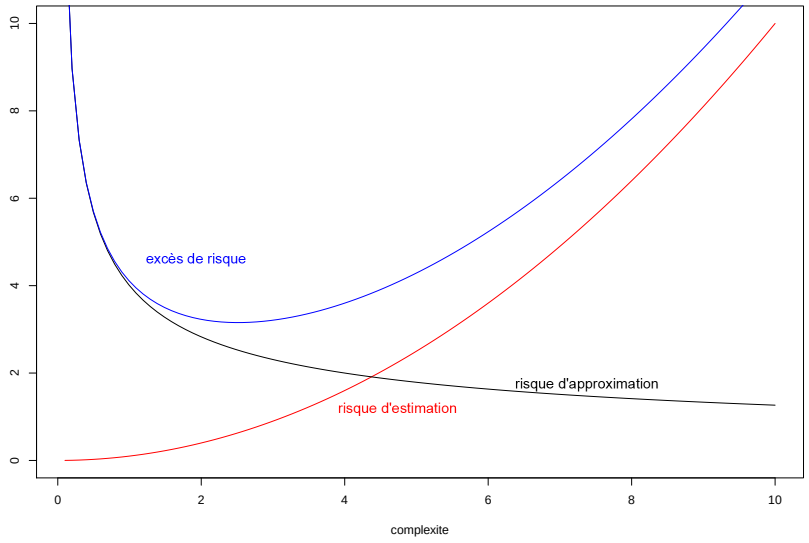


FIGURE 9 – Le compromis entre le risque d'approximation et le risque d'estimation : le premier décroît et le second croît avec la taille de la classe $\mathcal{C}$, et leur somme passe par un minimum.

Exemple 4.3: Classifieurs linéaires

Avec $\mathsf{Y} = \{-1, 1\}$, la classe des classifieurs linéaires sur $\mathbb{R}^d$ est

$$\mathcal{C} = \left\{\mathbf{x} \mapsto g_{\mathbf{w}}(\mathbf{x}) := \text{signe}\left(\mathbf{w}^\top \mathbf{x}\right) \ : \ \mathbf{w} \in \mathbb{R}^d\right\} \ ,$$

où $\text{signe}(t) = 2\,\text{heaviside}(t) - 1$. Minimiser le risque empirique dans cette classe revient à résoudre

$$\mathbf{w}_n^\star \in \arg\min_{\mathbf{w}\in\mathbb{R}^d} \frac{1}{n}\sum_{k=1}^{n} \mathbb{1}_{\{\text{signe}(\mathbf{w}^\top \mathbf{X}_k)\neq Y_k\}} \ ,$$

problème qui n'admet pas en général de solution unique. L'algorithme du perceptron travaille directement sur le vecteur de poids $\mathbf{w}$. Dans sa version stochastique, les attributs sont d'abord normalisés de sorte que $\|\mathbf{X}_k\| = 1$, le vecteur de poids est initialisé à $\mathbf{w}_0 = 0$, et, à chaque itération t, un indice K_t est tiré uniformément dans $\{1, \ldots, n\}$ et le vecteur de poids est mis à jour par

$$\mathbf{w}_{t+1} = \mathbf{w}_t + \gamma\, Y_{K_t}\, \mathbf{X}_{K_t}\, \mathbb{1}_{\{\text{signe}(\mathbf{w}_t^\top \mathbf{X}_{K_t})\neq Y_{K_t}\}} \ ,$$

où $\gamma \in]0,1]$ est un pas. La règle est donc inchangée lorsque l'exemple tiré est bien classé ; lorsqu'il est mal classé, on ajoute au vecteur de poids l'attribut $\mathbf{X}_{K_t}$ si son label vaut 1 et on le retranche si son label vaut -1. Lorsqu'il existe un hyperplan qui sépare parfaitement les deux classes de l'ensemble d'apprentissage, cet algorithme converge ; lorsqu'il n'en existe pas, on peut montrer que la complexité de la minimisation du risque empirique croît exponentiellement avec le nombre d'observations.

Deux stratégies permettent de régler ce compromis. La première restreint la classe $\mathcal{C}$ pour contrôler le risque d'estimation : on se limite par exemple aux discriminateurs linéaires, ou à des architectures de réseaux de neurones simples. La seconde ajoute au risque empirique une *pénalité*, dépendant éventuellement des données, qui mesure la complexité du modèle. Le chapitre 10 en étudie plusieurs. Mentionnons-en deux dès maintenant, de façon informelle.

La méthode du crible (*method of sieves*). On ajuste la complexité de la classe au nombre d'exemples disponibles. On se donne une collection de classes $\{\mathcal{C}_k\}_{k=1}^K$ de complexité croissante – par exemple $\mathcal{C}_k$ l'ensemble des classifieurs de la forme $g(\mathbf{x}) = 2\,\mathbb{1}_{\{a(\mathbf{x})\geq 0\}} - 1$ où a est un polynôme de degré au plus k, de sorte que $\mathcal{C}_1$ est la classe des discriminateurs linéaires et $\mathcal{C}_2$ celle des discriminateurs quadratiques. On calcule, pour chaque classe, la règle $\widehat{g}_k$ qui minimise le risque empirique sur $\mathcal{C}_k$, puis on choisit un indice K_n, dépendant de l'ensemble d'apprentissage, de façon que l'excès de risque de la règle retenue soit proche du meilleur excès de risque accessible dans la collection.

La méthode de validation simple (*hold-out*). On partage les données disponibles en un ensemble d'apprentissage $\mathcal{D}_T := \{(\mathbf{X}_k, Y_k), 1 \leq k \leq m\}$ et un ensemble de validation $\mathcal{D}_V := \{(\mathbf{X}_k, Y_k), m+1 \leq k \leq n\}$. Pour chaque classe $\mathcal{C}_k$, on calcule une règle $\widehat{g}_k^\star$ en n'utilisant que $\mathcal{D}_T$, puis on évalue ces règles sur les données de validation au moyen de l'erreur

$$\widehat{R}_V(g) := \frac{1}{n-m} \sum_{k=m+1}^{n} \mathbb{1}_{\{g(\mathbf{X}_k)\neq Y_k\}} \,,$$

et l'on retient la règle qui la minimise. Les données d'apprentissage servent à construire une famille de règles, les données de validation à en choisir une.

4.7 Excès de risque d'une règle par substitution

La majoration suivante, qui est celle de l'exercice 7, est le point d'appui de la proposition 1.5 : elle ramène le contrôle d'un excès de risque à celui d'une erreur d'estimation de la fonction de régression.

Proposition 4.2: Excès de risque d'une règle par substitution

Soit $\eta^\star$ la fonction de régression, $g^\star := 2\,\mathbb{1}_{\{\eta^\star \geq 1/2\}} - 1$ le classifieur bayésien pour la perte 0–1, $\eta : \mathbb{R}^d \to [0,1]$ une fonction mesurable et $g := 2\,\mathbb{1}_{\{\eta \geq 1/2\}} - 1$ la règle associée. Alors

$$R_{01}(g) - R_{01}(g^\star) = 2\,\mathbb{E}\left[\mathbb{1}_{\{g(\mathbf{X})\neq g^\star(\mathbf{X})\}}\,|\eta^\star(\mathbf{X}) - 1/2|\right] \leq 2\,\mathbb{E}\left[|\eta^\star(\mathbf{X}) - \eta(\mathbf{X})|\right] \,.$$

Démonstration

La première égalité est la formule d'excès de risque (4), où l'on a écrit $|2\eta^\star(\mathbf{X}) - 1| = 2\,|\eta^\star(\mathbf{X}) - 1/2|$.

Pour l'inégalité, plaçons-nous sur l'événement $\{g(\mathbf{X}) \neq g^\star(\mathbf{X})\}$. Les deux règles étant à valeurs dans $\{-1,1\}$ et données par le même seuil appliqué à η et à $\eta^\star$, cet événement s'écrit comme la réunion des deux événements disjoints $\{\eta^\star(\mathbf{X}) \geq 1/2, \eta(\mathbf{X}) < 1/2\}$ et $\{\eta^\star(\mathbf{X}) < 1/2, \eta(\mathbf{X}) \geq 1/2\}$. Sur le premier,

$$|\eta^\star(\mathbf{X}) - 1/2| = \eta^\star(\mathbf{X}) - \frac{1}{2} \leq \eta^\star(\mathbf{X}) - \eta(\mathbf{X}) = |\eta^\star(\mathbf{X}) - \eta(\mathbf{X})| \ ,$$

puisque $\eta(\mathbf{X}) < 1/2 \leq \eta^\star(\mathbf{X})$. Sur le second, de même,

$$|\eta^\star(\mathbf{X}) - 1/2| = \frac{1}{2} - \eta^\star(\mathbf{X}) \leq \eta(\mathbf{X}) - \eta^\star(\mathbf{X}) = |\eta^\star(\mathbf{X}) - \eta(\mathbf{X})| \ .$$

Dans les deux cas $|\eta^\star(\mathbf{X}) - 1/2| \leq |\eta^\star(\mathbf{X}) - \eta(\mathbf{X})|$, et en reportant dans la première égalité,

$$R_{01}(g) - R_{01}(g^\star) \leq 2\,\mathbb{E}\left[\mathbb{1}_{\{g(\mathbf{X}) \neq g^\star(\mathbf{X})\}}\,|\eta^\star(\mathbf{X}) - \eta(\mathbf{X})|\right] \leq 2\,\mathbb{E}\left[|\eta^\star(\mathbf{X}) - \eta(\mathbf{X})|\right] \ ,$$

la dernière majoration tenant à ce que l'indicatrice est majorée par 1 et l'intégrande positif. □

4.8 Perceptrons et réseaux de neurones

Un *discriminateur linéaire* partage l'espace des attributs par un hyperplan et attribue une classe différente à chaque demi-espace. C'est le classifieur

$$g(\mathbf{x}) := \sigma\left(a_0 + \sum_{i=1}^{d} a_i x^{(i)}\right) = \sigma\left(\mathbf{a}^\top \mathbf{x}\right) \ , \qquad \mathbf{x} := \begin{pmatrix} 1 \\ x^{(1)} \\ \vdots \\ x^{(d)} \end{pmatrix} \ , \quad \mathbf{a} := \begin{pmatrix} a_0 \\ a_1 \\ \vdots \\ a_d \end{pmatrix} \ ,$$

où $\mathbf{a}$ est le vecteur des *poids synaptiques*, a_0 le *biais*, et σ la *fonction d'activation*, prise ici égale à la fonction de Heaviside, heaviside$(t) = 0$ si $t \leq 0$ et 1 sinon. Pour obtenir une sortie dans $\{-1,1\}$ plutôt que dans $\{0,1\}$, on remplace σ par $t \mapsto 2\,\text{heaviside}(t) - 1$. La décision est facile à mettre en œuvre : son coût est proportionnel à d. Rosenblatt a nommé ces règles *perceptrons* et proposé de modifier le vecteur de poids au fur et à mesure que de nouvelles données arrivent, ce qui en fait le premier algorithme d'apprentissage séquentiel.

Le perceptron est un réseau de neurones sans couche cachée. Dans un réseau à une couche cachée, chaque neurone $i \in \{1,\ldots,k\}$ calcule une valeur $u_i = \sigma(\psi_i(\mathbf{x}))$ avec $\psi_i(\mathbf{x}) = b_i + \sum_{j=1}^{d} a_{i,j} x^{(j)}$, et le neurone de sortie combine ces valeurs et applique la fonction de Heaviside :

$$g(\mathbf{x}) = \text{heaviside}\left(c_0 + \sum_{i=1}^{k} c_i\,\sigma(\psi_i(\mathbf{x}))\right) \ .$$

La fonction d'activation σ est supposée croissante, de limites 0 en $-\infty$ et 1 en $+\infty$; les choix usuels sont la fonction signe, la fonction logistique $\sigma = \text{sigm}$ de la Section 2.9 et l'arc tangente normalisé $t \mapsto \frac{1}{2}\left(\frac{2}{\pi}\arctan(t) + 1\right)$. En itérant le procédé, on intercale plusieurs couches de neurones cachés entre l'entrée et la sortie.

L'analyse théorique de ces réseaux s'appuie sur un théorème de Kolmogorov (1957) et Lorentz (1976), selon lequel toute fonction continue f sur $[0,1]^d$ s'écrit

$$f(\mathbf{x}) = \sum_{i=1}^{2d+1} F_i\left(\sum_{j=1}^{d} G_{i,j}(x^{(j)})\right) \ ,$$

où F_i et $G_{i,j}$ sont des fonctions continues qui dépendent de f. En pratique, les réseaux multicouches approchent toute fonction mesurable avec une précision arbitraire, même à fonction d'activation fixée.

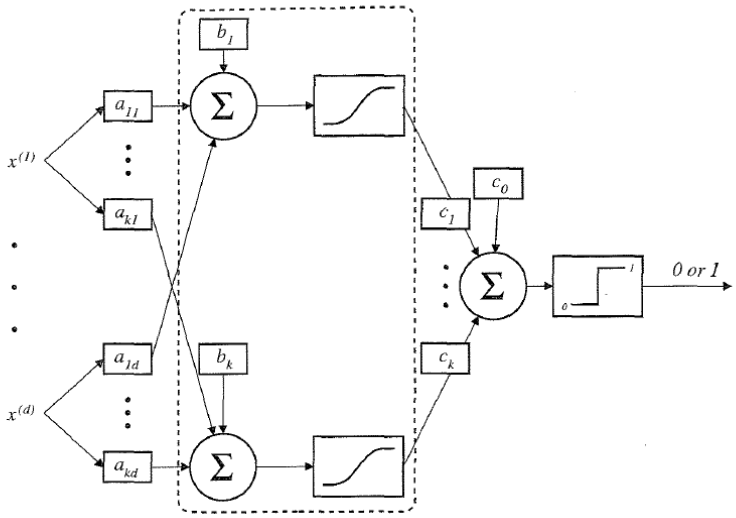


FIGURE 10 – Un réseau de neurones à une couche cachée. Les d entrées transmettent les coordonnées du vecteur d'attributs, les neurones de la couche cachée calculent $\sigma(\psi_i(\mathbf{x}))$, et le neurone de sortie en forme une combinaison linéaire à laquelle il applique la fonction d'activation.