Chapitre 8

Introduction à l'apprentissage statistique

Les sept premiers chapitres relèvent de la statistique : on observe $X_1, \dots, X_n$, on choisit un modèle $(\mathsf{X}, \mathcal{X}, \{\mathbb{P}_\theta \,:\, \theta \in \Theta\})$, et on infère une information sur le paramètre de la loi des observations, par estimation ou par test. La procédure est évaluée sur θ : par son risque quadratique, par son niveau, par sa puissance.
Les trois chapitres qui suivent relèvent de l'apprentissage statistique. Le but change : il s'agit de *prédire* une réponse Y en fonction d'attributs $\mathbf{X}$, à partir d'observations qui sont maintenant des paires $(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$. La procédure n'est plus évaluée sur un paramètre, mais par le risque de la règle de prédiction qu'elle produit. Deux voies y mènent. La première, plus proche de la statistique, modélise la loi jointe de $(\mathbf{X}, Y)$, apprend les paramètres de ce modèle et en déduit une règle de décision. La seconde, plus proche de l'apprentissage, choisit une classe de fonctions et une fonction de perte, et cherche la meilleure règle dans cette classe pour ce risque.
Le cadre de l'apprentissage supervisé tient en quatre objets : des attributs, une réponse, un prédicteur et une fonction de perte dont la moyenne définit le risque. Lorsque la loi de $(\mathbf{X}, Y)$ est connue, la règle de risque minimal se calcule : c'est l'espérance conditionnelle de la réponse sachant les attributs pour la perte quadratique, et le classifieur de Bayes, qui retourne le label le plus probable, pour la perte 0–1 ; une formule explicite donne l'écart entre le risque d'une règle quelconque et ce minimum. Mais le statisticien ne connaît pas la loi de $(\mathbf{X}, Y)$: la règle de Bayes n'est pas une fonction des observations, et le risque bayésien reste une référence théorique à laquelle se comparer. L'approche par modélisation construit alors une règle en estimant les paramètres d'un modèle pour la loi du couple, puis en les substituant dans l'expression de la règle de Bayes ; l'analyse discriminante linéaire et quadratique, le modèle logistique et le modèle linéaire gaussien en sont les trois exemples traités ici.
Les objectifs des chapitres 8 à 10 sont de comprendre et de maîtriser le cadre de l'apprentissage statistique (données, pertes, risque) ; les concepts fondamentaux que sont le risque conditionnel et la règle de Bayes ; la façon dont on peut « apprendre », c'est-à-dire construire des règles de décision à partir des données ; les compromis sous-jacents, absence de règle universellement bonne et sur-apprentissage ; et la façon dont on établit des résultats théoriques sur la qualité des règles ainsi apprises.

Statistique et apprentissage

Jusqu'ici, les observations $X_1, \dots, X_n$ étaient modélisées par une famille de lois $\{\mathbb{P}_\theta : \theta \in \Theta\}$ et l'inconnue était θ. L'apprentissage supervisé conserve une inconnue probabiliste – la loi du couple $(\mathbf{X}, Y)$ – mais déplace la question : on ne cherche plus à décrire cette loi, on cherche une fonction g qui, à un attribut $\mathbf{x}$, associe une prévision $g(\mathbf{x})$ de la réponse. La qualité de g se mesure par la perte moyenne que l'on subit en prédisant $g(\mathbf{X})$ alors que la réponse est Y.

L'intérêt porté à ce domaine vient du nombre de tâches qu'il permet de traiter : la traduction automatique, la reconnaissance d'images, la réponse automatique à des questions posées en langue naturelle, la génération d'images à partir d'une description textuelle, ou encore la prévision météorologique, où les modèles fondés sur l'apprentissage fournissent des prévisions plus rapides, et dans certains cas plus fiables, que la résolution numérique des équations de la dynamique atmosphérique.

Ce qui distingue l'apprentissage de l'informatique traditionnelle est la nature du raisonnement. L'informatique traditionnelle applique une règle donnée à l'avance pour obtenir une réponse : le raisonnement est déductif. L'apprentissage se propose d'*apprendre* la règle à partir des données, puis de l'utiliser : le raisonnement est inductif. L'apprentissage machine et l'apprentissage statistique sont les deux faces d'un même domaine, l'une du côté de l'informatique, l'autre du côté des mathématiques et de la statistique. C'est à ces fondements statistiques que ce chapitre est consacré, dans le cadre de l'apprentissage supervisé.

Intuition. *On peut se représenter la différence de la façon suivante. En statistique, la loi des observations est la cible : on veut savoir quel θ l'a engendrée, et la réponse est d'autant plus précise que n est grand, au point que le risque d'estimation tend vers zéro. En apprentissage, la loi de $(\mathbf{X}, Y)$ n'est qu'un intermédiaire : on veut savoir prédire Y à partir de $\mathbf{X}$, et même en connaissant parfaitement la loi il reste une erreur irréductible, celle que l'on commet parce que $\mathbf{X}$ ne détermine pas Y. Le risque ne tend donc pas vers zéro, il tend au mieux vers le risque de Bayes.*

1 Les fondamentaux

1.1 Le cadre de l'apprentissage supervisé

On observe un individu par un vecteur de caractéristiques et on cherche à prédire une grandeur attachée à cet individu. Le cadre suivant fixe les notations qui serviront dans tout le chapitre.

Cadre 1.1: Apprentissage supervisé

— Les *attributs* $\mathbf{X} \in \mathsf{X} = \mathbb{R}^d$, aussi appelés variables explicatives (*features*).

— La *réponse* $Y \in \mathsf{Y}$.

— Le couple $(\mathbf{X}, Y)$ suit une loi $\mathbb{P}$ sur $\mathsf{X} \times \mathsf{Y}$, et $\mathbb{P}$ est inconnue.

Selon la nature de Y, on parle de

— *classification binaire* si $\mathsf{Y} = \{-1, 1\}$;

— *classification multi-classe* si $\mathsf{Y} = \{0, 1, 2, \dots, K-1\}$;

— *régression* si $\mathsf{Y} = \mathbb{R}$.

Définition 1.1: Prédicteur, classifieur, régresseur

Un *prédicteur* (ou *classifieur*, ou *régresseur*) est une fonction mesurable $g : \mathsf{X} \to \mathsf{Y}$.

Objectif. On dispose d'un *ensemble d'apprentissage* (*training set*)

$$\mathcal{D}_n = \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\} ,$$

formé de n paires indépendantes et de même loi $\mathbb{P}$ que $(\mathbf{X}, Y)$, et l'on cherche à construire à partir de ces données un prédicteur $\widehat{g}_n$.

Le vocabulaire est celui de la prédiction, mais l'objet mathématique est familier : $\mathcal{D}_n$ est un n-échantillon de la loi $\mathbb{P}$ sur $\mathsf{X} \times \mathsf{Y}$, au sens du chapitre 1, et $\widehat{g}_n$ est une statistique à valeurs dans un espace de fonctions. Rien n'est supposé sur la structure de dépendance entre $\mathbf{X}$ et Y ; en particulier, on n'exclut pas que deux individus de mêmes attributs portent des réponses différentes.

Des exemples de problèmes d'apprentissage supervisé

Les trois exemples qui suivent fixent, sur des jeux de données usuels, ce que sont X, Y et n.

Exemple 1.1: Prix de vente de maisons

On observe les caractéristiques d'une maison et on cherche à prédire sa valeur de vente. Le jeu de données *House price prediction* comporte $n = 1500$ exemples. La sortie est la valeur de vente, donc $Y \in \mathbb{R}$: c'est une tâche de régression. Les attributs sont les 81 caractéristiques relevées pour chaque bien – année de construction, quartier, surface, étage, balcon –, de sorte que $\mathbf{X} \in \mathbb{R}^{81}$. Ces caractéristiques sont de natures variées, quantitatives, qualitatives ou ordinales, et leur mise sous forme de vecteur réel est une étape de traitement préalable que l'on suppose faite.

Exemple 1.2: Reconnaissance de chiffres manuscrits

On cherche à reconnaître le chiffre représenté par une image. Le jeu de données MNIST comporte 60 000 images, réparties en 50 000 images d'apprentissage et 10 000 images de test, équilibrées entre les classes ; chaque image est un carré de 28×28 pixels en niveaux de gris, soit $\mathbf{X} \in \mathbb{R}^{784}$ et $d = 784$. Il y a dix classes, $Y \in \{0, 1, 2, \dots, 9\}$: c'est une tâche de classification

multi-classe.

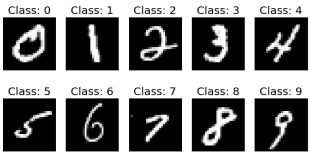


FIGURE 1 – Quelques images du jeu de données MNIST. Chaque image est décrite par les 784 niveaux de gris de ses pixels, et sa réponse est le chiffre qu'elle représente.

D'autres tâches entrent dans le même cadre. La détection de courriels indésirables prend pour attributs une représentation du courriel – par exemple le vecteur, de la taille du dictionnaire, qui compte les occurrences de chaque mot – et pour réponse l'appartenance ou non à la classe des pourriels. La segmentation sémantique d'images associe à chaque pixel d'une image la catégorie de l'objet auquel il appartient. La classification de sentiments prend un texte et lui associe une polarité. La prévision du prix de l'électricité prend l'état du réseau et des marchés et prédit un prix, donc une réponse réelle.

Les trois exemples suivants n'ont qu'un seul attribut, $d = 1$; ils seront repris pour illustrer la règle de Bayes et le choix d'un modèle.

Exemple 1.3: Taille et genre

L'attribut est la taille d'une personne, $X \in \mathbb{R}$, et la réponse est son genre, codé par $Y \in \{-1, 1\}$: c'est un problème de classification binaire. Conditionnellement à chacune des deux valeurs de Y, la taille se répartit autour d'une valeur moyenne propre à la classe, avec une dispersion du même ordre dans les deux classes ; une modélisation naturelle consiste donc à prendre deux lois gaussiennes de moyennes différentes et de même variance. Si de plus les deux classes sont également représentées, la règle optimale compare les deux densités et revient à placer un seuil au milieu des deux moyennes : on prédit une classe en deçà du seuil, l'autre au-delà. Les deux densités conditionnelles se recouvrent largement, et ce recouvrement empêche la probabilité d'erreur de descendre à zéro, quelle que soit la règle employée.

Exemple 1.4: Âge et maladie cardiovasculaire

L'attribut est l'âge d'un patient, $X \in \mathbb{R}$, et la réponse indique la présence ou l'absence d'une maladie cardiovasculaire, $Y \in \{-1, 1\}$. Ici, ce que l'on sait décrire n'est pas la loi de l'âge dans chaque classe, mais la probabilité d'être malade à âge donné : cette probabilité croît avec l'âge, de façon régulière, en restant comprise entre 0 et 1. C'est la forme même du modèle logistique, qui pose que cette probabilité vaut $\mathrm{sigm}(a + b\,x)$ pour deux réels a et b, où sigm est la fonction sigmoïde de la Section 2.9. La règle optimale consiste alors à prédire la présence de la maladie au-delà d'un âge seuil, celui où cette probabilité franchit $1/2$.

Exemple 1.5: Note à l'examen et nombre d'heures de travail

L'attribut est le nombre d'heures de travail consacrées à la préparation d'un examen, $X \in \mathbb{R}$, et la réponse est la note obtenue, $Y \in \mathbb{R}$: c'est un problème de régression. La note croît en moyenne avec le temps de travail, mais deux élèves ayant travaillé le même nombre d'heures n'obtiennent pas la même note. La règle optimale pour la perte quadratique est la note moyenne à temps de travail fixé, c'est-à-dire la fonction $x \mapsto \mathbb{E}[Y \mid X = x]$; si l'on modélise cette moyenne comme une fonction affine du temps de travail, on retrouve la régression linéaire simple, dont l'estimateur des moindres carrés a été introduit au chapitre 2 (exemple 1.15).

Perte et risque

Pour comparer deux prédicteurs, il faut d'abord chiffrer ce que coûte une prévision erronée. C'est le rôle de la fonction de perte, et la moyenne de cette perte définit le risque.

Définition 1.2: Fonction de perte

Une *fonction de perte* est une fonction mesurable positive $\ell : \mathsf{Y} \times \mathsf{Y} \to \mathbb{R}_+$; la quantité $\ell(y, g(\mathbf{x}))$ quantifie la qualité de la prévision $g(\mathbf{x})$ de la réponse y.

— *Perte* 0–1 (classification), pour $y \in \mathsf{Y} = \{-1, 1\}$ ou $y \in \mathsf{Y} = \{0, \dots, K-1\}$:

$$\ell_{01}(y, g(\mathbf{x})) = \mathbb{1}_{\{y \neq g(\mathbf{x})\}} .$$

— *Perte quadratique* (régression), pour $y \in \mathbb{R}$:

$$\ell_2(y, g(\mathbf{x})) = (y - g(\mathbf{x}))^2 .$$

Définition 1.3: Risque d'une règle de décision

Le *risque* d'un prédicteur g est la perte moyenne

$$R(g) := \mathbb{E}\left[\ell(Y, g(\mathbf{X}))\right] = \int \ell(y, g(\mathbf{x}))\, \mathrm{d}\mathbb{P}(\mathbf{x}, y) ,$$

sous réserve que cette espérance existe. En particulier :

— le risque 0–1 en classification vaut $R_{01}(g) = \mathbb{P}(Y \neq g(\mathbf{X}))$;

— le risque quadratique en régression vaut $R_2(g) = \mathbb{E}[(Y - g(\mathbf{X}))^2]$.

Pour la perte 0–1, le risque est une probabilité, donc un nombre de $[0, 1]$, et il s'interprète comme la proportion d'individus que la règle g classe mal. Pour la perte quadratique, le risque peut être infini ; les énoncés de la Section 1.2 prendront soin de supposer que Y est de carré intégrable et de restreindre la comparaison aux prédicteurs g tels que $g(\mathbf{X})$ l'est aussi.

Le cadre est maintenant complet : une règle de décision $g : \mathsf{X} \to \mathsf{Y}$ mesurable, une perte $\ell(Y, g(\mathbf{X}))$, un risque

$$R(g) = \mathbb{E}\left[\ell(Y, g(\mathbf{X}))\right] = \int \ell(y, g(\mathbf{x}))\, \mathrm{d}\mathbb{P}(\mathbf{x}, y) ,$$

et un ensemble d'apprentissage $\mathcal{D}_n = \{(\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)\}$ formé de n copies indépendantes de $(\mathbf{X}, Y)$. Trois questions se posent alors.

Questions.

— Existe-t-il une règle de décision $g^\star$ *optimale*, au sens où $R(g^\star) \leq R(g)$ pour toute règle de décision g ?

— Comment construire, à partir de $\mathcal{D}_n$, une règle $\widehat{g}_n$ qui approche $g^\star$?

— Peut-on quantifier l'écart $R(\widehat{g}_n) - R(g^\star)$?

La Section 1.2 répond à la première question, la Section 1.3 donne une réponse à la deuxième, et la troisième, abordée ici sur l'exemple des règles obtenues par substitution, est le sujet des chapitres 9 et 10.

1.2 Les règles bayésiennes

On suppose dans toute cette section que la loi $\mathbb{P}$ du couple $(\mathbf{X}, Y)$ est connue, et on cherche la meilleure règle de prédiction possible. Cette règle, dite bayésienne, n'est pas calculable en pratique puisque $\mathbb{P}$ est inconnue ; elle sert de référence à laquelle comparer les règles construites sur des données.

Lois jointe, marginales et conditionnelles

Le couple $(\mathbf{X}, Y)$ porte une seule loi, dite *loi jointe*, et l'on en déduit les lois des deux variables prises séparément, dites *lois marginales*, ainsi que la loi de l'une sachant l'autre, dite *loi conditionnelle*. On note

$$\mathbb{P}_{\mathbf{X},Y} \quad \text{la loi jointe,} \qquad \mathbb{P}_{\mathbf{X}} \text{ et } \mathbb{P}_Y \quad \text{les lois marginales des attributs et de la réponse,}$$

et $\mathbb{P}_{\mathbf{X}|Y}$, $\mathbb{P}_{Y|\mathbf{X}}$ les lois conditionnelles des attributs sachant la réponse et de la réponse sachant les attributs.

Tout le chapitre se place dans le cas où ces lois admettent des densités, au sens suivant : les deux espaces mesurés $(\mathsf{X}, \mathcal{X}, \mu)$ et $(\mathsf{Y}, \mathcal{Y}, \nu)$ étant donnés, on suppose que la loi de $(\mathbf{X}, Y)$ admet une densité $p_{\mathbf{X},Y}$ par rapport à la mesure produit $\mu \otimes \nu$. Les deux situations rencontrées dans ce chapitre sont $(\mathsf{Y}, \mathcal{Y}, \nu) = (\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathrm{Leb})$ et $(\mathsf{X}, \mathcal{X}, \mu) = (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d), \mathrm{Leb})$ en régression, et la même chose pour les attributs avec $(\mathsf{Y}, \mathcal{Y}, \nu) = (\{-1, 1\}, \mathcal{P}(\{-1, 1\}), \mathrm{c})$ en classification binaire, où $\mathrm{c} := \delta_{\{-1\}} + \delta_{\{1\}}$ est la *mesure de comptage*. Les formules ci-dessous valent dans les deux cas, la mesure dominante pouvant être discrète ou continue.

Les densités marginales s'obtiennent en intégrant la densité jointe par rapport à l'autre variable :

$$p_{\mathbf{X}}(\mathbf{x}) = \int_{\mathsf{Y}} p_{\mathbf{X},Y}(\mathbf{x}, y)\, \nu(\mathrm{d}y)\ , \qquad p_Y(y) = \int_{\mathsf{X}} p_{\mathbf{X},Y}(\mathbf{x}, y)\, \mu(\mathrm{d}\mathbf{x})\ . \tag{1}$$

La densité jointe se factorise de deux façons,

$$p_{\mathbf{X},Y}(\mathbf{x}, y) = q_{\mathbf{X}|Y}(\mathbf{x} \mid y)\, p_Y(y) = q_{Y|\mathbf{X}}(y \mid \mathbf{x})\, p_{\mathbf{X}}(\mathbf{x})\ , \tag{2}$$

et la densité conditionnelle de la réponse sachant les attributs est, pour tout $\mathbf{x}$ tel que $p_{\mathbf{X}}(\mathbf{x}) > 0$,

$$q_{Y|\mathbf{X}}(y \mid \mathbf{x}) = \frac{p_{\mathbf{X},Y}(\mathbf{x}, y)}{p_{\mathbf{X}}(\mathbf{x})}\ . \tag{3}$$

La construction de ces objets et la vérification que (3) définit bien une densité de probabilité sur Y sont reprises dans la Section 2.5.

Intuition. *La factorisation (2) dit qu'il y a deux manières de « voir » la même expérience aléatoire. Dans la première, on tire d'abord la classe Y, puis les attributs $\mathbf{X}$ dans la loi propre à cette classe : c'est la vue $q_{\mathbf{X}|Y}\, p_Y$, celle que suit l'approche générative (analyse discriminante) dans la Section 1.3. Dans la seconde, on tire d'abord les attributs $\mathbf{X}$, puis la réponse Y dans la loi propre à ces attributs : c'est la vue $q_{Y|\mathbf{X}}\, p_{\mathbf{X}}$, celle que suivent le modèle logistique et le modèle linéaire gaussien. Les deux décrivent la même loi jointe, mais ne se modélisent pas aussi facilement selon le problème.*

Risque et règle bayésiens

La première des trois questions posées plus haut a une réponse : il existe une valeur minimale du risque, et l'on appelle règle bayésienne toute règle qui l'atteint.

Définition 1.4: Risque et règle bayésiens

Soit $\ell : \mathsf{Y} \times \mathsf{Y} \to \mathbb{R}_+$ une fonction de perte et $\mathbb{P}$ une probabilité sur $\mathsf{X} \times \mathsf{Y}$. Le risque minimum

$$R^\star_{\ell,\mathbb{P}} := \inf \left\{ R_{\ell,\mathbb{P}}(g) = \int \ell(y, g(\mathbf{x}))\, \mathrm{d}\mathbb{P}(\mathbf{x}, y)\ ,\ g : \mathsf{X} \to \mathsf{Y} \text{ mesurable} \right\}$$

est le *risque bayésien* relatif à $\mathbb{P}$ et à ℓ. Une fonction mesurable $g^\star_{\ell,\mathbb{P}} : \mathsf{X} \to \mathsf{Y}$ telle que

$$R_{\ell,\mathbb{P}}\left(g^\star_{\ell,\mathbb{P}}\right) = R^\star_{\ell,\mathbb{P}}$$

est appelée *règle de décision bayésienne*.

Lorsque le choix de la perte et de la loi ne prête pas à ambiguïté, on écrit $g^\star_{\ell,\mathbb{P}} = g^\star$ et $R^\star_{\ell,\mathbb{P}} = R^\star$. L'infimum définissant $R^\star$ existe toujours, puisque l'ensemble des risques est une partie non vide de $\mathbb{R}_+ \cup \{+\infty\}$; en revanche, rien ne garantit a priori qu'il soit atteint, ni qu'il le soit par une seule règle. Les deux théorèmes qui suivent exhibent une règle qui l'atteint, en régression pour la perte quadratique et en classification binaire pour la perte 0–1.

Le risque conditionnel

Pour calculer une règle bayésienne, on raisonne attribut par attribut. L'outil est la décomposition du risque comme moyenne d'un risque calculé à $\mathbf{X}$ fixé.

Proposition 1.1: Risque conditionnel

Supposons que $(\mathbf{X}, Y)$ admette une densité $p_{\mathbf{X},Y}$ par rapport à $\mu \otimes \nu$ et soit $\ell : \mathsf{Y} \times \mathsf{Y} \to \mathbb{R}_+$ une fonction de perte. Pour tout prédicteur mesurable $g : \mathsf{X} \to \mathsf{Y}$,

$$R_{\ell,\mathbb{P}}(g) = \mathbb{E}\left[\ell(Y, g(\mathbf{X}))\right] = \mathbb{E}\left[\mathbb{E}\left[\,\ell(Y, g(\mathbf{X})) \,|\, \mathbf{X}\right]\right] = \int_{\mathsf{X}} R_{\ell,\mathbb{P}}(g, \mathbf{x})\, p_{\mathbf{X}}(\mathbf{x})\, \mu(\mathrm{d}\mathbf{x}) \;,$$

où le *risque conditionnel* au point $\mathbf{x}$ est

$$R_{\ell,\mathbb{P}}(g, \mathbf{x}) := \int_{\mathsf{Y}} \ell(y, g(\mathbf{x}))\, q_{Y|\mathbf{X}}(y \mid \mathbf{x})\, \nu(\mathrm{d}y) \;.$$

Si une fonction mesurable $g^\star : \mathsf{X} \to \mathsf{Y}$ vérifie

$$R_{\ell,\mathbb{P}}(g^\star, \mathbf{x}) = \inf_{a \in \mathsf{Y}} \int_{\mathsf{Y}} \ell(y, a)\, q_{Y|\mathbf{X}}(y \mid \mathbf{x})\, \nu(\mathrm{d}y)$$

pour $p_{\mathbf{X}} \cdot \mu$-presque tout $\mathbf{x} \in \mathsf{X}$, alors $g^\star$ est une règle de décision bayésienne.

Démonstration

L'intégrande $(\mathbf{x}, y) \mapsto \ell(y, g(\mathbf{x}))\, p_{\mathbf{X},Y}(\mathbf{x}, y)$ est mesurable et positive ; le théorème de Fubini-Tonelli autorise l'intégration successive et donne

$$\begin{aligned} R_{\ell,\mathbb{P}}(g) &= \int_{\mathsf{X}\times\mathsf{Y}} \ell(y, g(\mathbf{x}))\, p_{\mathbf{X},Y}(\mathbf{x}, y)\, \mu(\mathrm{d}\mathbf{x})\, \nu(\mathrm{d}y) \\ &= \int_{\mathsf{X}} \left\{ \int_{\mathsf{Y}} \ell(y, g(\mathbf{x}))\, q_{Y|\mathbf{X}}(y \mid \mathbf{x})\, \nu(\mathrm{d}y) \right\} p_{\mathbf{X}}(\mathbf{x})\, \mu(\mathrm{d}\mathbf{x}) \;, \end{aligned}$$

où l'on a utilisé (3) et le fait que l'ensemble $\{\mathbf{x} : p_{\mathbf{X}}(\mathbf{x}) = 0\}$ est de mesure nulle pour $p_{\mathbf{X}} \cdot \mu$. La deuxième écriture, $\mathbb{E}[\mathbb{E}\left[\,\ell(Y, g(\mathbf{X})) \,|\, \mathbf{X}\right]]$, est la propriété de l'espérance de l'espérance conditionnelle (proposition 2.2) jointe à l'expression de l'espérance conditionnelle dans le cas à densité (proposition 2.6).
Soit maintenant $g^\star$ comme dans l'énoncé et g un prédicteur mesurable quelconque. Pour $p_{\mathbf{X}} \cdot \mu$-presque tout $\mathbf{x}$, on a $R_{\ell,\mathbb{P}}(g^\star, \mathbf{x}) \le R_{\ell,\mathbb{P}}(g, \mathbf{x})$, puisque $g(\mathbf{x}) \in \mathsf{Y}$ et que le membre de gauche est l'infimum sur $a \in \mathsf{Y}$. L'intégration de cette inégalité contre la mesure positive $p_{\mathbf{X}} \cdot \mu$ donne $R_{\ell,\mathbb{P}}(g^\star) \le R_{\ell,\mathbb{P}}(g)$, d'où $R_{\ell,\mathbb{P}}(g^\star) = R^\star_{\ell,\mathbb{P}}$. □

Régression : le prédicteur bayésien est l'espérance conditionnelle

On considère la régression, $Y \in \mathbb{R}$, et la perte des moindres carrés $\ell_2(y, g(\mathbf{x})) = (y - g(\mathbf{x}))^2$. La meilleure prévision de Y à attributs fixés est la moyenne de Y à attributs fixés.

Théorème 1.1: Prédicteur bayésien en régression, perte quadratique

Supposons $\mathbb{E}[Y^2] < \infty$ et posons $g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) := \mathbb{E}[Y \mid \mathbf{X}]$. Alors, pour tout prédicteur mesurable $g : \mathbb{R}^d \to \mathbb{R}$ tel que $\mathbb{E}[g^2(\mathbf{X})] < \infty$,

$$\mathbb{E}\left[\left(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X})\right)^2\right] \leq \mathbb{E}\left[(Y - g(\mathbf{X}))^2\right] ,$$

et plus précisément

$$\mathbb{E}\left[(Y - g(\mathbf{X}))^2\right] = \mathbb{E}\left[\left(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X})\right)^2\right] + \mathbb{E}\left[\left(g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X})\right)^2\right] .$$

La fonction $g^\star_{\ell_2,\mathbb{P}}$ est donc une règle de décision bayésienne pour la perte quadratique, et elle est unique à l'égalité $\mathbb{P}$-presque sûre près.

Démonstration

L'espérance conditionnelle $\mathbb{E}[Y \mid \mathbf{X}]$ est, par définition (Section 2.1), la projection orthogonale de Y sur le sous-espace fermé $\mathrm{L}^2(\Omega, \sigma(\mathbf{X}), \mathbb{P})$ de $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$, et la caractérisation de Doob (proposition 2.1) fournit une fonction mesurable, notée ici $g^\star_{\ell_2,\mathbb{P}}$, telle que $g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) = \mathbb{E}[Y \mid \mathbf{X}]$. En particulier, $\mathbb{E}[(g^\star_{\ell_2,\mathbb{P}})^2(\mathbf{X})] < \infty$.

Soit g mesurable avec $\mathbb{E}[g^2(\mathbf{X})] < \infty$. En écrivant $Y - g(\mathbf{X}) = \left(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X})\right) + \left(g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X})\right)$ et en développant le carré,

$$\begin{aligned}\mathbb{E}\left[(Y - g(\mathbf{X}))^2\right] = \mathbb{E}\left[(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}))^2\right] + 2\,\mathbb{E}\left[(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}))\,(g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X}))\right] \\ + \mathbb{E}\left[(g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X}))^2\right] .\end{aligned}$$

Les trois espérances sont finies car les trois variables Y, $g^\star_{\ell_2,\mathbb{P}}(\mathbf{X})$ et $g(\mathbf{X})$ sont de carré intégrable. La variable $T := g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X})$ appartient à $\mathrm{L}^2(\Omega, \sigma(\mathbf{X}), \mathbb{P})$, donc la relation d'orthogonalité qui caractérise la projection donne $\mathbb{E}[(Y - g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}))\,T] = 0$: le terme croisé est nul, ce qui établit l'identité annoncée. L'inégalité s'en déduit, le dernier terme étant positif. Si g est un prédicteur mesurable tel que $\mathbb{E}[g^2(\mathbf{X})] = \infty$, alors $Y - g(\mathbf{X})$ n'est pas de carré intégrable, puisque Y l'est et que $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ est un espace vectoriel ; on a donc $\mathbb{E}[(Y - g(\mathbf{X}))^2] = +\infty$ et l'inégalité reste vraie. L'infimum de la définition 1.4 est donc atteint en $g^\star_{\ell_2,\mathbb{P}}$. Enfin, si g réalise aussi ce minimum, l'identité ci-dessus donne $\mathbb{E}[(g^\star_{\ell_2,\mathbb{P}}(\mathbf{X}) - g(\mathbf{X}))^2] = 0$, c'est-à-dire $g(\mathbf{X}) = g^\star_{\ell_2,\mathbb{P}}(\mathbf{X})$ $\mathbb{P}$-presque sûrement. □

Intuition. *L'énoncé est une propriété de projection : parmi toutes les fonctions des attributs, celle qui approche Y au mieux au sens quadratique est la projection de Y sur l'espace des fonctions des attributs, et cette projection est l'espérance conditionnelle. L'identité de décomposition se lit alors comme le théorème de Pythagore : l'erreur commise par g est la somme de l'erreur incompressible, celle que $g^\star_{\ell_2,\mathbb{P}}$ commet encore, et de la distance de g à $g^\star_{\ell_2,\mathbb{P}}$. La première ne dépend que de la loi de $(\mathbf{X}, Y)$ et ne peut pas être réduite ; c'est la part de Y que les attributs n'expliquent pas.*

Classification : le classifieur bayésien

On considère la classification binaire, $Y \in \{-1, 1\}$, et la perte 0–1, $\ell_{01}(y, g(\mathbf{x})) = \mathbb{1}_{\{y \neq g(\mathbf{x})\}}$. La quantité qui gouverne tout est la probabilité de la classe 1 sachant les attributs.

Définition 1.5: Fonction de régression

La *fonction de régression* est la fonction mesurable $\eta : \mathsf{X} \to [0,1]$, unique à l'égalité $\mathbb{P}$-presque sûre près, telle que

$$\eta(\mathbf{X}) = \mathbb{P}\left(Y = 1 \,|\, \mathbf{X}\right) = \mathbb{E}\left[\mathbb{1}_{\{Y=1\}} \,\middle|\, \mathbf{X}\right] \ .$$

L'existence et l'unicité de η résultent de la définition de l'espérance conditionnelle et de la caractérisation des variables $\sigma(\mathbf{X})$-mesurables (proposition 2.1) ; la positivité de l'espérance conditionnelle (proposition 2.4) donne $0 \leq \eta \leq 1$ presque sûrement. On a de plus $\mathbb{E}\left[\mathbb{1}_{\{Y=-1\}} \,\middle|\, \mathbf{X}\right] = 1 - \eta(\mathbf{X})$.

Théorème 1.2: Classifieur bayésien et excès de risque

Soit η la fonction de régression et soit

$$g^\star(\mathbf{x}) := 2\,\mathbb{1}_{\{\eta(\mathbf{x}) \geq 1/2\}} - 1 = \begin{cases} 1 & \text{si } \eta(\mathbf{x}) \geq 1/2 \ , \\ -1 & \text{sinon .} \end{cases}$$

Pour tout classifieur mesurable $g : \mathbb{R}^d \to \{-1, 1\}$,

$$\mathbb{E}\left[\ell_{01}(Y, g^\star(\mathbf{X}))\right] \leq \mathbb{E}\left[\ell_{01}(Y, g(\mathbf{X}))\right] \ ,$$

c'est-à-dire $\mathbb{P}(g^\star(\mathbf{X}) \neq Y) \leq \mathbb{P}(g(\mathbf{X}) \neq Y)$: $g^\star$ est un classifieur bayésien pour la perte 0–1. L'*excès de risque* d'un classifieur g vaut

$$R_{01}(g) - R_{01}(g^\star) = \mathbb{E}\left[|2\eta(\mathbf{X}) - 1|\ \mathbb{1}_{\{g^\star(\mathbf{X}) \neq g(\mathbf{X})\}}\right] \ , \tag{4}$$

et le risque bayésien vaut

$$R_{01}^\star = \mathbb{E}\left[\min\left(\eta(\mathbf{X}), 1 - \eta(\mathbf{X})\right)\right] \ . \tag{5}$$

Démonstration

Soit $g : \mathbb{R}^d \to \{-1, 1\}$ mesurable. On applique le lemme 2.2 à la fonction bornée $\psi_g(\mathbf{x}, y) := \mathbb{1}_{\{g(\mathbf{x}) \neq y\}}$. Comme g est à valeurs dans $\{-1, 1\}$, on a $\psi_g(\mathbf{x}, 1) = \mathbb{1}_{\{g(\mathbf{x})=-1\}}$ et $\psi_g(\mathbf{x}, -1) = \mathbb{1}_{\{g(\mathbf{x})=1\}}$, d'où

$$R_{01}(g) = \mathbb{E}\left[\mathbb{1}_{\{g(\mathbf{X})=-1\}}\,\eta(\mathbf{X})\right] + \mathbb{E}\left[\mathbb{1}_{\{g(\mathbf{X})=1\}}\,(1 - \eta(\mathbf{X}))\right] \ .$$

En remplaçant $\mathbb{1}_{\{g(\mathbf{X})=1\}}$ par $1 - \mathbb{1}_{\{g(\mathbf{X})=-1\}}$, il vient

$$R_{01}(g) = \mathbb{E}\left[\mathbb{1}_{\{g(\mathbf{X})=-1\}}\,(2\eta(\mathbf{X}) - 1)\right] + \mathbb{E}\left[1 - \eta(\mathbf{X})\right] \ . \tag{6}$$

Le second terme ne dépend pas de g. Par conséquent, pour deux classifieurs g_1 et g_2,

$$R_{01}(g_1) - R_{01}(g_2) = \mathbb{E}\left[\left(\mathbb{1}_{\{g_1(\mathbf{X})=-1\}} - \mathbb{1}_{\{g_2(\mathbf{X})=-1\}}\right)(2\eta(\mathbf{X}) - 1)\right] \ . \tag{7}$$

Appliquons (7) avec $g_1 = g$ et $g_2 = g^\star$, et posons $D := \mathbb{1}_{\{g(\mathbf{X})=-1\}} - \mathbb{1}_{\{g^\star(\mathbf{X})=-1\}}$, qui prend ses valeurs dans $\{-1, 0, 1\}$. Les deux classifieurs étant à valeurs dans $\{-1, 1\}$, on a $D = 0$ si et seulement si $g(\mathbf{X}) = g^\star(\mathbf{X})$. Si $D = 1$, alors $g(\mathbf{X}) = -1$ et $g^\star(\mathbf{X}) = 1$, donc $\eta(\mathbf{X}) \geq 1/2$ et $2\eta(\mathbf{X}) - 1 \geq 0$, de sorte que $D\,(2\eta(\mathbf{X}) - 1) = |2\eta(\mathbf{X}) - 1|$. Si $D = -1$, alors $g(\mathbf{X}) = 1$ et $g^\star(\mathbf{X}) = -1$, donc $\eta(\mathbf{X}) < 1/2$ et $2\eta(\mathbf{X}) - 1 < 0$, de sorte que l'on a encore $D\,(2\eta(\mathbf{X}) - 1) = -(2\eta(\mathbf{X}) - 1) = |2\eta(\mathbf{X}) - 1|$. Dans tous les cas,

$$D\,(2\eta(\mathbf{X}) - 1) = |2\eta(\mathbf{X}) - 1|\ \mathbb{1}_{\{g(\mathbf{X}) \neq g^\star(\mathbf{X})\}} \geq 0 \ ,$$

ce qui donne (4) et, le membre de droite étant positif, l'optimalité de $g^\star$ parmi les classifieurs mesurables, donc $R_{01}(g^\star) = R_{01}^\star$.
Il reste à calculer ce risque. En appliquant (6) à $g^\star$ et en utilisant $\mathbb{1}_{\{g^\star(\mathbf{X})=-1\}} = \mathbb{1}_{\{\eta(\mathbf{X})<1/2\}}$, on obtient

$$R_{01}(g^\star) = \mathbb{E}\left[\mathbb{1}_{\{\eta(\mathbf{X})<1/2\}}\,\eta(\mathbf{X}) + \mathbb{1}_{\{\eta(\mathbf{X})\geq 1/2\}}\,(1-\eta(\mathbf{X}))\right] .$$

Or $\min(\eta, 1-\eta) = \eta$ si et seulement si $\eta \leq 1/2$, et les deux quantités coïncident lorsque $\eta = 1/2$; l'intégrande vaut donc $\min(\eta(\mathbf{X}), 1-\eta(\mathbf{X}))$, ce qui établit (5). □

La règle $g^\star$ consiste simplement à retourner le label le plus probable à la vue des attributs $\mathbf{X}$: on prédit 1 lorsque $\eta(\mathbf{x}) \geq 1-\eta(\mathbf{x})$, c'est-à-dire $\eta(\mathbf{x}) \geq 1/2$. Le choix de l'inégalité large est une convention : sur l'événement $\{\eta(\mathbf{X}) = 1/2\}$ les deux décisions ont le même risque conditionnel, et (4) montre que changer $g^\star$ sur cet événement ne change pas son risque. Le classifieur bayésien n'est donc pas unique en général.

Intuition. *La formule d'excès de risque (4) se lit ainsi : on ne paie que là où g décide autrement que $g^\star$, et le prix payé en un tel point $\mathbf{x}$ est $|2\eta(\mathbf{x})-1|$, c'est-à-dire l'écart entre la probabilité de la classe majoritaire et celle de la classe minoritaire. Se tromper de décision là où $\eta(\mathbf{x})$ est proche de $1/2$ ne coûte presque rien, car les deux classes y sont presque également probables ; se tromper là où $\eta(\mathbf{x})$ est proche de 0 ou de 1 coûte cher. La formule (5) dit de même que le risque incompressible est la moyenne de la probabilité de la classe minoritaire : il est nul si et seulement si $\eta(\mathbf{X}) \in \{0,1\}$ presque sûrement, c'est-à-dire lorsque les attributs déterminent la classe.*

Explicitation de la règle bayésienne en classification binaire

On explicite maintenant η et $g^\star$ en fonction des lois conditionnelles des attributs dans chaque classe. On prend

$$(\mathsf{X}, \mathcal{X}, \mu) = (\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d), \mathrm{Leb}) , \qquad (\mathsf{Y}, \mathcal{Y}, \nu) = (\{-1,1\}, \mathcal{P}(\{-1,1\}), \mathrm{c}) ,$$

où $\mathrm{c} = \delta_{\{-1\}} + \delta_{\{1\}}$ est la mesure de comptage, et l'on note $\widetilde{\mathcal{B}\mathrm{er}}(p)$ la loi de Bernoulli de paramètre $p \in [0,1]$ à valeurs dans $\{-1,1\}$, de sorte que $\mathcal{L}(Y) = \widetilde{\mathcal{B}\mathrm{er}}(p)$ avec $p = \mathbb{P}(Y=1)$. Pour écarter les situations triviales, on suppose $p \in]0,1[$. Les formules (1) à (3) s'appliquent telles quelles, la mesure dominante de la réponse étant ici la mesure de comptage : la densité marginale des labels est la fonction

$$y \longmapsto p_Y(y) = p\,\mathbb{1}_{\{1\}}(y) + (1-p)\,\mathbb{1}_{\{-1\}}(y) .$$

On note q_1 et q_{-1} les densités de la loi des attributs conditionnellement à chacune des deux classes,

$$q_1(\mathbf{x}) := q_{\mathbf{X}|Y}(\mathbf{x} \mid y=1) , \qquad q_{-1}(\mathbf{x}) := q_{\mathbf{X}|Y}(\mathbf{x} \mid y=-1) ,$$

de sorte que, par la factorisation (2), la loi jointe des labels et des attributs a pour densité

$$p_{\mathbf{X},Y}(\mathbf{x}, y) = p\,q_1(\mathbf{x})\,\mathbb{1}_{\{1\}}(y) + (1-p)\,q_{-1}(\mathbf{x})\,\mathbb{1}_{\{-1\}}(y) . \tag{8}$$

Proposition 1.2: Loi marginale des attributs

La loi des attributs admet la densité

$$p_{\mathbf{X}}(\mathbf{x}) = \int_{\mathsf{Y}} p_{\mathbf{X},Y}(\mathbf{x}, y)\ \mathrm{c}(\mathrm{d}y) = p\,q_1(\mathbf{x}) + (1-p)\,q_{-1}(\mathbf{x}) \ :$$

c'est un mélange des deux lois conditionnelles, de poids p et $1-p$.

Proposition 1.3: Loi conditionnelle des labels sachant les attributs

Pour tout $\mathbf{x}$ tel que $p_{\mathbf{X}}(\mathbf{x}) > 0$,

$$\begin{cases} q_{Y|\mathbf{X}}(1 \mid \mathbf{x}) & = \dfrac{p_{\mathbf{X},Y}(\mathbf{x}, 1)}{p_{\mathbf{X}}(\mathbf{x})} = \dfrac{p\, q_1(\mathbf{x})}{p\, q_1(\mathbf{x}) + (1-p)\, q_{-1}(\mathbf{x})} \,, \\ q_{Y|\mathbf{X}}(-1 \mid \mathbf{x}) & = \dfrac{p_{\mathbf{X},Y}(\mathbf{x}, -1)}{p_{\mathbf{X}}(\mathbf{x})} = \dfrac{(1-p)\, q_{-1}(\mathbf{x})}{p\, q_1(\mathbf{x}) + (1-p)\, q_{-1}(\mathbf{x})} \,. \end{cases}$$

Proposition 1.4: Fonction de régression

Pour tout $\mathbf{x}$ tel que $p_{\mathbf{X}}(\mathbf{x}) > 0$, la fonction de régression vaut

$$\eta(\mathbf{x}) = q_{Y|\mathbf{X}}(1 \mid \mathbf{x}) = \frac{p\, q_1(\mathbf{x})}{p\, q_1(\mathbf{x}) + (1-p)\, q_{-1}(\mathbf{x})} = \frac{1}{1 + \dfrac{(1-p)\, q_{-1}(\mathbf{x})}{p\, q_1(\mathbf{x})}} \,,$$

la dernière écriture valant lorsque $q_1(\mathbf{x}) > 0$.

Démonstration

L'expression de l'espérance conditionnelle dans le cas à densité (proposition 2.6), appliquée à la variable $\mathbb{1}_{\{Y=1\}}$, donne

$$\eta(\mathbf{X}) = \mathbb{E}\left[\, \mathbb{1}_{\{Y=1\}} \,\middle|\, \mathbf{X} \right] = \left(\int_{\mathsf{Y}} \mathbb{1}_{\{y=1\}}\, q_{Y|\mathbf{X}}(y \mid \mathbf{x})\ \mathrm{c}(\mathrm{d}y) \right)_{\mathbf{x}=\mathbf{X}} = q_{Y|\mathbf{X}}(1 \mid \mathbf{X}) \,,$$

et l'on conclut par la proposition 1.3. L'ensemble $\{\mathbf{x} : p_{\mathbf{X}}(\mathbf{x}) = 0\}$ étant de probabilité nulle sous la loi de $\mathbf{X}$, cette identité détermine η à l'égalité presque sûre près. □

En reportant cette expression dans la définition de $g^\star$, on obtient une forme qui ne fait plus intervenir que les deux densités conditionnelles et la proportion des classes : pour tout $\mathbf{x}$ tel que $p_{\mathbf{X}}(\mathbf{x}) > 0$,

$$g^\star(\mathbf{x}) = \begin{cases} 1 & \text{si et seulement si } \ p\, q_1(\mathbf{x}) \geq (1-p)\, q_{-1}(\mathbf{x}) \,, \\ -1 & \text{sinon .} \end{cases} \tag{9}$$

En effet, $p_{\mathbf{X}}(\mathbf{x})$ étant strictement positif, l'inégalité $\eta(\mathbf{x}) \geq 1/2$ équivaut à $2\, p\, q_1(\mathbf{x}) \geq p\, q_1(\mathbf{x}) + (1-p)\, q_{-1}(\mathbf{x})$, c'est-à-dire à $p\, q_1(\mathbf{x}) \geq (1-p)\, q_{-1}(\mathbf{x})$.

Exemple 1.6: Taille et genre, suite

Reprenons l'exemple 1.3 avec $d = 1$, deux densités conditionnelles gaussiennes $q_1 = \mathcal{N}(\mu_1, \sigma^2)$ et $q_{-1} = \mathcal{N}(\mu_{-1}, \sigma^2)$ de même variance, et $p = 1/2$. La condition $p\, q_1(x) \geq (1-p)\, q_{-1}(x)$ de (9) s'écrit $q_1(x) \geq q_{-1}(x)$, c'est-à-dire, après passage au logarithme et simplification des termes en x^2,

$$(\mu_1 - \mu_{-1}) \left(x - \frac{\mu_1 + \mu_{-1}}{2} \right) \geq 0 \,.$$

Si $\mu_1 > \mu_{-1}$, la règle bayésienne prédit la classe 1 au-delà du point milieu $(\mu_1 + \mu_{-1})/2$ et la classe -1 en deçà. La frontière de décision est un seuil, et ce seuil se déplace dès que $p \neq 1/2$

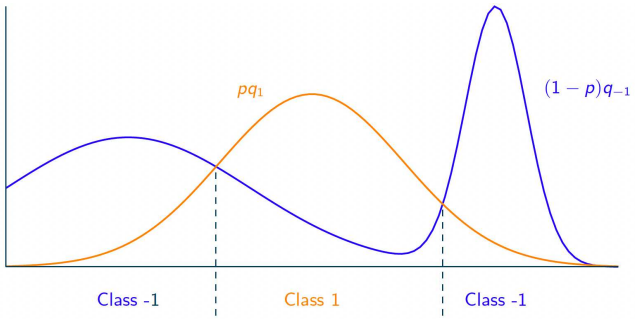


FIGURE 2 – Règle de décision du classifieur bayésien en dimension $d = 1$. La fonction η donne la probabilité de la classe 1 sachant les attributs ; la règle $g^\star$ prédit la classe 1 sur l'ensemble des $\mathbf{x}$ où $\eta(\mathbf{x}) \geq 1/2$.

ou que les deux variances diffèrent.

Bilan

Le prédicteur bayésien $g^\star_{\ell,\mathbb{P}}$ est optimal pour la loi $\mathbb{P}$ et la perte ℓ. Mais le statisticien ne connaît pas la loi jointe de $(\mathbf{X}, Y)$: $g^\star_{\ell,\mathbb{P}}$ n'est pas une fonction des observations, et le risque bayésien est à ce titre un objet purement théorique, auquel on se compare. On dispose en revanche d'un ensemble d'apprentissage $\mathcal{D}_n = \{(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)\}$, formé de n copies indépendantes de $(\mathbf{X}, Y)$, et c'est à partir de lui que l'on construira $\widehat{g}_n$.

Il faudra dès lors gérer un double aléa : celui du couple $(\mathbf{X}, Y)$ sur lequel la règle est évaluée, et celui de l'ensemble d'apprentissage $\mathcal{D}_n$ à partir duquel elle est construite. Les deux ne jouent pas le même rôle et ne se moyennent pas au même endroit, ce que la Section 1.3 et les compléments précisent.

Deux exercices de la feuille reprennent ce calcul dans des situations où tout est explicite : l'exercice 1 détermine le prédicteur bayésien en classification binaire pour une perte asymétrique, et l'exercice 5 le calcule, ainsi que son risque, sur une distribution particulière en dimension un.

1.3 L'approche par modélisation

La règle bayésienne n'est pas calculable parce que la loi de $(\mathbf{X}, Y)$ est inconnue. Une première façon de contourner cet obstacle reprend le schéma suivi jusqu'ici en statistique : on se donne un modèle paramétrique pour cette loi, on estime le paramètre sur l'ensemble d'apprentissage, et on substitue l'estimateur au paramètre dans l'expression de la règle bayésienne.

Méthode 1.1: Règle par substitution

1. **Modéliser** la loi de $(\mathbf{X}, Y)$ par un modèle paramétrique $\{\mathbb{P}_\theta \,:\, \theta \in \Theta\}$.
2. **Calculer** le prédicteur bayésien $g^\star_\theta$ sous chacune des lois $\mathbb{P}_\theta$.
3. **Estimer** θ par $\hat{\theta}_n$ à partir de l'ensemble d'apprentissage $\mathcal{D}_n$.
4. **Choisir** la règle $\widehat{g}_n := g^\star_{\hat{\theta}_n}$ (règle par substitution, ou *plug-in*).

La deuxième étape est un calcul exact, mené sous une loi connue : c'est le travail de la Section 1.2. La troisième relève des chapitres 2, 3 et 7. Reste à choisir la façon de modéliser la loi du couple, et la factorisation (2) en offre deux.

— Modéliser $\mathbf{X} \mid Y$ et Y : c'est l'*approche générative*, celle de l'analyse discriminante linéaire et quadratique et du classifieur bayésien naïf.

— Modéliser $Y \mid \mathbf{X}$ et $\mathbf{X}$: c'est l'approche du modèle logistique, du modèle linéaire gaussien et de l'algorithme des k plus proches voisins.

Intuition. *L'approche générative décrit comment les données sont produites : on tire une classe, puis des attributs conformes à cette classe. Elle demande donc de modéliser la loi des attributs dans chaque classe, ce qui est une information riche, et parfois trop riche pour être crédible en grande dimension. La seconde approche ne modélise que ce dont la règle a besoin, la probabilité de la classe à attributs donnés, et laisse la loi des attributs libre. Ce dernier point mérite d'être souligné : dans le modèle logistique et dans le modèle linéaire gaussien, la loi de* $\mathbf{X}$ *reste quelconque et n'intervient ni dans la règle bayésienne ni dans l'estimation du paramètre.*

Analyse discriminante linéaire et quadratique

On applique la méthode précédente à la classification binaire avec, pour chaque classe, une loi gaussienne sur $\mathbb{R}^d$.

Cadre 1.2: Modèle de l'analyse discriminante

Le paramètre est $\theta = (p, \mu_1, \mu_{-1}, \Sigma_1, \Sigma_{-1})$, avec $p \in]0,1[$, $\mu_i \in \mathbb{R}^d$ et $\Sigma_i \in \mathrm{S}_d^+$ l'ensemble des matrices de covariance $d \times d$ *inversibles*, et le modèle s'écrit

$$\begin{cases} \mathcal{L}(Y) = \widetilde{\mathcal{B}\mathrm{er}}(p) \ , \\ \text{pour } i \in \{-1, 1\} \ , \quad \mathcal{L}(\mathbf{X} \mid Y = i) = q_{i,\theta} \cdot \mathrm{Leb} \ , \quad \text{avec} \quad q_{i,\theta} \cdot \mathrm{Leb} = \mathcal{N}(\mu_i, \Sigma_i) \ . \end{cases}$$

La densité conditionnelle de la classe i est donc

$$q_{i,\theta}(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}\sqrt{\det \Sigma_i}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu_i)^\top \Sigma_i^{-1}(\mathbf{x}-\mu_i)\right) \ .$$

L'hypothèse d'inversibilité des deux matrices de covariance est nécessaire : sans elle, la loi conditionnelle des attributs est portée par un sous-espace affine strict de $\mathbb{R}^d$ et n'admet pas de densité par rapport à la mesure de Lebesgue. Elle entraîne $q_{i,\theta}(\mathbf{x}) > 0$ pour tout $\mathbf{x}$, donc $p_{\mathbf{X}}(\mathbf{x}) > 0$ pour tout $\mathbf{x}$, et la fonction de régression est définie partout.

Deuxième étape : le prédicteur bayésien sous $\mathbb{P}_\theta$. D'après (9),

$$g_\theta^\star(\mathbf{x}) = 1 \quad \text{si et seulement si} \quad p\, q_{1,\theta}(\mathbf{x}) \geq (1-p)\, q_{-1,\theta}(\mathbf{x}) \ . \tag{10}$$

Les deux membres étant strictement positifs, cette condition équivaut à $\phi_\theta(\mathbf{x}) \geq 0$, où

$$\begin{aligned} \phi_\theta(\mathbf{x}) &:= \log \frac{p\, q_{1,\theta}(\mathbf{x})}{(1-p)\, q_{-1,\theta}(\mathbf{x})} \\ &= \log\frac{p}{1-p} + \frac{1}{2}\log\frac{\det\Sigma_{-1}}{\det\Sigma_1} - \frac{1}{2}(\mathbf{x}-\mu_1)^\top\Sigma_1^{-1}(\mathbf{x}-\mu_1) + \frac{1}{2}(\mathbf{x}-\mu_{-1})^\top\Sigma_{-1}^{-1}(\mathbf{x}-\mu_{-1}) \ , \end{aligned} \tag{11}$$

et la proposition 1.4 s'écrit alors $\eta_\theta(\mathbf{x}) = \mathrm{sigm}(\phi_\theta(\mathbf{x}))$, où $\mathrm{sigm} : t \mapsto 1/(1+\mathrm{e}^{-t})$ est la fonction sigmoïde de la Section 2.9.

La fonction ϕ_θ est un polynôme de degré au plus deux en $\mathbf{x}$, et son terme de degré deux est $-\frac{1}{2}\mathbf{x}^\top(\Sigma_1^{-1} - \Sigma_{-1}^{-1})\mathbf{x}$. Deux cas se présentent.

— Si $\Sigma_1 = \Sigma_{-1} = \Sigma$, ce terme disparaît et

$$\phi_\theta(\mathbf{x}) = \mathbf{w}_\theta^\top \mathbf{x} + A_\theta \ , \qquad \mathbf{w}_\theta := \Sigma^{-1}(\mu_1 - \mu_{-1}) \ ,$$

$$A_\theta := \log\frac{p}{1-p} - \frac{1}{2}\left(\mu_1^\top\Sigma^{-1}\mu_1 - \mu_{-1}^\top\Sigma^{-1}\mu_{-1}\right) \ .$$

La frontière de décision $\{\mathbf{x} : \phi_\theta(\mathbf{x}) = 0\}$ est un hyperplan affine : on parle d'*analyse discriminante linéaire* (LDA, pour *linear discriminant analysis*).

— Si $\Sigma_1 \neq \Sigma_{-1}$, la frontière est une quadrique de $\mathbb{R}^d$ – ellipsoïde, paraboloïde ou hyperboloïde selon le signe des valeurs propres de $\Sigma_1^{-1} - \Sigma_{-1}^{-1}$. On parle d'*analyse discriminante quadratique* (QDA, pour *quadratic discriminant analysis*).

Troisième et quatrième étapes : estimation et substitution. Le paramètre θ est estimé par maximum de vraisemblance sur l'ensemble d'apprentissage : $\widehat{p}_n$ est la proportion d'individus de la classe 1, $\widehat{\mu}_{i,n}$ la moyenne empirique des attributs de la classe i et $\widehat{\Sigma}_{i,n}$ leur matrice de covariance empirique. Le calcul de cet estimateur et la démonstration de sa consistance font l'objet de l'exercice 3. La règle retenue est alors $\widehat{g}_n = g^\star_{\hat{\theta}_n}$: il suffit de remplacer θ par $\hat{\theta}_n$ dans (11).

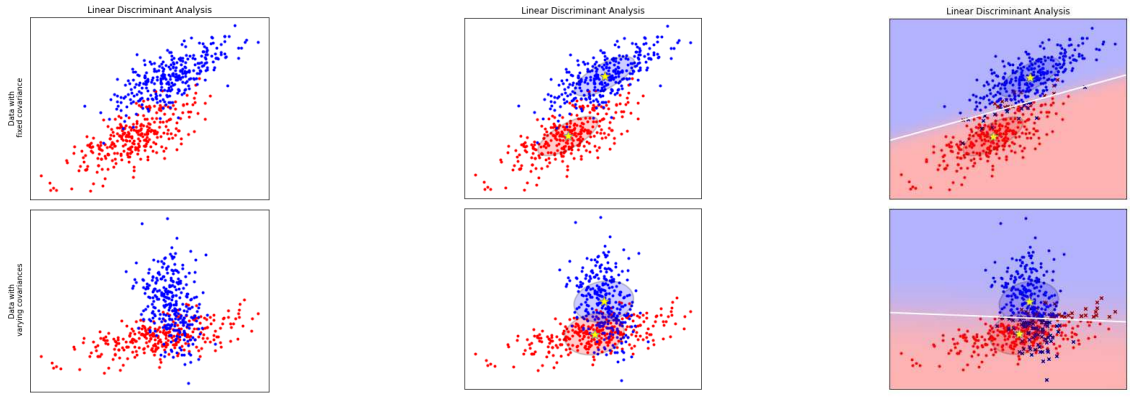


FIGURE 3 – Analyse discriminante linéaire, sur deux ensembles d'apprentissage simulés (une ligne par ensemble). À gauche, les attributs, chaque couleur marquant une classe ; au milieu, les moyennes et la matrice de covariance commune estimées sur ces points ; à droite, la frontière de décision de la règle $g^\star_{\hat{\theta}_n}$, qui est une droite, et les attributs mal classés, marqués d'une croix.



FIGURE 4 – Analyse discriminante quadratique, sur les deux mêmes ensembles d'apprentissage. Chaque classe reçoit sa propre matrice de covariance, et la frontière de décision est une courbe du second degré.

Classification : le modèle logistique

On modélise cette fois la loi de Y sachant $\mathbf{X}$, en laissant la loi de $\mathbf{X}$ libre.

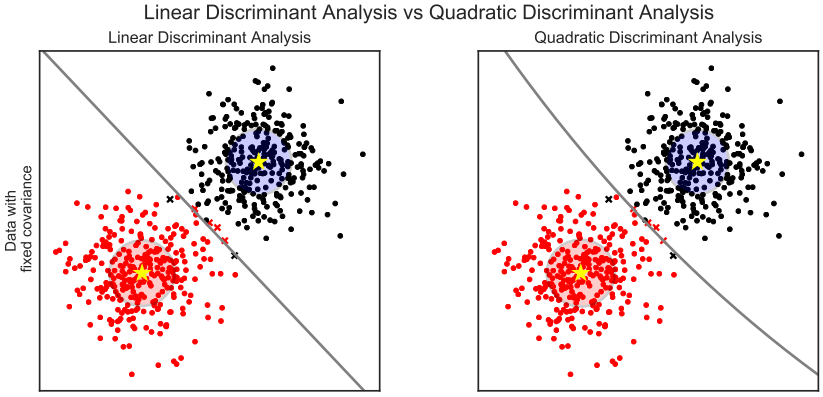


FIGURE 5 – Deux règles apprises sur le même ensemble d'apprentissage, par l'analyse discriminante linéaire (à gauche) et par l'analyse discriminante quadratique (à droite). Les attributs des deux classes sont distingués par leur couleur, les moyennes estimées sont marquées par une étoile, la frontière de décision est tracée en gris et les attributs mal classés par la règle sont marqués d'une croix. Cette figure est celle de l'exercice 3.

Cadre 1.3: Modèle logistique

Le paramètre est $\theta \in \mathbb{R}^d$ et le modèle s'écrit

$$\begin{cases} \mathcal{L}(Y \mid \mathbf{X}) = \widetilde{\mathcal{B}\mathrm{er}}\left(\mathrm{sigm}\left(\theta^\top \mathbf{X}\right)\right) , \\ \mathcal{L}(\mathbf{X}) \text{ quelconque} , \end{cases} \qquad \text{où} \quad \mathrm{sigm}(t) = \frac{1}{1+\mathrm{e}^{-t}} .$$

La fonction de régression sous $\mathbb{P}_\theta$ est donnée par le modèle lui-même : $\eta_\theta(\mathbf{X}) = \mathbb{P}_\theta(Y = 1 \mid \mathbf{X}) = \mathrm{sigm}(\theta^\top \mathbf{X})$. Comme sigm est croissante et vaut $1/2$ en 0, on a $\mathrm{sigm}(\theta^\top \mathbf{X}) \geq 1/2$ si et seulement si $\theta^\top \mathbf{X} \geq 0$, de sorte que

$$g^\star_\theta(\mathbf{X}) = 1 \quad \text{si et seulement si} \quad \theta^\top \mathbf{X} \geq 0 \ :$$

la règle bayésienne du modèle est une règle de séparation linéaire.

Le paramètre est estimé par maximum de vraisemblance. Comme la loi de $\mathbf{X}$ ne dépend pas de θ, elle se factorise dans la vraisemblance et seule la partie conditionnelle contribue ; par ailleurs $1 - \mathrm{sigm}(t) = \mathrm{sigm}(-t)$, de sorte que $\mathbb{P}_\theta(Y = y \mid \mathbf{X}) = \mathrm{sigm}(y\,\theta^\top \mathbf{X})$ pour $y \in \{-1, 1\}$. L'opposé de la log-vraisemblance conditionnelle normalisée vaut donc $n^{-1} \sum_{i=1}^n \log(1 + \exp(-Y_i\,\theta^\top \mathbf{X}_i))$, et l'estimateur du maximum de vraisemblance est

$$\widehat{\theta}_{\mathrm{MLE},n} = \operatorname*{arg\,min}_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \log\left(1 + \exp\left(-Y_i\,\theta^\top \mathbf{X}_i\right)\right) . \tag{12}$$

La règle retenue est $\widehat{g}_n = g^\star_{\widehat{\theta}_{\mathrm{MLE},n}}$, c'est-à-dire

$$\widehat{g}_n(\mathbf{X}) = 2\,\mathbb{1}_{\{\widehat{\theta}^\top_{\mathrm{MLE},n} \mathbf{X} \geq 0\}} - 1 .$$

Le critère minimisé dans (12) revient à employer la perte $\ell_{\log}(y, t) = \log(1 + \mathrm{e}^{-yt})$, dite *perte logistique*, sur la classe des fonctions linéaires $\mathbf{x} \mapsto \theta^\top \mathbf{x}$: la démarche par modélisation rejoint ici celle qui consiste à choisir d'emblée une perte et une classe de fonctions.

Régression : le modèle linéaire gaussien

Le même schéma s'applique en régression.

Cadre 1.4: Modèle linéaire gaussien homoscédastique

Le paramètre est $\theta \in \mathbb{R}^d$, la variance $\sigma^2 > 0$ est fixée, et le modèle s'écrit

$$\begin{cases} \mathcal{L}(Y \mid \mathbf{X}) = \mathcal{N}\left(\theta^\top \mathbf{X}, \sigma^2\right) , \\ \mathcal{L}(\mathbf{X}) \text{ quelconque} . \end{cases}$$

Le théorème 1.1 donne $g^\star_\theta(\mathbf{X}) = \mathbb{E}_\theta[Y \mid \mathbf{X}] = \theta^\top \mathbf{X}$: le prédicteur bayésien du modèle est linéaire. Le paramètre est estimé par maximum de vraisemblance, c'est-à-dire, la loi de $\mathbf{X}$ ne dépendant pas de θ et la densité conditionnelle étant gaussienne de variance connue,

$$\widehat{\theta}_{\mathrm{MLE},n} = \arg\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^{n} \left(\theta^\top \mathbf{X}_i - Y_i\right)^2 ,$$

et la règle retenue est $\widehat{g}_n(\mathbf{X}) = \widehat{\theta}^\top_{\mathrm{MLE},n} \mathbf{X}$. On retrouve l'estimateur des moindres carrés du chapitre 2 (exemple 1.15), et, comme pour le modèle logistique, la démarche revient à employer la perte des moindres carrés sur la classe des fonctions linéaires.

Ce que l'approche par modélisation garantit

L'approche par modélisation consiste à choisir un modèle pour la loi du phénomène – analyse discriminante linéaire ou quadratique, classifieur bayésien naïf, algorithme des k plus proches voisins – puis à exploiter ce modèle. C'est une approche de type statistique : on obtient des résultats *sous l'hypothèse de modélisation.*

Le résultat typique est le suivant. Pour l'énoncer, on note $R_{01}(g)$ le risque d'une règle fixée et, lorsque la règle $\widehat{g}_n$ est construite sur l'ensemble d'apprentissage, $R_{01}(\widehat{g}_n) := \mathbb{P}\left(\widehat{g}_n(\mathbf{X}) \neq Y \,|\, \mathcal{D}_n\right)$ la probabilité d'erreur conditionnelle, où $(\mathbf{X}, Y)$ est un couple indépendant de $\mathcal{D}_n$ et de même loi ; c'est une variable aléatoire, fonction de $\mathcal{D}_n$, sur laquelle la Section 4.4 revient.

Proposition 1.5: Risque d'une règle par substitution

Soit $\{\mathbb{P}_\theta \,:\, \theta \in \Theta\}$ un modèle de classification binaire et $\theta^\star \in \Theta$. On suppose :

(i) que le modèle est bien spécifié, c'est-à-dire que la loi de $(\mathbf{X}, Y)$ et celle des n paires de $\mathcal{D}_n$ sont données par $\mathbb{P}_{\theta^\star}$; on note $\mathbb{E}_{n,\theta^\star}$ l'espérance sous la loi de $\mathcal{D}_n$;

(ii) que η_θ désigne la fonction de régression sous $\mathbb{P}_\theta$ et $g^\star_\theta := 2\,\mathbb{1}_{\{\eta_\theta \geq 1/2\}} - 1$ la règle bayésienne associée ;

(iii) que l'estimateur $\hat{\theta}_n$, construit sur $\mathcal{D}_n$, vérifie $\eta_{\hat{\theta}_n}(\mathbf{x}) - \eta_{\theta^\star}(\mathbf{x}) \overset{\mathbb{P}_{n,\theta^\star}-\text{prob}}{\longrightarrow} 0$ pour $p_{\mathbf{X}} \cdot \mu$-presque tout $\mathbf{x} \in \mathsf{X}$.

Alors la règle par substitution $\widehat{g}_n := g^\star_{\hat{\theta}_n}$ vérifie

$$\lim_{n \to \infty} \mathbb{E}_{n,\theta^\star}\left[R_{01}(\widehat{g}_n) - R_{01}(g^\star_{\theta^\star})\right] = 0 .$$

Démonstration

L'exercice 7 établit que, pour toute fonction mesurable $\widetilde{\eta} : \mathsf{X} \to [0,1]$ et la règle associée $\widetilde{g} := 2\,\mathbb{1}_{\{\widetilde{\eta} \geq 1/2\}} - 1$,

$$R_{01}(\widetilde{g}) - R_{01}(g^\star_{\theta^\star}) \leq 2\,\mathbb{E}\left[\left|\eta_{\theta^\star}(\mathbf{X}) - \widetilde{\eta}(\mathbf{X})\right|\right] , \tag{13}$$

l'espérance portant sur le seul couple de test $(\mathbf{X}, Y)$; la démonstration en est redonnée à la Section 4.7. Appliquée à $\widetilde{\eta} = \eta_{\hat{\theta}_n}$, à $\mathcal{D}_n$ fixé, et compte tenu de l'indépendance de $(\mathbf{X}, Y)$ et

de $\mathcal{D}_n$, elle donne

$$0 \leq R_{01}(\widehat{g}_n) - R_{01}(g^\star_{\theta^\star}) \leq 2 \int_{\mathsf{X}} \left| \eta_{\theta^\star}(\mathbf{x}) - \eta_{\hat{\theta}_n}(\mathbf{x}) \right| p_{\mathbf{X}}(\mathbf{x})\, \mu(\mathrm{d}\mathbf{x}) \,.$$

En prenant l'espérance sous la loi de $\mathcal{D}_n$ et en intervertissant les deux intégrations, ce qui est licite pour un intégrande positif (Fubini-Tonelli),

$$0 \leq \mathbb{E}_{n,\theta^\star}\left[R_{01}(\widehat{g}_n) - R_{01}(g^\star_{\theta^\star})\right] \leq 2 \int_{\mathsf{X}} \mathbb{E}_{n,\theta^\star}\left[\left| \eta_{\theta^\star}(\mathbf{x}) - \eta_{\hat{\theta}_n}(\mathbf{x}) \right| \right] p_{\mathbf{X}}(\mathbf{x})\, \mu(\mathrm{d}\mathbf{x}) \,.$$

Fixons $\mathbf{x}$ hors de l'ensemble négligeable de l'hypothèse (iii). La suite de variables aléatoires $\left| \eta_{\theta^\star}(\mathbf{x}) - \eta_{\hat{\theta}_n}(\mathbf{x}) \right|$ converge vers 0 en probabilité sous $\mathbb{P}_{n,\theta^\star}$ et est majorée par 1, les deux fonctions de régression étant à valeurs dans $[0,1]$; le théorème de convergence dominée pour la convergence en probabilité donne donc $\mathbb{E}_{n,\theta^\star}\left[\left| \eta_{\theta^\star}(\mathbf{x}) - \eta_{\hat{\theta}_n}(\mathbf{x}) \right| \right] \to 0$. Chacune de ces espérances étant majorée par 1 et $p_{\mathbf{X}} \cdot \mu$ étant une probabilité, une seconde application du théorème de convergence dominée, cette fois en la variable $\mathbf{x}$, montre que l'intégrale tend vers zéro. □

Deux avertissements accompagnent cet énoncé.

> La conclusion ne tient que si l'hypothèse de modélisation (i) est vérifiée, c'est-à-dire si la loi qui a engendré les données appartient bien au modèle. Si le modèle est mal spécifié, $\eta_{\hat{\theta}_n}$ ne converge pas vers la vraie fonction de régression, et l'excès de risque de $\widehat{g}_n$ ne tend pas vers zéro.

> La quantité qui tend vers zéro est une moyenne prise sous deux aléas distincts : celui d'un point de test, à l'intérieur de $R_{01}(\widehat{g}_n) - R_{01}(g^\star_{\theta^\star})$, et celui de l'ensemble d'apprentissage, par l'espérance $\mathbb{E}_{n,\theta^\star}$. C'est le double aléa annoncé à la Section 1.2.

En résumé : si le modèle est bon, la méthode est bonne. En pratique, il est parfois difficile de disposer d'un modèle raisonnable pour la loi de $(\mathbf{X}, Y)$, et c'est ce qui conduit à l'approche discriminative, étudiée aux chapitres 9 et 10, où l'on renonce à modéliser la loi et où l'on choisit directement une classe de règles et une perte. Le *résultat typique* ci-dessus est le sujet de l'exercice 2, et sa mise en œuvre complète sur le modèle de l'analyse discriminante est celui de l'exercice 3.

1.4 Le programme des exercices

La feuille de ce chapitre comporte sept exercices.

— L'exercice 1 remplace la perte 0–1 par une perte asymétrique, qui pénalise d'un coût $c > 0$ le fait de prédire -1 lorsque la réponse vaut 1, et d'un coût 1 la situation inverse. On y calcule le risque en fonction de η et de c, on montre que $2\,\mathbb{1}_{\{\eta(\mathbf{X}) \geq 1/(c+1)\}} - 1$ est une règle bayésienne, et l'on discute l'unicité de cette règle.

— L'exercice 2 reprend les formules du théorème 1.2 : le risque bayésien $\mathbb{E}[\min(\eta(\mathbf{X}), 1-\eta(\mathbf{X}))]$, l'écriture du risque d'un classifieur quelconque donnée par (6), la majoration $|R(g_1) - R(g_2)| \leq \mathbb{E}[|2\eta(\mathbf{X}) - 1|\, \mathbb{1}_{\{g_1(\mathbf{X}) \neq g_2(\mathbf{X})\}}]$, puis la majoration de l'excès de risque d'une règle construite sur une approximation de η, et enfin le passage à la limite qui donne la proposition 1.5.

— L'exercice 3 traite l'analyse discriminante de bout en bout : expression de la fonction de régression sous la forme $\mathrm{sigm}(\phi_\theta(\mathbf{x}))$, frontière linéaire lorsque les deux covariances coïncident, log-vraisemblance de l'échantillon, estimateur du maximum de vraisemblance, consistance de cet estimateur, et convergence vers zéro de l'excès de risque de la règle par substitution. La dernière question étend la méthode à plus de deux classes.

— L'exercice 4 porte sur l'espérance conditionnelle elle-même : deux couples de même loi ont des espérances conditionnelles de même loi, calcul de $\mathbb{E}[X \,|\, |X|]$ pour une variable de loi symétrique, et calcul de $\mathbb{E}[X_i \,|\, X_1 + \cdots + X_n]$ pour des variables indépendantes de même loi intégrables.

— L'exercice 5 est un modèle jouet en dimension un où les deux lois conditionnelles des attributs sont uniformes sur des intervalles qui se chevauchent. On y calcule la loi marginale des attributs, la fonction de régression, le risque bayésien et l'excès de risque d'une règle à seuil donnée.

— L'exercice 6 étudie, toujours en dimension un, la classe des règles à seuil $g_{(x',y')}$, qui prédisent y' à gauche de x' et $-y'$ à droite. On y exprime le minimum du risque dans cette classe à l'aide des fonctions de répartition conditionnelles, on montre qu'il est majoré par $\min(p, 1-p)$, et on le relie au risque bayésien.

— L'exercice 7 démontre la majoration (13) de l'excès de risque d'une règle construite sur une fonction η approchée, par $2\,\mathbb{E}[|\eta^\star(\mathbf{X}) - \eta(\mathbf{X})|]$. C'est le résultat employé dans la démonstration de la proposition 1.5.