2 Les outils mathématiques

On construit ici l'espérance conditionnelle et on en établit les propriétés qu'emploient les deux théorèmes des fondamentaux. Pour une variable de carré intégrable, elle se définit comme une projection orthogonale dans un espace de Hilbert, et c'est sous cette forme géométrique que ses propriétés s'établissent le plus simplement ; la définition s'étend ensuite aux variables simplement intégrables. Lorsque le couple $(\mathbf{X}, Y)$ admet une densité par rapport à une mesure produit, elle prend la forme d'une intégrale ordinaire contre la densité conditionnelle, et c'est celle qu'emploient tous les calculs du chapitre. Viennent ensuite les objets secondaires que les fondamentaux mobilisent : la mesure de comptage, la densité du vecteur gaussien et la fonction sigmoïde.

Les six premières sections reprennent intégralement, dans leur ordre, les douze planches de « Rappels sur l'espérance conditionnelle » données en annexe du cours (espace L^2 et projection, cas d'une sous-tribu, cas L^1, conditionnement par une variable aléatoire, propriétés, variables à densité), et les complètent par les démonstrations, par les propriétés élémentaires et la propriété d'indépendance, et par le lemme de décomposition qu'emploie la démonstration du classifieur bayésien.

2.1 L'espace L^2 et la projection orthogonale

L'ensemble des variables aléatoires de carré intégrable se munit d'un produit scalaire, ce qui donne un sens géométrique à la notion de meilleure approximation.

Définition 2.1: Espace $\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$

On note $\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ l'espace des variables aléatoires de carré intégrable définies sur l'espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$:

$$Z \in \mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P}) \quad \Longleftrightarrow \quad \mathbb{E}[Z^2] < \infty \, .$$

La forme $\langle Z_1, Z_2 \rangle := \mathbb{E}[Z_1 Z_2]$ y définit un produit pré-hilbertien : elle est bilinéaire et positive, mais $\langle Z, Z \rangle = 0$ entraîne seulement $Z = 0$ $\mathbb{P}$-presque sûrement, et non $Z \equiv 0$.

On note $\mathcal{R}$ la relation d'équivalence définie par

$$X \; \mathcal{R} \; Y \quad \text{si et seulement si} \quad X = Y \; \mathbb{P} - \text{p.s.} \, ,$$

et l'on quotiente par cette relation pour obtenir un produit scalaire au sens strict.

Définition 2.2: Espace $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$

On note $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ le quotient de $\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ par la relation d'équivalence $\mathcal{R}$. Ses éléments sont des classes d'équivalence $\dot{X}$, et $Z \in \dot{X}$ si et seulement si $Z = X$ $\mathbb{P}$-presque sûrement. Si $\widetilde{X} \in \dot{X}$ et $\widetilde{Y} \in \dot{Y}$, alors $\left\langle \widetilde{X}, \widetilde{Y} \right\rangle = \langle X, Y \rangle$; on pose donc

$$\left\langle \dot{X}, \dot{Y} \right\rangle := \left\langle \widetilde{X}, \widetilde{Y} \right\rangle \, , \qquad \widetilde{X} \in \dot{X} \, , \quad \widetilde{Y} \in \dot{Y} \, ,$$

définition qui ne dépend pas du choix des représentants des deux classes.

Théorème 2.1: L'espace L^2 est hilbertien

L'espace $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ muni du produit scalaire $\langle \cdot, \cdot \rangle$ est un espace de Hilbert.

On note $\|\dot{X}\|_{\mathrm{L}^2}^2 := \left\langle \dot{X}, \dot{X} \right\rangle$ la norme associée. Dans la suite, et conformément à l'usage, on confond une variable aléatoire et sa classe d'équivalence, toutes les identités étant entendues $\mathbb{P}$-presque sûrement.

Théorème 2.2: Projection sur un sous-espace vectoriel fermé

Soit $\mathcal{H}$ un sous-espace vectoriel fermé de $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ et $Z \in \mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$.

(i) Il existe un unique élément de $\mathcal{H}$, appelé *projection* de Z sur $\mathcal{H}$ et noté $P_{\mathcal{H}} Z$, tel que

$$\|Z - P_{\mathcal{H}} Z\|_{\mathrm{L}^2}^2 \leq \|Z - T\|_{\mathrm{L}^2}^2 \qquad \text{pour tout } T \in \mathcal{H} \, .$$

(ii) Cette projection est caractérisée par la relation d'*orthogonalité*

$$\langle Z - P_{\mathcal{H}} Z, T \rangle = 0 \qquad \text{pour tout } T \in \mathcal{H} \, .$$

(iii) L'application $P_{\mathcal{H}}$ est un opérateur linéaire sur $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$.

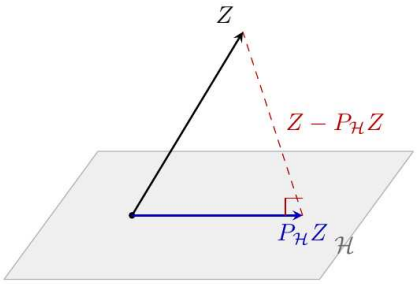


FIGURE 6 – La projection orthogonale de Z sur le sous-espace fermé $\mathcal{H}$: le vecteur $Z - P_{\mathcal{H}} Z$ est orthogonal à tout élément de $\mathcal{H}$, et $P_{\mathcal{H}} Z$ est le point de $\mathcal{H}$ le plus proche de Z.

Intuition. *Le point (ii) est la traduction du théorème de Pythagore dans un espace de dimension quelconque (figure 6) : le vecteur qui joint Z à son approximation la plus proche dans $\mathcal{H}$ est perpendiculaire à $\mathcal{H}$. C'est cette relation d'orthogonalité, et non l'inégalité du point (i), qui sert dans les calculs : elle transforme une propriété de minimalité en une famille d'égalités $\mathbb{E}[(Z - P_{\mathcal{H}} Z)\, T] = 0$, utilisable terme à terme.*

Appliquons cela au sous-espace des variables mesurables par rapport à une sous-tribu.

Lemme 2.1: Fermeture de $\mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$

Soit $\mathcal{A} \subset \mathcal{F}$ une σ-algèbre et soit $\mathcal{H} := \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ l'ensemble des variables aléatoires W de carré intégrable qui sont $\mathcal{A}$-mesurables, c'est-à-dire telles que $W^{-1}(B) \in \mathcal{A}$ pour tout $B \in \mathcal{B}(\mathbb{R})$. Alors $\mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ est un sous-espace hilbertien fermé de $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$.

Il en résulte que pour toute variable $Z \in \mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$, il existe une unique variable $X \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ telle que

$$\|Z - X\|_{\mathrm{L}^2} \leq \|Z - T\|_{\mathrm{L}^2} \qquad \text{pour tout } T \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P}) \, ,$$

ou, de façon équivalente, telle que pour tout $T \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$,

$$\langle Z, T\rangle = \langle X, T\rangle \ , \qquad \text{c'est-à-dire} \qquad \mathbb{E}\,[Z\,T] = \mathbb{E}\,[X\,T] \ . \tag{14}$$

Définition 2.3: Espérance conditionnelle comme projection dans L^2

On appelle *espérance conditionnelle* de Z sachant $\mathcal{A}$, et l'on note $\mathbb{E}\,[\,Z\,|\,\mathcal{A}]$, la projection orthogonale de Z sur $\mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$.

2.2 L'espérance conditionnelle dans L^1

La définition précédente demande un moment d'ordre deux. Elle s'étend aux variables simplement intégrables, au prix d'un énoncé d'existence et d'unicité qui remplace l'argument de projection.

Théorème et définition 2.1: Espérance conditionnelle sachant une sous-tribu

Soit Z une variable aléatoire de $\mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ et soit $\mathcal{A} \subset \mathcal{F}$ une σ-algèbre. Il existe une variable aléatoire X, unique à l'égalité $\mathbb{P}$-presque sûre près, telle que

(i) X est $\mathcal{A}$-mesurable ;

(ii) $\mathbb{E}[|X|] < \infty$;

(iii) pour toute variable aléatoire T $\mathcal{A}$-mesurable et bornée, $\mathbb{E}[ZT] = \mathbb{E}[XT]$.

La variable X est appelée *espérance conditionnelle* de Z sachant $\mathcal{A}$ et notée $\mathbb{E}\,[\,Z\,|\,\mathcal{A}]$. Lorsque Z est de carré intégrable, elle coïncide avec la projection de la définition 2.3.

2.3 Conditionnement par une variable aléatoire

Le conditionnement employé dans ce chapitre n'est pas celui par une tribu abstraite, mais celui par les attributs $\mathbf{X}$: la tribu est alors celle qu'engendre cette variable.

Si X est une variable aléatoire réelle, il est naturel de considérer la σ-algèbre engendrée par les événements de la forme $\{X \le a\}$; on la note $\sigma(X)$, et elle contient aussi tous les événements de la forme $\{X \in B\}$ pour $B \in \mathcal{B}(\mathbb{R})$. Si $\mathbf{X} = (X^{(1)}, \ldots, X^{(d)})$ est un vecteur aléatoire à valeurs dans $\mathbb{R}^d$, on note $\sigma(\mathbf{X})$ la σ-algèbre engendrée par les événements de la forme $\{\mathbf{X} \in B\}$, où $B \in \mathcal{B}(\mathbb{R}^d)$; de façon équivalente,

$$\sigma(\mathbf{X}) := \left\{A \subset \Omega \ : \ A = \mathbf{X}^{-1}(B) \text{ pour un } B \in \mathcal{B}(\mathbb{R}^d)\right\} \ .$$

Définition 2.4: Espérance conditionnelle sachant une variable aléatoire

Soit Z une variable aléatoire de $\mathcal{L}^1(\Omega, \mathcal{F}, \mathbb{P})$ et $\mathbf{X}$ une variable aléatoire à valeurs dans $(\mathsf{X}, \mathcal{X})$. L'*espérance conditionnelle* de Z sachant $\mathbf{X}$ est l'espérance conditionnelle de Z sachant $\sigma(\mathbf{X})$; on la note $\mathbb{E}\,[\,Z\,|\,\mathbf{X}]$.

Proposition 2.1: Caractérisation des variables $\sigma(\mathbf{X})$-mesurables

Soit $\mathbf{X}$ une variable aléatoire à valeurs dans $(\mathsf{X}, \mathcal{X})$, définie sur $(\Omega, \mathcal{F}, \mathbb{P})$. Une variable aléatoire réelle W sur $(\Omega, \mathcal{F}, \mathbb{P})$ est mesurable par rapport à $\sigma(\mathbf{X})$ si et seulement s'il existe une fonction mesurable $\Psi : \mathsf{X} \to \mathbb{R}$ telle que $W = \Psi(\mathbf{X})$.

Deux conséquences servent constamment dans les fondamentaux. D'abord, si $Y \in \mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$, la définition de $\mathbb{E}[Y \,|\, \mathbf{X}]$ comme projection donne

$$\mathbb{E}\left[(Y - \mathbb{E}[Y \,|\, \mathbf{X}])^2\right] \leq \mathbb{E}\left[(Y - T)^2\right] \qquad \text{pour tout } T \in \mathrm{L}^2(\Omega, \sigma(\mathbf{X}), \mathbb{P}) \,,$$

et la proposition 2.1 fournit une fonction mesurable $g^\star$ telle que $g^\star(\mathbf{X}) = \mathbb{E}[Y \,|\, \mathbf{X}]$. Ensuite, la même proposition identifie $\mathrm{L}^2(\Omega, \sigma(\mathbf{X}), \mathbb{P})$ à l'ensemble des $g(\mathbf{X})$ pour g mesurable avec $\mathbb{E}[g^2(\mathbf{X})] < \infty$, de sorte que

$$\mathbb{E}\left[(Y - g^\star(\mathbf{X}))^2\right] \leq \mathbb{E}\left[(Y - g(\mathbf{X}))^2\right] \qquad \text{et} \qquad \mathbb{E}[Y\, g(\mathbf{X})] = \mathbb{E}[g^\star(\mathbf{X})\, g(\mathbf{X})]$$

pour toute fonction mesurable g telle que $\mathbb{E}[g^2(\mathbf{X})] < \infty$: c'est l'énoncé du théorème 1.1.

2.4 Propriétés de l'espérance conditionnelle

Proposition 2.2: Espérance de l'espérance conditionnelle

Pour toute variable aléatoire intégrable Y et toute sous-tribu $\mathcal{A} \subset \mathcal{F}$,

$$\mathbb{E}[\mathbb{E}[Y \,|\, \mathcal{A}]] = \mathbb{E}[Y] \,.$$

Démonstration

Pour toute variable W $\mathcal{A}$-mesurable et bornée, $\mathbb{E}[W\mathbb{E}[Y \,|\, \mathcal{A}]] = \mathbb{E}[WY]$ par définition de l'espérance conditionnelle. Il suffit d'appliquer cette relation avec $W = 1$. □

Proposition 2.3: Produit

Soit Y une variable aléatoire intégrable et $\mathcal{A} \subset \mathcal{F}$ une sous-tribu. Pour toute variable aléatoire U $\mathcal{A}$-mesurable et bornée,

$$\mathbb{E}[U\, Y \,|\, \mathcal{A}] = U\, \mathbb{E}[Y \,|\, \mathcal{A}] \;, \quad \mathbb{P} - \text{p.s.} \,.$$

Démonstration

Pour toute variable aléatoire W $\mathcal{A}$-mesurable et bornée, la définition de l'espérance conditionnelle appliquée à UY, qui est intégrable puisque U est bornée, donne $\mathbb{E}[W\mathbb{E}[UY \,|\, \mathcal{A}]] = \mathbb{E}[WUY]$. Or UW est elle-même $\mathcal{A}$-mesurable et bornée, de sorte que la même définition, appliquée cette fois à Y, donne $\mathbb{E}[WUY] = \mathbb{E}[WU\mathbb{E}[Y \,|\, \mathcal{A}]]$. Les deux variables $\mathbb{E}[UY \,|\, \mathcal{A}]$ et $U\mathbb{E}[Y \,|\, \mathcal{A}]$ sont $\mathcal{A}$-mesurables et intégrables, et elles ont la même intégrale contre toute variable $\mathcal{A}$-mesurable bornée : l'unicité de l'espérance conditionnelle (théorème 2.1) permet de conclure. □

Les propriétés suivantes, énoncées pour des variables de carré intégrable, s'établissent toutes à partir de la définition comme projection.

Proposition 2.4: Propriétés élémentaires

Soient $U, V \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ à valeurs respectivement dans $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ et $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$.

(i) $\mathbb{E}[\mathbb{E}[U \,|\, V]] = \mathbb{E}[U]$.

(ii) Il existe une fonction mesurable $\Psi : \mathbb{R}^d \to \mathbb{R}$ telle que $\Psi(V) = \mathbb{E}[U \,|\, V]$ $\mathbb{P}$-presque sûrement.

(iii) Si $U \geq 0$, alors $\mathbb{E}[U \,|\, V] \geq 0$ $\mathbb{P}$-presque sûrement.

(iv) Pour tous réels α, β et toutes variables U_1, U_2 de $\mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$,

$$\mathbb{E}[\alpha U_1 + \beta U_2 \,|\, V] = \alpha \mathbb{E}[U_1 \,|\, V] + \beta \mathbb{E}[U_2 \,|\, V] \ .$$

(v) Pour toute fonction mesurable $\phi : \mathbb{R}^d \to \mathbb{R}$ telle que $\phi(V) \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$, $\mathbb{E}[\phi(V) \,|\, V] = \phi(V)$ $\mathbb{P}$-presque sûrement.

Démonstration

Le point (i) s'obtient en prenant $g \equiv 1$ dans (14). Le point (ii) est la proposition 2.1, jointe au fait que $\mathbb{E}[U \,|\, V]$ est $\sigma(V)$-mesurable. Pour (iii), on applique (14) avec $T = \mathbb{1}_{\{\mathbb{E}[U \,|\, V] < 0\}}$, qui est $\sigma(V)$-mesurable et bornée : si $\mathbb{P}(\mathbb{E}[U \,|\, V] < 0) > 0$, on obtient $\mathbb{E}[U \mathbb{1}_{\{\mathbb{E}[U \,|\, V] < 0\}}] < 0$, ce qui contredit $U \geq 0$. Le point (iv) résulte de la linéarité du produit scalaire et de l'unicité de la projection orthogonale. Le point (v) tient à ce que $\phi(V)$ appartient déjà à l'espace sur lequel on projette. □

La propriété suivante dit que, lorsque U et V sont indépendantes, l'espérance conditionnelle $\mathbb{E}[\phi(U, V) \,|\, V]$ s'obtient en gelant la variable V et en intégrant par rapport à U sous sa propre loi.

Proposition 2.5: Conditionnement et indépendance

Soient $U, V \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ à valeurs dans $(\mathbb{R}^p, \mathcal{B}(\mathbb{R}^p))$ et $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$ respectivement, et **indépendantes**. Soit $\phi : \mathbb{R}^p \times \mathbb{R}^d \to \mathbb{R}^q$ une fonction mesurable telle que $\phi(U, V) \in \mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$. Alors

$$\mathbb{E}[\phi(U, V) \,|\, V] = \Phi(V) \ , \qquad \text{où} \quad \Phi(v) := \mathbb{E}[\phi(U, v)] = \int \phi(u, v)\, \chi(\mathrm{d}u)$$

et où χ désigne la loi de U.

C'est cette proposition qui légitime le calcul de la probabilité d'erreur conditionnelle d'une règle apprise : on y prend pour U le couple de test $(\mathbf{X}, Y)$ et pour V l'ensemble d'apprentissage $\mathcal{D}_n$, qui sont indépendants (Section 4.4).

2.5 L'espérance conditionnelle pour des variables à densité

Les calculs du chapitre se font tous dans le cas où le couple admet une densité par rapport à une mesure produit. On en donne ici l'expression explicite, qui ramène l'espérance conditionnelle à une intégrale ordinaire.

Soient $(\mathsf{Y}, \mathcal{Y}, \mu)$ et $(\mathsf{X}, \mathcal{X}, \nu)$ deux espaces mesurés et soit $(Y, \mathbf{X})$ un vecteur aléatoire admettant une densité $p_{Y,\mathbf{X}}(y, \mathbf{x})$ par rapport à la mesure produit $\mu \otimes \nu$: pour toute fonction mesurable positive h,

$$\mathbb{E}[h(Y, \mathbf{X})] = \int_{\mathsf{Y} \times \mathsf{X}} h(y, \mathbf{x})\, p_{Y,\mathbf{X}}(y, \mathbf{x})\, \mu(\mathrm{d}y)\, \nu(\mathrm{d}\mathbf{x}) \ .$$

La loi marginale de $\mathbf{X}$ admet alors la densité

$$p_{\mathbf{X}}(\mathbf{x}) := \int_{\mathsf{Y}} p_{Y,\mathbf{X}}(y,\mathbf{x})\,\mu(\mathrm{d}y)\ ,$$

et, pour tout $\mathbf{x}$ tel que $p_{\mathbf{X}}(\mathbf{x}) > 0$, on pose

$$p_{Y|\mathbf{X}}(y \mid \mathbf{x}) := \frac{p_{Y,\mathbf{X}}(y,\mathbf{x})}{p_{\mathbf{X}}(\mathbf{x})}\ .$$

La fonction $y \mapsto p_{Y|\mathbf{X}}(y \mid \mathbf{x})$ est positive et d'intégrale 1 contre μ : c'est une densité par rapport à μ, appelée *densité conditionnelle de Y sachant $\mathbf{X} = \mathbf{x}$*.

Proposition 2.6: Espérance conditionnelle dans le cas à densité

Sous les hypothèses précédentes, si Y est intégrable, la fonction

$$\mathbf{x} \longmapsto \Phi(\mathbf{x}) := \int_{\mathsf{Y}} y\, p_{Y|\mathbf{X}}(y \mid \mathbf{x})\,\mu(\mathrm{d}y)$$

est définie pour $p_{\mathbf{X}} \cdot \nu$-presque tout $\mathbf{x}$, et

$$\Phi(\mathbf{X}) = \mathbb{E}\left[Y \,|\, \mathbf{X}\right]\ , \quad \mathbb{P}-\text{p.s.}\ .$$

Plus généralement, pour toute fonction mesurable ψ telle que $\psi(Y)$ soit intégrable, $\mathbb{E}\left[\psi(Y) \,|\, \mathbf{X}\right] = \left(\int_{\mathsf{Y}} \psi(y)\, p_{Y|\mathbf{X}}(y \mid \mathbf{x})\,\mu(\mathrm{d}y)\right)_{\mathbf{x}=\mathbf{X}}$.

Démonstration

La variable $\Phi(\mathbf{X})$ est $\sigma(\mathbf{X})$-mesurable par construction. Pour toute fonction mesurable bornée h, le théorème de Fubini et la définition de $p_{Y|\mathbf{X}}$ donnent

$$\begin{aligned}
\mathbb{E}\left[h(\mathbf{X})\,\Phi(\mathbf{X})\right] &= \int_{\mathsf{X}} h(\mathbf{x}) \left\{ \int_{\mathsf{Y}} y\, p_{Y|\mathbf{X}}(y \mid \mathbf{x})\,\mu(\mathrm{d}y) \right\} p_{\mathbf{X}}(\mathbf{x})\,\nu(\mathrm{d}\mathbf{x}) \\
&= \iint_{\mathsf{Y}\times\mathsf{X}} y\, h(\mathbf{x})\, \frac{p_{Y,\mathbf{X}}(y,\mathbf{x})}{p_{\mathbf{X}}(\mathbf{x})}\, p_{\mathbf{X}}(\mathbf{x})\,\mu(\mathrm{d}y)\,\nu(\mathrm{d}\mathbf{x}) \\
&= \iint_{\mathsf{Y}\times\mathsf{X}} y\, h(\mathbf{x})\, p_{Y,\mathbf{X}}(y,\mathbf{x})\,\mu(\mathrm{d}y)\,\nu(\mathrm{d}\mathbf{x}) = \mathbb{E}\left[Y\, h(\mathbf{X})\right]\ .
\end{aligned}$$

La contribution de l'ensemble $\{(y,\mathbf{x}) : p_{\mathbf{X}}(\mathbf{x}) = 0\}$ est nulle : la mesure de $\{\mathbf{x} : p_{\mathbf{X}}(\mathbf{x}) = 0\}$ sous la loi de $\mathbf{X}$ est nulle par définition de $p_{\mathbf{X}}$. Toute variable T $\sigma(\mathbf{X})$-mesurable et bornée s'écrivant $h(\mathbf{X})$ pour une fonction mesurable bornée h (proposition 2.1), on a $\mathbb{E}[Y\,T] = \mathbb{E}[\Phi(\mathbf{X})\,T]$ pour toute telle T, et $\Phi(\mathbf{X})$ est intégrable par le théorème de Fubini. Le théorème et définition 2.1 conclut. Le cas général se traite de la même façon en remplaçant y par $\psi(y)$. □

> Les mesures μ et ν peuvent être discrètes ou continues. Dans la Section 1.2, μ est la mesure de comptage sur $\{-1,1\}$ et l'intégrale en y est une somme de deux termes ; dans la Section 1.2, μ est la mesure de Lebesgue sur $\mathbb{R}$.

2.6 Un lemme de décomposition selon la fonction de régression

Le lemme suivant est l'outil de calcul de la démonstration du théorème 1.2 : il remplace l'espérance d'une fonction du couple $(\mathbf{X}, Y)$ par une espérance qui ne porte plus que sur $\mathbf{X}$, les deux valeurs possibles de Y étant pondérées par $\eta(\mathbf{X})$ et $1-\eta(\mathbf{X})$.

Lemme 2.2: Décomposition selon la fonction de régression

Soit Y une variable aléatoire à valeurs dans $\{-1,1\}$, η la fonction de régression et $\psi : \mathbb{R}^d \times \{-1,1\} \to \mathbb{R}_+$ une fonction mesurable bornée. Alors

$$\mathbb{E}\left[\psi(\mathbf{X},Y)\right] = \mathbb{E}\left[\psi(\mathbf{X},1)\,\eta(\mathbf{X})\right] + \mathbb{E}\left[\psi(\mathbf{X},-1)\,\left(1-\eta(\mathbf{X})\right)\right] \ .$$

Démonstration

La variable Y ne prenant que les valeurs -1 et 1, on a l'identité

$$\psi(\mathbf{X},Y) = \psi(\mathbf{X},1)\,\mathbb{1}_{\{Y=1\}} + \psi(\mathbf{X},-1)\,\mathbb{1}_{\{Y=-1\}} \ .$$

Prenons l'espérance et conditionnons par $\mathbf{X}$. Les variables $\psi(\mathbf{X},1)$ et $\psi(\mathbf{X},-1)$ sont $\sigma(\mathbf{X})$-mesurables et bornées, donc la propriété du produit (proposition 2.3) et la propriété de l'espérance de l'espérance conditionnelle (proposition 2.2) donnent

$$\mathbb{E}\left[\psi(\mathbf{X},1)\,\mathbb{1}_{\{Y=1\}}\right] = \mathbb{E}\left[\psi(\mathbf{X},1)\,\mathbb{E}\left[\,\mathbb{1}_{\{Y=1\}}\,\middle|\,\mathbf{X}\right]\right] = \mathbb{E}\left[\psi(\mathbf{X},1)\,\eta(\mathbf{X})\right] \ ,$$

et de même pour le second terme, puisque la linéarité de l'espérance conditionnelle donne $\mathbb{E}\left[\,\mathbb{1}_{\{Y=-1\}}\,\middle|\,\mathbf{X}\right] = 1 - \mathbb{E}\left[\,\mathbb{1}_{\{Y=1\}}\,\middle|\,\mathbf{X}\right] = 1-\eta(\mathbf{X})$. □

2.7 Mesure de comptage et modèle dominé

Lorsque la réponse prend un nombre fini de valeurs, la loi de Y n'admet pas de densité par rapport à la mesure de Lebesgue, mais elle en admet une par rapport à la *mesure de comptage*. Sur $\mathsf{Y} = \{-1,1\}$, cette mesure est $\mathrm{c} := \delta_{\{-1\}} + \delta_{\{1\}}$, et une fonction $p_Y : \{-1,1\} \to \mathbb{R}_+$ est une densité de probabilité par rapport à c si et seulement si $p_Y(-1) + p_Y(1) = 1$: l'intégrale contre c est la somme des deux valeurs. Le couple $(\mathbf{X},Y)$ admet alors une densité par rapport à la mesure produit $\mathrm{Leb} \otimes \mathrm{c}$ sur $\mathbb{R}^d \times \{-1,1\}$, et toutes les formules de la Section 2.5 s'appliquent. C'est la notion de modèle dominé du chapitre 1 (définition 1), appliquée ici à la mesure dominante produit.

2.8 Le vecteur gaussien et sa densité

Le modèle de l'analyse discriminante repose sur la densité d'un vecteur gaussien de $\mathbb{R}^d$. Un vecteur aléatoire $\mathbf{X}$ de $\mathbb{R}^d$ est dit gaussien lorsque toute combinaison linéaire de ses coordonnées est une variable gaussienne réelle (définition 10) ; sa loi est déterminée par son espérance $\mu \in \mathbb{R}^d$ et sa matrice de covariance Σ, qui est symétrique positive. Lorsque Σ est de plus inversible, cette loi admet par rapport à la mesure de Lebesgue de $\mathbb{R}^d$ la densité

$$q(\mathbf{x}) = \frac{1}{(2\pi)^{d/2}\sqrt{\det\Sigma}} \exp\left(-\frac{1}{2}(\mathbf{x}-\mu)^\top \Sigma^{-1}(\mathbf{x}-\mu)\right) \ ,$$

et seulement dans ce cas (proposition 2.7). C'est la raison pour laquelle le cadre 1.2 impose l'inversibilité des deux matrices de covariance.

2.9 La fonction sigmoïde

La fonction sigmoïde, ou fonction logistique, est

$$\mathrm{sigm} : t \longmapsto \frac{1}{1+\mathrm{e}^{-t}} \ .$$

Elle est de classe $\mathcal{C}^\infty$, strictement croissante de $\mathbb{R}$ sur $]0,1[$, de limites 0 en $-\infty$ et 1 en $+\infty$, et vérifie les deux identités

$$\mathrm{sigm}(-t) = 1 - \mathrm{sigm}(t)\ , \qquad \mathrm{sigm}'(t) = \mathrm{sigm}(t)\,(1 - \mathrm{sigm}(t))\ .$$

En particulier $\mathrm{sigm}(0) = 1/2$, de sorte que $\mathrm{sigm}(t) \geq 1/2$ si et seulement si $t \geq 0$: c'est ce qui ramène le seuil $\eta_\theta(\mathbf{x}) \geq 1/2$ à une condition affine en $\mathbf{x}$ dans le modèle logistique et dans l'analyse discriminante linéaire. Sa réciproque est la fonction *logit*, $u \mapsto \log(u/(1-u))$, de sorte que ϕ_θ défini en (11) est le logit de η_θ.

2.10 Les résultats antérieurs mobilisés

Les énoncés suivants sont employés tels quels.

— Du chapitre 1 : la notion de modèle dominé et de densité par rapport à une mesure dominante (définition 1), celle de n-échantillon (définition 6), la définition du vecteur gaussien et l'expression de sa densité (définition 10, proposition 2.7), et le théorème de Radon-Nikodym (théorème 2.1).

— Du chapitre 2 : la vraisemblance d'un échantillon et l'estimateur du maximum de vraisemblance (définition 1.4, méthode 1.2), ainsi que le point de vue des M-estimateurs (définition 1.8) et l'exemple des moindres carrés (exemple 1.15), que le modèle logistique et le modèle linéaire gaussien retrouvent.

— Du chapitre 6 : la convergence en probabilité (définition 2.1) et la consistance d'une suite d'estimateurs (définition 1.2), employées dans l'hypothèse (iii) de la proposition 1.5.

— Du chapitre 7 : la consistance de l'estimateur du maximum de vraisemblance, qui est l'hypothèse sous laquelle la règle par substitution de l'analyse discriminante est étudiée à l'exercice 3.

2.11 Les résultats admis

Quatre énoncés de cette partie sont utilisés sans être démontrés ici.

— La complétude de $\mathrm{L}^2(\Omega, \mathcal{F}, \mathbb{P})$, c'est-à-dire le théorème 2.1, qui relève de la théorie de la mesure.

— Le théorème de projection sur un sous-espace vectoriel fermé d'un espace de Hilbert (théorème 2.2) et la fermeture de $\mathrm{L}^2(\Omega, \mathcal{A}, \mathbb{P})$ (lemme 2.1).

— L'existence et l'unicité de l'espérance conditionnelle pour une variable simplement intégrable (théorème et définition 2.1), dont la démonstration passe par un argument de classe monotone ou par le théorème de Radon-Nikodym ; on en trouvera une rédaction au chapitre 34 de *Probability and Measure* de P. Billingsley.

— La caractérisation des variables $\sigma(\mathbf{X})$-mesurables (proposition 2.1), dite lemme de Doob.