1 Solutions

Solution Exercice 1. Rappels : pour toute paire de v.a. (X, Y), nous avons

$$\mathbb{E}\left[\phi(X,Y)\right] = \mathbb{E}\left[\mathbb{E}\left[\phi(X,Y)|Y\right]\right] = \mathbb{E}\left[\Psi(Y)\right], \qquad \Psi(Y) := \mathbb{E}\left[\phi(X,Y)|Y\right] .$$

Dans le cas où la loi du couple (X, Y) est de la forme $p(x, y)\mathrm{d}\mu(x)\mathrm{d}\nu(y)$, le terme de gauche s'écrit

$$\mathbb{E}\left[\phi(X,Y)\right] = \int_{\mathsf{X}\times\mathsf{Y}} \phi(x,y)\, p(x,y)\mathrm{d}\mu(x)\mathrm{d}\nu(y);$$

L'espérance conditionnelle vaut

$$\Psi(y) = \int_{\mathsf{X}} \phi(x,y)\, \frac{p(x,y)}{p_Y(y)}\mathrm{d}\mu(x); \qquad p_Y(y) := \int_{\mathsf{X}} p(u,y)\mathrm{d}\mu(u),$$

il s'agit de l'intégration en la variable x sous la loi conditionnelle de X sachant Y. Et donc, nous avons

$$\mathbb{E}\left[\phi(X,Y)\right] = \int_{\mathsf{Y}} \Psi(y)\, p_Y(y)\, \mathrm{d}\nu(y).$$

Lorsque X, Y sont indépendantes, la loi conditionnelle de X sachant Y est égale à la loi de X ; et nous avons donc

$$\Psi(y) = \int_{\mathsf{X}} \phi(x,y)\, p_X(x)\mathrm{d}\mu(x); \qquad p_X(x) := \int_{\mathsf{Y}} p(x,y)\mathrm{d}\nu(y) .$$

Par suite, dans le cas de v.a. indépendantes, conditionner par rapport à Y, s'interprète comme (a) "geler" la variable Y et considérer le calcul d'intégration par rapport à la variable x sous la loi de X ; (b) puis intégrer la quantité par rapport à la variable y sous la loi de Y.

1. Par linéarité de l'espérance

$$\mathbb{E}\left[\hat{R}_{n,m}\,\middle|\, D_n\right] = \frac{1}{m}\sum_{j=1}^{m} \mathbb{E}\left[\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}\,\middle|\, D_n\right] .$$

Comme la fonction aléatoire g_n dépend des données D_n, et que les v.a. $\{(X_{n+j}, Y_{n+j})\}_j$ sont indépendantes de D_n, on en déduit que (voir le rappel, cas indépendant)

$$\mathbb{E}\left[\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}\,\middle|\, D_n\right] = \mathbb{P}(g(X_{n+j}) \neq Y_{n+j})|_{g=g_n};$$

puis, comme $\{(X_{n+j}, Y_{n+j})\}_j$ ont même loi que (X, Y), il vient pour tout $j \geq 1$,

$$\mathbb{P}(g(X_{n+j}) \neq Y_{n+j}) = \mathbb{P}(g(X) \neq Y) = R(g).$$

Ainsi, pour tout $j \geq 1$,

$$\mathbb{E}\left[\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}\,\middle|\, D_n\right] = R(g_n)$$

dont nous déduisons que pour tout n, m,

$$\mathbb{E}\left[\hat{R}_{n,m}\,\middle|\, D_n\right] = R(g_n) .$$

2. $m\hat{R}_{n,m}$ est la somme des variables aléatoires $\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}$, $j=1,\dots,m$. Attention : il y a deux sources d'aléa, l'une via les données d'apprentissage au travers de g_n, et l'autre via les données de test au travers des $\{(X_{n+j},Y_{n+j})\}_j$. Puisque les données de test et celles d'apprentissage sont indépendantes, conditionner par D_n permet de "geler" l'aléa contenu dans g_n (et le voir comme une fonction déterministe) puis faire tous les calculs d'espérance par rapport à la loi des données de test uniquement. Ces variables sont, conditionnellement à D_n, indépendantes et de même loi de Bernoulli de paramètre $R(g_n)$, donc $\mathcal{L}(m\hat{R}_{n,m}|D_n)=\mathrm{Bin}(m,R(g_n))$.
3. On déduit de la question précédente que

$$\mathbb{E}\left[(\hat{R}_{n,m}-R(g_n))^2\,\middle|\,D_n\right]=\frac{1}{m^2}\mathrm{Var}\left(m\hat{R}_{n,m}|D_n\right)=\frac{R(g_n)\,(1-R(g_n))}{m}\leqslant\frac{1}{4m}\,.$$

La propriété

$$\mathbb{E}\left[(\hat{R}_{n,m}-R(g_n))^2\right]=\mathbb{E}\left[\mathbb{E}\left[(\hat{R}_{n,m}-R(g_n))^2\,\middle|\,D_n\right]\right]$$

entraine

$$\mathbb{E}\left[(\hat{R}_{n,m}-R(g_n))^2\right]\leq\frac{1}{4m}\,.$$

Par application de l'inégalité de Markov, il vient

$$\mathbb{P}(|\hat{R}_{n,m}-R(g_n)|\geq\varepsilon)\leq\frac{1}{\varepsilon^2 4m}$$

4. Les variables aléatoires $\{\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}-R(g_n)\}_{j=1}^m$ sont, conditionnellement à D_n, des variables aléatoires indépendantes à valeurs dans $[-R(g_n),1-R(g_n)]$; la taille de cet intervalle vaut 1. L'inégalité de Hoeffding assure que

$$\begin{aligned}\forall\varepsilon>0,\qquad&\mathbb{P}\left(\frac{1}{m}\sum_{j=1}^m(\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}-R(g_n))>\varepsilon\right)\\&=\mathbb{E}\left[\mathbb{P}\left(\sum_{j=1}^m(\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}-R(g_n))>m\varepsilon\,\middle|\,D_n\right)\right]\leqslant\mathbb{E}\left[\mathrm{e}^{-2m\varepsilon^2}\right]=\mathrm{e}^{-2m\varepsilon^2}\,.\end{aligned}$$

En appliquant le même raisonnement aux variables $R_n-\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}$, on trouve

$$\forall\varepsilon>0,\qquad\mathbb{P}\left(\frac{1}{m}\sum_{j=1}^m(\mathbb{1}_{\{g_n(X_{n+j})\neq Y_{n+j}\}}-R(g_n))<-\varepsilon\right)\leqslant\mathrm{e}^{-2m\varepsilon^2}\,.$$

On conclut avec une borne d'union :

$$\mathbb{P}(|Z|\geq\varepsilon)=\mathbb{P}(Z\geq\varepsilon)+\mathbb{P}(Z\leq-\varepsilon).$$

Solution Exercice 2. 1. La transformée de Laplace d'une variable gaussienne centrée est de variance σ^2 est $\exp(\lambda^2\sigma^2/2)$. On en déduit que

$$\ln\mathbb{E}[\exp(\lambda X)]=\frac{\lambda^2}{2}\sigma^2.$$

Nous avons en effet

$$\begin{aligned}\mathbb{E}[\exp(\lambda X)] &= \int \exp(\lambda x)\,\frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{x^2}{2\sigma^2}\right)\mathrm{d}x\\ &= \frac{1}{\sigma\sqrt{2\pi}}\int \exp\left(-\frac{1}{2\sigma^2}(x^2-2\lambda\sigma^2 x)\right)\mathrm{d}x\\ &= \frac{1}{\sigma\sqrt{2\pi}}\exp\left(\frac{\lambda^2\sigma^2}{2}\right)\int \exp\left(-\frac{1}{2\sigma^2}(x-\lambda\sigma^2)^2\right)\mathrm{d}x\\ &= \exp\left(\frac{\lambda^2\sigma^2}{2}\right)\times 1.\end{aligned}$$

2. Nous avons : $\mathbb{E}[\exp(\lambda X)] = (1/2)\{\mathrm{e}^{\lambda}+\mathrm{e}^{-\lambda}\}$. Puisque $\exp(u)=\sum_{k\geq 0}u^k/k!$, il vient

$$\begin{aligned}\mathbb{E}\left[\mathrm{e}^{\lambda X}\right] = \frac{1}{2}\left\{\mathrm{e}^{-\lambda}+\mathrm{e}^{\lambda}\right\} &= \frac{1}{2}\left\{\sum_{k=0}^{\infty}\frac{(-\lambda)^k}{k!}+\sum_{k=0}^{\infty}\frac{(\lambda)^k}{k!}\right\}\\ &= \sum_{k\geq 0,k\text{ paire}}\frac{\lambda^k}{k!} = \sum_{q=0}^{\infty}\frac{\lambda^{2q}}{(2q)!}\\ &\leq 1+\sum_{k=1}^{\infty}\frac{\lambda^{2k}}{2^k k!} = \mathrm{e}^{\lambda^2/2}.\end{aligned}$$

L'inégalité résulte du fait que pour $q\geq 1$,

$$(2q)! = 1\times 2\times\cdots\times(2q-2)\,(2q-1)\,2q \geq 2\times 4\times\cdots\times 2(q-1)\,2q = 2^q\,q!.$$

On en déduit que $\ln PE\left[\mathrm{e}^{\lambda X}\right]\leq \lambda^2/2$.

3. Puisque les v.a. X_i sont indépendantes, nous avons

$$\mathbb{E}\left[\mathrm{e}^{\lambda\sum_{i=1}^n X_i}\right] = \prod_{i=1}^n \mathbb{E}\left[\mathrm{e}^{\lambda X_i}\right]$$

ce qui entraine que $\psi_{\sum_{i=1}^n X_i}(\lambda) = \sum_{i=1}^n \psi_{X_i}(\lambda)$. On en déduit le résultat demandé.

4. Soit Z une variable aléatoire à valeur réelle. Pour $\lambda\geq 0$, l'inégalité de Markov implique

$$\mathbb{P}(Z\geq t)\leq \mathrm{e}^{-\lambda t}\mathbb{E}[\mathrm{e}^{\lambda Z}] = \exp\left(-\lambda t+\psi_Z(\lambda)\right).$$

Puisque cette inégalité est valable pour toutes les valeurs de $\lambda\geq 0$, elle est vraie en considérant la valeur minimale en λ ce qui donne

$$\mathbb{P}(Z\geq t)\leq \inf_{\lambda\geq 0}\exp\left(-\lambda t+\psi_Z(\lambda)\right) = \exp\left(-\sup_{\lambda\geq 0}\{\lambda t-\psi_Z(\lambda)\}\right).$$

5. Considérons maintenant le cas où Z est une v.a. sous-gaussienne. Alors $\psi_Z(\lambda)\leq \lambda^2/2v$ ce qui entraine

$$\mathbb{P}(Z\geq t)\leq \exp\left(-\sup_{\lambda\geq 0}\{\lambda t-\lambda^2/2v\}\right).$$

Il suffit d'optimiser $\lambda \mapsto \lambda t - \lambda^2 v/2$. Cette fonction a un maximum au point $\lambda_\star := t/v$. On en déduit que

$$\mathbb{P}(Z \geq t) \leq \exp\left(-\frac{t^2}{2v}\right).$$

Enfin, en observant que si Z est sous-gaussienne, alors $-Z$ l'est aussi, nous avons

$$\mathbb{P}(-Z \geq t) \leq \exp\left(-\frac{t^2}{2v}\right).$$

Les deux probabilités admettent le même majorant, donc le maximum des deux aussi.

Solution Exercice 3. 1. Nous écrivons

$$S_n - \mathbb{E}[S_n] = \sum_{i=1}^n (Z_i - \mathbb{E}[Z_i]) = \sum_{i=1}^n X_i \qquad X_i := Z_i - \mathbb{E}[Z_i].$$

Les v.a. $(X_i)_{1\leq i\leq n}$ sont centrées et indépendantes. $\mathbb{P}(Z_i \in [a_i, b_i]) = 1$ entraine que $\mathbb{P}(X_i \in [a_i - \mathbb{E}[Z_i], b_i - \mathbb{E}[Z_i]]) = 1$. On peut donc appliquer (1) et l'on a

$$\psi_{X_i}(\lambda) \leq \lambda \times 0 + \frac{\lambda^2}{2}\frac{(b_i - a_i)^2}{4}$$

dont on déduit que $X_i \in \mathcal{G}((b_i - a_i)^2/4)$.
On utilise alors la question 3 de l'exercice 2 pour en déduire que

$$S_n - \mathbb{E}[S_n] \in \mathcal{G}(\sum_{i=1}^n (b_i - a_i)^2/4).$$

On conclut ensuite en appliquant la question 5 de l'exercice 2.

2. La dérivée de $t \mapsto \ln \phi(\lambda)$ est donnée par $\phi'(\lambda)/\phi(\lambda)$. Puisque la dérivée de $\lambda \mapsto \mathbb{E}\left[\exp(\lambda X)\right]$ vaut $\mathbb{E}\left[X \exp(\lambda X)\right]$, nous en déduisons que

$$\psi'_X(\lambda) = \frac{\mathbb{E}\left[X \exp(\lambda X)\right]}{\mathbb{E}\left[\exp(\lambda X)\right]} = \int x \frac{\exp(\lambda x)\mu(\mathrm{d}x)}{\mathbb{E}\left[\exp(\lambda X)\right]} = \int x \mu_\lambda(\mathrm{d}x).$$

De même,

$$\psi''_X(\lambda) = \frac{\mathbb{E}\left[X^2 \exp(\lambda X)\right]\mathbb{E}\left[\exp(\lambda X)\right] - \left(\mathbb{E}\left[X \exp(\lambda X)\right]\right)^2}{\left(\mathbb{E}\left[\exp(\lambda X)\right]\right)^2} = \int x^2 \mu_\lambda(\mathrm{d}x) - \left(\int x \mu_\lambda(\mathrm{d}x)\right)^2.$$

La dérivée seconde $\psi''_X(\lambda)$ s'interprète comme la variance d'une v.a. de loi μ_λ.

3. Soit $\lambda \in \mathbb{R}$. La relation vient de l'inégalité de Taylor-Lagrange à l'ordre 2, et des relations

$$\psi_X(0) = \ln 1 = 0, \qquad \psi'_X(0) = \int x\, \mu_0(\mathrm{d}x) = \int x\, \mu(\mathrm{d}x) = \mathbb{E}[X].$$

Remarque. Par hypothèse

$$\mathbb{P}(X \in [a, b]) = 1 = \int_a^b \mu(\mathrm{d}x).$$

Soit $Y \sim \mu_\lambda$. Pour tout ensemble $\mathcal{C} \subset \mathbb{R} \setminus [a,b]$,

$$\mathbb{P}(Y \in \mathcal{C}) = \int_a^b \mathbb{1}_{x\in\mathcal{C}} \frac{\exp(\lambda x)}{\mathbb{E}[\exp(\lambda X)]}\mu(\mathrm{d}x) \leq \frac{\exp(|\lambda|\,(|b| \vee |a|))}{\mathbb{E}[\exp(\lambda X)]}\mu(\mathcal{C}\cap[a,b]) = 0.$$

On en déduit que si $Y \sim \mu_\lambda$ alors $\mathbb{P}(Y \in [a,b]) = 1$.

4. D'après la remarque, nous avons

$$\mathrm{Var}(Y) = \min_{c\in\mathbb{R}} \mathbb{E}\left[(Y-c)^2\right] \leq \mathbb{E}\left[\left(Y - \frac{a+b}{2}\right)^2\right].$$

Puisque $Y \in [a,b]$,

$$a - \frac{a+b}{2} \leq Y - \frac{a+b}{2} \leq b - \frac{a+b}{2},$$

dont on déduit que $(Y-(a+b)/2)^2 \leq (b-a)^2/4$. Par suite, $\mathrm{Var}(Y) \leq (b-a)^2/4$. La question 2 entraine que $\psi_Z''(\lambda) \leq (b-a)^2/4$. La majoration étant vraie pour tout $\lambda \in \mathbb{R}$, on a $\sup_{\lambda\in\mathbb{R}} \psi_Z''(\lambda) \leq (b-a)^2/4$.

5. La question 4 montre que $\sup_{u\in\mathbb{R}} \psi_X''(u) \leq (b-a)^2/4$. Ainsi

$$\psi_X(\lambda) \leq \lambda m + \frac{\lambda^2}{2}\frac{(b-a)^2}{4}.$$

Solution Exercice 4. 1. (a) La fonction $x \mapsto \mathrm{e}^{\lambda x}$ étant convexe, l'inégalité de Jensen assure que, pour toute variable aléatoire X, $\mathrm{e}^{\lambda\mathbb{E}[X]} \leqslant \mathbb{E}[\mathrm{e}^{\lambda X}]$. Cette inégalité appliquée à $X = \max_{i\in\{1,\dots,m\}} Z_i$ donne la première inégalité.
Pour la seconde, on utilise que

$$\mathrm{e}^{\lambda \max_{i\in\{1,\dots,m\}} Z_i} \leq \sum_{i=1}^m \exp(\lambda Z_i)$$

puis on applique l'espérance, et on utilise l'hypothèse sur la majoration de chaque transformée de Laplace.

(b) D'après la question précédente, on a, pour tout $\lambda > 0$,

$$\mathrm{e}^{\lambda\mathbb{E}[\max_{1\leq i\leq m} Z_i]} \leqslant m\mathrm{e}^{\lambda^2\sigma^2/2}\,.$$

En prenant le logarithme et en divisant par λ (qui est strictement positif), on en déduit

$$\mathbb{E}[\max_{i\in\{1,\dots,m\}} Z_i] \leqslant \frac{\log m}{\lambda} + \lambda\frac{\sigma^2}{2}\,.$$

On prend la valeur de λ qui équilibre les deux termes (ou celui qui minimise la fonction de λ) : $\lambda = \frac{\sqrt{2\log m}}{\sigma}$, et on obtient le résultat.

(c) On considère les variables aléatoires $Z_1', \dots, Z_{2m}'$ avec $Z_i' = Z_i$ pour tout $1 \leqslant i \leqslant m$ et $Z_i' = -Z_{i-m}$ pour tout $m+1 \leqslant i \leqslant 2m$. Ces variables satisfont $\mathbb{E}[\mathrm{e}^{\lambda Z_i'}] \leq \mathrm{e}^{\lambda^2\sigma^2/2}$ pour tout $i \in \{1,\dots,2m\}$ et tout $\lambda > 0$. On a

$$\max_{i\in\{1,\dots,m\}} |Z_i| = \max_{1\in\{1,\dots,2m\}} Z_i'\,.$$

En appliquant la question précédente aux variables Z_i', on obtient le résultat.

2. (a) Nous écrivons

$$R_n(g) - R(g) = \frac{1}{n}\sum_{k=1}^{n}\left(\mathbb{1}_{\{g(X_k)\neq Y_k\}} - \mathbb{P}(g(X)\neq Y)\right)$$

Les variables aléatoires $\mathbb{1}_{\{g(X_i)\neq Y_i\}} - \mathbb{P}(g(X)\neq Y)$ sont indépendantes, de même loi, et à valeurs dans $[-R(g), 1-R(g)]$, donc d'après le lemme d'Hoeffding (Polycopié VI-3.8.), pour tout classifieur g et tout $\lambda \in \mathbb{R}$,

$$\mathbb{E}\left[\exp\left(\lambda\{\frac{1}{n}\sum_{i=1}^{n}\mathbb{1}_{\{g(X_i)\neq Y_i\}} - R(g)\}\right)\right] = \left(\mathbb{E}\left[\exp\left((\lambda/n)\left(\mathbb{1}_{\{g(X_i)\neq Y_i\}} - R(g)\right)\right)\right]\right)^n$$
$$\leq \left(\exp\left(\frac{\lambda^2}{8n^2}\right)\right)^n = \exp\left(\frac{\lambda^2}{8n}\right) .$$

(b) Puisque $g^\star_{\mathcal{C}}$ et $\hat{g}^*_{n,\mathcal{C}}$ sont des éléments de $\mathcal{C}$, nous avons par définition (de chacun)

$$R_n(\hat{g}^*_{n,\mathcal{C}}) \leq R_n(g^\star_{\mathcal{C}}), \qquad R(g^\star_{\mathcal{C}}) \leq R(\hat{g}^*_{n,\mathcal{C}}).$$

Par suite,

$$0 \leq R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}}) = R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}}) + R_n(\hat{g}^*_{n,\mathcal{C}}) - R_n(g^*_{\mathcal{C}}) + R_n(g^*_{\mathcal{C}}) - R(g^*_{\mathcal{C}})$$
$$\leqslant R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}}) + R_n(g^*_{\mathcal{C}}) - R(g^*_{\mathcal{C}}) .$$

Il s'en suit que

$$\mathbb{E}[R(\hat{g}^*_{n,\mathcal{C}})] \leqslant R(g^*_\star) + \mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}})\right] + \mathbb{E}\left[R_n(g^*_{\mathcal{C}}) - R(g^*_{\mathcal{C}})\right] = \mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}})\right] .$$

On notera en effet que

$$\mathbb{E}\left[R_n(g^*_{\mathcal{C}})\right] = \frac{1}{n}\sum_{k=1}^{n}\mathbb{P}(g^\star_{\mathcal{C}}(X_k)\neq Y_k) = \mathbb{P}(g^\star_{\mathcal{C}}(X)\neq Y) = R(g^\star_{\mathcal{C}}).$$

travailler l'espérance de $R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}})$ n'est pas si simple puisqu'il y a un double aléa (qui n'est pas indépendant, puisque dépendant tous les deux de l'ensemble d'apprentissage) : un aléa dans la définition du risque empirque R_n, qui s'applique au second aléa : le classifieur $\hat{g}^*_{n,\mathcal{C}}$. Une façon de couper cette difficulté est d'écrire :

$$R(\hat{g}^*_{n,\mathcal{C}}) - R_n(\hat{g}^*_{n,\mathcal{C}}) \leq \sup_{g\in\mathcal{C}}\left(R(g) - R_n(g)\right) = \sup_{1\leq i\leq M}\left(R(g_i) - R_n(g_i)\right)$$

D'après la question 2a, la question 1b s'applique avec $\sigma^2 \leftarrow 1/4n$ et $m \leftarrow M$ et on en déduit

$$\mathbb{E}[R(\hat{g}^*_{n,\mathcal{C}})] \leqslant R(g^\star_{\mathcal{C}}) + \frac{1}{2}\sqrt{\frac{2\log(M)}{n}} .$$

Remarque : on a ici obtenu une borne sur l'excès de risque intégré. On aurait pu obtenir une borne en intégrant la borne PAC du cours, mais on aurait obtenu une borne proportionnelle au cardinal de l'ensemble $\mathcal{C}$(car la borne PAC du cours résulte d'Hoeffding + une borne d'union "brutale") au lieu de $\sqrt{\log(|\mathcal{C}|)}$.
En effet, en utilisant Pisier, on contrôle mieux l'espérance du max de $|\mathcal{C}|$ variables

aléatoires (potentiellement dépendantes) sous-gaussiennes (l'intuition est que, par exemple pour des variables aléatoires gaussiennes, (l'espérance du) maximum de $k = |\mathcal{C}|$ variables croit très lentement en fonction du nombre de variables, utiliser la borne $\mathbb{E}\max X_i \leq \mathbb{E}\sum_{i=1}^k X_i \leq k\mathbb{E}X$ résulterait en une dépendance linéaire en k extrêmement pessimiste. Au contraire $\mathbb{E}\max X_i = \ln\exp(\mathbb{E}\max X_i) \leq \ln\mathbb{E}\exp\max X_i \leq \ln k\mathbb{E}\exp(X)$ (avec en plus de l'optimisation en λ) permet d'avoir une dépendance plus raisonnable !
D'un autre coté, dans le cours comme dans l'exercice, la concentration vis a vis des v.a. de Bernoulli découle du lemme de Hoeffding, qui montre que des variables bornées centrées sont sous-gaussiennes (avec paramètre $(b-a)^2/4$), et qui n'est pas optimal (cf cours) pour des Bernoullis.

3. On a, en remarquant que $\mathbb{1}_{\{Y_i \neq g(X_i)\}} = 1 - \mathbb{1}_{\{Y_i = g(X_i)\}}$

$$\arg\min_{g\in\mathcal{C}} \sum_{i=1}^n \mathbb{1}_{\{Y_i\neq g(X_i)\}} = \arg\max_{g\in\mathcal{C}} \sum_{x\in\mathsf{X}}\sum_{i=1}^n \mathbb{1}_{\{Y_i=g(x)\}}\mathbb{1}_{\{X_i=x\}} \,.$$

Ainsi, toute règle de décision g_n vérifiant, en tout point x,

$$g_n(x) = \begin{cases} 1 & \text{si } \sum_{i=1}^n \mathbb{1}_{\{Y_i=1\}}\mathbb{1}_{\{X_i=x\}} \geq \sum_{i=1}^n \mathbb{1}_{\{Y_i=0\}}\mathbb{1}_{\{X_i=x\}} \,, \\ 0 & \text{si } \sum_{i=1}^n \mathbb{1}_{\{Y_i=1\}}\mathbb{1}_{\{X_i=x\}} < \sum_{i=1}^n \mathbb{1}_{\{Y_i=0\}}\mathbb{1}_{\{X_i=x\}} \,, \end{cases}$$

minimise le risque empirique. Comme g_n^* vérifie ces conditions, c'est un minimiseur du risque empirique.

4. (a) Comme le classifieur bayésien g^* est une règle de classification : $g^* \in \mathcal{C}$; donc $R^* \geq \inf_{g\in\mathcal{C}} R(g)$. D'autre part, par définition du classifieur bayésien, $R(g) - R^* \geqslant 0$. Ainsi, $\inf_{g\in\mathcal{C}} R(g) \geqslant R^*$.
Soit $g \in \mathcal{C}$. Les variables aléatoires $\{\mathbb{1}_{\{g(X_i)\neq Y_i\}}\}_i$ sont indépendantes et à valeurs dans $[0,1]$, donc d'après l'inégalité de Hoeffding

$$\forall \varepsilon > 0, \qquad \mathbb{P}(|R_n(g) - R(g)| > \varepsilon) \leqslant 2\mathrm{e}^{-2n\varepsilon^2} \,.$$

Comme le cardinal de $\mathcal{C}$ est 2^K, en appliquant une borne d'union, on en déduit

$$\forall \varepsilon > 0, \qquad \mathbb{P}(\sup_{g\in\mathcal{C}} |R_n(g) - R(g)| > \varepsilon) \leqslant \sum_{g\in\mathcal{C}} \mathbb{P}(|R_n(g) - R(g)| > \varepsilon) \leq 2^{K+1}\mathrm{e}^{-2n\varepsilon^2} \,.$$

(b) On a

$$R(g_n^*) - R^* = R(g_n^*) - R_n(g_n^*) + R_n(g_n^*) - R_n(g^*) + R_n(g^*) - R^* \,.$$

Pour les mêmes raisons que dans la question 2b, nous avons

$$0 \leq \mathbb{E}\left[R(g_n^*)\right] - R^* \leqslant \mathbb{E}\left[\sup_{g\in\mathcal{C}} \left(R_n(g) - R(g)\right)\right] \leq \mathbb{E}\left[\sup_{g\in\mathcal{C}} |R_n(g) - R(g)|\right] \,.$$

En se rappelant que

$$\mathbb{E}\left[|U|\right] = \int_0^\infty \mathbb{P}(|U| \geq \varepsilon)\mathrm{d}\varepsilon$$

on en déduit que

$$\mathbb{E}[R(g_n^*) - R^*] \leq \int_0^{+\infty} \mathbb{P}(\sup_{g\in\mathcal{C}} |R_n(g) - R(g)| > \varepsilon)\mathrm{d}\varepsilon \, .$$

Pour majorer cette intégrale, on veut utiliser la borne de la question 4a. On remarque que cette borne n'est informative que lorsque ε est suffisamment grand (pour les petites valeurs de ε, elle est supérieure à 1). On utilise donc la borne de la question 4a pour les grandes valeurs de ε et pour les petites valeurs de ε, on majore la probabilité par 1. On obtient que, pour tout $x > 0$,

$$\begin{aligned}\mathbb{E}[R(g_n^*) - R^*] &\leqslant \int_0^x \mathrm{d}\varepsilon + \int_x^{+\infty} 2^{K+1} e^{-2n\varepsilon^2}\mathrm{d}\varepsilon \\ &= \int_0^x \mathrm{d}\varepsilon + 2^{K+1}\int_0^{+\infty} e^{-2n(\varepsilon+x)^2}\mathrm{d}\varepsilon \\ &\leqslant x + 2^{K+1}e^{-2nx^2}\int_0^{+\infty} e^{-2n\varepsilon^2}\mathrm{d}\varepsilon = x + 2^{K-1}e^{-2nx^2}\sqrt{2\pi/n} \, .\end{aligned}$$

où la dernière inégalité est obtenu en développant le carré dans l'exponentielle et en remarquant que $\varepsilon x \geqslant 0$. Le majorant est vrai pour tout $x > 0$ et il est de la forme $x + \exp(A - 2nx^2)$ avec

$$A = (K-1)\ln 2 + \frac{1}{2}\ln\left(\frac{2\pi}{n}\right).$$

En prenant $2nx^2 = A - \ln(A/2n)/2$, nous obtenons

$$x + 2^{K-1}e^{-2nx^2}\sqrt{2\pi/n} \leq 2\sqrt{\frac{A}{2n}} \leq \sqrt{\frac{(K-1)\ln 2}{2n} + \frac{\ln(2\pi) - \ln n}{4n}}.$$

Solution Exercice 5.

1. Les variables aléatoires $Y_i = \mathbb{1}_{\{X_i\in R\}}$ sont indépendantes, de loi de Bernoulli de paramètre
$$\mathbb{E}[Y_i] = \mathbb{P}(X_i \in \mathsf{R}) = \frac{|\mathsf{P}\cap\mathsf{R}|}{|\mathsf{P}|} \, .$$
Le résultat est donc une application de l'inégalité de Hoeffding en remarquant que $|\mathsf{R}\cap\mathsf{S}| = \sum_{i=1}^k \mathbb{1}_{\{X_i\in R\}}$.
2. C'est une conséquence directe du résultat de la question précédente.
3. On a
$$\sup_{\mathsf{R}\in\mathcal{R}} \left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| \geqslant \sup_{\mathsf{R}\in\mathcal{R}_\mathsf{S}} \left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| \, ,$$
car $\mathcal{R}_\mathsf{S} \subset \mathcal{R}$. Réciproquement, quelque soit $\mathsf{R} \in \mathcal{R}$, il existe $\mathsf{R}' \in \mathcal{R}_\mathsf{S}$ tel que $\mathsf{R}\cap\mathsf{P} = \mathsf{R}'\cap\mathsf{P}$. Il s'en suit que, nécessairement $\mathsf{R}\cap\mathsf{S} = \mathsf{R}'\cap\mathsf{S}$, donc, que
$$\left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| = \left|\frac{|\mathsf{R}'\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}'\cap\mathsf{P}|}{|\mathsf{P}|}\right| \leqslant \sup_{\mathsf{R}\in\mathcal{R}_\mathsf{S}} \left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| \, .$$
Cette inégalité étant vraie pour tout $\mathsf{R} \in \mathcal{R}$, on a finalement
$$\sup_{\mathsf{R}\in\mathcal{R}} \left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| \leqslant \sup_{\mathsf{R}\in\mathcal{R}_\mathsf{S}} \left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right| \, .$$

4. Remarquons d'abord que $|\mathcal{R}_{\mathsf{S}}| = \left(\frac{n(n-1)}{2}\right)^d \leqslant n^{2d}/2$. En appliquant une borne d'union dans le résultat de la question 1., on en déduit que

$$\mathbb{P}\left(\sup_{\mathsf{R}\in\mathcal{R}_{\mathsf{S}}}\left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|}-\frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right|>\varepsilon\right)\leqslant n^{2d}\mathrm{e}^{-2\varepsilon^2 k}\,.$$

Si $k \geqslant (d/\varepsilon^2)\log(n/\delta^{1/2d})$, cette inégalité implique

$$\mathbb{P}\left(\sup_{\mathsf{R}\in\mathcal{R}_{\mathsf{S}}}\left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|}-\frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right|>\varepsilon\right)\leqslant \delta\,.$$

Sur l'événement $\sup_{\mathsf{R}\in\mathcal{R}_{\mathsf{S}}}\left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|}-\frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right|\leqslant\varepsilon$, dont la probabilité est supérieure à $1-\delta$, on a, d'après la question 3.,

$$\sup_{\mathsf{R}\in\mathcal{R}}\left|\frac{|\mathsf{R}\cap\mathsf{S}|}{|\mathsf{S}|}-\frac{|\mathsf{R}\cap\mathsf{P}|}{|\mathsf{P}|}\right|\leqslant\varepsilon\,.$$

Solution Exercice 6. 1. On a par définition de $\mathbb{P}_{\mathbf{q}}$,

$$\mathbb{P}_{\mathbf{q}}(X=a_j,Y=q_j)=\frac{1}{K},\quad \mathbb{P}_{\mathbf{q}}(X=a_j,Y=1-q_j)=0\,.$$

Donc

$$\mathbb{P}_{\mathbf{q}}(X=a_j)=\mathbb{P}_{\mathbf{q}}(X=a_j,Y=q_j)+\mathbb{P}_{\mathbf{q}}(X=a_j,Y=1-q_j)=\frac{1}{K}\,.$$

Ainsi, sous $\mathbb{P}_{\mathbf{q}}$, X suit la loi uniforme sur $\{a_1,\dots,a_K\}$.

2. Soit g un classifieur, on a

$$\begin{aligned}\mathbb{P}_{\mathbf{q}}(Y\neq g(X)) &= \sum_{i=1}^K \mathbb{P}_{\mathbf{q}}(Y\neq g(X)\cap X=a_i)\\ &= \sum_{i=1}^K \mathbb{P}_{\mathbf{q}}(Y\neq g(a_i)\cap X=a_i)\\ &= \sum_{i=1}^K \mathbb{P}_{\mathbf{q}}(Y=q_i\cap X=a_i)\mathbb{1}_{\{q_i\neq g(a_i)\}}+\mathbb{P}_{\mathbf{q}}(Y=1-q_i\cap X=a_i)\mathbb{1}_{\{q_i=g(a_i)\}}\\ &= \frac{1}{K}\sum_{i=1}^K \mathbb{1}_{\{q_i\neq g(a_i)\}}\,.\end{aligned}$$

3. Pour tout $i\in\{1,\dots,K\}$, $g_{\mathbf{q}}(a_i)=q_i$, donc $\mathbb{P}_{\mathbf{q}}(Y\neq g_{\mathbf{q}}(X))=0$ d'après la question précédente. Il s'en suit que

$$R^*_{\mathbb{P}_{\mathbf{q}}}=\inf_{g:\mathsf{X}\to\{0,1\}}\mathbb{P}_{\mathbf{q}}(Y\neq g(X))=\mathbb{P}_{\mathbf{q}}(Y\neq g_{\mathbf{q}}(X))=0\,.$$

4. La première inégalité vient du fait que l'ensemble des lois de probabilité sur $\mathcal{X}\otimes\mathcal{P}(\{0,1\})$ contient l'ensemble $(\mathbb{P}_{\mathbf{q}})_{\mathbf{q}\in\{0,1\}^K}$ et que, pour ces lois, $R^*_{\mathbb{P}_{\mathbf{q}}}=0$ par la question précédente. La seconde inégalité vient des majorations, pour tout $\mathbf{q}\in\{0,1\}^K$,

$$\mathbb{E}_{n,\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y\neq g_n(X;D_n)|D_n)]\leqslant\sup_{\mathbf{q}\in\{0,1\}^K}\mathbb{E}_{n,\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y\neq g_n(X;D_n)|D_n)]\,.$$

Pour la troisième inégalité, on écrit

$$\mathbb{E}_{n,\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y \neq g_n(X;D_n)|D_n)] = \mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}] \ .$$

On a ensuite

$$\mathbb{1}_{\{Y\neq g_n(X;D_n)\}} \geqslant \mathbb{1}_{\{Y\neq g_n(X;D_n)\}}\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}} \ .$$

Comme $\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}$ est mesurable par rapport à la tribu engendrée par (D_n, X),

$$\begin{aligned}\mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}] &\geqslant \mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}|X,\\ &= \mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}|X,D_n]]\\ &= \mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}|X,D_n]\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}] \ .\end{aligned}$$

5. Si on fixe D_n, on fixe la règle $g_n(\cdot, D_n)$ et en particulier la valeur de $g_n(a_i, D_n)$ en tous les points $a_i \notin D_n$, de façon indépendante de D_n. Pour tout $i \in \{1,\ldots,K\}$ tel que $a_i \notin \{X_1,\ldots,X_n\}$, il existe 2^{K-1} valeurs de $\mathbf{q} \in \{0,1\}^K$ tels que $q_i = g_n(a_i, D_n)$ et 2^{K-1} $\mathbf{q} \in \{0,1\}^K$ tels que $q_i = 1 - g_n(a_i, D_n)$. Pour les premiers $\mathbb{E}_{\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{Y\neq g_n(a_i;D_n)\}}|D_n] = 0$ et pour les seconds $\mathbb{E}_{\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{Y\neq g_n(x;D_n)\}}|D_n] = 1$.
6. Comme $X, X_1, \ldots, X_n$ sont indépendants et, sous $\mathbb{P}_{\mathbf{q}}$, de même loi uniforme sur $\{a_1,\ldots,a_K\}$,

$$\mathbb{P}_{\mathbf{q}}(X_1 \neq x,\ldots,X_n \neq x) = \mathbb{P}(X \neq x)^n = (1-K^{-1})^n \ .$$

7. On déduit de la question 4

$$\sup_{\mathbb{P}}\{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X;D_n)|D_n)] - R^*_{\mathbb{P}}\} \geqslant \frac{1}{2^K}\sum_{\mathbf{q}\in\{0,1\}^K}\mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(X;D_n)\}}|X,D_n]\mathbb{1}_{\{X\notin\{X_1,\ldots}$$

Il vient ensuite de la question 5

$$\begin{aligned}&\sup_{\mathbb{P}}\{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X;D_n)|D_n)] - R^*_{\mathbb{P}}\}\\ &\qquad\geqslant \frac{1}{2^K}\sum_{\mathbf{q}\in\{0,1\}^K:\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(x;D_n)\}}|D_n]=1}\mathbb{E}_{D_n\sim\mathbb{P}_{n,\mathbf{q}},(X,Y)\sim\mathbb{P}_{\mathbf{q}}}[\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}] \ .\end{aligned}$$

On a alors, d'après la question 6,

$$\begin{aligned}&\sup_{\mathbb{P}}\{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X;D_n)|D_n)] - R^*_{\mathbb{P}}\}\\ &\qquad\geqslant \frac{\mathrm{Card}(\{\mathbf{q}\in\{0,1\}^K : \mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(x;D_n)\}}|D_n]=1\})}{2^K}\left(1-\frac{1}{K}\right)^n \ .\end{aligned}$$

En appliquant le résultat de la question 5 de nouveau, on a finalement

$$\sup_{\mathbb{P}}\{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X;D_n)|D_n)] - R^*_{\mathbb{P}}\} \geqslant \frac{1}{2}\left(1-\frac{1}{K}\right)^n \ .$$

Comme X est infini, on peut appliquer l'inégalité précédente pour toute valeur de K. En prenant la limite de cette inégalité lorsque $K \to \infty$, on obtient (2).

Solution Exercice 7. 1. On a

$$\begin{aligned} R(g_{\mathbf{a},b}) &= \mathbb{P}(\mathbf{a}^\top \mathbf{X} + b \geqslant 0 \cap Y = 0) + \mathbb{P}(\mathbf{a}^\top \mathbf{X} + b < 0 \cap Y = 1) \\ &= (1-p)(1 - F_{0,\mathbf{a}}(-b)) + pF_{1,\mathbf{a}}(-b) \ . \end{aligned}$$

2. D'après la question 1.,

$$R(g_{-\mathbf{a},-b}) = (1-p)(1 - F_{0,-\mathbf{a}}(b)) + pF_{1,-\mathbf{a}}(b) \ .$$

Comme pour tout couple $\mathbf{a}, b$,

$$F_{i,\mathbf{a}}(b) = 1 - F_{i,-a}(-b) \ ,$$

on en déduit

$$R(g_{-\mathbf{a},-b}) = (1-p)F_{0,\mathbf{a}}(-b) + p(1 - F_{1,\mathbf{a}}(-b)) \ .$$

3. On calcule

$$R(g_{-\mathbf{a},-b}) + R(g_{\mathbf{a},b}) = (1-p)F_{0,\mathbf{a}}(-b) + p(1-F_{1,\mathbf{a}}(-b)) + (1-p)(1-F_{0,\mathbf{a}}(-b)) + pF_{1,\mathbf{a}}(-b) = 1 \ .$$

$$\begin{aligned} R(g_{-\mathbf{a},-b}) - R(g_{\mathbf{a},b}) &= (1-p)F_{0,\mathbf{a}}(-b) + p(1 - F_{1,\mathbf{a}}(-b)) - (1-p)(1 - F_{0,\mathbf{a}}(-b)) - pF_{1,\mathbf{a}}(-b) \\ &= (1-p)(2F_{0,\mathbf{a}}(-b) - 1) + p(1 - 2F_{1,\mathbf{a}}(-b)) \\ &= -2\left[-(1-p)F_{0,\mathbf{a}}(-b) + pF_{1,\mathbf{a}}(-b) + (1/2 - p)\right] \ . \end{aligned}$$

D'après l'indication, on en déduit

$$\min\left(R(g_{-\mathbf{a},-b}), R(g_{\mathbf{a},b})\right) = \frac{1}{2} - \left|-(1-p)F_{0,\mathbf{a}}(-b) + pF_{1,\mathbf{a}}(-b) + (1/2 - p)\right| \ .$$

4. On prend la limite du majorant lorsque $b \to +\infty$, on en déduit, si $p \neq 1/2$,

$$\min_{\mathbf{a},b} R(g_{-\mathbf{a},-b}) \leqslant \frac{1}{2} - |1/2 - p| < 1/2 \ .$$

5. Supposons $p = 1/2$. Si il existe $\mathbf{a}, b$ tels que

$$-F_{0,\mathbf{a}}(-b) + F_{1,\mathbf{a}}(-b) \neq 0 \ ,$$

alors $\mathrm{Leb}(\{\mathbf{x} \in \mathbb{R}^d \ : \ f_1(\mathbf{x}) \neq f_0(\mathbf{x})\}) > 0$.
Supposons réciproquement que $\mathrm{Leb}(\{\mathbf{x} \in \mathbb{R}^d \ : \ f_1(\mathbf{x}) \neq f_0(\mathbf{x})\}) > 0$, alors, il existe $\mathbf{a}$ et b tels que

$$-F_{0,\mathbf{a}}(-b) + F_{1,\mathbf{a}}(-b) \neq 0 \ .$$

Donc

$$\left| -\frac{1}{2}F_{0,\mathbf{a}}(-b) + \frac{1}{2}F_{1,\mathbf{a}}(-b) + \frac{1}{2} - \frac{1}{2}\right| > 0 \ .$$

Ainsi

$$\min_{\mathbf{a},b} R(g_{-\mathbf{a},-b}) \leqslant \frac{1}{2} - \left| -\frac{1}{2}F_{0,\mathbf{a}}(-b) + \frac{1}{2}F_{1,\mathbf{a}}(-b) + \frac{1}{2} - \frac{1}{2}\right| < 1/2 \ .$$

6. Considérons l'ensemble $\mathcal{A}$ des couples (A, z), où $A \subset \{1, \dots, n\}$, est de cardinal d et $z \in \{-1, 1\}$. Le cardinal de $\mathcal{A}$ est clairement égal à $2\binom{n}{d}$. On peut, à tout couple (A, z) de $\mathcal{A}$, associé le classifieur $g_{A,z}$ de $\mathcal{C}_n$ défini par $\hat{g}_{n,i_{1d},z}(\mathbf{x})$, avec $A = \{i_{1d}\}$. L'application $(A, z) \mapsto g_{A,z}$ réalise une surjection par construction de $\mathcal{C}_n$, ce qui montre que le cardinal de $\mathcal{C}_n$ est inférieur à celui de $\mathcal{A}$ donc à $2\binom{n}{d}$.

7. Soit $g \in \mathcal{C}$ et $i_1, \dots, i_k$ l'ensemble des indices des points $\mathcal{C}_1$ de la forme $\mathbf{X}_i$ tels que $g(\mathbf{X}_i) = 1$, $i_{k+1}, \dots, i_n$ les indices des points $\mathcal{C}_0$ tels que $g(\mathbf{X}_i) = 0$. Les enveloppes convexes des points $\mathbf{X}_{i_1}, \dots, \mathbf{X}i_k$ et des points $\mathbf{X}_{i_{k+1}}, \dots, \mathbf{X}_{i_n}$ sont disjointes et les bords de ces enveloppes convexes sont des hyperplans affines définissant les classifieurs de $\mathcal{C}_n$. Parmi ces classifieurs, il en existe au moins un définissant les mêmes classes que g, sauf peut être en les d points le définissant. On a donc

$$\forall g \in \mathcal{C},\ \exists h \in \mathcal{C}_n : \qquad \widehat{\mathrm{R}}_n(h) \leqslant \widehat{\mathrm{R}}_n(g) + \frac{d}{n} .$$

8. On a

$$R(\hat{g}_n^\star) - R^\star = R(\hat{g}_n^\star) - \widehat{\mathrm{R}}_n(\hat{g}_n^\star) + \widehat{\mathrm{R}}_n(\hat{g}_n^\star) - \widehat{\mathrm{R}}_n(g^\star) + \widehat{\mathrm{R}}_n(g^\star) - R^\star .$$

On a clairement

$$R(\hat{g}_n^\star) - \widehat{\mathrm{R}}_n(\hat{g}_n^\star) \leqslant \max_{g \in \mathcal{C}_n} \{R(g) - \widehat{\mathrm{R}}_n(g)\} .$$

D'après la question 7., on a aussi

$$\widehat{\mathrm{R}}_n(\hat{g}_n^\star) - \widehat{\mathrm{R}}_n(g^\star) \leqslant \frac{d}{n} .$$

Le résultat se déduit de ces trois bornes.

9. On utilise d'abord la question 8. pour obtenir

$$\mathbb{P}(R(\hat{g}_n^\star) - R^\star \geqslant \varepsilon) \leqslant \mathbb{P}\left(\max_{g \in \mathcal{C}_n} \{R(g) - \widehat{\mathrm{R}}_n(g)\} + \widehat{\mathrm{R}}_n(g^\star) - R^\star + \frac{d}{n} \geqslant \varepsilon \right) .$$

On utilise ensuite le fait que $A + B \geqslant x$ seulement si $A \geqslant x/2$ ou $B \geqslant x/2$ valable pour tout réel x pour dire que

$$\mathbb{P}(R(\hat{g}_n^\star) - R^\star \geqslant \varepsilon) \leqslant \mathbb{P}\left(\max_{g \in \mathcal{C}_n} \{R(g) - \widehat{\mathrm{R}}_n(g)\} \geqslant \varepsilon/2 \right) + \mathbb{P}\left(\widehat{\mathrm{R}}_n(g^\star) - R^\star + \frac{d}{n} \geqslant \varepsilon/2 \right) .$$

Enfin, on obtient la majoration désirée en utilisant une borne d'union pour majorer

$$\mathbb{P}\left(\max_{g \in \mathcal{C}_n} \{R(g) - \widehat{\mathrm{R}}_n(g)\} \geqslant \varepsilon/2 \right) \leqslant \sum_{g \in \mathcal{C}_n} \mathbb{P}\left(R(g) - \widehat{\mathrm{R}}_n(g) \geqslant \varepsilon/2 \right) .$$

10. D'après l'inégalité d'Hoeffding, on a

$$\mathbb{P}\left(\widehat{\mathrm{R}}_n(g^\star) - R^\star \geqslant \varepsilon/2 - \frac{d}{n} \right) \leqslant \mathrm{e}^{-2n\left(\frac{\varepsilon}{2} - \frac{d}{n}\right)^2} \leqslant \mathrm{e}^{2\varepsilon d} e^{-n\frac{\varepsilon^2}{2}} .$$

11. On a

$$R(\hat{g}_{n,i_{1d},z}) - \widehat{\mathrm{R}}_n(\hat{g}_{n,i_{1d},z}) = \frac{1}{n}\sum_{j=1}^{n}\{R(\hat{g}_{n,i_{1d},z}) - \mathbb{1}_{\{\hat{g}_{n,i_{1d},z}(\mathbf{X}_j)\neq Y_j\}}\}$$
$$= \frac{1}{n}\sum_{j\notin i_{1d}}\{R(\hat{g}_{n,i_{1d},z}) - \mathbb{1}_{\{\hat{g}_{n,i_{1d},z}(\mathbf{X}_j)\neq Y_j\}}\} + \frac{1}{n}\sum_{j\in i_{1d}}\{R(\hat{g}_{n,i_{1d},z}) - \mathbb{1}_{\{\hat{g}_{n,i_{1d},z}(\mathbf{X}_j)\neq Y_j\}}\}$$
$$\leqslant \frac{1}{n}\sum_{j\notin i_{1d}}\{R(\hat{g}_{n,i_{1d},z}) - \mathbb{1}_{\{\hat{g}_{n,i_{1d},z}(\mathbf{X}_j)\neq Y_j\}}\} + \frac{d}{n}\,.$$

où nous avons utilisé $R(\hat{g}_{n,i_{1d},z}) = \mathbb{P}\,(\,\hat{g}_{n,i_{1d},z}(X_j) \neq Y_j \,|\, \mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d})$ pour $j \notin i_{1d}$. On en déduit, en appliquant l'inégalité de Hoeffding

$$\mathbb{P}\left(\frac{1}{n}\sum_{j=1}^{n}\{R(\hat{g}_{n,i_{1d},z}) - \mathbb{1}_{\{\hat{g}_{n,i_{1d},z}(\mathbf{X}_j)\neq Y_j\}}\} \geq \varepsilon/2 \,\middle|\, \mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d}\right) \leqslant \mathrm{e}^{-2\frac{n^2}{n-d}\left(\frac{\varepsilon}{2}-\frac{d}{n}\right)^2} \leqslant \mathrm{e}^{2\varepsilon d}\mathrm{e}^{-n\frac{\varepsilon^2}{2}}\,.$$

12. En injectant les bornes des questions (9) et (10) dans la majoration obtenue à la question 9., on obtient

$$\mathbb{P}(R(\hat{g}_n^\star) - R^\star \geqslant \varepsilon) \leqslant \left(2\binom{n}{d}+1\right)\mathrm{e}^{2\varepsilon d}\mathrm{e}^{-n\frac{\varepsilon^2}{2}} \leqslant \left(2\mathrm{e}^{d\log\left(e\frac{n}{d}\right)}+1\right)\mathrm{e}^{2\varepsilon d}\mathrm{e}^{-n\frac{\varepsilon^2}{2}}\,.$$

On choisit alors n assez grand pour que

$$\log\left(2\mathrm{e}^{d\log\left(e\frac{n}{d}\right)}+1\right) + 2\varepsilon d - n\frac{\varepsilon^2}{2} \leqslant -\log 1/\delta\,,$$

ce qui est possible car, lorsque $n\to\infty$, $\log\left(2\mathrm{e}^{d\log\left(e\frac{n}{d}\right)}+1\right) \sim \log n$ et donc

$$\log\left(2\mathrm{e}^{d\log\left(e\frac{n}{d}\right)}+1\right) + 2\varepsilon d - n\frac{\varepsilon^2}{2} \sim -n\frac{\varepsilon^2}{2}\,.$$