Exercice 1 (Erreur de validation (⋆⋆)). Nous cherchons à estimer l'erreur

$$R(g_n) := \mathbb{P}(g_n(X) \neq Y | D_n)$$

d'une règle de classification g_n calculée à partir d'un ensemble d'apprentissage $D_n = \{(X_i, Y_i)\}_{i=1}^n$ indépendant de (X, Y).

Nous disposons pour cela d'un ensemble de test $T_m = \{(X_{n+i}, Y_{n+i})\}_{i=1}^m$ de m variables aléatoires indépendantes, indépendantes de D_n et distribuées suivant la loi du couple (X, Y). Nous notons

$$\hat{R}_{n,m} := \frac{1}{m} \sum_{j=1}^{m} \mathbb{1}_{\{g_n(X_{n+j}) \neq Y_{n+j}\}} .$$

1. Montrer que
$$\mathbb{E}\left[\hat{R}_{n,m} \,\middle|\, D_n \right] = R(g_n) .$$
2. Quelle est la distribution conditionnelle de $m\hat{R}_{n,m}$ sachant D_n ?
3. Montrer que
$$\mathbb{E}\left[(\hat{R}_{n,m} - R(g_n))^2 \,\middle|\, D_n \right] = \frac{R(g_n)(1 - R(g_n))}{m} ,$$
et en déduire une majoration de $\mathbb{P}(|\hat{R}_{n,m} - R(g_n)| \geq \varepsilon)$ pour tout $\varepsilon > 0$. *on pourra utiliser la majoration* $p(1-p) \leq 1/4$ *pour tout* $p \in [0, 1]$.
4. En utilisant une inégalité exponentielle, montrer que pour tout $\varepsilon > 0$,
$$\mathbb{P}(|\hat{R}_{n,m} - R(g_n)| \geq \varepsilon) \leq 2\mathrm{e}^{-2m\varepsilon^2} .$$

Exercice 2 (Variables sous-gaussiennes (⋆⋆)). Une variable aléatoire centrée X est dite *sous-gaussienne* avec un facteur de variance v ($v > 0$) si

$$\psi_X(\lambda) := \log \mathbb{E}[\mathrm{e}^{\lambda X}] \leq \frac{\lambda^2 v}{2} \quad \text{pour tout} \quad \lambda \in \mathbb{R}.$$

Nous notons $\mathcal{G}(v)$ la collection de telles variables aléatoires.
La fonction $\lambda \mapsto \mathbb{E}[\mathrm{e}^{\lambda X}]$ est la *transformée de Laplace* de la v.a. X ; et ψ_X est la *fonction génératrice des cumulants*.
Notons que cette définition n'exige pas que la variance de X soit égale à v mais simplement qu'elle soit bornée par v.

1. Soit X une variable aléatoire gaussienne centrée de variance v. Montrer que $X \in \mathcal{G}(v)$.
2. Soit X une variable de *Rademacher* : $X \in \{-1, +1\}$, $\mathbb{P}(X = 1) = \mathbb{P}(X = -1) = 1/2$. Montrer que $X \in \mathcal{G}(1)$.
3. Supposons que $X_1, \ldots, X_n$ sont des variables aléatoires indépendantes et pour tout $i \in \{1, \ldots, n\}$, $X_i \in \mathcal{G}(v_i)$. Montrer que $\sum_{i=1}^n X_i \in \mathcal{G}\left(\sum_{i=1}^n v_i\right)$.
4. **(inégalité de Chernoff)** Montrer que pour tout $t \geq 0$,
$$\mathbb{P}(Z \geq t) \leq \exp(-\psi_Z^*(t)) , \quad \text{où} \quad \psi_Z^*(t) := \sup_{\lambda \geq 0} (\lambda t - \psi_Z(\lambda))$$
La fonction $t \mapsto \psi_Z^*(t)$ est la *transformée de Legendre* de ψ_Z.

5. Montrer que si $X \in \mathcal{G}(v)$, alors pour tout $t > 0$,

$$\mathbb{P}(X > t) \vee \mathbb{P}(-X > t) \leq \mathrm{e}^{-t^2/(2v)}$$

où $a \vee b = \max(a, b)$. *On pourra commencer par prouver que* $\mathbb{P}(X > t) \leq \mathrm{e}^{-t^2/(2v)}$ *; puis observer que l'on a le même majorant pour* $\mathbb{P}(-X > t)$.

Exercice 3 (Lemme d'Hoeffding (⋆⋆)). Soit X une variable aléatoire de loi μ à support $[a, b]$ i.e. $\mu([a, b]) = 1$. On note $m := \mathbb{E}[X] = \int x\mu(\mathrm{d}x)$ son espérance. L'objectif des questions 2 à 5 est de montrer que pour tout $\lambda \in \mathbb{R}$,

$$\psi_X(\lambda) \leqslant \lambda m + \frac{\lambda^2}{8}(b-a)^2, \qquad \text{où} \quad \psi_X(\lambda) := \log \int \exp(\lambda x)\mu(\mathrm{d}x). \tag{1}$$

1. Soit $Z_1, \ldots, Z_n$, n variables aléatoires indépendantes. Supposons que pour tout $1 \leq k \leq n$, il existe $a_k < b_k$ tels que $\mathbb{P}(Z_k \in [a_k, b_k]) = 1$. Posons $S_n := \sum_{k=1}^n Z_k$. En utilisant les questions 3 et 5 de l'exercice 2, et la relation (1), montrer que pour tout $t \geq 0$

$$\mathbb{P}\left(S_n - \mathbb{E}\left[S_n\right] \geq t\right) \leq \exp\left(-\frac{2t^2}{D_n}\right), \qquad \mathbb{P}\left(S_n - \mathbb{E}\left[S_n\right] \leq -t\right) \leq \exp\left(-\frac{2t^2}{D_n}\right)$$

où $D_n := \sum_{k=1}^n (b_k - a_k)^2$.

Nous allons maintenant établir (1).

2. Pour tout $\lambda \in \mathbb{R}$ nous définissons la *loi de probabilité* μ_λ par

$$\mu_\lambda(\mathrm{d}x) := \frac{\mathrm{e}^{\lambda x}\mu(\mathrm{d}x)}{\int \mathrm{e}^{\lambda u}\mu(\mathrm{d}u)} = \frac{\mathrm{e}^{\lambda x}\mu(\mathrm{d}x)}{\mathbb{E}\left[\exp(\lambda X)\right]}\,.$$

Notons que $\mu_0 = \mu$. Montrer que pour tout $\lambda \in \mathbb{R}$,

$$\psi'_X(\lambda) = \int x\mu_\lambda(\mathrm{d}x), \qquad \psi''_X(\lambda) = \int (x - \psi'_X(\lambda))^2 \mu_\lambda(\mathrm{d}x).$$

3. En déduire que pour tout $\lambda \in \mathbb{R}$,

$$\psi_X(\lambda) \leq \lambda\mathbb{E}[X] + \frac{\lambda^2}{2}\sup_{u\in\mathbb{R}} \psi''_X(u).$$

4. Il ne reste qu'à montrer que $\sup_{\lambda\in\mathbb{R}} \psi''_X(\lambda) \leq (b-a)^2/4$. Soit $\lambda \in \mathbb{R}$ et $Y \sim \mu_\lambda$. En remarquant que

$$\mathbb{E}[Y] = \mathrm{argmin}_{c\in\mathbb{R}}\mathbb{E}\left[(Y-c)^2\right], \qquad \mathrm{Var}(Y) = \min_{c\in\mathbb{R}}\mathbb{E}\left[(Y-c)^2\right],$$

montrer que

$$\mathrm{Var}(Y) \leq \mathbb{E}\left[\left(Y - \frac{a+b}{2}\right)^2\right] \leq \frac{(b-a)^2}{4}.$$

En déduire que $\sup_{u\in\mathbb{R}} \psi''_X(u) \leq (b-a)^2/4$.

5. Conclure.

Exercice 4 (Inégalité de Pisier (⋆⋆)). 1. Soient m variables aléatoires réelles $Z_1, \dots, Z_m$ définies sur $(\Omega, \mathcal{A}, \mathbb{P})$ vérifiant la propriété : il existe $\sigma > 0$ tel que pour tout $\lambda \geq 0$,

$$\mathbb{E}[\mathrm{e}^{\lambda Z_i}] \leq \mathrm{e}^{\lambda^2\sigma^2/2} , \quad i \in \{1, \cdots, m\} .$$

On remarquera que lorsque $Z \sim \mathcal{N}(0, \sigma^2)$, on a $\mathbb{E}[\mathrm{e}^{\lambda Z}] = \mathrm{e}^{\lambda^2\sigma^2/2}$ pour tout $\lambda \in \mathbb{R}$.

(a) Montrer que pour tout $\lambda > 0$,

$$\mathrm{e}^{\lambda \mathbb{E}[\max_{1\leq i\leq m} Z_i]} \leq \mathbb{E}[\mathrm{e}^{\lambda \max_{1\leq i\leq m} Z_i}] \leq m\, \mathrm{e}^{\lambda^2\sigma^2/2} .$$

(b) En déduire que

$$\mathbb{E}[\max_{1\leq i\leq m} Z_i] \leq \sigma\sqrt{2\log(m)} .$$

On suppose de plus que pour tout $\lambda > 0$,

$$\mathbb{E}[\mathrm{e}^{-\lambda Z_i}] \leq \mathrm{e}^{\lambda^2\sigma^2/2} , \quad i \in \{1, \cdots, m\}.$$

(c) Montrer que

$$\mathbb{E}\left[\max_{1\leq i\leq m} |Z_i|\right] \leq \sigma\sqrt{2\log(2m)} .$$

Soit un ensemble d'apprentissage $D_n := \{(X_i, Y_i)\}_{i=1}^n$, contenant n observations indépendantes de même loi que (X, Y). On définit le risque et le risque empirique d'un classifieur g par

$$R(g) := \mathbb{P}(g(X) \neq Y), \qquad R_n(g) := \frac{1}{n}\sum_{i=1}^n \mathbb{1}_{\{g(X_i)\neq Y_i\}} .$$

2. (a) Montrer que pour tout classifieur g et pour tout $\lambda \in \mathbb{R}$,

$$\mathbb{E}[\mathrm{e}^{\lambda\{R_n(g)-R(g)\}}] \leq \exp\left(\frac{\lambda^2}{8n}\right) .$$

(b) Soit $\mathcal{C} := \{g_1, \dots, g_M\}$, M classifieurs. On note $\hat{g}^*_{n,\mathcal{C}}$ le classifieur de $\mathcal{C}$ qui minimise le risque empirique et $g^\star_{\mathcal{C}}$ le classifieur de $\mathcal{C}$ qui minimise le risque. Déduire de la question précédente une borne pour le risque moyen $\mathbb{E}[R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})]$.

On considère un problème de classification binaire. On suppose que l'ensemble des attributs X est un ensemble de cardinal fini K. On note $\mathcal{C}$ l'ensemble de toutes les règles de classification.

3. Montrer que la règle de classification minimisant le risque empirique est donnée, pour tout $x \in \mathsf{X}$ par

$$\hat{g}^*_n(x) := \begin{cases} 1 & \text{si } \sum_{i=1}^n \frac{Y_i+1}{2}\mathbb{1}_{\{X_i=x\}} \geq \sum_{i=1}^n \frac{1-Y_i}{2}\mathbb{1}_{\{X_i=x\}} , \\ 0 & \text{sinon} \end{cases}$$

4. (a) Montrer que $\inf_{g\in\mathcal{C}} R(g) = R^\star$ où $R^\star$ est le risque du classifieur bayésien. Montrer que

$$\forall \varepsilon > 0, \qquad \mathbb{P}\left(\sup_{g\in\mathcal{C}} |R_n(g) - R(g)| > \varepsilon\right) \leq 2^{K+1}\exp(-2n\varepsilon^2) .$$

(b) En déduire que pour tout $x > 0$,

$$\mathbb{E}[R(\hat{g}_n^*)] - R^* \leq x + 2^{K-1} e^{-2nx^2} \sqrt{2\pi/n}.$$

Le majorant est de la forme $x + \exp(A - 2nx^2)$ pour tout x ; et en prenant x tel que $2nx^2 = A - 0.5\ln(A/(2n))$, nous obtenons un majorant en $2\sqrt{A/(2n)}$. Soit un majorant en $O(\sqrt{K/n})$. En particulier, il décroît comme $1/\sqrt{n}$; et croît comme la racine carrée du logarithme du cardinal de $\mathcal{C}$.

Exercice 5 ($\star\star\star$). Considérons un ensemble de n points de $\mathbb{R}^d$ notés $\mathsf{P} = \{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$. Pour tout $i \in \{1, \ldots, n\}$, $\mathbf{x}_i = (x_i^{(1)}, \ldots, x_i^{(d)})$. Notons $\mathcal{R}$ l'ensemble des hyper-rectangles de $\mathbb{R}^d$.

$$\mathcal{R} = \left\{ \left[a^{(1)}, b^{(1)}\right] \times \left[a^{(2)}, b^{(2)}\right] \times \cdots \times \left[a^{(d)}, b^{(d)}\right] \,:\, a^{(i)} \leq b^{(i)}, i = 1, \ldots, d \right\} .$$

Pour un ensemble de point P, on note $|\mathsf{P}|$ le nombre de points qui le composent qu'ils soient distincts ou non et pour $\mathsf{R} \in \mathcal{R}$, on note $\mathsf{P} \cap \mathsf{R}$ l'ensemble de points composés des points de P qui appartiennent à R.

Soient $\mathsf{S} = (X_1, \ldots, X_k)$, k variables aléatoires indépendantes et de même loi uniforme sur P et soit $\varepsilon > 0$.

1. Montrer que, pour tout $\mathsf{R} \in \mathcal{R}$ [1],

$$\mathbb{P}\left(\left| \frac{|\mathsf{R} \cap \mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R} \cap \mathsf{P}|}{|\mathsf{P}|} \right| \geq \varepsilon \right) \leq 2\exp(-2\varepsilon^2 k) .$$

2. Soit $\gamma \in]0, 1[$. Montrer que si $k \geq (1/2\varepsilon^2)\ln(2/\gamma)$, alors avec probabilité supérieure à $1 - \gamma$,

$$\left| \frac{|\mathsf{R} \cap \mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R} \cap \mathsf{P}|}{|\mathsf{P}|} \right| \leq \varepsilon .$$

Pour $j \in \{1, \ldots, d\}$, notons par $x_{1:n}^{(j)} \leq x_{2:n}^{(j)} \leq \cdots \leq x_{n:n}^{(j)}$ l'échantillon ordonné de la j-ème coordonnée $(x_1^{(j)}, \ldots, x_n^{(j)})$. On note

$$\mathcal{R}_{\mathsf{S}} = \left\{ \left[x_{i_1:n}^{(1)}, x_{j_1:n}^{(1)}\right] \times \cdots \times \left[x_{i_d:n}^{(d)}, x_{j_d:n}^{(d)}\right] \,:\, 1 \leq i_\ell \leq j_\ell \leq n, \ell = 1, \ldots, d \right\} .$$

3. Montrer que

$$\sup_{\mathsf{R} \in \mathcal{R}} \left| \frac{|\mathsf{R} \cap \mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R} \cap \mathsf{P}|}{|\mathsf{P}|} \right| = \sup_{\mathsf{R} \in \mathcal{R}_{\mathsf{S}}} \left| \frac{|\mathsf{R} \cap \mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R} \cap \mathsf{P}|}{|\mathsf{P}|} \right| .$$

4. Soit $\delta \in]0, 1[$. Montrer que si $|S| = k \geqslant (d/\varepsilon^2)\log(n/\delta^{1/2d})$, alors avec une probabilité supérieure à $1 - \delta$, pour tout $\mathsf{R} \in \mathcal{R}$,

$$\left| \frac{|\mathsf{R} \cap \mathsf{S}|}{|\mathsf{S}|} - \frac{|\mathsf{R} \cap \mathsf{P}|}{|\mathsf{P}|} \right| \leq \varepsilon .$$

1. Par exemple, P peuvent représenter les utilisateurs d'une boutique, d est le nombre d'attributs pour chaque consommateur, et R est le profil désiré, les consommateurs qui ont fait entre 10 et 1000 achats, qui effectuent en moyenne entre 2.5 et 10 achats par semaine, qui dépensent en moyenne entre 10 et 50 euros par achat.

Exercice 6 (⋆⋆⋆). Nous considérons un problème de classification binaire. Nous supposons que le cardinal de l'ensemble des attributs, $|\mathsf{X}|$, est infini. Nous munissons X d'une σ-algèbre $\mathcal{X}$ telle que les singletons de $\{x\}$ soient mesurables. Nous notons $D_n := \{(X_i, Y_i)\}_{i=1}^n$ l'ensemble des variables aléatoires d'apprentissage, que nous supposons, sous $\mathbb{P}_n$, indépendantes et identiquement distribuées de même loi que (X, Y) sous $\mathbb{P}$. Nous allons démontrer pour toute règle de classification $x \mapsto g_n(x; D_n)$,

$$\sup_{\mathbb{P}} \{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X; D_n)|D_n)] - R^*_{\mathbb{P}}\} \geq 1/2 \,, \tag{2}$$

où le sup est pris sur l'ensemble des mesures de probabilité sur $\mathcal{X} \otimes \mathcal{P}(\{0,1\})$ et

$$R^*_{\mathbb{P}} := \inf_{g:\mathsf{X}\to\{0,1\}} \mathbb{P}(g(X) \neq Y) \,.$$

On dit qu'une règle de classification g_n est uniformément universellement consistante lorsque le membre de gauche dans l'équation (2) tend ers 0 avec n. On va donc montre qu'aucune règle de classification ne peut être uniformément universellement consistante lorsque X est infini. Ce résultat important est souvent appelé le "no free lunch theorem".

Soit $n, K \in \mathbb{N}$, $g_n : \mathsf{X} \mapsto \{0,1\}$ un classifieur. L'espace X étant infini, il contient au moins K points distincts $a_1, \ldots, a_K$. Dans la suite ces K points sont fixés. On considère l'ensemble des lois $(\mathbb{P}_{\mathbf{q}})_{\mathbf{q}\in\{0,1\}^K}$ sur $\mathcal{X} \otimes \mathcal{P}(\{0,1\})$, où, pour tout $\mathbf{q} := (q_1, \ldots, q_K), \mathbf{y} := (y_1, \ldots, y_K) \in \{0,1\}^K$,

$$\mathbb{P}_{\mathbf{q}}(X = a_j, Y = y_j) = K^{-1}\delta_{q_j, y_j} \quad \text{pour tout } j \in \{1, \ldots, K\}.$$

1. Montrer que pour tout $\mathbf{q} \in \{0,1\}^K$, $\mathbb{P}_{\mathbf{q}}(X = a_j) = 1/K$ pour tout $j \in \{1, \ldots, K\}$. En déduire que, pour tout $\mathbf{q} \in \{0,1\}^K$, sous $\mathbb{P}_{n,\mathbf{q}}$, les variables $X_1, \ldots, X_n$ sont distribuées suivant une loi uniforme sur $\{a_1, \ldots, a_K\}$.
2. Calculer $\mathbb{P}_{\mathbf{q}}(g(X) \neq Y)$ pour un classifieur g.
3. Montrer que $R^*_{\mathbb{P}_{\mathbf{q}}} := \inf_{g:\mathsf{X}\to\{0,1\}} \mathbb{P}_{\mathbf{q}}(g(X) \neq Y) = 0$ et que l'inf est atteint par toute fonction $g_{\mathbf{q}} : \mathsf{X} \to \{0,1\}$, vérifiant, pour tout $x \in \{a_1, \ldots, a_K\}$

$$g_{\mathbf{q}}(x) = \sum_{i=1}^K q_i \mathbb{1}_{\{a_i\}}(x) \,.$$

4. Montrer que

$$\begin{aligned}
\sup_{\mathbb{P}} \{\mathbb{E}_n[\mathbb{P}(Y \neq g_n(X; D_n)|D_n)] - R^*_{\mathbb{P}}\} &\geqslant \sup_{\mathbf{q}\in\{0,1\}^K} \mathbb{E}_{n,\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y \neq g_n(X; D_n)|D_n)] \\
&\geqslant \frac{1}{2^K} \sum_{\mathbf{q}\in\{0,1\}^K} \mathbb{E}_{n,\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y \neq g_n(X; D_n)|D_n)] \\
&\geqslant \frac{1}{2^K} \sum_{\mathbf{q}\in\{0,1\}^K} \mathbb{E}_{n,\mathbf{q}}[\mathbb{E}_{\mathbf{q}}[\mathbb{P}_{\mathbf{q}}(Y \neq g_n(X; D_n)|X, D_n)\mathbb{1}_{\{X\notin\{X_1,\ldots,X_n\}\}}] \,.
\end{aligned}$$

5. Montrer que, pour tout $x \notin \{X_1, \ldots, X_n\}$, il existe 2^{K-1} valeurs de $\mathbf{q} \in \{0,1\}^K$ telles que $\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(x;D_n)\}}|D_n] = 0$ et 2^{K-1} valeurs de $\mathbf{q} \in \{0,1\}^K$ telles que $\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{Y\neq g_n(x;D_n)\}}|D_n] = 1$.

6. Montrer que, pour tout $\mathbf{q} \in \{0,1\}^K$ et pour tout $x \in \{a_1, \ldots, a_K\}$,

$$\mathbb{E}_{\mathbf{q}}[\mathbb{1}_{\{X_1 \neq x, X_2 \neq x, \ldots, X_n \neq x\}}] = (1 - 1/K)^n \ .$$

7. Montrer (2).

Exercice 7 ($\star\star\star$). On considère le problème de classification binaire. On dispose d'un ensemble d'apprentissage $\{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ de variables aléatoires i.i.d. définies sur un espace de probabilité $(\Omega, \mathcal{F}, \mathbb{P})$. La loi de l'attribut $\mathbf{X} \in \mathbb{R}^d$, conditionnellement au label $Y = i$, $i \in \{0,1\}$ est absolument continue par rapport à la mesure de Lebesgue Leb sur $\mathbb{R}^d$, de densité notée f_i. On note $p = \mathbb{P}(Y = 1)$. On considère la famille $\mathcal{C}$ des classifieurs par hyperplan, définie par

$$\mathcal{C} = \{g_{\mathbf{a},b}(\mathbf{x}) = \mathbb{1}_{\{\mathbf{a}^\top \mathbf{x} + b \geq 0\}} \ , (\mathbf{a}, b) \in \mathbb{R}^d \times \mathbb{R}\} \ . \tag{3}$$

Pour un classifieur $g : \mathbb{R}^d \to \{0,1\}$, nous notons le risque associé à la perte 0-1 par

$$R(g) = \mathbb{P}(g(\mathbf{X}) \neq Y) \ .$$

Le risque empirique est défini par

$$\widehat{\mathrm{R}}_n(g) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{g(\mathbf{X}_i) \neq Y_i\}} \ .$$

Nous notons

— $L^\star = \inf_{g \in \mathcal{C}} R(g)$ le minimum du risque 0-1 sur la classe $\mathcal{C}$.

— $g^\star \in \mathcal{C}$ un classifieur atteignant le minimum (nous admettrons que le minimum est atteint pour au moins un classifieur), $L^\star = L(g^\star)$.

— $F_{i,\mathbf{a}}(z) = \mathbb{P}\left(\mathbf{a}^\top \mathbf{X} \leq z \,\middle|\, Y = i\right)$, $i \in \{0,1\}$.

1. Démontrer que, pour tout $(\mathbf{a}, b) \in \mathbb{R}^{d+1}$,

$$R(g_{\mathbf{a},b}) = pF_{1,\mathbf{a}}(-b) + (1-p)\{1 - F_{0,\mathbf{a}}(-b)\} \ .$$

2. Démontrer que, pour tout $(\mathbf{a}, b) \in \mathbb{R}^{d+1}$,

$$R(g_{-\mathbf{a},-b}) = p\{1 - F_{1,\mathbf{a}}(-b)\} + (1-p)F_{0,\mathbf{a}}(-b) \ .$$

3. En déduire que, pour tout $(\mathbf{a}, b) \in \mathbb{R}^{d+1}$,

$$\min(R(g_{\mathbf{a},b}), R(g_{-\mathbf{a},-b})) = \frac{1}{2} - |pF_{1,\mathbf{a}}(-b) - (1-p)F_{0,\mathbf{a}}(-b) + (1/2 - p)| \ .$$

[indication : on pourra utiliser $\min(u, v) = (1/2)(u + v - |u - v|)$.]

4. Montrer que si $p \neq 1/2$, $R^\star \leq \min_{(\mathbf{a},b) \in \mathbb{R}^{d+1}} R(g_{\mathbf{a},b}) < 1/2$.

5. Montrer que si $p = 1/2$, $\min_{(\mathbf{a},b) \in \mathbb{R}^{d+1}} R(g_{\mathbf{a},b}) < 1/2$ si et seulement si

$$\mathrm{Leb}(\left\{\mathbf{x} \in \mathbb{R}^d \ : \ f_1(\mathbf{x}) \neq f_0(\mathbf{x})\right\}) > 0 \ .$$

Nous supposons dans la suite que $d < n$. Pour tout ensemble $(\mathbf{z}_1, \mathbf{z}_2, \ldots, \mathbf{z}_d) \in \mathbb{R}^n$ de d points. Nous notons $\Pi_{\mathbf{z}_{1d}}$ le projecteur (affine) orthogonal sur le sous-espace affine engendré par les points $(\mathbf{z}_1, \ldots, \mathbf{z}_d)$: pour tout $\mathbf{z} \in \mathbb{R}^n$,

— $\Pi_{\mathbf{z}_1,\ldots,\mathbf{z}_d}(\mathbf{z})$ est un élément de l'espace affine engendré par les points $(\mathbf{z}_1,\ldots,\mathbf{z}_d)$

— $\mathbf{z}-\Pi_{\mathbf{z}_1,\ldots,\mathbf{z}_d}(\mathbf{z})$ est orthogonal au sous-espace linéaire $(\mathbf{z}_2-\mathbf{z}_1,\ldots,\mathbf{z}_d-\mathbf{z}_1)$.

Pour tout d-uplets $1\le i_1<\cdots<i_d\le n$ et $z\in\{-1,1\}$, nous considérons le classifieur

$$\hat{g}_{n,i_{1d},z}(\mathbf{x})=\mathbb{1}_{\{z(\{\mathbf{x}-\Pi_{i_{1d}}(\mathbf{x})\}^\top\Pi_{i_{1d}}(\mathbf{0}_{n\times 1}))\ge 0\}} \tag{4}$$

où nous avons posé $i_{1d}=(i_1,\ldots,i_d)$ et

$$\Pi_{i_{1d}}=\Pi_{\mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d}}$$

est le projecteur orthogonal sur le sous-espace affine engendré par les points $(\mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d})$. On pourra vérifier que $\hat{g}_{n,i_{1d},1}$ est le classifieur de $\mathcal{C}$ dont l'hyperplan $\mathbf{a}^T\mathbf{x}+b$ est l'unique hyperplan affine passant par les points $(\mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d})$. Nous notons $\mathcal{C}_n$ l'ensemble de ces classifieurs et

$$\hat{g}_n^\star=\min_{g\in\mathcal{C}_n}\widehat{\mathrm{R}}_n(g)\ .$$

Il est possible de montrer que, pour tout $g\in\mathcal{C}$, où $\mathcal{C}$ est défini dans (3), nous avons

$$\widehat{\mathrm{R}}_n(\hat{g}_n^\star)\le\widehat{\mathrm{R}}_n(g)+\frac{d}{n}\ .$$

Nous admettrons ce résultat pour la suite de l'exercice.

6. Montrer que le nombre de classifieurs distincts de l'ensemble $\mathcal{C}_n$ est au plus égal à $2\binom{n}{d}$.
7. Montrer que

$$R(\hat{g}_n^\star)-R^\star\le\max_{g\in\mathcal{C}_n}\{R(g)-\widehat{\mathrm{R}}_n(g)\}+\widehat{\mathrm{R}}_n(g^\star)-R(g^\star)+\frac{d}{n}\ .$$

8. Montrer que, pour tout $\varepsilon>0$,

$$\mathbb{P}\left(R(\hat{g}_n^\star)-R^\star\ge\varepsilon\right)\le\sum_{z\in\{-1,+1\}}\sum_{1\le i_1<\cdots<i_d\le n}\mathbb{P}\left(R(\hat{g}_{n,i_{1d},z})-\widehat{\mathrm{R}}_n(\hat{g}_{n,i_{1d},z})\ge\varepsilon/2\right)$$
$$+\mathbb{P}\left(\widehat{\mathrm{R}}_n(g^\star)-R(g^\star)+d/n\ge\varepsilon/2\right)\ .$$

9. Montrer que, pour tout $\varepsilon\in]0,1[$ et n tel que $2d/n\le\varepsilon\le 1$, nous avons

$$\mathbb{P}\left(\widehat{\mathrm{R}}_n(g^\star)-R(g^\star)\ge\varepsilon/2-d/n\right)\le\mathrm{e}^{2d\varepsilon}\mathrm{e}^{-n\varepsilon^2/2}\ .$$

10. Montrer que, pour tout $\varepsilon\in]0,1[$, n tel que $2d/n\le\varepsilon\le 1$, $1\le i_1<\cdots<i_d\le n$ et $z\in\{-1,1\}$, nous avons

$$\mathbb{P}\left(R(\hat{g}_{n,i_{1d},z})-\widehat{\mathrm{R}}_n(\hat{g}_{n,i_{1d},z})\ge\varepsilon/2\,\middle|\,\mathbf{X}_{i_1},\ldots,\mathbf{X}_{i_d}\right)\le\mathrm{e}^{2d\varepsilon}\mathrm{e}^{-n\varepsilon^2/2}\ .$$

11. Montrer que, pour tout $\delta\in]0,1[$ et $\varepsilon\in]0,1[$, il existe $n_0(\varepsilon,\delta,d)$ tel que, pour tout $n\ge n_0(\varepsilon,\delta,d)$, on a, avec une probabilité supérieure à $1-\delta$,

$$R(\hat{g}_n^\star)-R^\star\le\varepsilon\ .$$

12. Déterminer une borne de l'excès de risque moyen du classifieur

$$\mathbb{E}[R(\hat{g}_n^\star)]-R^\star\ .$$