4 Les compléments

Les contenus de cette partie ne sont pas exigibles. Ils donnent la démonstration du théorème *no free lunch*, les bornes PAC du polycopié d'origine dans le cas réalisable et dans le cas agnostique, leur application à la classification par histogramme, la démonstration de l'inégalité de Pisier, l'inégalité de McDiarmid, qui étend celle de Hoeffding à des fonctions plus générales que la moyenne, la démonstration de l'extension aux classifieurs affines, et des références pour aller plus loin.

4.1 Démonstration du théorème *no free lunch*

On démontre le théorème 1.1 ; c'est l'argument de l'exercice 6 (PC9), réécrit pour des labels dans $\{-1,1\}$.

Démonstration

Fixons n, la règle $\widehat{g}_n$ et $\varepsilon \in]0,1/2[$ (pour $\varepsilon \geq 1/2$ il n'y a rien à démontrer). Soit K un entier tel que $(1-1/K)^n \geq 1-2\varepsilon$, qui existe puisque $(1-1/K)^n \to 1$ quand $K \to \infty$, et soient $a_1, \dots, a_K$ des points distincts de X, qui existent puisque X est infini. Pour $\mathbf{b} = (b_1, \dots, b_K) \in \{-1,1\}^K$, on note $\mathbb{P}_{\mathbf{b}}$ la loi du couple $(\mathbf{X}, Y)$ où $\mathbf{X}$ est uniforme sur $\{a_1, \dots, a_K\}$ et $Y = b_j$ lorsque $\mathbf{X} = a_j$.
Sous $\mathbb{P}_{\mathbf{b}}$, la règle qui vaut b_j en a_j et 1 ailleurs, mesurable puisque les singletons le sont, a un risque nul ; donc $R^\star = 0$ et $\mathcal{E}(\widehat{g}_n) = R(\widehat{g}_n)$. Notons $\mathbb{E}_{\mathbf{b}}$ l'espérance lorsque $\mathcal{D}_n$ est formé de n couples indépendants de loi $\mathbb{P}_{\mathbf{b}}$ et $(\mathbf{X}, Y)$ est un couple indépendant de même loi. D'après la proposition 2.5, $\mathbb{E}_{\mathbf{b}}[R(\widehat{g}_n)] = \mathbb{P}_{\mathbf{b}}(\widehat{g}_n(\mathbf{X}; \mathcal{D}_n) \neq Y)$.
On moyenne sur $\mathbf{b}$. Soit $\mathbf{B} = (B_1, \dots, B_K)$ uniforme sur $\{-1,1\}^K$, c'est-à-dire formé de variables indépendantes uniformes sur $\{-1,1\}$, et $J, J_1, \dots, J_n$ des variables indépendantes de $\mathbf{B}$, indépendantes entre elles et uniformes sur $\{1, \dots, K\}$. On pose $\mathbf{X} = a_J$, $Y = B_J$, $\mathbf{X}_i = a_{J_i}$ et $Y_i = B_{J_i}$. Conditionnellement à $\mathbf{B} = \mathbf{b}$, les couples $(\mathbf{X}, Y), (\mathbf{X}_1, Y_1), \dots, (\mathbf{X}_n, Y_n)$ sont indépendants de loi $\mathbb{P}_{\mathbf{b}}$, de sorte que

$$\frac{1}{2^K} \sum_{\mathbf{b} \in \{-1,1\}^K} \mathbb{E}_{\mathbf{b}}\left[R(\widehat{g}_n)\right] = \mathbb{P}\left(\widehat{g}_n(\mathbf{X}; \mathcal{D}_n) \neq Y\right) \geq \mathbb{P}\left(\widehat{g}_n(\mathbf{X}; \mathcal{D}_n) \neq Y,\ J \notin \{J_1, \dots, J_n\}\right) .$$

Décomposons selon les valeurs $j, j_1, \dots, j_n$ de $J, J_1, \dots, J_n$, avec $j \notin \{j_1, \dots, j_n\}$. Sur l'événement correspondant, $\widehat{g}_n(\mathbf{X}; \mathcal{D}_n) = \widehat{g}_n(a_j; (a_{j_1}, B_{j_1}), \dots, (a_{j_n}, B_{j_n}))$ est une fonction de $(B_{j_1}, \dots, B_{j_n})$, tandis que $Y = B_j$ est indépendante de ce vecteur, puisque j n'est aucun des j_i, et uniforme sur $\{-1,1\}$. La probabilité que deux variables indépendantes, dont l'une est uniforme sur $\{-1,1\}$, diffèrent vaut $1/2$; par indépendance de $\mathbf{B}$ et de $(J, J_1, \dots, J_n)$,

$$\mathbb{P}\left(\widehat{g}_n(\mathbf{X}; \mathcal{D}_n) \neq Y,\ J \notin \{J_1, \dots, J_n\}\right) = \frac{1}{2}\,\mathbb{P}\left(J \notin \{J_1, \dots, J_n\}\right) = \frac{1}{2}\left(1 - \frac{1}{K}\right)^n \geq \frac{1}{2} - \varepsilon .$$

Une moyenne étant majorée par le maximum, il existe $\mathbf{b}$ tel que $\mathbb{E}_{\mathbf{b}}[R(\widehat{g}_n)] \geq 1/2 - \varepsilon$: la loi $\mathbb{P}_{\mathbf{b}}$ convient. □

Le polycopié d'origine mentionne une forme plus faible du théorème, où la loi est fixée une fois pour toutes au lieu de dépendre de n : pour toute suite de règles et toute suite (a_n) tendant vers zéro, il existe une loi telle que $R^\star = 0$ et $\mathbb{E}[R(\widehat{g}_n)] \geq a_n$ pour tout n. La convergence du risque moyen peut donc être arbitrairement lente. On en trouvera la démonstration au chapitre 7 de *A Probabilistic Theory of Pattern Recognition* de L. Devroye, L. Györfi et G. Lugosi.

4.2 Bornes PAC

Le polycopié d'origine présente les résultats de la Section 1.3 dans le cadre introduit par L. Valiant en 1984, celui des règles *probablement approximativement correctes*.

Définition 4.1: Règle PAC

Soit $\varepsilon > 0$, $\delta \in]0,1[$ et $\mathcal{C}$ une famille de règles de classification, munie du risque $R(g) = \mathbb{P}(g(\mathbf{X}) \neq Y)$. Une règle $\widehat{g}_n \in \mathcal{C}$ construite sur $\mathcal{D}_n$ est dite *probablement approximativement correcte avec une précision* ε *et une confiance* $1-\delta$, ou (ε,δ)-PAC, si

$$\mathbb{P}\left(R(\widehat{g}_n) - \inf_{g\in\mathcal{C}} R(g) \geq \varepsilon\right) \leq \delta \; .$$

On demande que la précision soit atteinte, non pas pour tout ensemble d'apprentissage, mais avec une probabilité au moins $1-\delta$: exiger $\delta = 0$ serait excessif, car un ensemble d'apprentissage peu représentatif, de probabilité faible mais non nulle, peut toujours se produire. La garantie doit en revanche être satisfaite pour toutes les lois du couple $(\mathbf{X}, Y)$.

Le cas réalisable

On suppose d'abord que la classe contient une règle de risque nul, ce qui entraîne que le classifieur bayésien est dans la classe et que $R^\star = 0$.

Théorème 4.1: Borne PAC élémentaire

On suppose que $|\mathcal{C}| < \infty$ et que $\min_{g\in\mathcal{C}} R(g) = 0$. Si $\hat{g}^*_{n,\mathcal{C}}$ est un minimiseur du risque empirique sur $\mathcal{C}$, alors, pour tout $n \in \mathbb{N}^*$ et tout $\varepsilon > 0$,

$$\mathbb{P}\left(R(\hat{g}^*_{n,\mathcal{C}}) \geq \varepsilon\right) \leq |\mathcal{C}|\, \mathrm{e}^{-n\varepsilon} \; .$$

Démonstration

Soit $g_0 \in \mathcal{C}$ telle que $R(g_0) = 0$. Comme $\widehat{\mathrm{R}}_n(g_0) \geq 0$ et $\mathbb{E}[\widehat{\mathrm{R}}_n(g_0)] = R(g_0) = 0$, on a $\widehat{\mathrm{R}}_n(g_0) = 0$ presque sûrement, et donc $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) = 0$ presque sûrement. Ainsi, presque sûrement, $R(\hat{g}^*_{n,\mathcal{C}}) \geq \varepsilon$ ne se produit que s'il existe $g \in \mathcal{C}$ telle que $R(g) \geq \varepsilon$ et $\widehat{\mathrm{R}}_n(g) = 0$. Par la borne de l'union,

$$\mathbb{P}\left(R(\hat{g}^*_{n,\mathcal{C}}) \geq \varepsilon\right) \leq \sum_{g\in\mathcal{C},\ R(g)\geq\varepsilon} \mathbb{P}\left(\widehat{\mathrm{R}}_n(g) = 0\right) \; .$$

Pour g fixée, $n\,\widehat{\mathrm{R}}_n(g)$ suit la loi binomiale de paramètres n et $R(g)$, donc $\mathbb{P}(\widehat{\mathrm{R}}_n(g) = 0) = (1-R(g))^n \leq (1-\varepsilon)^n \leq \mathrm{e}^{-n\varepsilon}$ lorsque $R(g) \geq \varepsilon$, et il y a au plus $|\mathcal{C}|$ termes. □

En résolvant $|\mathcal{C}|\,\mathrm{e}^{-n\varepsilon} \leq \delta$, on voit que, sous les hypothèses du théorème, le minimiseur du risque empirique est (ε,δ)-PAC dès que $n \geq (\log|\mathcal{C}| + \log(1/\delta))/\varepsilon$. La borne fournit aussi une borne du risque moyen, grâce au lemme élémentaire suivant.

Lemme 4.1: Intégration d'une queue exponentielle

Soit Z une variable aléatoire positive et $C \geq 1$, $\alpha > 0$ des constantes telles que $\mathbb{P}(Z \geq \varepsilon) \leq C\mathrm{e}^{-\alpha\varepsilon}$ pour tout $\varepsilon > 0$. Alors $\mathbb{E}[Z] \leq (1+\log C)/\alpha$. Si au contraire $\mathbb{P}(Z \geq \varepsilon) \leq C\mathrm{e}^{-\alpha\varepsilon^2}$ pour tout $\varepsilon > 0$, alors $\mathbb{E}[Z] \leq \sqrt{(1+\log C)/\alpha}$.

Démonstration

Comme $Z \geq 0$, $\mathbb{E}[Z] = \int_0^\infty \mathbb{P}(Z > t)\,\mathrm{d}t$. Pour tout $u \geq 0$, en majorant $\mathbb{P}(Z > t)$ par 1 sur $[0, u]$ et par $C\mathrm{e}^{-\alpha t}$ au-delà,

$$\mathbb{E}[Z] \leq u + C \int_u^\infty \mathrm{e}^{-\alpha t}\,\mathrm{d}t = u + \frac{C\mathrm{e}^{-\alpha u}}{\alpha}\ ,$$

et le choix $u = (\log C)/\alpha$, positif puisque $C \geq 1$, donne la première majoration. Pour la seconde, $\mathbb{P}(Z^2 \geq \varepsilon) \leq C\mathrm{e}^{-\alpha\varepsilon}$, d'où $\mathbb{E}[Z^2] \leq (1 + \log C)/\alpha$ par la première, et l'on conclut par l'inégalité de Jensen, $\mathbb{E}[Z] \leq \sqrt{\mathbb{E}[Z^2]}$. □

Appliqué à $Z = R(\hat{g}^*_{n,\mathcal{C}})$ avec $C = |\mathcal{C}|$ et $\alpha = n$, le lemme donne, sous les hypothèses du théorème 4.1, $\mathbb{E}[R(\hat{g}^*_{n,\mathcal{C}})] \leq (1 + \log|\mathcal{C}|)/n$. La vitesse est en $1/n$, et non en $1/\sqrt{n}$ comme dans le cas général.

Le cas agnostique

Lorsqu'on ne suppose rien sur la loi du couple, et en particulier pas que le classifieur bayésien est dans la classe, on parle de bornes PAC *agnostiques*. Le point de vue diffère de celui de la modélisation statistique, qui part d'une famille de lois supposée contenir la loi des observations.

Les bornes du théorème 1.5 en donnent plusieurs. D'abord, en appliquant la première inégalité aux variables $R(g) - \widehat{\mathrm{R}}_n(g)$, qui relève de la même déviation unilatérale de l'inégalité de Hoeffding, on obtient, pour tout $\delta \in\,]0, 1[$,

$$\mathbb{P}\left(\forall g \in \mathcal{C},\quad R(g) \leq \widehat{\mathrm{R}}_n(g) + \sqrt{\frac{\log|\mathcal{C}| + \log(1/\delta)}{2n}}\right) \geq 1 - \delta\ .$$

Le risque de chaque classifieur, et en particulier celui de $\hat{g}^*_{n,\mathcal{C}}$, est contrôlé uniformément sur la classe par son risque empirique, à un terme additif près qui ne dépend que de la complexité de la classe, mesurée par le logarithme de son cardinal. Ensuite, d'après le théorème 1.2,

$$\mathbb{P}\left(R(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g\in\mathcal{C}} R(g) \geq \varepsilon\right) \leq \mathbb{P}\left(\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| \geq \frac{\varepsilon}{2}\right) \leq 2\,|\mathcal{C}|\ \mathrm{e}^{-n\varepsilon^2/2}\ ,$$

la dernière majoration s'obtenant comme dans la démonstration du théorème 1.5, avec des inégalités larges. Le minimiseur du risque empirique est donc (ε, δ)-PAC dès que

$$n \geq \frac{2\{\log(1/\delta) + \log(2\,|\mathcal{C}|)\}}{\varepsilon^2}\ .$$

Enfin, le lemme 4.1, appliqué avec $C = 2\,|\mathcal{C}|$ et $\alpha = 2n$, donne $\mathbb{E}[\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|] \leq \sqrt{(1 + \log(2\,|\mathcal{C}|))/(2n)}$, un peu moins bon que la borne $\sqrt{\log(2\,|\mathcal{C}|)/(2n)}$ que l'inégalité de Pisier fournit à la Section 1.3.

Le nombre $\log_2|\mathcal{C}|$ est aussi le nombre de bits nécessaires pour désigner une règle particulière de $\mathcal{C}$; ce lien avec la théorie de l'information et du codage n'est pas fortuit.

4.3 Une application : la classification par histogramme

Soit $m \in \mathbb{N}^*$ et $\{Q_1, \ldots, Q_m\}$ une partition de l'ensemble des attributs X en ensembles mesurables. Par exemple, si $\mathsf{X} = [0, 1]^d$, on peut diviser chaque axe en q intervalles de même longueur et considérer les $m = q^d$ hypercubes ainsi obtenus. Les histogrammes sur la partition sont les classifieurs

$$\mathcal{C} = \left\{ g = \sum_{j=1}^m d_j \mathbb{1}_{Q_j}\ :\ (d_1, \ldots, d_m) \in \{-1, 1\}^m \right\}\ ,$$

qui prennent la même décision en tous les points d'une cellule ; la classe a 2^m éléments. Le risque empirique de $g = \sum_j d_j \mathbb{1}_{Q_j}$ s'écrit

$$\widehat{\mathrm{R}}_n(g) = \sum_{j=1}^{m} \frac{1}{n} \sum_{i=1}^{n} \mathbb{1}_{\{\mathbf{X}_i \in Q_j\}} \mathbb{1}_{\{Y_i \neq d_j\}} \,,$$

somme de termes dont chacun ne dépend que de d_j. On le minimise donc cellule par cellule : tout classifieur qui, dans chaque cellule, prend la décision majoritaire parmi les labels des observations qui y tombent minimise le risque empirique. Avec $|\mathcal{C}| = 2^m$, les théorèmes 1.6 et 1.8 donnent, pour tout $\delta \in]0,1[$,

$$\mathbb{P}\left(R(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g \in \mathcal{C}} R(g) \leq 2\sqrt{\frac{(m+1)\log 2 + \log(1/\delta)}{2n}} \right) \geq 1 - \delta \,,$$

$$\mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) \right] - \inf_{g \in \mathcal{C}} R(g) \leq \sqrt{\frac{(m+1)\log 2}{2n}} \,.$$

L'erreur d'estimation est contrôlée par m/n : pour qu'elle soit faible, il faut que le nombre de cellules soit petit devant le nombre d'observations, de sorte que chaque cellule contienne assez d'exemples pour que le vote majoritaire ait un sens.

4.4 Démonstration de l'inégalité de Pisier

On démontre le théorème 1.7 ; c'est l'exercice 4 (PC9).

Démonstration

Supposons d'abord seulement que $\mathbb{E}[\mathrm{e}^{\lambda Z_i}] \leq \mathrm{e}^{\lambda^2\sigma^2/2}$ pour tout $\lambda > 0$ et tout i, et montrons que $\mathbb{E}[\max_i Z_i] \leq \sigma\sqrt{2\log m}$. Les Z_i sont intégrables, puisque $\mathrm{e}^{|t|} \leq \mathrm{e}^t + \mathrm{e}^{-t}$ et que leur transformée de Laplace est finie en ± 1 dans le cadre du théorème ; il en va de même de $\max_i Z_i$. Pour $\lambda > 0$, l'inégalité de Jensen, appliquée à la fonction convexe $t \mapsto \mathrm{e}^{\lambda t}$, puis la majoration $\mathrm{e}^{\lambda \max_i Z_i} = \max_i \mathrm{e}^{\lambda Z_i} \leq \sum_{i=1}^m \mathrm{e}^{\lambda Z_i}$ donnent

$$\mathrm{e}^{\lambda \mathbb{E}[\max_i Z_i]} \leq \mathbb{E}\left[\mathrm{e}^{\lambda \max_i Z_i}\right] \leq \sum_{i=1}^{m} \mathbb{E}\left[\mathrm{e}^{\lambda Z_i}\right] \leq m\,\mathrm{e}^{\lambda^2\sigma^2/2} \,,$$

soit $\mathbb{E}[\max_i Z_i] \leq \log(m)/\lambda + \lambda\sigma^2/2$. Si $m \geq 2$, le choix $\lambda = \sqrt{2\log m}/\sigma$ donne $\sigma\sqrt{2\log m}$; si $m = 1$, on fait tendre λ vers 0 et l'on obtient $\mathbb{E}[Z_1] \leq 0$.
Sous l'hypothèse du théorème, les $2m$ variables $Z_1, \ldots, Z_m, -Z_1, \ldots, -Z_m$ vérifient toutes cette condition, puisque $\mathbb{E}[\mathrm{e}^{\lambda(-Z_i)}] = \mathbb{E}[\mathrm{e}^{(-\lambda)Z_i}] \leq \mathrm{e}^{\lambda^2\sigma^2/2}$. Comme $\max_i |Z_i| = \max(Z_1, \ldots, Z_m, -Z_1, \ldots, -Z_m)$, on obtient $\mathbb{E}[\max_i |Z_i|] \leq \sigma\sqrt{2\log(2m)}$. □

4.5 L'inégalité de McDiarmid

L'inégalité de Hoeffding porte sur une moyenne. Pour aborder les classes infinies, on a besoin d'une inégalité de concentration pour la variable $\sup_{g \in \mathcal{C}} |\widehat{\mathrm{R}}_n(g) - R(g)|$ elle-même, qui n'est pas une moyenne, mais qui dépend peu de chacune des observations. L'inégalité de McDiarmid traite ce cas ; elle ouvre le chapitre suivant du polycopié d'origine.

Définition 4.2: Différences bornées

Soit A un espace mesurable. Une fonction mesurable $f : \mathsf{A}^n \to \mathbb{R}$ est à *différences bornées* s'il existe des constantes $c_1, \dots, c_n$ telles que, pour tout $i \in \{1, \dots, n\}$,

$$\sup_{x_1,\dots,x_n,x_i' \in \mathsf{A}} |f(x_1, \dots, x_n) - f(x_1, \dots, x_{i-1}, x_i', x_{i+1}, \dots, x_n)| \leq c_i \; .$$

Théorème 4.2: Inégalité de McDiarmid

Soient $X_1, \dots, X_n$ des variables aléatoires indépendantes à valeurs dans A et $f : \mathsf{A}^n \to \mathbb{R}$ une fonction à différences bornées, de constantes $c_1, \dots, c_n$. Posons $G = f(X_1, \dots, X_n)$. Pour tout $t > 0$,

$$\mathbb{P}\left(G - \mathbb{E}[G] \geq t\right) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right) \qquad \text{et} \qquad \mathbb{P}\left(G - \mathbb{E}[G] \leq -t\right) \leq \exp\left(-\frac{2t^2}{\sum_{i=1}^n c_i^2}\right) \; .$$

Pour $f(x_1, \dots, x_n) = n^{-1} \sum_{i=1}^n x_i$ et $\mathsf{A} = [0, 1]$, on a $c_i = 1/n$ et l'on retrouve l'inégalité de Hoeffding.

Démonstration

Une fonction à différences bornées est bornée : en changeant les coordonnées une à une, $|f(x) - f(x')| \leq \sum_i c_i$ pour tous x, x'. Notons μ_i la loi de X_i et, pour $0 \leq i \leq n$,

$$H_i(x_1, \dots, x_i) := \int f(x_1, \dots, x_i, u_{i+1}, \dots, u_n) \, \mu_{i+1}(\mathrm{d}u_{i+1}) \cdots \mu_n(\mathrm{d}u_n) \; ,$$

de sorte que $H_n = f$ et $H_0 = \mathbb{E}[G]$; par le théorème de Fubini, ces fonctions sont mesurables et $H_{i-1}(x_1, \dots, x_{i-1}) = \int H_i(x_1, \dots, x_{i-1}, u) \, \mu_i(\mathrm{d}u)$. Posons $V_i = H_i(X_1, \dots, X_i) - H_{i-1}(X_1, \dots, X_{i-1})$, de sorte que $G - \mathbb{E}[G] = \sum_{i=1}^n V_i$.
Fixons i et $x_{1:i-1} = (x_1, \dots, x_{i-1})$. La fonction $u \mapsto H_i(x_{1:i-1}, u) - H_{i-1}(x_{1:i-1})$ est d'intégrale nulle sous μ_i, et ses valeurs sont comprises entre son infimum et son supremum, qui diffèrent d'au plus c_i, puisque $|H_i(x_{1:i-1}, u) - H_i(x_{1:i-1}, u')| \leq c_i$ par intégration de la propriété de différences bornées. Le lemme de Hoeffding (lemme 1.1), appliqué à la variable $H_i(x_{1:i-1}, X_i) - H_{i-1}(x_{1:i-1})$, donne, pour tout $s > 0$,

$$\Psi_i(x_{1:i-1}) := \int \mathrm{e}^{s\{H_i(x_{1:i-1},u) - H_{i-1}(x_{1:i-1})\}} \, \mu_i(\mathrm{d}u) \leq \mathrm{e}^{s^2 c_i^2/8} \; .$$

Comme X_i est indépendante de $(X_1, \dots, X_{i-1})$, la proposition 2.5 donne $\mathbb{E}\left[\mathrm{e}^{sV_i} \,\middle|\, X_1, \dots, X_{i-1}\right] = \Psi_i(X_1, \dots, X_{i-1}) \leq \mathrm{e}^{s^2 c_i^2/8}$. Les variables $V_1, \dots, V_{i-1}$ étant fonctions de $(X_1, \dots, X_{i-1})$ et toutes ces variables étant bornées,

$$\mathbb{E}\left[\mathrm{e}^{s \sum_{k=1}^i V_k}\right] = \mathbb{E}\left[\mathrm{e}^{s \sum_{k=1}^{i-1} V_k} \mathbb{E}\left[\mathrm{e}^{sV_i} \,\middle|\, X_1, \dots, X_{i-1}\right]\right] \leq \mathrm{e}^{s^2 c_i^2/8} \, \mathbb{E}\left[\mathrm{e}^{s \sum_{k=1}^{i-1} V_k}\right] \; ,$$

et, par récurrence, $\mathbb{E}[\mathrm{e}^{s(G - \mathbb{E}[G])}] \leq \mathrm{e}^{s^2 \sum_i c_i^2/8}$. La borne de Chernoff donne $\mathbb{P}(G - \mathbb{E}[G] \geq t) \leq \mathrm{e}^{-st + s^2 \sum_i c_i^2/8}$, et le choix $s = 4t / \sum_i c_i^2$ donne la première inégalité. La seconde s'obtient en appliquant la première à $-f$. □

Corollaire 4.1: Concentration de la déviation uniforme

Soit $\mathcal{C}$ une classe finie ou dénombrable de règles de classification, munie de la perte 0–1. Pour tout $\varepsilon > 0$,

$$\mathbb{P}\left(\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| - \mathbb{E}\left[\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|\right] \geq \varepsilon\right) \leq \mathrm{e}^{-2n\varepsilon^2} ,$$

et la même majoration vaut pour la déviation inférieure. En particulier, pour tout $\delta \in]0,1[$, avec une probabilité au moins $1-\delta$,

$$\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| \leq \mathbb{E}\left[\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|\right] + \sqrt{\frac{\log(1/\delta)}{2n}} .$$

Démonstration

Lorsque la classe est dénombrable, le supremum est mesurable. La fonction $f((\mathbf{x}_1,y_1),\dots,(\mathbf{x}_n,y_n)) = \sup_{g\in\mathcal{C}} |n^{-1}\sum_{i=1}^n \mathbb{1}_{\{g(\mathbf{x}_i)\neq y_i\}} - R(g)|$ est à différences bornées de constantes $c_i = 1/n$: changer un couple modifie chacune des moyennes empiriques d'au plus $1/n$, donc leur supremum aussi. On applique le théorème 4.2, avec $\sum_i c_i^2 = 1/n$, puis on choisit $\varepsilon = \sqrt{\log(1/\delta)/(2n)}$. □

La variable $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$ est donc concentrée autour de sa moyenne, indépendamment de la loi des données et du cardinal de la classe. Pour obtenir une borne de risque, il reste à majorer cette espérance ; pour une classe infinie, c'est l'objet de la théorie de Vapnik-Chervonenkis, qui ne fait pas partie de ce chapitre.

4.6 Extension aux classifieurs affines

On démontre la proposition 1.2, en suivant l'exercice 7 (PC9). On se place dans le cadre de cette proposition : $\mathsf{X} = \mathbb{R}^d$, $\mathsf{Y} = \{-1,1\}$, la loi de $\mathbf{X}$ a une densité et $n > d$.

La classe finie $\mathcal{C}_n$. Comme la loi de $\mathbf{X}$ a une densité, presque sûrement, toute famille de d attributs distincts de l'échantillon est affinement indépendante, et il passe par ces d points un unique hyperplan affine. Pour $I = \{i_1 < \cdots < i_d\} \subset \{1,\dots,n\}$, on choisit, de façon mesurable en $(\mathbf{X}_{i_1},\dots,\mathbf{X}_{i_d})$, un couple $(\mathbf{a}_I, b_I)$ tel que cet hyperplan soit $\{\mathbf{x} : \mathbf{a}_I^\top \mathbf{x} + b_I = 0\}$, et l'on pose, pour $z \in \{-1,1\}$,

$$h_{I,z}(\mathbf{x}) := 2\,\mathbb{1}_{\{z(\mathbf{a}_I^\top \mathbf{x} + b_I) \geq 0\}} - 1 .$$

Chaque $h_{I,z}$ appartient à $\mathcal{C}$, avec les paramètres $(z\mathbf{a}_I, zb_I)$. On note $\mathcal{C}_n$ l'ensemble de ces classifieurs ; il a au plus $2\binom{n}{d}$ éléments. On note $\widehat{g}_n$ un minimiseur du risque empirique sur $\mathcal{C}_n$.

Lemme 4.2: Lemme combinatoire, admis

Presque sûrement, pour toute règle $g \in \mathcal{C}$,

$$\widehat{\mathrm{R}}_n(\widehat{g}_n) \leq \widehat{\mathrm{R}}_n(g) + \frac{d}{n} .$$

Ce lemme est admis dans l'exercice 7 ; on en trouvera la démonstration au chapitre 4 de *A Probabilistic Theory of Pattern Recognition* de L. Devroye, L. Györfi et G. Lugosi. Il dit qu'en faisant pivoter et en translatant un hyperplan quelconque jusqu'à ce qu'il passe par d points de l'échantillon, on ne change la classification que de ces d points au plus.

Démonstration

Soit $g \in \mathcal{C}$ une règle fixée. On écrit

$$R(\widehat{g}_n) - R(g) = \Big\{R(\widehat{g}_n) - \widehat{\mathrm{R}}_n(\widehat{g}_n)\Big\} + \Big\{\widehat{\mathrm{R}}_n(\widehat{g}_n) - \widehat{\mathrm{R}}_n(g)\Big\} + \Big\{\widehat{\mathrm{R}}_n(g) - R(g)\Big\} \ .$$

Le terme du milieu est au plus d/n par le lemme. Pour le premier, comme $\widehat{g}_n \in \mathcal{C}_n$, il est majoré par $\max_{I,z}\{R(h_{I,z}) - \widehat{\mathrm{R}}_n(h_{I,z})\}$, où $R(h_{I,z}) = \mathbb{P}\,(h_{I,z}(\mathbf{X}) \neq Y \,|\, \mathcal{D}_n)$. Pour I fixé, notons $\widehat{\mathrm{R}}_n^I(h) = (n-d)^{-1}\sum_{k\notin I} \mathbb{1}_{\{h(\mathbf{X}_k)\neq Y_k\}}$ le risque empirique calculé sur les $n-d$ couples qui ne sont pas dans I. Comme $\widehat{\mathrm{R}}_n(h) \geq ((n-d)/n)\,\widehat{\mathrm{R}}_n^I(h)$ et $\widehat{\mathrm{R}}_n^I(h) \leq 1$,

$$R(h_{I,z}) - \widehat{\mathrm{R}}_n(h_{I,z}) \leq R(h_{I,z}) - \widehat{\mathrm{R}}_n^I(h_{I,z}) + \frac{d}{n} \ .$$

On obtient

$$R(\widehat{g}_n) - R(g) \leq \max_{I,z} \Big\{R(h_{I,z}) - \widehat{\mathrm{R}}_n^I(h_{I,z})\Big\} + \Big\{\widehat{\mathrm{R}}_n(g) - R(g)\Big\} + \frac{2d}{n} \ .$$

Soit $t > 0$. La règle $h_{I,z}$ ne dépend que des couples d'indices dans I, et les $n-d$ autres couples sont indépendants de ceux-là et de loi $\mathbb{P}$; d'après la proposition 2.5, la probabilité $\mathbb{P}(R(h_{I,z}) - \widehat{\mathrm{R}}_n^I(h_{I,z}) \geq t)$ est l'espérance de la même probabilité calculée pour une règle fixée, que la déviation unilatérale de l'inégalité de Hoeffding, appliquée à $n-d$ variables à valeurs dans $\{0,1\}$, majore par $\mathrm{e}^{-2(n-d)t^2}$. De même, $\mathbb{P}(\widehat{\mathrm{R}}_n(g) - R(g) \geq t) \leq \mathrm{e}^{-2nt^2} \leq \mathrm{e}^{-2(n-d)t^2}$. Si la somme des deux premiers termes du membre de droite dépasse $2t$, l'un d'eux dépasse t ; la borne de l'union donne donc

$$\mathbb{P}\left(R(\widehat{g}_n) - R(g) \geq \frac{2d}{n} + 2t\right) \leq \left(2\binom{n}{d} + 1\right)\mathrm{e}^{-2(n-d)t^2} \ .$$

On choisit t de sorte que le membre de droite vaille δ, soit $t = \sqrt{\log((2\binom{n}{d}+1)/\delta)/(2(n-d))}$, et l'on note $\Delta = 2d/n + 2t$.
Il reste à remplacer $R(g)$ par l'infimum. Pour $k \geq 1$, soit $g_k \in \mathcal{C}$ telle que $R(g_k) \leq \inf_{g\in\mathcal{C}} R(g) + 1/k$. Les événements $\{R(\widehat{g}_n) - \inf_{g\in\mathcal{C}} R(g) > \Delta + 1/k\}$ croissent vers $\{R(\widehat{g}_n) - \inf_{g\in\mathcal{C}} R(g) > \Delta\}$, et chacun est inclus dans $\{R(\widehat{g}_n) - R(g_k) > \Delta\}$, de probabilité au plus δ. Par continuité monotone de $\mathbb{P}$, $\mathbb{P}(R(\widehat{g}_n) - \inf_{g\in\mathcal{C}} R(g) > \Delta) \leq \delta$. □

L'exercice 7 en déduit aussi une borne de l'excès de risque moyen, par intégration de la queue comme au lemme 4.1.

4.7 Pour aller plus loin

Le deck renvoie à deux ouvrages sur les inégalités de concentration : *The Concentration of Measure Phenomenon* de M. Ledoux (American Mathematical Society, 2001), et *Concentration Inequalities : A Nonasymptotic Theory of Independence* de S. Boucheron, G. Lugosi et P. Massart (Oxford University Press, 2013). Le second traite l'argument de Herbst, les inégalités de Bennett et de Bernstein, qui tiennent compte de la variance, et l'inégalité de McDiarmid ; ses premiers chapitres sont accessibles avec les outils de ce chapitre.