Chapitre 9

Approche discriminative et minimisation du risque empirique

Le chapitre 8 a posé le cadre de l'apprentissage supervisé et a décrit une première façon de construire une règle de prédiction : modéliser la loi du couple $(\mathbf{X}, Y)$, estimer les paramètres du modèle, puis substituer l'estimateur dans l'expression de la règle de Bayes. On verra dans ce chapitre une approche différente.

Ce chapitre étudie la seconde voie, dite discriminative, qui est l'approche principale de l'apprentissage statistique. On ne modélise plus la loi des données : on choisit une classe $\mathcal{C}$ de règles et l'on retient celle qui commet, en moyenne, la plus petite perte sur l'ensemble d'apprentissage. C'est la minimisation du risque empirique. On en donne la définition et des exemples, puis on étudie les compromis qu'elle entraîne : la décomposition de l'excès de risque en une erreur d'approximation et une erreur d'estimation, le sur-apprentissage, et le théorème *no free lunch*, qui interdit toute garantie sans hypothèse.

On montre ensuite comment contrôler l'erreur d'estimation. Elle est majorée par les déviations uniformes du risque empirique autour du risque sur la classe, et ces déviations se contrôlent, pour une classe finie et la perte 0–1, par une inégalité de concentration, l'inégalité de Hoeffding, combinée à une borne de l'union. On obtient ainsi des bornes en grande probabilité et en espérance, d'ordre $\sqrt{\log|\mathcal{C}|/n}$. Enfin, comme la minimisation du risque empirique pour la perte 0–1 est un problème combinatoire, on la remplace par la minimisation d'un risque convexifié, ce qui soulève les questions étudiées au chapitre suivant.

De la modélisation à la minimisation du risque empirique

Dans l'approche par modélisation, la règle de décision est un sous-produit de l'estimation : on estime un paramètre, et on en déduit la règle par substitution (*plug-in*). Le chapitre 8 a cependant montré que, pour le modèle logistique et pour le modèle linéaire gaussien, l'estimateur du maximum de vraisemblance minimise une moyenne empirique de pertes, la perte logistique dans le premier cas, la perte quadratique dans le second. La règle obtenue peut donc se décrire sans référence au modèle : c'est la règle d'une classe de fonctions linéaires qui minimise une perte moyenne sur l'ensemble d'apprentissage.

L'approche discriminative prend ce constat pour point de départ. On renonce à décrire la loi du couple $(\mathbf{X}, Y)$, on se donne une perte et une classe de règles, et l'on cherche dans cette classe une règle qui soit bonne sur les données. Le choix de la classe joue alors le rôle que jouait le choix du modèle : il porte l'hypothèse qui rend l'apprentissage possible.

Intuition. *Le passage d'une approche à l'autre déplace l'hypothèse. En modélisation, on suppose que la loi des données appartient à une famille paramétrique, et l'on obtient des garanties sous cette loi. En minimisation du risque empirique, on ne suppose rien sur la loi, mais on ne compare plus la règle apprise qu'aux règles de la classe ; l'écart à la règle de Bayes dépend alors de la qualité de la classe, sur laquelle les données ne disent rien.*

1 Les fondamentaux

1.1 Rappel du cadre et motivation

On rappelle le cadre de l'apprentissage supervisé du chapitre 8, puis l'approche par modélisation, dont les limites motivent ce chapitre.

Le cadre de l'apprentissage supervisé

On observe un phénomène décrit par un couple aléatoire $(\mathbf{X}, Y) \sim \mathbb{P}$, à valeurs dans $\mathsf{X} \times \mathsf{Y}$ (cadre 1.1 du chapitre 8), et l'on veut prédire Y à partir de $\mathbf{X}$. Les objets sont les suivants.

— Une *règle de décision*, ou prédicteur, ou classifieur, est une fonction mesurable $g : \mathsf{X} \to \mathsf{Y}$ (définition 1.1).

— La *perte* $\ell(Y, g(\mathbf{X}))$ mesure la qualité de la prévision $g(\mathbf{X})$ de la réponse Y (définition 1.2).

— Le *risque*, ou risque de généralisation, est la perte moyenne $R(g) = \mathbb{E}[\ell(Y, g(\mathbf{X}))]$ (définition 1.3).

Le *prédicteur bayésien* $g^\star$ vérifie $R(g^\star) \leq R(g)$ pour toute règle g ; on note $R^\star = R(g^\star)$ le risque bayésien (définition 1.4). Le chapitre 8 l'a calculé dans les deux cas usuels : c'est l'espérance conditionnelle $\mathbb{E}[Y \mid \mathbf{X}]$ en régression pour la perte quadratique (théorème 1.1), et le classifieur $2\,\mathbb{1}_{\{\eta(\mathbf{X}) \geq 1/2\}} - 1$ en classification binaire pour la perte 0–1 (théorème 1.2).

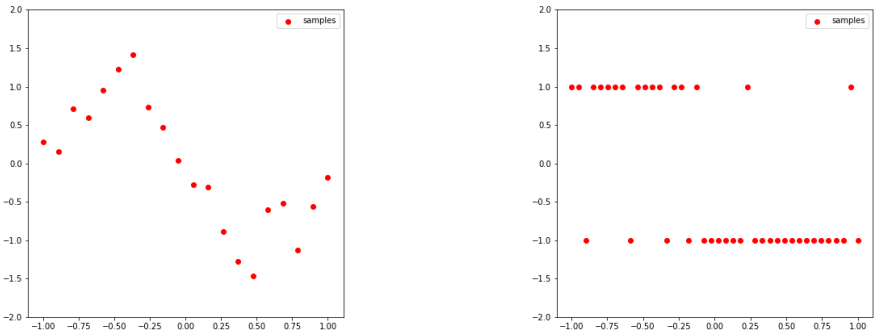


FIGURE 1 – Deux ensembles d'apprentissage avec un attribut réel. À gauche, un problème de régression : la réponse est réelle. À droite, un problème de classification binaire : la réponse vaut -1 ou 1.

Le prédicteur bayésien dépend de $\mathbb{P}$, qui est inconnue. On observe un *ensemble d'apprentissage* $\mathcal{D}_n = \{(\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n)\}$, formé de n couples indépendants de loi $\mathbb{P}$, et l'on construit à partir de lui une règle $\widehat{g}_n$. L'objectif est de contrôler l'*excès de risque* de généralisation

$$\mathcal{E}(\widehat{g}_n) := R(\widehat{g}_n) - R^\star = \mathbb{E}\left[\ell(Y, \widehat{g}_n(\mathbf{X})) \mid \mathcal{D}_n\right] - R^\star \,,$$

où $(\mathbf{X}, Y)$ est un couple de loi $\mathbb{P}$ indépendant de $\mathcal{D}_n$. Comme au chapitre 8 (Section 4.4), $R(\widehat{g}_n)$ est une variable aléatoire, fonction de $\mathcal{D}_n$: c'est le risque de la règle apprise, évalué sur un exemple nouveau. D'après la proposition 2.5, il s'obtient en calculant $R(g)$ pour une règle g fixée, puis en remplaçant g par $\widehat{g}_n$.

L'approche par modélisation

La première approche, étudiée au chapitre 8 (Section 1.3), procède en quatre étapes.

Méthode 1.1: Construction d'un estimateur par modélisation statistique et substitution

1. On **modélise** la loi de $(\mathbf{X}, Y)$ par un modèle paramétrique $\{\mathbb{P}_\theta \,:\, \theta \in \Theta\}$.
2. On calcule le prédicteur de Bayes $g^\star_\theta$ sous chacune des lois $\mathbb{P}_\theta$.
3. On estime θ par $\hat{\theta}_n$.
4. On choisit la règle $\widehat{g}_n = g^\star_{\hat{\theta}_n}$ (substitution, ou *plug-in*).

Trois exemples ont été traités. L'analyse discriminante linéaire et quadratique (Section 1.3) modélise $\mathbf{X}$ sachant $Y = i$ par une loi $\mathcal{N}(\mu_i, \Sigma_i)$ et Y par une loi de Bernoulli ; la règle de décision est linéaire ou quadratique, et l'estimateur typique est l'estimateur du maximum de vraisemblance. Le modèle logistique (Section 1.3) pose $\mathbb{P}_\theta(Y = 1 \mid \mathbf{X}) = \mathrm{sigm}(\theta^\top \mathbf{X})$ et laisse la loi de $\mathbf{X}$ quelconque ; la règle est linéaire, $\widehat{g}_n(\mathbf{X}) = 2\,\mathbb{1}_{\{\hat{\theta}_n^\top \mathbf{X} \geq 0\}} - 1$, et l'estimateur du maximum de vraisemblance, conditionnel aux $\mathbf{X}_i$, est

$$\hat{\theta}_n = \operatorname*{arg\,min}_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \log\left(1 + \exp\left(-Y_i \theta^\top \mathbf{X}_i\right)\right) \,.$$

Le modèle linéaire gaussien homoscédastique (Section 1.3) pose $\mathcal{L}(Y \mid \mathbf{X}) = \mathcal{N}(\theta^\top \mathbf{X}, \sigma^2)$; le prédicteur de Bayes est $g^\star_\theta(\mathbf{X}) = \theta^\top \mathbf{X}$, l'estimateur du maximum de vraisemblance est celui des moindres carrés,

$$\hat{\theta}_n = \operatorname*{arg\,min}_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \left(\theta^\top \mathbf{X}_i - Y_i\right)^2 \,,$$

et la règle retenue est $\widehat{g}_n(\mathbf{X}) = \hat{\theta}_n^\top \mathbf{X}$. Utiliser ce modèle revient à utiliser la perte des moindres carrés et une classe de fonctions linéaires. D'autres méthodes relèvent de la même démarche, avec des modèles non paramétriques et des règles non linéaires : le classifieur bayésien naïf et la règle des k plus proches voisins.

Le résultat typique de cette approche est la proposition 1.5, établie à l'exercice 2 (PC8) : sous $\mathbb{P}_{n,\theta^\star}$, si $\hat{\theta}_n$ est consistant et sous des conditions de continuité, l'excès de risque moyen tend vers zéro,

$$\mathbb{E}_{n,\theta^\star}\left[\mathcal{E}\left(g^\star_{\hat{\theta}_n}\right)\right] = \mathbb{E}_{n,\theta^\star}\left[R\left(g^\star_{\hat{\theta}_n}\right) - R\left(g^\star_{\theta^\star}\right)\right] \xrightarrow[n\to\infty]{} 0 \,.$$

Ce résultat ne tient que sous le modèle : c'est une approche de type statistique, qui utilise un modèle statistique et obtient des résultats pour ce modèle. Elle laisse entier un problème, celui du choix du modèle statistique.

1.2 Approche par minimisation du risque empirique

L'idée de l'approche discriminative est de chercher un prédicteur qui soit bon sur l'ensemble d'apprentissage $\{(\mathbf{X}_i, Y_i)\}_{1 \leq i \leq n}$. Le risque d'une règle n'est pas calculable, puisque $\mathbb{P}$ est inconnue, mais on peut en former une estimation à partir des données, et la minimiser.

Le minimiseur du risque empirique

Définition 1.1: Risque empirique et minimiseur du risque empirique

Soit ℓ une fonction de perte et $\mathcal{C}$ une classe de règles de décision $g : \mathsf{X} \to \mathsf{Y}$. Le *risque empirique* d'une règle g sur l'ensemble d'apprentissage $\mathcal{D}_n$ est

$$\widehat{\mathrm{R}}_n(g) := \frac{1}{n} \sum_{i=1}^n \ell(Y_i, g(\mathbf{X}_i)) \,.$$

Un *minimiseur du risque empirique* (MRE) sur $\mathcal{C}$ est une règle $\hat{g}^*_{n,\mathcal{C}} \in \mathcal{C}$, construite à partir de $\mathcal{D}_n$, telle que

$$\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) = \min_{g\in\mathcal{C}} \widehat{\mathrm{R}}_n(g)\ , \qquad \text{ce que l'on écrit} \quad \hat{g}^*_{n,\mathcal{C}} = \arg\min_{g\in\mathcal{C}} \widehat{\mathrm{R}}_n(g)\ .$$

Le minimum n'est pas toujours atteint, et le minimiseur n'est pas toujours unique ; lorsqu'il en existe plusieurs, on en considère un. On suppose dans tout le chapitre qu'un minimiseur existe et qu'il peut être choisi de façon mesurable en les données, de sorte que $\hat{g}^*_{n,\mathcal{C}}(\mathbf{x}) = g(\mathbf{x};\mathcal{D}_n)$ définit une règle apprise au sens du chapitre 8. Ces deux hypothèses sont satisfaites lorsque la classe $\mathcal{C}$ est finie, ce qui sera le cas de la Section 1.3.

On peut espérer que cette démarche soit raisonnable, pour la raison suivante. Pour toute règle g *fixée*, comme $R(g) = \mathbb{E}[\ell(Y, g(\mathbf{X}))]$ et que les couples $(\mathbf{X}_i, Y_i)$ ont la loi $\mathbb{P}$,

— $\widehat{\mathrm{R}}_n(g)$ est un estimateur sans biais de $R(g)$: $\mathbb{E}[\widehat{\mathrm{R}}_n(g)] = R(g)$, par linéarité de l'espérance ;

— la loi des grands nombres (chapitre 7, théorème 2.1) montre que $\widehat{\mathrm{R}}_n(g) \overset{\mathbb{P}-\text{prob}}{\longrightarrow} R(g)$ dès que $R(g) < \infty$, les variables $\ell(Y_i, g(\mathbf{X}_i))$ étant indépendantes, de même loi, positives et intégrables.

Intuition. *L'hypothèse « g fixée » est essentielle. Le minimiseur $\hat{g}^*_{n,\mathcal{C}}$ est choisi* au vu des données, *et son risque empirique n'est pas une moyenne de variables indépendantes de même loi : chacun des termes $\ell(Y_i, \hat{g}^*_{n,\mathcal{C}}(\mathbf{X}_i))$ dépend de tout l'échantillon. Les deux propriétés ci-dessus ne s'appliquent donc pas à $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})$, et toute la suite du chapitre consiste à mesurer ce que l'on perd en passant d'une règle fixée à une règle choisie dans $\mathcal{C}$ à partir des données.*

Le choix de la classe. Différentes classes donnent différents estimateurs, et l'on doit *restreindre* la classe de fonctions. Si l'on prend pour $\mathcal{C}$ l'ensemble Y^{X} de toutes les règles, le risque empirique se minimise sans rien apprendre, comme le montre l'exemple suivant.

Exemple 1.1: Une règle qui ne généralise pas

On se place en régression, $\mathsf{Y} = \mathbb{R}$, avec la perte quadratique, et l'on suppose que la loi de $\mathbf{X}$ n'a pas d'atome : $\mathbb{P}(\mathbf{X} = \mathbf{x}) = 0$ pour tout $\mathbf{x} \in \mathsf{X}$. Les attributs $\mathbf{X}_1, \dots, \mathbf{X}_n$ sont alors presque sûrement deux à deux distincts, et la règle

$$\hat{g}^*_{n,\mathcal{C}}(\mathbf{x}) = \begin{cases} Y_i & \text{si } \mathbf{x} = \mathbf{X}_i\ , \\ 0 & \text{si } \mathbf{x} \notin \{\mathbf{X}_1, \dots, \mathbf{X}_n\}\ , \end{cases}$$

vérifie $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) = 0$: elle minimise le risque empirique sur $\mathcal{C} = \mathbb{R}^{\mathsf{X}}$. Pourtant, si $(\mathbf{X}, Y)$ est un couple de loi $\mathbb{P}$ indépendant de $\mathcal{D}_n$, l'événement $\{\mathbf{X} \in \{\mathbf{X}_1, \dots, \mathbf{X}_n\}\}$ est de probabilité nulle, conditionnellement à $\mathcal{D}_n$, puisque la loi de $\mathbf{X}$ n'a pas d'atome. On a donc $\hat{g}^*_{n,\mathcal{C}}(\mathbf{X}) = 0$ presque sûrement, et

$$R(\hat{g}^*_{n,\mathcal{C}}) = \mathbb{E}\left[(Y - \hat{g}^*_{n,\mathcal{C}}(\mathbf{X}))^2 \,\middle|\, \mathcal{D}_n\right] = \mathbb{E}[Y^2]\ ,$$

qui est le risque de la règle constante nulle. Cette règle ne *généralise* pas : $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \ll R(\hat{g}^*_{n,\mathcal{C}})$. C'est le *sur-apprentissage*. Le chapitre 8 (Section 4.3) en donne la version en classification.

Choix de la classe : exemples en régression, perte quadratique

On compare, sur un même ensemble d'apprentissage en régression avec un attribut réel, les minimiseurs du risque empirique pour la perte quadratique dans quatre classes de complexité croissante : les fonctions affines, les polynômes de degré au plus 3, notés $\mathbb{R}_3[X]$, les polynômes de

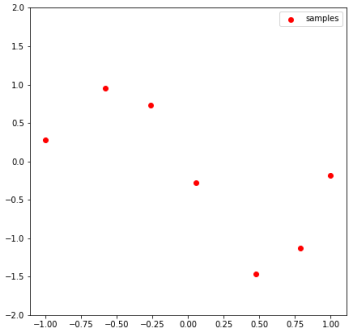


FIGURE 2 – Un petit ensemble d'apprentissage en régression. La règle de l'exemple 1.1 vaut Y_i en chacun des attributs observés et 0 partout ailleurs : son risque empirique est nul, et elle ne dit rien des attributs qui n'ont pas été observés.

degré au plus 20, notés $\mathbb{R}_{20}[X]$, et un réseau de neurones dense. On note d le nombre de paramètres de la classe, c'est-à-dire sa dimension lorsqu'elle est un espace vectoriel.

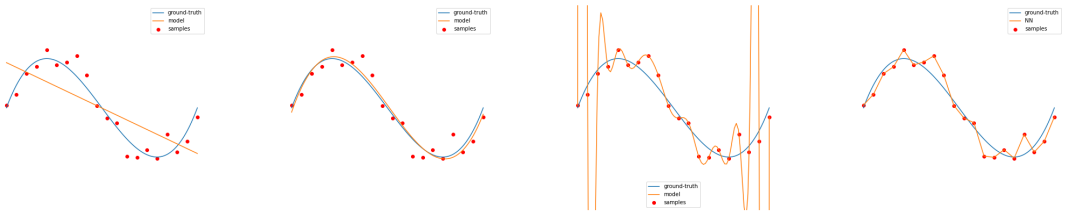


FIGURE 3 – Minimiseurs du risque empirique pour la perte quadratique (en orange) sur un même ensemble d'apprentissage (points rouges), dans quatre classes : fonctions affines, $\mathbb{R}_3[X]$, $\mathbb{R}_{20}[X]$ et réseau de neurones dense, de gauche à droite. La courbe bleue est la fonction de régression qui a servi à simuler les données.

$\mathcal{C}$	fonctions affines	$\mathbb{R}_3[X]$	$\mathbb{R}_{20}[X]$
d	2	4	21
$\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})$	grand	petit, non nul	nul
$R(\hat{g}^*_{n,\mathcal{C}})$	grand	petit	très grand
problème	sous-apprentissage	aucun	sur-apprentissage

Avec les fonctions affines, la classe est trop pauvre pour approcher la fonction de régression : le risque empirique et le risque sont tous deux grands, c'est le *sous-apprentissage*. Avec $\mathbb{R}_{20}[X]$, la classe contient un polynôme qui passe par tous les points de l'ensemble d'apprentissage, de sorte que le risque empirique du minimiseur est nul ; entre les points et près des bords de l'intervalle, ce polynôme oscille fortement, et son risque est très grand : c'est le *sur-apprentissage*. La classe $\mathbb{R}_3[X]$ réalise un compromis. Le réseau de neurones dense de la dernière figure passe lui aussi par les points de l'ensemble d'apprentissage, en les reliant presque par des segments. Le cours donne un carnet de démonstration qui permet de refaire ces ajustements (démonstration Colab).

Intuition. *Le tableau illustre le compromis de la Section 1.2. Plus la classe est riche, mieux elle peut suivre les données, et plus le minimiseur du risque empirique risque de suivre le bruit plutôt que la fonction*

de régression. Ce n'est pas un énoncé, mais une tendance : on verra que, pour des classes finies, l'écart entre risque et risque empirique est contrôlé par une quantité qui croît avec la taille de la classe et décroît avec n.

Choix de la classe en pratique : validation et validation croisée

En pratique, on ne connaît pas la fonction de régression et l'on ne peut pas calculer le risque. Pour choisir la complexité de $\mathcal{C}$ et éviter le sur-apprentissage, on réserve une partie des données à l'estimation du risque.

Méthode 1.2: Sélection par validation

On dispose de classes candidates $\mathcal{C}_1, \dots, \mathcal{C}_K$.

- On découpe l'ensemble d'apprentissage $\mathcal{D}_n$ en deux parties : un *ensemble d'ajustement* $\mathcal{D}_{\text{fit}}$, qui sert à ajuster les règles, et un *ensemble de validation* $\mathcal{D}_{\text{val}}$, qui sert à estimer leur risque de généralisation.
- Pour chaque classe $\mathcal{C}_i$, on construit la règle $\hat{g}^*_{n,\mathcal{C}_i}$ qui minimise le **risque empirique sur** $\mathcal{D}_{\text{fit}}$, puis on évalue

$$\widehat{\mathrm{R}}_n^{(\text{val})}(\hat{g}^*_{n,\mathcal{C}_i}) := \frac{1}{|\mathcal{D}_{\text{val}}|} \sum_{(\mathbf{x}_i, y_i) \in \mathcal{D}_{\text{val}}} \ell\left(y_i, \hat{g}^*_{n,\mathcal{C}_i}(\mathbf{x}_i)\right) \ .$$

- On sélectionne la classe, et la règle associée, qui minimise ce risque de validation.

La *validation croisée à k blocs* (*k-fold cross-validation*) répète cette procédure k fois en changeant les rôles des parties. On partage $\mathcal{D}_n$ en k blocs ; pour chaque bloc, on ajuste les règles sur les $k-1$ autres blocs et l'on calcule leur risque empirique sur le bloc laissé de côté. On retient la moyenne de ces k risques de validation pour faire la sélection.

L'exercice 1 (PC9) justifie cette démarche pour la perte 0–1. Si g_n est une règle construite sur un ensemble d'apprentissage et si l'on dispose de m couples de validation indépendants de cet ensemble et de loi $\mathbb{P}$, l'erreur de validation $\widehat{R}_{n,m}$ vérifie $\mathbb{E}\left[\widehat{R}_{n,m} \,\middle|\, \mathcal{D}_n\right] = R(g_n)$, et $\mathbb{P}(|\widehat{R}_{n,m} - R(g_n)| \geq \varepsilon) \leq 2\mathrm{e}^{-2m\varepsilon^2}$ pour tout $\varepsilon > 0$, par l'inégalité de Hoeffding de la Section 1.3.

Intuition. *L'ensemble de validation joue, pour la règle ajustée, le rôle que joue un échantillon frais pour une règle fixée : comme la règle a été choisie sans lui, son risque de validation est une moyenne de variables indépendantes de même loi, conditionnellement à la règle, et il estime sans biais le risque. Le risque empirique calculé sur les données d'ajustement n'a pas cette propriété, comme le montrera la proposition 1.1. La validation croisée moyenne ces estimations sur plusieurs découpages pour en réduire la variabilité ; c'est une heuristique, dont l'analyse sort du cadre du cours.*

Décomposition de l'excès de risque pour une classe

Le choix de la classe gouverne deux sources d'erreur, que la décomposition suivante sépare. Soit $g^*_{\mathcal{C}}$ une règle de $\mathcal{C}$ telle que $R(g^*_{\mathcal{C}}) = \inf_{g \in \mathcal{C}} R(g)$, appelée *oracle* de la classe, et soit $\hat{g}_{n,\mathcal{C}} \in \mathcal{C}$ un estimateur, c'est-à-dire une règle de $\mathcal{C}$ construite à partir de $\mathcal{D}_n$. L'excès de risque se décompose en

$$\mathcal{E}(\hat{g}_{n,\mathcal{C}}) = R(\hat{g}_{n,\mathcal{C}}) - R^\star = \underbrace{R(\hat{g}_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})}_{\text{erreur d'estimation}} + \underbrace{R(g^*_{\mathcal{C}}) - R^\star}_{\text{erreur d'approximation}} \ . \tag{1}$$

On note $\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}_{n,\mathcal{C}}) := R(\hat{g}_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})$ l'erreur d'estimation. Les deux termes sont positifs : le premier parce que $\hat{g}_{n,\mathcal{C}}$ appartient à $\mathcal{C}$, le second par définition du risque bayésien. Si l'infimum n'est pas atteint, on remplace $R(g^*_{\mathcal{C}})$ par $\inf_{g \in \mathcal{C}} R(g)$ dans toute la suite ; seule la valeur de l'infimum intervient.

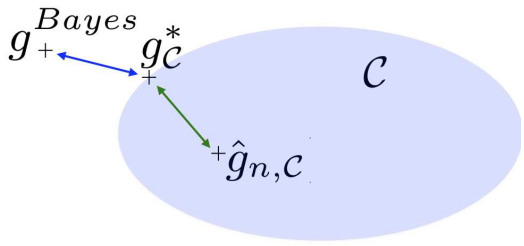


FIGURE 4 – La règle de Bayes $g^\star$, notée g^{Bayes} sur la figure, l'oracle $g^*_{\mathcal{C}}$ de la classe $\mathcal{C}$ et un estimateur $\hat{g}_{n,\mathcal{C}}$ de cette classe. La flèche bleue représente l'erreur d'approximation, la flèche verte l'erreur d'estimation.

— L'*erreur d'estimation* reflète notre connaissance imparfaite de la loi de $(\mathbf{X}, Y)$: elle provient de ce que l'on choisit la règle dans $\mathcal{C}$ au vu de n observations seulement.

— L'*erreur d'approximation* dépend du choix de $\mathcal{C}$ et de la loi $\mathbb{P}$, mais pas des données.

Comment ces deux erreurs varient-elles avec la classe et avec n ? Si $\mathcal{C} \subset \mathcal{C}'$, alors $\inf_{g\in\mathcal{C}'} R(g) \leq \inf_{g\in\mathcal{C}} R(g)$: l'erreur d'approximation décroît, au sens large, quand la classe grandit, et elle ne dépend pas de n. L'erreur d'estimation, au contraire, tend à croître quand la classe grandit et à décroître quand n grandit ; ce second point n'est pas un énoncé général, mais il sera établi, pour les minimiseurs du risque empirique sur une classe finie, par les bornes de la Section 1.3, qui croissent avec $|\mathcal{C}|$ et décroissent avec n.

	erreur d'approximation	erreur d'estimation
$\mathcal{C}$ grandit	décroît	tend à croître
n grandit	inchangée	tend à décroître

La somme des deux erreurs passe donc, en général, par un minimum pour une classe de complexité intermédiaire : c'est la figure 9 du chapitre 8, où les classes trop pauvres sont du côté du sous-apprentissage et les classes trop riches du côté du sur-apprentissage. La Section 4.6 du chapitre 8 présente la même décomposition pour le risque moyen.

Sur-apprentissage

On peut maintenant préciser ce que l'on entend par sur-apprentissage. On compare quatre situations pour le minimiseur du risque empirique $\hat{g}^*_{n,\mathcal{C}}$ et l'oracle $g^*_{\mathcal{C}}$:

$$\text{(a) } R(\hat{g}^*_{n,\mathcal{C}}) \ll \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \,, \qquad \text{(b) } \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \ll R(\hat{g}^*_{n,\mathcal{C}}) \,,$$
$$\text{(c) } R(g^*_{\mathcal{C}}) \ll R(\hat{g}^*_{n,\mathcal{C}}) \,, \qquad \text{(d) } \widehat{\mathrm{R}}_n(g^*_{\mathcal{C}}) \ll R(g^*_{\mathcal{C}}) \,.$$

Il y a sur-apprentissage dans la situation (b) : la règle apprise est bien meilleure sur les données qui ont servi à la choisir que sur des données nouvelles. La proposition suivante montre que l'inégalité va toujours dans ce sens en moyenne, ce qui écarte (a), et que le risque empirique de l'oracle, qui est une règle fixée, est un estimateur sans biais de son risque, ce qui écarte (d) en moyenne. La situation (c) décrit une erreur d'estimation grande, qui peut accompagner le sur-apprentissage mais qui fait intervenir le risque de l'oracle, inaccessible.

Proposition 1.1: Biais optimiste du risque empirique du minimiseur

On suppose que la perte ℓ est positive et que $R(g) < \infty$ pour tout $g \in \mathcal{C}$. Alors

$$\mathbb{E}\left[\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})\right] \leq \inf_{g\in\mathcal{C}} R(g) \leq \mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}})\right] \ .$$

De plus, pour toute règle $g \in \mathcal{C}$ fixée, $\mathbb{E}[\widehat{\mathrm{R}}_n(g)] = R(g)$.

Démonstration

La dernière affirmation est la linéarité de l'espérance. Pour tout $g \in \mathcal{C}$, on a $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \leq \widehat{\mathrm{R}}_n(g)$ par définition du minimiseur, donc $\mathbb{E}[\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})] \leq \mathbb{E}[\widehat{\mathrm{R}}_n(g)] = R(g)$; on passe à l'infimum en g. D'autre part, pour chaque réalisation de $\mathcal{D}_n$, la règle $\hat{g}^*_{n,\mathcal{C}}$ appartient à $\mathcal{C}$, donc son risque, calculé à $\mathcal{D}_n$ fixé comme le permet la proposition 2.5, est au moins égal à $\inf_{g\in\mathcal{C}} R(g)$; on prend l'espérance. □

Intuition. *Le risque empirique du minimiseur est biaisé de façon optimiste : en choisissant la meilleure règle sur les données, on choisit aussi la règle que le hasard de l'échantillon a le plus favorisée. Plus la classe est riche, plus ce hasard a de règles parmi lesquelles favoriser l'une d'elles, et plus l'écart entre $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})$ et $R(\hat{g}^*_{n,\mathcal{C}})$ risque d'être grand. Le théorème 1.2 quantifie cet écart.*

Le théorème *no free lunch*

Peut-on espérer une règle d'apprentissage dont l'excès de risque soit petit pour toutes les lois ? Le théorème suivant répond par la négative, pour la perte 0–1, $\ell(y, y') = \mathbb{1}_{\{y\neq y'\}}$.

Théorème 1.1: No free lunch

On se place en classification binaire, $\mathsf{Y} = \{-1, 1\}$, avec la perte 0–1, et l'on suppose que l'ensemble des attributs X est infini et muni d'une tribu qui contient les singletons (c'est le cas de $\mathsf{X} = \mathbb{R}^d$). Soit $\widehat{g}_n(\cdot) = \widehat{g}(\cdot\,; (\mathbf{X}_1, Y_1), \ldots, (\mathbf{X}_n, Y_n))$ une règle de classification, c'est-à-dire une fonction mesurable de $(\mathbf{x}, \mathcal{D}_n)$ à valeurs dans $\{-1, 1\}$. Pour tout $n \in \mathbb{N}^*$ et tout $\varepsilon > 0$, il existe une loi $\mathbb{P}$ sur $\mathsf{X} \times \mathsf{Y}$ telle que $R^\star = 0$ et

$$\mathbb{E}\left[\mathcal{E}(\widehat{g}_n)\right] = \mathbb{E}\left[R(\widehat{g}_n)\right] \geq \frac{1}{2} - \varepsilon \ ,$$

où l'espérance porte sur l'ensemble d'apprentissage $\mathcal{D}_n$, formé de n couples indépendants de loi $\mathbb{P}$.

La démonstration est donnée dans les compléments (Section 4.1), et l'exercice 6 (PC9) en est une version guidée. La loi $\mathbb{P}$ dépend de n et de la règle : pour chaque taille d'échantillon et chaque règle, on peut trouver un problème où la règle n'apprend rien. Le risque moyen 1/2 est celui d'une règle qui tire chaque prédiction à pile ou face.

Intuition. *La loi construite dans la démonstration répartit l'attribut uniformément sur un très grand nombre K de points et attache à chacun un label déterministe mais sans aucune régularité d'un point à l'autre. Avec n observations, on ne voit qu'au plus n de ces points ; un nouveau point est, avec une probabilité proche de un si $K \gg n$, un point jamais observé, et son label n'est pas relié à ceux des points*

observés. Aucune règle ne peut faire mieux que deviner, quelle que soit sa construction. L'argument est rendu rigoureux en moyennant sur tous les étiquetages possibles.

Interprétation du *no free lunch*. Il est impossible d'obtenir un résultat sur l'excès de risque $R(\widehat{g}_n) - R^\star$ sans *hypothèse sur la distribution* $\mathbb{P}$. Il faut faire une hypothèse ou changer d'objectif. Deux approches se présentent.

1. **L'approche par modélisation** fait une hypothèse sur la distribution $\mathbb{P}$. On contraint la loi du couple $(\mathbf{X}, Y)$ à un modèle statistique $\{\mathbb{P}_\theta : \theta \in \Theta\}$, on estime θ, on obtient $\widehat{g}_n$ par substitution et l'on contrôle $\mathcal{E}(\widehat{g}_n) = R(\widehat{g}_n) - R^\star$ sous $\mathbb{P}_\theta$. L'hypothèse, ou l'espoir, est que l'erreur de modélisation soit petite. Relèvent de cette approche l'analyse discriminante linéaire et quadratique, la régression gaussienne, la classification logistique et le classifieur bayésien naïf.
2. **L'approche discriminative** fait une hypothèse sur $g^\star$, ou change de métrique. On contraint la famille de classifieurs à une classe $\mathcal{C}$, on considère le minimiseur du risque empirique $\hat{g}^*_{n,\mathcal{C}}$, ou une approximation de celui-ci, et l'on contrôle l'erreur d'estimation $\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}^*_{n,\mathcal{C}}) = R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})$. L'hypothèse, ou l'espoir, est que l'erreur d'approximation soit petite, ce qui est une hypothèse sur $g^\star$, donc implicitement sur $\mathbb{P}$. Relèvent de cette approche la régression des moindres carrés, les réseaux de neurones, la classification logistique et les machines à vecteurs de support.

La classification logistique figure dans les deux listes : le même critère s'obtient comme maximum de vraisemblance dans le modèle logistique et comme minimiseur d'un risque empirique pour la perte logistique (Section 1.4).

Résumé : le cadre de la minimisation du risque empirique

Dans l'approche discriminative, on minimise le risque empirique sur une classe $\mathcal{C}$:

$$\hat{g}^*_{n,\mathcal{C}} = \arg\min_{g \in \mathcal{C}} \left\{ \widehat{\mathrm{R}}_n(g) = \frac{1}{n} \sum_{i=1}^{n} \ell(Y_i, g(\mathbf{X}_i)) \right\} .$$

Trois questions liées entre elles.

1. Comment choisir $\mathcal{C}$? On a vu des exemples en régression, la décomposition de l'excès de risque en erreur d'approximation et erreur d'estimation, le sur-apprentissage et le théorème *no free lunch* ; en pratique, on emploie la validation croisée (exercice 1 (PC9)).
2. Comment contrôler l'erreur d'estimation $R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})$? C'est l'objet de la Section 1.3.
3. Comment calculer $\hat{g}^*_{n,\mathcal{C}}$, et avec quelle précision ? La Section 1.4 aborde cette question.

1.3 Contrôle du risque d'estimation dans une classe

On cherche maintenant à contrôler l'erreur d'estimation du minimiseur du risque empirique, c'est-à-dire l'écart entre son risque et celui de l'oracle de la classe. On la ramène d'abord à une quantité qui ne dépend que de la classe, la déviation uniforme entre risque et risque empirique, puis on contrôle celle-ci par une inégalité de concentration.

Lien entre erreur d'estimation et déviation risque–risque empirique

Le but est de contrôler

$$\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}^*_{n,\mathcal{C}}) = R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}}) , \qquad \text{où} \quad \begin{cases} \hat{g}^*_{n,\mathcal{C}} = \arg\min_{g \in \mathcal{C}} \widehat{\mathrm{R}}_n(g) , \\ g^*_{\mathcal{C}} = \arg\min_{g \in \mathcal{C}} R(g) . \end{cases}$$

On considère *un* minimiseur s'il y en a plusieurs, et, comme seule la valeur du minimum compte, on écrit $\inf_{g \in \mathcal{C}} R(g)$ au lieu de $R(g^*_{\mathcal{C}})$ lorsque l'infimum n'est pas atteint.

Théorème 1.2: Lien entre erreur de généralisation et processus empirique

Soit $\mathcal{C}$ une classe de règles et ℓ une perte telle que $R(g) < \infty$ pour tout $g \in \mathcal{C}$, et soit $\hat{g}^*_{n,\mathcal{C}}$ un minimiseur du risque empirique sur $\mathcal{C}$. Alors

$$\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}^*_{n,\mathcal{C}}) = R(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g\in\mathcal{C}} R(g) \leq 2 \sup_{g\in\mathcal{C}} \left| \widehat{\mathrm{R}}_n(g) - R(g) \right| , \quad \text{p.s.} \tag{2}$$

Si de plus $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$ est une variable aléatoire intégrable, ce qui est le cas lorsque $\mathcal{C}$ est finie et la perte bornée, alors

$$\mathbb{E}\left[\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}^*_{n,\mathcal{C}})\right] \leq \mathbb{E}\left[\sup_{g\in\mathcal{C}} \left| \widehat{\mathrm{R}}_n(g) - R(g) \right|\right] . \tag{3}$$

L'excès de risque de généralisation du minimiseur du risque empirique est contrôlé par les déviations entre le risque et le risque empirique sur la classe. La démonstration repose sur deux observations :

1. $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \leq \widehat{\mathrm{R}}_n(g)$ pour tout $g \in \mathcal{C}$;
2. $|\,\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) - R(\hat{g}^*_{n,\mathcal{C}})| \leq \sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$, puisque $\hat{g}^*_{n,\mathcal{C}}$ appartient à $\mathcal{C}$.

Démonstration

Soit $\varepsilon > 0$ et $g_\varepsilon \in \mathcal{C}$ telle que $R(g_\varepsilon) \leq \inf_{g\in\mathcal{C}} R(g) + \varepsilon$; si l'oracle existe, on peut prendre $g_\varepsilon = g^*_{\mathcal{C}}$ et $\varepsilon = 0$. En utilisant $\widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) \leq \widehat{\mathrm{R}}_n(g_\varepsilon)$,

$$\begin{aligned} R(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g\in\mathcal{C}} R(g) &= R(\hat{g}^*_{n,\mathcal{C}}) - \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) + \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g\in\mathcal{C}} R(g) \\ &\leq R(\hat{g}^*_{n,\mathcal{C}}) - \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}}) + \widehat{\mathrm{R}}_n(g_\varepsilon) - R(g_\varepsilon) + \varepsilon . \end{aligned}$$

Chacune des deux différences est majorée par $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$, la première par la seconde observation ; on en déduit $R(\hat{g}^*_{n,\mathcal{C}}) - \inf_{g\in\mathcal{C}} R(g) \leq 2 \sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| + \varepsilon$, et (2) suit puisque ε est arbitraire.
Pour (3), on prend l'espérance de la même inégalité, mais on majore seulement le premier terme par le supremum. La règle g_ε est fixée, donc $\mathbb{E}[\widehat{\mathrm{R}}_n(g_\varepsilon)] = R(g_\varepsilon)$, et le second terme est d'espérance nulle :

$$\mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}})\right] - \inf_{g\in\mathcal{C}} R(g) \leq \mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) - \widehat{\mathrm{R}}_n(\hat{g}^*_{n,\mathcal{C}})\right] + \varepsilon \leq \mathbb{E}\left[\sup_{g\in\mathcal{C}} \left| \widehat{\mathrm{R}}_n(g) - R(g) \right|\right] + \varepsilon ,$$

et l'on conclut de même. Lorsque $\mathcal{C}$ est finie et la perte bornée, le supremum est un maximum d'un nombre fini de variables aléatoires bornées ; il est donc mesurable et intégrable. □

Intuition. *Le facteur 2 disparaît en espérance parce que l'un des deux termes porte sur une règle fixée, dont le risque empirique est sans biais. Seul le terme qui porte sur la règle apprise demande un contrôle uniforme : on ne sait pas à l'avance quelle règle de $\mathcal{C}$ sera choisie, et il faut donc que le risque empirique soit proche du risque pour toutes à la fois. C'est la conséquence du choix au vu des données que décrivait la proposition 1.1.*

Type de contrôle. Le risque $R(\hat{g}^*_{n,\mathcal{C}})$, donc l'erreur d'estimation $\mathcal{E}^{\mathcal{C}}_{\text{est}}(\hat{g}^*_{n,\mathcal{C}})$, sont des variables aléatoires, fonctions de $\mathcal{D}_n$. On peut chercher à les contrôler de deux façons :

1. en espérance, en majorant $\mathbb{E}[\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}})]$;
2. en *grande probabilité*, sous la forme

$$\mathbb{P}\left(\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}}) \leq \Delta_{n,\delta}(\mathcal{C})\right) \geq 1-\delta \,,$$

où $\Delta_{n,\delta}(\mathcal{C})$ dépend explicitement de la taille n de l'ensemble d'apprentissage $\mathcal{D}_n$, du niveau de confiance δ et de la classe.

Dans les deux cas, d'après le théorème 1.2, il faut étudier les *déviations uniformes* de variables aléatoires par rapport à leurs moyennes.

Contrôle des déviations uniformes, perte 0–1. On se restreint à la perte 0–1, pour laquelle

$$\widehat{\mathrm{R}}_n(g) = \frac{1}{n}\sum_{k=1}^{n} \mathbb{1}_{\{g(\mathbf{X}_k)\neq Y_k\}} \,.$$

L'objectif est de contrôler $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$, pour une classe $\mathcal{C}$ finie, en grande probabilité et en espérance. L'approche procède en deux temps.

1. Pour toute règle g fixée, la probabilité $\mathbb{P}(|\,\widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon)$ est faible : c'est une *inégalité de concentration*.
2. La *borne de l'union* donne

$$\mathbb{P}\left(\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon\right) \leq \sum_{g\in\mathcal{C}} \mathbb{P}\left(|\,\widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon\right) \,.$$

Inégalités de concentration : de Markov à Hoeffding

Une inégalité de concentration majore la probabilité qu'une variable aléatoire s'écarte de sa moyenne. Les plus simples sont celles de Markov et de Bienaymé-Tchebychev, rappelées à la Section 2.1 : si $Z \geq 0$, alors $\mathbb{P}(Z > t) \leq \mathbb{E}[Z]/t$ pour tout $t > 0$, ce qui implique, si Z est de variance finie, $\mathbb{P}(|Z - \mathbb{E}[Z]| \geq \varepsilon) \leq \mathrm{Var}(Z)/\varepsilon^2$. Si $X_1, \ldots, X_n$ sont indépendantes, de même loi et de carré intégrable, et si $Z = n^{-1}\sum_{i=1}^n X_i$, on a $\mathrm{Var}(Z) = \mathrm{Var}(X_1)/n$, d'où

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^{n} X_i - \mathbb{E}[X_1]\right| \geq \varepsilon\right) \leq \frac{\mathrm{Var}(X_1)}{n\varepsilon^2} \,.$$

Cette majoration décroît comme $1/n$. Lorsque les variables sont bornées, on dispose d'une majoration exponentielle en n.

Théorème 1.3: Inégalité de Hoeffding (outil fondamental)

Soient $X_1, \ldots, X_n$ des variables aléatoires indépendantes à valeurs dans $[0,1]$. Pour tout $\varepsilon > 0$,

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^{n} \{X_i - \mathbb{E}[X_i]\}\right| \geq \varepsilon\right) \leq 2\mathrm{e}^{-2n\varepsilon^2} \,,$$

et chacune des deux déviations unilatérales, $\mathbb{P}(n^{-1}\sum_{i=1}^n \{X_i - \mathbb{E}[X_i]\} \geq \varepsilon)$ et $\mathbb{P}(n^{-1}\sum_{i=1}^n \{X_i - \mathbb{E}[X_i]\} \leq -\varepsilon)$, est majorée par $\mathrm{e}^{-2n\varepsilon^2}$.

Ce théorème est le corollaire 2.1 de la Section 2.4, où il est démontré ; il complète l'énoncé admis au chapitre 4 (théorème 3.1).

Remarques.

— Il n'est pas besoin que les variables soient de même loi : il suffit qu'elles soient indépendantes.

— Le théorème s'étend à des variables $X_i \in [a_i, b_i]$: la majoration devient $2\exp\left(-2n^2\varepsilon^2 / \sum_{i=1}^n (b_i - a_i)^2\right)$.

— Il existe différentes écritures de cette inégalité, et il faut prendre garde à ne pas les confondre. Parmi les trois majorations $2\mathrm{e}^{-2n\varepsilon^2}$, $2\mathrm{e}^{-2\varepsilon^2/n}$ et $2\mathrm{e}^{-2n\varepsilon}$ de la probabilité ci-dessus, seule la première est la bonne. La deuxième est la majoration correcte pour la déviation de la *somme*, $\mathbb{P}(|\sum_{i=1}^n \{X_i - \mathbb{E}[X_i]\}| \geq \varepsilon)$; on retrouve la première en l'appliquant à $n\varepsilon$. La troisième est fausse : pour des variables de Bernoulli de paramètre $1/2$ et $\varepsilon = n^{-1/2}$, le théorème de la limite centrale (chapitre 6, théorème 1.6) montre que la probabilité tend vers $2(1 - \Phi(2)) > 0$, où Φ est la fonction de répartition de la loi $\mathcal{N}(0,1)$, tandis que $2\mathrm{e}^{-2\sqrt{n}}$ tend vers zéro.

L'inégalité de Hoeffding n'exploite *aucune* propriété de la distribution des variables $X_1, \ldots, X_n$ autre que leur support ; en particulier, la borne ne dépend pas de leur variance, et elle est la même pour toutes les distributions portées par l'intervalle $[0,1]$. Le fait que cette borne soit *agnostique* est désirable, comme on va le voir : la loi des pertes $\mathbb{1}_{\{g(\mathbf{X}_k) \neq Y_k\}}$ est inconnue, mais elle est portée par $\{0,1\}$. En contrepartie, pour certaines distributions, la moyenne empirique converge beaucoup plus vite vers son espérance que ne le prédit cette borne ; les inégalités de Bennett et de Bernstein, qui font intervenir la variance, permettent de raffiner ces résultats.

Intuition. *Pour une moyenne de n variables indépendantes de variance v, le théorème de la limite centrale suggère une probabilité de déviation de l'ordre de $\mathrm{e}^{-n\varepsilon^2/(2v)}$ pour ε petit et n grand. Une variable à valeurs dans $[0,1]$ a une variance au plus $1/4$, et l'exposant $2n\varepsilon^2 = n\varepsilon^2/(2 \cdot 1/4)$ de l'inégalité de Hoeffding est celui de ce comportement gaussien dans le pire cas. Ce rapprochement est heuristique : le théorème de la limite centrale est asymptotique et ne fournit aucune borne pour n fixé, alors que l'inégalité de Hoeffding en fournit une pour tout n.*

Structure de la preuve. La concentration se lit sur le contrôle des moments, et la preuve, détaillée à la Section 2.4 et reprise aux exercices 2 et 3 (PC9), comporte trois étapes.

1. *Borne de Chernoff.* Un contrôle de la fonction génératrice des moments $\mathbb{E}[\exp(\lambda Z)]$ entraîne la concentration. En particulier, si $\mathbb{E}[\exp(\lambda Z)] \leq \mathrm{e}^{\lambda^2\sigma^2/2}$ pour tout $\lambda \in \mathbb{R}$, la variable centrée Z est dite *sous-gaussienne*, et ses déviations sont majorées comme celles d'une loi $\mathcal{N}(0, \sigma^2)$.
2. *Lemme de Hoeffding.* Une variable aléatoire *bornée* et centrée est sous-gaussienne.
3. Si $Z = \sum_{i=1}^n X_i$ avec $X_1, \ldots, X_n$ indépendantes, alors $\mathbb{E}[\exp(\lambda Z)] = \prod_{i=1}^n \mathbb{E}[\exp(\lambda X_i)]$.

Lemme 1.1: Lemme de Hoeffding

Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace de probabilité et X une variable aléatoire réelle telle que $\mathbb{P}(X \in [a,b]) = 1$ et $\mathbb{E}[X] = 0$. Pour tout $\lambda \in \mathbb{R}$,

$$\mathbb{E}\left[\mathrm{e}^{\lambda X}\right] \leq \mathrm{e}^{\lambda^2 (b-a)^2/8} .$$

Écriture équivalente. L'inégalité de Hoeffding se lit aussi en fixant la probabilité d'échec plutôt que l'écart. On pose

$$\varepsilon = \sqrt{\frac{\ln(2/\delta)}{2n}} \quad \Longleftrightarrow \quad 2\mathrm{e}^{-2n\varepsilon^2} = \delta .$$

Théorème 1.4: Inégalité de Hoeffding, seconde écriture

Soient $X_1, \ldots, X_n$ des variables aléatoires indépendantes à valeurs dans $[0,1]$ et $\delta \in]0,1[$. Avec une probabilité supérieure à $1-\delta$,

$$\left| \frac{1}{n} \sum_{i=1}^{n} \{X_i - \mathbb{E}[X_i]\} \right| \leq \sqrt{\frac{\ln(2/\delta)}{2n}} \, .$$

Démonstration

Avec le choix de ε ci-dessus, le théorème 1.3 montre que l'événement contraire, $\{|n^{-1} \sum_{i=1}^{n} \{X_i - \mathbb{E}[X_i]\}| \geq \varepsilon\}$, a une probabilité au plus δ. □

Remarques.

— La *précision* ε est l'objectif que l'on se fixe sur la valeur absolue de la différence entre la moyenne empirique et l'espérance.

— La *confiance* δ est la borne de la probabilité avec laquelle on admet que la condition sur la précision ne soit pas satisfaite.

— Une fois ces deux paramètres choisis, le théorème donne le nombre d'observations suffisant : $n \geq \ln(2/\delta)/(2\varepsilon^2)$.

— La précision coûte cher : pour une confiance donnée, si l'on veut une précision dix fois meilleure, il faut multiplier le nombre d'observations par cent.

Application au contrôle du risque d'estimation

On combine maintenant l'inégalité de Hoeffding et la borne de l'union pour une classe finie de classifieurs, munie de la perte 0–1.

Théorème 1.5: Déviations uniformes sur une classe finie

On se place en classification avec la perte 0–1, et l'on suppose que $|\mathcal{C}| < \infty$. Pour tout $n \in \mathbb{N}^*$ et tout $\varepsilon > 0$,

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \left\{ \widehat{\mathrm{R}}_n(g) - R(g) \right\} > \varepsilon \right) \leq |\mathcal{C}| \, \mathrm{e}^{-2n\varepsilon^2} \, ,$$

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \left| \widehat{\mathrm{R}}_n(g) - R(g) \right| > \varepsilon \right) \leq 2\,|\mathcal{C}| \, \mathrm{e}^{-2n\varepsilon^2} \, .$$

Démonstration

Notons $\mathcal{C} = \{g_j\}_{j=1}^{|\mathcal{C}|}$. L'événement $\{\sup_{g \in \mathcal{C}} |\, \widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon\}$ est la réunion des événements $\{|\, \widehat{\mathrm{R}}_n(g_j) - R(g_j)| > \varepsilon\}$, et la borne de l'union (Section 2.6) donne

$$\mathbb{P}\left(\sup_{g \in \mathcal{C}} \left| \widehat{\mathrm{R}}_n(g) - R(g) \right| > \varepsilon \right) \leq \sum_{j=1}^{|\mathcal{C}|} \mathbb{P}\left(\left| \widehat{\mathrm{R}}_n(g_j) - R(g_j) \right| > \varepsilon \right) \, .$$

Pour chaque j, la règle g_j est fixée, et les variables $\mathbb{1}_{\{g_j(\mathbf{x}_k) \neq Y_k\}}$, $k = 1, \ldots, n$, sont indépendantes, à valeurs dans $\{0,1\}$, de loi de Bernoulli de paramètre $R(g_j)$; leur moyenne est $\widehat{\mathrm{R}}_n(g_j)$.

Le théorème 1.3 majore donc chaque terme par $2\mathrm{e}^{-2n\varepsilon^2}$, ce qui donne la seconde inégalité. La première s'obtient de la même façon, avec la déviation unilatérale, majorée par $\mathrm{e}^{-2n\varepsilon^2}$. □

On utilise ici la force de l'inégalité de Hoeffding, qui est valable pour toute distribution à support borné : la loi de Bernoulli de paramètre $R(g_j)$ est inconnue, mais la majoration n'en dépend pas, et elle est donc uniforme en j.

Conclusion : contrôle en grande probabilité en classification

Théorème 1.6: Contrôle en grande probabilité de l'erreur d'estimation

On suppose que la perte est à valeurs dans $[0,1]$, ce qui est le cas de la perte 0–1 en classification, et que la classe $\mathcal{C}$ est finie. Pour tout $\delta \in]0,1[$, avec une probabilité supérieure à $1-\delta$,

$$\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}}) = R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}}) \leq 2\sqrt{\frac{\log(2\,|\mathcal{C}|\,/\delta)}{2n}}\ .$$

Démonstration

D'après le théorème 1.2, $\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}}) \leq 2\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$ presque sûrement. Le théorème 1.5, dont la démonstration n'utilise que le fait que les pertes $\ell(Y_k, g(\mathbf{X}_k))$ sont indépendantes et à valeurs dans $[0,1]$ pour g fixée, donne, avec $\varepsilon = \sqrt{\log(2\,|\mathcal{C}|\,/\delta)/(2n)}$, de sorte que $2\,|\mathcal{C}|\,\mathrm{e}^{-2n\varepsilon^2} = \delta$,

$$\mathbb{P}\left(\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| \leq \sqrt{\frac{\log(2\,|\mathcal{C}|\,/\delta)}{2n}}\right) \geq 1-\delta\ .$$

Sur cet événement, $\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}}) \leq 2\sqrt{\log(2\,|\mathcal{C}|\,/\delta)/(2n)}$. □

Pour une perte bornée quelconque, à valeurs dans $[0,B]$, on applique le théorème à la perte ℓ/B : la borne est multipliée par B.

Remarques.

1. *Dépendance en $|\mathcal{C}|$.* La borne ne dépend de la taille de la classe qu'à travers $\log|\mathcal{C}|$. Cette dépendance logarithmique laisse l'espoir de généraliser le résultat à des classes infinies : par exemple, l'exercice 7 (PC9) montre que, pour les classifieurs linéaires en dimension d, on peut se limiter à une classe de cardinal au plus $2\binom{n}{d}$.
2. *Dépendance en n.* La borne décroît comme $1/\sqrt{n}$.

On a ainsi obtenu un contrôle en grande probabilité, du type $\mathbb{P}(\mathcal{E}^{\mathcal{C}}_{\mathrm{est}}(\hat{g}^*_{n,\mathcal{C}}) \leq \Delta_{n,\delta}(\mathcal{C})) \geq 1-\delta$; les éléments de preuve manquants, qui concernent l'inégalité de Hoeffding, font l'objet des exercices 2 et 3 (PC9). Restent deux questions : le contrôle en espérance et le contrôle pour une classe infinie.

Contrôle en espérance de l'erreur d'estimation

Le théorème 1.2 a établi

$$\mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})\right] \leq \mathbb{E}\left[\max_{g\in\mathcal{C}} \left|\widehat{\mathrm{R}}_n(g) - R(g)\right|\right]\ ,$$

le supremum étant un maximum puisque la classe est finie. Il reste à majorer l'espérance d'un maximum de variables aléatoires, ce que fait l'inégalité suivante pour des variables sous-gaussiennes.

Théorème 1.7: Inégalité de Pisier

Soient $Z_1, \dots, Z_m$ des variables aléatoires réelles sous-gaussiennes de même facteur σ^2, c'est-à-dire telles que, pour tout $\lambda \in \mathbb{R}$ et tout i,

$$\mathbb{E}\left[\mathrm{e}^{\lambda Z_i}\right] \leq \mathrm{e}^{\lambda^2\sigma^2/2} .$$

Alors

$$\mathbb{E}\left[\max_{1\leq i\leq m} |Z_i|\right] \leq \sigma\sqrt{2\log(2m)} .$$

La démonstration, qui fait l'objet de l'exercice 4 (PC9), est donnée dans les compléments (Section 4.4). Les variables n'ont pas à être indépendantes.

On l'applique aux variables $Z_j = \widehat{\mathrm{R}}_n(g_j) - R(g_j)$, $j \in \{1, \dots, |\mathcal{C}|\}$, pour la perte 0–1. Pour tout $\lambda \in \mathbb{R}$, par indépendance des couples $(\mathbf{X}_i, Y_i)$,

$$\mathbb{E}\left[\mathrm{e}^{\lambda Z_j}\right] = \mathbb{E}\left[\mathrm{e}^{(\lambda/n)\sum_{i=1}^n \{\mathbb{1}_{\{g_j(\mathbf{X}_i)\neq Y_i\}} - R(g_j)\}}\right] = \left(\mathbb{E}\left[\mathrm{e}^{(\lambda/n)\{\mathbb{1}_{\{g_j(\mathbf{X}_1)\neq Y_1\}} - R(g_j)\}}\right]\right)^n \leq \mathrm{e}^{\lambda^2/(8n)} ,$$

en utilisant le lemme de Hoeffding (lemme 1.1) pour la variable centrée $\mathbb{1}_{\{g_j(\mathbf{X}_1)\neq Y_1\}} - R(g_j)$, à valeurs dans l'intervalle $[-R(g_j), 1 - R(g_j)]$ de longueur 1 :

$$\mathbb{E}\left[\mathrm{e}^{(\lambda/n)\{\mathbb{1}_{\{g_j(\mathbf{X}_1)\neq Y_1\}} - R(g_j)\}}\right] \leq \mathrm{e}^{\lambda^2/(8n^2)} .$$

Les variables Z_j sont donc sous-gaussiennes de facteur $\sigma^2 = 1/(4n)$.

Théorème 1.8: Borne pour le risque intégré, ou borne en espérance

On se place en classification avec la perte 0–1, et l'on suppose que $|\mathcal{C}| < \infty$. Si $\hat{g}^*_{n,\mathcal{C}}$ est un minimiseur du risque empirique sur $\mathcal{C}$, alors

$$\mathbb{E}\left[R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})\right] \leq \sqrt{\frac{\log(2\,|\mathcal{C}|)}{2n}} .$$

Démonstration

On applique l'inégalité de Pisier avec $m = |\mathcal{C}|$ et $\sigma = 1/(2\sqrt{n})$: $\mathbb{E}[\max_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|] \leq (2\sqrt{n})^{-1}\sqrt{2\log(2\,|\mathcal{C}|)} = \sqrt{\log(2\,|\mathcal{C}|)/(2n)}$, et l'on conclut par (3). □

Extension à une classe infinie

Les bornes précédentes sont vides si la classe est infinie, ce qui est le cas de la plupart des classes utilisées en pratique. Pour les classifieurs linéaires en dimension d, qui sont ici des classifieurs affines, on peut cependant se ramener à une classe finie, de cardinal au plus $2\binom{n}{d}$, formée des classifieurs dont l'hyperplan séparateur passe par d points de l'ensemble d'apprentissage. La dépendance logarithmique en le cardinal donne alors une borne d'ordre

$$2\sqrt{\frac{\log(2\,|\mathcal{C}|\,/\delta)}{2n}} \simeq O\left(\sqrt{\frac{d\log(n)}{n}}\right) .$$

L'énoncé suivant précise ce résultat ; il est démontré dans les compléments (Section 4.6), à partir d'un lemme combinatoire admis, et c'est l'objet de l'exercice 7 (PC9).

Proposition 1.2: Classifieurs affines

On se place en classification binaire sur $\mathsf{X} = \mathbb{R}^d$, avec la perte 0–1, et l'on suppose que la loi de $\mathbf{X}$ admet une densité par rapport à la mesure de Lebesgue et que $n > d$. Soit

$$\mathcal{C} = \left\{ \mathbf{x} \mapsto 2\,\mathbb{1}_{\{\mathbf{a}^\top \mathbf{x} + b \geq 0\}} - 1 \,:\, (\mathbf{a}, b) \in \mathbb{R}^d \times \mathbb{R} \right\}$$

la classe des classifieurs affines, et $\widehat{g}_n$ un minimiseur du risque empirique sur la classe finie $\mathcal{C}_n \subset \mathcal{C}$, de cardinal au plus $2\binom{n}{d}$, des classifieurs dont l'hyperplan passe par d points de l'ensemble d'apprentissage (Section 4.6). Pour tout $\delta \in]0,1[$, avec une probabilité supérieure à $1-\delta$,

$$R(\widehat{g}_n) - \inf_{g \in \mathcal{C}} R(g) \leq \frac{2d}{n} + 2\sqrt{\frac{\log\left(\left(2\binom{n}{d} + 1\right)/\delta\right)}{2(n-d)}}\,.$$

Comme $\binom{n}{d} \leq n^d$, le membre de droite est, pour δ fixé et $n \geq 2d$, d'ordre $\sqrt{d\log(n)/n}$.

Résumé : contrôle de l'erreur d'estimation

Les trois questions, suite.

1. Comment choisir $\mathcal{C}$? Exemples en régression, décomposition en erreur d'approximation et erreur d'estimation, sur-apprentissage, théorème *no free lunch*, validation croisée : Section 1.2.
2. Comment contrôler l'erreur d'estimation $R(\hat{g}^*_{n,\mathcal{C}}) - R(g^*_{\mathcal{C}})$? On la majore par les déviations du processus empirique $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$. Pour la perte 0–1 et une classe $\mathcal{C}$ finie, les variables en jeu sont sous-gaussiennes : on obtient un contrôle en grande probabilité par l'inégalité de Hoeffding, un contrôle en espérance par l'inégalité de Pisier, et une extension à une classe infinie est possible.
3. Comment calculer $\hat{g}^*_{n,\mathcal{C}}$, et avec quelle précision ? C'est la question de la section suivante.

1.4 Décision douce et convexification du risque

La troisième question, celle du calcul du minimiseur, se pose dès que l'on quitte les classes finies. Pour la perte 0–1, elle est difficile, et l'on est conduit à remplacer cette perte par une perte convexe. On décrit ici cette relaxation, qui est le second moyen de contrôle annoncé en ouverture du chapitre.

En classification, minimiser le risque empirique est difficile

En classification avec la perte 0–1, le minimiseur du risque empirique est la solution du problème d'optimisation

$$\hat{g}^*_{n,\mathcal{C}} = \operatorname*{arg\,min}_{g\in\mathcal{C}} \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{\{Y_i \neq g(\mathbf{X}_i)\}}\,.$$

Le choix de la fonction de perte a ici une conséquence pratique : la perte 0–1 n'est ni différentiable, ni convexe, et le risque empirique, vu comme fonction des paramètres de la règle, est constant par morceaux. La minimisation du risque empirique est alors un problème combinatoire.

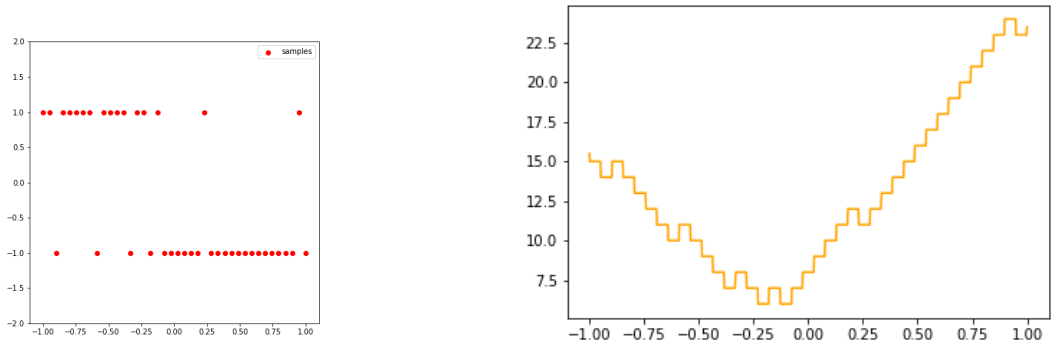


FIGURE 5 – À gauche, un ensemble d'apprentissage en classification binaire, avec un attribut réel. À droite, le nombre d'erreurs commises sur cet ensemble par une famille de règles indexée par un paramètre réel, en fonction de ce paramètre : la fonction est constante par morceaux, et ses minima sont des paliers.

Écriture en fonction de la marge

On prend les labels à valeurs dans $\mathsf{Y} = \{-1, 1\}$; le problème revient à trouver un classifieur $g : \mathsf{X} \to \{-1, 1\}$. Comme $g(\mathbf{X})Y$ vaut 1 si la prédiction est correcte et -1 sinon,

$$g(\mathbf{X}) \neq Y \quad \Longleftrightarrow \quad -g(\mathbf{X})Y > 0 \,,$$

et l'on peut réécrire la fonction objectif

$$\frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{\{g(\mathbf{X}_i)\neq Y_i\}} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}_{\{-g(\mathbf{X}_i)Y_i>0\}} = \frac{1}{n}\sum_{i=1}^{n} \varphi_{\mathbb{1}}(-g(\mathbf{X}_i)Y_i) \,, \qquad \text{avec} \quad \varphi_{\mathbb{1}} := \mathbb{1}_{[0,+\infty[} \,.$$

Les deux dernières écritures coïncident parce que $-g(\mathbf{X}_i)Y_i$ ne prend que les valeurs -1 et 1. Cette réécriture est appelée *spinning* dans le cours ; la quantité $Yg(\mathbf{X})$ est la *marge* de la prédiction.

Classifieur doux

L'écriture précédente garde un sens lorsque g prend des valeurs réelles quelconques, ce qui conduit à la définition suivante. On note $\text{signe}(t) = 2\,\text{heaviside}(t) - 1$, avec $\text{heaviside}(t) = 1$ si $t > 0$ et 0 sinon, comme au chapitre 8.

Définition 1.2: Classifieur doux

On appelle *classifieur doux* (*soft classifier*) toute fonction mesurable $h : \mathsf{X} \to \mathbb{R}$. Le classifieur *dur* (*hard classifier*) associé à h est $g = \text{signe}(h)$.

Exemple 1.2: Classifieurs doux linéaires

— Linéaire, ou affine : $h_\theta(\mathbf{x}) = \theta_0 + \sum_{i=1}^{d} \theta_i x^{(i)}$, pour $\mathbf{x} = (x^{(1)}, \ldots, x^{(d)})$.

— Linéaire généralisé : $h_\theta(\mathbf{x}) = \theta^\top \Phi(\mathbf{x})$, où Φ est une transformation du vecteur des attributs, par exemple

$$\Phi(\mathbf{x}) = \left[1, \{x^{(i)}\}_{i=1}^{d}, \{x^{(i)}x^{(j)}\}_{i,j=1}^{d}\right]^\top$$

ou

$$\Phi(\mathbf{x}) = \left[\psi_1(x^{(1)}), \psi_2(x^{(2)}), \ldots, \psi_d(x^{(d)})\right]^\top \,,$$

pour des fonctions réelles $\psi_1, \ldots, \psi_d$.

Pour un classifieur doux h, l'erreur du classifieur dur associé est contrôlée par la marge :

$$\mathbb{1}_{\{\text{signe}(h(\mathbf{x}))\neq y\}} \leq \varphi_{\mathbb{1}}(-y\,h(\mathbf{x}))\ , \qquad \mathbf{x}\in\mathsf{X}\ ,\ y\in\{-1,1\}\ . \tag{4}$$

En effet, si $\text{signe}(h(\mathbf{x}))\neq y$, alors ou bien $h(\mathbf{x})>0$ et $y=-1$, ou bien $h(\mathbf{x})\leq 0$ et $y=1$; dans les deux cas $-y\,h(\mathbf{x})\geq 0$. L'inégalité est une égalité, sauf lorsque $h(\mathbf{x})=0$ et $y=-1$.

Convexifier la perte

On remplace la perte 0–1 par une fonction φ convexe, croissante, telle que $\varphi(0)=1$ et $\varphi\geq\varphi_{\mathbb{1}}$, c'est-à-dire $\varphi(z)\geq\mathbb{1}_{\{z\geq 0\}}$ pour tout $z\in\mathbb{R}$. Pour une fonction croissante qui vaut 1 en 0, cette dernière condition se réduit à $\varphi\geq 0$ sur $]-\infty,0[$.

perte	$\varphi(z)$
0–1	$\mathbb{1}_{[0,+\infty[}(z)$
charnière (*hinge*)	$\max(1+z,0)$
exponentielle	$\exp(z)$
logistique	$\log_2(1+\exp(z))$
quadratique	$(z+1)^2$

Les pertes charnière, exponentielle et logistique remplissent toutes les conditions. La perte quadratique est convexe, vaut 1 en 0 et majore $\varphi_{\mathbb{1}}$, mais elle n'est pas croissante : elle décroît sur $]-\infty,-1]$, et pénalise donc aussi les prédictions correctes de grande marge.

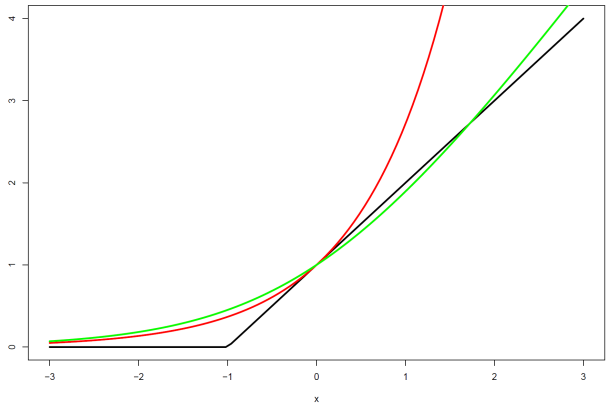


FIGURE 6 – Les pertes convexes charnière (en noir), exponentielle (en rouge) et logistique (en vert), en fonction de $z=-y\,h(\mathbf{x})$. Toutes valent 1 en 0 et majorent la perte 0–1.

Définition 1.3: φ-risque et φ-risque empirique

Soit φ une perte convexe comme ci-dessus. Le *φ-risque* d'un classifieur doux h est

$$R_\varphi(h) := \mathbb{E}\left[\varphi(-Y h(\mathbf{X}))\right]\ ,$$

et son *φ-risque empirique* est

$$\widehat{\mathrm{R}}_{n,\varphi}(h) := \frac{1}{n}\sum_{i=1}^{n}\varphi(-Y_i h(\mathbf{X}_i))\ .$$

Le φ-risque empirique est une approximation du φ-risque, au même sens que le risque empirique est une approximation du risque : pour h fixé tel que $R_\varphi(h) < \infty$, c'en est un estimateur sans biais et convergent. Il majore le risque 0–1 du classifieur dur associé.

Proposition 1.3: Le φ-risque majore le risque 0–1

Pour tout classifieur doux h,

$$\widehat{\mathrm{R}}_n(\mathrm{signe}(h)) \leq \widehat{\mathrm{R}}_{n,\varphi}(h) \qquad \text{et} \qquad R(\mathrm{signe}(h)) \leq R_\varphi(h)\ ,$$

où $\widehat{\mathrm{R}}_n$ et R désignent le risque empirique et le risque pour la perte 0–1.

Démonstration

D'après (4) et l'hypothèse $\varphi \geq \varphi_{\mathbb{1}}$, $\mathbb{1}_{\{\mathrm{signe}(h(\mathbf{x}))\neq y\}} \leq \varphi(-y\,h(\mathbf{x}))$ pour tous $\mathbf{x}$ et y. On applique cette inégalité aux couples $(\mathbf{X}_i, Y_i)$ et l'on moyenne, ou au couple $(\mathbf{X}, Y)$ et l'on prend l'espérance. □

Minimisation du risque empirique pour une perte générale

On cherche alors un classifieur doux h, dans une classe donnée, qui minimise le φ-risque empirique $\widehat{\mathrm{R}}_{n,\varphi}(h) = n^{-1}\sum_{i=1}^n \varphi(-Y_i h(\mathbf{X}_i))$, et l'on retient le classifieur dur $\mathrm{signe}(h)$.

Exemple 1.3: Cas logistique

Pour la perte logistique et la classe des classifieurs doux linéaires généralisés $h_\theta = \theta^\top \Phi(\cdot)$,

$$\widehat{\mathrm{R}}_{n,\varphi}(h_\theta) = \frac{1}{n}\sum_{i=1}^n \log_2\left(1 + \mathrm{e}^{-Y_i\theta^\top\Phi(\mathbf{X}_i)}\right)\ .$$

Cette fonction est convexe par rapport à θ : chaque terme est la composée de la fonction convexe φ et de la fonction linéaire $\theta \mapsto -Y_i\theta^\top\Phi(\mathbf{X}_i)$ (Section 2.7). On la minimise par des méthodes d'optimisation convexe : algorithme du gradient, algorithme de Newton. Avec $\Phi(\mathbf{x}) = \mathbf{x}$, ce critère est, au facteur $1/\log 2$ près, celui que minimise l'estimateur du maximum de vraisemblance du modèle logistique (chapitre 8, équation (12)) : les deux approches conduisent ici à la même règle.

Intuition. *La perte convexe remplace une fonction en escalier, sans pente exploitable, par une fonction convexe, dont tout minimum local est un minimum global et que les méthodes de gradient savent minimiser ; c'est ce qui rend le calcul possible. En contrepartie, elle ne compte plus seulement les erreurs : une erreur de grande marge coûte cher, et une prédiction correcte de faible marge coûte encore quelque chose. Le minimiseur du risque convexifié n'a donc aucune raison d'être celui du risque* 0–1*, et la figure ci-dessus montre qu'il peut en différer légèrement.*

Trois questions ouvertes

On a remplacé la perte 0–1 par une perte convexe, pour des raisons computationnelles. Cela soulève plusieurs questions, qui sont le sujet du chapitre suivant.

1. **Contrôle de l'écart entre R_φ et R.** Avoir un classifieur de faible risque logistique ou charnière garantit-il d'avoir un classifieur de faible risque 0–1 ? La proposition 1.3 répond dans un sens, en majorant le risque par le φ-risque, mais elle ne compare pas les excès de risque.

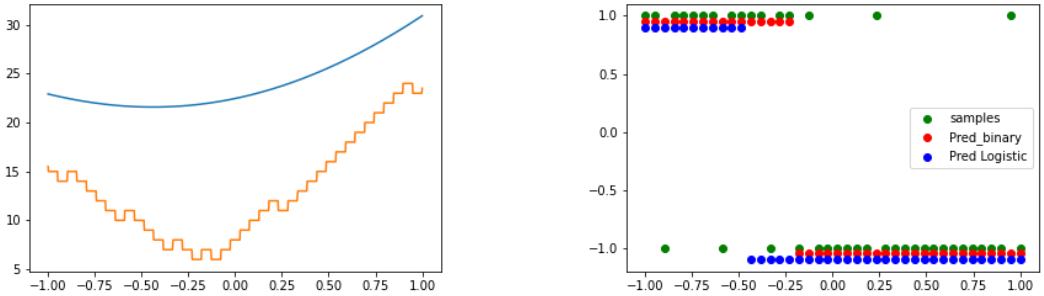


FIGURE 7 – Risque convexifié. À gauche, en fonction du paramètre réel d'une famille de règles, le nombre d'erreurs sur l'ensemble d'apprentissage (en orange, constant par morceaux) et la somme des pertes logistiques (en bleu, convexe). À droite, les labels observés (en vert) et les prédictions des règles qui minimisent le nombre d'erreurs (en rouge) et la perte logistique (en bleu) : les deux règles changent de label en des points voisins, mais distincts.

2. **Contrôle de l'erreur d'estimation** $R_\varphi(\hat{g}_{n,\mathcal{C},\varphi}) - R_\varphi(g^*_{\mathcal{C},\varphi})$**.** En pratique, on minimise une approximation empirique du risque convexifié sur une classe infinie de fonctions ; peut-on contrôler l'erreur d'estimation pour des classes infinies ?
3. **Contrôle de l'erreur d'optimisation.** En pratique, comment minimiser le risque convexifié, et avec quelle précision ?

1.5 Le programme des exercices

La feuille de ce chapitre comporte sept exercices.

— L'exercice 1 étudie l'erreur de validation $\widehat{R}_{n,m}$ d'une règle g_n construite sur $\mathcal{D}_n$, calculée sur m couples indépendants de $\mathcal{D}_n$. On y montre que $\mathbb{E}\left[\widehat{R}_{n,m}\,\middle|\,\mathcal{D}_n\right] = R(g_n)$, que $m\widehat{R}_{n,m}$ suit, conditionnellement à $\mathcal{D}_n$, une loi binomiale de paramètres m et $R(g_n)$, et l'on en tire deux majorations de $\mathbb{P}(|\widehat{R}_{n,m} - R(g_n)| \geq \varepsilon)$, par l'inégalité de Bienaymé-Tchebychev puis par celle de Hoeffding.

— L'exercice 2 introduit les variables sous-gaussiennes de facteur v : la loi $\mathcal{N}(0, v)$ et la loi de Rademacher en sont des exemples, la classe est stable par somme de variables indépendantes, et l'inégalité de Chernoff donne $\mathbb{P}(X > t) \vee \mathbb{P}(-X > t) \leq \mathrm{e}^{-t^2/(2v)}$.

— L'exercice 3 démontre le lemme de Hoeffding par l'étude de la fonction génératrice des cumulants ψ_X, dont la dérivée seconde est la variance d'une loi modifiée, et en déduit l'inégalité de Hoeffding pour une somme de variables indépendantes bornées.

— L'exercice 4 démontre l'inégalité de Pisier, en déduit la borne en espérance du théorème 1.8, puis l'applique à la classe de toutes les règles lorsque l'ensemble des attributs est fini, de cardinal K : l'excès de risque moyen du minimiseur du risque empirique est alors d'ordre $\sqrt{K/n}$.

— L'exercice 5 applique l'inégalité de Hoeffding à l'estimation, par un sous-échantillon tiré uniformément, de la proportion des points d'un ensemble fini qui tombent dans un hyper-rectangle, puis rend l'estimation uniforme sur tous les hyper-rectangles en se ramenant à une famille finie déterminée par l'échantillon.

— L'exercice 6 démontre le théorème *no free lunch* (théorème 1.1) lorsque l'ensemble des attributs est infini, en moyennant sur tous les étiquetages d'un ensemble de K points.

— L'exercice 7 traite les classifieurs par hyperplan : expression de leur risque à l'aide des fonctions de répartition conditionnelles de $\mathbf{a}^\top \mathbf{X}$, réduction à au plus $2\binom{n}{d}$ classifieurs passant

par d points de l'ensemble d'apprentissage, et bornes en probabilité et en espérance de l'excès de risque, qui sont celles de la proposition 1.2.