2 Les outils mathématiques

On rassemble ici les inégalités de concentration employées dans les fondamentaux. On part des inégalités de Markov et de Bienaymé-Tchebychev, on en tire les bornes de Chernoff, qui ramènent une probabilité de déviation à la fonction génératrice des moments, et l'on démontre le lemme puis l'inégalité de Hoeffding, dont le chapitre 4 avait admis l'énoncé. Viennent ensuite les outils plus élémentaires que les fondamentaux utilisent : la borne de l'union, la convexité et le calcul d'un risque à règle apprise fixée.

2.1 Inégalités de Markov et de Bienaymé-Tchebychev

Ces deux inégalités ont été établies au chapitre 2 (proposition 2.1) et rappelées au chapitre 6 (lemme 2.1) : si Z est une variable aléatoire positive, alors $\mathbb{P}(Z \geq t) \leq \mathbb{E}[Z]/t$ pour tout $t > 0$, et si W est de carré intégrable, $\mathbb{P}(|W - \mathbb{E}[W]| \geq \varepsilon) \leq \mathrm{Var}(W)/\varepsilon^2$ pour tout $\varepsilon > 0$. La première se déduit de l'inégalité $t\,\mathbb{1}_{\{Z \geq t\}} \leq Z$, et la seconde de la première, appliquée à $(W - \mathbb{E}[W])^2$. Comme $\{Z > t\} \subset \{Z \geq t\}$, la majoration vaut aussi pour $\mathbb{P}(Z > t)$, forme employée dans le deck.

2.2 Bornes de Chernoff

L'inégalité de Bienaymé-Tchebychev donne, pour une moyenne de n variables indépendantes de même loi, une majoration en $1/n$. On attend mieux.

Intuition. *Le théorème de la limite centrale (chapitre 6, théorème 1.6) montre que, pour des variables indépendantes de même loi et de variance $v = \mathrm{Var}(X_1)$ finie et non nulle,*

$$\lim_{n\to\infty} \mathbb{P}\left(\sum_{i=1}^{n} X_i - n\mathbb{E}[X_1] > \varepsilon\sqrt{n}\right) = 1 - \Phi\left(\varepsilon/\sqrt{v}\right) \leq \mathrm{e}^{-\varepsilon^2/(2v)} \,,$$

où Φ est la fonction de répartition de la loi $\mathcal{N}(0,1)$ et où la dernière inégalité, valable pour $\varepsilon \geq 0$, est une majoration classique de la queue gaussienne. On s'attend donc à une décroissance exponentielle en ε^2/v. Ce n'est qu'une indication : la limite ne dit rien pour n fixé, et c'est ce que les bornes qui suivent apportent.

L'idée est d'utiliser l'inégalité de Markov de façon plus astucieuse, en l'appliquant à une exponentielle.

Proposition 2.1: Borne de Chernoff

Soit Z une variable aléatoire réelle intégrable. Pour tout $\varepsilon > 0$ et tout $\lambda > 0$ tel que $\mathbb{E}[\mathrm{e}^{\lambda Z}] < \infty$,

$$\mathbb{P}\left(Z - \mathbb{E}[Z] \geq \varepsilon\right) \leq \frac{\mathbb{E}\left[\mathrm{e}^{\lambda(Z - \mathbb{E}[Z])}\right]}{\mathrm{e}^{\lambda\varepsilon}} \,.$$

En notant $\psi(\lambda) = \log \mathbb{E}[\mathrm{e}^{\lambda(Z-\mathbb{E}[Z])}]$, on a donc $\mathbb{P}(Z - \mathbb{E}[Z] \geq \varepsilon) \leq \exp\left(-\sup_{\lambda>0}\{\lambda\varepsilon - \psi(\lambda)\}\right)$.

Démonstration

La fonction $t \mapsto \mathrm{e}^{\lambda t}$ est strictement croissante, donc $\{Z - \mathbb{E}[Z] \geq \varepsilon\} = \{\mathrm{e}^{\lambda(Z-\mathbb{E}[Z])} \geq \mathrm{e}^{\lambda\varepsilon}\}$, et l'inégalité de Markov, appliquée à la variable positive $\mathrm{e}^{\lambda(Z-\mathbb{E}[Z])}$, donne la première majoration. La seconde s'obtient en passant à l'infimum sur λ. □

L'étape suivante est d'obtenir une borne pour la transformée de Laplace, ou fonction génératrice des moments, $\mathbb{E}[\mathrm{e}^{\lambda(Z-\mathbb{E}[Z])}]$, puis d'optimiser en λ. Lorsque $Z = \sum_{i=1}^{n} X_i$ est une somme de

variables aléatoires *indépendantes* telles que $\mathbb{E}[e^{\lambda X_i}] < \infty$, les variables $e^{\lambda(X_i - \mathbb{E}[X_i])}$ sont indépendantes et

$$\mathbb{E}\left[e^{\lambda(Z-\mathbb{E}[Z])}\right] = \prod_{i=1}^{n} \mathbb{E}\left[e^{\lambda(X_i-\mathbb{E}[X_i])}\right] ,$$

de sorte qu'il suffit de borner chacun des facteurs ; si les variables sont de même loi, le membre de droite vaut $(\mathbb{E}[e^{\lambda(X_1-\mathbb{E}[X_1])}])^n$. Le chapitre 4 a présenté ces bornes sous le nom d'inégalités de Chernoff (Section 5).

2.3 Variables sous-gaussiennes

Les variables dont la transformée de Laplace est dominée par celle d'une loi gaussienne se concentrent comme une loi gaussienne. C'est le cadre de l'exercice 2 (PC9).

Définition 2.1: Variable sous-gaussienne

Une variable aléatoire réelle centrée X est dite *sous-gaussienne de facteur de variance* $v > 0$ si

$$\psi_X(\lambda) := \log \mathbb{E}\left[e^{\lambda X}\right] \le \frac{\lambda^2 v}{2} \qquad \text{pour tout } \lambda \in \mathbb{R} .$$

On note $\mathcal{G}(v)$ l'ensemble de ces variables. La fonction $\lambda \mapsto \mathbb{E}[e^{\lambda X}]$ est la transformée de Laplace de X, et ψ_X sa fonction génératrice des cumulants.

Cette définition n'exige pas que la variance de X soit égale à v, mais seulement qu'elle soit majorée par v. Une variable gaussienne centrée de variance v appartient à $\mathcal{G}(v)$, et une variable de Rademacher, uniforme sur $\{-1, 1\}$, appartient à $\mathcal{G}(1)$; ce sont les deux premières questions de l'exercice 2.

Proposition 2.2: Somme et déviations de variables sous-gaussiennes

(i) Si $X_1, \dots, X_n$ sont indépendantes et $X_i \in \mathcal{G}(v_i)$ pour tout i, alors $\sum_{i=1}^n X_i \in \mathcal{G}(\sum_{i=1}^n v_i)$.

(ii) Si $X \in \mathcal{G}(v)$, alors, pour tout $t > 0$, $\mathbb{P}(X \ge t) \le e^{-t^2/(2v)}$ et $\mathbb{P}(-X \ge t) \le e^{-t^2/(2v)}$.

Démonstration

(i) Une somme de variables centrées est centrée, et, par indépendance, $\psi_{\sum_i X_i}(\lambda) = \sum_{i=1}^n \psi_{X_i}(\lambda) \le \lambda^2 \sum_{i=1}^n v_i/2$.
(ii) La borne de Chernoff donne, pour tout $\lambda > 0$, $\mathbb{P}(X \ge t) \le \exp(-\lambda t + \lambda^2 v/2)$. Le minimum en λ du membre de droite est atteint en $\lambda = t/v$ et vaut $e^{-t^2/(2v)}$. Comme $\psi_{-X}(\lambda) = \psi_X(-\lambda)$, la variable $-X$ appartient aussi à $\mathcal{G}(v)$, d'où la seconde majoration. □

2.4 Le lemme et l'inégalité de Hoeffding

Le lemme de Hoeffding (lemme 1.1) dit qu'une variable aléatoire bornée et centrée est sous-gaussienne. On le démontre par l'argument de Herbst : on étudie le logarithme de la transformée de Laplace, on majore sa dérivée seconde, et l'on intègre deux fois. Il en existe des démonstrations alternatives, fondées sur la convexité de $x \mapsto e^{\lambda x}$ et sur la fonction cosinus hyperbolique ; l'argument de Herbst a l'intérêt de s'étendre à des inégalités plus fines, dites de log-Sobolev, en établissant une inégalité différentielle que l'on intègre à la façon du lemme de Gronwall.

Démonstration

Soit X à valeurs dans $[a,b]$ presque sûrement, centrée. Pour tout $\lambda \in \mathbb{R}$, $\mathrm{e}^{\lambda X}$ est bornée, donc $\psi(\lambda) := \log \mathbb{E}[\mathrm{e}^{\lambda X}]$ est bien définie. Pour $k \in \{0,1,2\}$ et λ dans un intervalle borné $[-L,L]$, la dérivée k-ième en λ de $\mathrm{e}^{\lambda X}$ est $X^k \mathrm{e}^{\lambda X}$, dominée par la constante $M^k \mathrm{e}^{LM}$, où $M = \max(|a|,|b|)$; le théorème de dérivation sous le signe intégral (chapitre 3, proposition 2.2) montre que $\lambda \mapsto \mathbb{E}[\mathrm{e}^{\lambda X}]$ est deux fois dérivable, de dérivées $\mathbb{E}[X\mathrm{e}^{\lambda X}]$ et $\mathbb{E}[X^2\mathrm{e}^{\lambda X}]$. Il vient

$$\psi'(\lambda) = \frac{\mathbb{E}[X\mathrm{e}^{\lambda X}]}{\mathbb{E}[\mathrm{e}^{\lambda X}]} ,$$

et

$$\begin{aligned}\psi''(\lambda) &= \frac{\mathbb{E}[X^2\mathrm{e}^{\lambda X}]\,\mathbb{E}[\mathrm{e}^{\lambda X}] - \mathbb{E}[X\mathrm{e}^{\lambda X}]^2}{\mathbb{E}[\mathrm{e}^{\lambda X}]^2} \\ &= \mathbb{E}\left[X^2 \frac{\mathrm{e}^{\lambda X}}{\mathbb{E}[\mathrm{e}^{\lambda X}]}\right] - \left(\mathbb{E}\left[X \frac{\mathrm{e}^{\lambda X}}{\mathbb{E}[\mathrm{e}^{\lambda X}]}\right]\right)^2 .\end{aligned}$$

Notons $\widetilde{\mathbb{P}}_\lambda$ la probabilité de densité $\mathrm{e}^{\lambda X}/\mathbb{E}[\mathrm{e}^{\lambda X}]$ par rapport à $\mathbb{P}$. La formule précédente montre que $\psi''(\lambda)$ est la variance de X sous $\widetilde{\mathbb{P}}_\lambda$. Comme $\widetilde{\mathbb{P}}_\lambda$ est absolument continue par rapport à $\mathbb{P}$, on a $X \in [a,b]$, $\widetilde{\mathbb{P}}_\lambda$-presque sûrement. La variance étant le minimum en c de $\widetilde{\mathbb{E}}_\lambda[(X-c)^2]$,

$$\psi''(\lambda) = \widetilde{\mathrm{Var}}_\lambda(X) \le \widetilde{\mathbb{E}}_\lambda\left[\left(X - \frac{a+b}{2}\right)^2\right] \le \frac{(b-a)^2}{4} ,$$

puisque $|X-(a+b)/2| \le (b-a)/2$ presque sûrement. Enfin $\psi(0) = 0$ et $\psi'(0) = \mathbb{E}[X] = 0$, et la formule de Taylor-Lagrange à l'ordre deux donne, pour un ξ compris entre 0 et λ,

$$\psi(\lambda) = \psi(0) + \lambda\psi'(0) + \frac{\lambda^2}{2}\psi''(\xi) \le \frac{\lambda^2(b-a)^2}{8} ,$$

ce qui est l'inégalité annoncée. □

Le lemme s'énonce aussi sans hypothèse de centrage : si $X \in [a,b]$ presque sûrement, la variable $X - \mathbb{E}[X]$ est centrée et à valeurs dans l'intervalle $[a-\mathbb{E}[X], b-\mathbb{E}[X]]$, de même longueur $b-a$, de sorte que $\psi_X(\lambda) \le \lambda\mathbb{E}[X] + \lambda^2(b-a)^2/8$; c'est la forme de l'exercice 3 (PC9).

Théorème 2.1: Inégalité de Hoeffding, variables bornées

Soient $X_1, \dots, X_n$ des variables aléatoires réelles indépendantes telles que $X_i \in [a_i, b_i]$ presque sûrement, avec $a_i < b_i$. Posons $S_n := \sum_{i=1}^n \{X_i - \mathbb{E}[X_i]\}$ et $D_n := \sum_{i=1}^n (b_i - a_i)^2$. Pour tout $t > 0$,

$$\mathbb{P}(S_n \ge t) \le \mathrm{e}^{-2t^2/D_n} \qquad \text{et} \qquad \mathbb{P}(S_n \le -t) \le \mathrm{e}^{-2t^2/D_n} .$$

Démonstration

Les variables $X_i - \mathbb{E}[X_i]$ sont indépendantes, centrées et à valeurs dans des intervalles de longueurs $b_i - a_i$; par le lemme de Hoeffding, $X_i - \mathbb{E}[X_i] \in \mathcal{G}((b_i-a_i)^2/4)$. La proposition 2.2 (i) donne $S_n \in \mathcal{G}(D_n/4)$, et (ii) donne $\mathbb{P}(S_n \ge t) \le \mathrm{e}^{-t^2/(2D_n/4)} = \mathrm{e}^{-2t^2/D_n}$, ainsi que la même majoration pour $\mathbb{P}(-S_n \ge t)$. □

La démonstration du deck procède sans passer par la notion de variable sous-gaussienne : pour des variables à valeurs dans $[0,1]$, la borne de Chernoff et le lemme de Hoeffding donnent

$\mathbb{P}(S_n \geq t) \leq \mathrm{e}^{-\lambda t + n\lambda^2/8}$ pour tout $\lambda > 0$; le minimum en λ de l'exposant est atteint en $\lambda = 4t/n$ et vaut $-2t^2/n$.

Corollaire 2.1: Moyenne de variables à valeurs dans $[0,1]$

Soient $X_1, \ldots, X_n$ des variables aléatoires indépendantes à valeurs dans $[0,1]$. Pour tout $\varepsilon > 0$,

$$\mathbb{P}\left(\frac{1}{n}\sum_{i=1}^{n}\{X_i - \mathbb{E}[X_i]\} \geq \varepsilon\right) \leq \mathrm{e}^{-2n\varepsilon^2} ,$$

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{i=1}^{n}\{X_i - \mathbb{E}[X_i]\}\right| \geq \varepsilon\right) \leq 2\mathrm{e}^{-2n\varepsilon^2} .$$

Démonstration

On applique le théorème 2.1 avec $a_i = 0$, $b_i = 1$, donc $D_n = n$, et $t = n\varepsilon$: chacune des deux déviations unilatérales a une probabilité au plus $\mathrm{e}^{-2n^2\varepsilon^2/n} = \mathrm{e}^{-2n\varepsilon^2}$, et la sous-additivité de $\mathbb{P}$ donne la seconde majoration. C'est l'application de la borne de Chernoff et du lemme de Hoeffding aux variables X_i et $1 - X_i$ que décrit le deck. □

Le théorème 2.1 est le théorème 3.1 du chapitre 4, qui y était admis, et le corollaire est le théorème 1.3 des fondamentaux.

2.5 L'inégalité de Hoeffding pour une loi de Bernoulli

Pour des variables $Z_1, \ldots, Z_n$ indépendantes de loi de Bernoulli de paramètre p, on peut comparer la borne $2\mathrm{e}^{-2n\varepsilon^2}$ à la probabilité $\mathbb{P}(|n^{-1}\sum_{i=1}^{n} Z_i - p| > \varepsilon)$, que l'on calcule sans approximation puisque $\sum_{i=1}^{n} Z_i$ suit une loi binomiale de paramètres n et p. La figure 8 montre la comparaison pour deux valeurs de ε et deux valeurs de p.

La borne est d'autant plus pessimiste que p est loin de $1/2$: la variance $p(1-p)$ est alors petite, et l'inégalité de Hoeffding, qui ne la voit pas, la remplace par son maximum $1/4$. C'est ce que les inégalités de Bennett et de Bernstein corrigent.

2.6 La borne de l'union

Pour toute suite finie ou dénombrable d'événements (A_j),

$$\mathbb{P}\left(\bigcup_j A_j\right) \leq \sum_j \mathbb{P}(A_j) .$$

C'est la sous-additivité d'une mesure : on écrit la réunion comme la réunion disjointe des $B_j = A_j \setminus \bigcup_{k<j} A_k$, et l'on utilise $B_j \subset A_j$. Appliquée aux événements $A_g = \{|\,\widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon\}$, $g \in \mathcal{C}$, elle donne

$$\mathbb{P}\left(\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)| > \varepsilon\right) = \mathbb{P}\left(\bigcup_{g\in\mathcal{C}} A_g\right) \leq \sum_{g\in\mathcal{C}} \mathbb{P}(A_g) .$$

La borne ne suppose aucune indépendance entre les événements, ce qui importe ici : les risques empiriques des différentes règles sont calculés sur le même échantillon, et ils sont dépendants.

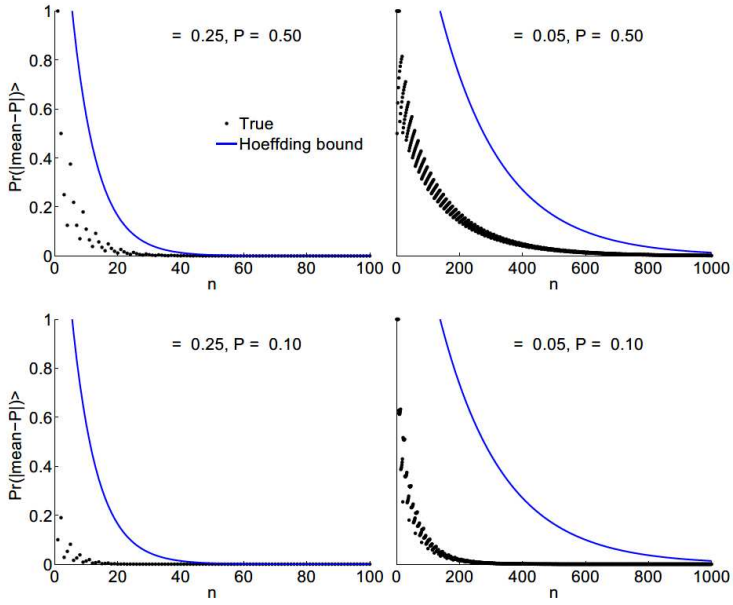


FIGURE 8 – La borne de Hoeffding $2\mathrm{e}^{-2n\varepsilon^2}$ (en bleu) et la probabilité $\mathbb{P}(|n^{-1}\sum_{i=1}^n Z_i - p| > \varepsilon)$ calculée par la loi binomiale (points noirs), en fonction de n, pour des variables de Bernoulli de paramètre p. En haut $p = 0{,}5$, en bas $p = 0{,}1$; à gauche $\varepsilon = 0{,}25$, à droite $\varepsilon = 0{,}05$. Le symbole ε manque dans les titres des quatre panneaux.

2.7 Convexité

Une fonction $\varphi : \mathbb{R} \to \mathbb{R}$ est convexe si $\varphi(tz+(1-t)z') \leq t\varphi(z)+(1-t)\varphi(z')$ pour tous $z, z' \in \mathbb{R}$ et $t \in [0,1]$. Le chapitre 2 en a rappelé la propriété de droite d'appui (lemme 2.2) et l'inégalité de Jensen (théorème 2.2). On utilise ici deux propriétés de stabilité, qui se vérifient directement sur la définition.

— Si $\varphi : \mathbb{R} \to \mathbb{R}$ est convexe et $A : \mathbb{R}^p \to \mathbb{R}$ est affine, alors $\varphi \circ A$ est convexe sur $\mathbb{R}^p$: comme $A(t\theta + (1-t)\theta') = tA(\theta) + (1-t)A(\theta')$, l'inégalité de convexité de φ s'applique.

— Une combinaison linéaire à coefficients positifs de fonctions convexes est convexe.

Le φ-risque empirique d'un classifieur doux linéaire généralisé, $\theta \mapsto n^{-1}\sum_{i=1}^n \varphi(-Y_i\theta^\top\Phi(\mathbf{X}_i))$, est donc une fonction convexe de θ dès que φ est convexe. Les pertes charnière, exponentielle, logistique et quadratique du tableau de la Section 1.4 sont convexes : la première est le maximum de deux fonctions affines, les trois autres ont une dérivée seconde positive (e^z, $\mathrm{e}^z/((1+\mathrm{e}^z)^2\log 2)$ et 2).

2.8 Le risque d'une règle apprise

Le risque d'une règle apprise, $R(\widehat{g}_n) = \mathbb{E}\left[\ell(Y, \widehat{g}_n(\mathbf{X})) \,|\, \mathcal{D}_n\right]$, est une espérance conditionnelle, et tous les calculs du chapitre l'évaluent en « gelant » l'ensemble d'apprentissage. C'est la proposition 2.5 du chapitre 8 : si U et V sont indépendantes et f est mesurable positive ou bornée, alors $\mathbb{E}\left[f(U,V) \,|\, V\right] = F(V)$ avec $F(v) = \mathbb{E}[f(U,v)]$. Appliquée à $U = (\mathbf{X}, Y)$ et $V = \mathcal{D}_n$, elle donne $R(\widehat{g}_n) = r(\mathcal{D}_n)$, où $r(d)$ est le risque de la règle fixée $\widehat{g}(\cdot\,; d)$. On l'emploie dans la proposition 1.1, dans l'exercice 1 (PC9) et dans les démonstrations des compléments.

2.9 Les résultats antérieurs mobilisés

Les énoncés suivants sont employés tels quels.

— Du chapitre 2 : les inégalités de Markov et de Bienaymé-Tchebychev (proposition 2.1), la droite d'appui d'une fonction convexe et l'inégalité de Jensen (lemme 2.2, théorème 2.2), cette dernière étant employée dans la démonstration de l'inégalité de Pisier.

— Du chapitre 3 : la dérivation sous le signe intégral (proposition 2.2), dans la démonstration du lemme de Hoeffding.

— Du chapitre 4 : l'énoncé de l'inégalité de Hoeffding (théorème 3.1), démontré ici, et les inégalités de Chernoff (Section 5).

— Du chapitre 6 : le théorème de la limite centrale (théorème 1.6), qui n'intervient que dans des remarques et des blocs d'intuition.

— Du chapitre 7 : la loi faible des grands nombres pour des variables indépendantes de même loi intégrables (théorème 2.1). La loi des grands nombres uniforme du même chapitre (théorème 1.2) porte sur le même type d'objet que le supremum $\sup_{g\in\mathcal{C}} |\,\widehat{\mathrm{R}}_n(g) - R(g)|$, une déviation uniforme sur une famille indexée par un paramètre.

— Du chapitre 8 : le cadre de l'apprentissage supervisé (cadre 1.1), la perte, le risque et le risque bayésien (définitions 1.2, 1.3 et 1.4), le prédicteur et le classifieur bayésiens (théorèmes 1.1 et 1.2), le modèle logistique et son estimateur du maximum de vraisemblance (Section 1.3), la probabilité d'erreur conditionnelle et le risque moyen (Section 4.4), et la propriété de conditionnement par une variable indépendante (proposition 2.5).

2.10 Les résultats admis

Trois énoncés sont utilisés sans être démontrés ici.

— L'existence d'un minimiseur du risque empirique et la possibilité de le choisir de façon mesurable en les données, supposées au début de la Section 1.2 ; elles sont immédiates pour une classe finie.

— Le lemme combinatoire sur les classifieurs affines employé à la Section 4.6 (lemme 4.2), admis dans l'exercice 7 (PC9).

— La majoration de la queue gaussienne $1 - \Phi(x) \leq \mathrm{e}^{-x^2/2}$ pour $x \geq 0$, qui n'intervient que dans un bloc d'intuition.